

Teil II: Eindimensionale Verteilungen und ihre Eigenschaften

Kapitel 5

Verteilungsfunktion

5. Verteilungsfunktion

5.1 Definition und Beispiele

5.2 Eigenschaften

5.3 Korrespondenzsatz

5.4 Median und Quantile

5.5 Lebensdauermodelle



Lernziele

- ▶ Verteilung ist das Bildmaß $\mathbb{P}_X$ einer meßbaren Zufallsvariable $X : \Omega_1 \rightarrow \Omega_2$.
- ▶ Wie können wir Verteilungen definieren?

Zuerst: Verteilungsfunktion

- ▶ Eigenschaften
- ▶ Eindeutigkeit (Verteilungsfunktion enthält dieselbe Information wie das Maß)

5. Verteilungsfunktion

5.1 Definition und Beispiele

5.2 Eigenschaften

5.3 Korrespondenzsatz

5.4 Median und Quantile

5.5 Lebensdauermodelle

Verteilungsfunktion

Definition (Verteilungsfunktion)

Ist $\mathbb{P} : \mathcal{B} \rightarrow [0, 1]$ ein Wahrscheinlichkeitsmaß auf $(\mathbb{R}, \mathcal{B})$, so heißt

$$\begin{aligned} F_{\mathbb{P}} : \mathbb{R} &\rightarrow [0, 1] \\ x &\mapsto F_{\mathbb{P}}(x) := \mathbb{P}(]-\infty, x]) \end{aligned}$$

die Verteilungsfunktion (engl. **cumulative distribution function, cdf**) von $\mathbb{P}$.

Anmerkungen

- ▶ Die Definition ist allgemein, insbesondere aber auch für Verteilungen von reellen Zufallsvariablen
- ▶ Um eine Verteilungsfunktion definieren zu können, muss der Maßraum $(\mathbb{R}, \mathcal{B})$ benutzt werden, auch wenn z.B. $\mathbb{N}$ als Ergebnisraum reichen würde.

Beispiele I

Beispiel 5.1 (Binomialverteilung)

n -facher Münzwurf, Anzahl der Würfe mit „Zahl“. Es gilt, siehe Def. 4.11

$$\mathbb{P}(\{k\}) = \binom{n}{k} p^k (1-p)^{n-k} I_{\{0, \dots, n\}}(k) \quad \forall k \in \mathbb{R}$$

Damit:

$$F(x) = \mathbb{P}([-\infty, x]) = \sum_{k=0}^{\lfloor x \rfloor} \binom{n}{k} p^k (1-p)^{n-k}$$

Beispiele II




Abbildung 2: Verteilungsfunktion $B(10, 0.3)$

Beispiele III

Beispiel 5.2 (Stetige Gleichverteilung)

Idee der Gleichverteilung (*Prinzip von unzureichenden Grund* nach Laplace), siehe Def. 3.20: Jedes Intervall $]c, d[$ gleicher Länge $d - c$ im Intervall $[a, b]$ ist gleich wahrscheinlich. Damit z.B. für $a = 0, b = 1$:

$$F(x) = \mathbb{P}(]-\infty, x]) = \begin{cases} 0 & \text{für } x < 0 \\ x & \text{für } 0 \leq x \leq 1 \\ 1 & \text{für } x > 1 \end{cases}$$

Beispiele IV




Abbildung 3: Verteilungsfunktion von $U[0,1]$

Benfordsches Gesetz I

Newcomb (1835–1909) und später Frank Benford (1883–1948) machten die verblüffende Entdeckung, dass die Anfangsziffern 1–9 von ganzen Zahlen in vielen Fällen nicht gleich häufig vorkommen. Am häufigsten ist die Anfangsziffer 1, am zweithäufigsten die Anfangsziffer 2 usw. Beispiele sind

- ▶ die Häufigkeit der Anfangsziffern von Zahlen in Zeitungsartikeln
- ▶ die Häufigkeit der Anfangsziffern von Steuerelementen
- ▶ die Häufigkeit der ersten Ziffer der Dateigröße von gespeicherten Dateien.

Benford publizierte für die Zufallsvariable die Wahrscheinlichkeitsfunktion

$$P(X = x) = \log_{10} \left(\frac{x+1}{x} \right) \cdot I_{\{1, \dots, 9\}}(x)$$

Benfords Gesetz findet zum Beispiel Anwendung bei der Fahndung nach Steuerbetrüchern, bei der Überprüfung von Wahlergebnissen.

Benfordsches Gesetz II




Abbildung 4: Wahrscheinlichkeit nach dem Benfordschen Gesetz

Benfordsches Gesetz III




Abbildung 5: Verteilungsfunktion Benfordsches Gesetz

5. Verteilungsfunktion

5.1 Definition und Beispiele

5.2 Eigenschaften

5.3 Korrespondenzsatz

5.4 Median und Quantile

5.5 Lebensdauermodelle

Eigenschaften der Verteilungsfunktion I

Satz (Eigenschaften der Verteilungsfunktion)

Eine Verteilungsfunktion $F_{\mathbb{P}}$ ist

- i) *monoton wachsend,*
- ii) *rechtsstetig,*
- iii) *und es gilt $\lim_{x \rightarrow -\infty} F_{\mathbb{P}}(x) = 0$; $\lim_{x \rightarrow \infty} F_{\mathbb{P}}(x) = 1$.*

Eigenschaften der Verteilungsfunktion II

Beweis:

i) $a \leq b \implies F_{\mathbb{P}}(b) - F_{\mathbb{P}}(a) = \mathbb{P}(]a, b]) \geq 0$

ii) $x_n \downarrow x \implies$

$$\lim_{n \rightarrow \infty} F_{\mathbb{P}}(x_n) = \lim_{n \rightarrow \infty} \mathbb{P}(]-\infty, x_n]) \stackrel{\text{Satz 3.30}}{=} \mathbb{P}(]-\infty, x]) = F_{\mathbb{P}}(x)$$

iii) $x_n \downarrow -\infty \implies$

$$\lim_{n \rightarrow \infty} F_{\mathbb{P}}(x_n) = \lim_{n \rightarrow \infty} \mathbb{P}(]-\infty, x_n]) \stackrel{\text{Satz 3.30}}{=} \mathbb{P}(\emptyset) = 0$$

$x_n \uparrow \infty \implies$

$$\lim_{n \rightarrow \infty} F_{\mathbb{P}}(x_n) = \lim_{n \rightarrow \infty} \mathbb{P}(]-\infty, x_n]) \stackrel{\text{Satz 3.30}}{=} \mathbb{P}(]-\infty, \infty[) = \mathbb{P}(\mathbb{R}) = 1$$



5. Verteilungsfunktion

5.1 Definition und Beispiele

5.2 Eigenschaften

5.3 Korrespondenzsatz

5.4 Median und Quantile

5.5 Lebensdauermodelle

Alternative Definition der Verteilungsfunktion

Definition (Verteilungsfunktion)

Jede (!) monoton wachsende, rechtsstetige Funktion

$$F : \mathbb{R} \rightarrow [0, 1] \quad \text{mit} \\ \lim_{x \rightarrow -\infty} F(x) = 0 \quad \text{und} \quad \lim_{x \rightarrow \infty} F(x) = 1$$

heißt Verteilungsfunktion.

Fragen

- ▶ Ist jede Verteilung durch die Verteilungsfunktion vollständig festgelegt?
- ▶ Gibt es zu jeder Verteilungsfunktion eine Verteilung?

Korrespondenzsatz I

Satz (Korrespondenzsatz)

- ▶ Für jede Verteilungsfunktion F ist $\lambda_F(]a, b]) = F(b) - F(a)$ ein Wahrscheinlichkeitsmaß mit $F_{\lambda_F} = F$.
 - ▶ Umgekehrt gibt es für jedes reelles Wahrscheinlichkeitsmaß $\mathbb{P}$ eine Verteilungsfunktion F .
-
- ▶ Wahrscheinlichkeitsmaße auf $\mathbb{R}$ sind also durch ihre Verteilungsfunktionen vollständig definiert
 - ▶ λ_F heißt Lebesgue-Stieltjes-Maß von F .

Korrespondenzsatz II

Beweis:

" $\Rightarrow$ ": F Verteilungsfunktion, $\mu = \lambda_F$

$$F_\mu(x) = \lim_{n \rightarrow \infty} \mu([-n, x]) = \lim_{n \rightarrow \infty} (F(x) - \underbrace{F(-n)}_{\rightarrow 0}) = F(x) \quad \forall x \in \mathbb{R}$$

" $\Leftarrow$ ": Nach erster Definition der Verteilungsfunktion. □

Korrespondenzsatz

Der Korrespondenzsatz sagt uns also, dass es zu jeder Verteilung genau eine Verteilungsfunktion gibt. Und umgekehrt: zu jeder Verteilungsfunktion gibt es genau eine Verteilung.

Transformation der Verteilungsfunktion I

Beispiel 5.3

Sei $\Omega = \{1, 2, \dots, n\}$ und $X(\omega) = \omega$. Dann ist X diskret gleichverteilt auf $1, \dots, n$ mit Verteilungsfunktion

$$F_X(x) = \mathbb{P}(X \leq x) = \begin{cases} 0 & \text{für } x < 1 \\ \frac{\lfloor x \rfloor}{n} & \text{für } 1 \leq x < n \\ 1 & \text{für } x \geq n \end{cases}$$

Sei nun $a \in \mathbb{N}$ und $Y(\omega) = \omega + a - 1 = X(\omega) + a - 1$. Die Verteilungsfunktion von Y ist

$$F_Y(y) = \mathbb{P}(Y \leq y) = \mathbb{P}(X + a - 1 \leq y) = \mathbb{P}(X \leq y - a + 1) = F_X(y - a + 1)$$

Transformation der Verteilungsfunktion II

Satz

Für umkehrbare, streng monotone steigende Transformationen g gilt

$$F_{g(X)}(y) = F_X(g^{-1}(y))$$

Beweis:

$$F_{g(X)}(y) = \mathbb{P}(g(X) \leq y) = \mathbb{P}(X \leq g^{-1}(y)) = F_X(g^{-1}(y))$$




Transformation der Verteilungsfunktion III

Beispiel 5.4

Sei $X \sim U(0, 1)$. $F_X(x) = x$ für $0 \leq x \leq 1$. Wie ist die Verteilungsfunktion von $Y = X^3$? Sei $g(x) = x^3 \Rightarrow g^{-1}(y) = y^{1/3}$. Für $0 \leq x \leq 1$ gilt $0 \leq y \leq 1$:

$$F_Y(y) = F_X(y^{1/3}) = y^{1/3}$$



5. Verteilungsfunktion

5.1 Definition und Beispiele

5.2 Eigenschaften

5.3 Korrespondenzsatz

5.4 Median und Quantile

5.5 Lebensdauermodelle

Median

Definition

Gegeben sei eine eindimensionale Zufallsvariable X mit Verteilung $\mathbb{P}_X$.
Eine reelle Zahl m für die gilt

$$\mathbb{P}_X([-\infty, m]) \geq 0.5 \text{ und } \mathbb{P}_X([m, +\infty[) \geq 0.5$$

heißt Median von $\mathbb{P}_X$ bzw. X .

Beispiel 5.5

- ▶ $X \sim B(2, 0.5)$ dann ist $m = 1$ Median, da $\mathbb{P}(X \leq 1) = 0.75$ und $\mathbb{P}(X \geq 1) = 0.75$.
- ▶ $X \sim B(3, 0.5)$ dann ist jeder Wert $m \in [1, 2]$ Median, da $\mathbb{P}(X \leq 1) = 0.5$ und $\mathbb{P}(X < 2) = 0.5$ (praktisch: $m = 1.5$).

Quantile

Definition

Gegeben sei eine eindimensionale Zufallsvariable X mit Verteilung $\mathbb{P}_X$.
Eine reelle Zahl q für die gilt

$$\mathbb{P}_X(]-\infty, q]) \geq p \text{ und } \mathbb{P}_X([q, +\infty[) \geq 1 - p$$

heißt p -Quantil von $\mathbb{P}_X$ bzw. X .

Beispiel 5.6

Sei $X \sim U[0, 1]$, dann ist q das q -Quantil.

Quantilsfunktion I

Definition (Quantilsfunktion)

Für eine Verteilungsfunktion F heißt

$$F^{-1}(p) := \inf\{x \in \mathbb{R} : F(x) \geq p\}, \quad p \in (0, 1)$$

Quantilsfunktion

Ohne Beweis: Die Quantilsfunktion ist

- ▶ monoton wachsend,
- ▶ linksstetig
- ▶ erfüllt

Quantilsfunktion II

$$P(X \leq F^{-1}(p)) \geq p$$

Satz (Inversionsmethode)

Ist $U \sim U(0, 1)$, dann gilt

$$F^{-1}(U) \sim F.$$

Beweis:

Setze $X := F^{-1}(U)$.

Sei Menge $A(u) := \{t \in \mathbb{R} : F(t) \geq u\}$.

Dann folgt aus der Definition $F^{-1}(p) := \inf\{x \in \mathbb{R} : F(x) \geq p\}$, $p \in (0, 1)$ auch $F^{-1}(u) = \inf A(u)$.

Angenommen $F^{-1}(u) \leq x$. Wäre $F(x) < u$, dann gilt wegen Monotonie von F :

Quantilsfunktion III

$$F(t) \leq F(x) < u \text{ für alle } t \leq x.$$

Also läge kein $t \leq x$ in $A(u)$; damit wäre $\inf A(u) > x$, also Widerspruch. Also muss $F(x) \geq u$, d.h. $u \leq F(x)$.

$\Leftarrow$ Angenommen $u \leq F(x)$. Dann ist $x \in A(u)$. Das Infimum einer Menge ist stets $\leq$ jedem ihrer Elemente, also

$$F^{-1}(u) = \inf A(u) \leq x.$$

Damit folgt

$$F^{-1}(u) \leq x \iff u \leq F(x),$$

Daher

Quantilsfunktion IV

$$\mathbb{P}(X \leq x) = \mathbb{P}(F^{-1}(U) \leq x) = \mathbb{P}(U \leq F(x)).$$

Da $U \sim U(0, 1)$ und $F(x) \in [0, 1]$,

$$\mathbb{P}(U \leq F(x)) = F(x)$$

Also ist $\mathbb{P}(X \leq x) = F(x)$ für alle x , d.h. X hat Verteilungsfunktion F . □

5. Verteilungsfunktion

5.1 Definition und Beispiele

5.2 Eigenschaften

5.3 Korrespondenzsatz

5.4 Median und Quantile

5.5 Lebensdauermodelle

Exponentialverteilung I


Definition (Exponentialverteilung)

Sei $X : \Omega \rightarrow \mathbb{R}$ eine Zufallsvariable mit Verteilungsfunktion

$$F(x) = \begin{cases} 1 - \exp(-\lambda x) & \text{für } x \geq 0 \\ 0 & \text{für } x < 0 \end{cases}$$

Dann heißt $X \sim \text{Exp}(\lambda)$ exponentialverteilt mit Parameter $\lambda \in \mathbb{R}^+$.

Exponentialverteilung II



Exponentialverteilung III

Satz (Gedächtnislosigkeit der Exponentialverteilung)

Sei $X \sim \text{Exp}(\lambda)$. Dann gilt mit $t > 0$ und $s > 0$,

$$\mathbb{P}(X > t + s | X > t) = \mathbb{P}(X > s).$$

Beweis:

$$\begin{aligned}\mathbb{P}(X > t) &= 1 - \mathbb{P}(X \leq t) = 1 - F_X(t) \\ &= 1 - (1 - \exp(-\lambda t)) \\ &= \exp(-\lambda t) \quad \forall t \geq 0.\end{aligned}$$

Exponentialverteilung IV

Damit für alle $s, t \geq 0$:

$$\begin{aligned}\mathbb{P}(X > t + s | X > t) &= \frac{\mathbb{P}(X > t + s)}{\mathbb{P}(X > t)} \\ &= \frac{\exp(-\lambda(t + s))}{\exp(-\lambda t)} \\ &= \frac{\exp(-\lambda t) \cdot \exp(-\lambda s)}{\exp(-\lambda t)} \\ &= \exp(-\lambda s) = \mathbb{P}(X > s)\end{aligned}$$



- ▶ Die Exponentialverteilung ist die einfachste Annahme für Wartezeiten.
- ▶ Die “Gedächtnislosigkeit” impliziert, dass die zukünftige Wartezeit unabhängig davon ist, wieviel Zeit bereits vergangen ist.

Lebensdauern I

Definition

Sei T eine stetige nichtnegative Zufallsvariable (Wartezeit auf ein Ereignis). Dann ist

$$S(t) := \mathbb{P}(T \geq t) = 1 - F_T(t)$$

die Survivorfunktion und

$$h(t) = \lim_{\Delta t \downarrow 0} \frac{P(t \leq T \leq t + \Delta t \mid t \leq T)}{\Delta t}$$

die Hazardrate (manchmal auch mit $\lambda(t)$ bezeichnet).

Lebensdauern II

- ▶ Die Survivorfunktion ist die Wahrscheinlichkeit, bis zum Zeitpunkt t zu “überleben”
- ▶ Die Hazardrate ist das Risiko, dass “im nächsten Moment” das Ereignis eintritt.
- ▶ Ist die Wartezeit $T \sim \text{Exp}(\lambda)$ exponentialverteilt, dann ist die Hazardrate konstant, $h(t) = \lambda$.

Lebensdauern III

Beispiel 5.7

Der Bus kommt zufällig, durchschnittlich alle zehn Minuten. Sei X die Wartezeit auf den Bus in Minuten.

- ▶ $X \sim \text{Exp}(\frac{1}{10})$
- ▶ $h(x) = \frac{1}{10}$

Beispiel 5.8

Ein Bus komme (pünktlich) im 10-Minuten-Takt. Sie kommen zu einem zufälligen Zeitpunkt zur Bushaltestelle ($Y \sim U[0, 10]$).

- ▶ $X = (10 - Y) \sim U(0, 10)$
- ▶ $S(x) = 1 - 0.1x = 0.1 \cdot (10 - x)$ für $x \in [0, 10]$
- ▶ $h(x) = \frac{1}{10-x}$ für $x \in [0, 10]$

Siehe auch Anhang Seite 802.

Kapitel 6

Lebesgue-Integral

6. Lebesgue-Integral

- 6.1 Definition des Lebesgue-Integral
- 6.2 Eigenschaften des Integrals
- 6.3 Lebesgue-Integral bezüglich spezieller Maße



Lebesgue-Integral

- Wir kennen das Riemann-Integral für reelwertige Funktionen $f : \mathbb{R}^d \rightarrow \mathbb{R}$. Dabei integrieren wir über die x-Achse der reellen Zahlen (bzw. über $\mathbb{R}^d$).

Ziel dieses Kapitels: Wir brauchen eine andere Art des Integrals für beliebige Messräume. Damit lassen sich Dichte, Erwartungswert, etc. allgemein definieren.

- Das **Lebesgue-Integral** ist ein sehr allgemeiner Integrationsbegriff für beliebige (!) Messräume und (Borel-)messbare Abbildungen nach $\mathbb{R}$ für Funktionen $f : \Omega \rightarrow \mathbb{R}$ (und $X : \Omega \rightarrow \mathbb{R}$).

Wiederholung: Idee des Riemann-Integrals I




Abbildung 6: Fläche unter einer Funktion

Wiederholung: Idee des Riemann-Integrals II




Abbildung 7: Ober- und Untersumme

Wiederholung: Idee des Riemann-Integrals III

Bernhard Riemann (17. September 1826 bis 20. Juli 1866)

Studium in Göttingen (u.a. bei Gauß) und Berlin, während der Revolution im März 1848 im Studentenkorps in Berlin, Promotion 1851 und Habilitation 1854 in Göttingen. Seit 1857 außerordentlicher Professor in Göttingen.



Grundidee des Lebesgue-Integral I




Abbildung 8: Grundidee Lebesgue-Integral

Grundidee des Lebesgue-Integral II

Henri Léon Lebesgue (28. Juni 1875 bis 26. Juli 1941)

1899–1902 Gymnasiallehrer in Nancy, dabei Arbeit am Integralbegriff und 1902 Dissertation. Ab 1906 Professor für Mechanik in Poitiers, ab 1918 an der Sorbonne.



6. Lebesgue-Integral

6.1 Definition des Lebesgue-Integral

6.2 Eigenschaften des Integrals

6.3 Lebesgue-Integral bezüglich spezieller Maße

Lebesgue-Integral für Indikatorfunktionen I

Im folgenden erstmal $f(x) = I_A(x)$.

Seien

- ▶ $(\Omega, \mathcal{F}, \mu)$ ein Maßraum,
- ▶ A eine meßbare Menge bezüglich $(\Omega, \mathcal{F})$.

Definition (Lebesgue-Integral für Indikatorfunktionen)

Das Lebesgue-Integral für die Indikatorfunktion I_A nach dem Maß μ ist definiert als

$$\int_{\Omega} I_A d\mu := \int I_A d\mu := \mu(A).$$

Lebesgue-Integral für Indikatorfunktionen II

Beispiel 6.1

$$\{\mathbb{R}, \mathcal{B}, \lambda\}; f(x) = I_{[-1,1]}(x)$$

$$\int f d\lambda = \lambda([-1, 1]) = 2$$

$$\{\mathbb{Z}, \mathcal{P}(\mathbb{Z}), \mu_Z\}; f(x) = I_{\{-1,0,1\}}(x)$$

$$\int f d\mu_Z = \mu_Z(\{-1, 0, 1\}) = 3$$

Lebesgue-Integral für Treppenfunktionen I

Definition (Treppenfunktion)

Sei $(\Omega, \mathcal{F}, \mu)$ ein Maßraum und $f : \Omega \rightarrow \mathbb{R}$ eine $\mathcal{F}$ - $\mathcal{B}$ -meßbare Funktion mit endlichem Bild $f(\Omega) = \{y_1, \dots, y_n\}$. Dann gibt es $A_i \in \mathcal{F}, i = 1, \dots, n$ so dass sich f darstellen lässt als

$$f = y_1 \mathbb{I}_{A_1} + \dots + y_n \mathbb{I}_{A_n} = \sum_{i=1}^n y_i \mathbb{I}_{A_i},$$

f heißt dann Treppenfunktion (engl. **step function**) oder einfache Funktion (engl. **simple function**).

- ▶ Menge der Treppenfunktionen $\mathcal{T} := \{f \mid f : \Omega \rightarrow \mathbb{R}, f \text{ Treppenfunktion}\}$
- ▶ Menge der nicht-negativen Treppenfunktionen $\mathcal{T}^+ := \{f \mid f \in \mathcal{T}, f \geq 0\}$


Lebesgue-Integral für Treppenfunktionen II

Beispiel 6.2

$$f(x) = \begin{cases} x & \text{für } x \in \{1, 2, 3, 4, 5, 6\} \\ 0 & \text{sonst} \end{cases}$$

Lebesgue-Integral für Treppenfunktionen III

Beispiel 6.3



Lebesgue-Integral für Treppenfunktionen IV

Abbildung 9: Beispiel Treppenfunktion

Lebesgue-Integral für Treppenfunktionen V

Im Folgenden gehen wir immer von der *Normaldarstellung* aus, d.h. die A_i sind eine disjunkte Zerlegung von Ω (die Definition funktioniert aber allgemein).

Definition (Lebesgue-Integral für Treppenfunktionen)

Sei $f = \sum_{i=1}^n y_i I_{A_i}$ mit $y_i \geq 0$ für alle i eine nichtnegative Treppenfunktion. Dann ist das Lebesgue-Integral von f nach μ

$$\int f \, d\mu := y_1 \mu(A_1) + \dots + y_n \mu(A_n)$$

Lebesgue-Integral für Treppenfunktionen VI

Beispiel 6.4

Sei $\Omega = \{0, 1\}$ und $(\Omega^2, \mathcal{P}(\Omega^2), \mathbb{P} = U(\Omega^2))$ ein Wahrscheinlichkeitsraum.

Sei $X : \Omega^2 \rightarrow \mathbb{R}$ eine Zufallsvariable mit $X(\omega) = \text{'Anzahl Einser in } \omega\text{'}$. Darstellung als Treppenfunktion:

$$y_1 = 0, A_1 = \{(0, 0)\};$$

$$y_2 = 1, A_2 = \{(0, 1), (1, 0)\};$$

$$y_3 = 2, A_3 = \{(1, 1)\}.$$

Es gilt

$$\int X d\mathbb{P} = 0 \cdot \mathbb{P}(A_1) + 1 \cdot \mathbb{P}(A_2) + 2 \cdot \mathbb{P}(A_3) = 1$$

Lebesgue-Integral für Treppenfunktionen VII

Also:

$$\int X d\mathbb{P} = \sum_{x=0}^2 x \mathbb{P}_X(\{x\}) = \mathbb{E}(X) \quad (!)$$

Eigenschaften des Lebesgue-Integrals I

Satz

Es gilt:

i) *Linearität: Für $f, g \in T^+$ und $\alpha, \beta \geq 0$ gilt*

$$\int (\alpha f + \beta g) d\mu = \alpha \int f d\mu + \beta \int g d\mu.$$

ii) *Monotonie: Sind $f, g \in T^+$ und $f \leq g$, so folgt*

$$\int f d\mu \leq \int g d\mu.$$

Wie wir später sehen, gelten diese Eigenschaften auch für das Lebesgue-Integral allgemein.

Eigenschaften des Lebesgue-Integrals II

Beweis:

Gegeben einer disjunkten Zerlegung $\bigcup_{i \in I} A_i = \Omega$ sei

$$f = \sum_{i=1}^n y_i I_{A_i}, \quad g = \sum_{i=1}^n z_i I_{A_i}.$$

Linearität:

$$\begin{aligned} \int (\alpha f + \beta g) d\mu &= \int \alpha \sum_{i=1}^n y_i I_{A_i} + \beta \sum_{i=1}^n z_i I_{A_i} d\mu \\ &= \int \sum_{i=1}^n (\alpha y_i + \beta z_i) I_{A_i} d\mu \stackrel{\text{Def. 6.3}}{=} \sum_{i=1}^n (\alpha y_i + \beta z_i) \mu(A_i) \\ &= \alpha \sum_{i=1}^n y_i \mu(A_i) + \beta \sum_{i=1}^n z_i \mu(A_i) = \alpha \int f d\mu + \beta \int g d\mu \end{aligned}$$



Eigenschaften des Lebesgue-Integrals III

Beweis:

Monotonie:

$$\begin{aligned} & f \leq g \\ \iff & f(x) \leq g(x) \quad \forall x \in \Omega \\ \iff & y_i \leq z_i \quad \forall i = 1, \dots, n \\ \Rightarrow & \sum_{i=1}^n y_i \mu(A_i) \leq \sum_{i=1}^n z_i \mu(A_i) \\ \iff & \int f \, d\mu \leq \int g \, d\mu \end{aligned}$$



Lebesgue-Integral für nicht-negative meßbare Funktionen I

Sei im Folgenden

- ▶ die Menge der meßbaren numerischen Funktionen $M := \{f \mid f : \Omega \rightarrow \bar{\mathbb{R}}, f \text{ meßbar}\}$,
- ▶ die Menge der nicht-negativen meßbaren numerischen Funktionen $M^+ := \{f \mid f \in M, f \geq 0\}$.

Lemma

Ist $f \in M^+$ eine nicht-negative Funktion, so gibt es eine Folge $(f_n)_{n \in \mathbb{N}} \in T^+$ von nicht-negativen Treppenfunktionen, so daß $f_n \uparrow f$.

Lebesgue-Integral für nicht-negative meßbare Funktionen II

Beweis:

Eine solche Funktion ist $f_n : \Omega \rightarrow \mathbb{R}$, $n \in \mathbb{N}$ mit

$$f_n(x) := \frac{\lfloor 2^n f(x) \rfloor}{2^n} \uparrow f(x) \quad \forall x \in \Omega$$

Dabei ist $\lfloor y \rfloor := \max\{k \in \mathbb{Z} \mid k \leq y\}$ (Abrundung).



Lebesgue-Integral für nicht-negative meßbare Funktionen III




Abbildung 10: Approximation von $f = x^2 \exp(-x^2)$ (auf $[0, 3]$) durch $f_n \in T^+$ für $n = 1, 2, 4$.

Lebesgue-Integral für nicht-negative meßbare Funktionen IV

Definition (Lebesgue-Integral für nicht-negative Funktionen)

Sei $f \in M^+$ und $(f_n)_{n \in \mathbb{N}} \in T^+$ mit $f_n \uparrow f$. Das Lebesgue-Integral von f nach μ ist dann

$$\int f \, d\mu := \lim_{n \rightarrow \infty} \int f_n \, d\mu.$$

Lebesgue-Integral für meßbare Funktion I





Jetzt allgemein $f : \Omega \rightarrow \bar{\mathbb{R}}$ meßbar. Wir können f in einen Positivteil f^+ und einen Negativteil f^- zerlegen:

$$f^+(x) := \max(f(x), 0),$$

$$f^-(x) := \max(-f(x), 0),$$

$$f = \underbrace{f^+}_{\in M^+} - \underbrace{f^-}_{\in M^+}.$$

Lebesgue-Integral für meßbare Funktion II



Lebesgue-Integral für meßbare Funktion III

Definition (quasi-integrierbar, Lebesgue-Integral)

Sei $f : \Omega \rightarrow \bar{\mathbb{R}}$ eine meßbare numerische Funktion. Die Funktion heißt $(\mu-)$ quasi-integrierbar, falls $\int f^+ d\mu < \infty$ oder $\int f^- d\mu < \infty$. Ist f $(\mu-)$ quasi-integrierbar, so ist durch

$$\int f d\mu := \int f^+ d\mu - \int f^- d\mu$$

das Lebesgue-Integral von f nach μ definiert. Gilt $\int f^+ d\mu < \infty$ und $\int f^- d\mu < \infty$, so heißt f $(\mu-)$ integrierbar.

Bemerkungen

► $|f| = f^+ + f^- \Rightarrow f$ integrierbar $\iff |f|$ integrierbar.

Lebesgue-Integral für meßbare Funktion IV

Definition

Sei A meßbar. Dann definieren wir das Integral von f über A nach μ als

$$\int_A f \, d\mu := \int (f \, I_A) \, d\mu.$$

6. Lebesgue-Integral

6.1 Definition des Lebesgue-Integral

6.2 Eigenschaften des Integrals

6.3 Lebesgue-Integral bezüglich spezieller Maße

Eigenschaften des Integrals I

Satz

Sind $f, g : \Omega \rightarrow \bar{\mathbb{R}}$ integrierbare numerische Funktionen und $\alpha, \beta \in \mathbb{R}$, so gilt

i) *Linearität:* $\alpha f + \beta g$ ist integrierbar und

$$\int (\alpha f + \beta g) d\mu = \alpha \int f d\mu + \beta \int g d\mu$$

ii) *Monotonie:* Ist $f \leq g$, so folgt $\int f d\mu \leq \int g d\mu$

iii) Für jedes $A \in \mathcal{F}$ gilt $\int f d\mu = \int_A f d\mu + \int_{\bar{A}} f d\mu$.

Eigenschaften des Integrals II

Beweis:

Erst: $f, g \in M^+$:

Sind $\underbrace{f_n}_{\in T^+} \uparrow f, \underbrace{g_n}_{\in T^+} \uparrow g$, so auch $\alpha f_n + \beta g_n \uparrow \alpha f + \beta g$

i) folgt somit aus Satz 6.4 (i) für f_n, g_n

ii) $f_n \leq \max(f_n, g_n) \uparrow g$ für $f \leq g$
und aus Satz 6.4 (ii) folgt ii)

Für $f, g \in M$ folgen i) und ii) nach Definition.

iii) $f = f I_A + f I_{\bar{A}} \quad \checkmark$



Monotone und Dominierte Konvergenz I

Ohne Beweis noch zwei wichtige Sätze der Integralrechnung:

Satz (Monotone Konvergenz, Satz von Beppo Levi)

Für eine monoton wachsende Folge $(f_n)_{n \in \mathbb{N}}$ von Funktionen aus M^+ gilt:

$$\lim_{n \rightarrow \infty} \int f_n d\mu = \int \lim_{n \rightarrow \infty} f_n d\mu.$$

Vgl. Def. 6.6.

Monotone und Dominierte Konvergenz II

Satz (Dominierte oder majorisierte Konvergenz, Satz von Lebesgue)

Seien f, g sowie $(f_n), (g_n)$ meßbare numerische Funktionen auf einem Maßraum $(\Omega, \mathcal{F}, \mu)$ mit $f_n \rightarrow f, g_n \rightarrow g$ (punktweise) und $|f_n| \leq g_n \forall n \in \mathbb{N}$. Sind g und $g_n \forall n \in \mathbb{N}$ integrierbar und gilt

$$\lim_{n \rightarrow \infty} \int g_n d\mu = \int g d\mu,$$

so sind f und $f_n \forall n \in \mathbb{N}$ integrierbar und es gilt

$$\lim_{n \rightarrow \infty} \int f_n d\mu = \int f d\mu.$$

Integral über Nullmengen I

Satz

Für f eine meßbare nicht-negative Funktion ($f \in M^+$) gilt

$$\int f \, d\mu = 0 \iff \underbrace{\{\omega \in \Omega \mid f(\omega) > 0\}}_{=: \text{Träger von } f} \text{ ist } \mu\text{-Nullmenge}$$

Das heißt: $\int_A f \, d\mu = \int I_A f \, d\mu = 0$ wenn A eine μ -Nullmenge.

Integral über Nullmengen II

Beweis:

$\Rightarrow$

$$A := \{\omega \in \Omega \mid f(\omega) > 0\}$$

$$A_n := \left\{ \omega \in \Omega \mid f(\omega) > \frac{1}{n} \right\} \quad \forall n \in \mathbb{N} \Rightarrow$$

$$A_n \uparrow A \Rightarrow \frac{1}{n} I_{A_n} \leq f \quad \forall n \in \mathbb{N}$$

$$0 \stackrel{\text{Ma\ss} > 0}{\leq} \frac{1}{n} \mu(A_n) = \int \frac{1}{n} I_{A_n} d\mu \stackrel{\text{Monotonie}}{\leq} \int f d\mu = 0$$

$$\Rightarrow \mu(A_n) = 0 \quad \forall n \in \mathbb{N}$$

$$\Rightarrow \mu(A_n) \uparrow \mu(A) = 0 \quad (\text{Stetigkeit von unten})$$

Integral über Nullmengen III



$$\mu(A) = 0; f_n \in T^+, f_n \uparrow f \in M^+;$$

$$m_n := \max_{\Omega}(f_n(x)) \in \mathbb{R}$$

$$\Rightarrow \{\omega \in \Omega | f_n(\omega) > 0\} \subset A$$

$$0 \leq \int f_n d\mu = \int_A f_n d\mu \leq \int m_n I_A d\mu = m_n \mu(A) = 0$$

$$\Rightarrow \int f_n d\mu = 0 \forall n \in \mathbb{N}$$

$$\Rightarrow \int f d\mu = \lim_{n \rightarrow \infty} \int f_n d\mu = 0$$



6. Lebesgue-Integral

6.1 Definition des Lebesgue-Integral

6.2 Eigenschaften des Integrals

6.3 Lebesgue-Integral bezüglich spezieller Maße

Lebesgue-Integral bezüglich Dirac-Maß I

Satz

Sei $\omega \in \Omega$ und δ_ω das Dirac-Maß. Sei f eine meßbare Funktion. Dann ist f genau dann δ_ω -integrierbar, wenn $f(\omega) < \infty$ und es gilt

$$\int f d\delta_\omega = f(\omega).$$

Lebesgue-Integral bezüglich Dirac-Maß II

Beweis:

Sei erstmal $f = \sum_i y_i I_{A_i} \in T^+$. Dann ist $\omega \in A_k$ für genau ein k . Also

$$\int f d\delta_\omega = \sum_{i=1}^n y_i \delta_\omega(A_i) = \sum_{i=1}^n y_i I_{A_i}(\omega) = y_k = f(\omega)$$

Sei nun $f \in M^+$. Dann gibt es ein Folge $f_n \uparrow f$ mit $f_n \in T^+$. Dann gilt also

$$\int f d\delta_\omega = \lim_{n \rightarrow \infty} \int f_n d\delta_\omega = \lim_{n \rightarrow \infty} f_n(\omega) = f(\omega)$$

Sei nun $f = f^+ - f^- \in M$. Offensichtlich ist f integrierbar, wenn $f^+(\omega) < \infty$ und $f^-(\omega) < \infty$ (eines davon ist gleich Null). Damit folgt auch

$$\int f d\delta_\omega = f^+(\omega) - f^-(\omega) = f(\omega)$$



Lebesgue-Integral bezüglich Zählmaß I

Satz

Sei (μ_n) eine Folge von Maßen auf $\mathcal{F}$ und $\mu = \sum_{i=1}^{\infty} \mu_i$ definiert als

$$\mu(A) = \sum_{i=1}^{\infty} \mu_i(A) \forall A \in \mathcal{F}.$$

Für eine $\mathcal{F}$ -meßbare Funktion f gilt:

$$f \text{ ist } \mu\text{-integrierbar} \iff \sum_{i=1}^{\infty} \int |f| d\mu_i < \infty$$

Es gilt dann:

$$\int f d\mu = \sum_{i=1}^{\infty} \int f d\mu_i$$

Lebesgue-Integral bezüglich Zählmaß II

Den genauen Beweis schenken wir uns. Für die Konvergenz braucht man den *großen Umordnungssatz* (Konvergiert eine Reihe absolut, kann man Reihenglieder beliebig zu Gruppen zusammenfassen und vertauschen)

Die Herleitung des Integrals folgt aber dem obigen Verfahren: Treppenfunktion, nichtnegative Funktion über Folge von Treppenfunktionen, beliebige meßbare Funktion.

Lebesgue-Integral bezüglich Zählmaß III

Satz

Gegeben sei der Maßraum $(\mathbb{N}, \mathcal{P}(\mathbb{N}), \mu_Z)$. Eine Funktion $f : \mathbb{N} \rightarrow \mathbb{R}$ ist genau dann μ_Z -integrierbar, wenn die Reihe $\sum_{n=1}^{\infty} f(n)$ absolut konvergiert. Es gilt:

$$\int_{\mathbb{N}} f \, d\mu_Z = \sum_{n=1}^{\infty} f(n)$$

Also ist die Integration mit dem Zählmaß genau die Summation!

Beweis:

Auf $(\mathbb{N}, \mathcal{P}(\mathbb{N}))$ gilt $\mu_Z = \sum_{i=1}^{\infty} \delta_i$. Rest folgt aus vorherigem Satz. □

Riemann- und Lebesgue-Integral I

Satz (Riemann & Lebesgue-Integral)

Sei $f : \mathbb{R} \rightarrow \mathbb{R}$ meßbar und auf $[a, b] \subset \mathbb{R}$ Riemann-integrierbar (Ober- und Untersumme konvergieren gegen Integralwert). Dann ist f Lebesgue-integrierbar und es gilt

$$\underbrace{\int_{[a,b]} f \, d\lambda}_{\text{Lebesgue}} = \underbrace{\int_a^b f(x) \, dx}_{\text{Riemann}}.$$

Beweis:

Skizze: Stelle Ober- und Untersumme jeweils als Integral einer Treppenfunktion dar, dann benutze Satz 6.10 (monotone Konvergenz). □

Genauer siehe Satz 2.17 Meintrup and Schäffler (2005).

Riemann- und Lebesgue-Integral II

Also, es gilt:

- ▶ f Riemann-integrierbar $\Rightarrow f$ Lebesgue-integrierbar, aber
- ▶ f Lebesgue-integrierbar $\nRightarrow f$ Riemann-integrierbar.

Vorteil des Lebesgue-Integrals I

- ▶ Riemann-Integrale sind nur für bestimmte $\Omega \subset \mathbb{R}^n$ definiert,
- ▶ Lebesgue-Integrale sind auf beliebige Messräumen $(\Omega, \mathcal{F})$ bzgl. beliebiger Maße μ definiert.

Lebesgue-Integral

Das Lebesgue-Integral ist allgemeiner definiert als das Riemann-Integral. Oft nutzen wir die Spezialfälle:

- ▶ Lebesgue-Integral bezüglich Zählmaß $\hat{=}$ Summe
- ▶ Lebesgue-Integral bezüglich Lebesgue-Maß $\hat{=}$ Riemann-Integral (wenn die Funktion Riemann-integrierbar ist)

Vorteil des Lebesgue-Integrals II

Beispiel 6.5

Sei $f(x) = I_{\mathbb{Q}}(x)$. Offensichtlich ist $f(x)$ nicht Riemann-integrierbar. Aber es gilt

$$\int f(x) d\lambda = \lambda(\mathbb{Q}) = 0$$




Mathematics With Younas • Folgen

4 Tag(e) ·



Meme of the day.....



🤔 1.013

👍 1.013

💬 34



➦ 134

Kapitel 7

Dichte

7. Dichte

7.1 Dichte eines Maßes

7.2 Arten von Verteilungen



Ziele des Kapitels

- ▶ Maß ist Funktion auf einer σ -Algebra $\mathcal{F} \subseteq \mathcal{P}(\Omega)$, also einem (komplizierten) Mengensystem.
- ▶ Wir wollen Maß einfacher durch eine Funktion auf Ω direkt beschreiben (die *Radon-Nikodým-Dichte*).
- ▶ Speziell: Wir wollen ein Wahrscheinlichkeitsmaß als Dichte zu einem Maß darstellen.
- ▶ Und wir beantworten die Frage: Wieviele Arten von Verteilungen gibt es eigentlich?

Dank der bis zu diesem Kapitel erarbeiteten, einheitlichen Theorie können wir alle erdenklichen Verteilungen behandeln. Lästige (und verwirrende) Fallunterscheidungen (stetig, diskret, ...) sind damit nicht mehr nötig.

7. Dichte

7.1 Dichte eines Maßes

7.2 Arten von Verteilungen

Dichte eines Maßes I

Satz

Für jedes $f \in M^+$ ist

$$f \odot \mu : \mathcal{F} \rightarrow \bar{\mathbb{R}}$$
$$(f \odot \mu)(A) := \int_A f \, d\mu = \int f \mathbf{1}_A \, d\mu$$

ein Maß.

Sei $\nu = f \odot \mu$, so gilt für alle $g \in M^+$

$$\int g \, d\nu = \int (gf) \, d\mu.$$

Das Symbol $\odot$ heißt Kreispunkt oder Komposition.

Dichte eines Maßes II

Definition (Maß mit Dichte, Dichte)

Sei $(\Omega, \mathcal{F}, \mu)$ Maßraum und $f \in M^+$. Dann heißt $f \odot \mu$ Maß mit der Dichte (engl. *measure with density*) f bezüglich μ .

Die Funktion $f : \Omega \rightarrow [0, \infty[$ heißt (Radon-Nikodým-) Dichte des Maßes $f \odot \mu$.

f wird auch als Radon-Nikodým-Ableitung $\frac{d\nu}{d\mu}$ bezeichnet.

Dichte eines Maßes III

Beweis:

M1) ✓

M2) ✓

M3) Sei $(A_n)_{n \in \mathbb{N}}$ mit disjunkten $A_n \in \mathcal{F}$ mit $\dot{\bigcup}_{n=1}^{\infty} A_n = A$ und damit $f \mathbb{I}_A = \sum_{n=1}^{\infty} f \mathbb{I}_{A_n}$.

$$\begin{aligned}(f \odot \mu)(A) &= \int f \mathbb{I}_A d\mu = \int \left(\sum_{n=1}^{\infty} f \mathbb{I}_{A_n} \right) d\mu \\&= \sum_{n=1}^{\infty} \int f \mathbb{I}_{A_n} d\mu \quad (\text{da } f \mathbb{I}_{A_n} \in M^+ \forall n \in \mathbb{N}) \\&= \sum_{n=1}^{\infty} (f \odot \mu)(A_n)\end{aligned}$$

Die zweite Behauptung folgt für $g = \mathbb{I}_A$ aus der Definition, und damit für allgemeine $g \in M^+$ via Standardprozedur. □

Dichte eines Maßes IV

Beispiel 7.1

Sei $\mu = \mu_Z$ das Zählmaß. Sei

$$f(x) = \mathbb{P}(\{x\})$$

die Zähldichte einer diskreten Verteilung $\mathbb{P}$. Dann ist

$$(f \odot \mu_Z)(A) = \int_A f \, d\mu_Z = \int f \mathbb{1}_A \, d\mu_Z = \sum_{x \in A} f(x) = \mathbb{P}(A).$$

Die Zähldichte ist also die Radon-Nikodým-Dichte bezüglich des Zählmaßes.

Dichte eines Maßes V

Weiterhin gilt: Für eine diskrete Verteilung $\mathbb{P}$ auf $(\mathbb{N}, \mathcal{P}(\mathbb{N}))$ ist die Verteilungsfunktion

$$F(x) = \sum_{n=1}^x \mathbb{P}(\{n\}) = \sum_{n=1}^x f(n) = \int_{\{1, \dots, x\}} f \, d\mu_Z$$

Zähldichte

Für diskrete Verteilungen ist die Zähldichte die Radon-Nikodým-Ableitung der Verteilung bezüglich des Zählmaßes.

Dominierendes Maß I

Definition (absolute Stetigkeit)

Sind μ und ν zwei Maße auf $(\Omega, \mathcal{F})$, so heißt ν absolut stetig (engl. *absolutely continuous*) bezüglich μ , wenn $\forall A \in \mathcal{F}$ gilt:

$$\mu(A) = 0 \implies \nu(A) = 0$$

Kurz: $\nu \ll \mu$. Man sagt auch: μ dominiert ν .

Dominierendes Maß II

Beispiel 7.2

Wir betrachten den Wahrscheinlichkeitsraum $(\mathbb{R}, \mathcal{B}, U([0, 1[))$ (stetige Gleichverteilung). Das Lebesgue-Maß λ dominiert $U([0, 1[)$. Def. 3.20:

$$U([0, 1[)(]c, d[) = \mathbb{P}(]c, d[) := \frac{d - c}{1 - 0} = \lambda([c, d])$$

Nach dem Masseindeutigkeitssatz (Satz 3.10) ist das Maß damit eindeutig festgelegt. Für allgemeine Borelmengen $B \in \mathcal{B}$ ergibt sich mit den Eigenschaften des Maßes

$$U([0, 1[)(B) = \mathbb{P}(B) = \lambda(B)$$

Für Nullmengen von λ ist also auch die Wahrscheinlichkeit gleich null, λ dominiert $U([0, 1[)$ (alle abzählbaren Mengen sind Nullmengen von λ).

Satz von Radon-Nikodým I

Satz (Satz von Radon-Nikodým)

Ist $(\Omega, \mathcal{F}, \mu)$ ein Maßraum mit einem σ -endlichen Maß μ und ν ein weiteres Maß auf $(\Omega, \mathcal{F})$, gilt

$$\nu \ll \mu \iff \exists \text{ Dichte } f \in M^+ : \nu = f \odot \mu.$$

Gibt es eine weitere Funktion $g \in M^+$ mit $\nu = g \odot \mu$ so gilt $g = f$ μ -fast überall.

Ohne Beweis.

Satz von Radon-Nikodým II

Johann Radon (16. Dezember 1887 bis 25. Mai 1956).

1910 Promotion in Wien, 1913 Beweis der Existenz von Dichten im $\mathbb{R}^n$, Professor in Hamburg, Greifswald, Erlangen und Breslau. Nach dem Krieg Professor und Rektor der Universität Wien. Doktorvater von Kurt Weichselberger (Mitgründer des Instituts für Statistik).



J. Radon

Otto Marcin Nikodym (13. August 1887 bis 4. Mai 1974)

Studium der Mathematik und Physik in Lemberg (Lviv), Promotion in Warschau, bis 1945 Professor in Warschau. 1930 Beweis des allgemeinen Falls. Nach dem zweiten Weltkrieg am Kenyon College in Ohio tätig.



Satz von Radon-Nikodým III

Sei $(\Omega, \mathcal{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum. Sei μ ein Maß, welches $\mathbb{P}$ dominiert, also aus $\mu(A) = 0 \implies \mathbb{P}(A) = 0$. Dann gibt es eine Wahrscheinlichkeitsdichtefunktion (engl. probability density function, pdf), kurz Dichte f mit $\mathbb{P} = f \odot \mu$, die *Dichte der Verteilung* $\mathbb{P}$.

Bei $\mathcal{F} = \mathcal{B}$ gilt für die Verteilungsfunktion

$$F(x) = \mathbb{P}(]-\infty, x]) = \int_{]-\infty, x]} f d\mu$$

Eindeutigkeit der Dichte I

Beispiel

Gegeben sei der Maßraum $(\mathbb{R}, \mathcal{B})$. Für das dominierende Maß λ seien folgende Dichten gegeben:

- ▶ $f_1(x) = I_{[0,1]}(x)$
- ▶ $f_2(x) = I_{]0,1[}(x)$
- ▶ $f_3(x) = I_{[0,1]} \cdot (1 - I_{\mathbb{Q}})(x)$

$$F_1(x) = \int_{]-\infty, x]} f_1 d\lambda = \int_{]-\infty, x]} I_{[0,1]} d\lambda \stackrel{\text{Def. 6.8}}{=} \int I_{]-\infty, x]} \cdot I_{[0,1]} d\lambda$$

Für $x < 0$ ist $I_{]-\infty, x]} \cdot I_{[0,1]} = 0$, also $F_1(x) = 0$.

Für $x \geq 0$ gilt

$$F_1(x) = \int I_{[0, \min(x, 1)]} d\lambda \stackrel{\text{Satz 6.16}}{=} \int_0^{\min(x, 1)} 1 dx$$

Eindeutigkeit der Dichte II

Zusammen:

$$F_1(x) = \begin{cases} 0 & \text{für } x \leq 0 \\ x & \text{für } 0 < x < 1 \\ 1 & \text{für } x \geq 1 \end{cases}$$

Für $x > 0$:

$$F_2(x) = \int_{]-\infty, x]} f_2 d\lambda = \int I_{]-\infty, x]} \cdot I_{]0, 1[} d\lambda = \int_0^{\min(x, 1)} 1 dx$$

Also $F_1 = F_2$!

Eindeutigkeit der Dichte III

$$\begin{aligned} F_3(x) &= \int_{]-\infty, x]} f_3 d\lambda = \int l_{]-\infty, x]} \cdot l_{[0, 1]} \cdot (1 - l_{\mathbb{Q}}) d\lambda \\ &= \int l_{]-\infty, x]} l_{[0, 1]} - l_{]-\infty, x]} l_{[0, 1]} l_{\mathbb{Q}} d\lambda = \\ &= \int l_{]-\infty, x]} l_{[0, 1]} d\lambda - \underbrace{\int l_{]-\infty, x]} l_{[0, 1]} l_{\mathbb{Q}} d\lambda}_{=0} = F_1 \end{aligned}$$

Also $F_1 = F_2 = F_3$! Es gilt mithin $U([0, 1]) = U(]0, 1[) := U(0, 1)$.

Eindeutigkeit der Dichte IV




Abbildung 11: Dichte der stetigen Gleichverteilung auf $(0,1)$

Eindeutigkeit der Dichte V

Satz von Radon-Nikodým

Der Satz von Radon-Nikodým garantiert, dass eine Verteilung eine Dichte hat, wenn sie von einem Maß dominiert ist.

Er garantiert aber nicht, dass diese Dichte eindeutig ist (anders als der Korrespondenzsatz für Verteilungsfunktionen).

Normalverteilung

Definition

Sei $X : \Omega \rightarrow \mathbb{R}$ Zufallsvariable mit stetiger Dichte

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right)$$

bzw. Verteilungsfunktion

$$F(x) = \int_{-\infty}^x f(y) dy$$

Dann heißt $X \sim N(\mu, \sigma^2)$ normalverteilt (engl. normal distributed/Gaussian distributed) mit Parametern $\mu \in \mathbb{R}$ und $\sigma^2 \in \mathbb{R}_0^+$.

Träger

Definition

Sei $\mathbb{P}$ eine (beliebige) Verteilung mit Dichte $f(x)$, dann ist $T = \{x | f(x) > 0\}$ der Träger (engl. support) der Verteilung.

7. Dichte

7.1 Dichte eines Maßes

7.2 Arten von Verteilungen

Diskrete Verteilungen I

Definition (Diskreter Wahrscheinlichkeitsraum)

Sei $(\Omega, \mathcal{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum. Gibt es eine (endlich oder unendlich) abzählbare Menge $T \in \mathcal{F}$ mit $\mathbb{P}(\{\omega\}) > 0 \forall \omega \in T$ und $\mathbb{P}(T) = 1$, so heißt

- ▶ $(\Omega, \mathcal{F}, \mathbb{P})$ diskreter Wahrscheinlichkeitsraum,
- ▶ $\mathbb{P}$ diskretes Wahrscheinlichkeitsmaß (engl. *discrete probability measure*)
- ▶ T ein abzählbarer Träger von $\mathbb{P}$.

- ▶ Ω selbst muß nicht abzählbar sein

Diskrete Verteilungen II

Beispiel 7.3

Ein Ereignis A tritt mit Wahrscheinlichkeit p ein. Sei die Zufallsvariable X die Anzahl von Versuchen bis zum ersten Mal A eintritt (diskrete Wartezeit).

Wir konstruieren einen Wahrscheinlichkeitsraum. Der ursprüngliche Wahrscheinlichkeitsraum $(\Omega_1, \mathcal{F}_1, \mathbb{P})$ ist (mit E Erfolg und M Misserfolg)

* $\Omega_1 = \{(E), (M, E), (M, M, E), (M, M, M, E), \dots\}$ * $\mathcal{F}_1 = \mathcal{P}(\Omega_1)$ *

$\mathbb{P}(\{\omega\}) := (1 - p)^{x-1}p$ mit x Länge von ω

Diskrete Verteilungen III

X ist eine meßbare Abbildung $\Omega_1 \rightarrow \Omega_2$. Auch hier konstruieren wir einen Wahrscheinlichkeitsraum:

- ▶ Sei $\Omega_2 = \mathbb{R}$!
- ▶ Also $\mathcal{F}_2 = \mathcal{B}$
- ▶ $\mathbb{P}_X := G(p)$ Geometrische Verteilung mit Träger $T = \mathbb{N}$ und Dichte

$$f(x) = (1 - p)^{x-1} p I_{\mathbb{N}}(x)$$

Hier ist $0 \leq p \leq 1$ ein Parameter der Verteilung.

Diskrete Verteilungen IV

Definition (Geometrische Verteilung)

Sei $X : \Omega \rightarrow \mathbb{R}$ diskrete Zufallsvariable mit Dichte

$$f(x) = (1 - p)^{x-1} p \, I_{\mathbb{N}}(x)$$

Dann ist $X \sim G(p)$ geometrisch verteilt mit Parameter $p \in [0, 1]$.

Alternativ möglich ist die Definition über die Dichte

$$f^*(x) = (1 - p)^x p \, I_{\mathbb{N}_0}(x)$$

Stetige Verteilungen I

Definition

Eine reelle Zufallsvariable X heißt (absolut) stetig verteilt (engl. *continuously distributed*), wenn es eine nichtnegative Borel-messbare Funktion $f : \mathbb{R} \rightarrow \mathbb{R}$ mit der Eigenschaft

$$\int_{-\infty}^{\infty} f(t) dt = 1$$

gibt, sodass gilt:

$$\mathbb{P}_X(B) = \mathbb{P}(X \in B) = \int_B f(t) dt, \quad B \in \mathcal{B}$$

f heißt stetige Dichte (bezüglich des Lebesgue-Maßes) von X bzw. von $\mathbb{P}_X$.

Stetige Verteilungen II

- ▶ f muss nicht stetig sein. Ist f nicht stetig, muss eine stetige Funktion $g : \mathbb{R} \rightarrow \mathbb{R}$ mit $f = g \cdot I_T$ sein.
- ▶ $T \subset \mathbb{R}$ ist der Träger der stetigen Verteilung.
- ▶ Die Verteilungsfunktion $F_{\mathbb{P}}$ ist auf ganz $\mathbb{R}$ stetig.

Radon-Nikodým-Ableitung

Für (absolut-)stetige Verteilungen ist die Dichte die Radon–Nikodým-Ableitung der Verteilung und zugleich (fast überall) die klassische Ableitung der Verteilungsfunktion.

Stetige Verteilungen III

Definition (Exponentialverteilung)

Sei $X : \Omega \rightarrow \mathbb{R}$ Zufallsvariable mit stetiger Dichte

$$f(x) = \lambda \exp(-\lambda x) I_{\mathbb{R}^+}(x)$$

bzw. Verteilungsfunktion

$$F(x) = \begin{cases} 1 - \exp(-\lambda x) & x > 0 \\ 0 & \text{sonst} \end{cases}$$

Dann ist $X \sim \text{Exp}(\lambda)$ exponentialverteilt (engl. exponential distributed) mit Parameter $\lambda \in \mathbb{R}^+$.

Stetige Verteilungen IV




Abbildung 12: Dichte der Exponentialverteilung

Stetige Verteilungen V

$$\begin{aligned} F(x) &= \int_{-\infty}^x f(y) dy \\ &= \int_{-\infty}^x \lambda \exp(-\lambda y) I_{\mathbb{R}^+}(y) dy = \lambda \int_0^x \exp(-\lambda y) dy \\ &= \lambda \frac{1}{-\lambda} [\exp(-\lambda y)]_0^x \\ &= \begin{cases} 1 - \exp(-\lambda x) & x > 0 \\ 0 & \text{sonst} \end{cases} \rightarrow 1 \quad \text{für } x \rightarrow \infty \end{aligned}$$

Stetige Verteilungen VI




Abbildung 13: Verteilungsfunktion der Exponentialverteilung

Stetigsinguläre Verteilungen I

Definition

Gegeben sei ein Messraum $(\Omega, \mathcal{F})$. Ein Maß ν heißt singulär (engl. *singular*) bezüglich eines Maßes μ , wenn es eine Menge $A \in \mathcal{F}$ gibt, so dass

$$\nu(\Omega \setminus A) = 0 \text{ und } \mu(A) = 0$$

Stetigsinguläre Verteilungen II

Definition

Sei $A_0 = [0, 1]$ und $A_{n+1} = \frac{1}{3}(A_n \cup (2 + A_n))$. Die Cantormenge ist


$$\mathcal{C} = \bigcap_{n=0}^{\infty} A_n = \lim_{n \rightarrow \infty} A_n$$

Die Cantorfunktion (engl. devil's staircase) ist

$$c(x) = \begin{cases} \sum_{n=1}^{\infty} \frac{a_n}{2^n}, & x = \sum_{n=1}^{\infty} \frac{2a_n}{3^n} \in \mathcal{C} \text{ für } a_n \in \{0, 1\}; \\ \sup_{y \leq x, y \in \mathcal{C}} c(y), & x \in [0, 1] \setminus \mathcal{C}. \end{cases}$$

- ▶ Die Cantorfunktion ist stetig und monoton wachsend zwischen 0 und 1.
- ▶ Die Cantorfunktion ist fast überall differenzierbar mit Ableitung 0.

Stetigsinguläre Verteilungen III



Stetigsinguläre Verteilungen IV

Definition

Sei X eine Zufallsvariable, deren Verteilungsfunktion die Cantorfunktion ist. Dann ist X Cantorverteilt.

Gemischte Verteilungen I

Darstellungssatz

Nach dem **Darstellungssatz** lässt sich jedes Wahrscheinlichkeitsmaß wie folgt zerlegen (Lebesgue-Zerlegung):

$$\mathbb{P} = a_D \mathbb{P}_D + a_A \mathbb{P}_A + a_S \mathbb{P}_S$$

mit $a_D, a_A, a_S \geq 0$ und $a_D + a_A + a_S = 1$. Dabei ist

- ▶ $\mathbb{P}_D$ eine diskrete Wahrscheinlichkeitsverteilung
- ▶ $\mathbb{P}_A$ eine (bzgl. des Lebesgue-Maßes) absolut-stetige Wahrscheinlichkeitsverteilung
- ▶ $\mathbb{P}_S$ eine stetig-singuläre Wahrscheinlichkeitsverteilung

Gemischte Verteilungen II

Beispiel 7.4

Ein Smartphone-Hersteller verkauft eine erweiterte Reparaturversicherung. Aus langjähriger Erfahrung ist ihm bekannt, dass der Anteil $0 < \alpha < 1$ seiner Smartphones während dieser Phase keine Reparatur benötigt. Die Kosten der Reparatur seien exponentialverteilt mit Erwartungswert β Euro. Sei X die zukünftigen Reparaturkosten eines neu verkauften Smartphones. Wie ist X verteilt?

Wir konstruieren uns ein Wahrscheinlichkeitsmaß $\mathbb{P}$ auf $(\mathbb{R}, \mathcal{B})$. Es gilt:

- $\mathbb{P}$ ist auf $\mathbb{R}^+$ absolut stetig,
- $\mathbb{P}(\{0\}) = \alpha > 0$.

Gemischte Verteilungen III

Wir suchen die Dichte und das dominierende Maß:

- ▶ $\mathbb{P}$ wird nicht vom Lebesguemaß dominiert: $\lambda(\{0\}) = 0$, aber $\mathbb{P}(\{0\}) > 0$.
- ▶ μ_Z ist nicht geeignet, da kein σ -endliches Maß auf $(\mathbb{R}, \mathcal{B})$.

Wähle das Maß μ , so daß $\mathbb{P} = f^* \odot \mu$ ein Maß mit Dichte f^* bezüglich μ ist.
Wähle

$$\mu := \lambda + \delta_0.$$

μ ist ein σ -endliches Maß!

Gemischte Verteilungen IV

Zu zeigen

$$\mathbb{P} \ll \mu.$$

Sei dazu $B \in \mathcal{B}$ eine μ -Nullmenge, also $\mu(B) = 0$. Dann gilt:

$$\mu(B) = \underbrace{\lambda(B)}_{\geq 0} + \underbrace{\delta_0(B)}_{\geq 0} = 0$$

und somit

$$\lambda(B) = 0, \delta_0(B) = 0.$$

Gemischte Verteilungen V

Offensichtlich ist $0 \notin B$. Damit folgt (mit $f(x)$ Dichte der Exponentialverteilung):

$$\mathbb{P}(B) = \int_B f(x) d\lambda(x) = \int f(x) I_B(x) d\lambda(x) \stackrel{\text{Bem. zu Satz 6.12}}{=} 0.$$

Also ist

$$\mathbb{P} \ll \lambda + \delta_0 = \mu$$

und damit existiert mit dem Satz von Radon-Nikodým auch eine Dichte $f^* \in M^+$ von $\mathbb{P}$ bzgl. μ . Es gilt

$$\mathbb{P}(B) = \int_B f d\lambda \quad \forall B \in \mathcal{B} \quad \text{mit } 0 \notin B$$

und

Gemischte Verteilungen VI

$$\mathbb{P}(\{0\}) = \alpha > 0.$$

Setze nun

$$f^*(x) := (1 - \alpha) \cdot f(x) \quad \forall x \in \mathbb{R} \setminus \{0\}$$

und

$$f^*(x) := \alpha \text{ falls } x = 0.$$

Gemischte Verteilungen VII

Dann ist

$$f^* : \mathbb{R} \rightarrow \mathbb{R}, \quad x \mapsto f^*(x)$$

die Radon-Nikodým-Dichte von $\mathbb{P}$ bzgl. $\mu = \lambda + \delta_0$ das heißt

$$\mathbb{P}(A) = \int_A f^* d\mu \quad \forall A \in \mathcal{B}.$$

Kapitel 8

Momente

8. Momente

8.1 Erwartungswert

8.2 Momente

8.3 Einige Ungleichungen

8.4 Normen



Momente

Da lernt man Dreisatz und Wahrscheinlichkeitsrechnung und steht trotzdem grübelnd vor dem Backofen, welche der vier Schienen nun die Mittlere ist.

anonym

Ziele des Kapitels

- ▶ Verallgemeinerung der Definition des Erwartungswertes
- ▶ Erwartungswert als Integral über die Zufallsvariable bezüglich der Verteilung
- ▶ Höhere Momente
- ▶ Beschreibung der Form der Dichte
- ▶ Einige Ungleichungen, die die Momente benutzen

8. Momente

8.1 Erwartungswert

8.2 Momente

8.3 Einige Ungleichungen

8.4 Normen

Erwartungswert I

Definition (Erwartungswert)

Ist $X : \Omega \rightarrow \mathbb{R}$ eine quasi-integrierbare reelle Zufallsvariable, so heißt

$$\mathbb{E}(X) := \int X \, d\mathbb{P} = \int x \, d\mathbb{P}_X(x)$$

der Erwartungswert (engl. **expected value**) von X .

Die zweite Gleichheit ergibt sich aus folgendem Satz:

Satz

Sei $X : \Omega \rightarrow \mathbb{R}^n$ eine n -dimensionale reelle Zufallsvariable und $g : \mathbb{R}^n \rightarrow \mathbb{R}$ eine meßbare Funktion, so daß $g \circ X : \Omega \rightarrow \mathbb{R}$ integrierbar ist. Dann gilt

$$\int g \, d\mathbb{P}_X = \int g \circ X \, d\mathbb{P}.$$

Erwartungswert II

Beweis:

Ist $g = I_A$, $A \in \mathcal{B}^n$, so ist

$$\begin{aligned}(g \circ X)(\omega) &= g(X(\omega)) \\&= I_A(X(\omega)) = \begin{cases} 1 & X(\omega) \in A \\ 0 & \text{sonst} \end{cases} \\&= \underbrace{I_{X^{-1}(A)}}_{\in \mathcal{F}}(\omega) = \begin{cases} 1 & \omega \in X^{-1}(A) = \{\omega \in \Omega \mid X(\omega) \in A\} \\ 0 & \text{sonst} \end{cases} \\ \implies \int g \, d\mathbb{P}_X &= \int I_A \, d\mathbb{P}_X = \mathbb{P}_X(A) = \mathbb{P}(X^{-1}(A)) \\&= \int I_{X^{-1}(A)} \, d\mathbb{P} = \int g \circ X \, d\mathbb{P}\end{aligned}$$

Für $g \in T^+$ folgt alles weitere aus der Linearität und $g \in M^+$ über Grenzwertbildung. □

Erwartungswert III

Es gilt also auch

$$\mathbb{E}(g(X)) = \int g \circ X d\mathbb{P} \stackrel{\text{Satz 8.2}}{=} \int g d\mathbb{P}_X$$

Außerdem gilt für eine Verteilung mit Dichte f_X

$$\mathbb{E}(g(X)) = \int g d(f_X \odot \mu) \stackrel{\text{Lemma 7.1}}{=} \int g f_X d\mu$$

Erwartungswert IV

Spezialfälle

- Für diskrete Zufallsvariablen, $\mu = \mu_Z$ und T abzählbar:

$$\mathbb{E}(g(X)) = \sum_{x \in T} g(x) f_X(x)$$

- Für stetige Zufallsvariablen, $\mu = \lambda$, wenn f_X Riemann-integrierbar:

$$\mathbb{E}(g(X)) = \int_{-\infty}^{\infty} g(x) f_X(x) dx$$

Eigenschaften des Erwartungswerts I

Alle Eigenschaften des Lebesgue-Integrals übertragen sich direkt auf den Erwartungswert, insbesondere Satz 6.9:

Linearität: $\mathbb{E}(aX + b) = a\mathbb{E}(X) + b$

$$\mathbb{E}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \mathbb{E}(X_i)$$

Monotonie: $X \leq Y \implies \mathbb{E}(X) \leq \mathbb{E}(Y)$

- An diese Eigenschaft des Erwartungswertes der Summe von Zufallsvariablen gibt es keine Voraussetzungen (außer dass die $\mathbb{E}(X_i)$ existieren). Insbesondere gelten diese Eigenschaften auch für abhängige Zufallsvariablen!

Eigenschaften des Erwartungswerts II

Aus dem Satz von Beppo-Levi (Satz 6.10) folgt für eine monoton wachsende Folge von Zufallsvariablen $(X_n)_{n \in \mathbb{N}}$

$$\lim_{n \rightarrow \infty} \mathbb{E}(X_n) = \mathbb{E} \left(\lim_{n \rightarrow \infty} X_n \right).$$

Beispiele I

Beispiel 8.1

Wir werfen zweimal eine faire Münze.

- ▶ Sei $X = 1$ wenn erster Wurf Kopf und 0 sonst.
- ▶ Sei Y die Anzahl der Würfe mit Kopf bei beiden Würfeln.

Offensichtlich sind X und Y stochastisch abhängig! Aber

$$\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y) = 0.5 + 1 = 1.5$$

Beispiele II

Beispiel 8.2 (Bernoulli-Verteilung)

Sei $X \sim B(1, p)$ mit Dichte $f(x) = p^x \cdot (1 - p)^{1-x} \cdot I_{\{0,1\}}(x)$

Dann:

$$\begin{aligned}\mathbb{E}(X) &= \int X \, d\mathbb{P} = \int x \, d\mathbb{P}_X(x) \\ &= \int x \, d(f_X \odot \mu_Z)(x) = \int x f_X(x) \, d\mu_Z(x) = \sum_{x \in \{0,1\}} x \cdot f_X(x) \\ &= 1 \cdot p + 0 \cdot (1 - p) = p\end{aligned}$$

Beispiele III

Beispiel 8.3 (Binomialverteilung)

Sei $X \sim B(n, p)$ mit Dichte $f(x) = \binom{n}{x} p^x (1-p)^{n-x} \cdot I_{\{0, \dots, n\}}(x)$

$$\begin{aligned}\mathbb{E}(X) &= \sum_{x=0}^n x \binom{n}{x} p^x (1-p)^{n-x} = n \sum_{x=0}^n \binom{n-1}{x-1} p^x (1-p)^{n-x} \\ &= n p \sum_{x=1}^n \binom{n-1}{x-1} p^{x-1} (1-p)^{n-x} = n p \underbrace{\sum_{x=0}^{n-1} \binom{n-1}{x} p^x (1-p)^{n-x-1}}_{\text{Binomische Formel}} \\ &= n p (p + (1-p))^{n-1} = np,\end{aligned}$$

Beispiele IV

Beispiel 8.4

Sei $X \sim \text{Exp}(\lambda)$ mit Dichte $f(x) = \lambda \exp(-\lambda x) I_{\mathbb{R}^+}(x)$

$$\begin{aligned}\mathbb{E}(X) &= \int_0^{\infty} \underbrace{x \cdot \lambda}_{h(x)} \underbrace{\exp(-\lambda x)}_{g'(x)} dx \\ &\stackrel{\text{PI}}{=} \left[\underbrace{x \cdot \lambda}_{h(x)} \underbrace{\frac{1}{-\lambda} \exp(-\lambda x)}_{g(x)} \right]_0^{\infty} - \int_0^{\infty} \underbrace{\lambda}_{h'(x)} \cdot \underbrace{\frac{1}{-\lambda} \exp(-\lambda x)}_{g(x)} dx \\ &= [-x \exp(-\lambda x)]_0^{\infty} + \int_0^{\infty} \exp(-\lambda x) dx \\ &= [-x \exp(-\lambda x)]_0^{\infty} + \left[-\frac{1}{\lambda} \exp(-\lambda x) \right]_0^{\infty} = \frac{1}{\lambda}\end{aligned}$$

Sankt-Petersburg-Paradoxon I

In einem Glücksspiel, für das eine Teilnahmegebühr verlangt wird, wird eine faire Münze so lange geworfen, bis zum ersten Mal „Kopf“ fällt (Geometrische Verteilung).

Als Gewinn erhält man bei x Würfeln insgesamt 2^{x-1} Euro. Welchen Geldbetrag würde man für die Teilnahme an diesem Spiel bezahlen?

Sei X die Zufallsvariable „Anzahl der Würfe“. Die Wahrscheinlichkeit, dass das erste Mal beim x -ten Münzwurf „Kopf“ fällt ist

$$\mathbb{P}(X = x) = \left(\frac{1}{2}\right)^x$$

Sankt-Petersburg-Paradoxon II

Wie groß ist der erwartete Gewinn?

$$\mathbb{E}(2^{X-1}) = \sum_{x=1}^{\infty} \mathbb{P}(X = x) \cdot 2^{x-1} = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 4 + \dots \quad (1)$$

$$= \sum_{x=1}^{\infty} \frac{1}{2^x} \cdot 2^{x-1} = \sum_{x=1}^{\infty} \frac{1}{2} = \infty. \quad (2)$$

- ▶ Der erwartete Gewinn ist also unendlich groß!
- ▶ Würde man rein rational gesehen unendlichen Einsatz akzeptieren?

Existenz des Erwartungswertes I

Zur Erinnerung: sei X eine Zufallsvariable mit Dichte f bezüglich des dominierenden Maßes μ . Dann ist nach Def. 6.7

$$\mathbb{E}(X) := \int X \, d\mathbb{P} = \int X^+ \, d\mathbb{P} - \int X^- \, d\mathbb{P}$$

wobei X^+ der Positivteil und X^- der Negativteil von X ist. Folgerungen:

- ▶ X besitzt genau dann einen *Erwartungswert*, wenn es *quasiintegrierbar* ist.
- ▶ Ist X integrierbar, dann ist auch $|X|$ integrierbar.

Sind beide Integrale endlich, ist X also *integrierbar*, dann ist auch der Erwartungswert endlich: $\mathbb{E}(X) < \infty$. Wir sagen,
der Erwartungswert von X existiert. Auch $\mathbb{E}(|X|) < \infty$ existiert dann.


Existenz des Erwartungswertes II

Definition

Sei $X : \Omega \rightarrow \mathbb{R}$ Zufallsvariable mit stetiger Dichte

$$f(x) = \frac{1}{\pi(1+x^2)}$$

Dann heißt X Cauchy-verteilt.



Existenz des Erwartungswertes III

Beispiel 8.5

Sei $X \sim \text{Cauchy}$.

$$\begin{aligned}\mathbb{E}(X) &= \int x \frac{1}{\pi(1+x^2)} dx = \frac{1}{\pi} \int \frac{x}{1+x^2} dx \\ &= \frac{1}{\pi} \left[\frac{1}{2} \log(1+x^2) \right]_{-\infty}^{+\infty}\end{aligned}$$

$\Rightarrow$ nicht integrierbar, Cauchy hat keinen Erwartungswert!

8. Momente

8.1 Erwartungswert

8.2 Momente

8.3 Einige Ungleichungen

8.4 Normen

Momente I

Definition (Momente)

Sei X eine integrierbare Zufallsvariable und $n \in \mathbb{N}$, so daß X^n quasi-integrierbar ist. Dann heißt

$m_n(X) = \mathbb{E}(X^n)$	n -tes <u>Moment</u> (engl. raw moment),
$m_{(n)}(X) = \mathbb{E}(X ^n)$	n -tes <u>absolutes Moment</u> (engl. absolute moment),
$m_n^0(X) = \mathbb{E}((X - \mathbb{E}(X))^n)$	n -tes <u>zentriertes Moment</u> (engl. central moment)

von X .

Momente II

- ▶ Erstes Moment: $m_1(X) = \mathbb{E}(X)$
- ▶ Erstes zentriertes Moment: $m_1^0(X) = \mathbb{E}(X - \mathbb{E}(X)) \equiv 0$
- ▶ Zweites zentriertes Moment: $m_2^0(X) = \text{Var}(X)$

Bemerkung: Def. 8.4 bezieht sich auf reelwertige Zufallsvariablen, lässt sich aber auch auf $X : \Omega \rightarrow \mathbb{R}^n$ verallgemeinern (später mehr dazu).

Varianz I

Definition (Varianz einer Zufallsvariablen)

Ist X eine ZV mit $\mathbb{E}(|X|) < \infty$ so heißt

$$\text{Var}(X) := \mathbb{E}((X - \mathbb{E}(X))^2)$$

Varianz (engl. *variance*) von X .

Verschiebungssatz

$$\text{Var}(X) := \mathbb{E}((X - \mathbb{E}(X))^2) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$$

Varianz II

Spezialfälle (unter Bedingungen wie beim Erwartungswert):

- ▶ Stetige Zufallsvariable: $\text{Var}(X) = \int (x - \mathbb{E}(X))^2 f_X(x) dx$
- ▶ Diskrete Zufallsvariable: $\text{Var}(X) = \sum_{x \in T} (x - \mathbb{E}(X))^2 f_X(x)$

Varianz III

Lineare Transformation

Satz

Sei $Y = a \cdot X + b$. Dann ist $\text{Var}(Y) = a^2 \text{Var}(X)$

Beweis:

$$\begin{aligned}\text{Var}(Y) &= \mathbb{E}(Y^2) - \mathbb{E}(Y)^2 \\&= \mathbb{E}((a \cdot X + b)^2) - \mathbb{E}(a \cdot X + b)^2 \\&= \mathbb{E}(a^2 X^2 + 2abX + b^2) - (a\mathbb{E}(X) + b)^2 \\&= a^2 \mathbb{E}(X^2) + 2ab\mathbb{E}(X) + b^2 - a^2 \mathbb{E}(X)^2 - 2ab\mathbb{E}(X) - b^2 \\&= a^2 (\mathbb{E}(X^2) - \mathbb{E}(X)^2) = a^2 \text{Var}(X)\end{aligned}$$



Varianz IV

Für reelle Zufallsvariablen gilt

$$\text{Var}(X) \geq 0$$

$$\begin{aligned}\text{Var}(X) = 0 &\implies \{\omega \in \Omega \mid (X(\omega) - \mathbb{E}(X))^2 > 0\} \text{ ist } \mathbb{P}\text{-Nullmenge} \\ &\implies X = \mathbb{E}(X) \quad \mathbb{P}\text{-fast-sicher} \\ &\text{bzw. } X \sim \delta_{\mathbb{E}(X)}\end{aligned}$$

Varianz V

Beispiel 8.6 (Bernoulli-Verteilung)

Sei $X \sim B(1, p)$.

$$\begin{aligned}\operatorname{Var}(X) &= \int (X - \mathbb{E}(X))^2 d\mathbb{P} = \sum_{x \in T} x^2 f_X(x) - p^2 \\ &= 1^2 \cdot p + 0^2 \cdot (1 - p) - p^2 = p(1 - p).\end{aligned}$$

Varianz VI

Beispiel 8.7 (Binomialverteilung)

$$X \sim B(n, p)$$

$$\begin{aligned}\text{Var}(X) &= \sum_{x=0}^n x^2 \binom{n}{x} p^x (1-p)^{n-x} - (np)^2 \\ &\stackrel{q:=1-p}{=} np \sum_{x=1}^n x \binom{n-1}{x-1} p^{x-1} q^{n-x} - (np)^2 \\ &= np \sum_{x=0}^{n-1} (x+1) \binom{n-1}{x} p^x q^{n-1-x} - (np)^2 \\ &= np \left(\sum_{x=0}^{n-1} x \binom{n-1}{x} p^x q^{n-1-x} + 1 \right) - (np)^2 \\ &= np((n-1)p + 1) - (np)^2 = np(1-p).\end{aligned}$$

Varianz VII

Beispiel 8.8

$$\begin{aligned} X &\sim \text{Exp}(\lambda) \\ \mathbb{E}(X^2) &= \int_0^{\infty} \underbrace{x^2}_{f(x)} \underbrace{\lambda \exp(-\lambda x)}_{g'(x)} dx \\ &= \left[\underbrace{x^2 \lambda}_{f(x)} \underbrace{\frac{1}{-\lambda} \exp(-\lambda x)}_{g(x)} \right]_0^{\infty} - \int_0^{\infty} \underbrace{2x \lambda}_{f'(x)} \underbrace{\frac{1}{-\lambda} \exp(-\lambda x)}_{g(x)} dx \\ &= 0 + \underbrace{\frac{2}{\lambda} \int_0^{\infty} x \lambda \exp(-\lambda x) dx}_{=\mathbb{E}(X)=1/\lambda} = \frac{2}{\lambda^2} \end{aligned}$$

Varianz VIII

$$\Rightarrow \text{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2 = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$$

Varianz IX

Beispiel 8.9 (Stetige Gleichverteilung)

$$\mathbb{E}(X) = \frac{1}{b-a} \int_a^b x \, dx = \frac{a+b}{2},$$

$$\begin{aligned} \text{Var}(X) &= \frac{1}{b-a} \int_a^b x^2 \, dx - \left(\frac{a+b}{2} \right)^2 = \frac{1}{b-a} \left[\frac{1}{3} x^3 \right]_a^b - \left(\frac{a+b}{2} \right)^2 \\ &= \frac{4(b^3 - a^3) - 3(b-a)(a^2 + 2ab + b^2)}{12(b-a)} = \frac{b^3 - a^3 - 3a^2b + 3ab^2}{12(b-a)} \\ &= \frac{(b-a)^2}{12}. \end{aligned}$$

Schiefe I

Definition

Sei X^3 quasi-integrierbar. Dann heißt

$$\gamma(X) := \frac{m_3^0(X)}{m_2^0(X)^{\frac{3}{2}}} = \frac{\mathbb{E}((X - \mathbb{E}(X))^3)}{\sqrt{\text{Var}(X)}^3}$$

die Schiefe (engl. *skewness*) von X . Für

- ▶ $\gamma(X) > 0$ heißt X bzw. deren Verteilung rechtsschief (engl. *right-skewed, positively skewed*) (linkssteil),
- ▶ $\gamma(X) < 0$ heißt X bzw. deren Verteilung linksschief (engl. *left-skewed, negatively skewed*) (rechtssteil).

Schiefe II

Definition

Eine Zufallsvariable X mit stetiger Dichte

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma_X} \exp\left(-\frac{(\ln(x) - \mu)^2}{2\sigma^2}\right) I_{\mathbb{R}^+}(x),$$

heißt log-normalverteilt, $X \sim \text{LN}(\mu, \sigma^2)$ mit Parametern $\mu \in \mathbb{R}$ und $\sigma^2 \in \mathbb{R}^+$

- ▶ Ist $X \sim \text{LN}(\mu, \sigma^2)$, dann ist $\ln(X) \sim \text{N}(\mu, \sigma^2)$.
- ▶ Die Log-Normalverteilung ist *rechtsschief* bzw. *linkssteil*:

$$\gamma = (\exp(\sigma^2) + 2) \sqrt{\exp(\sigma^2) - 1} > 0$$

Schiefe III

```
plot(x, dlnorm(x), type = "l", ylab = "f")
```




Abbildung 14: Dichte der LN(0,1)-Verteilung

Wölbung I

Definition

Sei X^4 quasi-integrierbar. Dann heißt

$$K(X) := \frac{m_4^0(X)}{(m_2^0(X))^2}$$

die Kurtosis oder Wölbung (engl. *kurtosis*) von X .

Wölbung II

Definition

Eine Zufallsvariable X mit stetiger Dichte

$$f(x) = \frac{1}{2\sigma} \exp\left(-\frac{|x - \mu|}{\sigma}\right)$$

heißt Laplaceverteilt mit Parametern $\mu \in \mathbb{R}$ und $\sigma \in \mathbb{R}^+$

- ▶ $X \sim \text{Laplace}(\mu, \sigma) \implies K(X) = 6$
- ▶ $X \sim N(\mu, \sigma^2) \implies K(X) = 3$
- ▶ $X \sim U(a, b) \implies K(X) = 1.8$

Wölbung III




Abbildung 15: Beispiel verschiedener Wölbungen

Symmetrische Verteilung I

Sei $\mathbb{P}$ Verteilung auf $(\mathbb{R}, \mathcal{B})$.

Definition

$\mathbb{P}$ heißt symmetrisch um $a \in \mathbb{R}$, wenn

$$\mathbb{P}([-\infty, a - x]) = \mathbb{P}([a + x, \infty])$$

Satz

Sei $\mathbb{P}$ eine um a symmetrische Verteilung auf $(\mathbb{R}, \mathcal{B})$; $X \sim \mathbb{P}_X = \mathbb{P}$ und g eine integrierbare Funktion. Dann gilt:

- i) $\int g \, d\mathbb{P}_X = \int g(x) \, d\mathbb{P}_X(x) = \int g(2a - x) \, d\mathbb{P}_X(x)$
- ii) $m_1(X) = a$
- iii) $m_{2n+1}^0(X) = 0 \quad \forall n \in \mathbb{N}$.
- iv) a ist Median von X

Symmetrische Verteilung II

Beweis:

i) $\mathbb{P}_{X-a} = \mathbb{P}_{-(X-a)}$ (da $\mathbb{P}$ symmetrisch)

$$\begin{aligned}\implies \mathbb{P}((X-a) \leq t) &= \mathbb{P}(X \leq a+t) \\ &= \mathbb{P}(X \geq a-t) = \mathbb{P}(-X + a \leq t) \quad (\text{Symmetrie})\end{aligned}$$

$$\begin{aligned}\implies \int g \circ X \, d\mathbb{P} &= \int g \, d\mathbb{P}_X = \mathbb{E}(g(X)) \\ &= \mathbb{E}(g(a + (X-a))) = \mathbb{E}(g(a - (X-a))) \quad (\text{Symmetrie}) \\ &= \mathbb{E}(g(2a - X)) = \int g(2a - x) \, d\mathbb{P}_X(x)\end{aligned}$$

Symmetrische Verteilung III

ii)

$$m_1(X) = \int X \, d\mathbb{P} \stackrel{i)}{=} \frac{1}{2} \left[\int X \, d\mathbb{P} + \int (2a - X) \, d\mathbb{P} \right] = \frac{1}{2} 2a = a$$

iii)

$$\begin{aligned} m_k^0(X) &= \int (X - m_1(X))^k \, d\mathbb{P} = \int (X - a)^k \, d\mathbb{P} \\ &\stackrel{i)}{=} \frac{1}{2} \left[\int (X - a)^k \, d\mathbb{P} + \int (2a - X - a)^k \, d\mathbb{P} \right] \\ &= \frac{1}{2} \left[\int (X - a)^k \, d\mathbb{P} + \int (-1)^k (X - a)^k \, d\mathbb{P} \right] \\ &= \frac{1}{2} \left[\int (X - a)^k \, d\mathbb{P} - \int (X - a)^k \, d\mathbb{P} \right] = 0 \quad (k \text{ ungerade}) \end{aligned}$$

Symmetrische Verteilung IV

iv) folgt direkt aus Definition. □

Beispiel 8.10

Dichte der Normalverteilung (Def.7.5):

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right)$$

$X \sim N(\mu, \sigma^2)$ symmetrisch um $\mu \implies m_1(X) = \mathbb{E}(X) = \mu$

Symmetrische Verteilung V

Beispiel 8.11

Dichte der Cauchy-Verteilung:

$$f(x) = \frac{1}{\pi(1+x^2)}$$

ist symmetrisch mit Median 0. Aber Satz 8.12 greift nicht, weil der $\mathbb{E}(X)$ nicht existiert!

8. Momente

8.1 Erwartungswert

8.2 Momente

8.3 Einige Ungleichungen

8.4 Normen

Ungleichungen von Markov- und Chebyshev I

Satz (Markov- und Chebyshev-Ungleichungen)

Sei $X : \Omega \rightarrow \mathbb{R}$ eine reelle ZV. Dann gilt für jedes $\epsilon > 0$:

$$\begin{aligned}\mathbb{P}(|X| \geq \epsilon) &\leq \frac{1}{\epsilon^n} \int |X|^n I_{\{|X| \geq \epsilon\}} d\mathbb{P} \\ &\leq \frac{1}{\epsilon^n} \mathbb{E}(|X|^n).\end{aligned}$$

Ungleichungen von Markov- und Chebyshev II

Spezialfälle:

- ▶ $n = 1$ (Markov-Ungleichung):

$$\mathbb{P}(|X| \geq \epsilon) \leq \frac{1}{\epsilon} \mathbb{E}(|X|)$$

- ▶ $n = 2$ (Chebyshev-Ungleichung): falls $\mathbb{E}(X^2) < \infty$:

$$\mathbb{P}(|X - \mathbb{E}(X)| \geq \epsilon) \leq \frac{\mathbb{E}((X - \mathbb{E}(X))^2)}{\epsilon^2} = \frac{\text{Var}(X)}{\epsilon^2}$$

Ungleichungen von Markov- und Chebyshev III

Beweis:

Sei $Y \geq 0$ Zufallsvariable. Dann gilt für jedes $\alpha > 0$:

$$\begin{aligned}\alpha \cdot I_{\{Y \geq \alpha\}} &\leq Y \cdot I_{\{Y \geq \alpha\}} \leq Y. \\ \Rightarrow \int \alpha \cdot I_{\{Y \geq \alpha\}} d\mathbb{P} &= \alpha \cdot \int I_{\{Y \geq \alpha\}} d\mathbb{P} = \alpha \cdot \mathbb{P}(\{Y \geq \alpha\}) \\ &\leq \int Y I_{\{Y \geq \alpha\}} d\mathbb{P} \leq \int Y d\mathbb{P} = \mathbb{E}(Y) \\ \Rightarrow \mathbb{P}(Y \geq \alpha) &\leq \frac{1}{\alpha} \int_{\{Y \geq \alpha\}} Y d\mathbb{P} \leq \frac{1}{\alpha} \mathbb{E}(Y)\end{aligned}$$

Mit $Y := |X|^n$ und $\alpha = \epsilon^n$ folgt

$$\mathbb{P}(|X|^n \geq \epsilon^n) \leq \frac{1}{\epsilon^n} \mathbb{E}(|X|^n)$$



Ungleichung von Jensen I

Die Ungleichung von Jensen ist aus der Analysis bekannt. Für eine konvexe Funktion $f(x)$ gilt:

$$f\left(\sum_{i=1}^n \lambda_i x_i\right) \leq \sum_{i=1}^n \lambda_i f(x_i).$$




Abbildung 16: Konvexe Funktion

Ungleichung von Jensen II

Satz (Jensen'sche Ungleichung)

Sei $f : I \rightarrow \mathbb{R}$ eine konvexe Funktion auf einem Intervall $I \subset \mathbb{R}$ und $X : \Omega \rightarrow I$ eine integrierbare Zufallsvariable. Dann gilt

$$f(\mathbb{E}(X)) \leq \mathbb{E}(f(X)).$$

Sei $g : I \rightarrow \mathbb{R}$ eine konkave Funktion auf einem Intervall $I \subset \mathbb{R}$ und $X : \Omega \rightarrow I$ eine integrierbare Zufallsvariable. Dann gilt

$$g(\mathbb{E}(X)) \geq \mathbb{E}(g(X)).$$

Ungleichung von Jensen III

Beweis:

$f : I \rightarrow \mathbb{R}$ konvex : $\Longleftrightarrow$

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y) \quad \forall x, y \in I, \alpha \in [0, 1]$$

Sei $V = \{v \mid v(x) = a + bx \leq f(x) \quad \forall x \in I\}$ die Menge aller linearen Funktionen unterhalb f .

$$f(x) = \sup_{v \in V} v(x)$$

$$\mathbb{E}(f(X)) = \mathbb{E}(\sup_{v \in V} v(X)) \stackrel{\forall v_0 \in V}{\geq} \mathbb{E}(v_0(X)) = v_0(\mathbb{E}(X))$$

$$\implies \mathbb{E}(f(X)) \geq \sup_{v_0 \in V} v_0(\mathbb{E}(X))$$

$$\mathbb{E}(f(X)) \geq f(\mathbb{E}(X))$$

Analog für g konkav.



Ungleichung von Jensen IV

Beispiel 8.12

a) $\mathbb{E}(X^2) \geq \mathbb{E}(X)^2$, da $f(x) = x^2$ konvex

b) $\mathbb{P}(X > 0) = 1 \implies \mathbb{E}\left(\frac{1}{X}\right) \geq \frac{1}{\mathbb{E}(X)}$ mit $f(x) = \frac{1}{x}$

8. Momente

8.1 Erwartungswert

8.2 Momente

8.3 Einige Ungleichungen

8.4 Normen

Normen I

Definition (Norm)

Sei $f : \Omega \rightarrow \mathbb{R}$ $\mathcal{F}$ - $\mathcal{B}$ -meßbar auf $(\Omega, \mathcal{F}, \mu)$. Dann heißt

$$\|f\|_p := \left(\int |f|^p d\mu \right)^{1/p} \in [0, \infty[$$

die p -Norm (engl. norm) von f .

- Für eine Zufallsvariable X ist also $\|X\|_p$ die p -te Wurzel aus dem p -ten absoluten Moment von X :

$$\mathbb{E}(|X|^p) = \|X\|_p^p$$

Normen II

Definition (L^p -Raum)

Für $p \geq 1$ ist der L^p -Raum

$$L^p := L^p(\Omega, \mathcal{F}, \mu) := \{f \mid f : \Omega \rightarrow \mathbb{R}, f \text{ } \mathcal{F}\text{-}\mathcal{B}\text{-meßbar}, \|f\|_p < \infty\}.$$

Normen III

Allgemein ist eine Norm eine Abbildung eines mathematischen Objekts auf eine Zahl. Bekannt aus lineare Algebra ist die **Vektornorm**

$$||\mathbf{v}|| := \sqrt{v_1^2 + \dots + v_n^2}$$

Ungleichung von Hölder I

Satz (Ungleichung von Hölder)

Es sei $1 < p, q < \infty$ mit $\frac{1}{p} + \frac{1}{q} = 1$.

Dann gilt für zwei meßbare Funktionen $f, g : \Omega \rightarrow \mathbb{R}$:

$$\|f \cdot g\|_1 \leq \|f\|_p \cdot \|g\|_q.$$

Beweis

- ▶ $\|f\|_p = 0$ oder $\|g\|_q = 0 \implies f \cdot g = 0 \text{ } \mu\text{-f.ü.}$ ✓
- ▶ $(\|f\|_p = \infty \text{ oder } \|g\|_q = \infty) \text{ und } \|f\|_p \|g\|_q > 0$ ✓

Ungleichung von Hölder II

- $0 < \|f\|_p, \|g\|_q < \infty$:
Sei $x, y \geq 0$, $\alpha, \beta \geq 0$ mit $\alpha + \beta = 1$.

$$\begin{aligned}\ln(x^\alpha y^\beta) &= \alpha \ln x + \beta \ln y \leq \ln(\alpha x + \beta y) && \text{(Konkavität)} \\ \implies x^\alpha y^\beta &\leq \alpha x + \beta y\end{aligned}$$

Ungleichung von Hölder III

$$\text{Mit } x := \frac{|f|^p}{\|f\|_p^p}; \quad y := \frac{|g|^q}{\|g\|_q^q}; \quad \alpha = \frac{1}{p}, \quad \beta = \frac{1}{q}$$

$$\begin{aligned} \frac{|f| |g|}{\|f\|_p \|g\|_q} &\leq \frac{1}{p} \frac{|f|^p}{\|f\|_p^p} + \frac{1}{q} \frac{|g|^q}{\|g\|_q^q} \\ \int \frac{|f| |g| d\mu}{\|f\|_p \|g\|_q} &\leq \frac{1}{p} \cdot \frac{1}{\|f\|_p^p} \underbrace{\int |f|^p d\mu}_{=\|f\|_p^p} + \frac{1}{q} \cdot \frac{1}{\|g\|_q^q} \underbrace{\int |g|^q d\mu}_{=\|g\|_q^q} \end{aligned}$$

$$\frac{\int |f| |g| d\mu}{\|f\|_p \|g\|_q} \leq \frac{1}{p} + \frac{1}{q} \stackrel{\text{n.V.}}{=} 1$$

$$\int |fg| d\mu \leq \|f\|_p \|g\|_q$$

$$\|fg\|_1 \leq \|f\|_p \|g\|_q$$



Ungleichung von Hölder IV

Daraus folgt direkt für $p = q = 2$

Satz (Cauchy-Schwarz-Ungleichung)

$$(\mathbb{E}(XY))^2 \leq \mathbb{E}(X^2) \mathbb{E}(Y^2)$$

Vergleiche auch Cauchy-Schwarz-Ungleichung für Vektoren.

Ungleichung von Hölder V

Satz

Ist $\mu(\Omega) < \infty$ und $q > p \geq 1$, so ist $L^q \subset L^p$ und es gibt $c \geq 0$, so daß

$$\|f\|_p \leq c \|f\|_q \quad \forall f \in L^q.$$

Beispiel 8.13

$$m_{(k)}(X) < \infty \implies m_{(j)}(X) < \infty \quad \forall j \leq k$$

Ungleichung von Hölder VI

Beweis:

$r := \frac{q}{p}$ $s := \left(1 - \frac{1}{r}\right)^{-1}$, so daß $\left(\frac{1}{r} + \frac{1}{s}\right) = 1$.

$$\begin{aligned}\|f\|_p^p &= \int |f|^p d\mu = \| |f|^p \cdot I_\Omega \|_1 \\ &\stackrel{\text{Hölder}}{\leq} \left(\int |f|^{pr} d\mu \right)^{\frac{1}{r}} \left(\int |I_\Omega|^s d\mu \right)^{\frac{1}{s}} = \left(\int |f|^q d\mu \right)^{\frac{p}{q}} \mu(\Omega)^{\frac{1}{s}} \\ &= \|f\|_q^p \cdot \underbrace{\mu(\Omega)^{\frac{1}{s}}}_{< \infty} < \infty\end{aligned}$$

und die p -te Wurzel liefert die Behauptung. □

Ungleichung von Minkowski I

Satz (Ungleichung von Minkowski, Dreiecksungleichung)

Sind $f, g : \Omega \rightarrow \mathbb{R}$ meßbar und $p \geq 1$, so gilt

$$\|f + g\|_p \leq \|f\|_p + \|g\|_p$$

Das heißt, für $1 \leq p < \infty$

$$\mathbb{E}(|X + Y|^p)^{\frac{1}{p}} \leq \mathbb{E}(|X|^p)^{\frac{1}{p}} + \mathbb{E}(|Y|^p)^{\frac{1}{p}}$$

Vergleiche

- ▶ Dreiecksungleichung für reelle Zahlen $|a + b| \leq |a| + |b|$
- ▶ Dreiecksungleichung für Vektoren $\|u + v\| \leq \|u\| + \|v\|$

Ungleichung von Minkowski II

Beweis

Für $p = 1$ oder $\|f\|_p = \infty$ oder $\|g\|_p = \infty$ oder $\|f + g\|_p = 0$ ✓

Jetzt

$p > 1, \|f\|_p < \infty, \|g\|_p < \infty, \|f + g\|_p > 0, q := (1 - \frac{1}{p})^{-1} \implies \frac{1}{p} + \frac{1}{q} = 1$:

$$\begin{aligned}\|f + g\|_p^p &= \int |f + g|^p d\mu \\&= \int |f + g| |f + g|^{p-1} d\mu \\&\leq \int (|f| + |g|) |f + g|^{p-1} d\mu && \text{(Dreiecksungleichung)} \\&= \int |f| |f + g|^{p-1} d\mu + \int |g| |f + g|^{p-1} d\mu \\&\leq (\|f\|_p + \|g\|_p) \| |f + g|^{p-1} \|_q && (2 \times \text{Hölder})\end{aligned}$$

Ungleichung von Minkowski III

$$\begin{aligned}\Rightarrow \| |f + g|^{p-1} \|_q &= \left(\int |f + g|^p d\mu \right)^{\frac{1}{q}} = \|f + g\|_p^{\frac{p}{q}} \\ \Rightarrow \|f + g\|_p^p &\leq (\|f\|_p + \|g\|_p) \|f + g\|_p^{\frac{p}{q}} \\ \|f + g\|_p^p \|f + g\|_p^{-\frac{p}{q}} &\leq (\|f\|_p + \|g\|_p) \|f + g\|_p^{\frac{p}{q}} \|f + g\|_p^{-\frac{p}{q}}\end{aligned}$$

Also da $p - \frac{p}{q} = p - p \left(1 - \frac{1}{p}\right) = 1$:

$$\|f + g\|_p \leq \|f\|_p + \|g\|_p$$



Kapitel 9

Weitere Parameter von Verteilungen

9. Weitere Parameter von Verteilungen

9.1 Modi

9.2 Lage-, Skalen- und Formparameter

9.3 Exponentialfamilie



9. Weitere Parameter von Verteilungen

9.1 Modi

9.2 Lage-, Skalen- und Formparameter

9.3 Exponentialfamilie

Modus I

Definition

Gegeben sei eine eindimensionale Zufallsvariable X mit Verteilung $\mathbb{P}_X$ und Dichte $f(x)$.


Eine Zahl m heißt Modus (engl. *mode*) von X bzw. $\mathbb{P}$ wenn $f(m)$ ein lokales Maximum von $f(x)$ ist.

- ▶ Die Definition lässt sich leicht auf mehrdimensionale Verteilungen erweitern.
- ▶ Da Dichten stetiger Zufallsvariablen nur fast sicher eindeutig sind, sind formal auch Modi nur fast sicher eindeutig.

Modus II

Beispiele

- ▶ Der Modus der $B(n, 0.5)$ -Verteilung ist $\frac{n}{2}$, wenn n gerade ist. Ist n ungerade, sind $\frac{n-1}{2}$ und $\frac{n+1}{2}$ Modi.
- ▶ Sei $X \sim \text{Exp}(1)$ mit Dichte $f(x) = \lambda \exp(-\lambda x) I_{\mathbb{R}_0^+}(x)$. Der Modus von X ist 0 und es gilt $\mathbb{P}(X > 0) = 1$.



Modus III

Definition

Hat eine stetige Dichte nur einen Modus, so nennt man die Verteilung unimodal.
Hat eine stetige Dichte mehrere Modi, so nennt man die Verteilung multimodal,
bei zwei Modi speziell bimodal.

Mischverteilung I

Satz (Mischverteilung)

Seien $\mathbb{P}_1, \dots, \mathbb{P}_n$ Verteilungen auf $(\Omega, \mathcal{F})$. Dann ist

$$\mathbb{P} := \sum_{i=1}^n w_i \mathbb{P}_i$$

genau dann eine Verteilung, wenn $\sum_{i=1}^n w_i = 1$.

Mischverteilung II

Beweis:

Wegen Satz 3.16 ist $\mathbb{P}$ schon mal ein Maß. Bleibt noch die Normiertheit zu beweisen:

$$\mathbb{P}(\Omega) = \sum_{i=1}^n (w_i \mathbb{P}_i(\Omega)) = \sum_{i=1}^n w_i = 1$$



Insbesondere gilt für stetige bzw. diskrete Zufallsvariablen mit stetigen bzw. Zähl-Dichten $f_1, \dots, f_n$, dass

$$f(x) = \sum w_i f_i(x)$$

die Dichte einer stetigen bzw. diskreten Zufallsvariablen ist.

Nicht verwechseln mit gemischt-stetig-diskrete Verteilungen aus Abschnitt 305.

Mischverteilung III

Definition

Mit $\varphi(x)$ Dichte der Standardnormalverteilung heißt für $i = 1, \dots, k$ die Verteilung mit stetiger Dichte

$$f(x) = \sum_{i=1}^k w_i \cdot \frac{1}{\sigma_i} \varphi\left(\frac{x - \mu_i}{\sigma_i}\right)$$

Gaußsche Mischverteilung (Gaussian mixture). Dabei sind μ_i die Erwartungswerte und σ_i^2 die Varianzen der einzelnen normalverteilten Komponenten.

Mischverteilung IV

Beispiel

Es gäbe in einer Grundgesamtheit zwei Gruppen

- ▶ *Fleißige Studenten* – Diese lernen im Durchschnitt 6 Stunden pro Tag, mit einer gewissen Streuung.
- ▶ *Gelegenheitslerner* – Diese lernen im Durchschnitt 2 Stunden pro Tag, ebenfalls mit einer gewissen Streuung.

Mischverteilung V




Abbildung 17: Gauß-Mischverteilungen. Oben links: identische Varianz und gleiches Gewicht. Oben rechts: Gewichte verschieden. Unten links: Varianzen verschieden. Unten rechts: Drei Verteilungen, mittlere mit höherem Gewicht.

Zero-inflated Poisson I

Für Zählvariablen benutzt man gerne $X \sim \text{Po}(\lambda)$ (siehe Statistik I). Träger ist $T = \mathbb{N}_0$, Parameter ist $\lambda \in \mathbb{R}^+$ (Rate).

$$f(x) = \frac{\lambda^x e^{-\lambda}}{x!} I_T(x)$$

Es gilt:

$$\mathbb{E}(X) = \lambda$$

$$\text{Var}(X) = \lambda$$

Nachteil der Poisson-Verteilung in Datensituationen ist oft, dass beobachteter Mittelwert und Varianz nicht übereinstimmen (Über- oder Unterdispersion). Grund kann zum Beispiel sein, dass öfter die Null beobachtet wird.

Zero-inflated Poisson II

Definition

Sei X eine diskrete Zufallsvariable mit

$$\mathbb{P}(X = 0) = \pi + (1 - \pi) \exp(-\lambda)$$

$$\mathbb{P}(X = x) = (1 - \pi) \exp(-\lambda) \frac{\lambda^x}{x!} \quad \text{für } x = 1, 2, 3, \dots$$

Dann ist X Zero-inflated Poisson-verteilt. $X \sim \text{ZIP}(\lambda, \pi)$.

Zero-inflated Poisson III

Zufällige Ziehung aus Zero-inflated Poisson




Abbildung 18: ZIP-Verteilung

9. Weitere Parameter von Verteilungen

9.1 Modi

9.2 Lage-, Skalen- und Formparameter

9.3 Exponentialfamilie

Lageparameter I

Als **Lageparameter** (engl. *location*) einer Verteilung bezeichnet man alle Parameter, die die Lage der Dichte auf der x -Achse beschreiben, z.B.

- ▶ Erwartungswert
- ▶ Modus
- ▶ Median


Nur für unimodale symmetrische Verteilungen gilt Erwartungswert ist gleich Median ist gleich Modus – sonst nicht!

Beispiel 9.1

Für $X \sim \text{LN}(\mu, \sigma^2)$ (siehe Def. 8.8, rechtsschief) gilt:

- ▶ $\mathbb{E}(X) = \exp(\mu + \frac{1}{2}\sigma^2)$
- ▶ $\text{Median}(X) = \exp(\mu)$
- ▶ $\text{Modus}(X) = \exp(\mu - \sigma^2)$

Lageparameter II



Lageparameter III

Leitsatz (Typische Lageparameter bei Schiefe)

Ist eine Verteilung unimodal und rechtsschief, so gilt typischerweise

$$\text{Modus} \leq \text{Median} \leq E(X).$$

Für linksschiefe Verteilungen kehrt sich die Ungleichung um.

Begründung

1) Sei f unimodal mit Modus m . Falls

$$\int_{-\infty}^m f(x) dx \leq \frac{1}{2}$$

dann gilt jeder Median q erfüllt $q \geq m$. Denn bis m ist noch nicht die Hälfte der Masse erreicht.

Lageparameter IV


2) Für jede Zufallsvariable gilt die Identität (für integrierbares X):

$$E(X) = \int_0^{\infty} P(X > t) dt - \int_0^{\infty} P(X < -t) dt$$

Ein Median q erfüllt $P(X \geq q) \geq \frac{1}{2}$ und $P(X \leq q) \geq \frac{1}{2}$. Bei rechtsschiefer Verteilung sind die rechten *Tail*-Wahrscheinlichkeiten $P(X > t)$ größer als die linken $P(X < -t)$ in einem systematischen Sinn (z.B. für viele Modellklassen/parametrische Familien), wodurch die erste Integralfäche überwiegt und $E(X)$ nach rechts rutscht.

Lageparameter V

Bei Standardverteilungen mit festem $\mathbb{E}(X)$ oft als zusätzlicher *Nichtzentralitätsparameter*. Z.B. nichtzentrale t-Verteilung (siehe 19.14)



Skalen- und Formparameter I

Als **Skalenparameter** (engl. *scale*) bezeichnet man alle Parameter, die die Breite der Dichte beschreiben, z.B.

- ▶ Varianz
- ▶ Interquartilsabstand (75%-Quantil minus 25%-Quantil)

Als **Formparameter** (engl. *shape*) bezeichnet man Parameter, die die Form der Dichte beschreiben. Diese beeinflussen zum Beispiel Schiefe und Kurtosis.

Skalen- und Formparameter II

Definition

Sei $X : \Omega \rightarrow \mathbb{R}$ Zufallsvariable mit stetiger Dichte (für $a, b > 0$),

$$f(x) = \frac{b^a}{\Gamma(a)} x^{a-1} \exp(-bx) \cdot I_{(0,\infty)}(x)$$

heißt Gamma-verteilt: $X \sim \text{Ga}(a, b)$ mit Parametern $a, b > 0$.

Alternative Definition im englischsprachigen Raum mit $k > 0$ und $\theta > 0$,

$$f(x) = \frac{x^{k-1} \exp(-x/\theta)}{\theta^k \Gamma(k)} \cdot I_{(0,\infty)}(x) \quad \text{for } x > 0$$

- ▶ $a = k$ wird als Formparameter bezeichnet
- ▶ b wird als inverser Skalenparameter bezeichnet
- ▶ θ wird als Skalenparameter bezeichnet

Skalen- und Formparameter III

Für $X \sim \text{Ga}(a, b)$ gilt



$$\blacktriangleright \mathbb{E}(X) = \frac{a}{b}$$

$$\blacktriangleright \text{Var}(X) = \frac{a}{b^2}$$

$$\blacktriangleright \text{Skew}(X) = \frac{2}{\sqrt{a}}$$

$$\blacktriangleright K(X) = 3 + \frac{6}{a}$$

Skalen- und Formparameter IV



Tails I




Abbildung 19: Dichte Standardnormal- und $t(2)$ -Verteilung

Tails II

Definition

Eine Verteilung heißt heavy-tailed (hat schweren Rand), wenn

$$\mathbb{E}(\exp(tX)) = \int \exp(tx)f(x)dx = \infty \text{ für alle } t > 0$$

- Äquivalent heißt das $\lim_{x \rightarrow \infty} \exp(tx)(1 - F(X)) = \infty$, also
 $(1 - F(X)) = \mathbb{P}(X > x)$ (*Tailfunktion*) fällt langsamer als $\exp(-tx)$.

Anmerkung: $\mathbb{E}(tX)$ ist die momenterzeugende Funktion, siehe Definition 10.1.

Tails III

Definition

Eine stetige Zufallsvariable X mit Dichte

$$f(x) = \frac{\alpha x_m^\alpha}{x^{\alpha+1}} \mathbb{I}_{[x_m, \infty[}(x)$$

heißt Pareto-verteilt mit Parametern $\alpha > 0$ und $x_m > 0$. Die Verteilungsfunktion ist

$$F(x) = \begin{cases} 1 - \left(\frac{x_m}{x}\right)^\alpha & \text{für } x \geq x_m, \\ 0 & \text{für } x < x_m. \end{cases}$$

O.b.d.A. $x_m = 1$, dann $\mathbb{P}(X > x) = x^{-\alpha}$ und $\exp(tx)x^{-\alpha} \rightarrow \infty$.

Tails IV




Abbildung 20: Dichte der Pareto(1.5, 1)-Verteilung

Tails V

Etwas schwächer:

Definition

Eine Verteilung heißt long-tailed (hat schweren Rand), wenn

$$\lim_{x \rightarrow \infty} \mathbb{P}(X > x + t | X > x) = 1$$

Beispiel Pareto-Verteilung:

$$\begin{aligned} \mathbb{P}(X > x + t | X > x) &= \frac{\mathbb{P}(X > x + t)}{\mathbb{P}(X > x)} \\ &= \left(\frac{x}{x + t} \right)^\alpha \rightarrow 1 \end{aligned}$$

9. Weitere Parameter von Verteilungen

9.1 Modi

9.2 Lage-, Skalen- und Formparameter

9.3 Exponentialfamilie

Exponentialfamilie

Definition

Eine Familie von Wahrscheinlichkeitsmaßen $(\mathbb{P}_\theta)_{\theta \in \Theta}$ $\Theta \subset \mathbb{R}$ heißt Exponentialfamilie, wenn es ein σ -endliches Maß μ gibt, so dass alle $\mathbb{P}_\theta$ eine Dichte der Form

$$f(x; \theta) = h(x)A(\theta) \exp \left(\sum_{i=1}^k \theta_i T_i(x) \right)$$

haben. Dabei heißt $\theta = (\theta_1, \dots, \theta_k)$ der natürliche Parameter.

- ▶ Die Exponentialfamilie ist eine sehr allgemeine und natürliche Klasse von Verteilungen, die unter anderem Normal-, Binomial- (bei festem n), Poisson-, Gamma-, Beta-, Exponential- und Geometrische Verteilung umfasst (Gegenbeispiel: Pareto-Verteilung).
- ▶ Die Exponentialfamilie hat günstige mathematische Eigenschaften, insbesondere in Hinblick auf Likelihood- und Bayes-Inferenz und generalisierte Modellierung.

Kapitel 10

Erzeugende Funktionen

10. Erzeugende Funktionen

10.1 Momenterzeugende Funktion

10.2 Charakteristische Funktion

10.3 Eigenschaften



10. Erzeugende Funktionen

10.1 Momenterzeugende Funktion

10.2 Charakteristische Funktion

10.3 Eigenschaften

Momenterzeugende Funktion I

Definition (momenterzeugende Funktion)

Ist X eine reelle Zufallsvariable und $D := \{t \in \mathbb{R} \mid \mathbb{E}(\exp(tX)) < \infty\}$, so heißt die Funktion

$$\begin{aligned} M : D &\rightarrow \mathbb{R} \\ M(t) &:= \mathbb{E}(\exp(tX)) = \int \exp(tx) d\mathbb{P}_X(x) \end{aligned}$$

momenterzeugende Funktion (engl. moment-generating function).

Momenterzeugende Funktion II

Beispiel 10.1 ($X \sim N(0, 1)$)

$$\begin{aligned}M(t) &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \exp(tx) \exp\left(-\frac{x^2}{2}\right) dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \exp\left(tx - \frac{x^2}{2}\right) dx \\&= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \exp\left(\frac{t^2}{2} - \frac{(x-t)^2}{2}\right) dx \\&= \frac{\exp\left(\frac{t^2}{2}\right)}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \exp\left(-\frac{(x-t)^2}{2}\right) dx \\&\stackrel{u=x-t}{=} \frac{1}{\sqrt{2\pi}} \exp\left(\frac{t^2}{2}\right) \underbrace{\int_{-\infty}^{\infty} \exp\left(-\frac{u^2}{2}\right) du}_{\sqrt{2\pi}} = \exp\left(\frac{t^2}{2}\right)\end{aligned}$$

Momenterzeugende Funktion III

Satz

Sei X eine Zufallsvariable mit momenterzeugender Funktion $M : D \rightarrow \mathbb{R}$.
Ist $] - a, a[\subset D$ für ein beliebiges $a > 0$, so gilt

- i) $\mathbb{E}(X^n) < \infty$,
- ii) $M(t) = \sum_{n=0}^{\infty} \frac{t^n}{n!} \mathbb{E}(X^n)$,
- iii) $\left. \frac{\partial^n M(t)}{\partial t^n} \right|_{t=0} = \mathbb{E}(X^n)$.

Momenterzeugende Funktion IV

Beweis:

i) Erinnerung an Analysis I, Exponentialreihe:

$$\exp(x) := \sum_{n=0}^{\infty} \frac{x^n}{n!}.$$

Nach Voraussetzung $\mathbb{E}(\exp(tX)) < \infty \ \forall t \in]-a, a[$, also $\exp(tX)$ ist $\mathbb{P}_X$ -integrierbar $\Rightarrow \exp(|tX|) = \sum_{n=0}^{\infty} \frac{|tX|^n}{n!}$ ist $\mathbb{P}_X$ -integrierbar. Summe und Integral sind vertauschbar (monotone Konvergenz), also $\Rightarrow |X|^n$ und damit auch X^n ist $\mathbb{P}_X$ -integrierbar $\forall n$ $\checkmark$

Momenterzeugende Funktion V

ii) Betrachte Exponentialfunktion als Folge

$$f_k(X) := \sum_{n=0}^k \frac{(tX)^n}{n!}; f_k(X) \rightarrow \exp(tX) \text{ für } k \rightarrow \infty$$

$$\begin{aligned} M(t) &= \mathbb{E}(\exp(tX)) = \int \exp(tX) d\mathbb{P}_X = \int \lim_{k \rightarrow \infty} f_k d\mathbb{P}_X \\ &= \lim_{k \rightarrow \infty} \int f_k d\mathbb{P}_X = \lim_{k \rightarrow \infty} \mathbb{E}(f_k) && (\text{Satz 6.10}) \\ &= \sum_{n=0}^{\infty} \frac{t^n}{n!} \mathbb{E}(X^n) \quad t \in]-a, a[. \quad \checkmark \end{aligned}$$

Momenterzeugende Funktion VI

iii) Erinnerung: Satz von Taylor (Analysis 2). Die Taylorreihe ist

$$T_m(x; a) := \sum_{k=0}^m \frac{f^{(k)}(a)}{k!} (x - a)^k$$

$$M(t) = \sum_{n=0}^{\infty} \frac{t^n}{n!} \left. \frac{\partial^n M(t)}{\partial t^n} \right|_{t=0}$$

Taylor mit $a = 0$

$$M(t) = \sum_{n=0}^{\infty} \frac{t^n}{n!} \mathbb{E}(X^n)$$

nach ii)

$$\Rightarrow \left. \frac{\partial^n M(t)}{\partial t^n} \right|_{t=0} = \mathbb{E}(X^n)$$

✓



Momenterzeugende Funktion VII

Fortsetzung Beispiel 10.1, $X \sim N(0, 1)$

$$\frac{\partial M(t)}{\partial t} \Big|_{t=0} = t \cdot \exp\left(\frac{t^2}{2}\right) \Big|_{t=0} = 0 \implies \mathbb{E}(X) = 0$$

$$\frac{\partial^2 M(t)}{\partial t^2} \Big|_{t=0} = t^2 \cdot \exp\left(\frac{t^2}{2}\right) + \exp\left(\frac{t^2}{2}\right) \Big|_{t=0} = 1 \implies \mathbb{E}(X^2) = 1$$

$$\text{Var}(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2 = 1$$

10. Erzeugende Funktionen

10.1 Momenterzeugende Funktion

10.2 Charakteristische Funktion

10.3 Eigenschaften

Charakteristische Funktion I

Die momenterzeugende Funktion ist nur dann definiert, wenn $M_X(t) = \mathbb{E}(\exp(tX)) < \infty$ für $-a < t < a$. Allgemeiner definiert ist die

Definition (Charakteristische Funktion)

Sei X eine Zufallsvariable. Die Funktion $\varphi_X : \mathbb{R} \rightarrow \mathbb{C}$ mit

$$\varphi_X(t) := \mathbb{E}(\exp(itX)) = \int \exp(itX) d\mathbb{P}$$

heißt die charakteristische Funktion (engl. **characteristic function**) von X .

Fourier-Transformation I

Definition (Fourier-Transformation)

Für Riemann-integrierbare Funktionen $f : \mathbb{R} \rightarrow \mathbb{C}$ ist die Fourier-Transformation (engl. **Fourier transform**)

$$\tilde{f}(\omega) = \int f(x) e^{-i\omega x} dx$$



Ist f eine Funktion in der Zeit x , lässt sich ω als Frequenz interpretieren. Nach der Eulerformel $e^{-i\omega x} = \cos(\omega x) - i \sin(\omega x)$ gilt

$$\tilde{f}(\omega) = \int_{-\infty}^{\infty} f(x) \cos(\omega x) dx - i \int_{-\infty}^{\infty} f(x) \sin(\omega x) dx.$$

Fourier-Transformation II

Beispiel 10.2

$$f(x) = 1 + \frac{3\pi - x}{10} (\sin(8x) + \cos(3x))$$



Charakteristische Funktion II

Satz

Sei φ_X eine charakteristische Funktion. Dann gilt: Ist $\mathbb{E}(|X|^k) < \infty$, dann ist für alle $k \in \mathbb{N}$

$$\mathbb{E}(X^k) = \frac{\varphi_X^{(k)}(0)}{i^k}.$$

Beweis siehe 16.4.5 in Schmidt (2011).

Beispiel 10.3

- * Sei $X \sim N(0, 1)$. Dann ist die Charakteristische Funktion $\varphi_X(t) = \exp\left(-\frac{1}{2}t^2\right)$.
- * Sei $X \sim N(\mu, \sigma^2)$. Dann ist die Charakteristische Funktion $\varphi_X(t) = \exp\left(i\mu t - \frac{1}{2}\sigma^2 t^2\right)$.

10. Erzeugende Funktionen

10.1 Momenterzeugende Funktion

10.2 Charakteristische Funktion

10.3 Eigenschaften

Zusammenhänge

Hat eine Zufallsvariable eine momenterzeugende Funktion, dann gilt offensichtlich:

$$\varphi_X(t) = M_{iX}(t) = M_X(it)$$

- ▶ Wir nutzen die erzeugenden Funktionen später im Beweis des Zentralen Grenzwertsatzes
- ▶ Beweis eigentlich mit φ_X , wir beschränken uns auf M_X

Eindeutigkeit I

Wir haben die erzeugenden Funktionen für Zufallsvariablen definiert, aber eigentlich nutzen wir sie für Verteilungen:

Satz

Seien X und Y reelle Zufallsvariablen mit Verteilungen $\mathbb{P}_X$ und $\mathbb{P}_Y$. Dann gilt für ihre charakteristische Funktionen φ_X und φ_Y :

$$\mathbb{P}_X = \mathbb{P}_Y \iff \varphi_X = \varphi_Y$$

Falls die momenterzeugenden Funktionen M_X von X und M_Y von Y existieren und $M_X(s), M_Y(s) < \infty$ für alle $s \in (-a, a)$, dann gilt

$$\mathbb{P}_X = \mathbb{P}_Y \iff M_X(s) = M_Y(s) \text{ für alle } s \in (-a, a)$$

Eindeutigkeit II

Eindeutigkeit erzeugender Funktionen

Charakteristische Funktionen existieren immer und bestimmen Verteilungen eindeutig.

Momenterzeugende Funktionen existieren nicht immer.

Beweis:

Siehe 16.4.7 in Schmidt (2011).

Linearität

Satz

Sei M_X eine momenterzeugende Funktion und φ_X eine charakteristische Funktion. Seien $a, b \in \mathbb{R}$, dann gilt:

$$M_{a+bX}(t) = \exp(at)M_X(bt)$$

$$\varphi_{a+bX}(t) = \exp(iat)\varphi_X(bt)$$

Beweis:

Linearität des Lebesgue-Integrals.



Unabhängigkeit

Satz

Sind $X_1, \dots, X_n$ unabhängige reelle Zufallsvariablen mit auf dem Intervall $] - a, a[$ definierten momenterzeugenden Funktionen $M_1, \dots, M_n$ sowie charakteristischen Funktionen $\varphi_{X_1}, \dots, \varphi_{X_n}$. Dann ist für $S := \sum_{i=1}^n X_i$ die momenterzeugende Funktion $M(s)$ auf $] - a, a[$ definiert mit

$$M_S(s) = \prod_{i=1}^n M_i(s), \quad s \in] - a, a[.$$

und die charakteristische Funktion von S ist

$$\varphi_S = \prod_{i=1}^n \varphi_i$$

Beweis später.

Dichteerzeugung

Satz

Sei φ_X die integrierbare charakteristische Funktion von X . Dann gilt: Die Verteilung von X hat die Dichte

$$f_X(x) = \frac{1}{2\pi} \int \exp(-itx) \varphi_X(t) dt.$$

Inverse Fouriertransformation.

χ^2 -Verteilung I

Definition

Sei X eine stetige Zufallsvariable mit Dichte

$$f_X(x) = \frac{1}{\Gamma\left(\frac{k}{2}\right)} \left(\frac{1}{2}\right)^{\frac{k}{2}} x^{\frac{k}{2}-1} \exp\left(-\frac{1}{2}x\right) \cdot I_{(0,\infty)}(x)$$

Dann heißt X χ^2 -verteilt mit Parameter $k \in \mathbb{N}$ (genannt Anzahl von Freiheitsgraden), $X \sim \chi^2(k)$.

Ohne Beweis: $X \sim \chi^2(k) \implies M_X(s) = \left(\frac{1}{1-2s}\right)^{\frac{k}{2}}, s < \frac{1}{2}$

χ^2 -Verteilung II

Satz

Seien $X_1, \dots, X_n$ stochastisch unabhängig mit $X_i \sim N(0, 1)$. Dann gilt

$$Y = \sum_{i=1}^n X_i^2 \sim \chi^2(n).$$

Beweis:

$$\begin{aligned} M_Y(s) &= \mathbb{E}(\exp(sY)) = \mathbb{E} \left(\exp \left(s \sum_{i=1}^n X_i^2 \right) \right) \\ &= \mathbb{E} \left(\prod_{i=1}^n \exp(s X_i^2) \right) \stackrel{X \text{ stu}}{=} \prod_{i=1}^n \mathbb{E}(\exp(s X_i^2)) \end{aligned}$$

χ^2 -Verteilung III

$$\begin{aligned}\mathbb{E}(\exp(sX_i^2)) &= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}x^2\right) \cdot \exp(sx^2) dx \\&= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left(\left(-\frac{1}{2} + s\right)x^2\right) dx \\&= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(1-2s)x^2\right) dx \\&\stackrel{\text{Kreative 1}}{=} \frac{1}{\sqrt{1-2s}} \underbrace{\int_{-\infty}^{\infty} \frac{\sqrt{1-2s}}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(1-2s)x^2\right) dx}_{\equiv 1, \text{ (Dichte von } N(0, (1-2s)^{-1})\text{)}} \\&= \frac{1}{\sqrt{1-2s}}\end{aligned}$$

χ^2 -Verteilung IV

Zusammen:

$$\begin{aligned} M_Y(s) &= \prod_{i=1}^n \mathbb{E}(\exp(s X_i^2)) \\ &= \prod_{i=1}^n \frac{1}{\sqrt{1-2s}} = \left(\frac{1}{1-2s} \right)^{\frac{n}{2}} \end{aligned}$$

$\implies$ Momentenerzeugende Funktion von $\chi^2(n)$.

