

Teil III: Mehrdimensionale Zufallsvariablen

Kapitel 11

Zufallsvektoren

11. Zufallsvektoren

11.1 Mehrdimensionale Wahrscheinlichkeitsräume

11.2 Mehrdimensionale Verteilungsfunktion und Dichte

11.3 Randverteilung

11.4 Transformationssatz für Dichten

11.5 Exkurs: Faltung



Nach Def. 4.8 ist jede messbare Abbildung $X : \Omega_1 \rightarrow \Omega_2$ eine Zufallsvariable. In Teil II war $\Omega_2 = \mathbb{R}$. Nun betrachten wir $\Omega_2 = \mathbb{R}^n$.

Ziele des Kapitels

- ▶ Konstruktion des mehrdimensionalen Messraums
- ▶ Verallgemeinerung Verteilungsfunktion und Dichte
- ▶ Erwartungswert, Randverteilung
- ▶ Dichtetransformationssatz

n -facher Münzwurf

Beispiel 1.2

Wir werfen die Münze n -mal. Ergebnisse sind n -Tupel der Form $\omega = (1, 0, 0, \dots, 1)$. Die Ergebnismenge Ω_n besteht aus 2^n Elementen.

Wir interessieren uns für die Wahrscheinlichkeit von Ereignissen $A \subset \Omega$.

$\implies$ i.i.d.-Modell!

Umfrage

- ▶ Wir fragen n Personen: “Welche Partei wollen Sie wählen?”
- ▶ Wir fragen eine Person nach Parteipräferenz, Schulabschluss, Einkommen, Geschlecht und Schuhgröße

Temperaturen




Abbildung 21: Durchschnittstemperatur in München Stadt von November 2020 bis Mai 2022

11. Zufallsvektoren

11.1 Mehrdimensionale Wahrscheinlichkeitsräume

11.2 Mehrdimensionale Verteilungsfunktion und Dichte

11.3 Randverteilung

11.4 Transformationssatz für Dichten

11.5 Exkurs: Faltung

Kartesisches Produkt I

Das kartesische Produkt zweier Mengen

$$A = \{a_1, a_2, a_3, \dots, a_k\}$$

$$B = \{b_1, b_2, b_3, \dots, b_m\}$$

ist die Menge

$$A \times B := \{(a_i, b_j) \mid i = 1, \dots, k, j = 1, \dots, m\}$$

Sie besteht also aus allen möglichen Kombinationen, so dass

$$\begin{aligned} A \times B = & \{(a_1, b_1), (a_1, b_2), (a_1, b_3), \dots, (a_1, b_m) \\ & (a_2, b_1), (a_2, b_2), (a_2, b_3), \dots, (a_2, b_m) \\ & \vdots \\ & (a_k, b_1), (a_k, b_2), (a_k, b_3), \dots, (a_k, b_m)\} \end{aligned}$$

Kartesisches Produkt II

Beispiel 11.1

$$A = \{1, 2, 3\}$$

$$B = \{1, 2, 3, 4\}$$

$$A \times B = \{(1, 1), (1, 2), (1, 3), (1, 4), (2, 1), \dots\}$$

Bei den Elementen von $A \times B$ handelt es sich um Tupel, das heißt die Reihenfolge ist wichtig! Z.B. ist $(1, 2)$ nicht gleich $(2, 1)$.

Kartesisches Produkt III

Verallgemeinerung

- Das kartesische Produkt der Mengen $\Omega_1, \Omega_2, \dots, \Omega_n$ wird mit

$$\bigtimes_{i=1}^n \Omega_i = \Omega_1 \times \Omega_2 \times \dots \times \Omega_n$$

bezeichnet und besteht aus allen möglichen n -Tupeln, die sich (unter Beachtung der Reihenfolge) aus Elementen aus $\Omega_1, \Omega_2, \dots, \Omega_n$ bilden lassen. - Die Mengen $\Omega_1, \Omega_2, \dots, \Omega_n$ müssen nicht endlich sein; für endliche Mengen gilt

$$\left| \bigtimes_{i=1}^n \Omega_i \right| = |\Omega_1| \cdot |\Omega_2| \cdot \dots \cdot |\Omega_n|$$

- Kartesische Produkte werden verwendet, um Ergebnisse komplexer Experimente aus Einzelexperimenten zusammenzusetzen.
- Beispiel n -facher Münzwurf: $\Omega = (\omega_1, \dots, \omega_n)$ mit $\omega_i \in \{\text{Kopf}, \text{Zahl}\}$.
- Übrigens n kann gegen ∞ gehen.

Produkt- σ -Algebra I

Ist $\Omega = \times_{i=1}^n \Omega_i$ und $\mathcal{F}_i$ σ -Algebra von Ω_i für alle i , dann lässt sich wie folgt eine σ -Algebra für Ω definieren:

$$\mathcal{F}_1 \otimes \mathcal{F}_2 \otimes \cdots \otimes \mathcal{F}_n := \sigma \left(\left\{ \times_{i=1}^n A_i \mid A_i \in \mathcal{F}_i, i = 1, \dots, n \right\} \right),$$

Produkt- σ -Algebra II

Beispiel 11.2

Wir werfen einen Würfel auf einer Linie der Länge 1. Ergebnisse sind die Augenzahlen $\Omega_1 = \{1, \dots, 6\}$ und wo auf der Linie der Würfel landet $\Omega_2 = (0, 1)$. Also insgesamt

$$\Omega = \{(\omega_1, \omega_2) | \omega_1 \in \Omega_1, \omega_2 \in \Omega_2\}$$

Erzeuger der passenden σ -Algebra ist

$$\{A_1 \times A_2 | A_1 \in \mathcal{P}(\Omega_1), A_2 \in \mathcal{B}_{(0,1)}\}$$

Produkt- σ -Algebra III

Borelsche σ -Algebra im n -dimensionalen

Siehe Def. 2.23: Die von $\mathcal{O}^n = \{U \subset \mathbb{R}^n \mid U \text{ offen}\}$ erzeugte σ -Algebra $\mathcal{B}^n = \mathcal{B}(\mathbb{R}^n)$ heißt Borelsche σ -Algebra auf $\mathbb{R}^n$.

$$\mathcal{O}^n = \bigtimes_{i=1}^n \mathcal{O}$$

Produktmaß I

Definition

Das Produktmaß $\bigotimes_{i=1}^n \mu_i$ ist definiert durch

$$\left(\bigotimes_{i=1}^n \mu_i \right) \left(\bigtimes_{i=1}^n A_i \right) = \prod_{i=1}^n \mu_i(A_i) \quad \forall A_i \in \mathcal{F}_i \quad \forall i = 1, \dots, n.$$

Streng genommen nur definiert auf messbaren Rechtecken, dann aber eindeutige Fortsetzung.

Beispiel 11.3

Siehe Definition 3.11: $\lambda : \mathcal{B}^n \rightarrow \overline{\mathbb{R}}$:

$$\lambda([a_1, b_1] \times \cdots \times [a_n, b_n]) = (b_1 - a_1) \cdot \dots \cdot (b_n - a_n)$$

Produktmaßraum I

Definition

Seien $(\Omega_i, \mathcal{F}_i, \mu_i), i = 1, \dots, n$ Maßräume. Ihr Produktmaßraum ist der Maßraum

$$\left(\bigtimes_{i=1}^n \Omega_i, \bigotimes_{i=1}^n \mathcal{F}_i, \bigotimes_{i=1}^n \mu_i \right)$$

- ▶ mit Basismenge $\bigtimes_{i=1}^n \Omega_i = \Omega_1 \times \Omega_2 \times \dots \times \Omega_n$,
- ▶ Produkt- σ -Algebra

$$\mathcal{F}_1 \otimes \mathcal{F}_2 \otimes \dots \otimes \mathcal{F}_n = \sigma \left(\left\{ \bigtimes_{i=1}^n A_i \mid A_i \in \mathcal{F}_i, i = 1, \dots, n \right\} \right),$$

- ▶ und dem Produktmaß

$$\left(\bigotimes_{i=1}^n \mu_i \right) \left(\bigtimes_{i=1}^n A_i \right) = \prod_{i=1}^n \mu_i(A_i) \quad \forall A_i \in \mathcal{F}_i \quad \forall i = 1, \dots, n.$$

Mehrdimensionale Zufallsvariable

Erinnerung

Def. 4.8: Ist $(\Omega_1, \mathcal{F}_1, \mathbb{P})$ ein Wahrscheinlichkeitsraum und $(\Omega_2, \mathcal{F}_2)$ ein Meßraum, so heißt eine $\mathcal{F}_1$ - $\mathcal{F}_2$ meßbare Abbildung

$$\mathbf{X} : \Omega_1 \rightarrow \Omega_2$$

Zufallsvariable (ZV). Ist $\Omega_2 = \mathbb{R}^n$, so heißt $\mathbf{X}$
n-dimensionale reelle Zufallsvariable.

Wir nennen $\mathbf{X} = (X_1, \dots, X_n)^\top$ auch Zufallsvektor (engl. random vector).

11. Zufallsvektoren

11.1 Mehrdimensionale Wahrscheinlichkeitsräume

11.2 Mehrdimensionale Verteilungsfunktion und Dichte

11.3 Randverteilung

11.4 Transformationssatz für Dichten

11.5 Exkurs: Faltung

Mehrdimensionale Verteilungsfunktion I

Definition (n -dimensionale Verteilungsfunktion)

Sei $(\Omega, \mathcal{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und $\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$ eine n -dimensionale reelle ZV, $\mathbf{X} = (X_1, \dots, X_n)$. Dann heißt die Funktion

$$\begin{aligned} F_{\mathbf{X}} : \mathbb{R}^n &\rightarrow [0, 1] \\ \mathbf{x} = (x_1, \dots, x_n) &\mapsto \mathbb{P}(\mathbf{X} \leq \mathbf{x}) \\ &= \mathbb{P}(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n) \\ &= \mathbb{P}(\{\omega \in \Omega \mid X_i(\omega) \leq x_i \forall i = 1, \dots, n\}) \end{aligned}$$

die n -dimensionale Verteilungsfunktion von X .

Mehrdimensionale Verteilungsfunktion II

Satz

Für $\mathbf{x} \in \mathbb{R}^n$ und $h \in \mathbb{R}$ sei $(\mathbf{x} + h) := (x_1 + h, \dots, x_n + h)$. Dann gilt

- i) $F_{\mathbf{X}}(\mathbf{x})$ ist monoton wachsend in jeder Komponente von $\mathbf{x}$.
- ii) $F_{\mathbf{X}}(\mathbf{x})$ ist rechtsstetig

$$\lim_{h \downarrow 0} F_{\mathbf{X}}(\mathbf{x} + \mathbf{h}) = F_{\mathbf{X}}(\mathbf{x}) \quad \forall \mathbf{x} \in \mathbb{R}^n.$$

- iii) $\lim_{x_k \rightarrow -\infty} F_{\mathbf{X}}(\mathbf{x}) = 0$ für alle $k \in \{1, \dots, n\}$, $\lim_{h \rightarrow \infty} F_{\mathbf{X}}(\mathbf{x} + h) = 1$.
- iv) Wahrscheinlichkeitsmaße auf $\mathbb{R}^n$ sind durch die zugehörigen n -dimensionalen Verteilungsfunktionen vollständig definiert.

Ohne Beweis.

Mehrdimensionale Verteilungsfunktion III

Beispiel 11.4

Die Gleichverteilung auf $(0, 1) \times (0, 1)$ hat die Verteilungsfunktion

$$F(x_1, x_2) = \begin{cases} 0 & x_1 \leq 0 \text{ oder } x_2 \leq 0 \\ x_1 \cdot x_2 & 0 < x_1 \leq 1 \text{ und } 0 < x_2 \leq 1 \\ x_1 & \text{für } 0 < x_1 \leq 1 \text{ und } x_2 > 1 \\ x_2 & x_1 > 1 \text{ und } 0 < x_2 \leq 1 \\ 1 & x_1 > 1 \text{ und } x_2 > 1 \end{cases}$$

Mehrdimensionale Verteilungsfunktion IV




Abbildung 22: Verteilungsfunktion der zweidimensionalen Gleichverteilung auf dem Einheitsquadrat

Mehrdimensionale Verteilungsfunktion V




Abbildung 23: Verteilungsfunktion der zweidimensionalen Gleichverteilung auf dem Einheitsquadrat

Satz von Fubini I

Satz (Satz von Fubini für das Riemann-Integral)

Seien $a, b, c, d, e, f \in \mathbb{R}^n, n \in \mathbb{N}, a < b, c < d, e < f, I = [a, b], J = [c, d], K = [e, f]$. Wenn $I = J \times K$ und $f \in \mathbb{R}$, dann gilt

$$\int_I f(x, y) d(x, y) = \int_K \int_J f(x, y) dx dy = \int_J \int_K f(x, y) dy dx$$

Beweis siehe Analysis II.

Satz von Fubini II

Satz (Satz von Fubini)

Seien $(\Omega_1, \mathcal{F}_1, \mu)$ und $(\Omega_2, \mathcal{F}_2, \nu)$ zwei Maßräume mit σ -endlichen Maßen μ und ν . Ist $f : \Omega_1 \times \Omega_2 \rightarrow \mathbb{R}$ eine nicht-negative, $(\mathcal{F}_1 \otimes \mathcal{F}_2)$ - $\mathcal{B}$ -meßbare Funktion bzw. eine $(\mu \otimes \nu)$ -integrierbare Funktion, so gilt

$$\begin{aligned} \int f \, d(\mu \otimes \nu) &= \int \left(\int f(\omega_1, \omega_2) \, d\mu(\omega_1) \right) d\nu(\omega_2) \\ &= \int \left(\int f(\omega_1, \omega_2) \, d\nu(\omega_2) \right) d\mu(\omega_1). \end{aligned}$$

Beweis siehe Meintrup and Schäffler (2005) Satz 2.24.

Satz von Fubini III

Über den *Satz von Fubini* definiert man sich mehrdimensionale Dichten bezüglich des dominierenden Produktmaßes $\mu \otimes \nu$:

- ▶ Beispiel “Würfel auf der Linie”: dominierendes Maß ist $\mu_Z \otimes \lambda$
- ▶ Für mehrdimensionale stetige Verteilungen ist λ^n das dominierende Maß
- ▶ Für mehrdimensionale diskrete Verteilungen ist μ_Z das dominierende Maß

Beispiel 11.5

Die Dichte der Gleichverteilung auf dem Einheitsquadrat $(0, 1) \times (0, 1)$ ist konstant gleich 1:

$$f(x_1, x_2) = I_{(0,1) \times (0,1)}(x_1, x_2)$$

Multinomialverteilung I

Urnenmodell mit k Farben. Es werden n Kugeln mit Zurücklegen gezogen. Die Zufallsvariable $\mathbf{X} = (X_1, X_2, \dots, X_k)$ beschreibt die gezogenen Farben, wobei X_i die Anzahl der Kugeln der Farbe i ist.

Definition

Sei $k \leq n \in \mathbb{N}_0$ und $p_1, \dots, p_k \in [0, 1]$ mit $\sum_{i=1}^k p_i = 1$. Die Verteilung mit der Zähldichte

$$f(n_1, \dots, n_k) = \binom{n}{n_1, \dots, n_k} p_1^{n_1} \cdots p_k^{n_k},$$

für $\sum_{i=1}^k n_i = n$ (sonst ist die Zähldichte gleich 0) heißt Multinomialverteilung $M(n, (p_1, \dots, p_k))$ bzw. $M(n, \mathbf{p})$.

Dabei ist $\binom{n}{n_1, \dots, n_k} = \frac{n!}{n_1! \cdots n_k!}$ der Multinomialkoeffizient.

Multinomialverteilung II

- Fasst man (o.b.d.A.) die Farben 2 bis k zusammen, dann wird aus dem Multinomialmodell offensichtlich ein Binomialmodell: Es wird entweder mit Wahrscheinlichkeit p_1 Farbe 1 gezogen oder nicht (mit Wahrscheinlichkeit

$$1 - p_1 = \sum_{i=2}^k p_i).$$

Dirichlet-Verteilung I

Definition

Sei $m \geq 2$. Mit $x_i \in [0, 1]$ und $\sum_{i=1}^m x_i = 1$ heißt die Verteilung mit der Dichte

$$f(\mathbf{x}) = \frac{\Gamma(\sum_{i=1}^m \alpha_i)}{\prod_{i=1}^m \Gamma(\alpha_i)} x_1^{\alpha_1-1} x_2^{\alpha_2-1} \dots x_m^{\alpha_m-1}$$

bezüglich des $(m-1)$ -dimensionalen Lebesgue-Maßes auf dem $(m-1)$ -Simplex heißt Dirichlet-Verteilung.

$\mathbf{X} \sim \text{Diri}(\alpha_1, \dots, \alpha_m)$.


Spezialfall der Dirichlet-Verteilung für $m = 2$ ist die Beta-Verteilung (Def. 19.15)

Dirichlet-Verteilung II


Dirichlet (1,1,1)




Dirichlet (2,2,2)




Dirichlet (10,10,10)




Dirichlet (2,10,2)



Dirichlet (2,2,10)



Dirichlet (0.9,0.9,0.9)



11. Zufallsvektoren

11.1 Mehrdimensionale Wahrscheinlichkeitsräume

11.2 Mehrdimensionale Verteilungsfunktion und Dichte

11.3 Randverteilung

11.4 Transformationssatz für Dichten

11.5 Exkurs: Faltung

Randverteilung I

Satz

Sei $\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$ eine n -dimensionale Zufallsvariable und $\mathbf{g} : \mathbb{R}^n \rightarrow \mathbb{R}^k$ $\mathcal{B}^n$ - $\mathcal{B}^k$ -meßbar. Dann ist

$$\mathbf{g} \circ \mathbf{X} : \Omega \rightarrow \mathbb{R}^k, \quad \omega \mapsto \mathbf{g}(\mathbf{X}(\omega))$$

eine k -dimensionale reelle Zufallsvariable mit Verteilung

$$\mathbb{P}_{\mathbf{g}(\mathbf{X})}(A) = \mathbb{P}(\mathbf{g}(\mathbf{X}) \in A) = \mathbb{P}(\{\omega \in \Omega \mid \mathbf{g}(\mathbf{X}(\omega)) \in A\}).$$

Beweis:

Satz 4.13 (Meßbarkeit der Komposition)



Randverteilung II

Insbesondere heißt das, dass für eine n -dimensionale Zufallsvariable oder **Zufallsvektor** $\mathbf{X} = (X_1, \dots, X_n)$ auch alle X_i eindimensionale Zufallsvariablen sind.

Definition (Randverteilung)

Ist $g : \mathbb{R}^n \rightarrow \mathbb{R}$ mit $g(\mathbf{x}) = x_j$ für ein festes $j \in \{1, \dots, n\}$ (Projektion auf j -te Koordinate), so gilt:

$$\begin{aligned} g(\mathbf{X}) &= X_j, \\ \mathbb{P}_{X_j}(A) &= \mathbb{P}_{\mathbf{X}}(\{\mathbf{x} \in \mathbb{R}^n : x_j \in A\}) = \mathbb{P}(X_j \in A) \text{ für } A \in \mathcal{B}. \end{aligned}$$

$\mathbb{P}_{X_j}$ heißt Randverteilung oder marginale Verteilung (engl. **marginal distribution**) von X_j .

Randverteilung III

- Besitzt $\mathbf{X}$ die Dichte f , so hat X_j (mit $\nu = \lambda$ oder $\nu = \mu_Z$) die **marginale Dichte** oder Randdichte

$$f_j : \mathbb{R} \rightarrow \mathbb{R}$$

$$f_j(y) = \int \dots \int f(x_1, x_2, \dots, x_{j-1}, y, x_{j+1}, \dots, x_n) \\ d\nu(x_n) \dots d\nu(x_{j+1}) d\nu(x_{j-1}) \dots d\nu(x_1)$$

- Erwartungswert und Varianz der marginalen Verteilung werden marginaler Erwartungswert bzw. marginale Varianz genannt (usw.).

Randverteilung IV

Beispiel 11.6 (Zweidimensionale Gleichverteilung)

$$(X, Y) \sim U((0, 1) \times (0, 1))$$

$$f(x, y) = I_{(0,1) \times (0,1)}(x, y) = I_{(0,1)}(x) \cdot I_{(0,1)}(y)$$

$$f_X(x) = \int f(x, y) dy = I_{(0,1)}(x)$$

$$X \sim U(0, 1)$$

Aus Symmetriegründen: $Y \sim U(0, 1)$

Mehrdimensionaler Erwartungswert

Definition

Sei $\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$, $\mathbf{X} = (X_1, \dots, X_n)$ eine n -dimensionale Zufallsvariable, dann heißt der Vektor der marginalen Erwartungswerte

$$\mathbb{E}(\mathbf{X}) := (\mathbb{E}(X_1), \dots, \mathbb{E}(X_n))$$

der (n -dimensionale) Erwartungswert oder Erwartungswertvektor von X

Multinomialverteilung I

Beispiel 11.7 (Multinomialverteilung)

Sei $\mathbf{X} \sim M(n, \mathbf{p})$

$$f(n_1, \dots, n_k) = \frac{n!}{n_1! \dots n_k!} p_1^{n_1} \dots p_k^{n_k},$$

O.B.d.A. für $i = 1$:

$$\begin{aligned} f_{X_1}(n_1) &= \sum_{n_2 + \dots + n_k = n - n_1} f(n_1, \dots, n_k) \\ &= \sum_{n_2 + \dots + n_k = n - n_1} \frac{n!}{n_1! \dots n_k!} p_1^{n_1} \dots p_k^{n_k} \\ &= \frac{n!}{n_1! (n - n_1)!} p_1^{n_1} \left(\sum_{n_2 + \dots + n_k = n - n_1} \frac{(n - n_1)!}{n_2! \dots n_k!} p_i^{n_i} \right) \\ &= \frac{n!}{n_1! (n - n_1)!} p_1^{n_1} \left(\sum_{i=2}^k p_i \right)^{n - n_1} \quad \text{Multinomialtheorem} \end{aligned}$$

Multinomialverteilung II

- ▶ Randverteilung $X_i \sim B(n, p_i)$
- ▶ Marginaler Erwartungswert $\mathbb{E}(X_i) = np_i$
- ▶ Marginale Varianz $\text{Var}(X_i) = np_i(1 - p_i)$

Zweidimensionale Normalverteilung I

Definition

Sei $\mathbf{X}$ eine Zufallsvariable $\Omega \rightarrow \mathbb{R}^2$ mit Dichte


$$f_{\mathbf{X}}(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\varrho^2}} \cdot \exp\left(-\frac{1}{2(1-\varrho^2)} \left[\frac{(x_1-\mu_1)^2}{\sigma_1^2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2} - \frac{2\varrho(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} \right]\right).$$

bezüglich λ^2 . Dann ist $\mathbf{X}$ zweidimensional normalverteilt


$$\mathbf{X} \sim N_2\left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \varrho\sigma_1\sigma_2 \\ \varrho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}\right)$$

Zweidimensionale Normalverteilung II


$\rho = 0$




$\rho = 0.5$







$\rho = -0.5$



$\rho = 0.9$



Zweidimensionale Normalverteilung III



Zweidimensionale Normalverteilung IV

Zur Vereinfachung arbeiten wir im Folgenden erst Mal mit $\mu_1 = \mu_2 = 0$ und $\sigma_1^2 = \sigma_2^2 = 1$. Die Dichte von $X = (X_1, X_2)$ ist dann

$$f_{\mathbf{X}}(x_1, x_2) = \frac{1}{2\pi\sqrt{1-\varrho^2}} \exp\left(-\frac{1}{2(1-\varrho^2)}(x_1^2 - 2\varrho x_1 x_2 + x_2^2)\right).$$

Randdichte:

$$\begin{aligned} f_{X_1}(x_1) &= \int f_{\mathbf{X}}(x_1, x_2) dx_2 \\ &= \int \frac{1}{2\pi\sqrt{1-\varrho^2}} \exp\left(-\frac{1}{2(1-\varrho^2)}(x_1^2 - 2\varrho x_1 x_2 + x_2^2)\right) dx_2 \\ &= \frac{1}{2\pi\sqrt{1-\varrho^2}} \exp\left(-\frac{1}{2(1-\varrho^2)}x_1^2\right) \cdot \\ &\quad \cdot \int \exp\left(-\frac{1}{2(1-\varrho^2)}(x_2^2 - 2\varrho x_1 x_2)\right) dx_2 \end{aligned}$$

Zweidimensionale Normalverteilung V

Berechnung des Integrals über den *1-Trick*:

$$\begin{aligned} & \int \exp \left(-\frac{1}{2(1-\varrho^2)} (x_2^2 - 2\varrho x_1 x_2) \right) dx_2 \\ &= \exp \left(\frac{x_1^2 \varrho^2}{2(1-\varrho^2)} \right) \int \exp \left(-\frac{1}{2(1-\varrho^2)} (x_2^2 - 2\varrho x_1 x_2 + x_1^2 \varrho^2) \right) dx_2 \\ &= \sqrt{2\pi(1-\varrho^2)} \exp \left(\frac{x_1^2 \varrho^2}{2(1-\varrho^2)} \right) \underbrace{\int \frac{1}{\sqrt{2\pi(1-\varrho^2)}} \exp \left(-\frac{1}{2(1-\varrho^2)} (x_2 - x_1 \varrho)^2 \right) dx_2}_{\text{Dichte von } N(x_1 \varrho, 1-\varrho^2)} \end{aligned}$$

Zweidimensionale Normalverteilung VI

Zusammen also

$$\begin{aligned}f_{X_1}(x_1) &= \int f_X(x_1, x_2) dx_2 \\&= \frac{\sqrt{2\pi(1-\varrho^2)}}{2\pi\sqrt{1-\varrho^2}} \exp\left(-\frac{1}{2(1-\varrho^2)}(x_1^2 - x_1^2\varrho^2)\right) \\&= \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}x_1^2\right)\end{aligned}$$

- ▶ Also ist $X_1 \sim N(0, 1)$.
- ▶ Aus Symmetriegründen gilt $X_2 \sim N(0, 1)$.

Zweidimensionale Normalverteilung VII

Für die allgemeine zweidimensionale Normalverteilung

$$\mathbf{X} \sim N_2 \left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix} \right)$$

gilt:

- ▶ $X_1 \sim N(\mu_1, \sigma_1^2)$
- ▶ $X_2 \sim N(\mu_2, \sigma_2^2)$

11. Zufallsvektoren

11.1 Mehrdimensionale Wahrscheinlichkeitsräume

11.2 Mehrdimensionale Verteilungsfunktion und Dichte

11.3 Randverteilung

11.4 Transformationssatz für Dichten

11.5 Exkurs: Faltung

Erinnerung: Transformationssatz für Dichten I

Satz (Dichtetransformationssatz)

Sei $X : \Omega \rightarrow \mathbb{R}$ Zufallsvariable mit stetiger Verteilungsfunktion F_X und Dichte $f_X(x) = \frac{\partial F_X(x)}{\partial x}$ bezüglich des Lebesgue-Maßes λ .

Sei $g : \mathbb{R} \rightarrow \mathbb{R}$ bijektiv und stetig differenzierbar, $\frac{\partial g(x)}{\partial x} \neq 0$ mit $h = g^{-1}$. Dann gilt: $g \circ X$ hat Dichte

$$f_{g \circ X}(y) = f_X(h(y)) \cdot \left| \frac{\partial h(y)}{\partial y} \right|$$

bezüglich λ .

Erinnerung: Transformationssatz für Dichten II

Beispiel 11.8

Sei $X \sim \text{Exp}(\lambda)$. Wie ist die Verteilung von X^2 ? Da $X \geq 0$ fast sicher, gilt:

$$\begin{aligned}g(x) &= x^2 \\h(y) &= g^{-1}(y) = \sqrt{y} \\ \frac{\partial h(y)}{\partial y} &= \frac{1}{2\sqrt{y}} \\f_{X^2}(y) &= f_X(\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} \\&= \lambda \exp(-\lambda\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} \cdot \mathbb{I}_{[0,\infty[}(\sqrt{y}) \\&= \frac{\lambda}{2\sqrt{y}} \exp(-\lambda\sqrt{y}) \cdot \mathbb{I}_{[0,\infty[}(y)\end{aligned}$$

Erinnerung: Transformationssatz für Dichten III

Vielleicht einfacher:

$$\begin{aligned}F_X(x) &= \mathbb{P}(X \leq x) = 1 - \exp(-\lambda x) \\F_{X^2}(y) &= \mathbb{P}(X^2 \leq y) = \mathbb{P}(X \leq \sqrt{y}) \\&= 1 - \exp(-\lambda\sqrt{y}) \\f_{X^2} &= \frac{\partial}{\partial y} F_{X^2} = \lambda \exp(-\lambda\sqrt{y}) \cdot \frac{1}{2\sqrt{y}} \cdot \mathbb{I}_{[0, \infty[}(\sqrt{y})\end{aligned}$$

Nicht anwendbar für

- ▶ $X \sim U_{\{-2, -1, +1, +2\}} \implies X^2 \sim U_{\{1, 4\}}.$
- ▶ $X \sim N(0, 1) \implies X^2 \sim \chi^2$ – aber $g(x) = x^2$ nicht bijektiv!
- ▶ $\mathbf{X} \sim N_k(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \implies g(\mathbf{X}) \sim ?$

Allgemeiner Transformationssatz I

Aus Analysis II:

Definition

Sei $G \subseteq \mathbb{R}^m$, $f : G \rightarrow \mathbb{R}^m$, $m \in \mathbb{N}$, $x \in G$. Wenn für die Funktion $\mathbf{f} := (f_1, \dots, f_m)$ alle partiellen Ableitungen $\partial_k f$ existieren, dann heißt die quadratische $m \times m$ -Matrix der partiellen Ableitungen die Jacobi-Matrix:

$$J(\mathbf{x}) := \frac{\partial (f_1, \dots, f_m)}{\partial (x_1, \dots, x_m)}(\mathbf{x}) := \begin{pmatrix} \partial_1 f_1(x) & \dots & \partial_m f_1(x) \\ \vdots & & \vdots \\ \partial_1 f_m(x) & \dots & \partial_m f_m(x) \end{pmatrix}$$

Allgemeiner Transformationssatz II

Satz (Allgemeiner Transformationssatz)

Sei $\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$ mit $n \in \mathbb{N}$ eine (stetige mehrdimensionale) Zufallsvariable mit Dichte $f_{\mathbf{X}}$ bzgl. λ^n . Sei $\mathbf{g} : \mathbb{R}^n \rightarrow \mathbb{R}^n$ meßbare Funktion. Ferner sei für $G_m \in \mathcal{B}^n$, $m = 1, \dots, M$ eine (fast sicher vollständige) Aufteilung des $\mathbb{R}^n$ mit $\mathbb{P} \left(\mathbf{X} \in \bigcup_{m \in M} G_m \right) = 1$, so dass

$\mathbf{g}_m := \mathbf{g}|_{G_m}$ bijektiv und stetig differenzierbar

Sei für alle $m \in M$ $\mathbf{J}_m(y)$ die Jacobi-Matrix für $\mathbf{g}_m^{-1} := \mathbf{h}_m = (h_{1m}, \dots, h_{nm})$.

Allgemeiner Transformationssatz III

Dann gilt

$$f_{\mathbf{g} \circ \mathbf{x}}(\mathbf{y}) = \sum_{m \in M} v_m(\mathbf{y})$$

mit

$$v_m(\mathbf{y}) = \begin{cases} f_{\mathbf{x}}(h_m(\mathbf{y})) \cdot |\det(\mathbf{J}_m(\mathbf{y}))| & \text{falls } h_m(\mathbf{y}) \in G_m, \\ 0 & \text{sonst.} \end{cases}$$

Allgemeiner Transformationssatz IV

Beweisidee:

$$P(Y \in A) = P(X \in g^{-1}(A)) .$$

Integration über das Urbild und Variablentransformation im Integral, daraus Jacobideterminante als Volumenfaktor.

Beispiel eindimensionale, nicht bijektive Transformation

$X \sim N(0, 1)$ und $g(x) = x^2$.

$$G_1 = \mathbb{R}^+; G_2 = \mathbb{R}^-; \mathbb{P}(G_1 \cup G_2) = 1$$

$$h_1(y) = \sqrt{y}; h_2(y) = -\sqrt{y}$$

$$|J_1(y)| = \frac{1}{2}y^{-1/2}; |J_2(y)| = |-\frac{1}{2}y^{-1/2}| = \frac{1}{2}y^{-1/2}$$

$$v_1(y) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(y^{1/2})^2\right) \cdot |J_1(y)| \cdot I_{\mathbb{R}^+}(\sqrt{y})$$

$$v_2(y) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}(-y^{1/2})^2\right) \cdot |J_2(y)| \cdot I_{\mathbb{R}^-}(-\sqrt{y})$$

$$v_m(y) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}y\right) \cdot \frac{1}{2}y^{-1/2} \cdot I_{\mathbb{R}^+}(y) \quad \text{für } m = 1, 2$$

$$\begin{aligned} f_{X^2}(y) &= v_1(y) + v_2(y) = 2v_1(y) = \\ &= \sqrt{\frac{1}{2\pi}} y^{-1/2} \exp\left(-\frac{1}{2}y\right) \cdot I_{\mathbb{R}^+}(y) \end{aligned}$$

f_{X^2} ist die Dichte der χ^2 -Verteilung mit $k = 1$ Freiheitsgraden, da $\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$.

Beispiel mehrdimensionale Transformation I

Seien $X_1 \sim N(0, 1)$, $X_2 \sim N(0, 1)$ stochastisch unabhängig. Wie ist die Verteilung von $Z = \frac{X_2}{X_1}$?

Mehrdimensionaler Transformationssatz

Der Transformationssatz gilt nur für $g : \mathbb{R}^n \rightarrow \mathbb{R}^n$. Wollen wir die Dimension ändern, müssen wir in zwei Schritten vorgehen:

- ▶ Definiere $g : \mathbb{R}^n \rightarrow \mathbb{R}^n$, z.B. für $g(X) = (Z, W)$, so dass Z die interessierende Zufallsvariable ist
- ▶ Berechne Randverteilung von Z

Beispiel mehrdimensionale Transformation II

Schritt 1

Seien $X_1 \sim N(0, 1)$, $X_2 \sim N(0, 1)$ stochastisch unabhängig. Wie ist die Verteilung von $\mathbf{Y} = \begin{pmatrix} X_2 \\ X_1 \end{pmatrix}$?

Gemeinsame Dichte: $f(x_1, x_2) = \phi(x_1)\phi(x_2)$ wegen Unabhängigkeit.

Beispiel mehrdimensionale Transformation III

$$g(x_1, x_2) := \left(\frac{x_2}{x_1}, x_1 \right)$$

$$h(y_1, y_2) = g^{-1}(y_1, y_2) = (y_2, y_1 y_2)$$

$$\det(\mathbf{J}) = \det \begin{pmatrix} 0 & 1 \\ y_2 & y_1 \end{pmatrix} = -y_2$$

$$\begin{aligned} f_{Y_1, Y_2}(y_1, y_2) &= \phi(y_2) \phi(y_1 \cdot y_2) |\det \mathbf{J}| \\ &= \frac{|-y_2|}{2\pi} \exp \left(-\frac{1}{2} (y_2^2 + (y_1 y_2)^2) \right) \\ &= \frac{|y_2|}{2\pi} \exp \left(-\frac{1}{2} (y_2^2 \cdot (1 + y_1^2)) \right) \end{aligned}$$

Beispiel mehrdimensionale Transformation IV

Schritt 2

Gegeben ist die Dichte von $\mathbf{Y} = \left(\frac{X_2}{X_1}, X_1 \right) = (Z, X_1)$. Wie ist die Verteilung von

$$Z = \frac{X_2}{X_1}?$$

Beispiel mehrdimensionale Transformation V

$$\begin{aligned}f_Z(y_1) &= \int_{-\infty}^{\infty} f_{Y_1, Y_2}(y_1, y_2) dy_2 \\&= 2 \int_0^{\infty} \frac{y_2}{2\pi} \exp\left(-\frac{1}{2} y_2^2 (1 + y_1^2)\right) dy_2 && \text{(Symmetrie)} \\&= \frac{1}{\pi} \int_0^{\infty} y_2 \exp\left(-\frac{1}{2} y_2^2 (1 + y_1^2)\right) dy_2 \\&= \frac{1}{\pi} \left[\exp\left(-\frac{1}{2} y_2^2 (1 + y_1^2)\right) \frac{-1}{1 + y_1^2} \right]_{y_2=0}^{\infty} = \frac{-1}{\pi(1 + y_1^2)} (0 - 1) \\&= \frac{1}{\pi(1 + y_1^2)} \quad \text{Dichte der Cauchy-Verteilung, Def. 8.3}\end{aligned}$$

Faltung I

Sei $\mathbf{X} = (X_1, X_2)$ eine zweidimensionale Zufallsvariable mit Dichte $f_{\mathbf{X}}$ bzgl. λ^2 .
Gesucht ist $f_{X_1+X_2}$.

Sei $g(x_1, x_2) := (x_1 + x_2, x_2) \in \mathbb{R}^2$. g ist bijektiv und damit

$$h(y) = g^{-1}(y_1, y_2) = (y_1 - y_2, y_2)$$

$$g \circ X = (\underbrace{X_1 + X_2}_{=Y}, X_2)$$

$$\det(\mathbf{J}) = \det\left(\frac{\partial g^{-1}}{\partial y}\right) = \det\begin{pmatrix} \frac{\partial y_1 - y_2}{\partial y_1} & \frac{\partial y_1 - y_2}{\partial y_2} \\ \frac{\partial y_2}{\partial y_1} & \frac{\partial y_2}{\partial y_2} \end{pmatrix}$$

$$= \det\begin{pmatrix} 1 & -1 \\ 0 & 1 \end{pmatrix} = 1$$

$$f_{Y, X_2}(y, x_2) = f_{\mathbf{X}}(y - x_2, x_2) \cdot 1$$

Faltung II

$$\begin{aligned}\Rightarrow f_Y(y) &= \int f_{Y,X_2}(y, x_2) dx_2 \\ &= \int f_X(y - x_2, x_2) dx_2 \quad (\text{Faltung})\end{aligned}$$

Falls X_1 und X_2 stochastisch unabhängig gilt $f_X(x_1, x_2) = f_{X_1}(x_1) \cdot f_{X_2}(x_2)$ und damit

$$f_Y(y) = \int f_{X_1}(y - x_2) \cdot f_{X_2}(x_2) dx_2$$

Vergleiche Faltung im diskreten Fall (Statistik 1):

$$f_Y(y) = \sum_{x_2} f_{X_1}(y - x_2) \cdot f_{X_2}(x_2)$$

Beispiel Faltung I

Satz

Seien $X_1 \sim N(0, \lambda^2)$ und $X_2 \sim N(0, 1 - \lambda^2)$ stochastisch unabhängig. Dann gilt $X_1 + X_2 \sim N(0, 1)$.

Beweis:

$$\begin{aligned} f_{X_1+X_2}(z) &= \int f_{X_1}(z-x) f_{X_2}(x) dx \quad (\text{Faltung}) \\ &= \int \frac{1}{\sqrt{2\pi\lambda^2}} \exp\left(-\frac{1}{2} \left(\frac{z-x}{\lambda}\right)^2\right) \cdot \\ &\quad \cdot \frac{1}{\sqrt{2\pi(1-\lambda^2)}} \exp\left(-\frac{1}{2} \frac{x^2}{1-\lambda^2}\right) dx \end{aligned}$$

Beispiel Faltung II

$$= \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2} z^2\right) \cdot \underbrace{\int \frac{1}{\sqrt{2\pi}} \frac{1}{\sqrt{\lambda^2(1-\lambda^2)}} \exp\left(-\frac{1}{2} \underbrace{\left(\frac{(z-x)^2}{\lambda^2} + \frac{x^2}{1-\lambda^2} - z^2\right)}_A\right) dx}_B$$

$$\begin{aligned} A &= \frac{(1-\lambda^2)z^2 - 2(1-\lambda^2)zx + (1-\lambda^2)x^2 + \lambda^2 x^2 - \lambda^2(1-\lambda^2)z^2}{\lambda^2(1-\lambda^2)} \\ &= \frac{x^2 - 2(1-\lambda^2)zx + [(1-\lambda^2)z]^2}{\lambda^2(1-\lambda^2)} = \frac{(x - (1-\lambda^2)z)^2}{\lambda^2(1-\lambda^2)} \end{aligned}$$

Beispiel Faltung III

$\Rightarrow B(x)$ ist Dichte von $N((1 - \lambda^2)z, \lambda^2(1 - \lambda^2))$

$$\Rightarrow \int B(x) dx = 1$$



11. Zufallsvektoren

11.1 Mehrdimensionale Wahrscheinlichkeitsräume

11.2 Mehrdimensionale Verteilungsfunktion und Dichte

11.3 Randverteilung

11.4 Transformationssatz für Dichten

11.5 Exkurs: Faltung

Faltung I

Definition

Die Faltung (engl. *convolution*, von lat. *convolvere*, *zusammenrollen*) $f * g$ zweier Funktionen $f, g : \mathbb{R}^n \rightarrow \mathbb{C}$ ist definiert durch

$$(f * g)(x) := \int_{\mathbb{R}^n} f(\tau)g(x - \tau)d\tau$$

Anschaulich bedeutet die Faltung $f * g$, dass jeder Wert von f durch das mit g gewichtete Mittel $(f * g)(x)$ ersetzt wird, genauer der Funktionswert $f(t)$ mit $g(x - t)$ gewichtet wird.

Anwendungen

- ▶ Gleitender Mittelwert
- ▶ Filter für Signale, Bilder
- ▶ Dichte der Summe von Zufallsvariablen
- ▶ Kerndichteschätzer

Beispiele I




Abbildung 24: Faltung als Glättung

Beispiele II




Abbildung 25: Faltung als Kerndichteschätzer mit verschiedenen Kernen

Fourier-Transformation der Faltung I

Wir betrachten die *Fourier-Transformation* (Def. 10.4)

$$\tilde{f}(\xi) = \mathcal{F}(f)(\xi) = \frac{1}{(2\pi)^{\frac{n}{2}}} \int f(x) e^{-ix\xi} dx$$

Nach dem Satz von Fubini dürfen wir die Integrationsreihenfolge vertauschen (sofern alles integrierbar ist):

$$\mathcal{F}(f * g)(\xi) = \int_{-\infty}^{\infty} f(y) \left(\int_{-\infty}^{\infty} g(x - y) e^{-ix\xi} dx \right) dy$$

Mit der Substitution $u = x - y$, also $du = dx$:

$$\mathcal{F}(f * g)(\xi) = \int_{-\infty}^{\infty} f(y) e^{-iy\xi} \left(\int_{-\infty}^{\infty} g(u) e^{-iu\xi} du \right) dy$$


Fourier-Transformation der Faltung II

Also erhalten wir die Fouriertransformation der Faltung einfach als Produkt der Fouriertransformierten:

$$\mathcal{F}(f * g)(\xi) = \mathcal{F}(f)(\xi) \cdot \mathcal{F}(g)(\xi)$$

Fourier-Transformation der Faltung III

Die *schnelle Fourier-Transformation* (englisch **fast Fourier transform**, **FFT**) ist ein sehr effizienter Algorithmus zur Berechnung der diskreten Fourier-Transformation.



Kapitel 12

(Un-)Abhängigkeit

12. (Un-)Abhängigkeit

12.1 Unabhängigkeit

12.2 Kovarianz

12.3 Bedingte Verteilung



(Un-)Abhängigkeit




Abbildung 26: <https://xkcd.com/552/>

12. (Un-)Abhängigkeit

12.1 Unabhängigkeit

12.2 Kovarianz

12.3 Bedingte Verteilung

Verteilungsfunktion I

Satz (Unabhängigkeit n -dimensionaler Zufallsvariablen)

Sei $\mathbf{X} = (X_1, \dots, X_n)$ eine reelle n -dimensionale Zufallsvariable. Dann gilt $X_1, \dots, X_n$ stochastisch unabhängig $\iff \forall \mathbf{c} = (c_1, \dots, c_n) \in \mathbb{R}^n$

$$\begin{aligned}\mathbb{P}(\mathbf{X} \leq \mathbf{c}) &= \mathbb{P}(X_1 \leq c_1, \dots, X_n \leq c_n) \\ &= \prod_{i=1}^n \mathbb{P}(X_i \leq c_i), \\ F_{\mathbf{X}}(\mathbf{c}) &= \prod_{i=1}^n F_{X_i}(c_i).\end{aligned}$$

Verteilungsfunktion II

Beweis:

“Unabhängigkeit $\implies$ Produktformel”

Wenn $X_1, \dots, X_n$ unabhängig sind, dann sind per Definition die von ihnen erzeugten σ -Algebren $\sigma(X_1), \dots, \sigma(X_n)$ unabhängig. Insbesondere sind dann für alle Borel-Mengen $A_i \in \mathcal{B}(\mathbb{R})$ die Ereignisse $\{X_i \in A_i\}$ unabhängig und es gilt:

$$P(X_1 \in A_1, \dots, X_n \in A_n) = \prod_{i=1}^n P(X_i \in A_i).$$

Wähle $A_i = (-\infty, c_i]$. Dann folgt sofort

$$P(X_1 \leq c_1, \dots, X_n \leq c_n) = \prod_{i=1}^n P(X_i \leq c_i).$$

Verteilungsfunktion III

“Produktformel $\implies$ Unabhängigkeit”

Betrachten wir $\mathcal{H} := \{(-\infty, c] : c \in \mathbb{R}\}$. $\mathcal{H}$ ist durchschnittsstabil (Def. 3.9):
 $(-\infty, c_1] \cap (-\infty, c_2] = (-\infty, \min(c_1, c_2)]$ und Erzeuger der Borelschen σ -Algebra $\mathcal{B}$.

Für feste $A_2, \dots, A_n \in \mathcal{H}$ definiere für $A \in \mathcal{B}(\mathbb{R})$ zwei Maße

$$\mu(A) = P(X_1 \in A, X_2 \in A_2, \dots, X_n \in A_n),$$

$$\nu(A) = P(X_1 \in A) \prod_{i=2}^n P(X_i \in A_i).$$

Beide sind Maße in der Variablen A . Aus Voraussetzung $P(X_1 \leq c_1, \dots, X_n \leq c_n) = \prod_{i=1}^n P(X_i \leq c_i)$ folgt

$$\mu((-\infty, c]) = \nu((-\infty, c]) \quad \forall c.$$

Verteilungsfunktion IV

Also stimmen μ und ν auf dem Erzeuger $\mathcal{H}$ überein und damit nach Eindeutigkeit von Maßen (Satz 3.10) $\mu = \nu$.

Damit gilt die Produktformel für alle Borelmengen A_1 , solange $A_2, \dots, A_n \in \mathcal{H}$ sind. Nun iteriere durch alle A_i , so dass

$$P(X_1 \in A_1, \dots, X_n \in A_n) = \prod_{i=1}^n P(X_i \in A_i)$$

für alle $A_i \in \mathcal{B}(\mathbb{R})$.



Dichte unabhängiger Zufallsvariablen I

Satz

Sind $X_1, \dots, X_n$ reelle unabhängige ZV mit Dichten $f_{X_1}, \dots, f_{X_n}$ bzgl. $\mu = \bigotimes_{i=1}^n \mu_i$, dann und genau dann ist die gemeinsame Dichte von $\mathbf{X} = (X_1, \dots, X_n)^\top$ das Produkt der einzelnen Dichten, d.h.

$$f_{\mathbf{X}}(x) = \prod_{i=1}^n f_{X_i}(x_i)$$

ist Dichte bzgl. μ .

Dichte unabhängiger Zufallsvariablen II

Beweis

$$\text{"}X_i \text{ stu} \implies f_{\mathbf{X}} = \prod f_{X_i}\text{"}$$

Sei $F_{\mathbf{X}}$ Verteilungsfunktion von $\mathbf{X}$, $c \in \mathbb{R}^n$. Nach Definition:

$$\begin{aligned} F_{\mathbf{X}}(c) &= \mathbb{P}_{\mathbf{X}}(I_c) = \int_{I_c} f d\mu \quad \text{für } I_c := (-\infty, c_1] \times \dots \times (-\infty, c_n] \\ &= \mathbb{P}(X_1 \leq c_1, \dots, X_n \leq c_n) \stackrel{\text{Satz 12.1}}{=} \prod_{i=1}^n \mathbb{P}(X_i \leq c_i) = \prod_{i=1}^n \int_{(-\infty, c_i]} f_{X_i} d\mu_i \\ &\stackrel{\text{Fubini}}{=} \int_{(-\infty, c_1]} \dots \int_{(-\infty, c_n]} \prod_{i=1}^n f_{X_i} d\mu_1 \dots d\mu_n \stackrel{\text{Fubini}}{=} \int_{I_c} \prod_{i=1}^n f_{X_i} d\mu \\ \implies f &= \prod_{i=1}^n f_{X_i} \mu - \text{f.ü.}, \quad (\text{Satz 7.4 Radon-Nikodym}) \end{aligned}$$

Dichte unabhängiger Zufallsvariablen III

“ $f_{\mathbf{X}} = \prod f_{X_i} \implies X_i$ stu”

$$\begin{aligned}\mathbb{P}(X_1 \leq c_1, \dots, X_n \leq c_n) &= F_{\mathbf{X}}(c) = \int_{I_c} \prod_{i=1}^n f_{X_i} d\lambda^n && \text{(nach Voraussetzung)} \\ &= \prod_{i=1}^n \int_{(-\infty, c_i]} f_{X_i} d\lambda && \text{(Fubini)} \\ &= \prod_{i=1}^n \mathbb{P}(X_i \leq c_i)\end{aligned}$$



Unabhängigkeit von Funktionen von Zufallsvariablen

Satz

Seien $\mathbf{X}_1 : \Omega \rightarrow \mathbb{R}^{n_1}$ und $\mathbf{X}_2 : \Omega \rightarrow \mathbb{R}^{n_2}$ zwei n_i -dimensionale stochastisch unabhängige Zufallsvariablen ($i = 1, 2$) und $\mathbf{h}_i : \mathbb{R}^{n_i} \rightarrow \mathbb{R}^{m_i}$ meßbare Funktionen. Dann sind $\mathbf{Y}_1 = \mathbf{h}_1 \circ \mathbf{X}_1$ und $\mathbf{Y}_2 = \mathbf{h}_2 \circ \mathbf{X}_2$ stochastisch unabhängig.

Erwartungswert des Produkts unabhängiger Zufallsvariablen I

Satz (Erwartungswert des Produkts unabhängiger Zufallsvariablen)

Sind $X_1, \dots, X_n$ unabhängige integrierbare Zufallsvariablen, so folgt

$$\mathbb{E} \left(\prod_{i=1}^n X_i \right) = \prod_{i=1}^n \mathbb{E}(X_i).$$

► Die Umkehrung folgt nicht!

Beweis:

Betrachte $n = 2$. Wegen stochastischer Unabhängigkeit $f_X = f_{X_1} \cdot f_{X_2}$.

$$\mathbb{P}_X = f_X \odot (\mu_1 \otimes \mu_2) = f_{X_1} \cdot f_{X_2} \odot (\mu_1 \otimes \mu_2)$$

Erwartungswert des Produkts unabhängiger Zufallsvariablen II

Sei nun $g : \mathbb{R}^2 \Rightarrow \mathbb{R}, x \mapsto g(x) = x_1 \cdot x_2$:

$$\begin{aligned}\mathbb{E}(X_1 X_2) &= \mathbb{E}(g \circ \mathbf{X}) = \int g d\mathbb{P}_{\mathbf{X}} \\&= \int g d(f_{\mathbf{X}} \odot (\mu_1 \otimes \mu_2)) \\&= \int g \cdot (f_{X_1} \cdot f_{X_2}) d(\mu_1 \otimes \mu_2) \quad (\text{Unabhängigkeit und Satz 7.1}) \\&= \int \int x_1 x_2 f_{X_1}(x_1) \cdot f_{X_2}(x_2) d\mu_1(x_1) d\mu_2(x_2) \\&= \int x_1 f_{X_1}(x_1) d\mu_1(x_1) \int x_2 f_{X_2}(x_2) d\mu_2(x_2) \\&= \mathbb{E}(X_1) \cdot \mathbb{E}(X_2)\end{aligned}$$

Erwartungswert des Produkts unabhängiger Zufallsvariablen III

Für $n > 2$ durch Induktion.



- Daraus folgt auch der Beweis von Satz 10.8 (Momenterzeugende/Charakteristische Funktion von Summen von Zufallsvariablen).

12. (Un-)Abhängigkeit

12.1 Unabhängigkeit

12.2 Kovarianz

12.3 Bedingte Verteilung

Kovarianz und Korrelation

Definition

Seien X und $Y : \Omega \rightarrow \mathbb{R}$ Zufallsvariablen mit $\mathbb{E}(X^2) < \infty$ und $\mathbb{E}(Y^2) < \infty$. Dann heißt

$$\text{Cov}(X, Y) := \mathbb{E}[(X - \mathbb{E}(X))(Y - \mathbb{E}(Y))]$$

die Kovarianz (engl. **covariance**) sowie, wenn $\text{Var}(X) > 0$ und $\text{Var}(Y) > 0$,

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)} \cdot \sqrt{\text{Var}(Y)}}.$$

die Korrelation (engl. **correlation**) von X und Y .

- Kovarianz und Korrelation sind Maße für die Stärke und Richtung der **linearen** stochastischen Abhängigkeit von Zufallsvariablen.

Eigenschaften der Kovarianz I

Im Folgenden gehen wir immer davon aus, dass die Kovarianzen bzw. die Erwartungswerte existieren.

Satz (Eigenschaften der Kovarianz)

- 1) $\text{Cov}(X, X) = \text{Var}(X)$
- 2) $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
- 3) $\text{Cov}(-X, Y) = -\text{Cov}(X, Y)$

Beweis:, Einsetzen!

Eigenschaften der Kovarianz II

Satz

$$|\operatorname{Cov}(X, Y)| \leq \sqrt{\operatorname{Var}(X) \operatorname{Var}(Y)}$$

$$-1 \leq \rho(X, Y) \leq +1$$

Beweis: Folgt direkt aus der Cauchy-Schwarz-Ungleichung Satz 8.18.

Eigenschaften der Kovarianz III

Satz (Verschiebungssatz)

$$\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

Beweis:

Ausmultiplizieren und Linearität des Erwartungswertes:

$$\begin{aligned}\text{Cov}(X, Y) &= \mathbb{E}[XY - X\mathbb{E}(Y) - \mathbb{E}(X)Y + \mathbb{E}(X)\mathbb{E}(Y)] \\ &= \mathbb{E}(XY) - \mathbb{E}(Y)\mathbb{E}(X) - \mathbb{E}(X)\mathbb{E}(Y) + \mathbb{E}(X)\mathbb{E}(Y) \\ &= \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)\end{aligned}$$



Eigenschaften der Kovarianz IV

Satz (Summe von Varianzen)

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y)$$

Beweis:

$$\begin{aligned}\text{Var}(X + Y) &= \mathbb{E}((X + Y)^2) - \mathbb{E}(X + Y)^2 \\ &= \mathbb{E}((X^2 + 2XY + Y^2)) - (\mathbb{E}(X) + \mathbb{E}(Y))^2 \\ &= \mathbb{E}(X^2) - \mathbb{E}(X)^2 + \mathbb{E}(Y^2) - \mathbb{E}(Y)^2 + 2\mathbb{E}(XY) - 2\mathbb{E}(X)\mathbb{E}(Y) \\ &= \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y)\end{aligned}$$



Eigenschaften der Kovarianz V

Nur für **stochastisch unabhängige** Zufallsvariablen X und Y gilt also:

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$$

Eigenschaften der Kovarianz VI

Satz (Bilinearität)

$$\text{Cov}(aX + b, cY + d) = ac \text{Cov}(X, Y)$$

Beweis:

$$\begin{aligned}\text{Cov}(aX + b, cY + d) &= \mathbb{E}[(aX + b - \mathbb{E}(aX + b)) \cdot (cY + d - \mathbb{E}(cY + d))] \\ &= \mathbb{E}[(aX - a\mathbb{E}(X)) \cdot (cY - c\mathbb{E}(Y))] \\ &= ac\mathbb{E}[(X - \mathbb{E}(X)) \cdot (Y - \mathbb{E}(Y))] \\ &= ac \text{Cov}(X, Y)\end{aligned}$$



Kovarianzmatrix I

Definition

Sei $\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$, $\mathbf{X} = (X_1, \dots, X_n)$ eine n -dimensionale Zufallsvariable, dann heißt

$$\mathbf{Cov}(\mathbf{X}) := \mathbb{E}((\mathbf{X} - \mathbb{E}(\mathbf{X}))(\mathbf{X} - \mathbb{E}(\mathbf{X}))^\top)$$

die Kovarianzmatrix (engl. *covariance matrix*) von $\mathbf{X}$.

$$\mathbf{Cov}(\mathbf{X}) \in \mathbb{R}^{n \times n}$$

$$(\mathbf{Cov}(\mathbf{X}))_{i,j} = \mathbb{E}((X_i - \mathbb{E}(X_i))(X_j - \mathbb{E}(X_j))) = \text{Cov}(X_i, X_j) = \mathbf{Cov}(\mathbf{X})_{j,i}$$

$$(\mathbf{Cov}(\mathbf{X}))_{i,i} = \mathbb{E}((X_i - \mathbb{E}(X_i))^2) = \text{Var}(X_i) \text{ (marginale Varianzen)}$$

► Die Kovarianzmatrix ist symmetrisch

Kovarianzmatrix II

Beispiel 12.1

$$\mathbf{X} \sim N_2 \left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix} \right)$$

Es gilt: $\text{Var}(X_1) = \sigma_1^2$, $\text{Var}(X_2) = \sigma_2^2$, $\text{Cov}(X_1, X_2) = \rho\sigma_1\sigma_2$.

Kovarianzmatrix III

Beispiel 12.2 (Multinomialverteilung)

Sei $\mathbf{X} \sim M(n, \mathbf{p})$ mit $\mathbf{p} = (p_1, \dots, p_k)$.

Wir wissen bereits $X_i \sim B(n, p_i) \implies \mathbb{E}(X_i) = np_i, \text{Var}(X_i) = np_i(1 - p_i)$. Wie ist die $\text{Cov}(X_i, X_j)$ für $i \neq j$?

Es gilt $X_i + X_j \sim B(n, p_i + p_j)$. Also

$$\text{Var}(X_i + X_j) = n(p_i + p_j)(1 - p_i - p_j)$$

Außerdem gilt allgemein

$$\text{Var}(X_i + X_j) = \text{Var}(X_i) + \text{Var}(X_j) + 2 \text{Cov}(X_i, X_j)$$

Kovarianzmatrix IV

Also

$$\begin{aligned}\text{Cov}(X_i, X_j) &= \frac{1}{2} (\text{Var}(X_i + X_j) - (\text{Var}(X_i) + \text{Var}(X_j))) \\ &= \frac{1}{2} (n(p_i + p_j)(1 - p_i - p_j) - (np_i(1 - p_i) + np_j(1 - p_j))) \\ &= \frac{1}{2} (np_i - np_i^2 - np_i p_j + np_j - np_i p_j - np_j^2 \\ &\quad - np_i + np_i^2 - np_j + np_j^2) \\ &= -np_i p_j\end{aligned}$$

Kovarianzmatrix $\mathbf{V}$

Zusammen also $\mathbf{X} \sim M(n, \mathbf{p}) \implies$

$$\mathbb{E}(\mathbf{X}) = \begin{pmatrix} np_1 \\ \vdots \\ np_k \end{pmatrix}$$

$$\mathbf{Cov}(\mathbf{X}) = \begin{pmatrix} np_1(1-p_1) & -np_1p_2 & -np_1p_3 & \cdots & -np_1p_k \\ -np_1p_2 & np_2(1-p_2) & -np_2p_3 & & -np_2p_k \\ -np_1p_3 & -np_2p_3 & np_3(1-p_3) & \ddots & \vdots \\ \vdots & & \ddots & \ddots & \\ -np_1p_k & -np_2p_k & \cdots & & np_k(1-p_k) \end{pmatrix}$$

Korrelationsmatrix I

Definition

Sei Σ die Kovarianzmatrix einer mehrdimensionalen Zufallsvariablen $X = (X_1, \dots, X_n)$ und $\text{diag}(\Sigma)$ die Matrix der Diagonalelemente von Σ . Dann heißt

$$R = \text{Corr}(X) := (\text{diag}(\Sigma))^{-1/2} \Sigma (\text{diag}(\Sigma))^{-1/2}$$

die Korrelationsmatrix von X .

Es gilt $r_{i,i} = 1$ für alle $i = 1, \dots, n$ und

$$r_{i,j} = \rho(X_i, X_j) = \frac{\text{Cov}(X_i, X_j)}{\sqrt{\text{Var}(X_i)} \cdot \sqrt{\text{Var}(X_j)}}$$

Korrelationsmatrix II

Beispiel 12.3

Sei $\mathbf{X} \sim M(10, (0.5, 0.3, 0.2))$. Die Kovarianzmatrix ist

$$\mathbf{Cov}(\mathbf{X}) = \Sigma = \begin{pmatrix} 2.5 & -1.5 & -1 \\ -1.5 & 2.1 & -0.6 \\ -1 & -0.6 & 1.6 \end{pmatrix}$$

$$\text{diag}(\Sigma) = \begin{pmatrix} 2.5 & 0 & 0 \\ 0 & 2.1 & 0 \\ 0 & 0 & 1.6 \end{pmatrix} \quad \text{diag}(\Sigma)^{-1/2} = \begin{pmatrix} 0.63... & 0 & 0 \\ 0 & 0.69... & 0 \\ 0 & 0 & 0.79... \end{pmatrix}$$

$$\text{Corr}(X) = (\text{diag}(\Sigma))^{-1/2} \Sigma (\text{diag}(\Sigma))^{-1/2} = \begin{pmatrix} 1 & -0.654... & -0.5 \\ -0.654... & 1 & -0.327... \\ -0.5 & -0.327... & 1 \end{pmatrix}$$

Eigenschaften I

Satz

Sei $\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$ n -dimensionale Zufallsvariable, $\mathbf{A} \in \mathbb{R}^{m \times n}$ und $\mathbf{b} \in \mathbb{R}^m$. Dann gilt

- i) $\mathbb{E}(\mathbf{AX} + \mathbf{b}) = \mathbf{A}\mathbb{E}(\mathbf{X}) + \mathbf{b}$
- ii) $\text{Cov}(\mathbf{AX} + \mathbf{b}) = \mathbf{A}\text{Cov}(\mathbf{X})\mathbf{A}^\top$

Eigenschaften II

Beweis:

i) Linearität des Erwartungswertes

ii)

$$\begin{aligned}\mathbf{Cov}(AX + b) &= \mathbb{E}((AX + b - \mathbb{E}(AX + b))(AX + b - \mathbb{E}(AX + b))^{\top}) \\&= \mathbb{E}((AX + b - A\mathbb{E}(X) - b)(AX + b - A\mathbb{E}(X) - b)^{\top}) \\&= \mathbb{E}((AX - A\mathbb{E}(X))(AX - A\mathbb{E}(X))^{\top}) \\&= \mathbb{E}(A(X - \mathbb{E}(X))(X - \mathbb{E}(X))^{\top} A^{\top}) \\&= A\mathbb{E}((X - \mathbb{E}(X))(X - \mathbb{E}(X))^{\top}) A^{\top} \\&= A\mathbf{Cov}(X)A^{\top}\end{aligned}$$



Eigenschaften III

Satz

Die Kovarianzmatrix ist positiv semidefinit.

Beweis:

Positiv semidefinit heißt $\mathbf{x}^\top \mathbf{Cov}(\mathbf{X}) \mathbf{x} \geq 0 \quad \forall \mathbf{x} \in \mathbb{R}^n$

$$\begin{aligned}\mathbf{x}^\top \mathbf{Cov}(\mathbf{X}) \mathbf{x} &= \mathbf{x}^\top \mathbb{E}((\mathbf{X} - \mathbb{E}(\mathbf{X})) (\mathbf{X} - \mathbb{E}(\mathbf{X}))^\top) \mathbf{x} \\ &= \mathbb{E}(\underbrace{(\mathbf{x}^\top \mathbf{X} - \mathbf{x}^\top \mathbb{E}(\mathbf{X})) (\mathbf{x}^\top \mathbf{X} - \mathbf{x}^\top \mathbb{E}(\mathbf{X}))^\top}_{\in \mathbb{R}}) \\ &= \mathbb{E}((\mathbf{x}^\top \mathbf{X} - \mathbf{x}^\top \mathbb{E}(\mathbf{X}))^2) \\ &= \mathbf{Cov}(\mathbf{x}^\top \mathbf{X}) = \text{Var}(\mathbf{x}^\top \mathbf{X}) \geq 0\end{aligned}$$

□

- ▶ Für $n = 1 \implies \text{Var}(X) \geq 0$.
- ▶ $\det(\Sigma) = 0$ heißt nicht $\mathbf{X} \equiv \text{const.}$

Eigenschaften IV

Beispiel 12.4

Sei X Zufallsvariable mit $\text{Var}(X) = 1$. Betrachte die zweidimensionale Zufallsvariable $\mathbf{Y} = (X, X)$. Es gilt $\text{Cov}(X, X) = \text{Var}(X) = 1$. Also

$$\mathbf{Cov}(\mathbf{Y}) = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$$

Es gilt $\det(\mathbf{Cov}(\mathbf{Y})) = 0$.

Standardisierung I

Satz (Standardisierung)

Sei $\mathbf{X} = (X_1, \dots, X_n)$ n -dimensionaler Zufallsvektor mit $\mathbb{E}(\mathbf{X}) = \boldsymbol{\mu}$ und positiv definiter Kovarianzmatrix $\mathbf{Cov}(\mathbf{X}) = \Sigma$. Dann existiert eine invertierbare Matrix $\mathbf{B} \in \mathbb{R}^{n \times n}$, so dass gilt:

Für $\mathbf{Y} = \mathbf{B}^{-1}(\mathbf{X} - \boldsymbol{\mu})$ ist $\mathbb{E}(\mathbf{Y}) = \mathbf{0}_n$, $\mathbf{Cov}(\mathbf{Y}) = \mathbf{I}_n$

- ▶ $\mathbf{0}_n$ bezeichnet den Null-Vektor der Länge n .
- ▶ $\mathbf{I}_n$ bezeichnet die Einheitsmatrix der Dimension $n \times n$.
- ▶ Für $n = 1$ gilt mit $\mathbf{Cov}(X) = \sigma^2$: $Y = \frac{X - \mu}{\sigma}$ hat $\mathbb{E}(Y) = 0$ und $\mathbf{Cov}(Y) = 1$.

Standardisierung II

Beweis:

Σ ist nach Voraussetzung positiv definit. Damit existiert die Cholesky-Zerlegung $\Sigma = \mathbf{B}\mathbf{B}^\top$ mit $\mathbf{B} \in \mathbb{R}^{n \times n}$ und $\mathbf{B}^{-1}$ existiert. Also

$$\mathbb{E}(\mathbf{Y}) = \mathbb{E}(\mathbf{B}^{-1}(\mathbf{X} - \boldsymbol{\mu})) = \mathbf{B}^{-1}(\mathbb{E}(\mathbf{X}) - \boldsymbol{\mu}) = \mathbf{B}^{-1}\mathbf{0}_n = \mathbf{0}_n$$

$$\text{Cov}(\mathbf{Y}) = \mathbf{B}^{-1} \text{Cov}(\mathbf{X}) \mathbf{B}^{-1\top} = \mathbf{B}^{-1} \mathbf{B} \mathbf{B}^\top \mathbf{B}^{-1\top} = \mathbf{I}_n (\mathbf{B}^{-1} \mathbf{B})^\top = \mathbf{I}_n$$

□

12. (Un-)Abhängigkeit

12.1 Unabhängigkeit

12.2 Kovarianz

12.3 Bedingte Verteilung

Bedingte Wahrscheinlichkeit I

In Def. 3.26 haben wir die bedingte Wahrscheinlichkeit kennen gelernt:

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

Das Konzept lässt sich leicht auf diskrete Zufallsvariablen erweitern. Seien X und Y diskrete Zufallsvariablen. Dann ist die bedingte Verteilung von X gegeben $Y = y$ (auf dem Träger von Y , also $\mathbb{P}(Y = y) > 0$):

$$\mathbb{P}(X = x|Y = y) = \frac{\mathbb{P}(X = x, Y = y)}{\mathbb{P}(Y = y)}$$

Bedingte Wahrscheinlichkeit II

Beispiel 12.5

Wir werfen zwei Mal eine faire Münze. Sei

- ▶ X Anzahl der Münzwürfe mit Kopf und
- ▶ $Y = 1$ wenn der erste Münzwurf Kopf ist, 0 sonst.

$$\mathbb{P}(X = x | Y = 1) = \frac{\mathbb{P}(X = x, Y = 1)}{\mathbb{P}(Y = 1)} = \begin{cases} \frac{0}{0.5} & = 0 & \text{für } x = 0 \\ \frac{0.25}{0.5} & = 0.5 & \text{für } x = 1 \\ \frac{0.25}{0.5} & = 0.5 & \text{für } x = 2 \end{cases}$$

Analog für $Y = 0$.

- ▶ Siehe auch Gedächtnislosigkeit der Exponentialverteilung, Satz 5.11.

Bedingte Verteilung I

Beispiel 12.6

Wir würfeln mit einem Würfel. Sei Y die Zufallsvariable und y das Ergebnis des Wurfs. Anschliessend werfen wir y -mal eine faire Münze. Die Anzahl der Münzwürfe, die *Kopf* zeigen, sei X .

► $X|Y = 1 \sim B\left(1, \frac{1}{2}\right)$

► $X|Y = 2 \sim B\left(2, \frac{1}{2}\right)$

► ...

Allgemein können wir schreiben:

$$X|(Y = y) \sim B\left(y, \frac{1}{2}\right)$$

Wir nennen dies die **bedingte Verteilung** (engl. *conditional distribution*) von $X|Y$.

Bedingte Verteilung II

Berechnen wir die **gemeinsame Dichte** (engl. **joint density**) von (X, Y) . Es gilt:


$$\begin{aligned}f_{(X,Y)}(x,y) &= \mathbb{P}(X=x, Y=y) \\&= \mathbb{P}(X=x|Y=y) \cdot \mathbb{P}(Y=y) \\&= \binom{y}{x} 0.5^y I_{\{0,\dots,y\}}(x) \cdot \frac{1}{6} I_{\{1,\dots,6\}}(y)\end{aligned}$$

Damit ergibt sich für die **Randdichte** (engl. **marginal density**) von X :

$$\mathbb{P}(X=x) = \frac{1}{6} \sum_{y=1}^6 \binom{y}{x} 0.5^y \cdot I_{\{0,\dots,y\}}(x)$$

	0	1	2	3	4	5	6
$P(X=x)$	0.1641	0.3125	0.2578	0.1667	0.0755	0.0208	0.0026

Bedingte Dichte I



Bedingte Dichte II

Beispiel 12.7

Wir rollen eine weiße Billardkugel auf einem Billardtisch der Länge 1. Die Zufallsvariable X beschreibe den Punkt auf $[0, 1]$, auf dem die Kugel zu liegen kommt.

Wir rollen weitere n rote Kugeln. Beschreibe die Zufallsvariable Y_i ob die rote Kugel i links von der weißen Kugel zu liegen kommt (also auf einem Punkt kleiner X). Offensichtlich gilt $\mathbb{P}(Y_i = 1|X = x) = x$ bzw. $Y \sim B(n, X)$.

Aber: Die bedingte Wahrscheinlichkeit $\mathbb{P}(Y|X = x)$ ist nicht definiert, da X eine stetige Zufallsvariable ist und damit $\mathbb{P}(X = x) \equiv 0$.

Bedingte Dichte III

Definition (Bedingte Dichte)

Seien (X, Y) Zufallsvariablen mit gemeinsamer Dichte f . Dann heißt

$$f_{X|Y}(x|y) := \begin{cases} \frac{f(x,y)}{f_Y(y)} & \text{falls } f_Y(y) > 0 \\ 0 & \text{sonst} \end{cases}$$

die bedingte Dichte (engl. **conditional density**) von X gegeben Y , also die Dichte von $X|Y$.

- Für X und Y diskret entspricht dies der bedingten Wahrscheinlichkeit.

Bedingte Dichte IV

Beispiel 12.8

Sei $(X, Y) : \Omega \rightarrow (0, 1) \times (0, 1)$ mit Dichte (im Folgenden immer $0 < x < 1$ und $0 < y < 1$)

$$f(x, y) = \frac{6}{5} (x^2 + y)$$

Die marginale Dichte von Y ist

$$\begin{aligned} f_Y(y) &= \int f(x, y) dx = \int_0^1 \frac{6}{5} (x^2 + y) dx \\ &= \frac{6}{5} \int_0^1 x^2 dx + \frac{6}{5} y = \frac{6}{5} \left[\frac{1}{3} x^3 \right]_0^1 + \frac{6}{5} y = \frac{2}{5} + \frac{6}{5} y \end{aligned}$$

Bedingte Dichte V

Die marginale Dichte von X ist

$$f_X(x) = \int f(x, y) dy = \int_0^1 \frac{6}{5}(x^2 + y) dy = \frac{6}{5}x^2 + \frac{6}{5} \int_0^1 y dy = \frac{6}{5}x^2 + \frac{3}{5}$$




Das ist wirklich eine Dichte, da

$$\int f_X(x) dx = \int_0^1 \left(\frac{6}{5}x^2 + \frac{3}{5} \right) dx = \frac{6}{5} \left[\frac{1}{3}x^3 \right]_0^1 + \frac{3}{5} = 1$$

Die bedingte Dichte von $X|Y$ ist

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)} = \frac{\frac{6}{5}(x^2 + y)}{\frac{2}{5} + \frac{6}{5}y} = \frac{3(x^2 + y)}{1 + 3y}$$

Bedingte Dichte VI



Satz von Bayes I

Satz (Satz von Bayes für Dichten)

Seien X und Y Zufallsvariablen mit Dichten f_X (bezüglich μ) und f_Y und gemeinsamer Dichte $f_{X,Y}$. Dann ist

$$f_{X|Y}(x|y) = \frac{f_{Y|X}(y|x)f_X(x)}{f_Y(y)} = \frac{f_{Y|X}(y|x)f_X(x)}{\int f_{Y|X}(y|x)f_X(x)d\mu(x)}$$

solange X bzw. Y eine Dichte haben (können also jeweils diskret oder stetig sein).

Satz von Bayes II

Beweis:

Nach Definition der bedingten Dichte:

$$f_{X,Y}(x,y) = f_{X|Y}(x|y)f_Y(y) = f_{Y|X}(y|x)f_X(x)$$

Nach Definition der marginalen Dichte:

$$f_Y(y) = \int f_{X,Y}(x,y)d\mu(x) = \int f_{Y|X}(y|x)f_X(x)d\mu(x)$$



Satz von Bayes III

Thomas Bayes (1701 bis 7. April 1761)

Englischer Mathematiker, Philosoph und presbyterianischer Pfarrer. Der nach ihm benannte Satz wurde 1763 in einem posthum erschienenen Artikel bewiesen.



Vermutlich nicht Rev. Thomas Bayes



Grab von Thomas Bayes

Satz von Bayes IV

Beispiel 12.9 (Beispiel von Bayes)

Fortsetzung von Beispiel 12.7.

Wir rollen eine weiße Billardkugel auf einem Billardtisch der Länge 1. Die Zufallsvariable X beschreibe den Punkt auf $[0, 1]$, auf dem die Kugel zu liegen kommt. Annahme: $X \sim U[0, 1]$.

Wir rollen weitere n rote Kugeln. Beschreibe die Zufallsvariable Y_i ob die rote Kugel i links von der weißen Kugel zu liegen kommt (also auf einem Punkt kleiner X). Offensichtlich gilt $\mathbb{P}(Y_i = 1 | X = x) = x$.

Wir kennen die Anzahl y der Kugeln, die insgesamt links von $X = x$ zu liegen kommen. Mit $Y = \sum_{i=1}^n Y_i$ gilt $Y | X = x \sim B(n, x)$. Können wir eine Aussage über die Verteilung von X gegeben $Y = y$ treffen?

Satz von Bayes V

Satz von Bayes:

$$\begin{aligned}f_{X|Y}(x|y) &= \frac{f_{Y|X}(y|x)f_X(x)}{\int f_{Y|X}(y|x)f_X(x)dx} \\&= \frac{\binom{n}{y}x^y(1-x)^{n-y} \cdot I_{[0,1]}(x)}{\int \binom{n}{y}x^y(1-x)^{n-y} \cdot I_{[0,1]}(x)dx} \\&= \frac{1}{B(y+1, n-y+1)}x^{(y+1)-1}(1-x)^{(n-y+1)-1}\end{aligned}$$

Also ist $X|Y = y \sim \text{Beta}(y+1, n-y+1)$. (vgl. Def. 19.15)

Satz von Bayes VI

Hier ist also die

- ▶ Vorinformation, auch **Priori** genannt, $X \sim U(0, 1)$, d.h. $X \sim \text{Beta}(1, 1)$
- ▶ Datenverteilung (Datendichte, **Likelihood**) $Y|X \sim B(n, x)$
- ▶ Information nach Beobachtung, auch **Posteriori** genannt,
 $X|Y \sim \text{Beta}(y + 1, n - y + 1)$

Bedingter Erwartungswert I

Definition

Seien X und Y reelwertige Zufallsvariablen. Ist $f_{X|Y}(x|y)$ die bedingte Dichte von X gegeben $Y = y$ mit dominierendem Maß μ , dann ist

$$\mathbb{E}(X|Y = y) = \int x f_{X|Y}(x|y) d\mu(x)$$

der bedingte Erwartungswert von X gegeben $Y = y$.

Damit ist

$$\mathbb{E}(X|Y) : \mathbb{R} \rightarrow \mathbb{R}$$

$$\text{mit } \mathbb{E}(X|Y)(y) := \mathbb{E}(X|Y = y),$$

der bedingte Erwartungswert von X gegeben Y , eine Zufallsvariable.

Bedingter Erwartungswert II

Beispiel 12.10 (Weiterführung Bsp. 12.6))

Es gilt $X|Y \sim B(Y, \frac{1}{2})$, also

$$\mathbb{E}(X|Y) = \frac{1}{2} \cdot Y$$

Satz vom iterierten Erwartungswert I

Satz (Satz vom iterierten Erwartungswert)

$$\mathbb{E}(\mathbb{E}(X|Y)) = \mathbb{E}(X)$$

Satz vom iterierten Erwartungswert II

Beweis:

$$\begin{aligned}\mathbb{E}_Y(\mathbb{E}_{X|Y}(X|Y)) &= \mathbb{E}_Y \left(\int x \, d\mathbb{P}_{X|Y=y}(x) \right) \\&= \mathbb{E}_Y \left(\int x f_{X|Y=y}(x|y) \, d\nu_X(x) \right) \\&= \int \int x f_{X|Y}(x|y) \, d\nu_X(x) f_Y(y) \, d\nu_Y(y) \\&\stackrel{\text{Fubini}}{=} \int \int x f_{X|Y}(x|y) f_Y(y) \, d\nu_X(x) \, d\nu_Y(y) \\&\stackrel{\text{Fubini}}{=} \int x \underbrace{\left(\int f_{X,Y}(x,y) \, d\nu_Y(y) \right)}_{f_X(x)} \, d\nu_X(x) \\&= \int x f_X(x) \, d\nu_X(x) = \mathbb{E}_X(X)\end{aligned}$$

□

Satz vom iterierten Erwartungswert III

Beispiel 12.11 (Weiterführung Bsp. 12.6))

$$\mathbb{E}(\mathbb{E}(X|Y)) = \mathbb{E}\left(\frac{1}{2} \cdot Y\right) = \frac{7}{4}$$

Varianzzerlegungssatz

Satz (Varianzzerlegungssatz)

Sei $X|Y$ eine stetige bedingte Zufallsvariable. Dann gilt:

$$\text{Var}(X) = \mathbb{E}(\text{Var}(X|Y)) + \text{Var}(\mathbb{E}(X|Y))$$

Interpretation: Fassen wir Y als “Gruppe” auf. Dann lässt sich Varianz von X in zwei Teile zerlegen:

- ▶ Mittlere Varianz von X innerhalb der Ausprägungen von Y
- ▶ Varianz von X zwischen den von Y definierten Gruppen

Beispiel I

Beispiel 12.12

Seien X und Y Zufallsvariablen mit gemeinsamer Dichte

$$f_{X,Y}(x,y) = \begin{cases} 1/x & \text{für } 0 < y \leq x < 1 \\ 0 & \text{sonst} \end{cases}$$

Beispiel II

Die Dichte der Randverteilung von X ist

$$f_X(x) = \int_0^x \frac{1}{x} dy = I_{(0,1)}(x).$$

Die Dichte der Randverteilung von Y ist

$$f_Y(y) = \int_y^1 \frac{1}{x} dx = \log\left(\frac{1}{y}\right) I_{(0,1)}(y).$$

Beispiel III

Die Dichte der bedingten Verteilung von $Y|X$ ist

$$f_{Y|X}(y|x) = \frac{1}{x} I_{(0,x)}(y).$$

Die Dichte der bedingten Verteilung von $X|Y$ ist

$$f_{X|Y}(x|y) = \frac{1/x}{\log(1/y)} I_{[y,1)}(x).$$

$$X \sim U(0,1) \implies \mathbb{E}(X) = 1/2; \text{Var}(X) = 1/12$$

Aber: $Y \sim ?$.

Beispiel IV

Wir kennen aber $Y|X \sim U(0, x)$:

$$\mathbb{E}(Y) = \mathbb{E}(\mathbb{E}(Y|X)) = \mathbb{E}\left(\frac{X}{2}\right) = \frac{1}{4}$$

$$\text{Var}(Y) = \mathbb{E}(\text{Var}(Y|X)) + \text{Var}(\mathbb{E}(Y|X)) = \frac{1}{12}\mathbb{E}(X^2) + \frac{1}{4}\text{Var}(X) = 7/144$$

$$\mathbb{E}(X \cdot Y) = \mathbb{E}(\mathbb{E}(X \cdot Y|X)) = \mathbb{E}(X\mathbb{E}(Y|X))$$

$$= \mathbb{E}\left(X \frac{X}{2}\right) = \frac{1}{2}\mathbb{E}(X^2)$$

$$= \frac{1}{2}(\text{Var}(X) + \mathbb{E}(X)^2) = \frac{1}{2}\left(\frac{1}{12} + \frac{1}{4}\right) = \frac{1}{6}$$

$$\text{Cov}(X, Y) = \frac{1}{6} - \frac{1}{2} \cdot \frac{1}{4} = \frac{1}{24}$$

Bedingte Unabhängigkeit I

Definition

Sei X , Y und Z Zufallsvariablen, so dass

$$f_{X,Y|Z}(x,y|z) = f_{X|Z}(x|z)f_{Y|Z}(y|z),$$

dann ist $X \perp Y \mid Z$: das heißt X und Y sind bedingt unabhängig gegeben Z .

Klassisches Beispiel: Anzahl der Störche und Anzahl von Geburten in einer Region ist korreliert.

Bedingte Unabhängigkeit II

Beispiel 12.13

Wir werfen drei Würfel (rot, grün und blau). Sei

- ▶ X Augensumme des roten und grünen Würfels
- ▶ Y Augensumme des roten und blauen Würfels
- ▶ Z Augenzahl des roten Würfels

Offensichtlich ist $X \perp Y \mid Z$.

Bedingte Unabhängigkeit III

Beispiel

Seien X_1 und X_2 die Ergebnisse zweier Klausuren einer Studentin. Wir nehmen an, dass ihr Ergebnis von ihrer eigentlichen Fähigkeit Z (mit unbekannter Verteilung und $\text{Var}(Z) > 0$) abhängt, aber zusätzlichen Fehler hat.

Modell: $X_i = Z + \epsilon_i$ mit $\epsilon_i \sim N(0, \sigma^2)$ für $i = 1, 2$ unabhängig, sowie Z und ϵ_i unabhängig.

Unabhängig von der Verteilung von Z gilt also: $X_i | (Z = z) \sim N(z, \sigma^2)$.

Damit ist

$$\text{Cov}(X_1, X_2) = \mathbb{E}(X_1 X_2) - \mathbb{E}(X_1) \mathbb{E}(X_2) \quad (3)$$

$$= \mathbb{E}[(Z + \epsilon_1)(Z + \epsilon_2)] - \mathbb{E}(Z + \epsilon_1) \mathbb{E}(Z + \epsilon_2) \quad (4)$$

$$= \mathbb{E}(Z^2 + Z\epsilon_1 + Z\epsilon_2 + \epsilon_1\epsilon_2) - [\mathbb{E}(Z) + \mathbb{E}(\epsilon_1)] [\mathbb{E}(Z) + \mathbb{E}(\epsilon_2)] \quad (5)$$

$$= \mathbb{E}(Z^2) - \mathbb{E}(Z)^2 + \mathbb{E}(Z\epsilon_1) - \mathbb{E}(Z)\mathbb{E}(\epsilon_1) \dots \quad (6)$$

$$= \text{Var}(Z) > 0 \quad (7)$$

Bedingte Unabhängigkeit IV

Aber

$$\text{Cov}(X_1, X_2 \mid Z = z) = \dots \quad (8)$$

$$= \mathbb{E}(z^2) - \mathbb{E}(z)^2 + \mathbb{E}(Z\epsilon_1) - \mathbb{E}(Z)\mathbb{E}(\epsilon_1) \dots \quad (9)$$

$$= z^2 - z^2 = 0 \quad (10)$$

Kapitel 13

Normalverteilung

13. Normalverteilung

13.1 Eindimensionale Normalverteilung

13.2 Multivariate Normalverteilung



Normalverteilung



13. Normalverteilung

13.1 Eindimensionale Normalverteilung

13.2 Multivariate Normalverteilung

Normalverteilung I

Definition

Sei $X : \Omega \rightarrow \mathbb{R}$ Zufallsvariable mit stetiger Dichte

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}x^2\right)$$

bzw. Verteilungsfunktion

$$F_X(x) = \int_{-\infty}^x \varphi(y) dy =: \Phi(x)$$

Dann ist $X \sim N(0, 1)$ standardnormalverteilt.

Normalverteilung II

Definition

Sei $X : \Omega \rightarrow \mathbb{R}$ Zufallsvariable mit stetiger Dichte


$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right)$$

bzw. Verteilungsfunktion

$$F(x) = \int_{-\infty}^x f(y) dy$$

Dann heit $X \sim N(\mu, \sigma^2)$ normalverteilt mit Parametern $\mu \in \mathbb{R}$ und $\sigma^2 \in \mathbb{R}^+$.

Normalverteilung III



Normalverteilung IV

Carl Friedrich Gauß (1777–1855), *Princeps mathematicorum*

Deutscher Mathematiker, Statistiker, Astronom, Geodät, Elektrotechniker und Physiker. Entwickelte im Alter von 18 Jahren die *Methode der kleinsten Quadrate*, die erste Methode zur Anpassung eines Modells an Daten (z.B. um die Bahn des Zwergplaneten Ceres zu bestimmen). Er benutzte als erstes die Normalverteilung, daher oft auch als *Gauß-Verteilung* bezeichnet (insbesondere in der Erweiterung der Gauß-Prozesse).

Außerdem begründete er die nichteuklidische Geometrie, auf ihn gehen diverse Integralsätze, mathematische Funktionen. Seine Ergebnisse wandte er neben der Astronomie insbesondere in der Landvermessung an, später arbeitete er auf dem Gebiet des Magnetismus.



Eigenschaften der Normalverteilung I

Satz (Lineare Transformation)

Sei $X \sim N(\mu, \sigma^2)$ und $Y = aX + b$ mit $a, b \in \mathbb{R}$. Dann ist $Y \sim N(a\mu + b, a^2\sigma^2)$.

Beweis:

Anwendung des Transformationssatzes für Dichten:

$$\begin{aligned} y = g(x) &= ax + b \\ g^{-1}(y) &= \frac{y - b}{a} \text{ bijektiv,} \\ \frac{\partial g^{-1}(y)}{\partial y} &= \frac{1}{a}. \end{aligned}$$

$\Rightarrow$

Eigenschaften der Normalverteilung II

$$\begin{aligned}f_Y(y) &= f_X\left(\frac{y-b}{a}\right) \cdot \frac{1}{|a|} \\&= \frac{1}{\sqrt{2\pi} \sigma |a|} \exp\left(-\frac{1}{2} \left(\frac{\frac{y-b}{a} - \mu}{\sigma}\right)^2\right) \\&= \frac{1}{\sqrt{2\pi \sigma^2 a^2}} \exp\left(-\frac{1}{2} \left(\frac{y - (a\mu + b)}{a \sigma}\right)^2\right)\end{aligned}$$

$$\implies Y \sim N(a\mu + b, a^2\sigma^2)$$



Eigenschaften der Normalverteilung III

Wegen Symmetrie der Dichte gilt $\mathbb{E}(X) = \mu$.

Nach Beispiel 10.1 gilt für $X \sim N(0, 1) \implies \text{Var}(X) = 1$. Nach 8.6 und 13.3 also für $Y \sim N(0, \sigma^2)$

$$\text{Var}(Y) = \text{Var}(\sigma X) = \sigma^2 \text{Var}(X)$$

Standardisierung

$$X \sim N(\mu, \sigma^2) \implies Y = \frac{X - \mu}{\sigma} \sim N(0, 1).$$

Unabhängigkeit I

Satz (Additivität der Normalverteilung)

Seien $X_1 \sim N(\mu_1, \sigma_1^2)$ und $X_2 \sim N(\mu_2, \sigma_2^2)$ stochastisch unabhängig. Dann gilt

$$X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2).$$

Beweis:

$$X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2) \iff \frac{X_1 + X_2 - (\mu_1 + \mu_2)}{\sqrt{\sigma_1^2 + \sigma_2^2}} \sim N(0, 1)$$

Weiterhin:

$$\frac{X_1 + X_2 - (\mu_1 + \mu_2)}{\sqrt{\sigma_1^2 + \sigma_2^2}} = \underbrace{\frac{X_1 - \mu_1}{\sqrt{\sigma_1^2 + \sigma_2^2}}}_{\tilde{X}_1} + \underbrace{\frac{X_2 - \mu_2}{\sqrt{\sigma_1^2 + \sigma_2^2}}}_{\tilde{X}_2} \sim N(0, 1)$$

Unabhängigkeit II

und

$$\widetilde{X}_1 \sim N\left(0, \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2}\right), \quad \widetilde{X}_2 \sim N\left(0, \frac{\sigma_2^2}{\sigma_1^2 + \sigma_2^2}\right).$$

Sei $\lambda^2 := \frac{\sigma_1^2}{\sigma_1^2 + \sigma_2^2}$. Es reicht also zu zeigen:

$$\widetilde{X}_1 \sim N(0, \lambda^2), \widetilde{X}_2 \sim N(0, 1 - \lambda^2) \text{ stochastisch unabhängig} \implies \widetilde{X}_1 + \widetilde{X}_2 \sim N(0, 1),$$

was wir bereits in Satz 11.16 bewiesen haben.



Unabhängigkeit III

Satz

Seien $X_1, \dots, X_n$ stochastisch unabhängig mit $X_i \sim N(\mu_i, \sigma_i^2)$ für $i = 1, \dots, n$.
Dann gilt

- i) $\sum_{i=1}^n X_i \sim N(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2)$
- ii) Für $\mu_1 = \dots = \mu_n =: \mu, \sigma_1^2 = \dots = \sigma_n^2 =: \sigma^2$ gilt

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Beweis:, Durch induktive Anwendung von Satz 13.4

Unabhängigkeit IV

Satz (von Cramér)

Sind X und Y stochastisch unabhängig und $X + Y$ ist normalverteilt mit $\mathbb{E}(X + Y) = \mu$ und $\text{Var}(X + Y) = \sigma^2 > 0$, so sind auch X und Y normalverteilt.

Beweis:

Wir nehmen an, dass X , Y und $X + Y$ momenterzeugende Funktionen haben (sonst Beweisführung über charakteristische Funktionen). Nach Beispiel 10.1 ist die momenterzeugende Funktion von $N(0,1)$ $M = \exp\left(\frac{t^2}{2}\right)$. Mit 10.7 ist die momenterzeugende Funktion von $X + Y \sim N(\mu, \sigma^2)$

$$M_{X+Y}(s) = \exp(\mu s) M(\sigma^2 s) = \exp\left(\mu s + \frac{\sigma^2 s^2}{2}\right)$$

Nach Satz 10.8 gilt wegen Unabhängigkeit

$$M_{X+Y} = M_X \cdot M_Y$$

Unabhängigkeit V

Betrachte nun den Logarithmus

$$\log(M_X(s)) + \log(M_Y(s)) = \mu s + \frac{1}{2}\sigma^2 s^2.$$

Setze $K_X(s) := \log M_X(s)$ und $K_Y(s) := \log M_Y(s)$ und entwickle in Taylorreihen (vgl. Beweis zu Satz 10.2):

$$K_X(s) = a_1 s + \frac{a_2}{2} s^2 + \frac{a_3}{6} s^3 + \dots, \quad (11)$$

$$K_Y(s) = b_1 s + \frac{b_2}{2} s^2 + \frac{b_3}{6} s^3 + \dots. \quad (12)$$

Vergleich der Koeffizienten liefert $a_1 + b_1 = \mu$, $a_2 + b_2 = \sigma^2$ und

Unabhängigkeit VI

$$a_r + b_r = 0 \quad \text{für alle } r \geq 3.$$

Da eine Verteilung genau dann normalverteilt ist, wenn $K(s) = \log(M(s))$ ein Polynom zweiten Grades ist (äquivalent: alle Koeffizienten ab Ordnung 3 verschwinden), folgt, dass auch X und Y normalverteilt sind.



13. Normalverteilung

13.1 Eindimensionale Normalverteilung

13.2 Multivariate Normalverteilung

Multivariate Standardnormalverteilung I

Definition (k -dimensionale Normalverteilung)

Sei $\mathbf{X} : \Omega \rightarrow \mathbb{R}^k$. $\mathbf{X} = (X_1, \dots, X_k)$ heißt k -dimensional (multivariat) standardnormalverteilt, wenn $\mathbf{X}$ eine stetige Verteilung mit Dichte

$$f_{\mathbf{X}}(x) = \left(\frac{1}{\sqrt{2\pi}} \right)^k \exp \left(-\frac{1}{2} \sum_{i=1}^k x_i^2 \right)$$

besitzt: $\mathbf{X} \sim N_k(0, I_k)$.

► Für $k = 1$ ergibt sich die eindimensionale Standardnormalverteilung.

Multivariate Standardnormalverteilung II

Satz

$$\mathbf{X} \sim N_k(0, I_k) \quad \Longleftrightarrow$$

$X_i \sim N(0, 1) \quad \forall i = 1, \dots, k$ und $X_1, \dots, X_k$ stochastisch unabhängig.

Multivariate Standardnormalverteilung III

Beweis:

$$\begin{aligned}f_{\mathbf{X}}(\mathbf{x}) &= \prod_{i=1}^k f_{X_i}(x_i) \quad (X_i \text{ stochastisch unabhängig}) \\&= \prod_{i=1}^k \varphi(x_i) \quad (X_i \sim N(0, 1)) \\&= \left(\frac{1}{\sqrt{2\pi}} \right)^k \exp \left(-\frac{1}{2} \sum_{i=1}^k x_i^2 \right)\end{aligned}$$

□

► In Matrixschreibweise ist die Dichte:

$$f_{\mathbf{X}}(\mathbf{x}) = (2\pi)^{-k/2} \exp \left(-\frac{1}{2} \mathbf{x}^\top \mathbf{x} \right)$$

Multivariate Normalverteilung I

Definition

Sei $\mathbf{X} \sim N_k(0, I_k)$ und $\mathbf{A} \in \mathbb{R}^{p \times k}$ sowie $\boldsymbol{\mu} \in \mathbb{R}^p$. Dann heit

$$\mathbf{Y} = \mathbf{A}\mathbf{X} + \boldsymbol{\mu}$$

p -dimensional normalverteilt:

$$\mathbf{Y} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \quad \text{mit } \boldsymbol{\Sigma} = \mathbf{A}\mathbf{A}^\top.$$

- In der Regel nimmt man $p = k$.
- $\boldsymbol{\Sigma} = \mathbf{A}\mathbf{A}^\top$ ist positiv semidefinit.

Multivariate Normalverteilung II

Satz

Sei $\mathbf{Y} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Dann ist

- ▶ $\mathbb{E}(\mathbf{Y}) = \boldsymbol{\mu}$
- ▶ $\text{Cov}(\mathbf{Y}) = \boldsymbol{\Sigma}$

Beweis:

Siehe Satz 12.13:

$$\begin{aligned}\mathbb{E}(\mathbf{A}\mathbf{X} + \boldsymbol{\mu}) &= \mathbf{A}\mathbb{E}(\mathbf{X}) + \boldsymbol{\mu} = \mathbf{A}\mathbf{0} + \boldsymbol{\mu} = \boldsymbol{\mu} \\ \text{Cov}(\mathbf{A}\mathbf{X} + \boldsymbol{\mu}) &= \mathbf{A}\text{Cov}(\mathbf{X})\mathbf{A}^\top = \mathbf{A}\mathbf{A}^\top\end{aligned}$$



Multivariate Normalverteilung III

Satz

Wenn $\mathbf{A} \in \mathbb{R}^{k \times k}$ invertierbar, dann hat $\mathbf{Y} \sim N_k(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ die Dichte $f_{\mathbf{Y}} : \mathbb{R}^k \rightarrow \mathbb{R}$

$$f_{\mathbf{Y}}(\mathbf{y}) = (2\pi)^{-k/2} \det(\boldsymbol{\Sigma})^{-1/2} \exp\left(-\frac{1}{2}(\mathbf{y} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{y} - \boldsymbol{\mu})\right)$$

mit $\boldsymbol{\Sigma} = \mathbf{A}\mathbf{A}^\top$.

Beweis Da $\mathbf{A}$ invertierbar, ist $\mathbf{A}\mathbf{A}^\top$ positiv definit und damit $\boldsymbol{\Sigma}$ invertierbar. Es gilt:

$$\mathbf{A}^{-1\top} \mathbf{A}^{-1} = (\mathbf{A}\mathbf{A}^\top)^{-1} = \boldsymbol{\Sigma}^{-1}$$

$$0 \stackrel{\text{psd}}{\leq} \det(\boldsymbol{\Sigma}) = \det(\mathbf{A}\mathbf{A}^\top) = \det(\mathbf{A})^2$$

Multivariate Normalverteilung IV

Mit Dichtetransformationssatz (Satz 11.15) gilt für $Y = A\mathbf{X} + \boldsymbol{\mu}$

$$f_Y(y) = f_X(A^{-1}(\mathbf{y} - \boldsymbol{\mu})) \cdot |\det(\mathbf{A})|^{-1}$$

Also:

$$\begin{aligned} f_X(\mathbf{x}) &= \frac{1}{\sqrt{(2\pi)^k}} \exp\left(-\frac{1}{2}\mathbf{x}^\top \mathbf{x}\right) \\ f_Y(y) &= f_X(\mathbf{A}^{-1}(\mathbf{y} - \boldsymbol{\mu})) \cdot |\det(\mathbf{A})|^{-1} \\ &= \frac{|\det(\mathbf{A})|^{-1}}{\sqrt{(2\pi)^k}} \exp\left(-\frac{1}{2}(\mathbf{y} - \boldsymbol{\mu})^\top \mathbf{A}^{-1\top} \mathbf{A}^{-1}(\mathbf{y} - \boldsymbol{\mu})\right) \\ &= \frac{1}{\sqrt{(2\pi)^k \det(\boldsymbol{\Sigma})}} \exp\left(-\frac{(\mathbf{y} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{y} - \boldsymbol{\mu})}{2}\right). \end{aligned}$$



Degenerierter Fall I

- ▶ Ist $\Sigma = \mathbf{A}\mathbf{A}^\top$ nicht invertierbar (mit Rang $p < k$), hat $\mathbf{Y} = \mathbf{A}\mathbf{X} + \boldsymbol{\mu}$ keine Dichte bezüglich λ^k .
- ▶ Es lässt sich allerdings eine Restriktion des Lebesgue-Maßes auf einen p -dimensionalen Unterraum von $\mathbb{R}^k$ konstruieren.
- ▶ Dann hat $\mathbf{Y}$ die Dichte

$$f(\mathbf{x}) = (2\pi)^{-\frac{p}{2}} (\det^*(\Sigma))^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^+(\mathbf{x} - \boldsymbol{\mu})\right)$$

mit

- ▶ Σ^+ eine verallgemeinerte Inverse (z.B. Moore–Penrose),
- ▶ $\det^*$ die verallgemeinerte Determinante (Produkt der Eigenwerte ungleich Null).

Degenerierter Fall II

Ist q der Rang von Σ . Dann gibt es eine $(q \times p)$ -Matrix $\mathbf{B}$ mit

$$\mathbf{B}\mathbf{Y} \sim N_q(\mathbf{B}\boldsymbol{\mu}, \mathbf{B}\Sigma\mathbf{B}^\top)$$

Beispiel

$$\mathbf{X} \sim N_2\left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}\right)$$

- ▶ Eigenwerte von Σ : 1 und 0
- ▶ Pseudoinverse $\Sigma^+ = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$

Degenerierter Fall III

$$f(x) = \frac{1}{2\pi} \exp\left(-\frac{1}{2}(x_1 - \mu_1)^2\right)$$

ist keine Dichte bezüglich λ^2 .

- ▶ Marginale Verteilung von $X_1 \sim N(\mu_1, 1)$
- ▶ $\mathbf{1}^\top \mathbf{X} \sim N(\mu_1 + \mu_2, 1)$
- ▶ X_2 hat uneigentliche Verteilung (engl. improper distribution):
„ $f_{X_2}(x_2) \propto \text{const.}$ “ ist keine Dichte bezüglich λ .

Kanonische Form der Normalverteilung

Definition (Kanonische Form der mehrdimensionalen Normalverteilung)

Sei $\mathbf{X} \sim N_k(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Dann heißen $\mathbf{Q} = \boldsymbol{\Sigma}^{-1}$ und $\mathbf{m} = \boldsymbol{\Sigma}^{-1}\boldsymbol{\mu}$ die kanonischen Parameter der Normalverteilung. Die Dichte läßt sich schreiben als

$$f(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^k}} \det(\mathbf{Q})^{1/2} \exp \left(-\frac{1}{2} (\mathbf{x}^\top \mathbf{Q} \mathbf{x} - 2\mathbf{x}^\top \mathbf{m} + \mathbf{m}^\top \mathbf{Q}^{-1} \mathbf{m}) \right).$$

Lineare Transformation

Satz

Ist $\mathbf{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, dann ist $\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$:

$$\mathbf{Y} \sim N(\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top)$$

Beweis wie bei Satz 13.11.

Marginale Verteilung I

Satz

Ist $\mathbf{X} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, dann ist für alle i die marginale Verteilung $X_i \sim N(\mu_i, \sigma_i^2)$ mit $\sigma_i^2 = \Sigma_{ii}$.

Beweis:

Setze $\mathbf{A}_i = (0, \dots, 0, \underbrace{1}_{i\text{-te Stelle}}, 0, \dots, 0)$. Dann ist $\mathbf{A}_i \mathbf{X} = X_i$, $\mathbf{A}_i \boldsymbol{\mu} = \mu_i$ und

$$\mathbf{A}_i \boldsymbol{\Sigma} \mathbf{A}_i^\top = \Sigma_{ii}.$$



Marginale Verteilung II

Sei im Folgenden $\mathbf{X} = \begin{pmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{pmatrix}$ mit $\mathbf{X} : \Omega \rightarrow \mathbb{R}^k$, $\mathbf{X}_1 : \Omega \rightarrow \mathbb{R}^{k_1}$, $\mathbf{X}_2 : \Omega \rightarrow \mathbb{R}^{k_2}$ und $k = k_1 + k_2$. Ist $\mathbf{X} \sim N_k(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, dann lassen sich Erwartungswertvektor und Kovarianzmatrix zerlegen:

$$\begin{pmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{pmatrix} \sim N_k \left(\begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{pmatrix}, \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix} \right)$$

mit $\boldsymbol{\Sigma}_{12} = \boldsymbol{\Sigma}_{21}^\top$. Wie in Satz 13.14 lässt sich zeigen:

- ▶ $\mathbf{X}_1 \sim N_{k_1}(\boldsymbol{\mu}_1, \boldsymbol{\Sigma}_{11})$,
- ▶ $\mathbf{X}_2 \sim N_{k_2}(\boldsymbol{\mu}_2, \boldsymbol{\Sigma}_{22})$,
- ▶ $\text{Cov}(\mathbf{X}_1, \mathbf{X}_2) = \boldsymbol{\Sigma}_{12}$.

Marginale Verteilung III

Beispiel 13.1

Sei

$$\mathbf{X} \sim N_3 \left(\begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} 1 & 0 & 0.5 \\ 0 & 1.5 & 1 \\ 0.5 & 1 & 2 \end{pmatrix} \right)$$

Dann ist

$$\mathbf{X}^* := \begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N_2 \left(\begin{pmatrix} 1 \\ 2 \end{pmatrix}, \begin{pmatrix} 1 & 0 \\ 0 & 1.5 \end{pmatrix} \right)$$

Bedingte Verteilung I

Satz

Sei

$$\begin{pmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{pmatrix} \sim N_k \left(\begin{pmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{pmatrix}, \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix} \right)$$

Dann gilt:

$$\mathbf{X}_1 \mid \mathbf{X}_2 \sim N_{p_1} \left(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} (\mathbf{X}_2 - \boldsymbol{\mu}_2), \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21} \right)$$

Bedingte Verteilung II

Beispiel 13.2

Sei

$$\mathbf{X} \sim N_3 \left(\begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \begin{pmatrix} 1 & 0 & 0.5 \\ 0 & 1.5 & 1 \\ 0.5 & 1 & 2 \end{pmatrix} \right)$$

$$\mathbf{E}(X_1|X_2, X_3) = 1 + (0, 0.5) \begin{pmatrix} 1.5 & 1 \\ 1 & 2 \end{pmatrix}^{-1} \begin{pmatrix} x_2 - 2 \\ x_3 - 3 \end{pmatrix} = \frac{3}{8} - \frac{x_2}{4} + \frac{3x_3}{8}$$

$$\mathbf{V}(X_1|X_2, X_3) = 1 - (0, 0.5) \begin{pmatrix} 1.5 & 1 \\ 1 & 2 \end{pmatrix}^{-1} \begin{pmatrix} 0 \\ 0.5 \end{pmatrix} = \frac{13}{16}$$

Bedingte Verteilung III

$$\mathbf{E}(X_1, X_2|X_3) = \begin{pmatrix} 1 \\ 2 \end{pmatrix} + \begin{pmatrix} 0.5 \\ 1 \end{pmatrix} \frac{1}{2}(x_3 - 3) = \begin{pmatrix} \frac{1}{4} + \frac{x_3}{4} \\ \frac{1}{2} + \frac{x_3}{2} \end{pmatrix}$$

$$\mathbf{V}(X_1, X_2|X_3) = \begin{pmatrix} 1 & 0 \\ 0 & 1.5 \end{pmatrix} - \begin{pmatrix} 0.5 \\ 1 \end{pmatrix} \frac{1}{2}(0.5, 1) = \begin{pmatrix} 7/8 & -1/4 \\ -1/4 & 1 \end{pmatrix}$$

Bedingte Verteilung IV

Marginale und bedingte Verteilungen der multivariaten Normalverteilung

Alle marginalen und bedingten Verteilungen der multivariaten Normalverteilung sind wieder Normalverteilungen.

Vorsicht: Die Umkehrung gilt nicht unbedingt!

Bedingte Verteilung V

Gegenbeispiel

- ▶ $X_1|X_2 \sim N(\alpha_0 + \alpha_1 X_2, \sigma_1^2),$
- ▶ $X_2|X_1 \sim N(\beta_0 + \beta_1 X_1^3, \sigma_2^2).$

$\Rightarrow$

$$\begin{aligned}\mathbb{E}(X_1) &= \mathbb{E}(\mathbb{E}(X_1|X_2)) = \mathbb{E}(\alpha_0 + \alpha_1 X_2) = \alpha_0 + \alpha_1 \mathbb{E}(X_2) \\ \mathbb{E}(X_2) &= \mathbb{E}(\mathbb{E}(X_2|X_1)) = \mathbb{E}(\beta_0 + \beta_1 X_1^3) = \beta_0 + \beta_1 \mathbb{E}(X_1^3)\end{aligned}$$

Nicht konsistent (außer im trivialen Fall $\alpha_1 = \beta_1 = 0$)!