

Teil IV: Konvergenz

Fragen

- ▶ Was konvergiert eigentlich bei Zufallsvariablen bzw. Verteilungen?
- ▶ Welche Voraussetzungen haben Grenzwertsätze?

Kapitel 14

Konvergenz von Zufallsvariablen

14. Konvergenz von Zufallsvariablen

14.1 Konvergenzarten

14.2 Gesetze der großen Zahlen



Ziel


Wir betrachten im Folgenden Folgen von Zufallsvariablen (von meßbaren Abbildungen)

$$X_1, X_2, \dots, X_n : \Omega \rightarrow \mathbb{R}$$

- ▶ Was passiert für $n \rightarrow \infty$?
- ▶ Was bedeutet Konvergenz für Zufallsvariablen bzw. Verteilungen?
- ▶ Welche Arten von Konvergenzsätzen gibt es für Zufallsvariablen und welche Folgerungen?


Beispiele I

```
x <- rnorm(1000, 0, 1)
plot(cumsum(x)/1:1000, type = "s", ylab = "Mittelwert")
```




Beispiele II

```
y <- rt(1000, 2)
plot(cumsum(y)/1:1000, type = "s", ylab = "Mittelwert")
```




Beispiele III

```
plot(ecdf(x), main = "Empirische Verteilungsfunktion")  
lines(seq(-5, 5, length = 1000), pnorm(seq(-5, 5, length = 1000))), col = "blue", lty = 2)
```




Beispiele IV

```
plot(ecdf(y), main = "Empirische Verteilungsfunktion", xlim = c(-10, 10))  
lines(seq(-5, 5, length = 1000), pt(seq(-5, 5, length = 1000), 2), col = "blue", lty = 2)
```




Beispiele V

```
rxquer <- function(i) return(mean(rnorm(1000)))  
xquer <- sapply(1:1000, rxquer)  
hist(xquer, breaks = 10, freq = FALSE)
```



Beispiele VI


```
rxquer <- function(i) return(mean(rt(1000, 2)))  
xquer <- sapply(1:1000, rxquer)  
hist(xquer, breaks = 20, freq = FALSE)
```



Beispiele VII

```
z <- vector(length = 5000)
z[1] <- rnorm(1)
for (i in 2:5000) z[i] <- rnorm(1, 0.5 * z[i - 1])
plot(cumsum(z)/(1:5000), type = "s", ylab = "Mittelwert")
```

Beispiele VIII



14. Konvergenz von Zufallsvariablen

14.1 Konvergenzarten

14.2 Gesetze der großen Zahlen

Konvergenzarten I

Aus der Analysis kennen wir

Definition

Sei (f_n) eine Funktionenfolge, $f_n : M \longrightarrow \mathbb{R}$, $\emptyset \neq M \subseteq \mathbb{R}$.

a) (f_n) konvergiert punktweise gegen $f : M \longrightarrow \mathbb{R}$ g.d.w.

$$\forall_{z \in M} \overline{\lim_{n \rightarrow \infty} f_n(z) = f(z)}, \text{ also genau dann wenn}$$

$$\forall_{z \in M} \forall_{\varepsilon \in \mathbb{R}^+} \exists_{N \in \mathbb{N}} \forall_{n > N} |f_n(z) - f(z)| < \varepsilon$$

N hängt im Allgemeinen von z und ε ab.

b) (f_n) konvergiert gleichmäßig gegen $f : M \longrightarrow \mathbb{K}$ genau dann wenn

$$\forall_{\varepsilon \in \mathbb{R}^+} \exists_{N \in \mathbb{N}} \forall_{n > N} \forall_{z \in M} |f_n(z) - f(z)| < \varepsilon$$

N hängt nicht von z ab, aber im Allgemeinen immer noch von $\varepsilon \rightarrow$
Konvergenz ist gleichmäßig in z .

Konvergenzarten II

Aus gleichmäßiger folgt punktweise Konvergenz, aber nicht umgekehrt.

Konvergenzarten III

Beispiel 14.1

$$\begin{aligned}f_n &: [0, 1] \rightarrow \mathbb{R} \\f_n(x) &:= x^n \\f(x) &:= \begin{cases} 0 & \text{für } 0 \leq x < 1 \\ 1 & \text{für } x = 1 \end{cases}\end{aligned}$$

Es gilt: $f_n(x)$ konvergiert punktweise gegen $f(x)$, aber nicht gleichmäßig.

Für Zufallsvariablen ist sogar punktweise Konvergenz unter Umständen zu “stark”. Insbesondere interessieren uns Fälle mit Wahrscheinlichkeit 0 nicht.

- ▶ Wir definieren vier Arten von Konvergenz für Zufallsvariablen
 - ▶ Fast sichere Konvergenz
 - ▶ Konvergenz in Erwartung
 - ▶ Konvergenz in Wahrscheinlichkeit
 - ▶ Konvergenz in Verteilung (genauer im übernächsten Kapitel)

Fast sichere Konvergenz I

Idee:

- ▶ Wir betrachten eigentlich *punktweise Konvergenz* von $X_n(\omega) \rightarrow X(\omega)$
- ▶ Aber “unmögliche” Ergebnisse interessieren uns nicht
- ▶ Sei also das Ereignis A : “Menge auf der X_n nicht gegen X konvergiert” eine $\mathbb{P}$ -Nullmenge.
- ▶ Die Aussage “ X_n konvergiert punktweise gegen X ” gilt also *fast überall*.

Definition

Sei $(\Omega, \mathcal{F}, \mathbb{P})$ Wahrscheinlichkeitsraum und $X_i : \Omega \rightarrow \mathbb{R}$ ZV, $i = 1, 2, \dots$

Dann konvergiert die Folge $(X_n)_{n \in \mathbb{N}}$ fast sicher (engl. *convergence almost surely*) gegen $X : \Omega \rightarrow \mathbb{R}$, wenn

$$\mathbb{P} \left(\left\{ \omega \in \Omega \mid \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega) \right\} \right) = 1;$$

Wir schreiben $X_n \xrightarrow{\text{f.s.}} X$ oder $X_n \rightarrow X$ mit Wahrscheinlichkeit 1.

Fast sichere Konvergenz II

Beispiel 14.2

Sei $X_1 \sim U[0, 1]$ und $X_n := X_1^n$. Dann gilt $X_n \xrightarrow{\text{f.s.}} 0$.

Beweis: Sei o.b.d.A. $([0, 1], \mathcal{B}_{[0,1]}, U[0, 1])$ und $X_1(\omega) = \omega$. Dann gilt für jedes $0 \leq \omega < 1$: $\lim_{n \rightarrow \infty} \omega^n = 0$. Für $\omega = 1$ gilt $\omega^n = 1^n = 1$. Damit ist

$A := \{\omega \in \Omega \mid X(\omega)^n \not\rightarrow 0\} = \{1\}$, eine Nullmenge bezüglich der stetigen Gleichverteilung.

- ▶ Im Beispiel konvergiert die Folge von Zufallsvariablen gegen einen Skalar (in der Praxis meistens der Fall).
- ▶ Wir können dies auch als Konvergenz gegen eine Zufallsvariable mit *Dirac-Verteilung* in diesem Skalar sehen.

Konvergenz in Wahrscheinlichkeit I

Idee:

Bei gleichmäßiger Konvergenz betrachten wir den Abstand der Folgenglieder von der Funktion, gegen die die Folge konvergiert:

$$\forall \varepsilon > 0 \exists N, \text{ so dass } \forall n \geq N : |f_n(x) - f(x)| < \varepsilon$$

- ▶ Für Zufallsvariablen reicht, dass dieser Abstand mit Wahrscheinlichkeit 1 kleiner als ε ist.
- ▶ Wir betrachten hier also das Ereignis $A_n = \{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \varepsilon\}$, also dass X_n von X um mehr als ε abweicht.
- ▶ Für beliebige kleine $\varepsilon > 0$ konvergiere $\mathbb{P}(A_n)$ gegen Null:

Konvergenz in Wahrscheinlichkeit II

Definition

Sei $(\Omega, \mathcal{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und $X_i : \Omega \rightarrow \mathbb{R}$, $i = 1, 2, \dots$

Dann konvergiert die Folge $(X_n)_{n \in \mathbb{N}}$ in Wahrscheinlichkeit (engl. *convergence in probability*) gegen $X : \Omega \rightarrow \mathbb{R}$, falls

$$\mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0 \quad \text{für } n \rightarrow \infty \quad \forall \varepsilon > 0;$$

Wir schreiben $X_n \xrightarrow{\mathbb{P}} X$ und sprechen auch von stochastischer Konvergenz.

Beispiel 14.3

Wie oben $X_1 \sim U[0, 1]$ und $X_n := X_1^n$. Dann gilt $X_n \xrightarrow{\mathbb{P}} 0$.

Sei o.b.d.A. $([0, 1], \mathcal{B}_{[0,1]}, U[0, 1])$ und $X(\omega) = \omega$. Dann gilt

$$\mathbb{P}(|X_n - 0| > \varepsilon) = \mathbb{P}(X_1^n > \varepsilon) = \mathbb{P}(X_1 > \varepsilon^{1/n}) = 1 - \varepsilon^{1/n} \xrightarrow{n \rightarrow \infty} 0$$

Konvergenz in Wahrscheinlichkeit III

Es ist kein Zufall, dass hier beide Konvergenzarten gelten:

Satz

Sei $(X_n)_{n \in \mathbb{N}}$, Folge von Zufallsvariablen $X_i : \Omega \rightarrow \mathbb{R}$ und $X : \Omega \rightarrow \mathbb{R}$. Dann gilt

$$X_n \xrightarrow{f.s.} X \implies X_n \xrightarrow{\mathbb{P}} X$$

Konvergenz in Wahrscheinlichkeit IV

Beweis:

Sei $C = \{\omega \in \Omega \mid X_n(\omega) \not\rightarrow X(\omega)\}$. Nach Def. $X_n \xrightarrow{\text{f.s.}} X \iff \mathbb{P}(C) = 0$.

Sei $B_n = \bigcup_{m \geq n} \{\omega \in \Omega : |X_m(\omega) - X(\omega)| > \varepsilon\}$ für beliebiges $\varepsilon > 0$. Die Folge B_n ist monoton absteigend: $B_n \supseteq B_{n+1} \supseteq \dots$, und es gilt für

$$B = \bigcap_{n \geq 1} B_n : \quad B_n \downarrow B,$$

also auch $\lim_{n \rightarrow \infty} \mathbb{P}(B_n) = \mathbb{P}(B)$.

Konvergenz in Wahrscheinlichkeit V

Zeige zunächst dass $\mathbb{P}(B) = 0$:

$$\begin{aligned} & \forall \omega \in \bar{C} : X_n(\omega) \rightarrow X(\omega) \\ \implies & \forall \omega \in \bar{C} : \exists n : |X_m(\omega) - X(\omega)| < \varepsilon \quad \forall m \geq n \\ \implies & \forall \omega \in \bar{C} : \exists n : \omega \notin B_m \quad \forall m \geq n \\ \implies & \forall \omega \in \bar{C} : \omega \notin B \\ \implies & B \cap \bar{C} = \emptyset \implies B \subseteq C \implies P(B) \leq P(C) = 0 \end{aligned}$$

Da $\{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \varepsilon\} \subseteq B_n$ und $\lim_{n \rightarrow \infty} \mathbb{P}(B_n) = \mathbb{P}(B) = 0$:

$$\mathbb{P}(|X_n - X| > \varepsilon) \leq \mathbb{P}(B_n) \rightarrow 0 \implies X_n \xrightarrow{\mathbb{P}} X.$$

□

- ▶ Die Umkehrung gilt aber nicht!
- ▶ Die fast sichere Konvergenz ist also **stärker** als die Konvergenz in Wahrscheinlichkeit

Konvergenz in Wahrscheinlichkeit VI

Beispiel 14.4

Wahrscheinlichkeitsraum $([0, 1], \mathcal{B}_{[0,1]}, U[0, 1])$, $X(\omega) = \omega$. Seien $m \geq 0$, $0 \leq k \leq 2^m - 1$ und $n = 2^m + k$. Sei weiter $A_n = [k2^{-m}, (k+1)2^{-m})$ und $X_n(\omega) = 1_{A_n}(\omega)$.

Dann gilt für $0 < \varepsilon < 1$: $\mathbb{P}[|X_n| > \varepsilon] = 2^{-m}$

Für $n \rightarrow \infty \Rightarrow m \rightarrow \infty \Rightarrow 2^{-m} \rightarrow 0$, also $X_n \xrightarrow{\mathbb{P}} 0$.

Aber X_n konvergiert nicht fast sicher, denn für jedes $\omega \in [0, 1]$ konvergiert $X_n(\omega)$ nicht.

Konvergenz im Moment I

Idee:

- ▶ Wir betrachten wieder den Abstand der Folgenglieder von der Zufallsvariablen, gegen die die Konvergenz erfolgt: $|X_n - X|$
- ▶ Dabei handelt es sich um eine Zufallsvariable.
- ▶ Der Abstand muss nicht gegen Null konvergieren, aber zumindest im Erwartungswert sollte er gegen Null konvergieren:

Definition

Sei $(\Omega, \mathcal{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und $X_i : \Omega \rightarrow \mathbb{R}$, $i = 1, 2, \dots$

Dann konvergiert die Folge $(X_n)_{n \in \mathbb{N}}$ im r -ten Moment (engl. **convergence in the r -th moment**) oder im r -ten Mittel, $r \geq 1$, gegen $X : \Omega \rightarrow \mathbb{R}$, wenn $\mathbb{E}(|X_n|^r) < \infty \forall n$, $\mathbb{E}(|X|^r) < \infty$ und

$$\mathbb{E}(|X_n - X|^r) \rightarrow 0 \quad \text{für } n \rightarrow \infty;$$

Wir schreiben $X_n \xrightarrow{r} X$ oder $X_n \xrightarrow{\mathcal{L}^r} X$

Konvergenz im Moment II

Beispiel 14.5

Sei $r > s \geq 1$ und

$$X_n = \begin{cases} n & \text{mit Wahrscheinlichkeit } n^{-\frac{1}{2}(r+s)} \\ 0 & \text{mit Wahrscheinlichkeit } 1 - n^{-\frac{1}{2}(r+s)} \end{cases}$$

Es gilt

$$\mathbb{E}(|X_n|^s) = n^s \cdot n^{-\frac{1}{2}(r+s)} = n^{\frac{1}{2}(s-r)} \rightarrow 0,$$

da $s < r$, also $X_n \xrightarrow{s} 0$.

Es gilt weiterhin

$$\mathbb{E}(|X_n|^r) = n^r \cdot n^{-\frac{1}{2}(r+s)} = n^{\frac{1}{2}(r-s)} \rightarrow \infty,$$

da $r > s$.

Konvergenz im Moment III

Satz

Sei $(X_n)_{n \in \mathbb{N}}$ eine Folge von Zufallsvariablen $X_i : \Omega \rightarrow \mathbb{R}$ und $X : \Omega \rightarrow \mathbb{R}$. Dann gilt

$$\forall r > s \geq 1 : X_n \xrightarrow{r} X \implies X_n \xrightarrow{s} X$$

Konvergenz im Moment IV

Beweis:

Voraussetzung ist:

$$\mathbb{E}(|X_n - X|^r) = \|X_n - X\|_r^r \rightarrow 0.$$

Nach Satz 8.19 gilt für $r > s \geq 1$ mit $c \geq 0$:

$$\|X_n - X\|_r^r \geq c \|X_n - X\|_s^s.$$

Da $\|X_n - X\|_s^s \geq 0$ und die linke Seite gegen Null geht, muss auch die rechte Seite gegen Null gehen. □

Konvergenz im Moment V

Vielleicht etwas überraschend ist die Konvergenz im Moment stärker als die Konvergenz in Wahrscheinlichkeit:

Satz

Sei $(X_n)_{n \in \mathbb{N}}$ eine Folge von Zufallsvariablen $X_i : \Omega \rightarrow \mathbb{R}$ und $X : \Omega \rightarrow \mathbb{R}$. Dann gilt für $r \geq 1$:

$$X_n \xrightarrow{r} X \implies X_n \xrightarrow{\mathbb{P}} X$$

Beweis:

Wegen Satz 14.6 reicht es, $r = 1$ zu nehmen. Dann gilt

$$\mathbb{P}(|X_n - X| > \varepsilon) \leq \frac{\mathbb{E}(|X_n - X|)}{\varepsilon},$$

in dem wir in die Markov-Ungleichung $(X_n - X)$ einsetzen. □

Zusammenhänge im Überblick I

- ▶ Fast sichere Konvergenz $\implies$ Konvergenz in Wahrscheinlichkeit
- ▶ Konvergenz im Moment $\implies$ Konvergenz in Wahrscheinlichkeit
- ▶ Für $r > s$: Konvergenz im r -ten Moment $\implies$ Konvergenz im s -ten Moment

Satz

Konvergiert eine Folge von Zufallsvariablen X_n im r -ten Mittel gegen X und gilt

$$\sum_{n=1}^{\infty} \mathbb{E}(|X_n - X|^r) < \infty$$

dann konvergiert die Folge auch fast sicher gegen X .

Zusammenhänge im Überblick II

Beweis:

Für jedes $\varepsilon > 0$ gilt nach der Markov-Ungleichung Satz 8.13

$$P(|X_n - X| > \varepsilon) \leq \frac{E(|X_n - X|^r)}{\varepsilon^r}$$

Ist nun

$$\sum_{n=1}^{\infty} E(|X_n - X|^r) < \infty,$$

so folgt

$$\sum_{n=1}^{\infty} P(|X_n - X| > \varepsilon) < \infty.$$

Nach dem Borel–Cantelli-Lemma tritt das Ereignis

$$|X_n - X| > \varepsilon$$

Zusammenhänge im Überblick III

nur endlich oft auf (fast sicher). Da dies für jedes $\varepsilon > 0$ gilt, folgt $X_n \xrightarrow{\text{f.s.}} X$. $\square$

Satz (Borel–Cantelli-Lemma I)

Sei $(A_n)_{n \in \mathbb{N}}$ eine Folge von Ereignissen in einem Wahrscheinlichkeitsraum. Es gilt

$$\sum_{n=1}^{\infty} P(A_n) < \infty \implies P(A_n \text{ tritt unendlich oft auf}) = 0$$

Beweis:

„Unendlich oft“ bedeutet

$$A_n \text{ „unendlich oft“} = \bigcap_{k=1}^{\infty} \bigcup_{n \geq k} A_n =: \limsup_{n \rightarrow \infty} A_n$$

Für jedes feste k gilt wegen der σ -Subadditivität (Satz 3.28):

Zusammenhänge im Überblick IV

$$P\left(\bigcup_{n \geq k} A_n\right) \leq \sum_{n \geq k} P(A_n).$$

Da die Reihe $\sum_{n=1}^{\infty} P(A_n)$ konvergiert, gilt

$$\sum_{n \geq k} P(A_n) \longrightarrow 0 \quad (k \rightarrow \infty).$$

Somit folgt

$$P\left(\bigcup_{n \geq k} A_n\right) \longrightarrow 0.$$

Auf Grund der Stetigkeit des Wahrscheinlichkeitsmaßes erhalten wir

Zusammenhänge im Überblick V

$$P(A_n \text{ „unendlich oft“}) = \lim_{k \rightarrow \infty} P\left(\bigcup_{n \geq k} A_n\right) = 0.$$



14. Konvergenz von Zufallsvariablen

14.1 Konvergenzarten

14.2 Gesetze der großen Zahlen

Unabhängig und identisch verteilt I

Definition

Eine Familie von Zufallsvariablen $X_i : \Omega \rightarrow \Omega_i, i \in I$ heißt unabhängig und identisch verteilt (u.i.v.), wenn die beiden folgenden Kriterien erfüllt sind:

- ▶ Die Familie $X_i : \Omega \rightarrow \Omega_i, i \in I$ ist stochastisch unabhängig, siehe Def. 4.20
 - ▶ Die Zufallsvariablen haben alle dieselbe Verteilung $X_i \sim F$.
-
- ▶ In der Regel benutzt man die Abkürzung des englischen Ausdruck *independent and identically distributed*, i.i.d. oder **iid**.

Unabhängig und identisch verteilt II

Diese Annahme bildet insbesondere die Standardituation ab, in der $X_1, \dots, X_n$ eine Stichprobe eines Merkmals $\tilde{X}$ bei einer einfachen Zufallsauswahl sind.

Beispiel $\tilde{X}$ Einkommen, n Personen zufällig ausgewählt

X_1	Einkommen der	ersten	zufällig ausgewählten Person
X_2	Einkommen der	zweiten	zufällig ausgewählten Person
$\vdots$		$\vdots$	
X_n	Einkommen der	n -ten	zufällig ausgewählten Person

Schwaches Gesetz der großen Zahlen I

Satz (Schwaches Gesetz der großen Zahlen)

Seien $X_1, \dots, X_n$ unabhängig und identisch verteilt mit $\mathbb{E}(X_i) = \mu$ und $\text{Var}(X_i) = \sigma^2 < \infty \quad \forall i = 1, \dots, n$.

Dann gilt

$$\bar{X}_n := \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{\mathbb{P}} \mu.$$

Schwaches Gesetz der großen Zahlen II

Beweis:

$\bar{X}_n \xrightarrow{2} \mu$ denn

$$\mathbb{E}(\bar{X}_n) = \frac{1}{n} \sum_{i=1}^n (\mathbb{E}(X_i)) = \frac{1}{n} \cdot n\mu = \mu$$

und

$$\mathbb{E}(|\bar{X}_n - \mu|^2) = \text{Var}(\bar{X}_n) = \frac{1}{n^2} n\sigma^2 = \frac{1}{n}\sigma^2 \rightarrow 0$$

$\implies \bar{X}_n \xrightarrow{\mathbb{P}} \mu$ wegen Satz 14.7.



Schwaches Gesetz der großen Zahlen III


Beispiel 14.6

$X_i \sim \text{Po}(\lambda)$ stochastisch unabhängig $\implies \mathbb{E}(X_i) = \lambda$,

$\text{Var}(X_i) = \lambda, i = 1, \dots, n$ und $\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{\mathbb{P}} \lambda$

```
set.seed(1)
N <- 500
x <- rpois(N, 2.5)
xbar <- cumsum(x)/(1:N)
plot(xbar, pch = 19, cex = 0.2, ylab = expression(bar(x)))
lines(c(0, N), rep(2.5, 2), lty = 2, col = "blue", lwd = 2)
```

Schwaches Gesetz der großen Zahlen IV



Theorem von Bernoulli I


Spezialfall des Gesetzes der großen Zahlen: Wir betrachten n 0/1-Experimente mit Erfolgswahrscheinlichkeit π . Das heißt $X_i \sim B(1, \pi)$. Dann ist $\bar{X}$ die *relative Häufigkeit* der Erfolge und es gilt

$$\bar{X}_n \xrightarrow{\mathbb{P}} \pi$$

Die relative Häufigkeit konvergiert also gegen die wahre Wahrscheinlichkeit.

Theorem von Bernoulli II

```
set.seed(1)
x <- cumsum(rbinom(500, 1, 0.3))/(1:500)
plot(x, pch = 19, cex = 0.2, ylab = expression(bar(x)))
lines(c(0, 1000), rep(0.3, 2), lty = 2, col = "blue", lwd = 2)
```



Frequentismus

Folgerungen

Frequentische Interpretation der Wahrscheinlichkeit: Wahrscheinlichkeiten werden als Grenzwert der relativen Häufigkeit aufgefasst.

Frequentische Interpretation des Erwartungswerts: Erwartungswert ist Grenzwert des Mittelwerts.

Satz von Khinchine I

Satz von Khinchine (ohne Beweis): Die Voraussetzung $\text{Var}(X_i) = \sigma^2$ ist nicht nötig! Es reicht, dass $\mathbb{E}(X_i)$ existiert. Weiterhin aber i.i.d. nötig.

Zum Beispiel $X_i \sim t(n)$ (Def. 19.12)

- ▶ $\mathbb{E}(X_i) = 0$ für $n > 1$, für $n = 1$ existiert der Erwartungswert nicht.
- ▶ $\text{Var}(X_i) = \frac{n}{n-2}$ für $n > 2$, für $n \leq 2$ existiert die Varianz nicht.

Satz von Khinchine II


```
set.seed(172)
N <- 10000
x3 <- rt(N, 3)
mean(x3)
```

```
## [1] -0.01566653
```

```
var(x3)
```

```
## [1] 2.521877
```

Satz von Khinchine III




Satz von Khinchine IV

```
x2 <- rt(N, 2)  
mean(x2)
```

```
## [1] 0.02320655
```

```
var(x2)
```

```
## [1] 7.795786
```




Gegenbeispiel I

Beispiel 14.7

$X_i \sim \text{Cauchy}$ iid. Gesetz der großen Zahlen ist für $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ nicht anwendbar, da die Cauchy-Verteilung keinen Erwartungswert hat (siehe Beispiel 8.5)!

Gegenbeispiel II



Starkes Gesetz der großen Zahlen I

Satz ((Zweites) Starkes Gesetz der großen Zahlen nach Kolmogorov)

Seien $X_1, \dots, X_n$ unabhängige, identisch verteilte Zufallsvariablen. Dann gilt: Existiert der Erwartungswert $\mathbb{E}(X_1)$ und ist er endlich (d.h. $\mathbb{E}(|X_1|) < \infty$), so

konvergiert $\bar{X}_n := \frac{1}{n} \sum_{i=1}^n X_i$ $\mathbb{P}$ -fast sicher mit

$$\lim_{n \rightarrow \infty} \bar{X}_n = \mathbb{E}(X_1) \quad \mathbb{P} - f.s.$$

Ist $\mathbb{E}(X_1) = \infty$, so konvergiert $\bar{X}_n$ $\mathbb{P}$ -fast sicher nicht gegen einen endlichen Grenzwert.

Beweis siehe Henze (2019), Seite 200ff.

- ▶ Voraussetzungen von starken und schwachem Gesetz sind identisch (i.i.d. und $\mathbb{E}(X_1) < \infty$)

Monte-Carlo-Verfahren I

Ziel: Wir wollen numerisch ein Integral (Fläche unter der Funktion) über die Funktion $f : (0, 1) \rightarrow (0, 1)$ berechnen. O.B.d.A. sei $f : (0, 1) \rightarrow (0, 1)$.

Seien $(X_i, Y_i)_{i=1, \dots, n}$ unabhängige, gleichverteilte Zufallsvariablen auf $\Omega = [0, 1) \times [0, 1)$. Sei B eine Borelmenge ($B \in \mathcal{B}_\Omega$) und $Z_i = \mathbb{I}_B(X_i, Y_i)$. Es gilt

$$p := \mathbb{P}(Z_i = 1) = \mathbb{P}((X_i, Y_i) \in B) = \int_B 1 \, d\lambda^2$$

Die Z_i sind unabhängig und identisch Bernoulli-verteilt mit $p = \mathbb{P}(Z_i = 1)$, daher $\mathbb{E}(Z_1) = p$, also Fläche von B .


Monte-Carlo-Verfahren II

Algorithmus zur Monte-Carlo-Integration

- ▶ Ziehe n unabhängige gleichverteilte Zufallszahlen (X_i, Y_i) auf $[0, 1)^2$
- ▶ Stelle fest, ob (X_i, Y_i) in B
- ▶ Gesetz der großen Zahlen sagt:

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n Z_i = p$$

Monte-Carlo-Verfahren III



Monte-Carlo-Verfahren IV

	Schätzung
N=10	0.8000000
N=10 ²	0.5700000
N=10 ³	0.6540000
N=10 ⁴	0.6460000
N=10 ⁵	0.6361100
N=10 ⁶	0.6371100
N=10 ⁷	0.6366096
Wahrer Wert	0.6366198

Allgemeine Gesetze der großen Zahlen I

Definition

Gegeben sei eine Folge von Zufallsvariablen $(X_n)_{n \in \mathbb{N}}$, für deren Erwartungswert gelte $\mathbb{E}(|X_n|) < \infty$ für alle $n \in \mathbb{N}$. Man sagt, die Folge genügt dem starken bzw. schwachen Gesetz der großen Zahlen (engl. **strong or weak law of large numbers, LLN**), wenn die Folge

$$\bar{X}_n := \frac{1}{n} \sum_{i=1}^n (X_i - \mathbb{E}(X_i))$$

der zentrierten Mittelwerte fast sicher bzw. in Wahrscheinlichkeit gegen 0 konvergiert.

Allgemeine Gesetze der großen Zahlen II

Ohne Beweise einige Gesetze der großen Zahlen, die nicht Unabhängigkeit oder identische Verteilung voraussetzen.

Satz (Starkes Gesetz der großen Zahlen von Etemadi)

Ist die Folge von Zufallsvariablen $(X_n)_{n \in \mathbb{N}}$ identisch verteilt und paarweise unabhängig mit $\mathbb{E}(|X_n|) < \infty$, so genügt sie dem starken Gesetz der großen Zahlen.

Allgemeine Gesetze der großen Zahlen III

Satz (Erstes Gesetz der großen Zahlen von Kolmogorow)

Gilt für eine unabhängige Folge von Zufallsvariablen $(X_n)_{n \in \mathbb{N}}$ mit endlicher Varianz die Kolmogorov-Bedingung

$$\sum_{n=1}^{\infty} \frac{\text{Var}(X_n)}{n^2} < \infty$$

so genügt sie dem starken Gesetz der großen Zahlen.

Allgemeine Gesetze der großen Zahlen IV

Satz (von Cantelli)

Ist eine Folge von Zufallsvariablen $(X_n)_{n \in \mathbb{N}}$ unabhängig, habe endliche vierte Momente und seien die zentralen vierten Momente gleichmäßig beschränkt

$$\sup_{n \in \mathbb{N}} \mathbb{E}((X_n - \mathbb{E}(X_n))^4) < \infty$$

so genügt sie dem starken Gesetz der großen Zahlen.

Allgemeine Gesetze der großen Zahlen V

Beispiel 14.8

In der Finanzmathematik bezeichnet man mit *Market Microstructure Noise* kleine Kursbewegungen, verursacht durch zufällige Trades bzw. Trade-Artifakte. Sie haben einen Mittelwert von 0, aber keine konstante Varianz. In der Regel gilt aber die Kolmogorov-Bedingung

$$\sum_{n=1}^{\infty} \frac{\text{Var}(X_n)}{n^2} < \infty,$$

so dass das Gesetz der großen Zahlen gilt, sprich der Mittelwert gegen 0 konvergiert.

Allgemeine Gesetze der großen Zahlen VI

Beispiel 14.9

Eine Versicherung hat viele Kunden, die im Laufe des Jahres Schadensfälle melden. Sei X_n die Schadenssumme des n -ten Kunden mit:

- ▶ Paarweise unabhängigen Schadenshöhen (Schäden sind nicht völlig unabhängig, aber direkte Abhängigkeiten bestehen nur zwischen einzelnen Gruppen, z. B. innerhalb von Haushalten).
- ▶ Gemeinsamer Erwartungswert: $\mathbb{E}[X_n] = \mu$ und eine gleichmäßig beschränkte zweite Momentenbedingung.

Die durchschnittliche Schadenshöhe konvergiert also nach dem Satz von Etemadi:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \rightarrow \mu \text{ f.s.}$$

- ▶ Für abhängige Zufallsvariablen gibt es Ergodensätze, siehe auch Kapitel stochastische Prozesse.

Multivariates Gesetz der großen Zahlen

Satz (Multivariates starkes Gesetz der großen Zahlen)

Seien $\mathbf{X}_1, \mathbf{X}_2, \dots$ mit $\mathbf{X}_i = (X_{i1}, \dots, X_{ip})$ iid reelwertige Zufallsvektoren auf $\mathbb{R}^p$ und $\boldsymbol{\mu} := \mathbb{E}(\mathbf{X}_1)$ mit $\mathbb{E}(\|\mathbf{X}_1\|) < \infty$. Dann gilt für alle $j = 1, \dots, p$

$$\bar{X}_j := \frac{1}{n} \sum_{i=1}^n X_{ij} \xrightarrow{\text{f.s.}} \mu_j.$$

Beweisidee: komponentenweise Anwendung des eindimensionalen Gesetzes der großen Zahlen.

Kapitel 15

Verteilungskonvergenz

15. Verteilungskonvergenz

15.1 Konvergenz in Verteilung

15.2 Zusammenhang Konvergenzarten

15.3 Zentrale Grenzwertsätze

15.4 Fundamentalsatz der Statistik



Verteilungskonvergenz

Far better an approximate answer to the right question, which is often vague, than the exact answer to the wrong question, which can always be made precise.

John Tukey (1915–2000)

Ann. Math. Statist. 33(1): 1-67 (1962)

15. Verteilungskonvergenz

15.1 Konvergenz in Verteilung

15.2 Zusammenhang Konvergenzarten

15.3 Zentrale Grenzwertsätze

15.4 Fundamentalsatz der Statistik

Konvergenz in Verteilung I

Definition

Sei $(\Omega, \mathcal{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und $X_i : \Omega \rightarrow \mathbb{R}$ Zufallsvariablen mit Verteilungsfunktionen F_i , $i = 1, 2, \dots$

Dann konvergiert die Folge $(X_n)_{n \in \mathbb{N}}$ in Verteilung (engl. *convergence in distribution*) gegen $X : \Omega \rightarrow \mathbb{R}$ mit Verteilungsfunktion F , falls

$$\lim_{n \rightarrow \infty} F_n(x) = F(x)$$

für alle x , in denen F stetig ist.

Wir schreiben $X_n \xrightarrow{D} X$. Man spricht auch von schwacher Konvergenz.

Konvergenz in Verteilung II

Beispiel 15.1

- ▶ Sei $X_n \sim U(0, 1)$, also für $0 \leq x \leq 1 : F_{X_n}(x) = x$.
 - ▶ Sei $Z = 1 - X_1$, also für $0 \leq x \leq 1 : F_Z(x) = x$.
 - ▶ Dann gilt offensichtlich $X_n \xrightarrow{D} Z$, aber auch $X_n \xrightarrow{D} X_1$
-
- ▶ Im Gegensatz zum letzten Kapitel konvergiert die Folge nicht gegen einen Skalar, sondern gegen eine Zufallsvariable.
 - ▶ Die Zufallsvariable ist aber nicht eindeutig, aber deren Verteilung

Wir schreiben $X_n \xrightarrow{D} U(0, 1)$ oder $X_n \overset{a}{\sim} U(0, 1)$.

Poisson-Approximation I

Satz

Sei $X_n \sim B(n, p_n)$ und $(p_n)_{n \geq 1}$ eine Folge mit

$$\lim_{n \rightarrow \infty} (np_n) = \lambda$$

für ein $\lambda > 0$. Dann gilt

$$X_n \xrightarrow{D} \text{Po}(\lambda).$$

Poisson-Approximation II

Beweis:

Statt mit der Verteilungsfunktion können wir hier auch mit der (Wahrscheinlichkeits-)Dichte arbeiten:

$$\begin{aligned}\lim_{n \rightarrow \infty} P(X_n = k) &= \lim_{n \rightarrow \infty} \binom{n}{k} p_n^k (1 - p_n)^{n-k} \\&= \lim_{n \rightarrow \infty} \frac{n!}{k! (n-k)!} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \\&= \lim_{n \rightarrow \infty} \left(\frac{\lambda^k}{k!}\right) \left(\frac{n(n-1)(n-2) \cdots (n-k+1)}{n^k}\right) \left(1 - \frac{\lambda}{n}\right)^n \left(1 - \frac{\lambda}{n}\right)^{-k} \\&= \frac{\lambda^k}{k!} \cdot \lim_{n \rightarrow \infty} \underbrace{\left(\frac{n}{n} \cdot \frac{n-1}{n} \cdot \frac{n-2}{n} \cdots \frac{n-k+1}{n}\right)}_{\rightarrow 1} \underbrace{\left(1 - \frac{\lambda}{n}\right)^n}_{\rightarrow e^{-\lambda}} \underbrace{\left(1 - \frac{\lambda}{n}\right)^{-k}}_{\rightarrow 1} \\&= \frac{\lambda^k}{k!} \exp(-\lambda).\end{aligned}$$

□

Poisson-Approximation III

Diese asymptotische Aussage lässt sich auch schon für endliche n anwenden. Es lässt sich sogar die Güte der Approximation abschätzen:

$$\sum_{k=0}^{\infty} |\mathrm{B}(n, p_n)(\{k\}) - \mathrm{Po}(np_n)(\{k\})| \leq 2np_n^2.$$

Die Approximation ist also besonders gut für kleine p .

Poisson-Approximation IV




Abbildung 27: Oben: Verteilungsfunktion der Binomial- und der approximierenden Poisson-Verteilungen, unten: Differenz der Verteilungsfunktionen.

15. Verteilungskonvergenz

15.1 Konvergenz in Verteilung

15.2 Zusammenhang Konvergenzarten

15.3 Zentrale Grenzwertsätze

15.4 Fundamentalsatz der Statistik

Zusammenhang Konvergenzarten I

Satz

Sei $(X_n)_{n \in \mathbb{N}}$ eine Folge von Zufallsvariablen $X_i : \Omega \rightarrow \mathbb{R}$ und $X : \Omega \rightarrow \mathbb{R}$. Dann gilt

$$X_n \xrightarrow{\mathbb{P}} X \implies X_n \xrightarrow{D} X$$

Beweis:

Voraussetzung: $X_n \xrightarrow{\mathbb{P}} X$.

Sei $F_n(x) = \mathbb{P}(X_n \leq x)$; $F(x) = \mathbb{P}(X \leq x)$. Es gilt für $\epsilon > 0$:

Zusammenhang Konvergenzarten II

$$\begin{aligned}F_n(x) &= \mathbb{P}(X_n \leq x) = \mathbb{P}(X_n \leq x, X \leq x + \epsilon) + \mathbb{P}(X_n \leq x, X > x + \epsilon) \\&\leq \mathbb{P}(X \leq x + \epsilon) + \mathbb{P}(X_n - X \leq x - X, x - X < -\epsilon) \\&\leq F(x + \epsilon) + \mathbb{P}(X_n - X < -\epsilon) \\&\leq F(x + \epsilon) + \mathbb{P}(X_n - X < -\epsilon) + \mathbb{P}(X_n - X > \epsilon) \\&\leq F(x + \epsilon) + \mathbb{P}(|X_n - X| > \epsilon)\end{aligned}$$

$$\begin{aligned}\text{und } F(x - \epsilon) &= \mathbb{P}(X \leq x - \epsilon) \\&= \mathbb{P}(X \leq x - \epsilon, X_n \leq x) + \mathbb{P}(X \leq x - \epsilon, X_n > x) \\&\leq F_n(x) + \mathbb{P}(|X_n - X| > \epsilon) \quad (\text{Umformung s.o.})\end{aligned}$$

Zusammen:

$$F(x - \epsilon) - \mathbb{P}(|X_n - X| > \epsilon) \leq F_n(x) \leq F(x + \epsilon) + \mathbb{P}(|X_n - X| > \epsilon)$$

Zusammenhang Konvergenzarten III

Für $n \rightarrow \infty$:

$$\begin{aligned} F(x - \epsilon) - \underbrace{\mathbb{P}(|X_n - X| > \epsilon)}_{\rightarrow 0} &\leq F_n(x) \leq F(x + \epsilon) + \underbrace{\mathbb{P}(|X_n - X| > \epsilon)}_{\rightarrow 0} \\ \implies F(x - \epsilon) &\leq \lim_{n \rightarrow \infty} F_n(x) \leq F(x + \epsilon) \end{aligned}$$

Falls F in x stetig:

$$\begin{aligned} F(x) &\leq \lim_{n \rightarrow \infty} F_n(x) \leq F(x) \\ \implies F(x) &= \lim_{n \rightarrow \infty} F_n(x) \implies X_n \xrightarrow{D} X \end{aligned}$$



Zusammenhang Konvergenzarten IV

Also:

- ▶ Stärkste Konvergenzarten: **fast sicher** und **im Moment**
- ▶ schwächer: **in Wahrscheinlichkeit** (schwaches Gesetz der großen Zahlen)
- ▶ am schwächsten: **in Verteilung** (manchmal auch schwache Konvergenz genannt)

Achtung! In der Regel:

- ▶ Konvergenz fast sicher, im Moment und in Wahrscheinlichkeit gegen Delta-verteilte Zufallsvariable, also gegen Skalar
- ▶ Konvergenz in Verteilung gegen mehrere Zufallsvariablen identischer Verteilung, also gegen Verteilung

Satz von Slutsky I

Satz

Seien $X_n \xrightarrow{\mathcal{D}} X$, $A_n \xrightarrow{\mathbb{P}} a$ und $B_n \xrightarrow{\mathbb{P}} b$. Dann gilt:

$$A_n + B_n X_n \xrightarrow{\mathcal{D}} a + bX$$

Es gilt also auch für $b \neq 0$:

$$X_n \xrightarrow{\mathcal{D}} X \implies a + bX_n \xrightarrow{\mathcal{D}} a + bX$$

Satz von Slutsky II

Beweis:

Hier nur eine Beweisskizze unter Unabhängigkeit:

Sei $Y_n \xrightarrow{\mathcal{D}} Y$ unabhängig von X_n, X . Dann

$$\text{Var } \phi_{(X_n, Y_n)}(t) \stackrel{\text{Satz 10.8}}{=} \text{Var } \phi_{X_n}(t) \cdot \text{Var } \phi_{Y_n}(t) \stackrel{\text{Satz 6.10}}{\implies} \text{Var } \phi_X(t) \cdot \text{Var } \phi_Y(t) = V$$

Mit $Y_n \xrightarrow{\mathbb{P}} a$ und Faltung folgt $X_n + Y_n \rightarrow X + a$, analog für $Y_n \xrightarrow{\mathbb{P}} b$. □

Satz von Slutsky III



Jewgeni Jewgenjewitsch Sluzki
(7./19. April 1880 bis 10. März
1948)

Geboren in Jaroslawl. Studierte Mathematik und Physik in Kiew, wurde 1902 wegen revolutionärer Bestrebungen exmatrikuliert. Anschliessend Studium des Ingenieurwesens an der heutigen TU München. 1905 nahm er sein Studium in Kiew wieder auf. Entwickelte in seiner Abschlussarbeit 1911 die Slutsky-Zerlegung zur Bestimmung der hicksschen Nachfragefunktion, noch heute wichtiges Instrument der Mikroökonomie. 1915 Professur in Kiew, ab 1926 in Moskau.

15. Verteilungskonvergenz

15.1 Konvergenz in Verteilung

15.2 Zusammenhang Konvergenzarten

15.3 Zentrale Grenzwertsätze

15.4 Fundamentalsatz der Statistik

Zentraler Grenzwertsatz I

Satz (Zentraler Grenzwertsatz (engl. central limit theorem, CLT) von Lindeberg-Lévy)

Seien $X_i, i = 1, \dots$ unabhängig und identisch verteilt (independent identically distributed, iid) mit $\mathbb{E}(X_i) = \mu$ und $\text{Var}(X_i) = \sigma^2 < \infty \forall i = 1, \dots$. Dann gilt

$$\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \xrightarrow{\mathcal{D}} N(0, 1)$$

bzw.

$$\sqrt{n}(\bar{X} - \mu) \xrightarrow{\mathcal{D}} N(0, \sigma^2)$$

Zentraler Grenzwertsatz II

Beweis:

Der folgende Beweis setzt die Existenz der momenterzeugenden Funktion in einer Umgebung um 0 voraus. Allgemeiner lässt sich der ZGWS mit der charakteristischen Funktion beweisen.

Sei $Y_i = \frac{X_i - \mu}{\sigma}$, also $\mathbb{E}(Y_i) = 0$, $\text{Var}(Y_i) = 1$ und $Z_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n Y_i$.

Benutze $K(s) = \log M(s)$, also $K'(s) = \frac{M'(s)}{M(s)}$ und (Quotientenregel, $M(0) = 1$):

$$K'(0) = M'(0) = \mathbb{E}(Y_i) = 0, \quad K''(0) = M''(0) - (M'(0))^2 = \text{Var}(Y_i) = 1.$$

für $n \in \{1, 2\}$ da $M(0) \equiv 1$. K wird auch kumulanten erzeugende Funktion genannt.

Zentraler Grenzwertsatz III

$$\begin{aligned} M_{Z_n}(t) &= \mathbb{E}(\exp(tZ_n)) = \mathbb{E}\left(\exp\left(\frac{t}{\sqrt{n}} \sum_{i=1}^n Y_i\right)\right) \\ &\stackrel{stu}{=} \prod_{i=1}^n \mathbb{E}\left(\exp\left(\frac{t}{\sqrt{n}} Y_i\right)\right) \stackrel{iid}{=} M_Y\left(\frac{t}{\sqrt{n}}\right)^n \end{aligned}$$

$$\text{also } K_{Z_n}(t) = \log M_{Z_n}(t) = n \log M_Y\left(\frac{t}{\sqrt{n}}\right) = n K_Y\left(\frac{t}{\sqrt{n}}\right)$$

Zentraler Grenzwertsatz IV

$$\begin{aligned}\lim_{n \rightarrow \infty} K_{Z_n}(t) &= \lim_{\epsilon \rightarrow 0} \frac{K_Y(\epsilon t)}{\epsilon^2} \quad \left(\frac{0}{0}, K_Y(0) = 0\right) \\ &\stackrel{\text{L'Hospital}}{=} \lim_{\epsilon \rightarrow 0} \frac{t K'_Y(\epsilon t)}{2\epsilon} \quad \left(\frac{0}{0}, K'_Y(0) = 0\right) \\ &\stackrel{\text{L'Hospital}}{=} \lim_{\epsilon \rightarrow 0} \frac{t^2 K''_Y(\epsilon t)}{2} = \frac{t^2}{2} \quad (K''_Y(0) = \text{Var}(Y_i) = 1)\end{aligned}$$

Behauptung folgt aus $M_{N(0,1)}(t) = \exp\left(\frac{t^2}{2}\right)$.



Beispiele I

Beispiel 15.2 (Diskrete Gleichverteilung (Würfelwurf))

Sei $X_i \sim U\{1, 2, 3, 4, 5, 6\}$. Dann ist $\mathbb{E}(X_i) = 3.5$ und $\text{Var}(X_i) = \frac{35}{12}$. Sei

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\sqrt{n} \frac{\bar{X} - 3.5}{\sqrt{35/12}} \xrightarrow{D} N(0, 1)$$

Beispiele II




Abbildung 28: Verteilung des Mittelwerts bei n -maligem Würfeln

Beispiele III

Beispiel 15.3

Sei $X_1, \dots, X_n$ iid mit $\mathbb{E}(X_i) = 0$, $\text{Var}(X_i) = \sigma^2$ und $\text{Var}(X_i^2) = \tau^2 < \infty$.

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \xrightarrow{\mathbb{P}} \sigma^2$$

Frage: Konvergiert $\sqrt{n}(S^2 - \sigma^2)$?

S^2 hängt nicht von μ ab, also o.B.d.A. $\mu = 0$.

Der Zentrale Grenzwertsatz sagt:

$$\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \sigma^2 \right) \xrightarrow{\mathcal{D}} N(0, \tau^2)$$

Gesetz der großen Zahlen: $\bar{X}^2 \xrightarrow{\mathbb{P}} 0$. Damit folgt:

$$\sqrt{n}(S^2 - \sigma^2) = \sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \underbrace{\bar{X}^2}_{\rightarrow 0} - \sigma^2 \right) \xrightarrow{D} N(0, \tau^2)$$

Asymptotik und Approximation I

Beispiel 15.4 (Binomialverteilung (vgl. Statistik I))

Sei $X_i \sim B(1, p)$, $i = 1, \dots, n$. Dann ist $Y_n = \sum_{i=1}^n X_i \sim B(n, p)$. Es gilt der **Zentrale Grenzwertsatz von de Moivre-Laplace**:

$$\frac{Y_n - np}{\sqrt{np(1-p)}} \xrightarrow{D} N(0, 1), \text{ oder } \frac{Y_n - np}{\sqrt{np(1-p)}} \overset{a}{\sim} N(0, 1).$$

Das ist eine **asymptotische Aussage**. Umformuliert (mit dem 0.025-Quantil der Standardnormalverteilung gleich ungefähr 1.96):

$$\begin{aligned} \frac{Y_n}{n} &\overset{a}{\sim} N\left(p, \frac{p(1-p)}{n}\right) \\ \Rightarrow \mathbb{P}\left(p - 1.96\sqrt{\frac{p(1-p)}{n}} \leq \frac{Y_n}{n} \leq p + 1.96\sqrt{\frac{p(1-p)}{n}}\right) &\approx 0.95 \end{aligned}$$

Für $n \rightarrow \infty$ degeneriert das Intervall zum Punkt p .

Asymptotik und Approximation II

Aber: schon für endliche n sind wir (vielleicht) schon nah dran. Wir nutzen die Grenzwertsätze zur **Approximation**:

$$\frac{Y_n}{n} \approx N\left(p, \frac{p(1-p)}{n}\right)$$

Obiges Intervall gilt **approximativ** schon für endliche n .

Zentraler Grenzwertsatz

Der Zentrale Grenzwertsatz ist deswegen so "Zentral", weil viele unbekannte Verteilungen durch die Normalverteilung (oder davon abgeleitete Verteilungen) approximiert werden können.

Beispiel: In der einfachen linearen Regression nimmt man an, dass der (Beobachtungs-)Fehler normalverteilt ist. Begründung: Der Fehler ergibt sich aus der Summe sehr vieler kleiner Fehlerquellen.

Konvergenzrate I

Definition (Landau-Symbole)

Sei f_n eine Folge von reellen Zahlen. Dann bezeichnet

$$o(g_n) \rightarrow \lim_{n \rightarrow \infty} \left| \frac{f_n}{g_n} \right| = 0$$

$$\mathcal{O}(g_n) \rightarrow \limsup_{n \rightarrow \infty} \left| \frac{f_n}{g_n} \right| < \infty$$

Interpretation von o : f_n geht schneller gegen 0 als g_n .

Konvergenzrate II

Satz

Es seien $X_1, \dots, X_n$ iid mit $X_i \sim F$, $\mathbb{E}(X_i) = \mu$, $\text{Var}(X_i) = \sigma^2$, $\mathbb{E}(X_i^3) < \infty$ und k -tem zentralen Moment $\mu_k^0 = \mathbb{E}((X_i - \mu)^k)$. Dann gilt:

$$\begin{aligned} G_n(x) &= \mathbb{P} \left(\sqrt{n} \left(\frac{\bar{X} - \mu}{\sigma} \right) \leq x \right) \\ &= \Phi(x) + \underbrace{\frac{\mu_3^0}{6\sigma^3\sqrt{n}} (1 - x^2) \text{Var } \phi(x)}_{\text{erste Edgeworth-Korrektur}} + o \left(\frac{1}{\sqrt{n}} \right) \end{aligned}$$

- ▶ $o \left(\frac{1}{\sqrt{n}} \right)$ meint eine Folge, die wie $\frac{1}{\sqrt{n}} \rightarrow 0$ für $n \rightarrow \infty$, aber schneller als $\frac{1}{\sqrt{n}}$.
- ▶ für symmetrische Verteilungen ist $\mu_3 = 0$ und damit ist z.B. für die t-Verteilung die Approximation durch $N(0, 1)$ schneller als $\frac{1}{\sqrt{n}}$. Die erste Edgeworth-Korrektur ist also für schiefe Verteilungen wie $\chi^2(n)$ von Interesse.

Konvergenzgeschwindigkeit

Satz (Berry-Esseen)

Seien $X_1, \dots, X_n$ iid, $X_i \sim F$ mit $\mathbb{E}(X_i) = \mu$, $\text{Var}(X_i) = \sigma^2$, $\mathbb{E}(X_i^3) < \infty \implies \exists c$ (unabhängig von F) mit

$$|G_n(x) - \Phi(x)| \leq \frac{c}{\sqrt{n}} \frac{\mathbb{E}(|X_1 - \mu|^3)}{\sigma^3}$$

wobei $G_n(x) = \mathbb{P}\left(\sqrt{n}\left(\frac{\bar{X} - \mu}{\sigma}\right) \leq x\right)$.


- ▶ Der Satz von Berry-Esseen gilt für endliche n
- ▶ c ist unabhängig von F
- ▶ c ist nicht genau bekannt, aktuell bekannte Obergrenze ist $c_{\min} \leq 0.4748$ (Korolev and Shevtsova (2012))

Gegenbeispiel I

Seien $X_1, X_2, \dots$, iid Pareto-verteilt (siehe Def. 9.9) mit $x_m = 1$ und $1 < \alpha < 2$. Dann gilt $\mathbb{E}(X_i) = \frac{\alpha}{\alpha-1}$ und die Varianz von X existiert nicht.

```
# Funktion zum Ziehen aus Pareto-Verteilung über Inversionsmethode
rpareto <- function(n, alpha, xm = 1) {
  u <- runif(n)
  xm * u^(-1/alpha)
}
ziehen <- function(n, alpha) {
  x <- rpareto(n, alpha)
  return(sqrt(n) * sum(x - alpha/(alpha - 1)))
}
draws <- sapply(rep(10000, 1000), ziehen, alpha = 1.5)
hist(draws)
```

Gegenbeispiel II



Anmerkung: In diesem Fall konvergiert $\frac{1}{n^{1/\alpha}} \sum_{i=1}^n (X_i - \mu)$, allerdings nicht gegen die Normalverteilung.

15. Verteilungskonvergenz

15.1 Konvergenz in Verteilung

15.2 Zusammenhang Konvergenzarten

15.3 Zentrale Grenzwertsätze

15.4 Fundamentalsatz der Statistik

Fundamentalsatz der Statistik I

Im Folgenden bezeichne $\hat{F}(x) = \frac{1}{n} \sum_{i=1}^n I_{(-\infty, x]}(X_i)$ die empirische Verteilungsfunktion von $X_1, \dots, X_n$.

Satz (Satz von Gliwenko-Cantelli, Hauptsatz der Statistik (engl. Glivenko–Cantelli theorem))

- a) $\hat{F}(x) \xrightarrow{f.s.} F(x) \quad \forall x \in \mathbb{R}$
- b) $\sqrt{n}(\hat{F}_n(x) - F(x)) \xrightarrow{\mathcal{D}} N(0, F(x)(1 - F(x))) \quad \forall x \in \mathbb{R}$
- c) $\sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| \xrightarrow{f.s.} 0$

Fundamentalsatz der Statistik II

Beweis:

b) $I_{X_i \leq x} \sim B(1, F(x))$ iid $\forall i = 1, \dots, n$ und $x \in \mathbb{R}$. Wegen des ZGWS gilt

$$\underbrace{\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n I_{X_i \leq x} - F(x) \right)}_{= \sqrt{n} (\hat{F}_n(x) - F(x))} \xrightarrow{\mathcal{D}} N(0, F(x)(1 - F(x))) \implies \text{b)}$$

a) Starkes Gesetz der großen Zahlen:

$$\hat{F}_n(x) = \frac{1}{n} \sum I_{X_i \leq x} \xrightarrow{\text{f.s.}} \mathbb{E}(I_{X_i \leq x}) = \mathbb{P}(X_i \leq x) = F(x)$$

c) ohne Beweis



Fundamentalsatz der Statistik III




Abbildung 29: Approximation der $\chi^2(5)$ -Verteilung durch die empirische Verteilungsfunktion

Fundamentalsatz der Statistik IV




Abbildung 30: Approximation der $Po(5)$ -Verteilung durch die empirische Verteilungsfunktion

Fundamentalsatz der Statistik V




Abbildung 31: Approximation der Cauchy-Verteilung durch die empirische Verteilungsfunktion

Fundamentalsatz der Statistik VI

Fundamentalsatz der Statistik

Der Fundamentalsatz, auch Hauptsatz der Statistik erlaubt, dass wir allgemein theoretische Verteilungen aus Stichproben schätzen können (wenn diese groß genug sind).

Multivariate Grenzwertsätze I

Definition (Konvergenz in Verteilung)

Seien $\mathbf{X}, \mathbf{X}_1, \mathbf{X}_2, \dots$ k -dimensionale Zufallsvektoren mit Verteilungsfunktionen $F(x) = \mathbb{P}(\mathbf{X} \leq x)$, $F_n(x) = \mathbb{P}(\mathbf{X}_n \leq x)$, $x \in \mathbb{R}^k$, $n \geq 1$.

Gilt $\lim_{n \rightarrow \infty} F_n(\mathbf{x}) = F(\mathbf{x})$ für alle $\mathbf{x}$ in denen F stetig ist, so konvergiert $\mathbf{X}_n$ in Verteilung gegen $\mathbf{X}$:

$$\mathbf{X}_n \xrightarrow{\mathcal{D}} \mathbf{X}.$$

Multivariate Grenzwertsätze II

Satz (Multivariater Zentraler Grenzwertsatz)

Sei $(\mathbf{X}_n)$ eine Folge unabhängiger und identisch verteilter k -dimensionaler Zufallsvektoren mit $\mathbb{E}(\mathbf{X}_1^\top \mathbf{X}_1) < \infty$.

Mit $\boldsymbol{\mu} := \mathbb{E}(\mathbf{X}_1)$ und $\boldsymbol{\Sigma} := \mathbf{Cov}(\mathbf{X}_1)$ gilt

$$\frac{1}{\sqrt{n}} \left(\sum_{j=1}^n \mathbf{X}_j - n\boldsymbol{\mu} \right) \xrightarrow{\mathcal{D}} N_k(\mathbf{0}_k, \boldsymbol{\Sigma}).$$

Beweisidee:

Seien $\mathbf{X}_1, \mathbf{X}_2, \dots$ iid $\mathbb{R}^k$ -wertig mit $E(\mathbf{X}_1) = \boldsymbol{\mu}$ und $\mathbf{Cov}(\mathbf{X}_1) = \boldsymbol{\Sigma}$.

Für jedes $\mathbf{a} \in \mathbb{R}^k$ gilt

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n \mathbf{a}^\top (\mathbf{X}_i - \boldsymbol{\mu}) \xrightarrow{D} N(0, \mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{a})$$

(eindimensionaler ZGWS). Das daraus

Multivariate Grenzwertsätze III

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n (X_i - \mu) \xrightarrow{D} \mathcal{N}_k(0, \Sigma).$$

folgt, ist das sogenannte Cramér–Wold-Theorem.

Multivariate Grenzwertsätze IV

Satz (Multivariater Hauptsatz der Statistik)

Seien $X_1, X_2, \dots$ iid $\mathbb{R}^k$ -wertige Zufallsvektoren mit gemeinsamer Verteilungsfunktion

$$F(x) = P(X_1 \leq x), \quad x \in \mathbb{R}^k,$$

wobei $X \leq x$ komponentenweise zu verstehen ist. Die empirische Verteilungsfunktion

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{X_i \leq x\}}.$$

konvergiert gegen die theoretische Verteilungsfunktion.

Multivariate Grenzwertsätze V

Dann gilt:

1. (Multivariates starkes Gesetz)

$$F_n(x) \xrightarrow{\text{f.s.}} F(x) \quad \forall x \in \mathbb{R}^k.$$

2. (Multivariater ZGWS, punktweise) Für jedes feste x gilt

$$\sqrt{n}(F_n(x) - F(x)) \xrightarrow{D} \mathcal{N}(0, F(x)(1 - F(x))).$$

Beweis: wie im eindimensionalen.