

Teil V: Abhängigkeitsstrukturen

Kapitel 16

Stochastische Prozesse

16. Stochastische Prozesse

16.1 Random Walk

16.2 Markov-Ketten

16.3 Stochastische Prozesse



16. Stochastische Prozesse

16.1 Random Walk

16.2 Markov-Ketten

16.3 Stochastische Prozesse

Random Walks I

- ▶ Namensgebend ist die Vorstellung einer desorientierten Person, die sich in jedem Schritt mit gewisser Wahrscheinlichkeit nach rechts bzw. links bewegt bzw. stehenbleibt.
- ▶ Irrfahrten (Random Walks) können ebenfalls als diskrete Idealisierung von Kursverläufen (Aktien, Währungen) betrachtet werden.
- ▶ Irrfahrten sind wichtiger Baustein oder Spezialfall von komplexeren statistischen Modellen, z.B. in der Zeitreihenanalyse.

Diskrete einfache Irrfahrt auf der Geraden

- ▶ Start in $X_0 = 0$ (Zeit $t = 0$).
- ▶ Bewegung: ($t = 1, 2, \dots$)
 - ▶ Ein Schritt nach rechts mit Wahrscheinlichkeit p
 - ▶ Ein Schritt nach links mit Wahrscheinlichkeit q
 - ▶ Verbleiben im Zustand mit Wahrscheinlichkeit r
- ▶ $p + q + r = 1$.
- ▶ X_t Position nach t -tem Schritt.

Simulation I

```
Z = sample(c(-1, 1), 100, replace = TRUE)
X = cumsum(Z)
plot(X, type = "s", xlab = "Schritt")
```




Abbildung 32: Simulierte symmetrische einfache diskrete Irrfahrt

Simulation II




Abbildung 33: Fünf simulierte symmetrische einfache diskrete Irrfahrten

Definitionen

Allgemeine Definition

Definition

Seien Z_t unabhängig und identisch verteilt für $t = 1, \dots, T$. Dann heißt $X = (X_0, \dots, X_T)$ mit $X_t = X_{t-1} + Z_t$ und $X_0 = 0$ (einfache) Irrfahrt (Random Walk).

Das vorherige Beispiel ergibt sich mit $Z_t \in \{-1, 0, 1\}$. Zum Beispiel Spiel zwischen zwei Spielpartnern.

Definition

Sei $Z_t \sim N(0, \sigma^2)$. Dann bezeichnet man $X = (X_1, \dots, X_T)$ mit $X_i = \sum_{t=1}^i Z_t$ als

Gauss-Irrfahrt.

Es gilt

- ▶ $X_t = \sum_{i=1}^t Z_i \sim N(0, t\sigma^2)$
- ▶ $X_{t+1} | X_t = x_t \sim N(x_t, \sigma^2)$
- ▶ $X \sim N_T(0, \Sigma)$ mit

16. Stochastische Prozesse

16.1 Random Walk

16.2 Markov-Ketten

16.3 Stochastische Prozesse

Markov-Eigenschaft

Definition

Sei $X = (X_0, \dots, X_T)$. Sind $(X_0, \dots, X_{t-1})$ und $(X_{t+1}, \dots, X_T)$ unabhängig gegeben X_t für alle t , dann erfüllt X die Markov-Eigenschaft:

$$\mathbb{P}(X_{t+1} \mid X_t, X_{t-1}, \dots, X_0) = \mathbb{P}(X_{t+1} \mid X_t).$$

Man nennt X eine Markov-Kette

Ist t (diskrete) Zeit, bedeutet das: für X ist die Zukunft bedingt unabhängig von der Vergangenheit gegeben der Gegenwart.

Andrei Andrejewitsch Markow

Andrei Andrejewitsch Markow (2./14. Juni 1856 bis 20. Juli 1922)

In Rußland geborener Mathematiker, 1885 verteidigte er seine Habilitationsschrift an der Universität Sankt Petersburg und wurde dort 1886 Professor an der Fakultät für Mathematik und Physik. Er berechnete 1913 die Buchstabensequenzen in russischer Literatur, um die Notwendigkeit der Unabhängigkeit für das Gesetz der großen Zahlen nachzuweisen. Aus diesem Ansatz entwickelte sich der Markow-Prozess.



Beispiel Diskrete Markovkette I

Beispiel 16.1

Anna, Bert und Clara werfen sich einen Ball zu. Wenn sie den Ball haben, werfen sie ihn wie folgt weiter:

- ▶ Anna wirft mit Wahrscheinlichkeit $2/3$ zu Bert
- ▶ Bert wirft mit Wahrscheinlichkeit $2/3$ zu Anna
- ▶ Clara wirft mit Wahrscheinlichkeit $2/3$ zu Anna

Frage: Wer hat nach einer großen Anzahl von Würfungen den Ball?

Beispiel Diskrete Markovkette II

- Wir können die **Übergangswahrscheinlichkeiten** in Form einer Matrix angeben:

$$\mathbf{P} = \begin{pmatrix} 0 & 2/3 & 1/3 \\ 2/3 & 0 & 1/3 \\ 2/3 & 1/3 & 0 \end{pmatrix}$$

Beispiel Diskrete Markovkette III

Bezeichne π_n die Wahrscheinlichkeitsverteilung auf die drei Spieler nach n Würfeln. Nehmen wir an, dass Anna zu Beginn den Ball hat, dann ist

- ▶ $\pi_0 = (1, 0, 0)$.
- ▶ $\pi_1 = \pi_0 \mathbf{P} = (0, 2/3, 1/3)$
- ▶ $\pi_2 = \pi_1 \mathbf{P} = (\frac{2}{3} \cdot \frac{2}{3} + \frac{1}{3} \cdot \frac{2}{3}, \frac{1}{3} \cdot \frac{1}{3}, \frac{2}{3} \cdot \frac{1}{3})$
- ▶ $\pi_n = \pi_0 \mathbf{P}^n$
- ▶ existiert $\lim_{n \rightarrow \infty} \pi_n$?

Beispiel Diskrete Markovkette IV

```
P <- matrix(c(0, 2/3, 1/3, 2/3, 0, 1/3, 2/3, 1/3, 0), nrow = 3, byrow = TRUE)
pi <- c(1, 0, 0)
(pi <- pi %*% P) # Wurf 1
```

```
##           [,1]      [,2]      [,3]
## [1,]      0 0.6666667 0.3333333
```

```
(pi <- pi %*% P) # Wurf 2
```

```
##           [,1]      [,2]      [,3]
## [1,] 0.6666667 0.1111111 0.2222222
```

```
(pi <- pi %*% P) # Wurf 3
```

```
##           [,1]      [,2]      [,3]
## [1,] 0.2222222 0.5185185 0.2592593
```

```
(pi <- pi %*% P %*% P) # Wurf 5
```

```
##           [,1]      [,2]      [,3]
## [1,] 0.3209877 0.4279835 0.2510288
```

Beispiel Diskrete Markovkette V

```
(pi <- pi %*% P %*% P %*% P %*% P %*% P) # Wurf 10
```

```
##           [,1]      [,2]      [,3]  
## [1,] 0.4104049 0.3395993 0.2499958
```

```
(pi <- pi %*% P %*% P %*% P %*% P %*% P) # Wurf 15
```

```
##           [,1]      [,2] [,3]  
## [1,] 0.3986298 0.3513702 0.25
```

```
(pi <- pi %*% P %*% P %*% P %*% P %*% P) # Wurf 20
```

```
##           [,1]      [,2] [,3]  
## [1,] 0.4001804 0.3498196 0.25
```

Stationäre Verteilung I

Definition

Sei S eine Menge von Zuständen. Ein Vektor von Wahrscheinlichkeiten $\pi : S \rightarrow [0, 1]$ mit $\sum_i \pi_i = 1$ heißt stationäre Verteilung, falls

$$\pi = \pi \mathbf{P}$$

das heißt

$$\pi_j = \sum_{i \in S} \pi_i p_{ij} \quad \text{für alle } j \in S.$$

Stationäre Verteilung II

Beispiel 16.2 (Fortsetzung Beispiel 16.1)

Nehmen wir an, wir geben den Ball zufällig mit folgender Startverteilung an Anna, Bert oder Clara:

- ▶ $\pi_0 = (0.4, 0.35, 0.25)$
- ▶ $\pi_1 = \left(0.35 \cdot \frac{2}{3} + 0.25 \cdot \frac{2}{3}, 0.4 \cdot \frac{2}{3} + 0.25 \cdot \frac{1}{3}, 0.4 \cdot \frac{1}{3} + 0.35 \cdot \frac{1}{3}\right) = (0.4, 0.35, 0.25) = \pi_0!$

Stationäre Verteilung III

Satz (Ergodensatz)

Eine Markovkette besitzt eine stationäre Verteilung, falls sie

- ▶ *aperiodisch (kehrt nicht in regelmäßigen Abständen in einen Zustand zurück)*
- ▶ *positiv-rekurrent (jeder Zustand wird mit Wahrscheinlichkeit größer 0 in endlicher Zeit wieder erreicht und die erwartete Rückkehrzeit ist endlich)*

ist.

- ▶ Falls die Markovkette konvergiert, hängt für $n \rightarrow \infty$ die stationäre Verteilung nicht mehr von der Startverteilung ab.

Stationäre Verteilung IV

- Um die stationäre Verteilung zu bekommen, müssen wir nur das Gleichungssystem

$$\pi = \pi \mathbf{P}$$

lösen. Dazu transponieren wir die Gleichung

$$\mathbf{P}^\top \pi^\top = 1 \pi^\top$$

Das entspricht der Eigenwertgleichung. π ist also der (unnormierte) Eigenvektor von $\mathbf{P}^\top$ bezüglich des Eigenwerts 1.

Stationäre Verteilung V

```
eigen(t(P)) -> e
pi <- Re(e$vector[, which(e$values == 1)])
(pi <- pi/sum(pi))
```

```
## [1] 0.40 0.35 0.25
```

- ▶ Die Ergebnisse lassen sich auch auf stetige Zustandsräume verallgemeinern.
- ▶ Statt der Übergangsmatrix braucht man einen **Übergangskern**
$$P(x, A) := P(X_{t+1} \in A | X_t = x) = P(X_1 \in A | X_0 = x)$$

Markov Chain Monte Carlo I

- ▶ Ziel von **Markov Chain Monte Carlo** (MCMC) Techniken ist die Konstruktion einer Markov-Kette, deren *Übergangskern* P gegen die gesuchte Verteilung π^* konvergiert (d.h. π^* soll die invariante Verteilung der Markov-Kette sein).
- ▶ Problem: Finde zu gegebener Verteilung π^* eine Markov-Kette mit Übergangskern P und π^* als invarianter Verteilung. P ist nicht eindeutig!
- ▶ Der Ergodensatz fungiert hier wie das Gesetz der großen Zahlen bzw. der Hauptsatz der Statistik, aber für abhängige Zufallsvariablen/Ziehungen.
- ▶ Anwendung insbesondere in hochdimensionalen Problemen, wenn die gemeinsame Verteilung analytisch nicht mehr berechenbar ist.

Markov Chain Monte Carlo II


Beispiel 16.3

Für $\begin{pmatrix} X \\ Y \end{pmatrix} \sim N_2 \left(0, \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} \right)$ gilt:


$$X|Y \sim N(\rho Y, 1 - \rho^2), \quad Y|X \sim N(\rho X, 1 - \rho^2)$$

```
set.seed(33)
rho <- 0.5
iterationen <- 100
x <- y <- rep(NA, iterationen)
x[1] <- y[1] <- 4.2
for (i in 2:iterationen) {
  x[i] <- rnorm(1, rho * y[i - 1], sqrt(1 - rho^2))
  y[i] <- rnorm(1, rho * x[i], sqrt(1 - rho^2))
}
```

Markov Chain Monte Carlo III



Markov Chain Monte Carlo IV



Modellierung mit Random Walk I



Abbildung 34: Daten für COPD bei Frauen in England and Wales von 1942 bis 1996 (courtesy Anna Hansell, Imperial College).

Modellierung mit Random Walk II

- ▶ Wir gehen davon aus, dass die Beobachtungen Poisson-verteilt sind:
 $Y_t \sim \text{Po}(\lambda_t)$.
- ▶ Aber offensichtlich nicht unabhängig. Es gibt einen zeitlichen Trend.
Annahme: Der Erwartungswert pro Zeitpunkt t folgt einem Random Walk,
z.B. $\log(\lambda_t) \sim N(\log(\lambda_{t-1}), \sigma^2)$.
- ▶ Leider kennen wir σ^2 nicht. Nehmen wir an, σ^2 sei zufällig (Bayesianische Herangehensweise), z.B. $\sigma^2 \sim \text{IG}(a, b)$.

Wir interessieren uns für die Verteilung der Parameter (λ, σ^2) . Diese lässt sich über einen MCMC-Algorithmus approximieren.

Modellierung mit Random Walk III

```
library(rjags)
library(coda)
model <- "model{
  for (t in 1:T) {
    y[t] ~ dpois(lambda[t])
    lambda[t] = exp(gamma[t])
  }
  for (t in 2:T)
  {
    gamma[t] ~ dnorm(gamma[t-1], tau) #zweiter Parameter ist Präzision!
  }
  gamma[1] ~ dnorm(0, tau)
  tau ~ dgamma(a,b)
}"
jagsmodel <- jags.model(file = textConnection(model), data = datalist, n.chains = 2)
update(jagsmodel, n.iter = 1000)
samples <- coda.samples(jagsmodel, variable.names = c("gamma", "tau"), n.iter = 1000)
```

Modellierung mit Random Walk IV




Abbildung 35: Trace plot und geschätzte Dichte eines $\log(\lambda)$

Modellierung mit Random Walk V




Abbildung 36: Geschätzer zeitlicher Trend

16. Stochastische Prozesse

16.1 Random Walk

16.2 Markov-Ketten

16.3 Stochastische Prozesse

Stochastische Prozesse I

Definition

Sei

$$X_t : (\Omega, \mathcal{F}, \mathbb{P}) \longrightarrow (S, \mathcal{S})$$

für alle t Zufallsvariablen auf $(\Omega, \mathcal{F}, \mathbb{P})$. Dann heißt

$$X = \{\Omega, \mathcal{F}, \mathbb{P}, \{X_t, t \in T\}\}$$

stochastischer Prozess. T heißt Indexmenge, S heißt Zustandsraum.

Stochastische Prozesse II

Die Indexmenge T kann zum Beispiel sein

- ▶ diskrete Zeit: $T \subseteq \mathbb{N}^+$
- ▶ stetige Zeit: $T \subseteq \mathbb{R}^+$
- ▶ ungerichtete eindimensionale Indexmenge, z.B. Positionen im DNA-Strang (Lange (1997))
- ▶ Abzählbare Menge von räumlichen Einheiten, z.B. Länder auf einer Landkarte
- ▶ zweidimensionale Fläche $T \subseteq \mathbb{R}^2$
- ▶ höhere Dimensionen, Kombinationen davon (räumlich-zeitliche Prozesse), ...

Beispiele

- ▶ Markovketten
- ▶ Poissonprozesse (siehe 820)
- ▶ Gaussprozesse

Gaussprozesse I

Definition

$T = \mathbb{R}_0^+$. X ist ein Gauß-Prozess, wenn gilt

$$(X_{t_1}, X_{t_2}, \dots, X_{t_k}) \sim N_k(\mu, \Sigma)$$

für alle $t_i \in T$ für $i = 1, \dots, k$ und für alle k .

- ▶ Speziell beim stationären, isotropen Gauß-Prozess gilt $\mu = 0$ und $\text{Cov}(X_t, X_s) = \sigma^2 \rho(|t - s|)$, wobei ρ eine Korrelationsfunktion ist.
- ▶ Vgl. Bsp. 16.2

Gaussprozesse II




Abbildung 37: Durchschnittstemperatur in München Stadt von November 2020 bis Mai 2022

Gaussprozesse III




Abbildung 38: Simulierter Wienerprozess, $\rho(s, t) = \min(s, t)/\sigma^2$

Gaussprozesse IV




Abbildung 39: Simulierter Gaussprozess mit Gausskorrelationsfunktion, $\rho(s, t) = \exp(-25(s - t)^2)$

Gaussprozesse V




Abbildung 40: Messungen des Regen an 100 Wetterstationen in der Schweiz am 8. Mai 1986

Gaussprozesse VI




Abbildung 41: Glatte Prädiktion des Regenfalls in der Schweiz am 8. Mai 1986, basierend auf Gaussprozess (Kriging-Verfahren).

Kapitel 17

Copula

17. Copula

17.1 Definition und Eigenschaften

17.2 Spezielle Copulas



17. Copula

17.1 Definition und Eigenschaften

17.2 Spezielle Copulas

Definition Copulas I

Definition

Eine Copula $C : [0, 1]^n \rightarrow [0, 1]$ ist eine n -dimensionale Verteilungsfunktion

$$C(u_1, \dots, u_n) := \mathbb{P}(U_1 \leq u_1, \dots, U_n \leq u_n)$$

über $[0, 1]^n$ deren n Randverteilungen alle Standard-Gleichverteilungen $U[0, 1]$ sind.

- ▶ $C(u_1, \dots, u_n)$ ist monoton ansteigend in jeder Komponente u_j
- ▶ Die Randverteilung der j -ten Komponente bekommt man mit $u_i = 1 \forall i \neq j$, und da sie eine Gleichverteilung ist muss gelten:

Definition Copulas II

$$C(1, \dots, 1, u_j, 1, \dots, 1) = u_j$$

Satz (Verteilung durch Copula und Randverteilungen)

Sei $C(u_1, \dots, u_n)$ eine Copula, und $F_1, \dots, F_n$ beliebige eindimensionale Verteilungsfunktionen. Dann ist

$$F(x_1, \dots, x_n) = C(F_1(x_1), \dots, F_n(x_n))$$

eine Verteilungsfunktion mit Randverteilungsfunktionen $F_1, \dots, F_n$.

- ▶ $\mathbb{P}(F(X) \leq u) = u$, $u \in [0, 1]$ für stetige Verteilungsfunktionen F , also $F(X) \sim U[0, 1]$.
- ▶ Damit gilt auch:

Definition Copulas III

$$C(u_1, \dots, u_n) = F(F_{X_1}^{-1}(u_1), \dots, F_{X_n}^{-1}(u_n)).$$

Satz (Satz von Sklar)

Sei F eine n -dimensionale Verteilungsfunktion mit den Randverteilungen $F_1, \dots, F_n$. Dann existiert eine Copula C , so dass Satz 17.2 gilt. Sind alle Randverteilungen stetig, so ist C eindeutig.

Beweis siehe Sklar (1997).

Das heißt, dass jede stetige multivariate Verteilung in ihre Randverteilungen (marginale Verteilungsfunktionen) und ihre Abhängigkeitsstruktur (Copula) zerlegt werden kann.

Eigenschaften I

Satz (Copula unter monotonen Transformationen)

Seien $X_1, \dots, X_n$ reellwertige Zufallsvariablen mit stetigen Randverteilungen und einer Copula C_X . Seien $g_i : \mathbb{R} \rightarrow \mathbb{R}$, $i = 1, \dots, n$ strikt monoton steigende Funktionen und $Y_i = g_i(X_i)$. Dann gilt für die Copula C_Y von $Y_1, \dots, Y_n$:

$$C_Y = C_X.$$

Eigenschaften II

Beweis:

$$\begin{aligned}F_Y(y_1, \dots, y_n) &= P(g_1(X_1) \leq y_1, \dots, g_n(X_n) \leq y_n) \\&= P(X_1 \leq g_1^{-1}(y_1), \dots, X_n \leq g_n^{-1}(y_n)) \\&= F_X(g_1^{-1}(y_1), \dots, g_n^{-1}(y_n))\end{aligned}$$

also mit $y_i \rightarrow \infty \forall i \neq j : F_{Y_j}(y_j) = F_{X_j}(g_j^{-1}(y_j))$, und damit:

$$\begin{aligned}C_Y(u_1, \dots, u_n) &= F_Y(F_{Y_1}^{-1}(u_1), \dots, F_{Y_n}^{-1}(u_n)) \\&= F_X(g_1^{-1}(F_{Y_1}^{-1}(u_1)), \dots, g_n^{-1}(F_{Y_n}^{-1}(u_n))) \\&= F_X(F_{X_1}^{-1}(u_1), \dots, F_{X_n}^{-1}(u_n)) = C_X(u_1, \dots, u_n)\end{aligned}$$



Eigenschaften III

Satz (Fréchet-Hoeffding Schranken)

Für eine gültige Copula $C(u_1, \dots, u_n)$ muss gelten:

$$\max \left(1 - n + \sum_{i=1}^n u_i, 0 \right) \leq C(u_1, \dots, u_n) \leq \min(u_1, \dots, u_n)$$

- ▶ Die obere Schranke bezeichnet man als ko-monotone Copula. Sie entsteht zum Beispiel wenn alle $X_i, i \neq 1$ monotone Transformationen von X_1 sind. (“vollständige gleichsinnige Abhängigkeit”)
- ▶ Die untere Schranke ist für $n > 2$ keine gültige Copula. Für $n = 2$ entsteht sie durch die gemeinsame Verteilung von $(X, 1 - X)$ mit $X \sim U[0, 1]$. (“vollständige gegensinnige Abhängigkeit”)
- ▶ Unter Unabhängigkeit ist die Copula $C(u_1, \dots, u_n) = \prod_{i=1}^n u_i$.

17. Copula

17.1 Definition und Eigenschaften

17.2 Spezielle Copulas

Gauss-Copula I

Beispiel 17.1

Sei $X = (X_1, X_2) \sim N_2(0, R)$ mit $R = \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}$ eine Korrelationsmatrix. Dann ist

$$\begin{aligned} F_{X_1, X_2}(x_1, x_2) &= \Phi_R(x_1, x_2) \\ &= \Phi_R(\Phi^{-1}(u_1), \Phi^{-1}(u_2)) \\ &= C_R^{Ga}(u_1, u_2) \end{aligned}$$

Dabei ist Φ_R die Verteilungsfunktion für $N_2(0, R)$.

C_R^{Ga} heißt Gauss-Copula.

Für $\rho = -1, 0, 1$ bekommt man entsprechend jeweils die Copula für vollständige gegensinnige Abhängigkeit, die Unabhängigkeitscopula, und die ko-monotone Copula.

Gauss-Copula II




Abbildung 42: Gauss-Copula für extreme Parameter und Datenbeispiele mit verschiedenen Randverteilungen

Archimedische Copulas I

Definition (Archimedische Copula)

Sei $\psi : [0, 1] \times \Theta \rightarrow \mathbb{R}_0^+$ eine stetige, streng fallende und konvexe Generator-Funktion mit $\psi(1; \theta) = 0$ und Pseudo-Umkehrfunktion

$$\psi^- = \begin{cases} \psi^{-1}(p, \theta) & 0 \leq p \leq \psi(0, \theta) \\ 0 & \text{sonst} \end{cases}.$$

Eine Copula heit archimedische Copula wenn sie sich darstellen lt als

$$C(u_1, \dots, u_n) = \psi^- \left(\sum_{i=1}^n \psi(u_i; \theta); \theta \right)$$

Archimedische Copulas II

Beispiel 17.2 (Archimedische Copulas)

Die Clayton-Copula ist asymmetrisch mit stärkerer Abhängigkeit für kleine u :

$\psi(u; \theta) = \frac{1}{\theta}(u^{-\theta} - 1)$; $\theta \in [-1, \infty) \setminus \{0\}$ ergibt

$$C(u_1, u_2) = (\max(u_1^{-\theta} + u_2^{-\theta} - 1, 0))^{-\frac{1}{\theta}}.$$

Die Gumbel-Copula ist asymmetrisch mit stärkerer Abhängigkeit für große u :

$\psi(u; \theta) = (-\log(u))^\theta$; $\theta \in [1, \infty)$ ergibt

$$C(u_1, u_2) = \exp\left(-\left((-\log(u_1))^\theta + (-\log(u_2))^\theta\right)^{1/\theta}\right).$$

Die Frank-Copula ist symmetrisch: $\psi(u; \theta) = -\log\left(\frac{\exp(-\theta u)-1}{\exp(-\theta)-1}\right)$; $\theta \in \mathbb{R} \setminus \{0\}$ ergibt

$$C(u_1, u_2) = -\frac{1}{\theta} \log\left(1 + \frac{(\exp(-\theta u_1)-1)(\exp(-\theta u_2)-1)}{\exp(-\theta)-1}\right).$$

Archimedische Copulas III




Abbildung 43: Archimedische Copulas und Datenbeispiele mit verschiedenen Randverteilungen