

# Teil IV: Konvergenz

## Fragen

- ▶ Was konvergiert eigentlich bei Zufallsvariablen bzw. Verteilungen?
- ▶ Welche Voraussetzungen haben Grenzwertsätze?

# Kapitel 14

## Konvergenz von Zufallsvariablen

### 14. Konvergenz von Zufallsvariablen

#### 14.1 Konvergenzarten

#### 14.2 Gesetze der großen Zahlen



# Ziel


Wir betrachten im Folgenden Folgen von Zufallsvariablen (von meßbaren Abbildungen)

$$X_1, X_2, \dots, X_n : \Omega \rightarrow \mathbb{R}$$

- ▶ Was passiert für  $n \rightarrow \infty$ ?
- ▶ Was bedeutet Konvergenz für Zufallsvariablen bzw. Verteilungen?
- ▶ Welche Arten von Konvergenzsätzen gibt es für Zufallsvariablen und welche Folgerungen?


# Beispiele I

```
x <- rnorm(1000, 0, 1)
plot(cumsum(x)/1:1000, type = "s", ylab = "Mittelwert")
```




# Beispiele II

```
y <- rt(1000, 2)
plot(cumsum(y)/1:1000, type = "s", ylab = "Mittelwert")
```



# Beispiele III


```
plot(ecdf(x), main = "Empirische Verteilungsfunktion")  
lines(seq(-5, 5, length = 1000), pnorm(seq(-5, 5, length = 1000)),  
      col = "blue", lty = 2)
```



# Beispiele IV


```
plot(ecdf(y), main = "Empirische Verteilungsfunktion", xlim = c(-10,
  10))
lines(seq(-5, 5, length = 1000), pt(seq(-5, 5, length = 1000), 2),
  col = "blue", lty = 2)
```

# Beispiele V




# Beispiele VI

```
rxquer <- function(i) return(mean(rnorm(1000)))  
xquer <- sapply(1:1000, rxquer)  
hist(xquer, breaks = 10, freq = FALSE)
```



# Beispiele VII


```
rxquer <- function(i) return(mean(rt(1000, 2)))  
xquer <- sapply(1:1000, rxquer)  
hist(xquer, breaks = 20, freq = FALSE)
```



# Beispiele VIII

```
z <- vector(length = 5000)
z[1] <- rnorm(1)
for (i in 2:5000) z[i] <- rnorm(1, 0.5 * z[i - 1])
plot(cumsum(z)/(1:5000), type = "s", ylab = "Mittelwert")
```

# Beispiele IX



## **14. Konvergenz von Zufallsvariablen**

### 14.1 Konvergenzarten

### 14.2 Gesetze der großen Zahlen

# Konvergenzarten I

Aus der Analysis kennen wir

## Definition 14.1

Sei  $(f_n)$  eine Funktionenfolge,  $f_n : M \longrightarrow \mathbb{R}$ ,  $\emptyset \neq M \subseteq \mathbb{R}$ .

a)  $(f_n)$  konvergiert punktweise gegen  $f : M \longrightarrow \mathbb{K}$  g.d.w.

$$\forall_{z \in M} \overline{\lim_{n \rightarrow \infty} f_n(z) = f(z)}, \text{ also genau dann wenn}$$

$$\forall_{z \in M} \forall_{\epsilon \in \mathbb{R}^+} \exists_{N \in \mathbb{N}} \forall_{n > N} |f_n(z) - f(z)| < \epsilon$$

$N$  hängt im Allgemeinen von  $z$  und  $\epsilon$  ab.

b)  $(f_n)$  konvergiert gleichmäßig gegen  $f : M \longrightarrow \mathbb{K}$  genau dann wenn

$$\forall_{\epsilon \in \mathbb{R}^+} \exists_{N \in \mathbb{N}} \forall_{n > N} \forall_{z \in M} |f_n(z) - f(z)| < \epsilon$$

$N$  hängt nicht von  $z$  ab, aber im Allgemeinen immer noch von  $\epsilon \rightarrow$   
Konvergenz ist gleichmäßig in  $z$ .

# Konvergenzarten II

Aus gleichmäßiger folgt punktweise Konvergenz, aber nicht umgekehrt.

# Konvergenzarten III

## Beispiel 14.1

$$\begin{aligned}f_n &: [0, 1] \rightarrow \mathbb{R} \\f_n(x) &:= x^n \\f(x) &:= \begin{cases} 0 & \text{für } 0 \leq x < 1 \\ 1 & \text{für } x = 1 \end{cases}\end{aligned}$$

Es gilt:  $f_n(x)$  konvergiert punktweise gegen  $f(x)$ , aber nicht gleichmäßig.

Für Zufallsvariablen ist sogar punktweise Konvergenz unter Umständen zu “stark”. Insbesondere interessieren uns Fälle mit Wahrscheinlichkeit 0 nicht.

- ▶ Wir definieren vier Arten von Konvergenz für Zufallsvariablen
  - ▶ Fast sichere Konvergenz
  - ▶ Konvergenz in Erwartung
  - ▶ Konvergenz in Wahrscheinlichkeit
  - ▶ Konvergenz in Verteilung (genauer im übernächsten Kapitel)

# Fast sichere Konvergenz I

## Idee:

- ▶ Wir betrachten eigentlich *punktweise Konvergenz* von  $X_n(\omega) \rightarrow X(\omega)$
- ▶ Aber “unmögliche” Ergebnisse interessieren uns nicht
- ▶ Sei also das Ereignis  $A$ : “Menge auf der  $X_n$  nicht gegen  $X$  konvergiert” eine  $\mathbb{P}$ -Nullmenge.
- ▶ Die Aussage “ $X_n$  konvergiert punktweise gegen  $X$ ” gilt also *fast überall*.

## Definition 14.2

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  Wahrscheinlichkeitsraum und  $X_i : \Omega \rightarrow \mathbb{R}$  ZV,  $i = 1, 2, \dots$

Dann konvergiert die Folge  $(X_n)_{n \in \mathbb{N}}$  fast sicher (engl. *convergence almost surely*) gegen  $X : \Omega \rightarrow \mathbb{R}$ , wenn

$$\mathbb{P} \left( \left\{ \omega \in \Omega \mid \lim_{n \rightarrow \infty} X_n(\omega) = X(\omega) \right\} \right) = 1;$$

Wir schreiben  $X_n \xrightarrow{\text{f.s.}} X$  oder  $X_n \rightarrow X$  mit Wahrscheinlichkeit 1.

# Fast sichere Konvergenz II

## Beispiel 14.2

Sei  $X_1 \sim U[0, 1]$  und  $X_n := X_1^n$ . Dann gilt  $X_n \xrightarrow{\text{f.s.}} 0$ .

**Beweis:** Sei o.b.d.A.  $([0, 1], \mathcal{B}_{[0,1]}, U[0, 1])$  und  $X_1(\omega) = \omega$ . Dann gilt für jedes  $0 \leq \omega < 1$ :  $\lim_{n \rightarrow \infty} \omega^n = 0$ . Für  $\omega = 1$  gilt  $\omega^n = 1^n = 1$ . Damit ist  $A := \{\omega \in \Omega \mid X(\omega)^n \not\rightarrow 0\} = \{1\}$ , eine Nullmenge bezüglich der stetigen Gleichverteilung.

- ▶ Im Beispiel konvergiert die Folge von Zufallsvariablen gegen einen Skalar (in der Praxis meistens der Fall).
- ▶ Wir können dies auch als Konvergenz gegen eine Zufallsvariable mit *Dirac-Verteilung* in diesem Skalar sehen.

# Konvergenz in Wahrscheinlichkeit I

## Idee:

Bei gleichmäßiger Konvergenz betrachten wir den Abstand der Folgenglieder von der Funktion, gegen die die Folge konvergiert:

$$\forall \varepsilon > 0 \exists N, \text{ so dass } \forall n \geq N : |f_n(x) - f(x)| < \varepsilon$$

- ▶ Für Zufallsvariablen reicht, dass dieser Abstand mit Wahrscheinlichkeit 1 kleiner als  $\varepsilon$  ist.
- ▶ Wir betrachten hier also das Ereignis  $A_n = \{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \varepsilon\}$ , also dass  $X_n$  von  $X$  um mehr als  $\varepsilon$  abweicht.
- ▶ Für beliebige kleine  $\varepsilon > 0$  konvergiere  $\mathbb{P}(A_n)$  gegen Null:

# Konvergenz in Wahrscheinlichkeit II

## Definition 14.3

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  ein Wahrscheinlichkeitsraum und  $X_i : \Omega \rightarrow \mathbb{R}$ ,  $i = 1, 2, \dots$

Dann konvergiert die Folge  $(X_n)_{n \in \mathbb{N}}$  in Wahrscheinlichkeit (engl. *convergence in probability*) gegen  $X : \Omega \rightarrow \mathbb{R}$ , falls

$$\mathbb{P}(|X_n - X| > \epsilon) \rightarrow 0 \quad \text{für } n \rightarrow \infty \quad \forall \epsilon > 0;$$

Wir schreiben  $X_n \xrightarrow{\mathbb{P}} X$  und sprechen auch von stochastischer Konvergenz.

## Beispiel 14.3

Wie oben  $X_1 \sim U[0, 1]$  und  $X_n := X_1^n$ . Dann gilt  $X_n \xrightarrow{\mathbb{P}} 0$ .

Sei o.b.d.A.  $([0, 1], \mathcal{B}_{[0,1]}, U[0, 1])$  und  $X(\omega) = \omega$ . Dann gilt

$$\mathbb{P}(|X_n - 0| > \epsilon) = \mathbb{P}(X_1^n > \epsilon) = \mathbb{P}(X_1 > \epsilon^{1/n}) = 1 - \epsilon^{1/n} \xrightarrow{n \rightarrow \infty} 0$$

# Konvergenz in Wahrscheinlichkeit III

Es ist kein Zufall, dass hier beide Konvergenzarten gelten:

## Satz 14.4

Sei  $(X_n)_{n \in \mathbb{N}}$ , Folge von Zufallsvariablen  $X_i : \Omega \rightarrow \mathbb{R}$  und  $X : \Omega \rightarrow \mathbb{R}$ . Dann gilt

$$X_n \xrightarrow{f.s.} X \implies X_n \xrightarrow{\mathbb{P}} X$$

# Konvergenz in Wahrscheinlichkeit IV

## Beweis:

Sei  $C = \{\omega \in \Omega \mid X_n(\omega) \not\rightarrow X(\omega)\}$ . Nach Def.  $X_n \xrightarrow{\text{f.s.}} X \iff \mathbb{P}(C) = 0$ .

Sei  $B_n = \bigcup_{m \geq n} \{\omega \in \Omega : |X_m(\omega) - X(\omega)| > \varepsilon\}$  für beliebiges  $\varepsilon > 0$ . Die Folge  $B_n$  ist monoton absteigend:  $B_n \supseteq B_{n+1} \supseteq \dots$ , und es gilt für

$$B = \bigcap_{n \geq 1} B_n : \quad B_n \downarrow B,$$

also auch  $\lim_{n \rightarrow \infty} \mathbb{P}(B_n) = \mathbb{P}(B)$ .

# Konvergenz in Wahrscheinlichkeit V

Zeige zunächst dass  $\mathbb{P}(B) = 0$ :

$$\begin{aligned} & \forall \omega \in \bar{C} : X_n(\omega) \rightarrow X(\omega) \\ \implies & \forall \omega \in \bar{C} : \exists n : |X_m(\omega) - X(\omega)| < \epsilon \quad \forall m \geq n \\ \implies & \forall \omega \in \bar{C} : \exists n : \omega \notin B_m \quad \forall m \geq n \\ \implies & \forall \omega \in \bar{C} : \omega \notin B \\ \implies & B \cap \bar{C} = \emptyset \implies B \subseteq C \implies P(B) \leq P(C) = 0 \end{aligned}$$

Da  $\{\omega \in \Omega : |X_n(\omega) - X(\omega)| > \epsilon\} \subseteq B_n$  und  $\lim_{n \rightarrow \infty} \mathbb{P}(B_n) = \mathbb{P}(B) = 0$ :

$$\mathbb{P}(|X_n - X| > \epsilon) \leq \mathbb{P}(B_n) \rightarrow 0 \implies X_n \xrightarrow{\mathbb{P}} X.$$

□

- ▶ Die Umkehrung gilt aber nicht!
- ▶ Die fast sichere Konvergenz ist also **stärker** als die Konvergenz in Wahrscheinlichkeit

# Konvergenz in Wahrscheinlichkeit VI

## Beispiel 14.4

Wahrscheinlichkeitsraum  $([0, 1], \mathcal{B}_{[0,1]}, U[0, 1])$ ,  $X(\omega) = \omega$ . Seien  $m \geq 0$ ,  $0 \leq k \leq 2^m - 1$  und  $n = 2^m + k$ . Sei weiter  $A_n = [k2^{-m}, (k+1)2^{-m})$  und  $X_n(\omega) = 1_{A_n}(\omega)$ .

Dann gilt für  $0 < \varepsilon < 1$ :  $\mathbb{P}[|X_n| > \varepsilon] = 2^{-m}$

Für  $n \rightarrow \infty \Rightarrow m \rightarrow \infty \Rightarrow 2^{-m} \rightarrow 0$ , also  $X_n \xrightarrow{\mathbb{P}} 0$ .

Aber  $X_n$  konvergiert nicht fast sicher, denn für jedes  $\omega \in [0, 1]$  konvergiert  $X_n(\omega)$  nicht.

# Konvergenz im Moment I

## Idee:

- ▶ Wir betrachten wieder den Abstand der Folgenglieder von der Zufallsvariablen, gegen die die Konvergenz erfolgt:  $|X_n - X|$
- ▶ Dabei handelt es sich um eine Zufallsvariable.
- ▶ Der Abstand muss nicht gegen Null konvergieren, aber zumindest im Erwartungswert sollte er gegen Null konvergieren:

## Definition 14.5

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  ein Wahrscheinlichkeitsraum und  $X_i : \Omega \rightarrow \mathbb{R}$ ,  $i = 1, 2, \dots$

Dann konvergiert die Folge  $(X_n)_{n \in \mathbb{N}}$  im  $r$ -ten Moment (engl. **convergence in the  $r$ -th moment**) oder im  $r$ -ten Mittel,  $r \geq 1$ , gegen  $X : \Omega \rightarrow \mathbb{R}$ , wenn  $\mathbb{E}(|X_n|^r) < \infty \forall n$  und

$$\mathbb{E}(|X_n - X|^r) \rightarrow 0 \quad \text{für } n \rightarrow \infty;$$

Wir schreiben  $X_n \xrightarrow{r} X$  oder  $X_n \xrightarrow{\mathcal{L}^r} X$

# Konvergenz im Moment II

## Beispiel 14.5

Sei  $r > s \geq 1$  und

$$X_n = \begin{cases} n & \text{mit Wahrscheinlichkeit } n^{-\frac{1}{2}(r+s)} \\ 0 & \text{mit Wahrscheinlichkeit } 1 - n^{-\frac{1}{2}(r+s)} \end{cases}$$

Es gilt

$$\mathbb{E}(|X_n|^s) = n^s \cdot n^{-\frac{1}{2}(r+s)} = n^{\frac{1}{2}(s-r)} \rightarrow 0,$$

da  $s < r$ , also  $X_n \xrightarrow{s} 0$ .

Es gilt weiterhin

$$\mathbb{E}(|X_n|^r) = n^r \cdot n^{-\frac{1}{2}(r+s)} = n^{\frac{1}{2}(r-s)} \rightarrow \infty,$$

da  $r > s$ .

# Konvergenz im Moment III

## Satz 14.6

Sei  $(X_n)_{n \in \mathbb{N}}$  ein Folge von Zufallsvariablen  $X_i : \Omega \rightarrow \mathbb{R}$  und  $X : \Omega \rightarrow \mathbb{R}$ . Dann gilt

$$\forall r > s \geq 1 : X_n \xrightarrow{r} X \implies X_n \xrightarrow{s} X$$

### Beweis:

Voraussetzung ist:

$$\mathbb{E}(|X_n - X|^r) = \|X_n - X\|_r^r \rightarrow 0.$$

Nach Satz 8.19 gilt für  $r > s > 1$  mit  $c \geq 0$ :

$$\|X_n - X\|_r^r \geq c \|X_n - X\|_s^s \rightarrow 0$$



# Konvergenz im Moment IV

Vielleicht etwas überraschend ist die Konvergenz im Moment stärker als die Konvergenz in Wahrscheinlichkeit:

## Satz 14.7

Sei  $(X_n)_{n \in \mathbb{N}}$  eine Folge von Zufallsvariablen  $X_i : \Omega \rightarrow \mathbb{R}$  und  $X : \Omega \rightarrow \mathbb{R}$ . Dann gilt für  $r \geq 1$ :

$$X_n \xrightarrow{r} X \implies X_n \xrightarrow{\mathbb{P}} X$$

### Beweis:

Wegen Satz 14.6 reicht es,  $r = 1$  zu nehmen. Dann gilt

$$\mathbb{P}(|X_n - X| > \epsilon) \leq \frac{\mathbb{E}(|X_n - X|)}{\epsilon},$$

in dem wir in die Markov-Ungleichung  $(X_n - X)$  einsetzen. □

# Zusammenhänge im Überblick I

- ▶ Fast sichere Konvergenz  $\implies$  Konvergenz in Wahrscheinlichkeit
- ▶ Konvergenz im Moment  $\implies$  Konvergenz in Wahrscheinlichkeit
- ▶ Für  $r > s$ : Konvergenz im  $r$ -ten Moment  $\implies$  Konvergenz im  $s$ -ten Moment

## Satz 14.8

*Konvergiert eine Folge von Zufallsvariablen  $X_n$  im  $r$ -ten Mittel gegen  $X$  und gilt*

$$\sum_{n=1}^{\infty} \mathbb{E}(|X_n - X|^r) < \infty$$

*dann konvergiert die Folge auch fast sicher gegen  $X$ .*

# Zusammenhänge im Überblick II

## Beweis:

Für jedes  $\varepsilon > 0$  gilt nach der Markov-Ungleichung Satz 8.13

$$P(|X_n - X| > \varepsilon) \leq \frac{E(|X_n - X|^r)}{\varepsilon^r}$$

Ist nun

$$\sum_{n=1}^{\infty} E(|X_n - X|^r) < \infty,$$

so folgt

$$\sum_{n=1}^{\infty} P(|X_n - X| > \varepsilon) < \infty.$$

Nach dem Borel–Cantelli-Lemma tritt das Ereignis

$$|X_n - X| > \varepsilon$$

# Zusammenhänge im Überblick III

nur endlich oft auf (fast sicher). Da dies für jedes  $\varepsilon > 0$  gilt, folgt  $X_n \xrightarrow{\text{f.s.}} X$ .  $\square$

## Satz 14.9 (Borel–Cantelli-Lemma I)

Sei  $(A_n)_{n \in \mathbb{N}}$  eine Folge von Ereignissen in einem Wahrscheinlichkeitsraum. Es gilt

$$\sum_{n=1}^{\infty} P(A_n) < \infty \implies P(A_n \text{ tritt unendlich oft auf}) = 0$$

### Beweis:

„Unendlich oft“ bedeutet

$$A_n \text{ „unendlich oft“} = \bigcap_{k=1}^{\infty} \bigcup_{n \geq k} A_n =: \limsup_{n \rightarrow \infty} A_n$$

Für jedes feste  $k$  gilt wegen der  $\sigma$ -Subadditivität (Satz 3.28):

# Zusammenhänge im Überblick IV

$$P\left(\bigcup_{n \geq k} A_n\right) \leq \sum_{n \geq k} P(A_n).$$

Da die Reihe  $\sum_{n=1}^{\infty} P(A_n)$  konvergiert, gilt

$$\sum_{n \geq k} P(A_n) \longrightarrow 0 \quad (k \rightarrow \infty).$$

Somit folgt

$$P\left(\bigcup_{n \geq k} A_n\right) \longrightarrow 0.$$

# Zusammenhänge im Überblick V

Wegen der Stetigkeit des Wahrscheinlichkeitsmaßes von oben erhalten wir

$$A_n \text{ „unendlich oft“} = \lim_{k \rightarrow \infty} P\left(\bigcup_{n \geq k} A_n\right) = 0.$$



## **14. Konvergenz von Zufallsvariablen**

### 14.1 Konvergenzarten

### 14.2 Gesetze der großen Zahlen

# Unabhängig und identisch verteilt I

## Definition 14.10

Eine Familie von Zufallsvariablen  $X_i : \Omega \rightarrow \Omega_i, i \in I$  heißt unabhängig und identisch verteilt (u.i.v.), wenn die beiden folgenden Kriterien erfüllt sind:

- ▶ Die Familie  $X_i : \Omega \rightarrow \Omega_i, i \in I$  ist stochastisch unabhängig, siehe Def. 4.20
  - ▶ Die Zufallsvariablen haben alle dieselbe Verteilung  $X_i \sim F$ .
- 
- ▶ In der Regel benutzt man die Abkürzung des englischen Ausdruck *independent and identically distributed*, i.i.d. oder **iid**.

# Unabhängig und identisch verteilt II

Diese Annahme bildet insbesondere die Standardituation ab, in der  $X_1, \dots, X_n$  eine Stichprobe eines Merkmals  $\tilde{X}$  bei einer einfachen Zufallsauswahl sind.

**Beispiel**  $\tilde{X}$  Einkommen,  $n$  Personen zufällig ausgewählt

|          |               |          |                              |
|----------|---------------|----------|------------------------------|
| $X_1$    | Einkommen der | ersten   | zufällig ausgewählten Person |
| $X_2$    | Einkommen der | zweiten  | zufällig ausgewählten Person |
| $\vdots$ |               | $\vdots$ |                              |
| $X_n$    | Einkommen der | $n$ -ten | zufällig ausgewählten Person |

# Schwaches Gesetz der großen Zahlen I

## Satz 14.11 (Schwaches Gesetz der großen Zahlen)

Seien  $X_1, \dots, X_n$  unabhängig und identisch verteilt mit  $\mathbb{E}(X_i) = \mu$  und  $\text{Var}(X_i) = \sigma^2 < \infty \quad \forall i = 1, \dots, n$ .

Dann gilt

$$\bar{X}_n := \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{\mathbb{P}} \mu.$$

# Schwaches Gesetz der großen Zahlen II

**Beweis:**

$\bar{X}_n \xrightarrow{2} \mu$  denn

$$\mathbb{E}(\bar{X}_n) = \frac{1}{n} \sum_{i=1}^n (\mathbb{E}(X_i)) = \frac{1}{n} \cdot n\mu = \mu$$

und

$$\mathbb{E}(|\bar{X}_n - \mu|^2) = \text{Var}(\bar{X}_n) = \frac{1}{n^2} n\sigma^2 = \frac{1}{n}\sigma^2 \rightarrow 0$$

$\implies \bar{X}_n \xrightarrow{\mathbb{P}} \mu$  wegen Satz 14.7.



# Schwaches Gesetz der großen Zahlen III


## Beispiel 14.6

$X_i \sim \text{Po}(\lambda)$  stochastisch unabhängig  $\implies \mathbb{E}(X_i) = \lambda$ ,

$\text{Var}(X_i) = \lambda, i = 1, \dots, n$  und  $\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{\mathbb{P}} \lambda$

```
set.seed(1)
N <- 500
x <- rpois(N, 2.5)
xbar <- cumsum(x)/(1:N)
plot(xbar, pch = 19, cex = 0.2, ylab = expression(bar(x)))
lines(c(0, N), rep(2.5, 2), lty = 2, col = "blue", lwd = 2)
```

# Schwaches Gesetz der großen Zahlen IV



# Theorem von Bernoulli I


Spezialfall des Gesetzes der großen Zahlen: Wir betrachten  $n$  0/1-Experimente mit Erfolgswahrscheinlichkeit  $\pi$ . Das heißt  $X_i \sim B(1, \pi)$ . Dann ist  $\bar{X}$  die *relative Häufigkeit* der Erfolge und es gilt

$$\bar{X}_n \xrightarrow{\mathbb{P}} \pi$$

Die relative Häufigkeit konvergiert also gegen die wahre Wahrscheinlichkeit.

# Theorem von Bernoulli II

```
set.seed(1)
x <- cumsum(rbinom(500, 1, 0.3))/(1:500)
plot(x, pch = 19, cex = 0.2, ylab = expression(bar(x)))
lines(c(0, 1000), rep(0.3, 2), lty = 2, col = "blue", lwd = 2)
```



# Frequentismus

## Folgerungen

Frequentische Interpretation der Wahrscheinlichkeit: Wahrscheinlichkeiten werden als Grenzwert der relativen Häufigkeit aufgefasst.

Frequentische Interpretation des Erwartungswerts: Erwartungswert ist Grenzwert des Mittelwerts.

# Satz von Khinchine I

Satz von Khinchine (ohne Beweis): Die Voraussetzung  $\text{Var}(X_i) = \sigma^2$  ist nicht nötig! Es reicht, dass  $\mathbb{E}(X_i)$  existiert. Weiterhin aber i.i.d. nötig.

Zum Beispiel  $X_i \sim t(n)$  (Def. 19.12)

- ▶  $\mathbb{E}(X_i) = 0$  für  $n > 1$ , für  $n = 1$  existiert der Erwartungswert nicht.
- ▶  $\text{Var}(X_i) = \frac{n}{n-2}$  für  $n > 2$ , für  $n \leq 2$  existiert die Varianz nicht.

# Satz von Khinchine II


```
set.seed(172)
N <- 10000
x3 <- rt(N, 3)
mean(x3)
```

```
## [1] -0.01566653
```

```
var(x3)
```

```
## [1] 2.521877
```

# Satz von Khinchine III




# Satz von Khinchine IV

```
x2 <- rt(N, 2)
mean(x2)
```

```
## [1] 0.02320655
```

```
var(x2)
```

```
## [1] 7.795786
```




# Gegenbeispiel I

## Beispiel 14.7

$X_i \sim \text{Cauchy}$  iid. Gesetz der großen Zahlen ist für  $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$  nicht anwendbar, da die Cauchy-Verteilung keinen Erwartungswert hat (siehe Beispiel 8.5)!

# Gegenbeispiel II



# Starkes Gesetz der großen Zahlen I

## Satz 14.12 ((Zweites) Starkes Gesetz der großen Zahlen nach Kolmogorov)

Seien  $X_1, \dots, X_n$  unabhängige, identische verteilte Zufallsvariablen. Dann gilt: Existiert der Erwartungswert  $\mathbb{E}(X_1)$  und ist er endlich (d.h.  $\mathbb{E}(|X_1|) < \infty$ ), so

konvergiert  $\bar{X}_n := \frac{1}{n} \sum_{i=1}^n X_i$   $\mathbb{P}$ -fast sicher mit

$$\lim_{n \rightarrow \infty} \bar{X}_n = \mathbb{E}(X_1) \quad \mathbb{P} - f.s.$$

Ist  $\mathbb{E}(X_1) = \infty$ , so konvergiert  $\bar{X}_n$   $\mathbb{P}$ -fast sicher nicht gegen einen endlichen Grenzwert.

**Beweis** siehe Henze (2019), Seite 200ff.

- Voraussetzungen von starken und schwachem Gesetz sind identisch (i.i.d. und  $\mathbb{E}(X) < \infty$ )

# Monte-Carlo-Verfahren I

**Ziel:** Wir wollen numerisch ein Integral (Fläche unter der Funktion) über die Funktion  $f : (0, 1) \rightarrow (0, 1)$  berechnen. O.B.d.A. sei  $f : (0, 1) \rightarrow (0, 1)$ .

Seien  $(X_i, Y_i)_{i=1, \dots, n}$  unabhängige, gleichverteilte Zufallsvariablen auf  $\Omega = [0, 1) \times [0, 1)$ . Sei  $B$  eine Borelmenge ( $B \in \mathcal{B}_\Omega$ ) und  $Z_i = \mathbb{I}_B(X_i, Y_i)$ . Es gilt

$$p := \mathbb{P}(Z_i = 1) = \mathbb{P}((X_i, Y_i) \in B) = \int_B 1 \, d\lambda^2$$

Die  $Z_i$  sind unabhängig und identisch Bernoulli-verteilt mit  $p = \mathbb{P}(Z_i = 1)$ , daher  $\mathbb{E}(Z_1) = p$ , also Fläche von  $B$ .


# Monte-Carlo-Verfahren II

## Algorithmus zur Monte-Carlo-Integration

- ▶ Ziehe  $n$  unabhängige gleichverteilte Zufallszahlen  $(X_i, Y_i)$  auf  $[0, 1)^2$
- ▶ Stelle fest, ob  $(X_i, Y_i)$  in  $B$
- ▶ Gesetz der großen Zahlen sagt:

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n Z_i = p$$

# Monte-Carlo-Verfahren III



# Monte-Carlo-Verfahren IV

|                   | Schätzung |
|-------------------|-----------|
| N=10              | 0.8000000 |
| N=10 <sup>2</sup> | 0.5700000 |
| N=10 <sup>3</sup> | 0.6540000 |
| N=10 <sup>4</sup> | 0.6460000 |
| N=10 <sup>5</sup> | 0.6361100 |
| N=10 <sup>6</sup> | 0.6371100 |
| N=10 <sup>7</sup> | 0.6366096 |
| Wahrer Wert       | 0.6366198 |

# Allgemeine Gesetze der großen Zahlen I

## Definition 14.13

Gegeben sei eine Folge von Zufallsvariablen  $(X_n)_{n \in \mathbb{N}}$ , für deren Erwartungswert gelte  $\mathbb{E}(|X_n|) < \infty$  für alle  $n \in \mathbb{N}$ . Man sagt, die Folge genügt dem starken bzw. schwachen Gesetz der großen Zahlen (engl. **strong or weak law of large numbers**, **LLN**), wenn die Folge

$$\bar{X}_n := \frac{1}{n} \sum_{i=1}^n (X_i - \mathbb{E}(X_i))$$

der zentrierten Mittelwerte fast sicher bzw. in Wahrscheinlichkeit gegen 0 konvergiert.

# Allgemeine Gesetze der großen Zahlen II

Ohne Beweise einige Gesetze der großen Zahlen, die nicht Unabhängigkeit oder identische Verteilung voraussetzen.

## **Satz 14.14 (Starkes Gesetz der großen Zahl von Etemadi)**

*Ist die Folge von Zufallsvariablen  $(X_n)_{n \in \mathbb{N}}$  identisch verteilt und paarweise unabhängig mit  $\mathbb{E}(|X_n|) < \infty$ , so genügt sie dem starken Gesetz der großen Zahlen.*

# Allgemeine Gesetze der großen Zahlen III

## Satz 14.15 (Erstes Gesetz der großen Zahlen von Kolmogorow)

*Gilt für eine unabhängige Folge von Zufallsvariablen  $(X_n)_{n \in \mathbb{N}}$  mit endlicher Varianz die Kolmogorov-Bedingung*

$$\sum_{n=1}^{\infty} \frac{\text{Var}(X_n)}{n^2} < \infty$$

*so genügt sie dem starken Gesetz der großen Zahlen.*

# Allgemeine Gesetze der großen Zahlen IV

## Satz 14.16 (von Cantelli)

*Ist eine Folge von Zufallsvariablen  $(X_n)_{n \in \mathbb{N}}$  unabhängig, habe endliche vierte Momente und seien die zentralen vierten Momente gleichmäßig beschränkt*

$$\sup_{n \in \mathbb{N}} \mathbb{E}((X_n - \mathbb{E}(X_n))^4) < \infty$$

*so genügt sie dem starken Gesetz der großen Zahlen.*

# Allgemeine Gesetze der großen Zahlen V

## Beispiel 14.8

In der Finanzmathematik bezeichnet man mit *Market Microstructure Noise* kleine Kursbewegungen, verursacht durch zufällige Trades bzw. Trade-Artifakte. Sie haben einen Mittelwert von 0, aber keine konstante Varianz. In der Regel gilt aber die Kolmogorov-Bedingung

$$\sum_{n=1}^{\infty} \frac{\text{Var}(X_n)}{n^2} < \infty,$$

so dass das Gesetz der großen Zahlen gilt, sprich der Mittelwert gegen 0 konvergiert.

# Allgemeine Gesetze der großen Zahlen VI

## Beispiel 14.9

Eine Versicherung hat viele Kunden, die im Laufe des Jahres Schadensfälle melden. Sei  $X_n$  die Schadenssumme des  $n$ -ten Kunden mit:

- ▶ Paarweise unabhängigen Schadenshöhen (Schäden sind nicht völlig unabhängig, aber direkte Abhängigkeiten bestehen nur zwischen einzelnen Gruppen, z. B. innerhalb von Haushalten).
- ▶ Gemeinsamer Erwartungswert:  $\mathbb{E}[X_n] = \mu$  und eine gleichmäßig beschränkte zweite Momentenbedingung.

Die durchschnittliche Schadenshöhe konvergiert also nach dem Satz von Etemadi:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \rightarrow \mu \text{ f.s.}$$

- ▶ Für abhängige Zufallsvariablen gibt es Ergodensätze, siehe auch Kapitel stochastische Prozesse.

# Multivariates Gesetz der großen Zahlen

## Satz 14.17 (Multivariates starkes Gesetz der großen Zahlen)

Seien  $\mathbf{X}_1, \mathbf{X}_2, \dots$  mit  $\mathbf{X}_i = (X_{i1}, \dots, X_{ip})$  iid reelwertige Zufallsvektoren auf  $\mathbb{R}^p$  und  $\mu := \mathbb{E}(\|\mathbf{X}_1\|) < \infty$ . Dann gilt für alle  $j = 1, \dots, p$

$$\bar{X}_j := \frac{1}{n} \sum_{i=1}^n X_{ij} \xrightarrow{\text{f.s.}} \mu_j.$$

**Beweisidee:** komponentenweise Anwendung des eindimensionalen Gesetzes der großen Zahlen.

# Kapitel 15

## Verteilungskonvergenz

### 15. Verteilungskonvergenz

15.1 Konvergenz in Verteilung

15.2 Zusammenhang Konvergenzarten

15.3 Zentrale Grenzwertsätze

15.4 Fundamentalsatz der Statistik



# Verteilungskonvergenz

*Far better an approximate answer to the right question, which is often vague, than the exact answer to the wrong question, which can always be made precise.*

*John Tukey (1915–2000)*

*Ann. Math. Statist. 33(1): 1-67 (1962)*

## **15. Verteilungskonvergenz**

15.1 Konvergenz in Verteilung

15.2 Zusammenhang Konvergenzarten

15.3 Zentrale Grenzwertsätze

15.4 Fundamentalsatz der Statistik

# Konvergenz in Verteilung I

## Definition 15.1

Sei  $(\Omega, \mathcal{F}, \mathbb{P})$  ein Wahrscheinlichkeitsraum und  $X_i : \Omega \rightarrow \mathbb{R}$  Zufallsvariablen mit Verteilungsfunktionen  $F_i$ ,  $i = 1, 2, \dots$

Dann konvergiert die Folge  $(X_n)_{n \in \mathbb{N}}$  in Verteilung (engl. *convergence in distribution*) gegen  $X : \Omega \rightarrow \mathbb{R}$  mit Verteilungsfunktion  $F$ , falls

$$\lim_{n \rightarrow \infty} F_n(x) = F(x)$$

für alle  $x$ , in denen  $F$  stetig ist.

Wir schreiben  $X_n \xrightarrow{D} X$ . Man spricht auch von schwacher Konvergenz.

# Konvergenz in Verteilung II

## Beispiel 15.1

- ▶ Sei  $X_n \sim U(0, 1)$ , also für  $0 \leq x \leq 1 : F_{X_n}(x) = x$ .
  - ▶ Sei  $Z = 1 - X_1$ , also für  $0 \leq x \leq 1 : F_Z(x) = x$ .
  - ▶ Dann gilt offensichtlich  $X_n \xrightarrow{D} Z$ , aber auch  $X_n \xrightarrow{D} X_1$
- 
- ▶ Im Gegensatz zum letzten Kapitel konvergiert die Folge nicht gegen einen Skalar, sondern gegen eine Zufallsvariable.
  - ▶ Die Zufallsvariable ist aber nicht eindeutig, aber deren Verteilung

Wir schreiben  $X_n \xrightarrow{D} U(0, 1)$  oder  $X_n \overset{a}{\sim} U(0, 1)$ .

# Poisson-Approximation I

## Satz 15.2

Sei  $X_i \sim B(n, p_n)$  und  $(p_n)_{n \geq 1}$  eine Folge mit

$$\lim_{n \rightarrow \infty} (np_n) = \lambda$$

für ein  $\lambda > 0$ . Dann gilt

$$X_i \xrightarrow{D} \text{Po}(\lambda).$$

# Poisson-Approximation II

## Beweis:

Statt mit der Verteilungsfunktion können wir hier auch mit der (Wahrscheinlichkeits-)Dichte arbeiten:

$$\begin{aligned}\lim_{n \rightarrow \infty} P(X_n = k) &= \lim_{n \rightarrow \infty} \binom{n}{k} p_n^k (1 - p_n)^{n-k} \\&= \lim_{n \rightarrow \infty} \frac{n!}{k! (n-k)!} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \\&= \lim_{n \rightarrow \infty} \left(\frac{\lambda^k}{k!}\right) \left(\frac{n(n-1)(n-2) \cdots (n-k+1)}{n^k}\right) \left(1 - \frac{\lambda}{n}\right)^n \left(1 - \frac{\lambda}{n}\right)^{-k} \\&= \frac{\lambda^k}{k!} \cdot \lim_{n \rightarrow \infty} \underbrace{\left(\frac{n}{n} \cdot \frac{n-1}{n} \cdot \frac{n-2}{n} \cdots \frac{n-k+1}{n}\right)}_{\rightarrow 1} \underbrace{\left(1 - \frac{\lambda}{n}\right)^n}_{\rightarrow e^{-\lambda}} \underbrace{\left(1 - \frac{\lambda}{n}\right)^{-k}}_{\rightarrow 1} \\&= \frac{\lambda^k}{k!} \exp(-\lambda).\end{aligned}$$




# Poisson-Approximation III

Diese asymptotische Aussage lässt sich auch schon für endliche  $n$  anwenden. Es lässt sich sogar die Güte der Approximation abschätzen:

$$\sum_{k=0}^{\infty} |\mathrm{B}(n, p_n)(\{k\}) - \mathrm{Po}(np_n)(\{k\})| \leq 2np_n^2.$$

Die Approximation ist also besonders gut für kleine  $p$ .

# Poisson-Approximation IV



**Abbildung 27:** Oben: Verteilungsfunktion der Binomial- und der approximierenden Poisson-Verteilungen, unten: Differenz der Verteilungsfunktionen.

## **15. Verteilungskonvergenz**

15.1 Konvergenz in Verteilung

15.2 Zusammenhang Konvergenzarten

15.3 Zentrale Grenzwertsätze

15.4 Fundamentalsatz der Statistik

# Zusammenhang Konvergenzarten I

## Satz 15.3

Sei  $(X_n)_{n \in \mathbb{N}}$  eine Folge von Zufallsvariablen  $X_i : \Omega \rightarrow \mathbb{R}$  und  $X : \Omega \rightarrow \mathbb{R}$ . Dann gilt

$$X_n \xrightarrow{\mathbb{P}} X \implies X_n \xrightarrow{D} X$$

## Beweis:

Vorraussetzung:  $X_n \xrightarrow{\mathbb{P}} X$ .

Sei  $F_n(x) = \mathbb{P}(X_n \leq x)$ ;  $F(x) = \mathbb{P}(X \leq x)$ . Es gilt für  $\epsilon > 0$ :

# Zusammenhang Konvergenzarten II

$$\begin{aligned}F_n(x) &= \mathbb{P}(X_n \leq x) = \mathbb{P}(X_n \leq x, X \leq x + \epsilon) + \mathbb{P}(X_n \leq x, X > x + \epsilon) \\&\leq \mathbb{P}(X \leq x + \epsilon) + \mathbb{P}(X_n - X \leq x - X, x - X < -\epsilon) \\&\leq F(x + \epsilon) + \mathbb{P}(X_n - X < -\epsilon) \\&\leq F(x + \epsilon) + \mathbb{P}(X_n - X < -\epsilon) + \mathbb{P}(X_n - X > \epsilon) \\&\leq F(x + \epsilon) + \mathbb{P}(|X_n - X| > \epsilon)\end{aligned}$$

$$\begin{aligned}\text{und } F(x - \epsilon) &= \mathbb{P}(X \leq x - \epsilon) \\&= \mathbb{P}(X \leq x - \epsilon, X_n \leq x) + \mathbb{P}(X \leq x - \epsilon, X_n > x) \\&\leq F_n(x) + \mathbb{P}(|X_n - X| > \epsilon) \quad (\text{Umformung s.o.})\end{aligned}$$

Zusammen:

$$F(x - \epsilon) - \mathbb{P}(|X_n - X| > \epsilon) \leq F_n(x) \leq F(x + \epsilon) + \mathbb{P}(|X_n - X| > \epsilon)$$

# Zusammenhang Konvergenzarten III

Für  $n \rightarrow \infty$ :

$$F(x - \epsilon) - \underbrace{\mathbb{P}(|X_n - X| > \epsilon)}_{\rightarrow 0} \leq F_n(x) \leq F(x + \epsilon) + \underbrace{\mathbb{P}(|X_n - X| > \epsilon)}_{\rightarrow 0}$$
$$\implies F(x - \epsilon) \leq \lim_{n \rightarrow \infty} F_n(x) \leq F(x + \epsilon)$$

Falls  $F$  in  $x$  stetig:

$$F(x) \leq \lim_{n \rightarrow \infty} F_n(x) \leq F(x)$$
$$\implies F(x) = \lim_{n \rightarrow \infty} F_n(x) \implies X_n \xrightarrow{D} X$$



# Zusammenhang Konvergenzarten IV

Also:

- ▶ Stärkste Konvergenzarten: **fast sicher** und **im Moment**
- ▶ schwächer: **in Wahrscheinlichkeit** (schwaches Gesetz der großen Zahlen)
- ▶ am schwächsten: **in Verteilung** (manchmal auch schwache Konvergenz genannt)

Achtung! In der Regel:

- ▶ Konvergenz fast sicher, im Moment und in Wahrscheinlichkeit gegen Delta-verteilte Zufallsvariable, also gegen Skalar
- ▶ Konvergenz in Verteilung gegen mehrere Zufallsvariablen identischer Verteilung, also gegen Verteilung

# Satz von Slutsky I

## Satz 15.4

Seien  $X_n \xrightarrow{\mathcal{D}} X$ ,  $A_n \xrightarrow{\mathbb{P}} a$  und  $B_n \xrightarrow{\mathbb{P}} b$ . Dann gilt:

$$A_n + B_n X_n \xrightarrow{\mathcal{D}} a + bX$$

Es gilt also auch für  $b \neq 0$ :

$$X_n \xrightarrow{\mathcal{D}} X \implies a + bX_n \xrightarrow{\mathcal{D}} a + bX$$

# Satz von Slutsky II

## Beweis:

Hier nur eine Beweisskizze unter Unabhängigkeit:

Sei  $Y_n \xrightarrow{\mathcal{D}} Y$  unabhängig von  $X_n, X$ . Dann

$$\varphi_{(X_n, Y_n)}(s) \stackrel{\text{Satz 10.8}}{=} \varphi_{X_n}(s) \cdot \varphi_{Y_n}(s) \stackrel{\text{Satz 6.10}}{\implies} \varphi_X(t) \cdot \varphi_Y(t) = \varphi_{(X, Y)}(t)$$

Mit  $Y_n \xrightarrow{\mathbb{P}} a$  und Faltung folgt  $X_n + Y_n \rightarrow X + a$ , analog für  $Y_n \xrightarrow{\mathbb{P}} b$ . □

# Satz von Slutsky III



**Jewgeni Jewgenjewitsch Sluzki**  
(7./19. April 1880 bis 10. März  
1948)

Geboren in Jaroslawl. Studierte Mathematik und Physik in Kiew, wurde 1902 wegen revolutionärer Bestrebungen exmatrikuliert. Anschliessend Studium des Ingenieurwesens an der heutigen TU München. 1905 nahm er sein Studium in Kiew wieder auf. Entwickelte in seiner Abschlussarbeit 1911 die Slutsky-Zerlegung zur Bestimmung der hicksschen Nachfragefunktion, noch heute wichtiges Instrument der Mikroökonomie. 1915 Professur in Kiew, ab 1926 in Moskau.

## **15. Verteilungskonvergenz**

15.1 Konvergenz in Verteilung

15.2 Zusammenhang Konvergenzarten

15.3 Zentrale Grenzwertsätze

15.4 Fundamentalsatz der Statistik

# Zentraler Grenzwertsatz I

## Satz 15.5 (Zentraler Grenzwertsatz (engl. central limit theorem, CLT) von Lindenber-Lévy)

Seien  $X_i, i = 1, \dots$  unabhängig und identisch verteilt (independent identically distributed, iid) mit  $\mathbb{E}(X_i) = \mu$  und  $\text{Var}(X_i) = \sigma^2 < \infty \forall i = 1, \dots$ . Dann gilt

$$\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} \xrightarrow{\mathcal{D}} N(0, 1)$$

bzw.

$$\sqrt{n}(\bar{X} - \mu) \xrightarrow{\mathcal{D}} N(0, \sigma^2)$$

# Zentraler Grenzwertsatz II

## Beweis:

*Der folgende Beweis setzt die Existenz der momenterzeugenden Funktion in einer Umgebung um 0 voraus. Allgemeiner lässt sich der ZGWS mit der charakteristischen Funktion beweisen.*

Sei  $Y_i = \frac{X_i - \mu}{\sigma}$ , also  $\mathbb{E}(Y_i) = 0$ ,  $\text{Var}(Y_i) = 1$  und  $Z_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n Y_i$ .

Sei  $K_X(s) = \log M_X(s)$ . Benutze

$$\left. \frac{\partial^n K_X(s)}{\partial^n s} \right|_{s=0} = \left. \frac{\partial^n \log(M_X(s))}{\partial^n s} \right|_{s=0} = \frac{1}{M_X(s)^n} \left. \frac{\partial^n M_X(s)}{\partial^n s} \right|_{s=0} = \mathbb{E}(X^n)$$

für  $n \in \{1, 2\}$  da  $M(0) \equiv 1$ .

# Zentraler Grenzwertsatz III

$$\begin{aligned} M_{Z_n}(t) &= \mathbb{E}(\exp(tZ_n)) = \mathbb{E}\left(\exp\left(\frac{t}{\sqrt{n}} \sum_{i=1}^n Y_i\right)\right) \\ &\stackrel{stu}{=} \prod_{i=1}^n \mathbb{E}\left(\exp\left(\frac{t}{\sqrt{n}} Y_i\right)\right) \stackrel{iid}{=} M_Y\left(\frac{t}{\sqrt{n}}\right)^n \end{aligned}$$

$$\text{also } K_{Z_n}(t) = \log M_{Z_n}(t) = n \log M_Y\left(\frac{t}{\sqrt{n}}\right) = n K_Y\left(\frac{t}{\sqrt{n}}\right)$$

# Zentraler Grenzwertsatz IV

$$\begin{aligned}\lim_{n \rightarrow \infty} K_{Z_n}(t) &= \lim_{n \rightarrow \infty} n K_Y \left( \frac{t}{\sqrt{n}} \right) \\ &= \lim_{\epsilon \rightarrow 0} \frac{K_Y(\epsilon t)}{\epsilon^2} \quad (\epsilon := \frac{1}{\sqrt{n}}) \\ &= \lim_{\epsilon \rightarrow 0} \frac{t K'_Y(\epsilon t)}{2\epsilon} \quad (\text{L'Hospital da } \frac{0}{0}) \\ &= \lim_{\epsilon \rightarrow 0} \frac{t^2 K''_Y(\epsilon t)}{2} = \frac{t^2}{2} \quad \text{da } K''_Y(0) = \text{Var}(Y) = 1.\end{aligned}$$

Behauptung folgt aus  $M_{N(0,1)}(t) = \exp\left(\frac{t^2}{2}\right)$ .



# Beispiele I


## Beispiel 15.2 (Diskrete Gleichverteilung (Würfelwurf))

Sei  $X_i \sim U\{1, 2, 3, 4, 5, 6\}$ . Dann ist  $\mathbb{E}(X_i) = 3.5$  und  $\text{Var}(X_i) = \frac{35}{12}$ . Sei

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\sqrt{n} \frac{\bar{X} - 3.5}{\sqrt{35/12}} \xrightarrow{D} N(0, 1)$$

# Beispiele II



**Abbildung 28:** Verteilung des Mittelwerts bei  $n$ -maligem Würfeln

# Beispiele III

## Beispiel 15.3

Sei  $X_1, \dots, X_n$  iid mit  $\mathbb{E}(X_i) = 0$ ,  $\text{Var}(X_i) = \sigma^2$  und  $\text{Var}(X_i^2) = \tau^2 < \infty$ .

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \xrightarrow{\mathbb{P}} \sigma^2$$

*Frage:* Konvergiert  $\sqrt{n}(S^2 - \sigma^2)$ ?

$S^2$  hängt nicht von  $\mu$  ab, also o.B.d.A.  $\mu = 0$ .

Der Zentrale Grenzwertsatz sagt:

$$\sqrt{n} \left( \frac{1}{n} \sum_{i=1}^n X_i^2 - \sigma^2 \right) \xrightarrow{\mathcal{D}} N(0, \tau^2)$$

Gesetz der großen Zahlen:  $\bar{X}^2 \xrightarrow{\mathbb{P}} 0$  Damit folgt:

$$\sqrt{n}(S^2 - \sigma^2) = \sqrt{n} \left( \frac{1}{n} \sum_{i=1}^n X_i^2 - \underbrace{\bar{X}^2}_{\rightarrow 0} - \sigma^2 \right) \xrightarrow{\mathcal{D}} N(0, \tau^2)$$

# Asymptotik und Approximation I

## Beispiel 15.4 (Binomialverteilung (vgl. Statistik I))

Sei  $X_i \sim B(1, p)$ ,  $i = 1, \dots, n$ . Dann ist  $Y_n = \sum_{i=1}^n X_i \sim B(n, p)$ . Es gilt der **Zentrale Grenzwertsatz von de Moivre-Laplace**:

$$\frac{Y_n - np}{\sqrt{np(1-p)}} \xrightarrow{D} N(0, 1), \text{ oder } \frac{Y_n - np}{\sqrt{np(1-p)}} \overset{a}{\sim} N(0, 1).$$

Das ist eine **asymptotische Aussage**. Umformuliert (mit dem 0.025-Quantil der Standardnormalverteilung gleich ungefähr 1.96):

$$\begin{aligned} \frac{Y_n}{n} &\overset{a}{\sim} N\left(p, \frac{p(1-p)}{n}\right) \\ \Rightarrow \mathbb{P}\left(p - 1.96\sqrt{\frac{p(1-p)}{n}} \leq \frac{Y_n}{n} \leq p + 1.96\sqrt{\frac{p(1-p)}{n}}\right) &\approx 0.95 \end{aligned}$$

Für  $n \rightarrow \infty$  gehen die Intervallgrenzen natürlich gegen  $\frac{Y_n}{n}$ .

# Asymptotik und Approximation II

Aber: schon für endliche  $n$  sind wir (vielleicht) schon nah dran. Wir nutzen die Grenzwertsätze zur **Approximation**:

$$\frac{Y_n}{n} \approx N\left(p, \frac{p(1-p)}{n}\right)$$

Obiges Intervall gilt **approximativ** schon für endliche  $n$ .

## Zentraler Grenzwertsatz

Der Zentrale Grenzwertsatz ist deswegen so "Zentral", weil viele unbekannte Verteilungen durch die Normalverteilung (oder davon abgeleitete Verteilungen) approximiert werden können.

Beispiel: In der einfachen linearen Regression nimmt man an, dass der (Beobachtungs-)Fehler normalverteilt ist. Begründung: Der Fehler ergibt sich aus der Summe sehr vieler kleiner Fehlerquellen.

# Konvergenzrate I

## Definition 15.6 (Landau-Symbole)

Sei  $f_n$  eine Folge von reellen Zahlen. Dann bezeichnet

$$o(g_n) \rightarrow \lim_{n \rightarrow \infty} \left| \frac{f_n}{g_n} \right| = 0$$

$$\mathcal{O}(g_n) \rightarrow \limsup_{n \rightarrow \infty} \left| \frac{f_n}{g_n} \right| < \infty$$

Interpretation von  $o$ :  $f_n$  geht schneller gegen 0 als  $g_n$ .

# Konvergenzrate II

## Satz 15.7

Es seien  $X_1, \dots, X_n$  iid mit  $X_i \sim F$ ,  $\mathbb{E}(X_i) = \mu$ ,  $\text{Var}(X_i) = \sigma^2$ ,  $\mathbb{E}(X_i^3) < \infty$  und  $k$ -tem zentralen Moment  $\mu_k^0 = \mathbb{E}((X_i - \mu)^k)$ . Dann gilt:

$$\begin{aligned} G_n(x) &= \mathbb{P} \left( \sqrt{n} \left( \frac{\bar{X} - \mu}{\sigma} \right) \leq x \right) \\ &= \Phi(x) + \underbrace{\frac{\mu_3^0}{6 \sigma^3 \sqrt{n}} (1 - x^2) \varphi(x)}_{\text{erste Edgeworth-Korrektur}} + o \left( \frac{1}{\sqrt{n}} \right) \end{aligned}$$

- ▶  $o \left( \frac{1}{\sqrt{n}} \right)$  meint eine Folge, die wie  $\frac{1}{\sqrt{n}} \rightarrow 0$  für  $n \rightarrow \infty$ , aber schneller als  $\frac{1}{\sqrt{n}}$ .
- ▶ für symmetrische Verteilungen ist  $\mu_3 = 0$  und damit ist z.B. für die t-Verteilung die Approximation durch  $N(0, 1)$  schneller als  $\frac{1}{\sqrt{n}}$ . Die erste Edgeworth-Korrektur ist also für schiefe Verteilungen wie  $\chi^2(n)$  von Interesse.

# Konvergenzgeschwindigkeit

## Satz 15.8 (Berry-Esseen)

Seien  $X_1, \dots, X_n$  iid,  $X_i \sim F$  mit  $\mathbb{E}(X_i) = \mu$ ,  $\text{Var}(X_i) = \sigma^2$ ,  $\mathbb{E}(X_i^3) < \infty \implies \exists c$  (unabhängig von  $F$ ) mit

$$|G_n(x) - \Phi(x)| \leq \frac{c}{\sqrt{n}} \frac{\mathbb{E}(|X_1 - \mu|^3)}{\sigma^3}$$

wobei  $G_n(x) = \mathbb{P}\left(\sqrt{n}\left(\frac{\bar{X} - \mu}{\sigma}\right) \leq x\right)$ .


- ▶ Der Satz von Berry-Esseen gilt für endliche  $n$
- ▶  $c$  ist unabhängig von  $F$
- ▶  $c$  ist nicht genau bekannt, aktuell bekannte Obergrenze ist  $c_{\min} \leq 0.4748$  (Korolev and Shevtsova (2012))

# Gegenbeispiel I

Seien  $X_1, X_2, \dots$ , iid Pareto-verteilt (siehe Def. 9.9) mit  $x_m = 1$  und  $1 < \alpha < 2$ . Dann gilt  $\mathbb{E}(X_i) = \frac{\alpha}{\alpha-1}$  und die Varianz von  $X$  existiert nicht.

```
# Funktion zum Ziehen aus Pareto-Verteilung über  
# Inversionsmethode  
rpareto <- function(n, alpha, xm = 1) {  
  u <- runif(n)  
  xm * u^(-1/alpha)  
}  
ziehen <- function(n, alpha) {  
  x <- rpareto(n, alpha)  
  return(sqrt(n) * sum(x - alpha/(alpha - 1)))  
}  
draws <- sapply(rep(10000, 1000), ziehen, alpha = 1.5)  
hist(draws)
```

# Gegenbeispiel II



*Anmerkung:* In diesem Fall konvergiert  $\frac{1}{n^{1/\alpha}} \sum_{i=1}^n (X_i - \mu)$ , allerdings nicht gegen die Normalverteilung.

## **15. Verteilungskonvergenz**

15.1 Konvergenz in Verteilung

15.2 Zusammenhang Konvergenzarten

15.3 Zentrale Grenzwertsätze

15.4 Fundamentalsatz der Statistik

# Fundamentalsatz der Statistik I

Im Folgenden bezeichne  $\hat{F}(x) = \frac{1}{n} \sum_{i=1}^n I_{(-\infty, x]}(X_i)$  die empirische Verteilungsfunktion von  $X_1, \dots, X_n$ .

## Satz 15.9 (Satz von Gliwenko-Cantelli, Hauptsatz der Statistik (engl. Glivenko–Cantelli theorem))

- a)  $\hat{F}(x) \xrightarrow{f.s.} F(x) \quad \forall x \in \mathbb{R}$
- b)  $\sqrt{n}(\hat{F}_n(x) - F(x)) \xrightarrow{\mathcal{D}} N(0, F(x)(1 - F(x))) \quad \forall x \in \mathbb{R}$
- c)  $\sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| \xrightarrow{f.s.} 0$

# Fundamentalsatz der Statistik II

## Beweis:

b)  $I_{X_i \leq x} \sim B(1, F(x))$  iid  $\forall i = 1, \dots, n$  und  $x \in \mathbb{R}$ . Wegen des ZGWS gilt

$$\underbrace{\sqrt{n} \left( \frac{1}{n} \sum_{i=1}^n I_{X_i \leq x} - F(x) \right)}_{= \sqrt{n} (\hat{F}_n(x) - F(x))} \xrightarrow{\mathcal{D}} N(0, F(x)(1 - F(x))) \implies \text{b)}$$


a) Starkes Gesetz der großen Zahlen:

$$\hat{F}_n(x) = \frac{1}{n} \sum I_{X_i \leq x} \xrightarrow{\text{f.s.}} \mathbb{E}(I_{X_i \leq x}) = \mathbb{P}(X_i \leq x) = F(x)$$

c) ohne Beweis




# Fundamentalsatz der Statistik III




**Abbildung 29:** Approximation der  $\chi^2(5)$ -Verteilung durch die empirische Verteilungsfunktion

# Fundamentalsatz der Statistik IV



**Abbildung 30:** Approximation der  $Po(5)$ -Verteilung durch die empirische Verteilungsfunktion

# Fundamentalsatz der Statistik V



**Abbildung 31:** Approximation der Cauchy-Verteilung durch die empirische Verteilungsfunktion

# Fundamentalsatz der Statistik VI

## Fundamentalsatz der Statistik

Der Fundamentalsatz, auch Hauptsatz der Statistik erlaubt, dass wir allgemein theoretische Verteilungen aus Stichproben schätzen können (wenn diese groß genug sind).

# Multivariate Grenzwertsätze I

## Definition 15.10 (Konvergenz in Verteilung)

Seien  $\mathbf{X}, \mathbf{X}_1, \mathbf{X}_2, \dots$   $k$ -dimensionale Zufallsvektoren mit Verteilungsfunktionen  $F(x) = \mathbb{P}(\mathbf{X} \leq x)$ ,  $F_n(x) = \mathbb{P}(\mathbf{X}_n \leq x)$ ,  $x \in \mathbb{R}^k$ ,  $n \geq 1$ .

Gilt  $\lim_{n \rightarrow \infty} F_n(\mathbf{x}) = F(\mathbf{x})$  für alle  $\mathbf{x}$  in denen  $F$  stetig ist, so konvergiert  $\mathbf{X}_n$  in Verteilung gegen  $\mathbf{X}$ :

$$\mathbf{X}_n \xrightarrow{\mathcal{D}} \mathbf{X}.$$

# Multivariate Grenzwertsätze II

## Satz 15.11 (Multivariater Zentraler Grenzwertsatz)

Sei  $(\mathbf{X}_n)$  eine Folge unabhängiger und identisch verteilter  $k$ -dimensionaler Zufallsvektoren mit  $\mathbb{E}(\mathbf{X}_1^\top \mathbf{X}_1) < \infty$ .

Mit  $\boldsymbol{\mu} := \mathbb{E}(\mathbf{X}_1)$  und  $\boldsymbol{\Sigma} := \mathbf{Cov}(\mathbf{X}_1)$  gilt

$$\frac{1}{\sqrt{n}} \left( \sum_{j=1}^n \mathbf{X}_j - n\boldsymbol{\mu} \right) \xrightarrow{\mathcal{D}} N_k(\mathbf{0}_k, \boldsymbol{\Sigma}).$$

### Beweisidee:

Seien  $\mathbf{X}_1, \mathbf{X}_2, \dots$  iid  $\mathbb{R}^k$ -wertig mit  $E(\mathbf{X}_1) = \boldsymbol{\mu}$  und  $\mathbf{Cov}(\mathbf{X}_1) = \boldsymbol{\Sigma}$ .

Für jedes  $\mathbf{a} \in \mathbb{R}^k$  gilt

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n \mathbf{a}^\top (\mathbf{X}_i - \boldsymbol{\mu}) \xrightarrow{D} N(0, \mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{a})$$

(eindimensionaler ZGWS). Das daraus

# Multivariate Grenzwertsätze III

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n (X_i - \mu) \xrightarrow{D} \mathcal{N}_k(0, \Sigma).$$

folgt, ist das sogenannte Cramér–Wold-Theorem.

# Multivariate Grenzwertsätze IV

## Satz 15.12 (Multivariater Hauptsatz der Statistik)

Seien  $X_1, X_2, \dots$  iid  $\mathbb{R}^k$ -wertige Zufallsvektoren mit gemeinsamer Verteilungsfunktion

$$F(x) = P(X_1 \leq x), \quad x \in \mathbb{R}^k,$$

wobei  $X \leq x$  komponentenweise zu verstehen ist. Die empirische Verteilungsfunktion sei

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{X_i \leq x\}}.$$

# Multivariate Grenzwertsätze V

Dann gilt:

1. (Multivariates starkes Gesetz)

$$F_n(x) \xrightarrow{\text{f.s.}} F(x) \quad \forall x \in \mathbb{R}^k.$$

2. (Multivariater ZGWS, punktweise) Für jedes feste  $x$  gilt

$$\sqrt{n}(F_n(x) - F(x)) \xrightarrow{D} \mathcal{N}(0, F(x)(1 - F(x))).$$

**Beweis:** wie im eindimensionalen.