

Einführung

Beispiele

Statistik: Was - Wie - Warum

Gegenwart & Zukunft der Statistik

Theorie-Empirie-Statistik

Einführung

Beispiele

Statistik: Was - Wie - Warum

Gegenwart & Zukunft der Statistik

Theorie-Empirie-Statistik


Bundestagswahl 2021

Prognose 18:00 Infratest Dimap (ARD):

Partei:	CDU/CSU	SPD	AfD	FDP	Linke	Grüne
Stimmanteil (%):	25	25	11	11	5	15

Basis: Nachwahlbefragung, ca. 33 000 Wahlberechtigte

Ergebnis:



bundestagswahl.br.de/public/ec/ergebnis-bundestagswahl-2021-bayern-deutschland.html

Bundestagswahl 2021


Ziele:

- ▶ Schluss von der Befragung einer Stichprobe von Wähler:innen auf Gesamtergebnis
- ▶ Analyse von Wahlverhalten durch weitere Fragen (Wechselwähler:innen etc.)

Wahlfälschung

Idee: Untersuche Zusammenhang zwischen Wahlergebnis (Stimmenanteil der Sieger) und Wahlbeteiligung.

ballot stuffing treibt beides in die Höhe!



P. Klimek, Y. Yegorov, R. Hanel, S. Thurner (2012). Statistical detection of systematic election irregularities. PNAS 109(41):16469–16473.

KOALA - Koalitions Analyse


StaBLab-Projekt mit H. Küchenhoff, A. Bender, A. Bauer

- ▶ Ziel: Bessere Vermittlung der den Wahlumfragen zugrunde liegenden Unsicherheiten
- ▶ Kleinere Änderungen in Umfrageanteilen der Parteien vor Wahlen nicht immer relevant, teilweise überbewertet
- ▶ Tatsächlich relevant sind Änderungen in der Wahrscheinlichkeit bestimmter Ereignisse nach Wahlen (Wahrscheinlichkeit für Zustandekommen von Mehrheiten für Koalitionen)
- ▶ Basis: Simulation vieler möglicher Wahlergebnisse auf Basis (mehrerer) aktueller Umfragen
- ▶ Wahrscheinlichkeit: Anteil der Simulationen in welchen Ereignis eintritt

Website: koala.stat.uni-muenchen.de

KOALA - Koalitions Analyse

Gepoolte Umfrage (10.09 - 24.09.2021)





KOALA - Koalitions Analyse

Zeitverlauf bzgl. Koalitionen

Betrachtete Koalitionen

Grüne-SPD-Linke




ISAR - Lebensmittelimportscreening

StaBLab-Projekt mit H. Küchenhoff, A. Bauer und F. Günther in Zusammenarbeit mit Bayrischem Landesamt für Gesundheit und Lebensmittelsicherheit, sowie Bundesamt für Verbraucherschutz und Lebensmittelsicherheit

- ▶ Ziel: Früherkennung von Risiken im Lebensmittelhandel
- ▶ Ansatz: Dauerhaftes Screening von produkt- und länderspezifischen Daten aller deutscher Lebensmittelimporte
- ▶ Auffälligkeiten in Mengen oder Preisen können Hinweise zu Risiken und Betrugspotentialen liefern
- ▶ Ansatz: Verwendung statistischer Zeitreihen-Modelle
 - ▶ Vergleich der Beobachtungen mit Vorhersagen der Modelle
 - ▶ Definition von Auffälligkeiten von Interesse
 - ▶ Jeden Monat erhalten Lebensmittelkontrolleure Liste mit auffälligen Zeitreihen
- ▶ Programmierung von Tool zur interaktiven Darstellung der Daten in enger Zusammenarbeit mit Anwendern


ISAR: Beispiel Haselnüsse Türkei

- ▶ 2014 Ernteeinbruch von Haselnüssen in der Türkei
- ▶ Darauf folgend starker Preisanstieg
- ▶ Es wurden verstärkt Kontrollen der nach Deutschland importierten Haselnussprodukte durchgeführt
- ▶ In verarbeiteten Produkten wurde Verfälschungen, u.a. durch Cashews/Mandeln gefunden, hohes Gesundheitsrisiko (Allergie)
- ▶ In ISAR erste Signale für auffällige Preisentwicklung im September 2015



ISAR: Beispiel Haselnüsse Türkei

- ▶ 2014 Ernteeinbruch von Haselnüssen in der Türkei
- ▶ Darauf folgend starker Preisanstieg
- ▶ Es wurden verstärkt Kontrollen der nach Deutschland importierten Haselnussprodukte durchgeführt
- ▶ In verarbeiteten Produkten wurde Verfälschungen, u.a. durch Cashews/Mandeln gefunden, hohes Gesundheitsrisiko (Allergie)
- ▶ In ISAR erste Signale für auffällige Preisentwicklung im September 2015



Mineralwasserstudie

Studie in Zusammenarbeit mit Prof. O. Adam (LMU)

Fragestellung: Schmeckt mit Sauerstoff angereichertes Mineralwasser besser als gewöhnliches Mineralwasser ?

- ▶ Doppel-Blindstudie
- ▶ Kontroll-Gruppe: zweimal das gleiche Wasser ohne O_2
- ▶ Verum-Gruppe: Beim zweiten Mal mit O_2 angereichertes Mineralwasser

Ergebnis (Clausnitzer et al., 2004) :

- ▶ Placebo: 76% gaben an, dass das zweite Wasser anders schmeckt
- ▶ Verum : 89 % gaben an, dass das zweite Wasser anders schmeckt

Signifikanter Effekt → Zulassung

Ziele und Methoden

- ▶ Randomisierte Studie (Doppelblind)
- ▶ Entscheidungsfindung durch statistischen Test
- ▶ Quantifizierung des Effekts

Umweltzone und Feinstaubbelastung

Wirkt die Umweltzone?

Einfacher Ansatz: Vergleiche Mittelwerte vor und nach der Einführung von Umweltzone und Fahrverbot


Probleme:

- ▶ Grundbelastung ohne Autoverkehr kann sich ändern
- ▶ Starke Wettereinflüsse
- ▶ Schwankungen über Tag und Jahreszeit


Daher: Regressionsmodell mit Referenzstation, Wetter, Tagesverlauf

V. Fensterer, H. Küchenhoff, V. Maier, H.-E. Wichmann, S. Breitner, A. Peters, J. Gu, and J. Cyrys (2014). Evaluation of the impact of low emission zone and heavy traffic ban in Munich (Germany) on the reduction of PM_{10} in ambient air. *International Journal of Environmental Research and Public Health* 11(5):5094-5112.

Wirkung der Umweltzone: Prinzregentenstrasse



Wirkung der Umweltzone: Lothstrasse



Weitere Beispiele

- ▶ Klinische Studien
- ▶ Epidemiologische Studien
- ▶ Qualitätskontrolle
- ▶ Marktforschung
 - ▶ Einschaltquoten
 - ▶ Bewertung und Vergleich von Produkten gleichen Typs aber verschiedener Produzenten durch Verbraucher (Waschmittel, Kaffee, Schokolade, usw.)
 - ▶ Online-Tracking-Daten: Cookies, Userprofile, Websitenutzung, ...
 - ▶ A-B-Testing von Websitedesigns, User Interfaces
- ▶ Sportstatistik
- ▶ Analyse von Genexpressions- oder -sequenzdaten
- ▶ Netzwerkanalysen
- ▶ Mustererkennung (“‘Pattern recognition’”): Spamfilter, Customer Churn, Kundensegmentierung, ...

Einführung

Beispiele

Statistik: Was - Wie - Warum

Gegenwart & Zukunft der Statistik

Theorie-Empirie-Statistik

Was ist Statistik?

Statistik als Wissenschaft bezeichnet eine Methodenlehre, die sich mit der Erhebung, der Darstellung, der Analyse und der Bewertung von Daten auseinander setzt.

Ein zentraler Aspekt ist dabei die Modellbildung mit zufälligen Komponenten.

Teilgebiete:

- ▶ **Deskriptive** Statistik:
Beschreibung, Zusammenfassung, Visualisierung von Daten.
Techniken: Grafiken, Tabellen, Kennzahlen
- ▶ **Explorative** Statistik:
Suche nach Strukturen in Daten. Benutzt deskriptive und induktive Techniken interaktiv und iterativ.
- ▶ **Induktive** Statistik: Schließt von beobachteten Daten auf zugrundeliegende Strukturen.
Angewandte Wahrscheinlichkeitsmathematik.
Techniken: Statistische Modellierung, statistische Tests.

Deskriptive Statistik

- ▶ *Data is merely the raw material of knowledge.*
Charles Wheelan (* 1966, Autor)

Ziel: Wahrhaftige Beschreibung von Daten mit möglichst geringem Informationsverlust

- ▶ Eigenschaften und Strukturen erkennbar machen
- ▶ Grafisch und durch Kennwerte
- ▶ Eindimensional und mehrdimensional ("*uni-/multivariat*")
- ▶ keine Rückschlüsse von beobachteter Stichprobe auf die Grundgesamtheit oder allgemeine Phänomene (nur *Deskription*, nicht *Inferenz*)

Was ist Statistik?

- ▶ *Maths is a language that you use to describe statistics, but really it's about collecting information and putting it in an order that makes sense.*

Lauren Stamile (* 1976, Schauspielerin)

- ▶ *Statistics is the grammar of science.*

Karl Pearson (1857 - 1936, Mathematiker)

- ▶ *Statistics is the science of learning from experience.*

Bradley Efron (* 1938, Statistiker)

- ▶ **⇒ Statistische Methodik als unabdingbares Werkzeug jeder empirischen Wissenschaft.**

Was ist Statistik?

- ▶ *Maths is a language that you use to describe statistics, but really it's about collecting information and putting it in an order that makes sense.*
Lauren Stamile (* 1976, Schauspielerin)
- ▶ *Statistics is the grammar of science.*
Karl Pearson (1857 - 1936, Mathematiker)
- ▶ *Statistics is the science of learning from experience.*
Bradley Efron (* 1938, Statistiker)
- ▶ **⇒ Statistische Methodik als unabdingbares Werkzeug jeder empirischen Wissenschaft.**

Was ist Statistik?

- ▶ *Maths is a language that you use to describe statistics, but really it's about collecting information and putting it in an order that makes sense.*
Lauren Stamile (* 1976, Schauspielerin)
- ▶ *Statistics is the grammar of science.*
Karl Pearson (1857 - 1936, Mathematiker)
- ▶ *Statistics is the science of learning from experience.*
Bradley Efron (* 1938, Statistiker)
- ▶ **⇒ Statistische Methodik als unabdingbares Werkzeug jeder empirischen Wissenschaft.**

Was ist Statistik?

- ▶ *Maths is a language that you use to describe statistics, but really it's about collecting information and putting it in an order that makes sense.*
Lauren Stamile (* 1976, Schauspielerin)
- ▶ *Statistics is the grammar of science.*
Karl Pearson (1857 - 1936, Mathematiker)
- ▶ *Statistics is the science of learning from experience.*
Bradley Efron (* 1938, Statistiker)
- ▶ **⇒ Statistische Methodik als unabdingbares Werkzeug jeder empirischen Wissenschaft.**

Warum Statistik?

- ▶ *Statistics is a body of methods for making wise decisions in the face of uncertainty.*

W. Allen Wallis (1912-1998, Statistiker & Ökonom)

- ▶ *Cognitive psychology tells us that the unaided human mind is vulnerable to many fallacies and illusions because of its reliance on its memory for vivid anecdotes rather than systematic statistics.*

Steven Pinker (* 1954, Psychologe & Linguist)

- ▶ *It is the mark of a truly intelligent person to be moved by statistics.*

George Bernard Shaw (1856 - 1950, Dramatiker)

- ▶ *Statistik ist für mich das Informationsmittel der Mündigen. Wer mit ihr umgehen kann, ist weniger leicht zu manipulieren. Der Satz "Mit Statistik kann man alles beweisen" gilt nur für die Bequemen, die keine Lust haben, genau hinzusehen.*

Elisabeth Noelle-Neumann (1916-2010, Demoskopin)

- ▶ **⇒ Statistische (Aus-)Bildung um irrationales Handeln zu vermeiden und mit Unsicherheit vernünftig umzugehen.**

Warum Statistik?

- ▶ *Statistics is a body of methods for making wise decisions in the face of uncertainty.*

W. Allen Wallis (1912-1998, Statistiker & Ökonom)

- ▶ *Cognitive psychology tells us that the unaided human mind is vulnerable to many fallacies and illusions because of its reliance on its memory for vivid anecdotes rather than systematic statistics.*

Steven Pinker (* 1954, Psychologe & Linguist)

- ▶ *It is the mark of a truly intelligent person to be moved by statistics.*

George Bernard Shaw (1856 - 1950, Dramatiker)

- ▶ *Statistik ist für mich das Informationsmittel der Mündigen. Wer mit ihr umgehen kann, ist weniger leicht zu manipulieren. Der Satz "Mit Statistik kann man alles beweisen" gilt nur für die Bequemen, die keine Lust haben, genau hinzusehen.*

Elisabeth Noelle-Neumann (1916-2010, Demoskopin)

- ▶ **⇒ Statistische (Aus-)Bildung um irrationales Handeln zu vermeiden und mit Unsicherheit vernünftig umzugehen.**

Warum Statistik?

- ▶ *Statistics is a body of methods for making wise decisions in the face of uncertainty.*

W. Allen Wallis (1912-1998, Statistiker & Ökonom)

- ▶ *Cognitive psychology tells us that the unaided human mind is vulnerable to many fallacies and illusions because of its reliance on its memory for vivid anecdotes rather than systematic statistics.*

Steven Pinker (* 1954, Psychologe & Linguist)

- ▶ *It is the mark of a truly intelligent person to be moved by statistics.*

George Bernard Shaw (1856 - 1950, Dramatiker)

- ▶ *Statistik ist für mich das Informationsmittel der Mündigen. Wer mit ihr umgehen kann, ist weniger leicht zu manipulieren. Der Satz "Mit Statistik kann man alles beweisen" gilt nur für die Bequemen, die keine Lust haben, genau hinzusehen.*

Elisabeth Noelle-Neumann (1916-2010, Demoskopin)

- ▶ **⇒ Statistische (Aus-)Bildung um irrationales Handeln zu vermeiden und mit Unsicherheit vernünftig umzugehen.**

Warum Statistik?

- ▶ *Statistics is a body of methods for making wise decisions in the face of uncertainty.*

W. Allen Wallis (1912-1998, Statistiker & Ökonom)

- ▶ *Cognitive psychology tells us that the unaided human mind is vulnerable to many fallacies and illusions because of its reliance on its memory for vivid anecdotes rather than systematic statistics.*

Steven Pinker (* 1954, Psychologe & Linguist)

- ▶ *It is the mark of a truly intelligent person to be moved by statistics.*

George Bernard Shaw (1856 - 1950, Dramatiker)

- ▶ *Statistik ist für mich das Informationsmittel der Mündigen. Wer mit ihr umgehen kann, ist weniger leicht zu manipulieren. Der Satz "Mit Statistik kann man alles beweisen" gilt nur für die Bequemen, die keine Lust haben, genau hinzusehen.*

Elisabeth Noelle-Neumann (1916-2010, Demoskopin)

- ▶ **⇒ Statistische (Aus-)Bildung um irrationales Handeln zu vermeiden und mit Unsicherheit vernünftig umzugehen.**

Warum Statistik?

- ▶ *Statistics is a body of methods for making wise decisions in the face of uncertainty.*

W. Allen Wallis (1912-1998, Statistiker & Ökonom)

- ▶ *Cognitive psychology tells us that the unaided human mind is vulnerable to many fallacies and illusions because of its reliance on its memory for vivid anecdotes rather than systematic statistics.*

Steven Pinker (* 1954, Psychologe & Linguist)

- ▶ *It is the mark of a truly intelligent person to be moved by statistics.*

George Bernard Shaw (1856 - 1950, Dramatiker)

- ▶ *Statistik ist für mich das Informationsmittel der Mündigen. Wer mit ihr umgehen kann, ist weniger leicht zu manipulieren. Der Satz "Mit Statistik kann man alles beweisen" gilt nur für die Bequemen, die keine Lust haben, genau hinzusehen.*

Elisabeth Noelle-Neumann (1916-2010, Demoskopin)

- ▶ **⇒ Statistische (Aus-)Bildung um irrationales Handeln zu vermeiden und mit Unsicherheit vernünftig umzugehen.**

Warum (nicht) Statistik?

- ▶ *All models are wrong, but some are useful.*
George E. P. Box (1919 - 2013, Statistiker)
- ▶ *The combination of some data and an aching desire for an answer does not ensure that a reasonable answer can be extracted from a given body of data.*
John Tukey (1915- 2000, Mathematiker)
- ▶ *If you torture the data enough, nature will always confess.*
Ronald Coase (1910 - 2013, Ökonom)
- ▶ *There are no routine statistical questions, only questionable statistical routines.*
David R. Cox (1924 - 2022, Statistiker)
- ▶ **⇒ Statistik ist komplex und ihre Ergebnisse werden oft missbraucht oder missinterpretiert.**

Warum (nicht) Statistik?

- ▶ *All models are wrong, but some are useful.*
George E. P. Box (1919 - 2013, Statistiker)
- ▶ *The combination of some data and an aching desire for an answer does not ensure that a reasonable answer can be extracted from a given body of data.*
John Tukey (1915- 2000, Mathematiker)
- ▶ *If you torture the data enough, nature will always confess.*
Ronald Coase (1910 - 2013, Ökonom)
- ▶ *There are no routine statistical questions, only questionable statistical routines.*
David R. Cox (1924 - 2022, Statistiker)
- ▶ **⇒ Statistik ist komplex und ihre Ergebnisse werden oft missbraucht oder missinterpretiert.**

Warum (nicht) Statistik?

- ▶ *All models are wrong, but some are useful.*
George E. P. Box (1919 - 2013, Statistiker)
- ▶ *The combination of some data and an aching desire for an answer does not ensure that a reasonable answer can be extracted from a given body of data.*
John Tukey (1915- 2000, Mathematiker)
- ▶ *If you torture the data enough, nature will always confess.*
Ronald Coase (1910 - 2013, Ökonom)
- ▶ *There are no routine statistical questions, only questionable statistical routines.*
David R. Cox (1924 - 2022, Statistiker)
- ▶ **⇒ Statistik ist komplex und ihre Ergebnisse werden oft missbraucht oder missinterpretiert.**

Warum (nicht) Statistik?

- ▶ *All models are wrong, but some are useful.*
George E. P. Box (1919 - 2013, Statistiker)
- ▶ *The combination of some data and an aching desire for an answer does not ensure that a reasonable answer can be extracted from a given body of data.*
John Tukey (1915- 2000, Mathematiker)
- ▶ *If you torture the data enough, nature will always confess.*
Ronald Coase (1910 - 2013, Ökonom)
- ▶ *There are no routine statistical questions, only questionable statistical routines.*
David R. Cox (1924 - 2022, Statistiker)

- ▶ **⇒ Statistik ist komplex und ihre Ergebnisse werden oft missbraucht oder missinterpretiert.**

Warum (nicht) Statistik?

- ▶ *All models are wrong, but some are useful.*
George E. P. Box (1919 - 2013, Statistiker)
- ▶ *The combination of some data and an aching desire for an answer does not ensure that a reasonable answer can be extracted from a given body of data.*
John Tukey (1915- 2000, Mathematiker)
- ▶ *If you torture the data enough, nature will always confess.*
Ronald Coase (1910 - 2013, Ökonom)
- ▶ *There are no routine statistical questions, only questionable statistical routines.*
David R. Cox (1924 - 2022, Statistiker)

- ▶ **⇒ Statistik ist komplex und ihre Ergebnisse werden oft missbraucht oder missinterpretiert.**

Warum nicht Statistik?

- ▶ *Not everything that counts can be counted, and not everything that can be counted counts.*

William Bruce Cameron (1904 - 1988, Soziologe)

- ▶ *Our scientific age demands that we provide definitions, measurements, and statistics in order to be taken seriously. Yet most of the important things in life cannot be precisely defined or measured. Can we define or measure love, beauty, friendship, or decency, for example?*

Dennis Prager (* 1948, Radiomoderator & Publizist)

- ▶ *Statistics are the triumph of the quantitative method, and the quantitative method is the victory of sterility and death.*

Hilaire Belloc (1870 - 1953, Schriftsteller & Historiker)

- ▶ **⇒ Statistik nur dort sinnvoll, wo Messbarkeit und Quantifizierbarkeit gegeben sind.**

Warum nicht Statistik?

- ▶ *Not everything that counts can be counted, and not everything that can be counted counts.*

William Bruce Cameron (1904 - 1988, Soziologe)

- ▶ *Our scientific age demands that we provide definitions, measurements, and statistics in order to be taken seriously. Yet most of the important things in life cannot be precisely defined or measured. Can we define or measure love, beauty, friendship, or decency, for example?*

Dennis Prager (* 1948, Radiomoderator & Publizist)

- ▶ *Statistics are the triumph of the quantitative method, and the quantitative method is the victory of sterility and death.*

Hilaire Belloc (1870 - 1953, Schriftsteller & Historiker)

- ▶ **⇒ Statistik nur dort sinnvoll, wo Messbarkeit und Quantifizierbarkeit gegeben sind.**

Warum nicht Statistik?

- ▶ *Not everything that counts can be counted, and not everything that can be counted counts.*

William Bruce Cameron (1904 - 1988, Soziologe)

- ▶ *Our scientific age demands that we provide definitions, measurements, and statistics in order to be taken seriously. Yet most of the important things in life cannot be precisely defined or measured. Can we define or measure love, beauty, friendship, or decency, for example?*

Dennis Prager (* 1948, Radiomoderator & Publizist)

- ▶ *Statistics are the triumph of the quantitative method, and the quantitative method is the victory of sterility and death.*

Hilaire Belloc (1870 - 1953, Schriftsteller & Historiker)

- ▶ **⇒ Statistik nur dort sinnvoll, wo Messbarkeit und Quantifizierbarkeit gegeben sind.**

Warum nicht Statistik?

- ▶ *Not everything that counts can be counted, and not everything that can be counted counts.*

William Bruce Cameron (1904 - 1988, Soziologe)

- ▶ *Our scientific age demands that we provide definitions, measurements, and statistics in order to be taken seriously. Yet most of the important things in life cannot be precisely defined or measured. Can we define or measure love, beauty, friendship, or decency, for example?*

Dennis Prager (* 1948, Radiomoderator & Publizist)

- ▶ *Statistics are the triumph of the quantitative method, and the quantitative method is the victory of sterility and death.*

Hilaire Belloc (1870 - 1953, Schriftsteller & Historiker)

- ▶ **⇒ Statistik nur dort sinnvoll, wo Messbarkeit und Quantifizierbarkeit gegeben sind.**

... und außerdem:

- ▶ *Any observed statistical regularity will tend to collapse once pressure is placed upon it for control purposes.*

Goodhart's Law, auch:

"When a measure becomes a target, it ceases to be a good measure."

oder

"The more any quantitative social indicator is used for social decision-making, the more subject it will be to corruption pressures."

- ▶ Ähnlich auch: Präventions-Paradox, *self-fulfilling/-destroying prophecies*
- ▶ **⇒ Verlässliche Messungen & Vorhersagen in Systemen, die selbst Messergebnissen beeinflussen können & von Vorhersagen beeinflusst werden, sind problematisch.**

... und außerdem:

- ▶ *Any observed statistical regularity will tend to collapse once pressure is placed upon it for control purposes.*

Goodhart's Law, auch:

"When a measure becomes a target, it ceases to be a good measure."
oder

"The more any quantitative social indicator is used for social decision-making, the more subject it will be to corruption pressures."

- ▶ Ähnlich auch: Präventions-Paradox, *self-fulfilling/-destroying prophecies*
- ▶ **⇒ Verlässliche Messungen & Vorhersagen in Systemen, die selbst Messergebnissen beeinflussen können & von Vorhersagen beeinflusst werden, sind problematisch.**

Einführung

Beispiele

Statistik: Was - Wie - Warum


Gegenwart & Zukunft der Statistik

Theorie-Empirie-Statistik

“Big Data”

- ▶ Analyse und Verarbeitung großer Datenmengen
- ▶ Drei Vs: Volume, Velocity, Variety
- ▶ Häufig rein heuristische/algorithmische Herangehensweise ohne probabilistische Modelle oder kausale Theorien
- ▶ Große Herausforderungen für Statistik und Informatik

"Big Data"



Big Data, Machine Learning, KI

- ▶ *Induktive Statistik* umfasst “Machine Learning” & heutige “Künstliche Intelligenz” :≈ Methoden für Mustererkennung & Vorhersagen basierend auf Daten
- ▶ Alltagserfahrungen zunehmend durch datengetriebene Algorithmen bestimmt – Beispiele:
 - ▶ (Soziale) Medien: “filter bubble”, “engagement maximization” durch Empfehlungsalgorithmen
 - ▶ Finanziell: z.B. werden verfügbare Zahlungsmethoden bei Online-Käufen durch Kreditscores etc. bestimmt
- ▶ Entscheidungen großer Tragweite zunehmend durch datengetriebene Algorithmen – Beispiele:
 - ▶ Kreditvergabe via AI-basiertes Kreditscoring: Stanford HAI Study (2024), AI Credit Scoring (2025)
 - ▶ Medizinische Diagnostik: AI Cancer Diagnostics (2025), RSNA AI Radiology (2024), AI Pathology (2025)
 - ▶ “Predictive Policing”: US DOJ (2024), Europol AI Strategy (2025)
 - ▶ Strafjustiz: COMPAS & Algorithmic Bias, CCJ: AI & Criminal Justice (2024)
 - ▶ Autonome Militärsysteme: US Congressional Research Service: Lethal Autonomous Weapons Policy (2025), SIPRI: Autonome Waffensysteme und KI (2025), UN Resolution zu letalen autonomen Waffensystemen (2024)

Big Data & ML: Politische & soziale Folgen

- ▶ *Big data knows and can deduce more about you than Big Brother ever could.*

Toomas Hendrik Ilves (*1953, Diplomat & Politiker)

- ▶ *Arguing that you don't care about the right to privacy because you have nothing to hide is no different than saying you don't care about free speech because you have nothing to say. [...]*

Privacy isn't about something to hide. Privacy is about something to protect. And that's who you are. That's what you believe in. That's who you want to become. Privacy is the right to the self. Privacy is what gives you the ability to share with the world who you are on your own terms.

Edward Snowden (* 1983, Dissident¹)

- ▶ *No system of mass surveillance has existed in any society, that we know of to this point, that has not been abused.*

Edward Snowden (* 1983, Dissident)

- ▶ **⇒ Bedeutet vollautomatische, allgegenwärtige, pausenlose Datenerfassung das Ende der Privatsphäre?**

¹Verräter/Doppelagent?

Big Data & ML: Politische & soziale Folgen

- ▶ *Big data knows and can deduce more about you than Big Brother ever could.*
Toomas Hendrik Ilves (*1953, Diplomat & Politiker)
- ▶ *Arguing that you don't care about the right to privacy because you have nothing to hide is no different than saying you don't care about free speech because you have nothing to say. [...]*
Privacy isn't about something to hide. Privacy is about something to protect. And that's who you are. That's what you believe in. That's who you want to become. Privacy is the right to the self. Privacy is what gives you the ability to share with the world who you are on your own terms.
Edward Snowden (* 1983, Dissident¹)
- ▶ *No system of mass surveillance has existed in any society, that we know of to this point, that has not been abused.*
Edward Snowden (* 1983, Dissident)
- ▶ **⇒ Bedeutet vollautomatische, allgegenwärtige, pausenlose Datenerfassung das Ende der Privatsphäre?**

¹Verräter/Doppelagent?

Big Data & ML: Politische & soziale Folgen

- ▶ *Big data knows and can deduce more about you than Big Brother ever could.*
Toomas Hendrik Ilves (*1953, Diplomat & Politiker)
- ▶ *Arguing that you don't care about the right to privacy because you have nothing to hide is no different than saying you don't care about free speech because you have nothing to say. [...]*
Privacy isn't about something to hide. Privacy is about something to protect. And that's who you are. That's what you believe in. That's who you want to become. Privacy is the right to the self. Privacy is what gives you the ability to share with the world who you are on your own terms.
Edward Snowden (* 1983, Dissident¹)
- ▶ *No system of mass surveillance has existed in any society, that we know of to this point, that has not been abused.*
Edward Snowden (* 1983, Dissident)
- ▶ **⇒ Bedeutet vollautomatische, allgegenwärtige, pausenlose Datenerfassung das Ende der Privatsphäre?**

¹Verräter/Doppelagent?

Big Data & ML: Politische & soziale Folgen

- ▶ *Big data knows and can deduce more about you than Big Brother ever could.*
Toomas Hendrik Ilves (*1953, Diplomat & Politiker)
- ▶ *Arguing that you don't care about the right to privacy because you have nothing to hide is no different than saying you don't care about free speech because you have nothing to say. [...]*
Privacy isn't about something to hide. Privacy is about something to protect. And that's who you are. That's what you believe in. That's who you want to become. Privacy is the right to the self. Privacy is what gives you the ability to share with the world who you are on your own terms.
Edward Snowden (* 1983, Dissident¹)
- ▶ *No system of mass surveillance has existed in any society, that we know of to this point, that has not been abused.*
Edward Snowden (* 1983, Dissident)
- ▶ **⇒ Bedeutet vollautomatische, allgegenwärtige, pausenlose Datenerfassung das Ende der Privatsphäre?**

¹Verräter/Doppelagent?

Big Data & ML: Politische & soziale Folgen

- **Predictive models are, increasingly, the tools we will be relying on to run our institutions, deploy our resources, and manage our lives.** But [...] these models are constructed not just from data but from the choices we make about which data to pay attention to – and which to leave out. Those choices are not just about logistics, profits, and efficiency. They are fundamentally moral. If we back away from them and treat mathematical models as a neutral and inevitable force, like the weather or the tides, we abdicate our responsibility. We must come together to police [...], tame and disarm them. My hope is that they'll be remembered, like the deadly coal mines of a century ago, as relics of the early days of this new revolution, before we learned how to bring fairness and accountability to the age of data.

Cathy O'Neil (Statistikerin, Zitat aus "Weapons of Math Destruction" (Crown, 2016))

Big Data & ML: Politische & soziale Folgen

- ▶ *[... M]any of these models encode human prejudice, misunderstanding, and bias into the software systems that increasingly manage our lives. Like gods, these mathematical models are opaque, their workings invisible to all but the highest priests in their domain: mathematicians and computer scientists. Their verdicts, even when wrong or harmful, are beyond dispute or appeal. And they tend to punish the poor and the oppressed in our society, while making the rich richer.*

Cathy O'Neil (Statistikerin, Zitat aus "Weapons of Math Destruction" (Crown, 2016))

- ▶ *Hidden biases in both the collection and analysis stages present considerable risks and are as important to the big-data equation as the numbers themselves. [...] The fear isn't that big data discriminates. We already know that it does. It's that you don't know if you've been discriminated against.*

Kate Crawford (Informatikerin)

- ▶ **⇒ Große Herausforderung der nächsten Jahrzehnte: Humane & faire Verwirklichung der positiven Potentiale, Vermeidung der dystopischen Aspekte.**

Big Data & ML: Politische & soziale Folgen

- ▶ *[... M]any of these models encode human prejudice, misunderstanding, and bias into the software systems that increasingly manage our lives. Like gods, these mathematical models are opaque, their workings invisible to all but the highest priests in their domain: mathematicians and computer scientists. Their verdicts, even when wrong or harmful, are beyond dispute or appeal. And they tend to punish the poor and the oppressed in our society, while making the rich richer.*
Cathy O'Neil (Statistikerin, Zitat aus "Weapons of Math Destruction" (Crown, 2016))

- ▶ *Hidden biases in both the collection and analysis stages present considerable risks and are as important to the big-data equation as the numbers themselves. [...] The fear isn't that big data discriminates. We already know that it does. It's that you don't know if you've been discriminated against.*
Kate Crawford (Informatikerin)

- ▶ **⇒ Große Herausforderung der nächsten Jahrzehnte: Humane & faire Verwirklichung der positiven Potentiale, Vermeidung der dystopischen Aspekte.**

Big Data & ML: Politische & soziale Folgen

- ▶ *[... M]any of these models encode human prejudice, misunderstanding, and bias into the software systems that increasingly manage our lives. Like gods, these mathematical models are opaque, their workings invisible to all but the highest priests in their domain: mathematicians and computer scientists. Their verdicts, even when wrong or harmful, are beyond dispute or appeal. And they tend to punish the poor and the oppressed in our society, while making the rich richer.*
Cathy O'Neil (Statistikerin, Zitat aus "Weapons of Math Destruction" (Crown, 2016))
- ▶ *Hidden biases in both the collection and analysis stages present considerable risks and are as important to the big-data equation as the numbers themselves. [...] The fear isn't that big data discriminates. We already know that it does. It's that you don't know if you've been discriminated against.*
Kate Crawford (Informatikerin)
- ▶ **⇒ Große Herausforderung der nächsten Jahrzehnte: Humane & faire Verwirklichung der positiven Potentiale, Vermeidung der dystopischen Aspekte.**

Gegenwart & Zukunft der Statistik

- ▶ Wachsender Bedarf durch Allgegenwart automatisiert erhobener Daten & Digitalisierung.

Wachsendes Angebot durch automatisierte, prompt-basierte Analysen mit chatGPT & Co.

Statistisches Grundverständnis notwendig für alle, die mit Daten arbeiten!

- ▶ Falsch/missbräuchlich angewendete Statistik führt zu Reproduzierbarkeitskrisen in (Sozial-)psychologie, vielen Bereichen der Medizin, Ernährungswissenschaften

Gegenwärtiger Paradigmenwechsel in der angewandten Forschung
(Stichworte: *p-hacking*, *replication crisis*)

- ▶ “Künstliche Intelligenz” / Maschinelles Lernen & Big Data: Hochkomplexe, extrem rechenintensive Algorithmen in Kombination mit riesigen Datenmengen ermöglichen ganz neue Anwendungen von Datenanalyse

Beitrag der Statistik zur Beherrschbarmachung / Interpretation / Risikoabschätzung dieser Techniken?

Einführung


Beispiele

Statistik: Was - Wie - Warum


Gegenwart & Zukunft der Statistik

Theorie-Empirie-Statistik

Theorie & Empirie



Theorie & Empirie



Theorie & Empirie

- ▶ Modellbildung aus mathemat. Formalisierung liefert vereinfachte, grobe Abbildung eines Ausschnitts der Realität in Symbolen.
- ▶ Daten aus Messung liefern vereinfachte, grobe Abbildung eines Ausschnitts der Realität in Zahlen.
- ▶ Deskriptive Statistik fasst Aspekte der gemessenen Daten in Kennzahlen, Grafiken, Tabellen für Menschen lesbar zusammen.
- ▶ Statistische Inferenz (Schätzungen & Tests) liefert auf Basis von Daten quantitative Aussagen über Modell(komponenten).

Obacht: Modell $\neq$ Realität!

- ▶ Messung selbst bzw. Definition von Messverfahren oft “modellbasiert”.
- ▶ Expertise für substantielle Fragestellung *und* Mathe nötig um Realitätsnähe & Tauglichkeit einer mathematischen Formalisierung beurteilen zu können.
⇒ sinnvolle angewandte Statistik ist **immer interdisziplinär!**

Theorie & Empirie

Mathematischer Formalismus

Empirie / Daten

Wahrscheinlichkeit	verursacht(?) →	Beobachtete Häufigkeit
Wahrscheinlichkeit	repräsentiert(?) ←	Beobachtete Häufigkeit
Zufallsvariable	entspricht ↔	Statistisches Merkmal
Erwartungswert	Schätzung für ←	Arithmetisches Mittel
Stochastische Grundgesamtheit Ω	? ↔	Statistische Grundgesamtheit

USW.