

Zusammenhangsmaße für diskrete Merkmale

Kontingenztafeln für diskrete und gruppierte Merkmale

Bedingte Häufigkeiten

Diskrete Zusammenhangsanalyse: Odds

Diskrete Zusammenhangsanalyse: Unabhängigkeit & Kontingenz

Multivariate Kontingenztafeln & Mosaikplots

Zusammenhangsmaße für diskrete Merkmale

Kontingenztafeln für diskrete und gruppierte Merkmale

Bedingte Häufigkeiten

Diskrete Zusammenhangsanalyse: Odds

Diskrete Zusammenhangsanalyse: Unabhängigkeit & Kontingenz

Multivariate Kontingenztafeln & Mosaikplots

Einführung

Zurück zur Empirie –

Wie können wir in beobachteten Daten Aussagen über die (Un-)Abhängigkeit von Merkmalen machen?

⇒ **mehrdimensionale** oder **multivariate** Daten

Multivariate Daten

- ▶ Stichprobe mit Untersuchungseinheiten $i = 1, \dots, n$
- ▶ **Beobachtungen** (x_i, y_i, z_i) der **Merkmale** (X, Y, Z)
- ▶ Daten $(x_1, y_1, z_1), \dots, (x_i, y_i, z_i), \dots, (x_n, y_n, z_n)$
(Im weiteren: Meistens nur 2 Merkmale X, Y)
- ▶ Fragestellungen:
 - ▶ $X \leftrightarrow Y$: (Wie) hängen X und Y zusammen?
Assoziation, Korrelation
("Sind X und Y *unabhängig*?")
 - ▶ $X \rightarrow Y$: (Wie) beeinflusst X das (Ziel-)Merkmal Y ?
Regression, Kausalität (... nicht Teil dieses Kurses)

Diskrete und gruppierte Merkmale

- Darstellung, Präsentation von diskreten Merkmalen X und Y mit den Ausprägungen

$$\begin{array}{ll} a_1, \dots, a_k & \text{für } X \\ b_1, \dots, b_m & \text{für } Y \end{array}$$

- Skalenniveau von X, Y hier beliebig; X, Y können auch gruppierte metrische Merkmale sein.
- *benutzt* wird hier allerdings nur das *Nominalskalenniveau* der Merkmale.

Beispiel: Wahlverhalten nach Geschlecht

Nachwahlbefragung Bundestag 2021:

	SPD	CDU/CSU	Grüne	FDP	AfD	Linke	Rest	Σ
Männer	626	601	352	325	300	125	175	2504
Frauen	567	504	335	211	167	104	210	2098
Σ	1193	1105	687	536	467	229	385	4602

Quelle: Nachwahlbefragung ARD via [statista.com](https://www.statista.com)

Beispiel: Arbeitslosigkeit

Zwei Merkmale:

- ▶ X Ausbildungsniveau mit den Kategorien
 - ▶ “keine Ausbildung”
 - ▶ “Lehre”
 - ▶ “fachspezifische Ausbildung”
 - ▶ “Hochschulabschluss”
- ▶ Y Dauer der Arbeitslosigkeit mit den Kategorien
 - ▶ “Kurzzeitarbeitslosigkeit” (≤ 6 Monate)
 - ▶ “mittelfristige Arbeitslosigkeit” (7–12 Monate)
 - ▶ “Langzeitarbeitslosigkeit” (≥ 12 Monate)

Arbeitslosigkeit

	Kurzzeit- arbeitslosigkeit	mittelfristige Arbeitslosigkeit	Langzeit- arbeitslosigkeit	Σ
k.A.	86	19	18	123
Lehre	170	43	20	233
Fachspez.	40	11	5	56
Hochschule	28	4	3	35
Σ	324	77	46	447

Tabelle 2: Kontingenztafel der absoluten Häufigkeiten für die Merkmale Ausbildungsniveau und Dauer der Arbeitslosigkeit

Allgemeine Darstellung

Kontingenztafel der absoluten Häufigkeiten:

Eine $(k \times m)$ -**Kontingenztafel der absoluten Häufigkeiten** besitzt die Form

	b_1	...	b_m	
a_1	h_{11}	...	h_{1m}	$h_{1\cdot}$
a_2	h_{21}	...	h_{2m}	$h_{2\cdot}$
$\vdots$	$\vdots$		$\vdots$	$\vdots$
a_k	h_{k1}	...	h_{km}	$h_{k\cdot}$
	$h_{\cdot 1}$	...	$h_{\cdot m}$	n

Notation

$h_{ij} = h(a_i, b_j)$ die absolute Häufigkeit der Kombination (a_i, b_j) ,

$h_{1.}, \dots, h_{k.}$ die Randhäufigkeiten von X
 $h_{.1}, \dots, h_{.m}$ die Randhäufigkeiten von Y

mit

$$h_{i.} = \sum_{j=1}^m h_{ij}, \quad h_{.j} = \sum_{i=1}^k h_{ij}$$

Die Kontingenztafel gibt die gemeinsame Verteilung der Merkmale X und Y in absoluten Häufigkeiten wieder.

Kontingenztafel der relativen Häufigkeiten

Die $(k \times m)$ -**Kontingenztafel der relativen Häufigkeiten** hat die Form

	b_1	...	b_m	
a_1	f_{11}	...	f_{1m}	$f_{1\cdot}$
⋮	⋮		⋮	⋮
a_k	f_{k1}	...	f_{km}	$f_{k\cdot}$
	$f_{\cdot 1}$	...	$f_{\cdot m}$	1

Notation

$f_{ij} = h_{ij}/n$ die relative Häufigkeit der Kombination (a_i, b_j) ,

$f_{i.} = \sum_{j=1}^m f_{ij} = h_{i.}/n, \quad i = 1, \dots, k$, die relativen Randhäufigkeiten zu X ,

$f_{.j} = \sum_{i=1}^k f_{ij} = h_{.j}/n, \quad j = 1, \dots, m$, die relativen Randhäufigkeiten zu Y .

Die Kontingenztafel gibt die gemeinsame Verteilung von X und Y wieder.

Zusammenhangsmaße für diskrete Merkmale

Kontingenztafeln für diskrete und gruppierte Merkmale

Bedingte Häufigkeiten

Diskrete Zusammenhangsanalyse: Odds

Diskrete Zusammenhangsanalyse: Unabhängigkeit & Kontingenz

Multivariate Kontingenztafeln & Mosaikplots

Bedingte Häufigkeiten

Zusammenhang zwischen X und Y aus **gemeinsamen** Häufigkeiten h_{ij} bzw. f_{ij} schwer ersichtlich.

Deshalb: Blick auf **bedingte** Häufigkeiten

⇒ Verteilung eines Merkmals für festen Wert des 2. Merkmals

Bedingte Häufigkeiten: Beispiel

Wahlverhalten nach Geschlecht, Bundestagswahl 2021:

	SPD	CDU/CSU	Grüne	FDP	AfD	Linke	Rest	
Männer	25	24	14	13	12	5	7	100
Frauen	27	24	16	10	8	5	10	100

Prozentzahlen für Parteipräferenz in den Schichten (Subpopulationen)
“Frauen”, “Männer”

= **bedingte relative Häufigkeiten für Parteipräferenzen bei gegebenem Geschlecht**

Bedingte relative Häufigkeitsverteilung

Die **bedingte Häufigkeitsverteilung von Y unter der Bedingung $X = a_i$** , kurz $Y|X = a_i$, ist bestimmt durch

$$f_{Y|X}(b_1|a_i) = \frac{h_{i1}}{h_{i\cdot}}, \dots, f_{Y|X}(b_m|a_i) = \frac{h_{im}}{h_{i\cdot}}.$$

Die **bedingte Häufigkeitsverteilung von X unter der Bedingung $Y = b_j$** , kurz

$X|Y = b_j$, ist bestimmt durch

$$f_{X|Y}(a_1|b_j) = \frac{h_{1j}}{h_{\cdot j}}, \dots, f_{X|Y}(a_k|b_j) = \frac{h_{kj}}{h_{\cdot j}}.$$

Bedingte relative Häufigkeit: Berechnung

Wegen

$$\frac{h_{i1}}{h_{i.}} = \frac{h_{i1}/n}{h_{i.}/n} = \frac{f_{i1}}{f_{i.}}$$

gilt auch

$$f_{Y|X}(b_1|a_i) = \frac{f_{i1}}{f_{i.}}, \dots, f_{Y|X}(b_m|a_i) = \frac{f_{im}}{f_{i.}}$$

$$f_{X|Y}(a_1|b_j) = \frac{f_{1j}}{f_{.j}}, \dots, f_{X|Y}(a_k|b_j) = \frac{f_{kj}}{f_{.j}}.$$

Merksatz:

Bedingte Häufigkeitsverteilungen werden durch Division der h_{ij} bzw. f_{ij} durch die entsprechende Zeilen- bzw. Spaltensumme gebildet.

Beispiel: Wahlverhalten

	SPD	CDU/CSU	Grüne	FDP	AfD	Linke	Rest	Σ
Männer	626	601	352	325	300	125	175	2504
Frauen	567	504	335	211	167	104	210	2098



	SPD	CDU/CSU	Grüne	FDP	AfD	Linke	Rest	
Männer	25	24	14	13	12	5	7	100
Frauen	27	24	16	10	8	5	10	100

- ▶ Zeile $X = a_1$ (Männer)

Bedingte relative Häufigkeiten für Parteipräferenz der Männer

$f_{Y|X}(Y = b_j | X = a_1)$:

“Erste Zeile / Randhäufigkeit für Männer”

$$\frac{h(a_1, b_1)}{h(a_1)} = f_{Y|X}(b_1 | a_1), \dots, \frac{h(a_1, b_j)}{h(a_1)} = f_{Y|X}(b_j | a_1), \dots$$

$$\frac{626}{2504} \approx 25\%, \dots, \frac{175}{2504} \approx 7\% \text{ usw.}$$

- ▶ Zeile $X = a_2$ (Frauen) analog, z.B. $\frac{h(a_2, b_1)}{h(a_2)} = \frac{567}{2098} \approx 27\% \text{ usw.}$

Bedingte und gemeinsame Häufigkeiten

Man kann auch umgekehrt aus bedingten Häufigkeiten und Randhäufigkeiten die gemeinsamen Häufigkeiten ausrechnen. Bei der Nachwahlbefragung aus den bedingten Häufigkeiten und Randhäufigkeiten also z.B.

$$h(a_1) = 2504 \text{ Männer, } h(a_2) = 2098 \text{ Frauen; } n = 4602.$$

$$\begin{aligned} \Rightarrow \quad & h(a_1) \cdot f(b_1 | a_1) = h(a_1, b_1) \\ & 2504 \cdot 25\% \approx 626 \quad \text{usw.} \end{aligned}$$

Beispiel: Arbeitslosigkeit

$f(b_j|a_i), \quad X = a_i, \quad i = 1, \dots, 4$ Ausbildungsniveau

z.B. $\frac{86}{123} = 0.699, \quad \frac{19}{123} = 0.154, \dots$

$\frac{170}{233} = 0.730, \dots$

usw.

Für festgehaltenes Ausbildungsniveau ($X = a_i$) erhält man die relative Verteilung über die Dauer der Arbeitslosigkeit durch die folgende Tabelle.

Bedingte Verteilung


	Kurzzeit- arbeitslosigkeit	mittelfristige Arbeitslosigkeit	Langzeit- arbeitslosigkeit	
Keine Ausb.	0.699	0.154	0.147	1
Lehre	0.730	0.184	0.086	1
Fachspez. Aus.	0.714	0.197	0.089	1
Hochschula.	0.800	0.114	0.086	1

- ▶ Bedingen auf das Ausbildungsniveau:
 - ⇒ Verteilung der Dauer der Arbeitslosigkeit für die Subpopulationen “Keine Ausbildung”, “Lehre”, usw.
- ▶ Verteilungen lassen sich nun miteinander vergleichen

⇒ Relative Häufigkeit für Kurzarbeitslosigkeit ist in der Subpopulation “Hochschulabschluss” mit 0.8 am größten.

Darstellung der bedingten Verteilung

Zum Beispiel Stapeldiagramme:



Zusammenhangsmaße für diskrete Merkmale

Kontingenztafeln für diskrete und gruppierte Merkmale

Bedingte Häufigkeiten

Diskrete Zusammenhangsanalyse: Odds

Diskrete Zusammenhangsanalyse: Unabhängigkeit & Kontingenz

Multivariate Kontingenztafeln & Mosaikplots

Zusammenhangsanalyse in Kontingenztabellen

Bisher: Tabellarische / grafische Präsentation

Jetzt: Maßzahlen für Stärke des Zusammenhangs zwischen X und Y.

Chancen und relative Chancen:

- Betrachte zunächst nur 2×2 - Kontingenztafeln

		Y		
		1	2	
X	1	h_{11}	h_{12}	$h_{1\cdot}$
	2	h_{21}	h_{22}	$h_{2\cdot}$
		$h_{\cdot 1}$	$h_{\cdot 2}$	n

Odds (Chancen)

- ▶ Wir betrachten die Merkmale X und Y zunächst asymmetrisch: Die Ausprägungen von X definieren (hier 2) Subpopulationen, Y ist das interessierende dichotome Merkmal in diesen Subpopulationen
- ▶ Unter einer **Chance** (*odds*) versteht man nun das **Verhältnis der Häufigkeiten** von $Y = 1$ und $Y = 2$.
- ▶ **bedingte Odds**: Verhältnis der bedingten Häufigkeiten von $Y = 1$ und $Y = 2$ **in einer Subpopulation** $X = a_j$.

Chancenverhältnis (Odds Ratio)

- Die (empirischen) **bedingten Odds** für festes $X = a_i$ sind definiert als

$$\gamma(1, 2|X = a_i) = \frac{h_{i1}}{h_{i2}}.$$

- Ein sehr einfaches Zusammenhangsmaß stellen die empirischen **relativen Chancen** (*Odds Ratio*) dar, die gegeben sind durch

$$\gamma(1, 2|X = 1, X = 2) = \frac{\gamma(1, 2|X = 1)}{\gamma(1, 2|X = 2)} = \frac{h_{11}/h_{12}}{h_{21}/h_{22}} = \frac{h_{11}h_{22}}{h_{21}h_{12}},$$

d.h. $\gamma(1, 2|X = 1, X = 2)$ ist das Verhältnis zwischen den Odds für $Y = 1$ gegen $Y = 2$ in der 1. Population ($X = 1$, 1. Zeile) zu den entsprechenden Odds in der 2. Population ($X = 2$, 2. Zeile).

Beispiel: Dauer der Arbeitslosigkeit

Beschränkt man sich jeweils nur auf zwei Kategorien der Merkmale Ausbildungsniveau und Dauer der Arbeitslosigkeit, erhält man beispielsweise die Tabelle

	Kurzzeit- arbeitslosigkeit	Mittel- und langfristige Arbeitslosigkeit
Fachspezifische Ausbildung	40	16
Hochschulabschluss	28	7

Daraus ergeben sich für Personen mit fachspezifischer Ausbildung die Odds, kurzzeitig arbeitslos zu sein statt mittel- oder langfristig arbeitslos zu sein, als

$$\gamma(1,2|\text{fachsp. Ausbildung}) = \frac{40}{16} = 5 : 2 = 2.5.$$

Beispiel: Dauer der Arbeitslosigkeit

Für Arbeitslose mit Hochschulabschluss erhält man

$$\gamma(1, 2 | \text{Hochschulabschluss}) = \frac{28}{7} = 4 : 1 = 4.$$

Für fachspezifische Ausbildung stehen die Odds für Kurzarbeitslosigkeit somit 5 : 2, für Arbeitslose mit Hochschulabschluss 4 : 1.

Man erhält für fachspezifische Ausbildung und Hochschulabschluss das **Odds Ratio**

$$\gamma(1, 2 | \text{fachsp. Ausbildung, Hochschule}) = \frac{5 : 2}{4 : 1} = \frac{2.5}{4} = 0.625 = \frac{40 \cdot 7}{16 \cdot 28}$$

Odds Ratio: Interpretation

- ▶ Wegen der spezifischen Form $\gamma(1, 2|X = 1, X = 2) = (h_{11}h_{22})/(h_{21}h_{12})$ wird das *Odds Ratio* auch als **Kreuzproduktverhältnis** bezeichnet. Es gilt

$\gamma = 1$ Odds in beiden Subpopulationen gleich

$\gamma > 1$ Odds in Subpopulation $X = 1$
größer als in Subpopulation $X = 2$

$\gamma < 1$ Odds in Subpopulation $X = 1$
niedriger als in Subpopulation $X = 2$.

- ▶ Das Odds Ratio gibt somit an, um welchen Faktor sich die Odds in den beiden Subpopulationen unterscheiden

Odds Ratio: Symmetrie

- Für die Kontingenztafel

h_{11}	h_{12}
h_{21}	h_{22}

ist das *Kreuzproduktverhältnis* (*relative Chance* oder *Odds Ratio*) bestimmt durch

$$\gamma = \frac{h_{11}/h_{12}}{h_{21}/h_{22}} = \frac{h_{11}h_{22}}{h_{21}h_{12}}.$$

- Die asymmetrische Betrachtung der Merkmale X und Y wird aufgehoben:

$$\begin{aligned}\gamma(Y = 1, Y = 2 | X = 1, X = 2) &= \gamma(X = 1, X = 2 | Y = 1, Y = 2) \\ &= \gamma(Y = 2, Y = 1 | X = 2, X = 1) \\ &= \gamma(X = 2, X = 1 | Y = 2, Y = 1) \\ &= 1 / \gamma(Y = 2, Y = 1 | X = 1, X = 2) \\ &= 1 / \gamma(X = 2, X = 1 | Y = 1, Y = 2) \dots \text{etc.}\end{aligned}$$

Odds Ratio: Fall - Kontroll - Studie

Beispiel: Morbus Alzheimer und Genetik

	ApoE3	ApoE4	Σ
Kontrolle	2258	803	3061
Fall	593	620	1213
Σ	2851	1423	4274

$$OR = \gamma(\text{ApoE3, ApoE4} | \text{Kontrolle, Fall}) = \frac{2258/803}{593/620} \approx 2.94$$

⇒ Odds für ApoE3 bei Kontrollen um den Faktor 3 höher als bei Fällen

⇒ Odds für ApoE4 bei Kontrollen um den Faktor 3 niedriger als bei Fällen

[?]
⇒ ApoE4 Risiko-Faktor für Morbus Alzheimer

Odds Ratio: Fall - Kontroll - Studie

Zentrale Argumentation:

Odds Ratio ist *symmetrisches* Maß

d.h. Chancenverhältnis für Auftreten von ApoE4 bei Kontrolle zu Auftreten von ApoE4 bei Fällen

entspricht

Chancenverhältnis für Ausbleiben von Alzheimer bei ApoE3 zu Ausbleiben von Alzheimer bei ApoE4

⇒ Interpretation als **Risikofaktor** zulässig:

$\gamma(\text{Kontrolle, Fall} | \text{ApoE3, ApoE4}) = \gamma(\text{ApoE3, ApoE4} | \text{Kontrolle, Fall}) \approx 2.94$

Verallgemeinerung auf $k \times m$ Kontingenztafeln, Anmerkungen

- ▶ Verallgemeinerung des Verfahrens auf mehr als zwei Ausprägungen mindestens eines Merkmals: Man beschränkt sich auf jeweils zwei Zeilen $X = a_i$ und $X = a_j$ und zwei Spalten $Y = b_r$ und $Y = b_s$ und die zugehörigen vier Zellen einer $(k \times m)$ -Kontingenztafel.
- ▶ Verwendung einer Referenzkategorie
- ▶ Statt Odds Ratio wird oft auch das logarithmierte Odds Ratio verwendet

Anwendung: Apolipoprotein E und Morbus Alzheimer

Etablierter Zusammenhang zwischen Apolipoprotein E ϵ 4 und Morbus Alzheimer

Daten aus Metaanalyse:

ApoE genotype	ϵ 2 ϵ 2	ϵ 2 ϵ 3	ϵ 2 ϵ 4	ϵ 3 ϵ 3	ϵ 3 ϵ 4	ϵ 4 ϵ 4
Clinical controls	27	425	81	2258	803	71
Clinical Alzheimer	7	74	41	593	620	207
PM controls	3	75	18	358	120	8
PM Alzheimer	1	20	17	249	373	97

Anwendung: Apolipoprotein E und Morbus Alzheimer

ORs γ (Alzheimer, Control| $\epsilon\epsilon$?, $\epsilon 3\epsilon 3$),
also immer im Vergleich zu $\epsilon 3\epsilon 3$ (Referenz):

ApoE genotype	$\epsilon 2\epsilon 2$	$\epsilon 2\epsilon 3$	$\epsilon 2\epsilon 4$	$\epsilon 3\epsilon 3$	$\epsilon 3\epsilon 4$	$\epsilon 4\epsilon 4$
OR (klinisch)	0.99	0.7	1.93	1	2.94	11.1
OR (post mortem)	0.5	0.4	1.4	1	4.5	17.4

Zusammenhangsmaße für diskrete Merkmale

Kontingenztafeln für diskrete und gruppierte Merkmale

Bedingte Häufigkeiten

Diskrete Zusammenhangsanalyse: Odds

Diskrete Zusammenhangsanalyse: Unabhängigkeit & Kontingenz


Multivariate Kontingenztafeln & Mosaikplots

Kontingenz- und χ^2 -Koeffizient

Jetzt: Definiere allgemein anwendbares Zusammenhangsmaß für diskrete Merkmale.

Idee:

1. Was wären die gemeinsamen Häufigkeiten $\tilde{h}_{ij}$ bzw. $\tilde{f}_{ij}$, falls - bei vorgegebenen Randverteilungen - die Merkmale X und Y *empirisch unabhängig* wären?
2. Quantifiziere "Abstand" der *beobachteten* gemeinsamen Häufigkeiten h_{ij} bzw. f_{ij} von den *unter Unabhängigkeit erwarteten* gemeinsamen Häufigkeiten $\tilde{h}_{ij}$ bzw. $\tilde{f}_{ij}$.



Empirische Unabhängigkeit

Idee:

X und Y “empirisch unabhängig” $\iff$

Verteilung von Y nicht beeinflusst von X (und umgekehrt) $\iff$

Bedingte relative Häufigkeiten von Y sind in jeder Teilpopulation $X = a_i$ identisch, d.h. unbeeinflusst von X :

$$f_{Y|X}(b_j|a_1) = f_{Y|X}(b_j|a_2) = \dots = f_{Y|X}(b_j|a_k), \forall j = 1, \dots, m$$

Vergleiche **stoch. Unabhängigkeit**: $A \perp B \iff P(A|B) = P(A)$

Bsp: Empirische Unabhängigkeit

	b_1	b_2	b_3	
a_1	10	20	30	60
a_2	20	40	60	120
	30	60	90	180

$$f_{Y|X}(b_1|a_1) = f_{Y|X}(b_1|a_2) = f_Y(b_1) = \frac{1}{6}$$

$$f_{Y|X}(b_2|a_1) = f_{Y|X}(b_2|a_2) = f_Y(b_2) = \frac{1}{3}$$

$$f_{Y|X}(b_3|a_1) = f_{Y|X}(b_3|a_2) = f_Y(b_3) = \frac{1}{2}$$

Bemerkung: Lokale Odds Ratios sind alle 1

Bsp: Empirische Unabhängigkeit

Wie sehen also die **unter empirischer Unabhängigkeit erwarteten** (absoluten und relativen) Häufigkeiten $\tilde{h}_{ij}$ und $\tilde{f}_{ij}$ aus?

$$f_{Y|X}(b_1|a_i) = f_Y(b_1), \dots, f_{Y|X}(b_m|a_i) = f_Y(b_m), \quad i = 1, \dots, k$$

$$\iff \frac{\tilde{h}_{ij}}{h_{i.}} = \frac{h_{.j}}{n}; \forall i = 1, \dots, k; j = 1, \dots, m$$

$$\iff \tilde{h}_{ij} = \frac{h_{i.} \cdot h_{.j}}{n}; \forall i = 1, \dots, k; j = 1, \dots, m$$

$$\iff \tilde{f}_{ij} = f_{i.} \cdot f_{.j}; \forall i = 1, \dots, k; j = 1, \dots, m$$

($\tilde{h}_{ij}$ sind üblicherweise keine ganzen Zahlen...)

Unabhängigkeitstabelle

Idee:

Vergleiche für jede Zelle (i, j) die *unter Unabh. erwarteten* $\tilde{h}_{ij}$ mit den *tatsächlich beobachteten* h_{ij}

χ^2 -**Koeffizient** ist bestimmt durch

$$\chi^2 := \sum_{i=1}^k \sum_{j=1}^m \frac{(h_{ij} - \tilde{h}_{ij})^2}{\tilde{h}_{ij}} = \sum_{i=1}^k \sum_{j=1}^m \frac{\left(h_{ij} - \frac{h_{i.} \cdot h_{.j}}{n}\right)^2}{\frac{h_{i.} \cdot h_{.j}}{n}} = n \sum_i \sum_j \frac{(f_{ij} - f_{i.} \cdot f_{.j})^2}{f_{i.} \cdot f_{.j}}$$

Eigenschaften des χ^2 -Koeffizienten

- ▶ $\chi^2 \in [0, n(\min(k, m) - 1)]$
- ▶ $\chi^2 = 0 \iff X$ und Y **empirisch unabhängig**
- ▶ χ^2 groß $\iff$ starker Zusammenhang
- ▶ χ^2 klein $\iff$ schwacher Zusammenhang

Schwachpunkt:

Wertebereich von χ^2 hängt vom Stichprobenumfang n und von der Dimension der Tafel ab. Numerischer Wert deshalb schwierig direkt interpretierbar $\rightarrow$ Normierung

Kontingenzkoeffizient und korrigierter Kontingenzkoeffizient

Weitere Normierung $\implies$ **Kontingenzkoeffizient**

Der Kontingenzkoeffizient ist bestimmt durch

$$K := \sqrt{\frac{\chi^2}{n + \chi^2}}$$

und besitzt den Wertebereich $K \in \left[0, \sqrt{\frac{M-1}{M}}\right]$, wobei $M = \min\{k, m\}$.

Der **korrigierte Kontingenzkoeffizient** ergibt sich durch

$$K^* := \frac{K}{\sqrt{(M-1)/M}}$$

mit dem Wertebereich $K^* \in [0, 1]$.

Eigenschaften des (korrigierten) Kontingenzkoeffizienten

- ▶ Es wird nur die *Stärke* des Zusammenhangs gemessen, nicht die Richtung wie beim Odds Ratio.
- ▶ Vorsicht ist geboten bei einem Vergleich von Kontingenztafeln gleicher Zellenzahl mit stark unterschiedlichen Stichprobenumfängen, da χ^2 mit wachsendem Stichprobenumfang wächst, beispielsweise führt eine Verzehnfachung von h_{ij} und $\tilde{h}_{ij}$ zu zehnfachem χ^2
- ▶ Sämtliche Maße benutzen nur das Nominalskalenniveau von X und Y .

Beispiel: Nachwahlbefragung 2021

Für die Kontingenztafel aus Geschlecht und Parteipräferenz für das Beispiel der Nachwahlbefragung erhält man die folgenden *zu erwartenden* Häufigkeiten $\tilde{h}_{ij}$.

	SPD	CDU/CSU	Grüne	FDP	AfD	Linke	Rest	Σ
Männer	649.12 (626)	601.24 (601)	373.80 (352)	291.64 (325)	254.10 (300)	124.60 (125)	209.48 (175)	2504
Frauen	543.88 (567)	503.76 (504)	313.20 (335)	244.36 (211)	212.90 (167)	104.40 (104)	175.52 (210)	2098
Σ	1193	1105	687	536	467	229	385	4602

Unter Unabh. erwartete Häufigkeiten $\tilde{h}_{ij}$ und beobachtete Häufigkeiten h_{ij} (in Klammern)

Interpretation: Wären Geschlecht und Parteipräferenz unabhängig, dann wären 649.12 SPD-wählende Männer in der Stichprobe zu erwarten gewesen, tatsächlich wurden aber nur 626 beobachtet.

Interpretation:

Insgesamt hier

- ▶ $\chi^2 = 43.6$
- ▶ $K = \sqrt{\frac{\chi^2}{\chi^2 + n}} = 0.097$ mit $n = 4602$
- ▶ $K^* = \frac{K}{\sqrt{(M-1)/M}} = 0.14$ mit $M = \min(7, 2)$

⇒ keine starke Abhängigkeit zwischen Geschlecht & Parteienpräferenz

Spezialfall: (2×2) -Tafel

Für den Spezialfall einer (2×2) -Tafel

a	b	$a + b$
c	d	$c + d$
$a + c$	$b + d$	

erhält man χ^2 aus

$$\chi^2 = \frac{n(ad - bc)^2}{(a + b)(a + c)(b + d)(c + d)}.$$

Beispiel: Arbeitslosigkeit

Aus der Kontingenztafel

	Mittelfristige Arbeitslosigkeit	Langfristige Arbeitslosigkeit	
Keine Ausbildung	19	18	37
Lehre	43	20	63
	62	38	100

erhält man also unmittelbar

$$\chi^2 = \frac{100(19 \cdot 20 - 18 \cdot 43)^2}{37 \cdot 63 \cdot 62 \cdot 38} = 2.8$$

und $K = 0.17$, $K^* = 0.23$.

Zusammenhangsmaße für diskrete Merkmale

Kontingenztafeln für diskrete und gruppierte Merkmale

Bedingte Häufigkeiten

Diskrete Zusammenhangsanalyse: Odds

Diskrete Zusammenhangsanalyse: Unabhängigkeit & Kontingenz

Multivariate Kontingenztafeln & Mosaikplots

Mehrdimensionale Kontingenztafeln

Beispiel: Überleben beim Titanic-Untergang

- ▶ Mehrere diskrete Merkmale:
 - ▶ Geschlecht (m / w)
 - ▶ Klasse (1st / 2nd / 3rd / Crew)
 - ▶ Alter (Kind/ Erwachsene)
 - ▶ Überleben (Ja / Nein)
- ▶ Darstellung durch geeignete bedingte und marginale Verteilungen
- ▶ Berechnung von Odds-Ratio zweier Merkmale bedingt auf ein drittes Merkmal
- ▶ grafische Darstellung durch Mosaik-Plot

Beispiel: Titanic

```
str(Titanic)
```

```
## 'table' num [1:4, 1:2, 1:2, 1:2] 0 0 35 0 0 0 17 0 118 154 ...
## - attr(*, "dimnames")=List of 4
## ..$ Class : chr [1:4] "1st" "2nd" "3rd" "Crew"
## ..$ Sex : chr [1:2] "Male" "Female"
## ..$ Age : chr [1:2] "Child" "Adult"
## ..$ Survived: chr [1:2] "No" "Yes"
```

⇒ echt multivariate Kontingenztafeln sind hochdimensionale Arrays

```
apply(Titanic, MAR = c(4, 1), FUN = sum)
```

```
##           Class
## Survived 1st 2nd 3rd Crew
##           No  122 167 528  673
##           Yes 203 118 178  212
```

⇒ (Gemeinsame) Randhäufigkeiten durch Akkumulation über restliche Merkmale/Dimensionen

Beispiel: Titanic

Randverteilung von “Klasse”:

```
apply(Titanic, FUN = sum, MAR = 1)
```

```
## 1st 2nd 3rd Crew  
## 325 285 706 885
```

Bedingte Verteilungen von “Überleben” gegeben “Klasse”:

```
apply(Titanic, FUN = sum, MAR = c(1, 4))/apply(Titanic, FUN = sum, MAR = 1)
```

```
##      Survived  
## Class      No  Yes  
## 1st  0.38 0.62  
## 2nd  0.59 0.41  
## 3rd  0.75 0.25  
## Crew 0.76 0.24
```

Beispiel: Titanic

```
apply(Titanic, FUN = sum, MAR = c(2, 4))
```

```
##           Survived
## Sex           No Yes
## Male      1364 367
## Female    126 344
```

Bedingte Verteilung:

```
apply(Titanic, FUN = sum, MAR = c(2, 4))/apply(Titanic, FUN = sum, MAR = c(2))
```

```
##           Survived
## Sex           No Yes
## Male      0.79 0.21
## Female    0.27 0.73
```

Überlebens-Chance Frauen: $\frac{344}{126} \approx 2.7 \approx 3 : 1$


Überlebens-Chance Männer: $\frac{367}{1364} \approx 0.27 \approx 1 : 3$

Chancenverhältnis: 10

Mosaik-Plot


- ▶ *Flächentreue* Darstellung von gemeinsamen Häufigkeiten
- ▶ Aufteilung schrittweise:
Zuerst nach *Einflussgrößen*, dann nach *Zielgröße* aufteilen
- ▶ Gut geeignet für mehrkategoriale ordinale Daten
- ▶ Auch für höhere Dimensionen geeignet (... angeblich)
- ▶ für 2 Dimensionen: entspricht gestapeltem Balkendiagramm mit variabler Balkenbreite

Beispiel: Überlebende bei Titanic



Beispiel: Titanic

Zellen eingefärbt nach $\frac{(h_{ij} - \tilde{h}_{ij})}{\sqrt{\tilde{h}_{ij}}}$ (standardized pearson residuals):



Beispiel: Titanic

