

Zufallsvariablen, Verteilungen & Häufigkeiten

Diskrete Zufallsvariablen

Stetige Zufallsvariablen

Empirische Häufigkeitsverteilungen

Empirische Verteilungsfunktion

Zufallsvariablen, Verteilungen & Häufigkeiten

Zufallsvariablen - Motivation

- ▶ Ergebnisse von Zufallsvorgängen sind nicht notwendigerweise Zahlen
- ▶ Oft ist es aber hilfreich diese durch Zahlen zu repräsentieren, um mit ihnen rechnen zu können
- ▶ Beispiel: 3-maliger Wurf einer Münze

$$\Omega = \{Z, K\} \times \{Z, K\} \times \{Z, K\}$$

$$|\Omega| = 2^3 = 8$$

$$\text{z.B. } \omega = ZKZ := (Z, K, Z)$$

Angenommen man interessiert sich für

$$Y := \text{“Anzahl Kopf”}$$

Dann nennt man Y eine **Zufallsvariable** (ZV) mit reellwertigen **Ausprägungen** bzw. **Realisierungen** $y \in T \subseteq \mathbb{R}$.

Man schreibt kurz $Y = y$, wenn die *Ausprägung* y der ZV Y eingetreten ist.

Zufallsvariable - Definition

Def.: Träger einer ZV

Die Menge der möglichen Ausprägungen einer ZV X heißt *Träger* T_X der ZV X

Im Bsp: $T_Y = \{0, 1, 2, 3\}$

Def.: Zufallsvariable


Eine *Zufallsvariable* X ist eine **eindeutige Abbildung** von Ω nach $T_X \subseteq \mathbb{R}$:

$$X : \Omega \rightarrow T_X$$

- ▶ Eine Zufallsvariable X ordnet also jedem Elementarereignis $\omega \in \Omega$ *genau einen* Zahlenwert $x \in T_X$ zu: $X(\omega) = x$
- ▶ Mehrere Elementarereignisse können dem selben Zahlenwert zugeordnet werden.
- ▶ Unterscheide: Zufallsvariable $X : \Omega \rightarrow T_X$
vs. Ausprägungen/Realisierungen $x = X(\omega)$ von X .

Zufallsvariable - Diagramm

Zufallsvariable $X(\omega)$: Abbildung von Ω auf T_X



Zufallsvariable - Motivation

- ▶ Man kann mit X “rechnen”: z.B $P(X \leq a)$ oder $P(X^2 > b)$, oder “Welches Ergebnis erwarten wir ‘im Mittel’?”
- ▶ Ursprünglicher Wahrscheinlichkeitsraum (Ω, P) wird letztendlich nicht mehr benötigt, stattdessen nur Wahrscheinlichkeiten für die Werte der ZV
 - ⇒ meist deutlich einfacher zu handhaben
 - im Bsp: Verteilung über $\{0, 1, 2, 3\}$ statt über $\{KKK, KKZ, KZK, \dots, ZZK, ZZZ\}$
- ▶ Mathematische Formalisierung eines (quantitativen) Messvorgangs – jeder möglichen Beobachtung (= Elementarereignis) wird genau ein Zahlenwert zugeordnet.
 - in vielen Anwendungen Ω kaum zugänglich oder mathematisch formalisierbar und nur Ergebnis des Messvorgangs überhaupt *beobachtbar*
 - ⇒ ZV zentraler Begriff für statistische Anwendungen und Ansatzpunkt für mathematische Formalisierung empirischer Phänomene

Zufallsvariablen, Verteilungen & Häufigkeiten

Diskrete Zufallsvariablen

Stetige Zufallsvariablen

Empirische Häufigkeitsverteilungen

Empirische Verteilungsfunktion

Diskrete Zufallsvariable

Def.: Diskrete Zufallsvariable

Eine ZV X heißt **diskret**, falls sie nur endlich oder abzählbar unendlich viele Werte $x_1, x_2, \dots$ annehmen kann, also: falls die Menge $T = \{x_1, x_2, \dots\}$ der möglichen Ausprägungen x_i von X mit $P(X = x_i) > 0$ abzählbar ist.

Def.: Wahrscheinlichkeitsfunktion einer diskreten ZV

Die *Wahrscheinlichkeitsfunktion* von X ist durch

$$f_X(x_i) := P(X = x_i) = P(\{\omega \in \Omega : X(\omega) = x_i\})$$

für $x_i \in \mathbb{R}$ gegeben.

- Alternativ: “Wahrscheinlichkeitsdichte”

Folgerungen

Als Funktion von $B \subset \mathbb{R}$ ist also

$$P(X \in B) = P(\{\omega \in \Omega : X(\omega) \in B\})$$

eine Wahrscheinlichkeitsverteilung auf $\mathbb{R}$.

Man nennt diese die **Verteilung** der Zufallsvariable X .

Sie ist durch die Abbildung X und die Wahrscheinlichkeitsverteilung P über $\omega \in \Omega$ induziert.

Für $x \notin T_X$ ist $f_X(x) = P(\emptyset) = 0$.

Die Verteilungsfunktion

Def.: Verteilungsfunktion (diskret)

Die *Verteilungsfunktion* einer diskreten ZV ist definiert als

$$F_X(x) := P(X \leq x) = \sum_{i: x_i \leq x} f_X(x_i).$$

Kennt man also die **Wahrscheinlichkeitsfunktion** $f(x)$ für alle $x \in T$, so kennt man auch die **Verteilungsfunktion** $F(x)$ und umgekehrt.

Eigenschaften der Verteilungsfunktion

- ▶ $F(x)$ ist monoton wachsend (“Treppenfunktion”)
- ▶ $F(x)$ ist stückweise konstant mit Sprungstellen an Werten x_i mit $f(x_i) > 0$, d.h. an allen Realisierungen $x_i \in T$
- ▶ Die Höhe des Sprungs an der Stelle $x_i \in T$ ist $f(x_i)$
- ▶ $\lim_{x \rightarrow \infty} F(x) = 1$
- ▶ $\lim_{x \rightarrow -\infty} F(x) = 0$

Beispiel: 3-maliger Münzwurf

$X := \text{"Anzahl Kopf"} , T = \{0, 1, 2, 3\}$

$$f(0) = P(\{ZZZ\}) = 1/8$$

$$f(1) = P(\{KZZ, ZKZ, ZZK\}) = 3/8$$

$$f(2) = P(\{KKZ, KZK, ZKK\}) = 3/8$$

$$f(3) = P(\{KKK\}) = 1/8$$

$\Rightarrow$

$$F(x) = \begin{cases} 0 & x < 0 \\ 1/8 & 0 \leq x < 1 \\ 4/8 & 1 \leq x < 2 \\ 7/8 & 2 \leq x < 3 \\ 1 & x \geq 3 \end{cases}$$

Beachte: $f(x) = 0$ für alle $x \notin T$

Zufallsvariablen, Verteilungen & Häufigkeiten

Diskrete Zufallsvariablen

Stetige Zufallsvariablen

Empirische Häufigkeitsverteilungen

Empirische Verteilungsfunktion

Stetige Zufallsvariable - Definition 1

Def.: Stetige Zufallsvariable

Eine Zufallsvariable X ist **stetig**, falls ihr Träger eine *überabzählbare* Teilmenge der reellen Zahlen $\mathbb{R}$ ist.

Beispiel:

Glücksrad mit stetigem Wertebereich $[0^\circ, 360^\circ)$

Von Interesse also die Zufallsvariable, die den *exakten* Winkel angibt, an dem das Glücksrad stehen bleibt.

Stetige Zufallsvariablen - Definition 2

Def.: Stetige Zufallsvariable

Eine Zufallsvariable X heißt *stetig*, wenn es eine Funktion $f(x) \geq 0$ gibt, so dass sich die Verteilungsfunktion $F_X(x) := P(X \leq x)$ von X wie folgt darstellen lässt:

$$F_X(x) = \int_{-\infty}^x f_X(u) du$$

Def.: Dichtefunktion einer (stetigen) ZV

Diese nicht-negative Funktion $f(x)$ zur Verteilungsfunktion $F(x)$ heißt *Wahrscheinlichkeitsdichte* (auch: *Dichte* oder *Dichtefunktion*) von X .

Beachte: bei *diskreten* Zufallsvariablen gilt $F(x) = \sum_{i: x_i \leq x} f(x_i)$.

Dichtefunktionen

- ▶ Nicht-negative, *normierte* Funktion $f(x) \geq 0$ mit $\int_{-\infty}^{+\infty} f(x) dx = 1$
- ▶ $f(x)$ selbst gibt **keine W.keit** an, sondern misst die “Dichte” von Realisierungen von X in der Umgebung von x
- ▶ Intuitiv: Je höher die Dichte an einer Stelle, desto mehr “W.keit” steckt in der Umgebung dieser Stelle
 - ▶ Je größer $f(x)$, desto wahrscheinlicher ist es, dass X Werte in der Nähe von x annimmt
 - ▶ W.keit für X in einem Intervall $[a, b]$ ist

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$

– Dichte also quasi *Vorstufe* von Wahrscheinlichkeiten

Folgerungen

- ▶ $F(x)$ einer stetigen ZV ist
 - ▶ stetig und
 - ▶ monoton wachsend
 - ▶ mit $\lim_{x \rightarrow \infty} F(x) = 1$, $\lim_{x \rightarrow -\infty} F(x) = 0$
- ▶ $\int_{-\infty}^{+\infty} f(x) dx = 1$ (da $F(\infty) = 1$)
- ▶ Mit Dichte- bzw. Verteilungsfunktion lassen sich W.keiten für beliebige Teilmengen des Trägers ausrechnen:
 $P(X \in [a, b]) = \int_a^b f(x) dx = F(b) - F(a)$
 $\implies$ **Unintuitive Konsequenz:** für stetige ZV gilt

$$P(X = x) = 0 \quad \forall x \in \mathbb{R} (!!)$$

$$\text{da } \int_x^x f_X(u) du = 0$$

Video dazu von [3blue1brown](#)

Folgerungen

- ▶ $\lim_{x \rightarrow -\infty} F(x) = 0$
- ▶ $\lim_{x \rightarrow \infty} F(x) = 1$
- ▶ $F'(x) = f(x)$ überall dort wo $f(x)$ stetig ist.
- ▶ $P(a \leq X \leq b) = F(b) - F(a)$
- ▶ $P(X > a) = 1 - F(a)$

Stringentere Definitionen in späteren Vorlesungen zu W.theorie

Eine allgemein gültige Definition ohne Fallunterscheidungen zwischen

- ▶ diskreten ZVn,
- ▶ stetigen ZVn,
- ▶ und ZVn, deren Träger teils stetig und teils diskret ist,

benötigt Maßtheorie mit einem verallgemeinertem Integrationsbegriff.

Für Expert:innen und Profis: $\int_{[a,b]} dP_X = \int_{[a,b]} f_X d\mu = \int_a^b f_X(x) dx$

- ▶ Maßintegral bzgl W.keitsmaß P_X wird im stetigen Fall dargestellt als Lebesgue-Integral der Dichte f_X , und dieses als Riemann-Integral.
- ▶ im diskreten als Zählmaß-Integral der Wahrscheinlichkeitsfunktion f_X
- ▶ sonst als gemischtes Maßintegral mit Darstellung über eine gemischte W.keits- und Dichtefunktion.

Zufallsvariablen, Verteilungen & Häufigkeiten

Diskrete Zufallsvariablen

Stetige Zufallsvariablen

Empirische Häufigkeitsverteilungen

Empirische Verteilungsfunktion

Empirische Häufigkeitsverteilungen

Zurück zur Empirie

Zufallsvariablen sind Bestandteil der mathematischen Formalisierung eines zufälligen Prozesses.

Jetzt: Betrachte *empirische* Entsprechungen der eben eingeführten Begriffe.

Häufigkeitsverteilung: Notation & Terminologie

Im Weiteren:

- ▶ $X, Y, \dots$ Bezeichnung für **Merkmale**
- ▶ n ist Anzahl der **Untersuchungseinheiten**
- ▶ $x_i, i \in \{1, \dots, n\}$ ist **beobachteter Wert** bzw. **Merkmalsausprägung** von Merkmal X für i -te Untersuchungseinheit
- ▶ $x_1, \dots, x_n$ **Rohdaten, Urliste**
- ▶ $a_1, a_2, \dots, a_k, k \leq n$ (evtl. der Größe nach geordnete) *verschiedene* Werte der Urliste $x_1, \dots, x_n$: die **Menge der beobachteten Merkmalsausprägungen** von X .

Eindimensionale Häufigkeitsverteilung

- ▶ Sortierung der Daten nach einem Merkmal
- ▶ Auszählen der Häufigkeiten der einzelnen Merkmalsausprägungen
- ▶ **Relative Häufigkeiten** = Häufigkeit einer Merkmalsausprägung / Anzahl der Untersuchungseinheiten (*Anteil*)
- ▶ **Kumulative relative Häufigkeiten** bei ordinal oder metrisch skalierten Merkmalen sinnvoll:
 $F(x) :=$ "Anteil UE mit Merkmalsausprägung $\leq x$ " heißt **empirische Verteilungsfunktion**

Häufigkeitsverteilungen

Bemerkungen:

- ▶ Für Nominalskalen hat die Anordnung “<” keine inhaltliche Bedeutung.
- ▶ Bei kategorialen Merkmalen k = Anzahl der Kategorien
- ▶ Bei stetigen Merkmalen k oft nicht oder kaum kleiner als n .

Absolute und relative Häufigkeiten

$h(a_j) = h_j$ **absolute Häufigkeit** der Ausprägung a_j ,

d.h. Anzahl der x_i aus $x_1, \dots, x_n$ mit $x_i = a_j$

$f(a_j) = f_j = h_j / n$ **relative Häufigkeit** von a_j

$h_1, \dots, h_k$ **absolute Häufigkeitsverteilung**

$f_1, \dots, f_k$ **relative Häufigkeitsverteilung**

Bemerkungen:

- ▶ Wenn statt der Urliste bereits die Ausprägungen $a_1, \dots, a_k$ und ihre Häufigkeiten $f_1, \dots, f_k$ bzw. $h_1, \dots, h_k$ vorliegen, sprechen wir von **Häufigkeitsdaten**.
- ▶ **Klassenbildung, gruppierte Daten:** Vor allem bei metrischen, stetigen (oder quasi-stetigen) Merkmalen oft Aggregation der Urliste durch Bildung geeigneter Klassen

Beispiel Nettomieten I

Wir greifen aus dem gesamten Datensatz des Münchner Mietspiegels 2015 die Wohnungen ohne zentrale Warmwasserversorgung ($zh0 == 1$) und mit einer Wohnfläche kleiner als $60m^2$ ($wf1 < 60$) heraus.

Die folgende Urliste zeigt, bereits der Größe nach geordnet, die Nettomieten dieser $n = 88$ Wohnungen:

```
mietspiegel_url <- "http://chris.userweb.mwn.de/statistikbuch/mietspiegel2015.txt"
mietspiegel <- read.table(file = mietspiegel_url, header = TRUE)
klein_und_kalt <- subset(mietspiegel, zh0 == 1 & wf1 < 60)
sort(klein_und_kalt[, "nm"]) |>
  print(digits = 4)
```

```
## [1] 174.8 175.0 211.0 211.9 212.9 245.0 257.2 266.8 276.6 278.1 282.4 287.4
## [13] 294.9 299.5 302.9 308.4 315.7 318.0 322.0 323.0 330.0 336.0 336.0 338.5
## [25] 339.7 343.0 346.5 362.0 363.5 370.0 375.1 379.6 380.0 390.4 391.4 395.1
## [37] 408.9 410.0 415.6 421.8 437.7 440.0 440.0 443.6 446.6 451.6 452.2 461.9
## [49] 470.0 472.4 480.8 490.0 495.0 500.0 510.0 513.0 515.0 515.0 517.1 518.0
## [61] 520.2 521.6 523.0 526.5 540.0 543.0 550.0 551.0 556.0 570.0 570.0 573.5
## [73] 576.0 590.0 590.0 590.0 600.7 610.0 610.0 630.0 638.0 660.0 695.0 700.0
## [85] 700.0 726.9 730.0 790.0
```

Alle Werte verschieden:

$$\Rightarrow k = n \text{ und } \{x_1, \dots, x_n\} = \{a_1, \dots, a_k\}; f_j = \frac{1}{88} \forall j = 1, \dots, 88.$$

Beispiel Nettomieten II

Gruppiert man die Urliste in 7 Klassen mit gleicher Klassenbreite von 100€, so erhält man folgende Häufigkeitstabelle:

```
gruppierung <- seq(from = 150, to = 850, by = 100)
klein_und_kalt[, "nm_gruppiert"] <- cut(klein_und_kalt[, "nm"], breaks = gruppierung)
table(klein_und_kalt[, "nm_gruppiert"])
```

```
##
## (150,250] (250,350] (350,450] (450,550] (550,650] (650,750] (750,850]
##          6         21         18         22         14         6         1
```

Klasse	absolute H.keit	relative H.keit	kumulative rel. H.keit
(150,250]	6	0.07	0.07
(250,350]	21	0.24	0.31
(350,450]	18	0.20	0.51
(450,550]	22	0.25	0.76
(550,650]	14	0.16	0.92
(650,750]	6	0.07	0.99
(750,850]	1	0.01	1.00

Zufallsvariablen, Verteilungen & Häufigkeiten

Diskrete Zufallsvariablen

Stetige Zufallsvariablen

Empirische Häufigkeitsverteilungen

Empirische Verteilungsfunktion

Empirische Verteilungsfunktion

Häufigkeitsfunktion:

$$H(x) := (\text{Anzahl der Werte } \leq x)$$

Verteilungsfunktion:

$$F_n(x) = H(x)/n = (\text{Anteil der Werte } x_i \text{ mit } x_i \leq x)$$

bzw.

$$F_n(x) = f(a_1) + \dots + f(a_j) = \sum_{i: a_i \leq x} f_i,$$


für $a_j \leq x$ und $a_{j+1} > x$.

****ECDF**** (empirical cumulative distribution function)

Eigenschaften der ECDF $F_n(x)$


- ▶ monoton wachsende Treppenfunktionen mit Sprüngen an den Ausprägungen $a_1, \dots, a_k$
- ▶ Sprunghöhen: $f_1, \dots, f_k$
- ▶ rechtsseitig stetig
- ▶ $F_n(x) = 0$ für $x < a_1$, $F_n(x) = 1$ für $x \geq a_k$

Beispiel: F_n (Quadratmetermiete) für Klein & Kalt




Beispiel: F_n (Quadratmetermiete) für Klein & Kalt

Wie groß ist der Anteil von kleinen Wohnungen ohne ZH mit qm-Miete ≤ 12 €? Wie viel kosten die günstigsten 25% der Wohnungen höchstens?



Beispiel: F_n (Quadratmetermiete) für Klein & Kalt

Wie groß ist der Anteil von kleinen Wohnungen ohne ZH mit qm-Miete ≤ 12 €?




$\Rightarrow \approx 80\%$

Beispiel: F_n (Quadratmetermiete) für Klein & Kalt

Wie viel kosten die günstigsten 25% der Wohnungen höchstens?

Was ist die maximale qm-Miete im billigsten unteren Viertel der Wohnungen?



Theorie & Empirie

Theorie		Empirie
Zufallsvariable X	$\cong$	Merkmal X
Träger T_X	$\supseteq$	Beobachtete Merkmalsausprägungen $\{a_1, \dots, a_k\}$ von X
W.kheitsfunktion $f_X(x)$	$\leftrightarrow$	relative H.keiten $f_X(a_j)$
Verteilungsfunktion $F_X(x)$	$\leftrightarrow$	kumul. relative H.keiten / empirische Verteilungsfunktion $F_n(x)$