

Statistische Grafiken

Grammar of Graphics

Grafiken: Wahrnehmung

Grafiken: Infoviz vs Statistische Grafiken

Farbskalen

Diskrete Merkmale: Visualisierung von Häufigkeiten und Verteilungen

Metrische Merkmale: Visualisierung von Häufigkeiten und Verteilungen

Kerndichteschätzung

Metrische Merkmale: Visualisierung gemeinsamer Verteilungen

Statistische Grafiken

Grammar of Graphics

Grafiken: Wahrnehmung

Grafiken: Infoviz vs Statistische Grafiken

Farbskalen

Diskrete Merkmale: Visualisierung von Häufigkeiten und Verteilungen

Metrische Merkmale: Visualisierung von Häufigkeiten und Verteilungen

Kerndichteschätzung

Metrische Merkmale: Visualisierung gemeinsamer Verteilungen

Statistische Grafik

Statistische Grafiken

repräsentieren die *Ausprägungen* gewisser *Merkmale* in einem *Datensatz* durch die *ästhetischen* Eigenschaften *geometrischer* Objekte.

Aus dieser Definition können wir eine formale “Grammatik” für grafische Darstellungen ableiten.

(s.a. Wilkinson (2005) *The Grammar of Graphics*,

Wickham et al. (2020) *ggplot2: Elegant Graphics for Data Analysis*)

Grammar of Graphics

(Fast) jede sinnvolle Grafik lässt sich als Kombination der folgenden Basis-Elemente beschreiben:

- ▶ *Daten*: enthalten die *Beobachtungen* der dargestellten *Merkmale* (Oft auch: daraus abgeleitete *Statistiken* wie Anteile, Mittelwerte, etc)
- ▶ *Geometrische Elemente*: z.B. Punkte, Linien, Rechtecke, etc...
- ▶ *Ästhetische Zuordnungen*: die *Ausprägungen* der in der Grafik dargestellten *Merkmale* werden durch sichtbare Eigenschaften der geometrischen Elemente repräsentiert, z.B.
 - ▶ Position (vertikal/horizontal)
 - ▶ Farbe
 - ▶ Größe
 - ▶ Form

Grammar of Graphics

Also: *Daten* werden über *ästhetische Eigenschaften* von *geometrischen Elementen* dargestellt.

zusätzlich:

- ▶ *Datentransformationen/Statistiken*: Oft werden nicht Rohdaten selbst, sondern daraus abgeleitet Größen (Mittelwerte, Anteile,) abgebildet. Komplexere geometrische Elemente basieren oft intern auf Datentransformationen (→ Balkendiagramme, geglättete Trendlinien, Boxplots,).
- ▶ *Skalen ordnen* für ein gegebenes *Merkmal/Statistik* und ihrer *ästhetischen Zuordnung* jeder *Ausprägungen* bestimmte Werte zu (z.B. Achsenabschnitte für Position, Farbpaletten für Farbe, etc...) und legen damit auch Legenden (z.B. für Farbskalen) und Achsenbeschriftungen fest.
- ▶ *Koordinatensysteme*: kartesische / logarithmische / Polarkoordinatensysteme; Kartenprojektionen

Grammar of Graphics


zusätzlich:

- ▶ *Facettierung* definiert anhand welcher Merkmale die Daten in Subgruppen aufgeteilt werden und wie die Darstellungen der verschiedenen Subgruppen arrangiert werden (s.a.: *small multiples plot*, *lattice plots*).
- ▶ *Theme*: umfasst sämtliche Designaspekte wie Fonteigenschaften, Gitterlinien, Hintergrundfarben, Layout von Textelementen und Legenden, ...

Implementation in R: `ggplot2`

Python: `plotnine`

Beispiele: Geometrien




.. und viele viele mehr ...


Abb: Wickham et al. (2020)

Beispiele: Ästhetiken

position



shape




size



color



line width



line type



Abb: Wilke (2020)

Grammar of Graphics: Beispiele mit Code

Aden-Buie, 2018

Reynolds, 2019

Statistische Grafiken

Grammar of Graphics

Grafiken: Wahrnehmung

Grafiken: Infoviz vs Statistische Grafiken

Farbskalen

Diskrete Merkmale: Visualisierung von Häufigkeiten und Verteilungen

Metrische Merkmale: Visualisierung von Häufigkeiten und Verteilungen

Kerndichteschätzung

Metrische Merkmale: Visualisierung gemeinsamer Verteilungen

Wahrnehmung von Grafiken

Wahrnehmungspsychologische Experimente zeigen deutliche Unterschiede in der korrekten Interpretation der folgenden Grafiktypen:





Abb.: Healy, K. (2018). *Data visualization: a practical introduction*. Princeton University Press. (übernommen aus Heer & Bostock)

Cleveland, W.S., McGill, R. (1984): *Graphical Perception: Theory, Experimentation, and Application to the Development of Graphical Methods*. *JASA* 79(387), 531-554.


Heer, J., Bostock, M. (2010): *Crowdsourcing graphical perception: using Mechanical Turk to assess visualization design*. *SIGCHI Proceedings*, 203-212.

Wahrnehmung von Grafiken

Cleveland & McGill's Results



Crowdsourced Results



Wahrnehmung von Grafiken

Hierarchie der korrekten Interpretation:

1. Position (gemeinsame/parallele Skala > verschobene Skalen)
2. Abstände & Längen
3. Steigung & Winkel
4. Flächen
5. Volumen
6. Farbton-Farbsättigung-Farbhelligkeit

Da **Position & Abstände** am besten wahrgenommen werden, müssen diese verwendet werden um die wichtigsten Merkmale zu codieren.

Principles of Graphical Excellence

- ▶ Graphical excellence is the well-designed presentation of interesting data – a matter of *substance*, of *statistics* and of *design*.
- ▶ Graphical excellence consists of complex ideas communicated with *clarity*, *precision* and *efficiency*.
- ▶ Graphical excellence is that which gives to the viewer the *greatest number of ideas* in the *shortest time* with the *least ink* in the *smallest space*.
- ▶ Graphical excellence is nearly always *multivariate*.
- ▶ And graphical excellence requires telling the *truth about the data*.

Tufte, E. (2001): *The Visual Display of Information*. Graphic Press 2nd ed.

Goldene Regeln für Grafikgestaltung

- ▶ Verständnis von Grafiken erfordert:
 - ▶ *Detektion*: Erkennen welche geometrischen Elemente und ästhetische Eigenschaften welche Werte repräsentieren
 - ▶ *Synthese*: Gruppierung & In-Relation-Setzen der entdeckten Inhalte
 - ▶ *Evaluation*: Bewertung der relativen Größen und Bedeutung dieser Inhalte.
Speziell: Unterscheidung, Rangbildung, Abschätzung von Verhältnissen.
- ▶ alle drei Phasen unterstützt durch *bewusste Wahl*
 - ▶ geeigneter Ästhetiken & Geometrien (s.o.: Abstände > Farbe, etc.)
 - ▶ geeigneter Achsen, Gitterlinien und Seitenverhältnisse
 - ▶ inhaltlich adäquater Sortierung/Reihenfolge der Ausprägungen qualitativer Merkmale
 - ▶ entsprechender Annotationen & Hervorhebungen

⇒ **Kommunikationsabsicht** klarmachen:

Welche Informationen will ich primär vermitteln? Welche zusätzlich? Auf welche Vergleiche soll Aufmerksamkeit gelenkt werden?

⇒ **Lesbarkeit** maximieren – sowohl Genauigkeit als auch Geschwindigkeit/Schwierigkeit sind wichtig.

Harrell, F.E. (2017), *Principles of Graph Construction*;

Grolemund, G., Wickham, H. (2017) *R for Data Science*, Ch. 28; Rauser, J. (2016) *How Humans See Data*

Statistische Grafiken

Grammar of Graphics

Grafiken: Wahrnehmung

Grafiken: Infoviz vs Statistische Grafiken

Farbskalen


Diskrete Merkmale: Visualisierung von Häufigkeiten und Verteilungen

Metrische Merkmale: Visualisierung von Häufigkeiten und Verteilungen


Kerndichteschätzung

Metrische Merkmale: Visualisierung gemeinsamer Verteilungen


“Infoviz” vs Statistische Grafiken I




“Infoviz” vs Statistische Grafiken I




“Infoviz” vs Statistische Grafiken I




“Infoviz” vs Statistische Grafiken II




“Infoviz” vs Statistische Grafiken II




“Infoviz” vs Statistische Grafiken II



“Infoviz” vs Statistische Grafiken IV



“Infoviz” vs Statistische Grafiken IV



Statistische Grafiken

Grammar of Graphics

Grafiken: Wahrnehmung

Grafiken: Infoviz vs Statistische Grafiken

Farbskalen

Diskrete Merkmale: Visualisierung von Häufigkeiten und Verteilungen

Metrische Merkmale: Visualisierung von Häufigkeiten und Verteilungen

Kerndichteschätzung

Metrische Merkmale: Visualisierung gemeinsamer Verteilungen

Wahrnehmung Ästhetischer Zuordnungen

Kodieren von Information durch:

- ▶ **Position, Längen & Abstände:** am einfachsten zu erkennen, v.a. für gemeinsame/parallele Skalen
- ▶ **Winkel & Steigung:** visueller Eindruck abhängig von Richtung & vom Seitenverhältnis der Darstellung
- ▶ **Flächen:**
 - ▶ lang/dünn erscheint größer als kompakt/konvex
 - ▶ abhängig von Farbe: hellere Flächen wirken größer
- ▶ **Farbe:** oft schwierig präzise Vergleiche abzulesen
 - ▶ dennoch allgegenwärtig da *kombinierbar* mit anderen grafischen Elementen.


Farbwahrnehmung

- ▶ Farbwahrnehmung ist komplex
- ▶ Farben für Grafiken so wählen dass **Wahrnehmungseinheitlichkeit** berücksichtigt wird:
 - ▶ Grün-/Gelbtöne werden bei gleicher Sättigung intensiver wahrgenommen als andere Farben
 - ▶ Sehschwächen mitbedenken

Farbwahrnehmung







Rot-Grün-Sehschwäche

(Protanopia: Prävalenz 6%, Deutanopia: Prävalenz 2%)



aus Wong, B. *Nature Methods* 8(6), p. 441 (2011).

Wahrnehmungseinheitlichkeit: Veranschaulichung



Farbräume

- ▶ repräsentieren Farben als (Vektoren von) Zahlen
- ▶ “technische” Farbräume: RGB (Rot-Grün-Blau, für Bildschirme) oder CMYK (Cyan-Magenta-Yellow-Black, für Druck)
- ▶ Additive Farbräume wie RGB / CMYK entsprechen nicht Funktionsweise der menschlichen Wahrnehmung, deswegen:
- ▶ Farbräume:
 - ▶ HCL: hue-chroma-luminance
 - ▶ HSV: hue-saturation-value
 - ▶ Lab: Lightness-a (grün-rot Achse) - b (blau-gelb Achse)

HCL - Farbraum


- ▶ **Farbton:** dominante Wellenlänge (*hue*)
 - ▶ kreisförmige Dimension (grün - gelb - rot - lila - blau - grün)



- ▶ **Farbsättigung** (*chroma*)
- ▶ **Helligkeit** (*luminance*)

HCL - Farbraum



- ▶ **Farbton:** dominante Wellenlänge (*hue*)
 - ▶ kreisförmige Dimension (rot - gelb - grün - blau - lila - rot)
- ▶ **Farbsättigung** (*saturation, chroma*)



- ▶ **Helligkeit** (*brightness, luminance*)


HCL - Farbraum

- ▶ **Farbton:** dominante Wellenlänge (*hue*)
 - ▶ kreisförmige Dimension (rot - gelb - grün - blau - lila - rot)
- ▶ **Farbsättigung** (*saturation, chroma*)
- ▶ **Helligkeit** (*brightness, luminance*)



HCL - Farbraum

- ▶ **Farbton:** dominante Wellenlänge (*hue*)
 - ▶ kreisförmige Dimension (rot - gelb - grün - blau - lila - rot)
- ▶ **Farbsättigung** (*saturation, chroma*)
- ▶ **Helligkeit** (*brightness, luminance*)



Farbskalentypen

- ▶ **Qualitativ:** (eher) nur für nominales Skalenniveau.
- ▶ **Sequentiell:** mindestens ordinales Skalenniveau
- ▶ **Divergierend:** mindestens ordinales Skalenniveau, mit “neutralem” mittleren Wert.

Farbskalen für nominales Skalenniveau

Qualitative Farbskalen für nominale Variablen:


- ▶ Fokus auf **Unterscheidbarkeit** bei gleichbleibender “Prägnanz”
- ▶ Variierender *Farbton* bei konstanter Sättigung & Helligkeit (korrigiert für menschliche Wahrnehmung)



barrierefrei – lesbar auch bei Sehschwächen




Beispiel



Erster Vokal im Namen




Sinnvoll, aber viel rot-grün Kontrast



Erster Vokal im Namen




Bessere Balance, weniger rot-grün



Erster Vokal im Namen



Ok, aber Farben implizieren Ordnung



Erster Vokal im Namen



Schlechte Farbskala! Zu viel (rot-grün) Kontrast & Sättigung.

Sequentielle Farbskalen

- ▶ konstanter Farbton und Sättigung, variiere nur Helligkeit



- ▶ mehrere Farbtöne, mit variierender Sättigung und abnehmender Helligkeit



- ▶ Höchste Prägnanz für Werte die mit niedriger Helligkeit kodiert werden.

Beispiel



Electoral College Votes



10 20 30 40 50

Sinnvoll, aber evtl. kleine Unterschiede verwischt




Electoral College Votes



10 20 30 40 50

Sinnvoll, aber evtl. kleine Unterschiede verwischt



Electoral College Votes



10 20 30 40 50

Sinnvoll, aber besser dunklere Farben für 'wichtigere' Werte



Electoral College Votes



10 20 30 40 50

Sinnvoll, überbetont evtl. kleine Unterschiede durch Farbübergänge


Divergierende Farbskalen

- ▶ 2 sequentielle Skalen mit je konstantem Farbton werden kombiniert





- ▶ “neutrale” Mitte: höchste Prägnanz für obere und untere Enden der Skala



Beispiel: Divergierende Farbskalen




Minority / Majority for Trump [2016, %]




Minority / Majority for Trump [2016, %]




Minority / Majority for Trump [2016, %]



Mitte nicht viel weniger prägnant als Enden.




Minority / Majority for Trump [2016, %]



Nicht divergierend: Mitte nicht viel weniger prägnant als Enden, zu bunt!

Beispiel: Divergierende Farbskalen

Differenz der Änderungsraten von Median-Bruttolöhnen und
Neuvertragsmieten 2014 - 2018:



Quelle: IW, Berliner Morgenpost (17.01.2020)

Statistische Grafiken

Grammar of Graphics

Grafiken: Wahrnehmung

Grafiken: Infoviz vs Statistische Grafiken

Farbskalen

Diskrete Merkmale: Visualisierung von Häufigkeiten und Verteilungen

Metrische Merkmale: Visualisierung von Häufigkeiten und Verteilungen

Kerndichteschätzung

Metrische Merkmale: Visualisierung gemeinsamer Verteilungen

Visualisierung der Häufigkeiten diskreter Merkmale

(Bedingte) Häufigkeiten für diskrete/gruppierte Merkmale darstellbar u.a. als

- ▶ Stab-, Balken- und Säulendiagramm
- ▶ Histogramm
- ▶ (Kreis-/Tortendiagramm)

Stab-, Säulen-, Balkendiagramm

- ▶ **Stabdiagramm:** Trage über $a_1, \dots, a_k$ jeweils einen zur x-Achse senkrechten Strich (Stab) mit Höhe $h_1, \dots, h_k$ (oder $f_1, \dots, f_k$) ab.
- ▶ **Säulendiagramm** wie Stabdiagramm, aber mit Rechtecken statt Strichen.
- ▶ **Balkendiagramm:** wie Säulendiagramm, aber mit vertikal statt horizontal gelegter x-Achse.

Anwendungen:

- ▶ Ordinale Merkmale
- ▶ Metrische Merkmale mit *wenigen Ausprägungen*
- ▶ Nominale Merkmale (Problem: Anordnung der Ausprägungen beliebig!)

Stab-, Säulen-, Balkendiagramm

Darstellung der absoluten oder relativen Häufigkeiten als Höhen (Längen).



Verwendete Geometrien:

Vertikale oder horizontale Linien oder Rechtecke

Ästhetische Zuordnungen:

- ▶ x-Position: Ausprägungen des Merkmals
- ▶ y-Position des oberen Endes: absolute oder relative Häufigkeiten
- ▶ (x und y umgekehrt für Balkendiagramm)

Beispiel Mietspiegel: Säulendiagramm / Balkendiagramm



Stapeldiagramm

Darstellen absoluter oder relativer Häufigkeiten als Länge. Die Abschnitte werden übereinander gestapelt und unterschiedlich eingefärbt.

Anwendungen:

- ▶ Nominale Merkmale (aber: Reihenfolge?!)
- ▶ Ordinale / gruppierte Merkmale
- ▶ Metrische Daten mit wenigen Ausprägungen

Besonders geeignet für den Vergleich verschiedener Gruppen durch nebeneinander liegende Stapel.

⇒ also: *bedingte* Häufigkeiten gegeben Gruppe

Zu beachten ist dann die Unterscheidung:
relative Häufigkeit (*Anteil*) ↔ absolute Häufigkeit (*Anzahl*)

Stapeldiagramm

Darstellung der absoluten oder relativen Häufigkeiten als Segmente unterschiedlicher Länge (vertikal) oder Breite (horizontal).


verwendete Geometrien:

Vertikale oder horizontale Rechtecksegmente

Ästhetische Zuordnungen:

- ▶ Ausdehnung: absolute oder relative Häufigkeiten der Merkmalsausprägungen
- ▶ (Füll-)farbe: Ausprägungen des Merkmals
- ▶ optional: x- oder y-Position des Segments: Ausprägungen des bedingenden Merkmals

Beispiel Mietspiegel: Stapeldiagramme



Kreisdiagramm, Tortendiagramm

Darstellung von relativen/absoluten Häufigkeiten als Anteile der Fläche eines Kreises.

Suboptimale Visualisierung –


Darstellung über Längen » Darstellung über Winkel!

Grundsätzlich anwendbar für



- ▶ Nominale Merkmale
- ▶ Ordinale Merkmale (Problem: Ordnung nicht korrekt wiedergegeben)
- ▶ Gruppierte Daten

pie chart

Tortendiagramm: Klein & Kalt



Beispiel Mietspiegel: Vergleich mit Kreisdiagramm



Statistische Grafiken

Grammar of Graphics

Grafiken: Wahrnehmung

Grafiken: Infoviz vs Statistische Grafiken

Farbskalen

Diskrete Merkmale: Visualisierung von Häufigkeiten und Verteilungen

Metrische Merkmale: Visualisierung von Häufigkeiten und Verteilungen

Kerndichteschätzung

Metrische Merkmale: Visualisierung gemeinsamer Verteilungen

Dotplots

“Eindimensionales Streudiagramm”

Darstellung der einzelnen Beobachtungen als Punkte (Breiten) entlang der Achse.


Verwendete Geometrien:

Punkte (oder andere Symbole)


Ästhetische Zuordnungen:

- ▶ x-Position: beobachtete Merkmalsausprägungen der UE
- ▶ optional: y-Position: Ausprägungen des bedingenden Merkmals
- ▶ (oder auch umgekehrt)

Beispiel: Dotplot




Variante: Gruppiertes Dotplot




(bin width = 10)

Beispiel: Dotplot für bedingte Verteilungen



Negativbeispiel: Streudiagramm



→ Ungeeignet, da horizontale Achse ohne Informationsgehalt.

Histogramm

Grafiktyp für Häufigkeitsverteilungen auf mindestens Intervallskala.

Darstellung der relativen Häufigkeiten durch *Flächen* (Prinzip der **Flächentreue**)

Vorgehen:





1. Aufteilung in Klassen (falls die Daten noch nicht gruppiert sind)
2. Bestimmung der Klassenhäufigkeiten n_j und der relativen Häufigkeiten

$$f_j = \frac{n_j}{n}$$

3. Bestimmung der Histogramm-Höhen y_j , so dass gilt:

$$b_j \cdot y_j = f_j, \text{ wobei } b_j \text{ die Breite der Klasse } j \text{ ist.}$$

Beispiel: Nettomiete Klein & Kalt



Histogramm

- ▶ Flächentreue Darstellung ähnlich zu Idee von *Dichtefunktionen*: Histogramm ist stückweise konstante Approximation der Dichte.
- ▶ nur bei metrischen Daten sinnvoll
- ▶ Beachte: Interpretation der Balkenhöhe bei unterschiedlichen Klassenbreiten nicht angemessen – Flächentreue!
⇒ unterschiedlichen Klassenbreiten vermeiden zu Gunsten einfacher Interpretierbarkeit
- ▶ Nachteil: Visueller Eindruck von Klassenbreite abhängig
⇒ verschiedene Varianten ansehen, falls möglich: Klassenbreiten inhaltlich begründen
- ▶ Vorsicht bei Rändern (s.a. Kapitel “Kerndichteschätzer”)

Histogramm

Flächentreue Darstellung der Verteilung eines metrischen Merkmals, unterteilt in Klassen.

Verwendete Geometrien:

Achsenparallele Rechtecke

Ästhetische Zuordnungen:

- ▶ x-Position der Ecken: Histogrammklassengrenzen
- ▶ Fläche (*implizit also: Höhe*): relative Häufigkeit der Klasse

Statistische Grafiken

Grammar of Graphics

Grafiken: Wahrnehmung

Grafiken: Infoviz vs Statistische Grafiken

Farbskalen

Diskrete Merkmale: Visualisierung von Häufigkeiten und Verteilungen

Metrische Merkmale: Visualisierung von Häufigkeiten und Verteilungen



Kerndichteschätzung

Metrische Merkmale: Visualisierung gemeinsamer Verteilungen

Dichtefunktion I

Histogramm:

- ▶ Relative Häufigkeit in einer Histogramm-Klasse = Fläche der Histogramm-Säule = Fläche “unter der Kurve”
- ▶ Aber: Histogramm ist stückweise konstante Funktion
- ▶ Sehr problematisch: Abhängigkeit von Wahl der Klassengrenzen



- ▶ $\Rightarrow$ Ersetze Histogramm durch glatte Funktion f

Dichtefunktion II

Wiederholung: Für eine **Dichte**(-funktion) (*density*) gilt:


- ▶ $f(x) \geq 0 \quad \forall x$ und
- ▶ $\int_{-\infty}^{\infty} f(x) dx = 1.$

Die Fläche unter der Dichte über beliebige Intervalle soll in etwa den relativen Häufigkeiten in diesen Intervallen entsprechen, d.h.


$$\int_a^b f(x) dx \approx \frac{1}{n} |\{x_i : a < x_i \leq b\}|$$

$|\{...\}|$: *Mächtigkeit* der Menge, also Anzahl der Elemente der Menge


Beispiele Histogramm und Dichte



Beispiele Histogramm und Dichte



Beispiele Histogramm und Dichte



Berechnung von Dichte-Kurven

$$\hat{f}(x) = \frac{\frac{1}{n} |\{x_i : x_i \in [x - h, x + h]\}|}{2h}$$

⇒ Gleitendes Histogramm

$$= \frac{1}{n} \sum_{i=1}^n \frac{1}{h} k\left(\frac{x - x_i}{h}\right)$$

mit “Rechteck”-**Kernfunktion**

$$k(u) = \begin{cases} \frac{1}{2} & \text{für } -1 \leq u < 1 \\ 0 & \text{sonst} \end{cases}$$

Kerndichteschätzer

$k(u)$ sei **Kernfunktion**, d.h. $k(u) \geq 0 \forall u$ und $\int_{-\infty}^{\infty} k(u) du = 1$

Dann ist der **Kerndichteschätzer** (auch: KDE - *kernel density estimator*)

$$\hat{f}(x) = \frac{1}{nh} \sum_{i=1}^n k\left(\frac{x - x_i}{h}\right)$$


Beispiele für Kernfunktionen:

Gauß-Kern $k(u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}u^2\right)$

Epanechnikov-Kern $k(u) = \max\left(0, \frac{3}{4}(1 - u^2)\right)$



Dreieck-Kern $k(u) = \max(0, 1 - |u|)$

Kerndichteschätzer





Kerndichteschätzer

- ▶ Histogramme berücksichtigen nicht, *wo* Beobachtungen in der Klasse liegen, zählen nur die *Anzahl der Beobachtungen* innerhalb der Klassengrenzen
- ▶ Kerndichteschätzung an der Stelle x berücksichtigt *Entfernung der benachbarten Punkte zu x* , mit über die Distanz *abnehmender Gewichtung*:




Kerndichteschätzer

- ▶ Histogramme berücksichtigen nicht, *wo* Beobachtungen in der Klasse liegen, zählen nur die *Anzahl der Beobachtungen* innerhalb der Klassengrenzen
- ▶ Kerndichteschätzung an der Stelle x berücksichtigt *Entfernung der benachbarten Punkte zu x* , mit über die Distanz *abnehmender Gewichtung*:




Kerndichteschätzer: Bandbreite



Obere Reihe: Gauss-Kern, untere Reihe: Dreiecks-Kern

Kern-Dichteschätzer



Kerndichteschätzer mit “optimaler” Bandbreite h (blau), zu kleiner (orange) und zu großer (lila) Bandbreite h .

Bemerkungen zur Dichteschätzung

- ▶ Abhängigkeit von der Bandbreite h
→ Benutze automatische Verfahren zur Bestimmung von “optimalem” h aus den Daten
- ▶ Abhängigkeit von der Wahl der Kernfunktion eher unbedeutend
- ▶ Kerndichteschätzungen sind insbesondere bei größeren Datenmengen und (quasi-)stetigen Merkmalen Histogrammen vorzuziehen.
- ▶ Kerndichteschätzungen sind *immer* Histogrammen mit unterschiedlichen Klassenbreiten vorzuziehen.

Animation 1, Animation 2

Statistische Grafiken

Grammar of Graphics

Grafiken: Wahrnehmung

Grafiken: Infoviz vs Statistische Grafiken

Farbskalen

Diskrete Merkmale: Visualisierung von Häufigkeiten und Verteilungen

Metrische Merkmale: Visualisierung von Häufigkeiten und Verteilungen

Kerndichteschätzung

Metrische Merkmale: Visualisierung gemeinsamer Verteilungen

Bivariate metrische Daten

Daten liegen zu zwei metrischen Merkmalen vor:

Datenpaare (x_i, y_i) , $i = 1, \dots, n$

Fragen:

Gibt es einen Zusammenhang zwischen diesen Merkmalen?

Wie lässt sich dieser Zusammenhang beschreiben?

Was ist die *gemeinsame* Verteilung dieser Merkmale?

Einfachste grafische Darstellung: **Streudiagramm**.


Die Datenpaare entsprechen Punkten in der Ebene (“Punktwolke”)

Beispiele:


X: Wohnfläche [m^2]

Y: Nettomiete [€] oder Quadratmetermiete [€/m²]

Streudiagramm




Streudiagramm




Darstellung für größere Datenmengen:

Besser mit halbdurchsichtigen & kleineren Symbolen - Overplotting vermeiden:

.. so ist es lesbar





.. so nicht




Darstellung für größere Datenmengen

Alternativen: Anzahlen/Dichte direkt über Farbe codieren (hexbin-Plots, 2D-Kerndichte):




Darstellung für größere Datenmengen

in 3D:




R-Pakete: {rayshader}, {plotly}, {ggrrgl}


Streudiagramme mit diskreter Drittvariable




Streudiagramme mit diskreter Drittvariable




Streudiagramme mit diskreter Drittvariable




Streudiagramme mit stetiger Drittvariable



Streudiagramme mit stetiger Drittvariable



Streudiagramme mit gruppierter Drittvariable



Streudiagramme mit gruppierter Drittvariable

