

Kennwerte & Verteilungseigenschaften

Univariate statistische Kennwerte

Statistische Kennwerte: Lagemaße

Lagemaße für Zufallsvariablen

Erwartungswert einer Zufallsvariablen

Statistische Kennwerte: Streuungsmaße

Varianz einer Zufallsvariable

Statistische Kennzahlen: Verteilungseigenschaften

Statistische Kennzahlen: Konzentrationsmaße

Kennwerte & Verteilungseigenschaften

Univariate statistische Kennwerte

Statistische Kennwerte: Lagemaße

Lagemaße für Zufallsvariablen

Erwartungswert einer Zufallsvariablen

Statistische Kennwerte: Streuungsmaße

Varianz einer Zufallsvariable

Statistische Kennzahlen: Verteilungseigenschaften

Statistische Kennzahlen: Konzentrationsmaße

Statistische Kennwerte

Lagemaßzahlen

- ▶ Wo liegt die “Mitte” der beobachteten Werte?
- ▶ Welche Merkmalsausprägung ist “typisch” für dieses Merkmal?
- ▶ Wo liegen die meisten beobachteten Daten?

Streuungsmaßzahlen

- ▶ Wie groß ist die Schwankung der beobachteten Werte?
- ▶ Über welchen Bereich erstrecken sich die Merkmalsausprägungen?
- ▶ Wie nah zusammen/weit entfernt voneinander liegen die beobachteten Werte?

Kennwerte & Verteilungseigenschaften

Univariate statistische Kennwerte

Statistische Kennwerte: Lagemaße

Lagemaße für Zufallsvariablen

Erwartungswert einer Zufallsvariablen

Statistische Kennwerte: Streuungsmaße

Varianz einer Zufallsvariable

Statistische Kennzahlen: Verteilungseigenschaften

Statistische Kennzahlen: Konzentrationsmaße

Lagemaß: Modus

Definition: **Häufigster Wert**

Eigenschaften:

- ▶ oft nicht eindeutig
- ▶ nur bei gruppierten Daten oder bei Merkmalen mit wenigen Ausprägungen sinnvoll
- ▶ direkt übertragbar bei allen *eindeutigen* Transformationen
- ▶ geeignet für alle Skalenniveaus

Lagemaß: Median

Definition: Der **Median** ($\tilde{x}_{\text{med}}$) ist der Wert für den gilt

- ▶ mindestens 50% der Daten sind kleiner oder gleich $\tilde{x}_{\text{med}}$,
- ▶ mindestens 50% der Daten sind größer oder gleich $\tilde{x}_{\text{med}}$.

$$\tilde{x}_{\text{med}} = \begin{cases} x_{(k)} & \text{falls } k = \frac{n+1}{2} \text{ ganze Zahl} \\ \frac{1}{2} (x_{(k)} + x_{(k+1)}) & \text{falls } k = \frac{n}{2} \text{ ganze Zahl} \end{cases}$$

- ▶ $x_{(1)}, \dots, x_{(n)}$ sind **geordnete Werte**
- ▶ Alternative Definition: $\tilde{x}_{\text{med}} \in [x_{(k)}, x_{(k+1)}]$ falls $k = \frac{n}{2}$ ganze Zahl.

Eigenschaften des Medians

- ▶ anschaulich
- ▶ geeignet für mindestens ordinale Daten
- ▶ robust gegenüber extremen Werten
- ▶ direkt übertragbar bei monotonen Transformationen

Formal:

- ▶ Wert, der die Summe der *absoluten* Differenzen zu den beobachteten Werten minimiert:

$$\tilde{x}_{\text{med}} = \arg \min_x \sum_{i=1}^n |x_i - x|$$

Lagemaß: Quantil

Definition: Das p -**Quantil** ist der Wert $\tilde{x}_p$ für den gilt


- ▶ mindestens Anteil p der Daten sind kleiner oder gleich $\tilde{x}_p$,
- ▶ mindestens Anteil $1 - p$ der Daten sind größer oder gleich $\tilde{x}_p$.

$$\tilde{x}_p = \begin{cases} x_{(k)} & \text{falls } np \text{ keine ganze Zahl und } k \text{ kleinste Zahl } > np \\ \in [x_{(k)}; x_{(k+1)}] & \text{falls } k = np \text{ ganze Zahl} \end{cases}$$

- ▶ Viele alternative Definitionen von Quantilen (in R 9 Typen!), die sich aber meist nur für extreme Quantile relevant unterscheiden.
- ▶ p -Quantil $\equiv (100 \cdot p)$ -Perzentil
- ▶ Der Median ist das 0.5-Quantil bzw. 50-Perzentil

Anwendung in Visualisierung: Boxplot

- Überblicks-Darstellung der Verteilung eines Merkmals
- Visualisieren der 5-Punkte-Zusammenfassung:
Minimum, 25-, 50-, 75-Perzentile, Maximum



Boxplot

Einfacher **Boxplot**:



- ▶ $\tilde{x}_{0.25}$ = Anfang der Schachtel (Box) (= unteres **Quartil**)
- ▶ $\tilde{x}_{0.75}$ = Ende der Schachtel (= oberes **Quartil**)
- ▶ d_Q = Länge der Schachtel (= **Inter-Quartile-Range** (IQR) $\tilde{x}_{0.75} - \tilde{x}_{0.25}$)
- ▶ Der **Median** wird durch den Strich in der Box markiert
- ▶ Zwei Linien (*whiskers*) außerhalb der Box gehen bis zu x_{min} und x_{max} .

Boxplot


Modifizierter **Boxplot**:

- ▶ *whiskers* werden nur bis zu $x_{\min}$ bzw. $x_{\max}$ gezogen, falls $x_{\min}$ und $x_{\max}$ innerhalb des Bereichs $[z_u, z_o]$ der *Zäune* liegen.
Üblicherweise: $z_u = \tilde{x}_{0.25} - 1.5d_Q$, $z_o = \tilde{x}_{0.75} + 1.5d_Q$
- ▶ Ansonsten gehen die Linien nur bis zum kleinsten bzw. größten Wert *innerhalb der Zäune*, die außerhalb liegenden Werte werden individuell als Punkte/Symbole eingezeichnet.

Boxplot: Beispiel Quadratmetermiete Mietspiegel



Gruppiertes Boxplot:



Gruppengrößen darstellbar über Höhe (horizontale Box) bzw. Breite (vertikale B.).

Boxplot: Vor- und Nachteile

+:

- ▶ kompakt
- ▶ geeignet für Vergleiche
- ▶ zentraler Bereich der Daten einfach ablesbar
- ▶ **Ausreißer** sichtbar
- ▶ **Schiefe** sichtbar

-:

- ▶ gegen Intuition (Viel Farbe – wenig Daten) da Ausreißer sehr prominent
- ▶ **Multimodale** Verteilungen nicht sichtbar
- ▶ (Höhe der Box trägt keine Information)

Einfacher Boxplot: Grammar of Graphics

verwendete Geometrie:

Rechteck mit vertikalem Band und horizontalen “whiskers”.

zugeordnete Ästhetiken:

- ▶ horizontale Ausdehnung des Rechtecks: von $\tilde{x}_{0.25}$ bis $\tilde{x}_{0.75}$
- ▶ horizontale Position des vertikalen Bands: $\tilde{x}_{med}$
- ▶ horizontale Positionen der Enden der “whiskers”: x_{min} bzw. x_{max}
- ▶ optional: vertikale Ausdehnung der Box: Anzahl der eingeflossenen Beobachtungen

⇒ zugeordnete Ästhetiken in statistischen Grafiken repräsentieren oft zusammenfassende Kennwerte der zugrundeliegenden Daten!

(hier nur für *einfachen, horizontale* Boxplots, für vertikale Boxplots analog mit vertikaler Position.)

Boxplot: Grammar of Graphics

- ▶ Für *modifizierten* Boxplot zusätzlich:
 - ▶ Geometrie “Punkte/Symbole” für Beobachtungen außerhalb der Zäune
 - ▶ entsprechend modifizierte Position der “whiskers”
- ▶ Alternative “Boxplots” auf Basis anderer Lage- und Streuungsmaße oder anderer Definition der “Zäune” auch zulässig und oft sinnvoll.

Der Mittelwert (arithmetisches Mittel)

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- ▶ bekanntestes Lagemaß
- ▶ stark beeinflusst von extremen Werten
- ▶ geeignet für intervallskalierte Daten
- ▶ “Durchschnitt” oder “Schwerpunkt” der Daten

Formal:

- ▶ Wert, der die Summe der *quadrierten* Differenzen zu den beobachteten Werten minimiert:

$$\bar{x} = \arg \min_x \sum_{i=1}^n (x_i - x)^2$$

Mittelwert bei gruppierten Daten

$$\begin{aligned}\bar{x} &= \frac{1}{n} \sum_{i=1}^n x_i \\ &= \frac{1}{n} (x_1 + x_2 + \dots + x_n) \\ &= \frac{1}{n} \sum_{j=1}^k h_j a_j \\ &= \sum_{j=1}^k f_j a_j\end{aligned}$$

h_j : Häufigkeit von a_j

Gewichteter Mittelwert

Allgemeiner gilt:

Der *gewichtete Mittelwert* mit Gewichten $w_i \geq 0, i = 1, \dots, n$ ist

$$\bar{x}_W = \frac{1}{\sum_{i=1}^n w_i} \sum_{i=1}^n w_i x_i$$

Das geometrische Mittel

$$\bar{x}_G = \sqrt[n]{\prod_{i=1}^n x_i}$$

- rücktransformiertes arithmetisches Mittel auf der log-Skala:

$$\bar{x}_G = \exp\left(\frac{1}{n} \sum_{i=1}^n \log(x_i)\right)$$

- nur geeignet für positive, mindestens intervallskalierte Merkmale
- Anwendung: Durchschnitt von Änderungsraten, z.B. durchschnittliche Verzinsung

Allgemein: Das geometrische Mittel ist der richtige Mittelwert für Merkmale, deren Ausprägungen als multiplikative Faktoren zu interpretieren sind.

Das geometrische Mittel: Beispiel

Anfangskapital 100 €, Entwicklung über 3 Quartale

- ▶ Q1: 20% Gewinn (Faktor 1.2)
- ▶ Q2: 50% Gewinn (Faktor 1.5)
- ▶ Q3: 40% Verlust (Faktor 0.6)

```
r <- c(1.2, 1.5, 0.6)
cumprod(c(100, r)) # Kapital nach jedem Quartal
## [1] 100 120 180 108

mean(r) # arithmetisches Mittel der Renditen
## [1] 1.1 # --> "durchschnittlich" 10% Gewinn pro Quartal ?

exp(mean(log(r))) # geom. Mittel der Renditen
## [1] 1.026 # --> "durchschnittlich" 2.6% Gewinn pro Quartal !

100 * mean(r)^3 # "effektive" Verzinsung pro Quartal in%??
## [1] 133.1
# 10% pro Quartal entspräche 100 -> 133 über 3 Quartale, also falsch

100 * exp(mean(log(r)))^3 # effektive Verzinsung pro Periode in %!!
## [1] 108
# 2.6% pro Quartal ergibt 100 -> 108 über 3 Quartale, also korrekt
```

Das harmonische Mittel

$$\bar{x}_H = \frac{1}{\frac{1}{n} \sum_{i=1}^n \frac{1}{x_i}}$$

Das harmonische Mittel entspricht dem inversen Mittelwert der inversen Werte:

$$\bar{x}_H = \left(\frac{1}{n} \sum_{i=1}^n \frac{1}{x_i} \right)^{-1}$$

- ▶ Anwendung für Mittelwerte von Quotienten/Verhältnissen unterschiedlicher Skalen, z.B.
 - ▶ Geschwindigkeiten (in $\frac{km}{h}$, $\frac{m}{s}$ etc)
 - ▶ Kurs-Gewinn-Verhältnisse (PE ratios, in $\frac{\text{Aktienkurs in €}}{\text{Gewinn in €}}$)

Bsp: harmonisches Mittel

Sie fahren die ersten 100 km mit 30km/h und die zweiten 100km mit 100 km/h.

Was ist Ihre Durchschnittsgeschwindigkeit?

Gesamtstrecke: 200 km

Gesamtzeit: $3.33h + 1h = 4.33h$

$$\Rightarrow \frac{200km}{4.33h} = 46.2km/h.$$

Arithm. Mittel:

$$\bar{x} = \frac{30+100}{2} = 65, \text{ wäre also } 65 \text{ km/h und offensichtlich falsch.}$$

Harmonisches Mittel:

$$\bar{x}_H = \frac{1}{\frac{1}{2}\left(\frac{1}{30} + \frac{1}{100}\right)} = \frac{600}{13} = 46.2, \text{ also } 46.2 \text{ km/h!}$$

Allgemeine Transformation des Arithm. Mittels

Lineare Transformation:

$$\begin{aligned}g(x) &= a + bx \\y_i &= a + bx_i \Rightarrow \bar{y} = a + b\bar{x}\end{aligned}$$

d.h.

$$\begin{aligned}\overline{a + bx} &= a + b\bar{x} \\ \overline{g(x)} &= g(\bar{x})\end{aligned}$$

Generell ist $\overline{g(x)} \neq g(\bar{x})$!

Getrimmtes Mittel

Um die Ausreißerempfindlichkeit von $\bar{x}$ abzuschwächen definiert man

$$\bar{x}_\alpha = \frac{1}{n - 2r} \sum_{i=r+1}^{n-r} x_{(i)}$$

- ▶ $x_{(i)}$: geordnete x-Werte
- ▶ r ist die größte ganze Zahl mit $r \leq n\alpha$

Es wird also “unten” und “oben” jeweils der Anteil α der extremsten Werte abgeschnitten:

α -getrimmtes Mittel

Alternative:

Winsorisiertes Mittel (**gestutztes** Mittel):

Der Anteil α der extremsten Werte wird **durch die entsprechenden oberen/unteren Quantile ersetzt.**

Kennwerte & Verteilungseigenschaften

Univariate statistische Kennwerte

Statistische Kennwerte: Lagemaße

Lagemaße für Zufallsvariablen

Erwartungswert einer Zufallsvariablen

Statistische Kennwerte: Streuungsmaße

Varianz einer Zufallsvariable

Statistische Kennzahlen: Verteilungseigenschaften

Statistische Kennzahlen: Konzentrationsmaße

Einleitung

Bereits kennengelernt:

- ▶ *Empirische* Lage- und Streuungsmaße
(Mittelwerte, Median, Modus, Stichprobenvarianz, MAD, ...)
die Verteilung der *Beobachtungen eines Merkmals in einer Stichprobe* beschreiben.

Jetzt:

- ▶ *Theoretische* Entsprechungen für *Verteilungen von Zufallsvariablen*.

(Spätere Veranstaltungen: Schätztheorie – welche empirischen Maße sind wie gut geeignet um bestimmte theoretische Größen aus Daten zu schätzen?)

Modus einer Zufallsvariablen

Definition: Modus einer Zufallsvariable

Der *Modus* einer Zufallsvariable X ist ein Wert x_{Mod} , für den gilt:

$$f(x_{Mod}) \geq f(x) \quad \forall x \in T_X$$

⇒ Modi (auch: Modalwerte) sind die globalen Maximumsstellen der Dichte-/Wahrscheinlichkeitsfunktion von X .

- ▶ Genau wie der empirische Modus eines beobachteten Merkmals ist der Modus einer ZV weder notwendigerweise eindeutig noch muss er existieren.

Median und Quantile einer Zufallsvariablen

Mediane und andere Quantile einer Zufallsvariable X sind inhaltlich analog zu ihren empirischen Analoga definiert – es gilt:

Definition: Quantil einer Zufallsvariable

Das p -Quantil $\tilde{x}_p$ einer ZV X , mit $p \in [0, 1]$, ist

$$\tilde{x}_p := \arg \min_{x \in T_X} \{x : F_X(x) \geq p\}.$$

- ▶ der kleinste Wert für den die Verteilungsfunktion mindestens den Wert p annimmt.
- ▶ der kleinste Wert der mindestens mit Wahrscheinlichkeit p unterschritten wird
- ▶ für stetige ZV mit strikt positiver Dichte bzw. streng monotoner Verteilungsfunktion gilt:

$$\tilde{x}_p = F_X^{-1}(p)$$

- ▶ $F_X^{-1}(p)$ heißt auch *Quantilfunktion* von X .

Kennwerte & Verteilungseigenschaften

Univariate statistische Kennwerte

Statistische Kennwerte: Lagemaße

Lagemaße für Zufallsvariablen

Erwartungswert einer Zufallsvariablen

Statistische Kennwerte: Streuungsmaße

Varianz einer Zufallsvariable

Statistische Kennzahlen: Verteilungseigenschaften

Statistische Kennzahlen: Konzentrationsmaße

Erwartungswert einer ZV

Definition: Diskreter Erwartungswert

Der *Erwartungswert* (EW) $E(X)$ einer *diskreten* ZV X mit Träger T_X ist definiert als

$$\begin{aligned} E(X) &:= \sum_{x \in T_X} x \cdot P_X(X = x) = \sum_{\omega \in \Omega} P(\{\omega\}) X(\omega) \\ &= \sum_{x \in T_X} x \cdot f_X(x) \end{aligned}$$

Definition: Stetiger Erwartungswert

Der *Erwartungswert* $E(X)$ einer *stetigen* ZV X mit Dichtefunktion $f_X(x)$ ist definiert als

$$E(X) := \int_{-\infty}^{\infty} x \cdot f_X(x) dx$$

Erwartungswert einer ZV

Intuition:

Der Erwartungswert ist *gewichtetes arithmetisches Mittel* der möglichen Werte einer ZV, wobei die Gewichte den Wahrscheinlichkeiten entsprechen, einen bestimmten Wert zu beobachten.

- ▶ Der Erwartungswert existiert bzw. ist endlich, wenn gilt:
 - ▶ für diskrete ZV: $\sum_{x \in T_X} |x| \cdot f(x) < \infty$ (absolut konvergente Summe),
 - ▶ für stetige ZV: $\int_{-\infty}^{\infty} |x f(x)| dx = \int_{-\infty}^{\infty} |x| f(x) dx < \infty$ (absolut integrierbar).
- ▶ Beachte: $\sum_{x \in T_X} x \cdot P(X = x) = \sum_{x \in \mathbb{R}} x \cdot P(X = x)$, da $P(X = x) = 0 \forall x \notin T_X$

Eigenschaften des Erwartungswertes

- ▶ Sei $X = a$ mit Wahrscheinlichkeit 1 (“*deterministische ZV*”). Dann gilt:

$$E(X) = a$$

- ▶ **Linearität des Erwartungswertes:**

Sei $a, b \in \mathbb{R}$ und X, Y beliebige ZV. Dann gilt:

$$E(a \cdot X + b \cdot Y) = a \cdot E(X) + b \cdot E(Y)$$

$\implies$ Für beliebige $a, b \in \mathbb{R}$ gilt daher

$$E(aX + b) = a \cdot E(X) + b$$

- ▶ Ist $f(x)$ symmetrisch um einen Punkt c , d.h. $f(c - x) = f(c + x) \forall x \in T_X$, dann ist $E(X) = c$.

Eigenschaften des Erwartungswertes II

Allgemeiner auch für beliebige $a_1, \dots, a_n \in \mathbb{R}$ und beliebige ZV $X_1, \dots, X_n$:

$$E\left(\sum_{i=1}^n a_i X_i\right) = \sum_{i=1}^n a_i \cdot E(X_i)$$

Transformationsregel für Erwartungswerte

Sei X eine ZV und $g : \mathbb{R} \rightarrow \mathbb{R}$ eine reelle Funktion. Dann gilt für $Y = g(X)$:

$$E(Y) = E[g(X)] = \begin{cases} \sum_{x \in T} g(x) f(x) & X \text{ diskret} \\ \int_{-\infty}^{\infty} g(x) f(x) dx & X \text{ stetig} \end{cases}$$

► Im Allgemeinen gilt **nicht**: $E(g(X)) = g(E(X))$!

Beispiel

Sei X eine ZV mit folgender Wahrscheinlichkeitsfunktion

$$f(x) = \begin{cases} 1/4 & \text{für } x = -2 \\ 1/8 & \text{für } x = -1 \\ 1/4 & \text{für } x = 1 \\ 3/8 & \text{für } x = 3 \end{cases}$$

Berechne den Erwartungswert von $E(X^2)$

Erwartungswert von ZVn mit Träger $\mathbb{N}^+$

Für ZV X mit Träger $T_X = \mathbb{N}^+$ gilt: $E(X) = \sum_{k=1}^{\infty} P(X \geq k)$

Beweis:

$$\begin{aligned}\sum_{k=1}^{\infty} P(X \geq k) &= \sum_{k=1}^{\infty} \sum_{t=k}^{\infty} P(X = t) \\&= P(X = 1) + P(X = 2) + P(X = 3) + P(X = 4) + \dots \\&\quad + P(X = 2) + P(X = 3) + P(X = 4) + \dots \\&\quad + P(X = 3) + P(X = 4) + \dots \\&\quad + P(X = 4) + \dots \\&\quad + \dots \dots \dots \\&= \sum_{t=1}^{\infty} t \cdot P(X = t) \\&= E(X)\end{aligned}$$

Kennwerte & Verteilungseigenschaften

Univariate statistische Kennwerte

Statistische Kennwerte: Lagemaße

Lagemaße für Zufallsvariablen

Erwartungswert einer Zufallsvariablen

Statistische Kennwerte: Streuungsmaße

Varianz einer Zufallsvariable

Statistische Kennzahlen: Verteilungseigenschaften

Statistische Kennzahlen: Konzentrationsmaße

Maße für die Streuung

- ▶ Spannweite
- ▶ Interquartilsabstand
- ▶ Standardabweichung und Varianz
- ▶ Variationskoeffizient

Die Spannweite (Range)

Definition:

$$sp = x_{\max} - x_{\min}$$

- ▶ Größe des Intervalls in dem die Daten liegen
- ▶ Anwendung primär für Kontrolle der Datenqualität:
Plausibilität, Eingabe-/Codierungsfehler, Existenz von Fehlmessungen und Ausreißern
- ▶ extrem sensibel gegen Ausreißer

Der Quartilsabstand

Definition:

$$d_Q = \tilde{x}_{0.75} - \tilde{x}_{0.25}$$

- ▶ Größe des Bereichs in dem die “mittlere Hälfte” der Daten liegt
 - ▶ Länge der Box des Boxplots
- ▶ Alternativer Name: *interquartilerange*: IQR
- ▶ Robust gegen Ausreißer
- ▶ Bei ordinal skalierten Daten Angabe von $x_{0.75}$ und $x_{0.25}$:
definiert Bereich der zentralen 50% der Daten.

Standardabweichung und Stichprobenvarianz

Definition:

$$\text{Stichprobenvarianz } s_x^2 := \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

$$\text{Standardabweichung } s_x := \sqrt{s_x^2}$$

- ▶ s_x lose interpretierbar als “mittlere Abweichung vom Mittelwert”
- ▶ Mindestens Intervallskala
- ▶ Empfindlich gegen Ausreißer
- ▶ Verwende $\tilde{s}_x^2 := \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ für Vollerhebungen, Division durch $n - 1$ nur bei Stichproben sinnvoll

Transformationsregel

$$\begin{aligned} y_i = a + bx_i &\implies \tilde{s}_y^2 = b^2 \tilde{s}_x^2 \\ &\tilde{s}_y = |b| \tilde{s}_x \end{aligned}$$

(Analog für s_x, s_y)

Varianz und Standardabweichung sind also für lineare Transformationen einfach umrechenbar.

Verschiebungssatz:

Für jedes $c \in \mathbb{R}$ gilt:

$$\sum_{i=1}^n (x_i - c)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - c)^2$$

$$\begin{aligned}\text{Setze } c = 0 &\implies \tilde{s}_x^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 \\ \tilde{s}_x^2 &= \overline{x^2} - \bar{x}^2\end{aligned}$$

Beachte:

Der Verschiebungssatz ist für die Berechnung präziser numerischer Ergebnisse am Computer **nicht geeignet** (Auslöschung von Gleitkommazahlen).

Streuungszerlegung I

Seien die Daten in r Schichten aufgeteilt:

$$x_1, \dots, x_{n_1}, x_{n_1+1}, \dots, x_{n_1+n_2}, \dots, x_n$$

mit $n = \sum_{j=1}^r n_j$

Schichtmittelwerte:

$$\bar{x}_1 = \frac{1}{n_1} \sum_{i=1}^{n_1} x_i, \quad \bar{x}_2 = \frac{1}{n_2} \sum_{i=n_1+1}^{n_1+n_2} x_i, \text{ usw.}$$

Schichtvarianzen:

$$\tilde{s}_{x1}^2 = \frac{1}{n_1} \sum_{i=1}^{n_1} (x_i - \bar{x}_1)^2, \quad \tilde{s}_{x2}^2 = \frac{1}{n_2} \sum_{i=n_1+1}^{n_1+n_2} (x_i - \bar{x}_2)^2, \text{ usw.}$$

Streuungszerlegung II

Dann gilt, mit $\bar{x} = \frac{1}{n} \sum_{j=1}^r n_j \bar{x}_j$:

$$\tilde{s}_x^2 = \frac{1}{n} \sum_{j=1}^r n_j \tilde{s}_{xj}^2 + \frac{1}{n} \sum_{j=1}^r n_j (\bar{x}_j - \bar{x})^2$$

Gesamtstreuung = Streuung Streuung
 innerhalb + *zwischen*
 der Schichten den Schichten

Streuungszerlegung: Nettomiete & Zimmerzahl

Streuungszerlegung der Netto-Quadratmetermiete bezüglich Zimmerzahl:


Zimmer	n_j	$\bar{x}_j$	$\tilde{s}_{xj}^2$
8	2	6.2	1.2
6	16	10.0	13.2
5	99	9.9	7.3
4	442	10.2	7.0
3	1175	10.4	7.1
2	1049	10.9	6.1
1	282	12.6	6.2

Gesamtvarianz: $\tilde{s}_x^2 \approx 7.15$

Innerhalb: $\frac{1}{n} \sum_{j=1}^r n_j \tilde{s}_{xj}^2 = 6.7$

Zwischen:

$$\frac{1}{n} \sum_{j=1}^r n_j (\bar{x}_j - \bar{x})^2 = 0.45$$



Höhe der Boxplots proportional zur Gruppengröße

Variationskoeffizient

Das Verhältnis von Standardabweichung und Mittelwert ist gegeben durch

$$v = \frac{\tilde{s}_x}{\bar{x}} \text{ mit } \bar{x} > 0$$

Der Variationskoeffizient hat keine Einheit und ist skalenunabhängig.

Er ist eine Maßzahl für die relative Schwankung um den Mittelwert und nur für Merkmale mit positiven Ausprägungen sinnvoll.

Mittlere absolute Abweichung (MAD)

Die **mittlere absolute Abweichung** (*mean absolute deviation*) ist definiert als

$$\text{MAD}_x = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

Es gilt: $\text{MAD}_x \leq \tilde{s}_x$

Der **Median der absoluten Abweichungen** ist

$$\text{MedAD}_x := \text{Median}(|x_i - x_{med}|)$$

- ▶ MAD_x einfacher interpretierbar als s_x
- ▶ beide weniger ausreißer-empfindlich, vor allem MedAD_x
- ▶ beide weniger “schöne” theoretische Eigenschaften als s_x und werden deswegen seltener angewendet

Kennwerte & Verteilungseigenschaften

Univariate statistische Kennwerte

Statistische Kennwerte: Lagemaße

Lagemaße für Zufallsvariablen

Erwartungswert einer Zufallsvariablen

Statistische Kennwerte: Streuungsmaße

Varianz einer Zufallsvariable

Statistische Kennzahlen: Verteilungseigenschaften

Statistische Kennzahlen: Konzentrationsmaße

Varianz

Def.: Varianz einer ZV

Die *Varianz* $\text{Var}(X)$ einer ZV X ist definiert als:

$$\begin{aligned}\text{Var}(X) &:= E[(X - E(X))^2] \\ &= \begin{cases} \sum_{x \in T_X} (x - E(X))^2 f_X(x) & X \text{ diskret} \\ \int_{-\infty}^{\infty} (x - E(X))^2 f_X(x) dx & X \text{ stetig} \end{cases}\end{aligned}$$

$\Rightarrow$ “erwartete quadratische Abweichung vom Erwartungswert”

Beachte:

- ▶ Varianz nicht immer endlich! ($\text{Var}(X) = \infty \iff$ “Varianz existiert nicht.”)
- ▶ Existiert der Erwartungswert nicht, so existiert auch die Varianz nicht.

Eigenschaften der Varianz

- ▶ Zur einfacheren Berechnung kann man häufig den **Verschiebungssatz** verwenden:

$$\text{Var}(X) = E(X^2) - (E(X))^2$$

- ▶ $\text{Var}(aX + b) = a^2 \text{Var}(X) \forall a, b \in \mathbb{R}$
- ▶ für unabhängige Zufallsvariablen X, Y gilt: $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$

Ungleichung von Tschebyscheff

Tschebyscheff-Ungleichung

Sei X eine beliebige ZV. Dann gilt:

$$P(|X - E(X)| \geq c) \leq \frac{\text{Var}(X)}{c^2}$$

Beispiel:

Für $\text{Var}(X) = 1$ und beliebiges $E(X)$ gilt also

$$P(|X - E(X)| \geq 1) \leq 1$$

$$P(|X - E(X)| \geq 2) \leq \frac{1}{4}$$

$$P(|X - E(X)| \geq 3) \leq \frac{1}{9}$$

Standardabweichung

Def.: Standardabweichung einer ZV

Die *Standardabweichung* $\sigma(X)$ einer ZV X ist die positive Wurzel ihrer Varianz:

$$\sigma(X) = +\sqrt{\text{Var}(X)}$$

Es gilt:

$$\sigma(aX + b) = |a| \cdot \sigma(X)$$

Die *erwartete absolute Abweichung* $E(|X - E(X)|)$ wäre zwar das intuitivere Streuungsmaß, ist aber mathematisch deutlich schwieriger zu handhaben.

Kennwerte & Verteilungseigenschaften

Univariate statistische Kennwerte

Statistische Kennwerte: Lagemaße

Lagemaße für Zufallsvariablen

Erwartungswert einer Zufallsvariablen

Statistische Kennwerte: Streuungsmaße


Varianz einer Zufallsvariable

Statistische Kennzahlen: Verteilungseigenschaften

Statistische Kennzahlen: Konzentrationsmaße

Uni- und multimodale Verteilungen

unimodal = eingipflig, **multimodal** = mehrgipflig



Das Histogramm der Zinssätze zeigt eine bimodale (trimodale...?) Verteilung.

Symmetrie und Schiefe I

symmetrisch



Rechte und linke Hlfte der Verteilung sind annhernd zueinander spiegelbildlich

**linkssteil
(rechtsschief)**




Verteilung fllt nach links deutlich steiler und nach rechts langsamer ab

**rechtssteil
(linksschief)**




Verteilung fllt nach rechts deutlich steiler und nach links langsamer ab


Symmetrie und Schiefe II



(a)



(b)



(c)

Eine linkssteile (a), symmetrische (b) und rechtssteile Verteilung (c)

Lageregeln

- ▶ Symmetrische und unimodale Verteilung:
 $\bar{x} \approx x_{med} \approx x_{mod}$
- ▶ Linkssteile Verteilung: $\bar{x} > x_{med} > x_{mod}$
- ▶ Rechtssteile Verteilung: $\bar{x} < x_{med} < x_{mod}$
- ▶ Bei gruppierten Daten: Auch für Histogramme gültig

Beachte:

- ▶ Lageregeln sind Daumenregeln, gelten nicht notwendigerweise in jedem Einzelfall.
- ▶ Form der Verteilung bleibt bei linearen Transformationen gleich, aber ändert sich bei nichtlinearen Transformationen.

Maßzahlen für die Schiefe I

Quantilkoeffizient:

$$g_p = \frac{(\tilde{x}_{1-p} - \tilde{x}_{med}) - (\tilde{x}_{med} - \tilde{x}_p)}{\tilde{x}_{1-p} - \tilde{x}_p}; \quad \text{mit } 0 < p < 0.5$$

$g_{0.25}$ bezeichnet man als **Quantilkoeffizient**.

Werte des Quantilkoeffizienten:

- $g_p = 0$ für symmetrische Verteilungen
- $g_p > 0$ für linkssteile Verteilungen
- $g_p < 0$ für rechtssteile Verteilungen

Maßzahlen für die Schiefe II

Momentenkoeffizient der Schiefe:

$$g_m = \frac{m_3}{s_x^3} \quad \text{mit} \quad m_3 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3$$

bzw.

$$g_m = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s_x} \right)^3$$

Werte des Momentenkoeffizienten:




$$\begin{aligned} g_m &= 0 && \text{für symmetrische Verteilungen} \\ g_m &> 0 && \text{für linkssteile Verteilungen} \\ g_m &< 0 && \text{für rechtssteile Verteilungen} \end{aligned}$$

Wölbung und Extremwerte

Sehr wichtige Verteilungseigenschaft für viele Anwendungsbereiche:

Wie häufig oder selten treten extreme Werte auf, die weit entfernt von der "Mitte" der Verteilung liegen?

Wie häufig sind Beobachtungen aus den Rändern der Verteilung (im Vergleich zur "Mitte")?



Wölbung und Extremwerte

⇒ Wölbung/**Kurtosis** misst Häufigkeit (und Distanz) extremer Werte:

$$k = \frac{m_4}{s_x^4} \quad \text{mit} \quad m_4 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4$$
$$= \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s_x} \right)^4$$

Meist betrachtet: **Exzess-Kurtosis**

$$k^\star = k - 3$$

- ▶ $k^\star \approx 0$: normalgipflig (vgl. *Normalverteilung*), *mesokurtisch*.
- ▶ $k^\star > 0$: steilgipflig, *leptokurtisch*.
Stärker ausgeprägter schmaler Gipfel im Vergleich zu den Rändern,
häufigere extreme Werte
- ▶ $k^\star < 0$: flachgipflig, *platykurtisch*.
Wenig ausgeprägter breiterer Gipfel im Vergleich zu den Rändern,
seltene extreme Werte

Wölbung und Extremwerte

Klassisches theoretisches Schaubild:






Abb: Wikimedia Commons

Wölbung und Extremwerte


Praktische Beispiele:



keine Ausreißer –
Exzesskurtosis = -0.69



viele Ausreißer –
Exzesskurtosis = 5.3



viele extreme Ausreißer –
Exzesskurtosis = 22

Momente von Zufallsvariablen

Def.: Moment einer ZV

Das k -te Moment einer ZV X ist $E(X^k)$

Def.: Zentriertes Moment einer ZV

Das k -te zentrierte Moment einer ZV X ist $E((X - E(X))^k)$

- ▶ Der Erwartungswert ist das *erste Moment* einer Verteilung
- ▶ Die Varianz ist das *zweite zentrierte Moment* einer Verteilung

Höhere Momente von Zufallsvariablen

Theoretische Analoga zu empirischem Momentenkoeffizient der Schiefe und und Wölbung:

- ▶ Die **Schiefe** einer Verteilung ist das dritte (zentrale) Moment ihrer standardisierten Werte: $E \left[\left(\frac{X-E(X)}{\sigma(X)} \right)^3 \right]$
- ▶ Die **Wölbung** (Kurtosis) einer Verteilung ist das vierte (zentrale) Moment ihrer standardisierten Werte: $E \left[\left(\frac{X-E(X)}{\sigma(X)} \right)^4 \right]$
- ▶ Alle geraden zentralen Momente sind im Endeffekt “Varianzen”, die zunehmend mehr Gewicht auf die extremen Ränder der Verteilung legen
- ▶ Alle ungeraden zentralen Momente (außer dem ersten) messen die *Asymmetrie* von Verteilungen, mit immer größerem Gewicht auf Asymmetrie in den extremen Rändern der Verteilung

Theorie & Empirie

Theorie (ZV)		Empirie (beob. Merkmale)
$E(X) := \int x f(x) dx$	$\leftrightarrow$	$\bar{x} := 1/n \sum_{i=1}^n x_i = \sum_{j=1}^k a_j f_j$
$\text{Var}(X) := \int (x - E(X))^2 f(x) dx$	$\leftrightarrow$	$s_x^2 := 1/(n-1) \sum_{i=1}^n (x_i - \bar{x})^2$
Median $x_{\text{med}} : F_X(x_{\text{med}}) = 0.5$	$\leftrightarrow$	$\tilde{x}_{\text{med}} := x_{(\lceil n/2 \rceil)}$
Modus $x_{\text{mod}} := \arg \max(f_X(x))$	$\leftrightarrow$	$\tilde{x}_{\text{mod}} : h(x_{\text{mod}}) \geq h(a_j) \forall j = 1, \dots, k$

etc etc

Kennwerte & Verteilungseigenschaften

Univariate statistische Kennwerte

Statistische Kennwerte: Lagemaße

Lagemaße für Zufallsvariablen

Erwartungswert einer Zufallsvariablen

Statistische Kennwerte: Streuungsmaße

Varianz einer Zufallsvariable

Statistische Kennzahlen: Verteilungseigenschaften

Statistische Kennzahlen: Konzentrationsmaße

Konzentrationsmaße

Motivation:

Existiert eine Menge, die auf viele Individuen verteilt ist, kann es hilfreich sein zu wissen, wie diese Menge verteilt ist.

Beispiele:

- ▶ Vermögensverteilung in einem Staat
- ▶ Marktanteile von Firmen in einem Marktsegment

Lorenzkurve

Grundidee:

Es sollen folgende Aussagen grafisch dargestellt werden:

- ▶ Die “Ärmsten”/“Kleinsten” $x\%$ besitzen einen Anteil von $y\%$ der gesamten Merkmalssumme.
- ▶ Die “Reichsten”/“Größten” $x\%$ besitzen einen Anteil von $y\%$ der gesamten Merkmalssumme.

Lorenzkurve

Definition:

- ▶ Das Merkmal darf nur *positive* Ausprägungen annehmen.
- ▶ Die Gesamtsumme aller Merkmalswerte ist $\sum_{i=1}^n x_i = \sum_{i=1}^n x_{(i)}$.
- ▶ Die Lorenzkurve verbindet Punktepaaire bestehend aus den *Teilsummen* der *nach Größe geordneten* Beobachtungswerte $0 \leq x_{(1)} \leq \dots \leq x_{(n)}$ und dem *relativen Anteil* der Individuen, die diese Teilsumme besitzen.

Lorenzkurve

- ▶ Es wird festgelegt: $u_0 = 0$ und $v_0 = 0$.
- ▶ Die horizontale Achse wird in *gleiche Längen* aufgeteilt, deren Anzahl der der Individuen (Merkmalsausprägungen) entspricht:

$$u_j = \frac{j}{n}, \quad j = 1, \dots, n.$$

- ▶ Die Werte auf der vertikalen Achse werden wie folgt berechnet:

$$v_j = \frac{\sum_{i=1}^j x_{(i)}}{\sum_{i=1}^n x_{(i)}}, \quad j = 1, \dots, n,$$


also: Quotienten aus der Teilsumme und der Gesamtsumme.

- ▶ Die so errechneten Koordinatenpunkte (u_j, v_j) werden in den Graphen eingetragen und mit Linien verbunden.

Lorenzkurve

Beispiel: 5 Bauern teilen sich eine Ackerfläche von 100ha zu je 20ha.


j	$x_{(j)}$	u_j	v_j
0	-	0	0
1	20	$\frac{1}{5}$	$\frac{20}{100}$
2	20	$\frac{2}{5}$	$\frac{40}{100}$
3	20	$\frac{3}{5}$	$\frac{60}{100}$
4	20	$\frac{4}{5}$	$\frac{80}{100}$
5	20	$\frac{5}{5}$	$\frac{100}{100}$



Lorenzkurve

Beispiel: 4 Bauern besitzen nichts, 1 besitzt alles:

j	$x_{(j)}$	u_j	v_j
0	-	0	0
1	0	$\frac{1}{5}$	$\frac{0}{100}$
2	0	$\frac{2}{5}$	$\frac{0}{100}$
3	0	$\frac{3}{5}$	$\frac{0}{100}$
4	0	$\frac{4}{5}$	$\frac{0}{100}$
5	100	$\frac{5}{5}$	$\frac{100}{100}$



Lorenzkurve

Erscheinungsbild von Lorenzkurven:


- ▶ Die Koordinate $(u_0; v_0)$ ist *immer* $(0; 0)$.
- ▶ Die Koordinate $(u_n; v_n)$ ist *immer* $(1; 1)$.
- ▶ Der konstruierte Polygonzug verläuft *immer unterhalb* (im Grenzfall auf) der Winkelhalbierenden.
- ▶ Der konstruierte Polygonzug ist *(streng) monoton steigend*.
- ▶ Die Steigung des nächsten Polygonsegments ist entweder *gleich groß* oder *größer* als die Steigung des vorherigen Polygonsegments.

Gini-Koeffizient

Der **Gini-Koeffizient** bzw. das **Lorenz'sche Konzentrationsmaß** ist eine Maßzahl, die das *Ausmaß* der Konzentration beschreibt. Er ist definiert als

$$G = 2 \cdot F,$$

wobei F die Fläche zwischen der Diagonalen und der Lorenzkurve ist.



Gini-Koeffizient

Berechnung:

Für die praktische Berechnung von G aus den Wertepaaren $(u_i; v_i)$ stehen folgende alternative Formeln zur Verfügung:

$$G = \frac{2 \sum_{i=1}^n i \cdot x_{(i)} - (n+1) \sum_{i=1}^n x_{(i)}}{n \sum_{i=1}^n x_{(i)}}$$

oder alternativ

$$G = 1 - \frac{1}{n} \sum_{i=1}^n (v_{i-1} + v_i).$$

Wertebereich des Gini-Koeffizienten:

$$0 \leq G \leq \frac{n-1}{n}$$

Gini-Koeffizient

Normierter Gini-Koeffizient G^+ :

Der Gini-Koeffizient wird auf folgende Weise normiert:

$$G^+ = \frac{n}{n-1} G.$$

Er hat somit den Wertebereich

$$0 \leq G^+ \leq 1,$$

wobei 0 für *keine Konzentration* (Gleichverteilung) und 1 für *vollständige Konzentration* (Monopol) steht.

Eigenschaften des Gini-Koeffizient

- ▶ Sehr unterschiedliche Lorenzkurven führen zum selben Gini-Wert, z.B: $G^+ = 0.5$ für
 - ▶ Verteilung 1: 50% ohne Anteile, restliche 50% haben gleiche Anteile an Gesamtsumme
 - ▶ Verteilung 2: untere 75% teilen sich gleichmäßig 25% der Gesamtsumme, obere 25% gleichmäßig 75%
- ▶ Unempfindlich gegen relatives Wachstum: G^+ -Wert bleibt unverändert falls alle x -Werte um den selben Faktor wachsen/schrumpfen
- ▶ “Empfindlich” gegen Ausreißer am oberen Ende
 - ⇒ niedrige Gini-Werte für große Grundgesamtheiten unwahrscheinlicher selbst wenn Verteilung ähnlich zu der in kleinerer Grundgesamtheit, da größere Grundgesamtheiten häufiger extremere Ausreißer enthalten (z.B. US-Amerikaner $\ni$ Jeff Bezos $\gg$ Susanne Klatten $\in$ Deutsche)
- ▶ Häufig Anwendung von verallgemeinerten Lorenzkurven bzw. Ginikoeffizienten auch auf Merkmale mit teils negativen Ausprägungen (z.B. Schulden als negatives Vermögen, s. übernächste Folie) - dann keine Monotonie etc mehr.

Herfindahl-Index

$x_1, \dots, x_n$ seien die Daten mit $x_i \geq 0$.

Die Anteile der Einheiten i sind wie folgt definiert:

$$p_i := \frac{x_i}{\sum_{j=1}^n x_j}$$


Der Herfindahl-Index ist

$$H := \sum_{i=1}^n p_i^2$$

Der Wertebereich ist von $\frac{1}{n}$ (identische x_i) bis 1 (Monopol)

Konzentrationsmessung: Deutsche Vermögensverteilung


Lorenzkurve der individuellen Nettovermögen in Deutschland
Gini-Koeffizienten: ca. 0.77 – 0.80



Daten: www.armuts-und-reichtumsbericht.de / BM Arbeit & Soziales, 4.10.2021 (nur Dezile)

Gini-Index Vermögen Deutschland

Vermögensverteilung individuelle Nettovermögen nach SOEP




© Bundesministerium für Arbeit und Soziales

Armuts- & Reichtumsbericht, BM Arbeit & Soziales

Gini-Index Einkommen Deutschland

Einkommensverteilung Gini-Koeffizient



© Bundesministerium für Arbeit und Soziales

Armuts- & Reichtumsbericht, BM Arbeit & Soziales