

## **Zusammenhangsmaße für metrische Merkmale**

Kovarianz und Korrelation beobachteter Merkmale

Darstellung multivariater Zusammenhänge

Kovarianz und Korrelation von Zufallsvariablen

Alternative Zusammenhangsmaße

Beispiele: Zusammenhänge metrischer Variablen

Zusammenhangsmaße für dichotome und ordinale/metrische Merkmale

## **Zusammenhangsmaße für metrische Merkmale**

Kovarianz und Korrelation beobachteter Merkmale

Darstellung multivariater Zusammenhänge

Kovarianz und Korrelation von Zufallsvariablen

Alternative Zusammenhangsmaße

Beispiele: Zusammenhänge metrischer Variablen

Zusammenhangsmaße für dichotome und ordinale/metrische Merkmale

# Kovarianz

Kennzahl für Stärke und Richtung des linearen Zusammenhang zweier metrischer Merkmale:


Daten:  $(x_i, y_i), i = 1, \dots, n$

$$S_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$


Beachte:

- ▶ Summand  $i$  positiv, falls Abweichungen von  $x_i$  und  $y_i$  zum jeweiligen Mittelwert das gleiche Vorzeichen haben, negativ falls unterschiedlich.
- ▶ Für  $S_{xx}$  ergibt sich die Varianz von  $X$ :  $S_{xx} = S_x^2$
- ▶ Der Wert der Kovarianz hängt sowohl von den **Streuungen** der beiden Merkmal als auch von der **Stärke und Richtung ihres Zusammenhangs** ab.


# Kovarianz: Geometrische Intuition



# Kovarianz: Geometrische Intuition



# Kovarianz: Geometrische Intuition



# Bravais-Pearson-Korrelationskoeffizient

Der Bravais-Pearson-Korrelationskoeffizient  $r_{xy}$  ergibt sich aus den Daten  $(x_i, y_i), i = 1, \dots, n$  durch

$$\begin{aligned} r_{xy} &= \frac{1}{n-1} \sum_{i=1}^n \frac{(x_i - \bar{x})}{S_x} \frac{(y_i - \bar{y})}{S_y} \\ &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{S_{xy}}{S_x S_y} \end{aligned}$$

Wertebereich:  $-1 \leq r_{xy} \leq 1$

► dimensionslose Größe, hängt nicht mehr von  $S_x$  oder  $S_y$  ab:

- $r_{xy} > 0$  positive Korrelation, gleichsinniger linearer Zusammenhang, Tendenz: Werte  $(x_i, y_i)$  um eine Gerade positiver Steigung liegend
- $r_{xy} < 0$  negative Korrelation, gegenläufiger linearer Zusammenhang, Tendenz: Werte  $(x_i, y_i)$  um eine Gerade negativer Steigung liegend
- $r_{xy} = 0$  keine Korrelation, unkorreliert, kein linearer Zusammenhang







# Eigenschaften des Korrelationskoeffizienten

- ▶ Misst vor allem die Stärke des **linearen** Zusammenhangs
- ▶ Betrag der Korrelation unverändert bei linearen Transformationen
- ▶ Symmetrisch:  $r_{xy} = r_{yx}$
- ▶ Positive Korrelation bedeutet:  
“Je größer X, desto größer im Durchschnitt Y”
- ▶ Korrelation = +1 [-1] falls die Punkte genau auf einer Geraden mit positiver [negativer] Steigung liegen – **unabhängig von Steigung dieser Geraden** (außer sie ist 0 oder  $\infty$ ).
- ▶ “Korrelation = 0” bedeutet “kein *linearer* Zusammenhang”, aber **nicht Unabhängigkeit!** (s. Bsp. unten)
- ▶ Korrelation (und Kovarianz) sind empfindlich gegenüber Ausreißern




# Eigenschaften von $r_{xy}$

Misst nur Stärke des **linearen** Zusammenhangs:



# Eigenschaften Bravais-Pearson-Korrelation



**Alle** diese Datensätze haben  $r_{xy} = -0.06!$

(und  $n = 142$ ,  $\bar{x} = 54.3$ ,  $S_x = 16.8$ ,  $\bar{y} = 47.8$ ,  $S_y = 26.9$ )

# Lineare Transformationen

- ▶ Bei exakten linearen Zusammenhängen gilt:

$$r_{xy} = +1 \text{ bzw. } -1 \quad \Longleftrightarrow \quad Y = aX + b \text{ mit } a > 0 \text{ bzw. } a < 0$$

- ▶ Lineare Transformationen  $\tilde{X} = a_X X + b_X, \tilde{Y} = a_Y Y + b_Y, a_X, a_Y \neq 0$ :

$r_{xy}$  Korrelationskoeffizient zwischen  $X$  und  $Y$

$\tilde{r}_{xy}$  Korrelationskoeffizient zwischen  $\tilde{X}$  und  $\tilde{Y}$

$$\begin{aligned} \Rightarrow \quad \tilde{r}_{xy} &= r_{xy} && \Longleftrightarrow && a_X, a_Y \text{ gleiches Vorzeichen} \\ \tilde{r}_{xy} &= -r_{xy} && \Longleftrightarrow && a_X, a_Y \text{ verschiedene Vorzeichen.} \end{aligned}$$

## **Zusammenhangsmaße für metrische Merkmale**

Kovarianz und Korrelation beobachteter Merkmale

Darstellung multivariater Zusammenhänge

Kovarianz und Korrelation von Zufallsvariablen

Alternative Zusammenhangsmaße

Beispiele: Zusammenhänge metrischer Variablen

Zusammenhangsmaße für dichotome und ordinale/metrische Merkmale

# Kovarianz- und Korrelationsmatrix

Bei mehr als zwei Merkmalen werden Kovarianzen und Korrelationen häufig in Form einer Matrix dargestellt.

Auf der Hauptdiagonalen stehen die Stichprobenkovarianzen bzw. die Korrelationen jedes Merkmals mit sich selbst, also die jeweilige Stichprobenvarianz bzw 1.


Die Matrix ist symmetrisch da  $S_{XY} = S_{YX}$ .

Bsp: Korrelationsmatrix der Merkmale X, Y, Z:


$$\begin{pmatrix} 1 & r_{xy} & r_{xz} \\ r_{xy} & 1 & r_{yz} \\ r_{xz} & r_{yz} & 1 \end{pmatrix}$$

Analog für Zufallsvektoren mit entsprechenden *Erwartungswertvektoren* und *Kovarianzmatrizen*!

# (Scatter)plotmatrix I



# (Scatter)plotmatrix II



## **Zusammenhangsmaße für metrische Merkmale**

Kovarianz und Korrelation beobachteter Merkmale

Darstellung multivariater Zusammenhänge

Kovarianz und Korrelation von Zufallsvariablen

Alternative Zusammenhangsmaße

Beispiele: Zusammenhänge metrischer Variablen

Zusammenhangsmaße für dichotome und ordinale/metrische Merkmale



# Kovarianzen und Korrelationen

## Def.: Kovarianz und Korrelation

Die **Kovarianz**  $\text{Cov}(X, Y)$  bzw die **Korrelation**  $\rho(X, Y)$  zweier ZVn  $X, Y$  sind Maße für die Stärke und Richtung der linearen Abhängigkeit von ZVn  $X$  und  $Y$ . Es gilt:

$$\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))]$$
$$\text{und } \rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}}.$$

Letzteres unter der Voraussetzung, dass  $\text{Var}(X) > 0$  und  $\text{Var}(Y) > 0$ .

Beachte:  $\text{Cov}(X, X) = \text{Var}(X)$

# Der Verschiebungssatz für die Kovarianz

Es gilt zudem:

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$$

Beweis:

$$\begin{aligned}\text{Cov}(X, Y) &= E((X - E(X))(Y - E(Y))) \\ &= E(XY - YE(X) - XE(Y) + E(X)E(Y)) \\ &= E(XY) - 2E(X)E(Y) + E(X)E(Y) = E(XY) - E(X)E(Y)\end{aligned}$$

# Unkorreliertheit

$X$  und  $Y$  heißen **unkorreliert**, wenn

$$\text{Cov}(X, Y) = 0 \quad \text{bzw.} \quad \rho(X, Y) = 0$$

d.h. wenn

$$E(XY) = E(X) \cdot E(Y)$$

gilt.

Beachte: Aus Unabhängigkeit folgt Unkorreliertheit, aber der Umkehrschluss gilt i.A. nicht!

$X$  und  $Y$  sind **positiv/negativ korreliert** falls

$$\rho(X, Y) > 0 \quad \text{bzw.} \quad \rho(X, Y) < 0$$

# Beispiel: Unabhängig vs Unkorreliert

Seien  $X \sim \mathcal{B}(\pi = \frac{1}{2})$  und  $Y \sim \mathcal{B}(\pi = \frac{1}{2})$  unabhängig.

Betrachte

$$Z_1 = X + Y = \begin{cases} 0 & \text{mit Wkeit } \frac{1}{4} \\ 1 & \text{mit Wkeit } \frac{1}{2} \\ 2 & \text{mit Wkeit } \frac{1}{4} \end{cases} ; \quad Z_2 = X - Y = \begin{cases} -1 & \text{mit Wkeit } \frac{1}{4} \\ 0 & \text{mit Wkeit } \frac{1}{2} \\ 1 & \text{mit Wkeit } \frac{1}{4} \end{cases}$$

Dann sind  $Z_1$  und  $Z_2$  zwar unkorreliert aber nicht unabhängig:

| $f_{Z_1, Z_2}(z_1, z_2)$ | $z_1 = 0$ | $z_1 = 1$ | $z_1 = 2$ | $f_{Z_2}(z_2)$ |
|--------------------------|-----------|-----------|-----------|----------------|
| $z_2 = -1$               | 0         | 1/4       | 0         | 1/4            |
| $z_2 = 0$                | 1/4       | 0         | 1/4       | 1/2            |
| $z_2 = 1$                | 0         | 1/4       | 0         | 1/4            |
| $f_{Z_1}(z_1)$           | 1/4       | 1/2       | 1/4       |                |

$\Rightarrow f(z_1, z_2) \neq f(z_1)f(z_2)$  d.h.  $Z_1, Z_2$  nicht unabhängig.  
Aber  $E(Z_1) = 1, E(Z_2) = 0; E(Z_1 Z_2) = 0$ , also  $\text{Cov}(Z_1, Z_2) = 0!$

# Eigenschaften von Korrelationen

Für alle ZVn  $X$  und  $Y$  gilt:

$$-1 \leq \rho(X, Y) \leq 1$$

$|\rho(X, Y)| = 1$  gilt genau dann, wenn perfekte lineare Abhängigkeit zwischen  $X$  und  $Y$  besteht:

$$|\rho(X, Y)| = 1 \iff Y = a + b \cdot X \quad \text{für } a, b \in \mathbb{R}; b \neq 0$$

# Lineare Transformationen

Sei  $a, b, c, d \in \mathbb{R}$  mit  $b \cdot d > 0$  und  $X, Y$  beliebige ZVn. Dann gilt:

$$\text{Cov}(a + bX, c + dY) = b \cdot d \cdot \text{Cov}(X, Y)$$

Daher gilt:

$$\rho(a + bX, c + dY) = \text{sgn}(b) \cdot \text{sgn}(d) \cdot \rho(X, Y)$$

d.h. die Korrelation ist **invariant** bzgl. linearer Transformationen

$$\text{sgn}(x) := \frac{x}{|x|} = \begin{cases} 1 & x > 0 \\ 0 & x = 0 \\ -1 & x < 0 \end{cases}$$

# Varianz der Summe zweier ZVn

Seien  $X$  und  $Y$  beliebige ZVn. Dann gilt für  $X + Y$ :

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \cdot \text{Cov}(X, Y)$$

Daher gilt speziell für *unabhängige* und damit unkorrelierte  $X$  und  $Y$ :

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$$

# Anwendung: Bivariate Standardnormalverteilung


Die **bivariate Standardnormalverteilung** mit Parameter  $\rho$  ( $|\rho| < 1$ ) hat Träger  $T = \mathbb{R} \times \mathbb{R}$  und Dichtefunktion

$$f(x, y) = \frac{1}{2\pi\sqrt{(1-\rho^2)}} \exp\left(-\frac{1}{2(1-\rho^2)}(x^2 - 2\rho xy + y^2)\right)$$

- ▶ Die Randverteilungen von  $X$  und  $Y$  sind (für jedes  $\rho$ ) standard-normalverteilt.
- ▶ Die Korrelation zwischen  $X$  und  $Y$  ist gleich  $\rho$ .
- ▶ Aus Unkorreliertheit von  $X$  und  $Y$  folgt in diesem Spezialfall die Unabhängigkeit von  $X$  und  $Y$ .




# Visualisierung: Bivariate Standardnormalverteilung




# Visualisierung: Bivariate Standardnormalverteilung


$$\rho = 0.8$$



$$\rho = 0$$



$$\rho = -0.5$$



# Multivariate Normalverteilung

Die allgemeine bivariate Normalverteilung erhält man durch lineare Transformation der Komponenten der bivariaten Standardnormalverteilung:

$$X \rightarrow \mu_X + \sigma_X \cdot X; \quad Y \rightarrow \mu_Y + \sigma_Y \cdot Y$$

Insgesamt fünf Parameter:  $\mu_X, \mu_Y, \sigma_X^2, \sigma_Y^2, \rho$ .

Es gilt  $\sigma_{XY} := \text{Cov}(X, Y) = \rho \sigma_X \sigma_Y$

Notation:

$$(X, Y) \sim \mathcal{N}_2 \left( \boldsymbol{\mu} = (\mu_X, \mu_Y)^T, \boldsymbol{\Sigma} = \begin{pmatrix} \sigma_X^2 & \sigma_{XY} \\ \sigma_{XY} & \sigma_Y^2 \end{pmatrix} \right)$$

Ausblick: Das Konzept ist auf beliebig hohe Dimensionen übertragbar. Die Parameter einer  $d$ -dimensionalen NV sind ihr Erwartungswertvektor  $\boldsymbol{\mu}$  und ihre Kovarianzmatrix  $\boldsymbol{\Sigma}$ :

$$\begin{aligned} \mathbf{X} = (X_1, X_2, \dots, X_d)^T &\sim \mathcal{N}_d(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \\ \implies f(\mathbf{x}) &= \frac{1}{\sqrt{(2\pi)^d |\boldsymbol{\Sigma}|}} \exp \left( -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right) \end{aligned}$$

## **Zusammenhangsmaße für metrische Merkmale**

Kovarianz und Korrelation beobachteter Merkmale

Darstellung multivariater Zusammenhänge

Kovarianz und Korrelation von Zufallsvariablen

**Alternative Zusammenhangsmaße**

Beispiele: Zusammenhänge metrischer Variablen

Zusammenhangsmaße für dichotome und ordinale/metrische Merkmale

# Spearman-/Rang-Korrelationskoeffizient

$X, Y$  (mindestens) ordinal

**Idee:** Berechne **Korrelation nach Bravais-Pearson für die Ränge** statt für die Werte der Merkmale.

Der *Korrelationskoeffizient nach Spearman* ist definiert durch

$$r_{xy}^{SP} = \frac{\sum (rg(x_i) - \bar{rg}_X)(rg(y_i) - \bar{rg}_Y)}{\sqrt{\sum (rg(x_i) - \bar{rg}_X)^2 \sum (rg(y_i) - \bar{rg}_Y)^2}}.$$

Wertebereich:  $-1 \leq r_{xy}^{SP} \leq 1$

# Vorgehen

- ▶ Urliste der Größe nach sortieren
- ▶  $\Rightarrow$  Ranglisten  $rg(x_i), rg(y_i), i = 1, \dots, n$  vergeben (bei Bindungen: Durchschnittsränge)

z.B:

|           |     |     |     |     |
|-----------|-----|-----|-----|-----|
| $x_i$     | 2.3 | 7.1 | 1.0 | 2.1 |
| $rg(x_i)$ | 3   | 4   | 1   | 2   |

bei Bindungen (ties):


|           |     |     |     |     |     |
|-----------|-----|-----|-----|-----|-----|
| $x_i$     | 2.3 | 7.1 | 1.0 | 2.1 | 2.3 |
| $rg(x_i)$ | 3.5 | 5   | 1   | 2   | 3.5 |

$\Rightarrow$  Durchschnittsrang  $\frac{3+4}{2} = 3.5$  vergeben.

# Interpretation

- ▶  $r_{xy}^{SP} > 0 \iff$  gleichsinniger monotoner Zusammenhang,  
Tendenz:  $x$  groß  $\iff y$  groß,  $x$  klein  $\iff y$  klein
- ▶  $r_{xy}^{SP} < 0 \iff$  gegensinniger monotoner Zusammenhang,  
Tendenz:  $x$  groß  $\iff y$  klein,  $x$  klein  $\iff y$  groß
- ▶  $r_{xy}^{SP} \approx 0 \iff$  kein monotoner Zusammenhang

# Extremfälle



$r_{xy}^{SP} = 1$  (oben) und  $r_{xy}^{SP} = -1$  (unten)



# Bemerkungen:

- Rechentechnische Vereinfachungen:

$$\begin{aligned}\bar{r}g_X &= \frac{1}{n} \sum_{i=1}^n rg(x_i) = \frac{1}{n} \sum_{i=1}^n i = (n+1)/2, \\ \bar{r}g_Y &= \frac{1}{n} \sum_{i=1}^n rg(y_i) = \frac{1}{n} \sum_{i=1}^n i = (n+1)/2.\end{aligned}$$

Rechentechnisch günstige Version von  $r_{xy}^{SP}$ :

- Voraussetzung: keine Bindungen
- Daten:  $(x_i, y_i)$ ,  $i = 1, \dots, n$ ,  $x_i \neq x_j$ ,  $y_i \neq y_j$  für alle  $i, j$
- Rangdifferenzen:  $d_i = rg(x_i) - rg(y_i)$

$$\Rightarrow r_{xy}^{SP} = 1 - \frac{6 \sum d_i^2}{(n^2 - 1)n}$$

# Monotone Transformationen

$\tilde{X} = g(X)$   $g$  streng monoton,  
 $\tilde{Y} = h(Y)$   $h$  streng monoton

- ▶  $g$  und  $h$  beide monoton wachsend oder beide monoton fallend  
 $\implies r^{SP}(\tilde{X}, \tilde{Y}) = r^{SP}(X, Y)$
- ▶  $g, h$  nicht *beide* wachsend oder *beide* fallend  
 $\implies r^{SP}(\tilde{X}, \tilde{Y}) = -r^{SP}(X, Y)$

# Paarvergleichsmaße: Kendall's Tau

Betrachte Paare von Beobachtungen  $(x_i, y_i)$  und  $(x_j, y_j)$

Ein Paar heißt:

**konkordant**, falls  $x_i < x_j$  und  $y_i < y_j$   
oder  $x_i > x_j$  und  $y_i > y_j$ ,  
also: Rangfolge der X-Werte gleich der der Y-Werte.

**diskordant**, falls  $x_i < x_j$  und  $y_i > y_j$   
oder  $x_i > x_j$  und  $y_i < y_j$ ,  
also: Rangfolge der X-Werte umgekehrt der Y-Werte.


$N_C$ : Anzahl der konkordanten Paare

$N_D$ : Anzahl der diskordanten Paare

Insgesamt  $n(n - 1)/2$  mögliche Paare.

**Kendall's Tau:** 
$$\tau_{xy} = \frac{N_C - N_D}{n(n - 1)/2}$$

# Kendall's Tau: Veranschaulichung



$n = 10$ ;  $N_C = 23$ ;  $N_D = 22$ ;  $\tau_{XY} = 0.02$

$n = 15$ ;  $N_C = 81$ ;  $N_D = 24$ ;  $\tau_{XY} = 0.54$

$n = 20$ ;  $N_C = 56$ ;  $N_D = 134$ ;  $\tau_{XY} = -0.41$

# Varianten

- ▶ Goodman & Kruskal  $\gamma$ -Koeffizient ignoriert Paare mit Bindungen:

$$\gamma_{xy} = \frac{N_C - N_D}{N_C + N_D}$$

- ▶ Somers' D wird typischerweise verwendet wenn Y binär ist  
( $\Rightarrow$  viele Paare mit Bindungen in Y)

$$D_{xy} := \frac{N_C - N_D}{\text{Anzahl Paare mit ungleichem } y}$$

# Gemeinsamkeiten der Paarvergleichsmaße

Für Kendall's  $\tau$ , Somers' D und Goodman & Kruskal's  $\gamma$ -Koeffizient gilt:

- ▶ ihr Wertebereich ist  $[-1, 1]$
- ▶ sie setzen (mindestens) *ordinale* Variablen  $X, Y$  voraus

# Paarvergleichsmaßen vs. Spearman's $r_{xy}^{SP}$

- ▶  $r_{xy}^{SP}$  verwendet Abstände auf der Rang-Skala
- ▶  $\tau_{xy}$  und Varianten verwendet alle Paarvergleiche
- ▶  $\tau_{xy}$  ist in der Regel betragsmäßig kleiner als  $r_{xy}^{SP}$

# Distanzkovarianz & Distanzkorrelation

Modernes Zusammenhangsmaß für (fast) beliebige Zusammenhänge (nicht nur linear/monoton).

Basiert auf Produkten der (zentrierten) Distanzen der Beobachtungen untereinander, nicht nur auf Distanzen zu ihren Mittelwerten.

**Distanzkovarianz**  $dS_{xy}$ :

$$dS_{xy} = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n D_{ij}^x D_{ij}^y$$

- ▶ zentrierte Distanzen  $D_{ij}^x = d_{ij}^x - (\bar{d}_{i\cdot}^x + \bar{d}_{\cdot j}^x - \bar{d}^x)$  mit
- ▶  $d_{ij}^x = |x_i - x_j|$
- ▶  $\bar{d}_{i\cdot}^x = \frac{1}{n} \sum_{j=1}^n d_{ij}^x$  und  $\bar{d}_{\cdot j}^x = \frac{1}{n} \sum_{i=1}^n d_{ij}^x$ ,
- ▶  $\bar{d}^x = \frac{1}{n^2} \sum_{i=1}^n \sum_{j=1}^n d_{ij}^x$
- ▶ analog für  $D_{ij}^y$



# Distanzkorrelation

Die **Distanzkorrelation** ist definiert als

$$dr_{xy} = \sqrt{\frac{dS_{xy}^2}{\sqrt{dS_{xx}^2 dS_{yy}^2}}}$$

wobei

- ▶  $dS_{xy}^2 = dS_{xy} dS_{xy}$
- ▶  $dS_{xx}$  ist die Distanzkovarianz von X mit sich selbst.

# Eigenschaften Distanzkorrelation

- ▶  $0 \leq dr_{xy} \leq 1$  – misst nur Stärke, nicht “Richtung” der Abhängigkeit.
- ▶  $dr_{xy} = 0 \iff X$  und  $Y$  empirisch unabhängig (!)
- ▶  $dr_{xy} = 1$  für perfekt lineare Zusammenhänge (bei Verwendung der euklidischen Distanz)
- ▶ **Sehr** allgemein anwendbar:
  - ▶ beliebige Distanzmaße verwendbar als  $d_{ij}^x, d_{ij}^y$
  - ▶  $\implies$  auch für alle *multivariaten* oder *nicht-numerischen* Daten  $X, Y$  (z.B. Bilder, Audiosignale, Gensequenzen, ...) benutzbar, für die man Distanzen definieren kann.

(Székely, Rizzo, Bakirov; 2007)

## **Zusammenhangsmaße für metrische Merkmale**

Kovarianz und Korrelation beobachteter Merkmale

Darstellung multivariater Zusammenhänge

Kovarianz und Korrelation von Zufallsvariablen


Alternative Zusammenhangsmaße

**Beispiele: Zusammenhänge metrischer Variablen**

Zusammenhangsmaße für dichotome und ordinale/metrische Merkmale


# Beispiele: Deterministische Zusammenhänge

Lineare (unverrauschte) Funktion,  $Y = a + b \cdot X$ , 101 equidistante Stützstellen im Intervall  $[-1,1]$




# Beispiele: Deterministische Zusammenhänge

Periodische (unverrauschte) Funktionen, 101 equidistante Stützstellen im Intervall  $[-1, 1]$






# Beispiele: Deterministische Zusammenhänge

Quadratische und kubische (unverrauschte) Funktionen, 101 equidistante Stützstellen im Intervall  $[-1, 1]$




# Beispiele: Exakte & verrauschte Zusammenhänge

Lineare, verrauschte Funktionen  $Y = 2 + 0.8X + U$  mit zufälligem Fehler  $U$ .  
101 equidistante Stützstellen im Intervall  $[-1,1]$



# Noch mehr Beispiele





## **Zusammenhangsmaße für metrische Merkmale**

Kovarianz und Korrelation beobachteter Merkmale

Darstellung multivariater Zusammenhänge

Kovarianz und Korrelation von Zufallsvariablen

Alternative Zusammenhangsmaße

Beispiele: Zusammenhänge metrischer Variablen

**Zusammenhangsmaße für dichotome und ordinale/metrische Merkmale**

# Dichotome und ordinale/metrische Merkmale

Wichtiger Spezialfall:

Dichotomes Merkmal  $Y$  und ein mindestens ordinalskaliertes  $X$ .

## Beispiele:

- ▶ Medizin: Diagnostische Tests  
X: Biomarker (Stoffkonzentration in Blut o.ä.) oder diagnostischer Score  
Y: krank vs. gesund; genesen vs. verstorben; etc...
- ▶ Marketing:  
X: Kundeneigenschaften (z.B. bisher erzielter Umsatz mit diesem Kunden)  
Y: Kaufentscheidung ja/nein; Vertragsverlängerung ja/nein; etc...
- ▶ Kredit-Score o.ä.  
Y: Schufa-Eintrag (Kreditausfall) binnen 1.5 Jahre oder nicht

# Sensitivität und Spezifität

*Setting:*

- ▶  $Y \in \{0, 1\}$  dichotom (Zielgröße)
- ▶  $X$  mindestens ordinalskaliert (Einflussgröße)

$Y = 1 \iff$  **“positiver”** Fall (z.B. “krank”, “Kreditausfall”, “Kündigung”, ...)

$Y = 0 \iff$  **“negativer”** Fall (z.B. “gesund”, “Rückzahlung”, “Verlängerung”, ...)

*Ziel:*

Vorhersage/Diagnose  $\hat{y}_i$  nur auf Basis von  $x_i$  und Schwellenwert  $c$ :

$$\hat{y}_i = 1 \iff x_i \geq c$$

*Fragestellung:*

Wie kann ein geeigneter Schwellenwert  $c$  bestimmt werden?

Wie gut oder schlecht eignet sich Merkmal  $X$  insgesamt zur Einschätzung von  $Y$ ?

# Sensitivität und Spezifität

|                            | $y_i = 0$        | $y_i = 1$        |                        |
|----------------------------|------------------|------------------|------------------------|
| Vorhersage $\hat{y}_i = 0$ | “wahr negativ”   | “falsch negativ” | # negative Vorhersagen |
| Vorhersage $\hat{y}_i = 1$ | “falsch positiv” | “wahr positiv”   | # positive Vorhersagen |
|                            | # negative       | # positive       |                        |

## Dilemma:

- ▶ Je größer  $c$ 
  - ▶ desto weniger “positive” Vorhersagen insgesamt
  - ▶ tendenziell: desto weniger falsch positive aber auch weniger wahr positive
- ▶ Je kleiner  $c$ 
  - ▶ desto weniger “negative” Vorhersagen insgesamt
  - ▶ tendenziell: desto weniger falsch negative aber auch weniger wahr negative

# Sensitivität und Spezifität

**Anteil wahr positiver Prognosen für echt positive = Sensitivität**

$$TPR(c) = f(\hat{Y} = 1 | Y = 1) = f(X \geq c | Y = 1)$$

“Welcher Anteil der Kranken wurde entdeckt?": “Empfindlichkeit” des Tests

*true positive rate TPR*

**Anteil falsch positiver Prognosen für echt negative**

$$FPR(c) = f(\hat{Y} = 1 | Y = 0) = f(X \geq c | Y = 0)$$

“Welcher Anteil der Gesunden wurde falsch diagnostiziert?”

*false positive rate FPR*

**Anteil wahr negativer Prognosen für echt negative = Spezifität**

$$TNR(c) = f(\hat{Y} = 0 | Y = 0) = 1 - f(X \geq c | Y = 0) = 1 - FPR(c)$$

“Welcher Anteil der Gesunden wurde korrekt diagnostiziert?”

*true negative rate TNR*

# ROC-Kurve

## Die ROC-Kurve



- ▶ verbindet die Punkte  $(FPR(c), TPR(c))$ , also (1-Spezifität, Sensitivität) bzw. (“falsch positiv”-Rate, “wahr positiv”-Rate)
- ▶ für *alle* möglichen Schwellenwerte  $c \in [x_{(1)}, x_{(n)}]$

Sie zeigt die Zuverlässigkeit der Vorhersagen für alle möglichen Schwellenwerte  $c$  an.

Es gilt:

- ▶ Für  $c < x_{(1)}$ : Test immer “positiv”, also  
 $\hat{y}_i = 1 \forall i \implies (FPR(c), TPR(c)) = (1, 1)$
- ▶ Für  $c > x_{(n)}$ : Test immer “negativ”, also  
 $\hat{y}_i = 0 \forall i \implies (FPR(c), TPR(c)) = (0, 0)$



# Beispiel 1: Mittelmäßig starker Zusammenhang



|            | gesund | krank |
|------------|--------|-------|
| <"gesund"> | 27     | 2     |
| <"krank">  | 3      | 8     |

|                       |      |
|-----------------------|------|
| Sensitivität          | 0.80 |
| Spezifität            | 0.90 |
| pos. prädiktiver Wert | 0.73 |
| neg. prädiktiver Wert | 0.93 |

# Beispiel 2: Mittelmäßig starker Zusammenhang





|            | gesund | krank |
|------------|--------|-------|
| <"gesund"> | 185    | 17    |
| <"krank">  | 15     | 33    |

|                       |      |
|-----------------------|------|
| Sensitivität          | 0.66 |
| Spezifität            | 0.93 |
| pos. prädiktiver Wert | 0.69 |
| neg. prädiktiver Wert | 0.92 |





# Beispiel 2: Mittelmäßig starker Zusammenhang



|                              | gesund | krank |
|------------------------------|--------|-------|
| <"gesund">                   | 197    | 30    |
| <"krank">                    | 3      | 20    |
| <i>Sensitivität</i>          | 0.40   |       |
| <i>Spezifität</i>            | 0.98   |       |
| <i>pos. prädiktiver Wert</i> | 0.87   |       |
| <i>neg. prädiktiver Wert</i> | 0.87   |       |



# Beispiel 2: Mittelmäßig starker Zusammenhang



|            | gesund | krank |
|------------|--------|-------|
| <"gesund"> | 99     | 0     |
| <"krank">  | 101    | 50    |

|                       |      |
|-----------------------|------|
| Sensitivität          | 1.00 |
| Spezifität            | 0.49 |
| pos. prädiktiver Wert | 0.33 |
| neg. prädiktiver Wert | 1.00 |



# Beispiel 3: Kein Zusammenhang



|            | gesund | krank |
|------------|--------|-------|
| <"gesund"> | 101    | 22    |
| <"krank">  | 99     | 28    |

|                       |      |
|-----------------------|------|
| Sensitivität          | 0.56 |
| Spezifität            | 0.51 |
| pos. prädiktiver Wert | 0.22 |
| neg. prädiktiver Wert | 0.82 |



# Beispiel 3: Kein Zusammenhang



|            | gesund | krank |
|------------|--------|-------|
| <"gesund"> | 165    | 40    |
| <"krank">  | 35     | 10    |

|                       |      |
|-----------------------|------|
| Sensitivität          | 0.20 |
| Spezifität            | 0.82 |
| pos. prädiktiver Wert | 0.22 |
| neg. prädiktiver Wert | 0.80 |



# Beispiel 3: Kein Zusammenhang



|            | gesund | krank |
|------------|--------|-------|
| <"gesund"> | 29     | 9     |
| <"krank">  | 171    | 41    |

|                       |      |
|-----------------------|------|
| Sensitivität          | 0.82 |
| Spezifität            | 0.14 |
| pos. prädiktiver Wert | 0.19 |
| neg. prädiktiver Wert | 0.76 |

# Beispiel 4: Sehr starker Zusammenhang




|            | gesund | krank |
|------------|--------|-------|
| <"gesund"> | 198    | 3     |
| <"krank">  | 2      | 47    |

|                              |      |
|------------------------------|------|
| <i>Sensitivität</i>          | 0.94 |
| <i>Spezifität</i>            | 0.99 |
| <i>pos. prädiktiver Wert</i> | 0.96 |
| <i>neg. prädiktiver Wert</i> | 0.99 |

# Beispiel für ROC-Kurve mit Bindung

|    | X | Y |
|----|---|---|
| 1  | 1 | 0 |
| 2  | 1 | 0 |
| 3  | 2 | 0 |
| 4  | 2 | 0 |
| 5  | 3 | 0 |
| 6  | 3 | 0 |
| 7  | 4 | 0 |
| 8  | 4 | 1 |
| 9  | 5 | 0 |
| 10 | 6 | 1 |



# Maß zur Bewertung der Kurve: AUC

Das AUC entspricht der Fläche unter der ROC-Kurve.

$$AUC := \frac{N_C + N_E/2}{N}$$

- ▶ Anzahl konkordante Paare

$$N_C = |\{(i, j) : (x_i > x_j \wedge y_i > y_j) \vee (x_i < x_j \wedge y_i < y_j)\}|$$

- ▶ Anzahl Paare mit Bindungen in  $X$

$$N_E = |\{(i, j) : x_i = x_j \wedge y_i \neq y_j\}|$$

- ▶ Anzahl aller Paare mit unterschiedlichem  $Y$

$$N = |\{(i, j) : y_i \neq y_j\}| = h_Y(0)h_Y(1)$$



# Interpretation AUC

- ▶ perfekte Trennbarkeit der  $Y$ -Gruppen durch den Scorewert  $X$  würde einen AUC-Wert von 1 ergeben
- ▶ Unabhängigkeit zwischen  $X$  und  $Y$  einen AUC-Wert von ca. 0.5.

⇒ AUC ist ein Maß dafür wie gut man  $Y$  auf Basis einer einfachen Schwellenwertregel für  $X$  vorhersagen kann.


AUC entspricht (in etwa) der **relativen Häufigkeit mit der, in einem beliebigen Paar von Untersuchungseinheiten mit unterschiedlichem  $Y$ , die Beobachtung mit  $Y = 1$  den höheren  $X$ -Wert hat.**

# Beispiel: Pima Indian Diabetes-Daten



- ▶ 532 Frauen über 21
- ▶ vom Volk der Pima bei Phoenix, AZ
- ▶ sehr hohe Prävalenz von *Diabetes mellitus*: 33%
- ▶ viele zusätzlich erhobene Stoffwechselfparameter (Blutplasmaglukose, Blutdruck, ...), Alter, Anzahl Schwangerschaften, etc
- ▶ was sind Risikofaktoren bzw was ist prognostisch verwendbar für Diabetes?

Datenquelle: US National Institute of Diabetes and Digestive and Kidney Diseases



# Beispiel: Pima Indian Diabetes-Daten



# Beispiel: Pima Indian Diabetes-Daten



# Beispiel: Pima Indian Diabetes-Daten



# Kritik AUC

AUC basierend auf Sensitivität  $f(\hat{Y} = 1 | Y = 1)$ : *“Welcher Anteil der Kranken wurde korrekt diagnostiziert?”*;

Spezifität  $f(\hat{Y} = 0 | Y = 0)$ : *“Welcher Anteil der Gesunden wurde korrekt diagnostiziert?”*

AUC behandelt Spezifität & Sensitivität gleichwertig –

oft aber dramatisch (!! ) unterschiedlich wichtige Konsequenzen für *“falschen Alarm ausgelöst”* (falsch positiv)

oder *“keine Therapie eingeleitet da Krankheit nicht entdeckt”, “Bauteil nicht gewartet/ersetzt da Defekt nicht gefunden”, etc.* (falsch negativ)

⇒ auch sehr wichtig:

- ▶ **positiv prädiktiver Wert (ppv)** des Diagnoseverfahrens:  $f(Y = 1 | \hat{Y} = 1)$   
*Wie groß ist der Anteil echter Alarme an den ausgelösten Alarmen?*
- ▶ **negativ prädiktiver Wert (npv)** des Diagnoseverfahrens:  $f(Y = 0 | \hat{Y} = 0)$   
*Wie viele der als “gesund” Diagnostizierten sind tatsächlich gesund?*

# Positiv/negativ prädiktiver Wert: ppV & npV

Bsp: Nicht-invasive Pränataldiagnostik (NIPT) für Trisomie-21

- ▶ Prävalenz Trisomie-21 bei 22-jährigen Müttern:  
ca. 8 von 10 000 Kindern (0.008%)
- ▶ NIPT: Sensitivität 99.2%, Spezifität 99.9%

Erwartete Häufigkeiten dementsprechend bei 1 000 000 getesteten 22-jährigen Schwangeren:

|                     | Kind krank | Kind gesund |           |
|---------------------|------------|-------------|-----------|
| NIPT: "Kind krank"  | 794        | 999         | 1793      |
| NIPT: "Kind gesund" | 6          | 998 201     | 998207    |
|                     | 800        | 999 200     | 1 000 000 |

$$\text{npV} := \frac{\text{"wahr negativ"}}{\text{"wahr negativ"} + \text{"falsch negativ"}} = 998201 / 998207 = 0.99994$$

$$\text{ppV} := \frac{\text{"wahr positiv"}}{\text{"wahr positiv"} + \text{"falsch positiv"}} = 794 / 1793 \approx 0.443$$

Also: Negative NIPT Diagnosen sind nahezu sicher korrekt, aber **nur 44% der positiven NIPT Diagnosen sind zutreffend.**

Zahlen aus Gießelmann, Kathrin: "Nichtinvasive Pränataltests: Risiko für Fehlinterpretationen." *Dtsch Arztebl* 2020; 117(7): A-320

# But wait, there's more.....

## Babylonische terminologische Zustände:

|                     |                              | True condition                                                                                                                                             |                                                                                                                                              |                                                                                                                               |                                                                                                                                                                                  |
|---------------------|------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Total population    |                              | Condition positive                                                                                                                                         | Condition negative                                                                                                                           | Prevalence = $\frac{\Sigma \text{Condition positive}}{\Sigma \text{Total population}}$                                        | Accuracy (ACC) = $\frac{\Sigma \text{True positive} + \Sigma \text{True negative}}{\Sigma \text{Total population}}$                                                              |
| Predicted condition | Predicted condition positive | <b>True positive</b>                                                                                                                                       | <b>False positive, Type I error</b>                                                                                                          | Positive predictive value (PPV), Precision = $\frac{\Sigma \text{True positive}}{\Sigma \text{Predicted condition positive}}$ | False discovery rate (FDR) = $\frac{\Sigma \text{False positive}}{\Sigma \text{Predicted condition positive}}$                                                                   |
|                     | Predicted condition negative | <b>False negative, Type II error</b>                                                                                                                       | <b>True negative</b>                                                                                                                         | False omission rate (FOR) = $\frac{\Sigma \text{False negative}}{\Sigma \text{Predicted condition negative}}$                 | Negative predictive value (NPV) = $\frac{\Sigma \text{True negative}}{\Sigma \text{Predicted condition negative}}$                                                               |
|                     |                              | True positive rate (TPR), Recall, Sensitivity, probability of detection, Power<br>$= \frac{\Sigma \text{True positive}}{\Sigma \text{Condition positive}}$ | False positive rate (FPR), Fall-out, probability of false alarm<br>$= \frac{\Sigma \text{False positive}}{\Sigma \text{Condition negative}}$ | Positive likelihood ratio (LR+) = $\frac{\text{TPR}}{\text{FPR}}$                                                             | Diagnostic odds ratio (DOR) = $\frac{\text{LR+}}{\text{LR-}}$<br><br>$F_1 \text{ score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$ |
|                     |                              | False negative rate (FNR), Miss rate = $\frac{\Sigma \text{False negative}}{\Sigma \text{Condition positive}}$                                             | Specificity (SPC), Selectivity, True negative rate (TNR) = $\frac{\Sigma \text{True negative}}{\Sigma \text{Condition negative}}$            | Negative likelihood ratio (LR-) = $\frac{\text{FNR}}{\text{TNR}}$                                                             |                                                                                                                                                                                  |

Quelle: Wikipedia