

Korrelation & Kausalität

Kausale & assoziative Strukturen

(Schein)Assoziation über Drittvariablen

(Schein)Assoziation durch Aggregation

(Schein)Assoziation durch Stichprobenauswahl

Korrelation & Kausalität


Kausale & assoziative Strukturen

(Schein)Assoziation über Drittvariablen

(Schein)Assoziation durch Aggregation

(Schein)Assoziation durch Stichprobenauswahl

Kausale & assoziative Strukturen




Kausale & assoziative Strukturen


$A \longrightarrow B$: "A ist *Ursache* von B"

$A \sim B$: "A und B sind *assoziiert*"


"Fork"




"Collider"



$\Longrightarrow$ führen alle zu



"Pipe"




Kausale & assoziative Strukturen


$A \longrightarrow B$: “A ist *Ursache* von B”

$A \sim B$: “A und B sind *assoziiert* (nicht unabhängig)”


Still a “Fork”




Still a “Collider”



führen alle zu



Still a “Pipe”



Kausale & assoziative Strukturen

- ▶ sehr unterschiedliche kausale Strukturen ergeben identische assoziative Struktur
- ▶ große Vorsicht bei (kausaler) Interpretation beobachteter Korrelationen / Assoziationen geboten
- ▶ “Kausalität” hier stochastisch/probabilistisch gemeint, (meistens) nicht deterministisch.

Korrelation & Kausalität

Kausale & assoziative Strukturen

(Schein)Assoziation über Drittvariablen

(Schein)Assoziation durch Aggregation

(Schein)Assoziation durch Stichprobenauswahl

Confounding

- ▶ Gemeinsame Ursache X für interessierende Variablen Y, Z
(Kausale Struktur: *Fork*)
- ▶ erzeugt oft marginale Abhängigkeiten zwischen nicht kausal verbundenen Y und Z :
“Scheinkorrelation”, *spurious correlation*
- ▶ kann auch evtl. vorhandene (bedingte) Assoziationen zwischen Y und Z gegeben X abschwächen oder sogar umkehren:
Simpson's “Paradox”

Confounding: Schein-Assoziationen

Drittvariablen erzeugen oft Assoziationen ohne kausale Entsprechung:

Beispiele:

Storchenpopulation

}

Geburtenrate

Ertrunkene/Monat

}

Eiscremeabsatz/Monat

Schuhgröße


}

Wortschatz

Confounding: Schein-Assoziationen


Drittvariablen erzeugen oft Assoziationen ohne kausale Entsprechung:

Beispiele:




Confounding: Noten & Nachhilfe

Zusammenhang Abschlußnote - Nachhilfestunden/Woche (fiktiv):




Confounding: Noten & Nachhilfe

Zusammenhang Abschlußnote - Nachhilfestunden/Woche (fiktiv):



Confounding: Noten & Nachhilfe

Zusammenhang Abschlußnote - Nachhilfestunden/Woche (fiktiv):



Korrelation & Kausalität

Kausale & assoziative Strukturen

(Schein)Assoziation über Drittvariablen

(Schein)Assoziation durch Aggregation

(Schein)Assoziation durch Stichprobenauswahl


Simpson's Paradox

- ▶ Kein echtes Paradox
- ▶ Beschreibt häufig auftretendes Phänomen:
Durch Bedingen auf Drittvariable(n) können Assoziationen
 - ▶ entstehen (s. Titanic),
 - ▶ verschwinden (s. Berkeley),
 - ▶ oder ihre Richtung ändern. (s. Nachhilfe)
(Autsch.)
- ▶ Synonyme: *omitted variable bias*

Simpson's Paradox: Titanic

Überleben von erwachsenen Titanicpassagieren 3. Klasse und Crew:

	Died	Saved	Rate
3rd	476	151	0.24
Crew	673	212	0.24




⇒ gleiche Überlebensraten für Passagiere 3. Klasse und Crew (?)

Simpson's Paradox: Titanic

Bedingt auf Geschlecht:

Males:				Females:			
	Died	Saved	Rate		Died	Saved	Rate
3rd	387	75	0.16	3rd	89	76	0.46
Crew	670	192	0.22	Crew	3	20	0.87




⇒ (deutlich) schlechtere Überlebensraten für Passagiere 3. Klasse, für beide Geschlechter.

Simpson's Paradox: Berkeley Admissions

Aufnahmequoten der Uni Berkeley im Jahr 1973:

	Admitted	Rejected	Admission Rate
Male	1198	1493	0.45
Female	557	1278	0.30




⇒ Benachteiligung von Bewerberinnen ...?

Odds Ratio: $\gamma(\text{Admitted, Rejected}|\text{Male, Female}) = 1.83!$

Simpson's Paradox: Berkeley Admissions

Bedingt auf Departments (A-F; absteigend nach Aufnahmequote):


Department A – Odds Ratio : 0.35




Department B – Odds Ratio : 0.8




Department C – Odds Ratio : 1.13




Department D – Odds Ratio : 0.92



Department E – Odds Ratio : 1.22



Department F – Odds Ratio : 0.83




Simpson's Paradox: Berkeley Admissions



Simpson's Paradox: Berkeley Admissions

Kausalität hier eher:



- ▶ hier kein “Confounding” mit *Fork*-Struktur im klassischen Sinn
- ▶ Stattdessen *Pipe*-Struktur: Durch Bedingen auf *Mediator* “Fach” wird Assoziation zwischen “Geschlecht” und “Aufnahme” komplexer, hier insgesamt schwächer.


Ökologischer Fehlschluss

Allgemeinere Art von “omitted variable bias”:

Unzulässige / falsche Schlüsse von aggregierten Daten auf Individualdaten.

Aus einem bestehenden Zusammenhang auf Aggregatebene folgt nicht zwangsläufig ein entsprechender Zusammenhang auf Individualebene.


Einkommen & Politische Einstellung



“Republikaner gewinnen in *ärmeren Bundesstaaten* $\Rightarrow$ höhere Zustimmung zu Republikanern bei *Menschen mit niedrigerem Einkommen*”
?

Einkommen & Politische Einstellung


Bush vote in 2004 by income




⇒ Aus “Republikaner gewinnen in ärmeren Bundesstaaten” folgt **nicht** “Höhere Zustimmung zu Republikanern bei Menschen mit niedrigerem Einkommen”!

Quelle: Gelman, A. et al. (2007) “Rich State, Poor State, Red State, Blue State: What’s the Matter with Connecticut?” *Quarterly Journal of Political Science* 2: 345-367.


Einkommensniveau & Kindersterblichkeit




Einkommensniveau & Kindersterblichkeit



Einkommensniveau & Kindersterblichkeit



Einkommensniveau & Kindersterblichkeit



Quelle: WHO/OECD, Stand 2010 (dslabs::gapminder)

Korrelation & Kausalität

Kausale & assoziative Strukturen


(Schein)Assoziation über Drittvariablen

(Schein)Assoziation durch Aggregation

(Schein)Assoziation durch Stichprobenauswahl


Conditioning on the Collider

- ▶ X ist “collider” wenn Y und Z beides Ursachen von X sind:




- ▶ Durch Bedingen auf X können *spurious correlations* zwischen Y und Z entstehen
- ▶ Durch Bedingen auf X können (marginale) Assoziationen zwischen Y und Z ihre Richtung ändern oder verschwinden

Conditioning on the Collider: Beispiel



“Schlampige Genies” und “Stumpfe Arbeitsbienen”...?


Conditioning on the Collider: Beispiel



Conditioning on the Collider: Beispiel



Conditioning on the Collider: Beispiel



Durch die Bedingung auf “Studiert” entsteht eine Scheinkorrelation zwischen Schläue und Fleiß:
nur diejenigen, die eher schlau oder eher fleißig oder sogar beides sind, können studieren,
dadurch entsteht eine negative Korrelation in der *beobachteten* Teilpopulation der Studierenden.

Anders gesagt: Durch den Auswahlprozess der Stichprobe sind “besonders schlau, nicht so fleißig” und “besonders fleißig, nicht so schlau” in der Stichprobe relativ häufiger als in der Gesamtpopulation. Dadurch entsteht eine negative Korrelation.

Conditioning on the Collider: *endogeneous selection bias*


Hier also Spezialfall *endogeneous selection bias*:

Ob eine Untersuchungseinheit in der beobachteten Stichprobe ist oder nicht hängt von einer Variable ab, die von den untersuchten Variablen kausal abhängt.

Auch bekannt als *selection-distortion effect*.


Conditioning on the Collider: *endogenous selection bias*

Gesamtbevölkerung




kein Zusammenhang!

Beobachtet falls $x + y > \text{const}$




beobachtet • ja • nein



⇒ negative Korrelation


Conditioning on the Collider: *endogenous selection bias*

Gesamtbevölkerung




kein Zusammenhang!

Beobachtet falls $|x - y| < \text{const}$



beobachtet • ja • nein



⇒ positive Korrelation

Colophon

Material teils basierend auf früheren Vorlesungen von Helmut Küchenhoff, Torsten Hothorn und Leonhard Held.

Berechnungen mit R, gerendert mit pandoc via `{rmarkdown}` und X_YTeX.
Beamer-Theme “Simple” adaptiert von Facundo Muñoz.

R-Pakete:

- ▶ Grafiken mit `{ggplot2}`, `{ggrepel}`, `{grid}`, `{gridExtra}`, `{rayshader}`, `{patchwork}`, `{viridisLite}`, `{colorspace}`
- ▶ Datensätze aus `{dslabs}`, `{socviz}` & `{datasaurus}`
- ▶ Daten-Wrangling mit `{dplyr}` & `{tidyr}`
- ▶ Interaktive Quizzes mit `{exams}`

Fonts: Fira Sans, Fira Math, XITS Math