

Einführung in die Wahrscheinlichkeitsrechnung und induktive Statistik
Online-Hausarbeit – Hauptprüfung am 26.07.2021

Name: _____

Matrikelnummer: _____

Studiengang (Hauptfach): _____

Angestrebter Abschluss: ☐ Bachelor (BA) ☐ Andere: _____

Prüfungsordnung: ☐ 2010 ☐ Andere: _____

Ich bestätige, dass ich die Vorgaben und Hinweise zur Prüfung auf der Angabe zur Kenntnis genommen und die Angabe auf Vollständigkeit überprüft habe.

Unterschrift: _____

Ergänzen Sie hier die bei den Hinweisen notierte Eigenständigkeitserklärung und Unterschreiben Sie diese im Anschluss:

Unterschrift:

Vorgaben und Hinweise zur Online-Hausarbeit:

1. Überprüfen Sie zunächst, ob Ihre Online-Hausarbeit vollständig ist. Es darf lediglich die eigene Aufgabenstellung bearbeitet werden, die Bearbeitung fremder Aufgaben wird nicht bewertet. Diese Online-Hausarbeit sollte aus 6 Seiten (zuzüglich Deckblatt und diesen beiden Hinweisblättern) mit 6 Aufgaben bestehen.
2. Die veranschlagte Bearbeitungszeit für diese Online-Hausarbeit beträgt 2 Stunden. Es können maximal 120 Punkte erreicht werden. Ein nachvollziehbarer Lösungsweg ist Voraussetzung zum Erlangen der vollen Punktzahl. Alle Ergebnisse sind soweit wie möglich zu vereinfachen. Brüche sind vollständig zu kürzen. Geben Sie die Ergebnisse auf drei Nachkommastellen gerundet an.
3. Wenn nicht anders in der Aufgabe angegeben, ist als α -Niveau 0.05 zu verwenden. R darf, falls nicht explizit ausgeschlossen, verwendet werden. Auch bei Nutzung von R ist auf eine Nachvollziehbarkeit der Lösung zu achten, da die entsprechenden R-Codes und die daraus resultierenden Ergebnisse auch bewertungsrelevant sind.
4. Die Lösungen zur Online-Hausarbeit müssen am 26. Juli 2021 bis spätestens 18:00 Uhr (CEST) im pdf-Format auf der Moodle Seite des Kurses hochgeladen sein. Für jede Aufgabe ist eine eigene pdf-Datei hochzuladen (Aufgabe: 'Abgabe der Online-Hausarbeit zur Hauptprüfung'). Eine Abgabe nach 18:00 Uhr am 26. Juli 2021 ist nicht möglich.
5. Die Dateinamen sollen dem folgenden Prinzip folgen:
AufgX_Nachname_Vorname_Matrikelnummer.pdf (z.B.: Aufg1_Muster_Maria_123456.pdf).
Beachten Sie dabei, dass Sie die korrekte Aufgabennummer verwenden und die Dokumente nicht größer als 50 Megabyte sein dürfen.
6. Es können nur pdf-Dateien abgegeben werden. Daher müssen die erstellten Lösungen als pdf-Datei gespeichert bzw. in eine pdf-Datei konvertiert werden. Dabei ist darauf zu achten, dass alle Schriftarten eingebettet sind, da ansonsten die pdf-Datei nicht auf allen PCs problemfrei geöffnet werden kann.
7. Für die Lesbarkeit Ihrer eingescannten/fotografierten Lösungen sind Sie selbst verantwortlich. Bei farbigen Scans/Fotos ist die Verwendung von roten Stiften nicht erlaubt.
8. Bei technischen Problemen beim Hochladen wenden Sie sich vor der Abgabefrist um 18:00 Uhr am 26. Juli 2021 an Dr. André Klima **und** Hannah Blocher M.Sc.. Schreiben Sie bitte eine E-Mail an beide Personen. Nutzen sie dafür ausschließlich Ihre Campus E-Mailadresse. Falls die technischen Probleme erst kurz vor der Abgabefrist auftreten, schicken Sie bitte Ihre Lösungen und Ihr Deckblatt als Anhang bei der Mail mit. Bei der Bewertung hat im Allgemeinen die auf Moodle gestellte Lösung Vorrang.
9. Fragen zur Prüfung sind ausschließlich per Mail an Dr. André Klima **und** Hannah Blocher M.Sc. zu richten. Schreiben Sie bitte eine E-Mail an beide Personen. E-Mails an andere Adressaten werden während der Prüfung nicht von diesen beantwortet und auch nicht an uns weitergeleitet. Nutzen sie dafür ausschließlich Ihre Campus E-Mailadresse. Bei Fragen, die bis um 12:00 Uhr am 26. Juli 2021 eingegangen sind, wird eine Antwort innerhalb einer Stunde nach Eingang der E-Mail garantiert.
10. Fragen zur Online-Hausarbeit werden ausschließlich öffentlich beantwortet. Die Fragen und Antworten sind im bereitgestellten Forum auf der Moodle Homepage des Kurses ('Fragen zur Hauptprüfung am 26.07.2021') zu finden. Wir übertragen – wenn sinnvoll – die Fragen und Antworten in das Moodle-Forum zur Online-Hausarbeit.

11. Für die Prüfung ist eine lauffähige Version von R notwendig. Alle in Vorlesung und Übung verwendeten Pakete und Funktionen müssen vorhanden und funktionsfähig sein.
12. Die Lösungen dürfen ausschließlich handschriftlich (auf Papier oder auf einem Tablett) erstellt werden. Nicht handschriftliche geschriebene Lösungen können nicht gewertet werden. Ausgenommen von dieser Regel sind R-Code und zugehörige R-Outputs. Diese dürfen in das handschriftliche Dokument an der entsprechenden Stelle in der zugehörigen Teilaufgabe in nicht-handschriftlicher Form eingefügt werden.
13. In jeder abgegebenen pdf-Datei muss auf der ersten Seite der vollständige Name und die Matrikelnummer vermerkt sein.
14. Die Online-Hausarbeit erfolgt ohne Begrenzung der (nicht-menschlichen) Hilfsmittel. Auch die Nutzung elektronischer Hilfsmittel (Online-Zeitschriften, Internetrecherche etc.) ist erlaubt. Werden Quellen außer den Vorlesungs-/Übungsunterlagen benutzt, sind diese zu dokumentieren; die Übernahme fremden geistigen Eigentums ist durch entsprechende Zitate zu belegen. Vorlesungsunterlagen sind im üblichen Rahmen zu zitieren.
15. Die Online-Hausarbeit ist selbständig zu bearbeiten. Es ist weder gestattet, während des Prüfungszeitraums um Hilfe von anderen Personen zu bitten noch Hilfe von anderen Personen anzunehmen (auch nicht digital in Online-Foren, Messenger Chats, usw.) oder anderen zu Prüfenden Hilfestellung zu leisten. Insbesondere ist es nicht erlaubt, die Aufgaben, Lösungen, Lösungsideen oder andere Hinweise zu dieser Online-Hausarbeit in jeglicher Form an andere Personen weiterzugeben oder in irgendeiner Form öffentlich, d.h. für andere Prüfungsteilnehmer zugänglich, zu machen. Zuwiderhandlungen führen zum Nichtbestehen der Prüfung und es erfolgt eine Meldung an das Prüfungsamt. Sie sind verpflichtet, durch Ihr Verhalten jegliche Missverständnisse diesbezüglich auszuschließen. Diese Beschränkungen umfassen den gesamten Prüfungszeitraum und enden nicht mit der Abgabe Ihrer Prüfung. Der Prüfungszeitraum endet am 26. Juli 2021, 18:00 Uhr (CEST).
16. Zusätzlich zu den Aufgaben ist ein Deckblatt abzugeben. Dafür kann das Deckblatt dieser Angabe genutzt werden oder die geforderten Angaben werden auf einen gesonderten Blatt handschriftlich getätigt. Beachten Sie bitte, dass – falls Sie mehr als eine Prüfung schreiben – Sie für jeden Prüfungsteil ein eigenes Deckblatt abzugeben haben. Das Namensschema der Datei(en) lautet: Prüfung_Name_Vorname_Matrikelnummer.pdf. Für die Art der Prüfung verwenden Sie bitte folgende Kürzel: Wahrscheinlichkeitstheorie (W), Induktive Statistik (I), eine Prüfung über beide Teile (B).
17. Auf dem Deckblatt ist die Selbstständigkeit der Bearbeitung dieser Online-Hausarbeit in Schriftform zusätzlich mit der eigenen Unterschrift durch folgenden Text zu erklären:

"Hiermit bestätige ich, dass ich alle eingereichten Lösungen zu dieser Online-Hausarbeit selbständig verfasst, keine anderen als die angegebenen Quellen und Hilfsmittel benutzt und Zitate und gedankliche Übernahmen kenntlich gemacht habe."

Viel Erfolg!

Aufgabe 1 (16 Punkte)

Sei X eine Zufallsvariable mit Dichte

$$f(x) = \begin{cases} c(x-1)(4-x), & \text{falls } 1 \leq x \leq 4 \\ 0, & \text{sonst} \end{cases}$$

mit Konstante $c > 0$.

- (a) (i) Geben Sie an, was für eine Funktion f gelten muss, sodass f eine Dichte ist? (2P)
- (ii) Bestimmen Sie die Konstante c so, dass $f(x)$ eine Dichte ist und prüfen Sie, ob $f(x)$ die Eigenschaften aus Teilaufgabe (a)(i) erfüllt. (4P)
- (iii) Geben Sie den Träger von $f(x)$ an. (2P)
- (b) Bestimmen Sie den Erwartungswert der Zufallsvariable X . (4P)
- (c) Seien $X_1, \dots, X_n$ für $n \in \mathbb{N}$ i.i.d. verteilt wie die Zufallsvariable X . Betrachtet wird jetzt $Y_n := \sum_{i=1}^n X_i$. Sei $\tilde{Y}_n$ die standardisierte Zufallsvariable von Y_n für $n \in \mathbb{N}$. Welche Aussage können Sie über die Konvergenz von $\tilde{Y}_n$ für $n \rightarrow \infty$ treffen und warum? (3P)
- (d) Bestimmen Sie $P(X = 2)$. (1P)

Aufgabe 2 (25 Punkte)

Im Rahmen eines Forschungsprojektes zu COVID-19 wurden Daten zur Bestimmung der wirklichen Ansteckungsrate in München erhoben. In München leben aktuell 1561505 Bürger/-innen.

- (a) Geben Sie den exakten Ergebnisraum für das Zufallsexperiment "Anzahl der Personen mit (vergangener) COVID-19 Infektion in München" an. Welche Mächtigkeit hat der Ergebnisraum? (2P)
- (b) Ist bei dem in (a) definierten Zufallsexperiment die Annahme, dass es sich um ein Laplace-Experiment handelt, gerechtfertigt? Begründen Sie Ihre Antwort. (2P)

Für die Beantwortung der Forschungsfrage wurden zufällig $N=5000$ der 1561505 Münchner Bürger/-innen auf Vorliegen einer (vergangenen) Infektion mit COVID-19 getestet. Aufgrund der Art der Erhebung ist ausgeschlossen, dass ein/e Bürger/-in zweimal in die Stichprobe gelangen konnte.

- (c) Beschreiben Sie die gerade beschriebene Ziehung der Stichprobe über das Urnenmodell. Achten Sie dabei auf die Vollständigkeit Ihrer Erläuterung. (4P)
- (d) Gehen Sie im Folgenden davon aus, dass die Verteilung der (vergangenen) COVID-19 Infektionen in der Erhebung einer Binomialverteilung folgt.
 - (i) Was bedeutet der Parameter π der Binomialverteilung dann inhaltlich in diesem Fall? (2P)
 - (ii) Geben Sie die Wahrscheinlichkeit an, dass bei einer Ansteckungsrate von 15% in der Münchner Bevölkerung der beobachtete Anteil in der Stichprobe um mehr als einen Prozentpunkt von diesem Wert abweicht. (5P)
- (e) Gehen Sie jetzt davon aus, dass bei vorliegender (vergangener) Infektion der verwendete Test diese in 95% richtig identifiziert und bei Personen ohne (vergangene) Infektion in 1% der Fälle fälschlicherweise diese als Person mit (vergangener) Infektion identifiziert.
 - (i) Veranschaulichen Sie die gerade beschriebene Situation anhand eines Wahrscheinlichkeitsbaumes für die Stichprobe. Nutzen Sie für den unbekannten Anteil der Personen mit (vergangener) Infektion in der Stichprobe die Bezeichnung ρ und berechnen Sie ggf. notwendige Zahlen in Abhängigkeit von ρ . (6P)
 - (ii) Wie groß müsste der Anteil der Münchner in der Stichprobe mit (vergangener) COVID-19 Infektion mindestens sein, so dass 66% aller Testergebnisse, die das Vorliegen einer (vergangenen) Infektion anzeigen, auch auf eine entsprechende Infektion zurückzuführen sind? (4P)

Aufgabe 3 (19 Punkte)

Vier Studierende beschließen, ihr Ersparnis für ein Jahr anzulegen. Dabei sei G_i , für $i \in \{A, B, C, D\}$, die Zufallsvariable, die den Gewinn der Investition des Studierenden i beschreibt.


Student A investiert 1000 Euro in eine Kryptowährung. Der erwartete Gewinn für diese Investition nach einem Jahr betrage $\mathbb{E}(G_A) = 100$ Euro bei einer Varianz von $\text{Var}(G_A) = (100 \text{ Euro})^2$. Studentin B steckt 1000 Euro in Aktien aus dem DAX. Für den Gewinn aus dieser Investition nach einem Jahr gelte $\mathbb{E}(G_B) = 80$ Euro bei einer Varianz von $\text{Var}(G_B) = (20 \text{ Euro})^2$. Studentin C legt ihre 1000 Euro auf einem Festgeldkonto an, sie erhält nach einem Jahr garantiert 50 Euro Zinsen (= Gewinn). Gehen Sie davon aus, dass G_A und G_B jeweils normalverteilt sind. Außerdem sei bekannt: $\text{Var}(G_A + G_B) = (110 \text{ Euro})^2$.

- (a) Berechnen Sie $\text{Cov}(G_A, G_B)$. (3P)
- (b) Berechnen Sie den Korrelationskoeffizienten $\rho(G_A, G_B)$ und interpretieren Sie diesen. (3P)
- (c) Wie groß ist die Wahrscheinlichkeit, dass Student A nach einem Jahr einen höheren Gewinn erzielt hat als Studentin C? (3P)
- (d) Studentin D möchte ihre 1550 Euro zu einem Teil $\alpha \in [0, 1]$ auf einem Festgeldkonto mit einer garantierten Verzinsung von 6% pro Jahr anlegen. Den Rest möchte sie in amerikanische Aktien mit einem erwarteten Gewinn von 10% bei einer Standardabweichung von 20% pro Jahr anlegen. Die Gewinne der beiden Investitionen können als unabhängig voneinander angenommen werden.
 - (i) Sei $\alpha = 0.5$. Berechnen Sie den erwarteten Gesamtgewinn in Prozent (der Investition) für die Investition der Studentin D nach einem Jahr. (3P)
 - (ii) Welchen Anteil sollte Studentin D höchstens auf das Festgeldkonto legen, wenn der zu erwartende Gesamtgewinn mindestens 9% betragen soll? (3P)
 - (iii) Welchen Anteil sollte Studentin D mindestens auf das Festgeldkonto legen, wenn die Standardabweichung des Gewinns nicht über 10% liegen soll? (4P)

Aufgabe 4 (20 Punkte)

Beantworten Sie die folgenden Fragen. Falls eine Begründung gefordert ist, gibt es ohne diese keine Punkte.

- (a) Seien $X_1, \dots, X_n$; $n \in \mathbb{N}$; unabhängig und identisch verteilte Zufallsvariablen mit zugehöriger Dichte $f_a(x)$ und unbekanntem Parameter $a > 0$. Sei $l(a) = \log(\prod_{i=1}^n f_a(x_i))$ die zugehörige Log-Likelihood Funktion. Nehmen Sie an, dass die erste Ableitung der Log-Likelihood linear ist. Betrachten Sie die folgende Graphik und bestimmen Sie visuell den Maximum-Likelihood-Schätzer für a gegeben einer fixen Realisation $x_1, \dots, x_n$ von $X_1, \dots, X_n$. Beschreiben Sie Ihr Vorgehen und erklären Sie Ihre Wahl. (5P)



- (b) Betrachten Sie einen asymptotisch erwartungstreuen, aber nicht erwartungstreuen Schätzer. Gibt es eine Möglichkeit über die i.i.d. Stichprobe den (erwarteten) Bias dieses Schätzer zu verringern? Begründen Sie Ihre Antwort. (3P)
- (c) Geben Sie an, wie man Vorwissen über den interessierenden Parameter mit der Likelihood der Daten verknüpfen kann. Beschreiben und Benennen Sie dieses Verfahren. (3P)
- (d) Geben Sie an, was die Gütefunktion und was die Trennschärfe eines Tests sind. Wie hängen diese beiden Begriffe zusammen? (3P)
- (e) Gibt es einen Zusammenhang zwischen dem Signifikanz-Niveau und dem Fehler 1. Art eines Testes? Begründen Sie Ihre Antwort. (2P)
- (f) Besteht unter H_0 bei einem Parametertest ein direkter Zusammenhang zwischen dem $1 - \alpha$ Konfidenzintervall und dem Annahmebereich des Testes? Begründen Sie Ihre Antwort. (2P)
- (g) Bei einer normalverteilten Zufallsvariable ist die Breite des zweiseitigen $1 - \alpha$ Konfidenzintervalls für festes $\alpha \in [0, 1]$ bei bekannter Varianz und bekanntem Stichprobenumfang eine Konstante. Ist diese Aussage immer wahr? Begründen Sie Ihre Antwort. (2P)

Aufgabe 5 (22 Punkte)

Ein Student möchte der Vermutung nachgehen, dass man beim Radfahren tagsüber schneller auf Gefahren reagiert als nachts. Dazu misst er die Reaktionszeit (in Sekunden) von fünf weiteren Studierenden ($i \in \{1, \dots, 5\}$) auf eine Ampel, die von grün auf rot umspringt, und zwar nachts (die Zufallsvariable zur Reaktionszeit nachts sei X) und tagsüber (die Zufallsvariable zur Reaktionszeit tagsüber sei Y):

Studierende	1	2	3	4	5
X_i	1.9	2.8	2.1	2.7	2.3
Y_i	2.0	2.5	1.5	2.2	1.8

- (a) Lässt sich die Vermutung anhand der vorliegenden Daten zu einem Signifikanzniveau von $\alpha = 0.05$ bestätigen? Benutzen Sie dazu einen verteilungsfreien Test und geben Sie die dazugehörigen Hypothesen an. Berechnen Sie die Teststatistik analytisch (ohne R, Sie dürfen jedoch für die Berechnung der Varianz, der Standardabweichung, des Mittelwertes und der Quantile R verwenden) und treffen Sie anhand dieser die Testentscheidung. (6P)
- (b) Der Student möchte im Folgenden einen parametrischen Test verwenden.
- (i) Geben Sie einen geeigneten parametrischen Test und die zugehörigen Hypothesen an, den der Student verwenden kann. Gehen Sie dabei auch auf die benötigten Annahmen ein. (4P)
 - (ii) Gehen Sie im Folgenden davon aus, dass die Annahmen aus Teilaufgabe (b)(i) erfüllt sind. Führen Sie den Test aus Teilaufgabe (b)(i) analytisch (ohne R, Sie dürfen jedoch für die Berechnung der Varianz, der Standardabweichung, des Mittelwertes und der Quantile R verwenden) durch. Berechnen Sie dafür die Teststatistik und treffen Sie anhand dieser die Testentscheidung. (4P)
- (c) Eine weitere Studentin untersucht, ob der Konsum eines Energy Drinks die nächtliche Reaktionszeit beeinflusst. Dazu misst sie die nächtliche Reaktionszeit nach dem Konsum von drei Dosen des Energy Drinks (die zugehörige Zufallsvariable sei Z) bei fünf weiteren zufällig und unabhängig von (a) ausgewählten Studierenden ($(i \in \{6, \dots, 10\})$).

Studierende	6	7	8	9	10
Z_i	2.3	2.7	2.4	2.2	2.4

Aus zeitlichen Gründen verwendet die Studentin die Daten ihres Kommilitonen aus (a) als Vergleichsgrundlage. Sie nimmt an, dass X und Z jeweils normalverteilt sind. Welcher Test eignet sich unter diesen Bedingungen zur Überprüfung der Hypothese, dass das Getränk die mittlere nächtliche Reaktionszeit verändert? Führen Sie diesen Test durch ($\alpha = 0.05$). Geben Sie die Hypothesen an und berechnen Sie die Teststatistik analytisch (ohne R, Sie dürfen jedoch für die Berechnung der Varianz, der Standardabweichung, des Mittelwertes und der Quantile R verwenden). Treffen Sie anhand dieser die Testentscheidung. (8P)

Aufgabe 6 (18 Punkte)

Im Rahmen einer Studie zu den wirtschaftlichen Auswirkungen des Klimawandels auf den Weinanbau in Deutschland soll der Weinmostertrag (in hl/ha) in den 13 deutschen Weinanbaugebieten miteinander verglichen werden. Anhand der jetzt bereits vorhandenen Unterschiede zwischen den Regionen erhofft man sich, Informationen für die Zukunft gewinnen zu können. Für das Jahr 2020 liegen die folgenden Zahlen für die Regionen vor. Sie können für die folgenden Aufgaben davon ausgehen, dass der Rot- und Weißmostertrag zwischen den Regionen jeweils normalverteilt ist.

	Württemberg	Baden	Franken	Hessische Bergstrasse	Rheingau	Ahr
Rotmost	71.4	64	40.5	74.6	59.2	56.1
Weißmost	58.3	74.9	44.2	76.1	75.4	63.5

	Mittelrhein	Mosel	Nahe	Rheinhessen	Pfalz	Saale-Unstrut	Sachsen
Rotmost	52.2	89.1	82.3	99.7	103.9	36.4	38.5
Weißmost	59.1	98.9	75.5	97.2	97.6	38.5	43.3

(Quelle: Destatis, Datensatz: 41253-0002)

- (a) Es soll überprüft werden, ob sich der mittlere Rot- und Weißmostertrag in den Regionen signifikant ($\alpha = 0.05$) voneinander unterscheidet.
 - (i) Welchen Test würden Sie hierfür verwenden? Begründen Sie ihre Entscheidung. Stellen Sie die zu testenden Hypothesen auf. (4P)
 - (ii) Führen Sie den Test in R durch. Zu welchem Ergebnis kommen Sie? (4P)
- (b) Geben Sie für den mittleren Unterschied zwischen Rot- und Weißmostertrag in den Regionen ein 90%-Konfidenzintervall an. (2P)
- (c) Im zweiten Schritt soll jetzt überprüft werden, ob eine Abhängigkeit zwischen Rot- und Weißmostertrag in den Regionen besteht.
 - (i) Welchen Test würden Sie hierfür verwenden? Begründen Sie ihre Entscheidung. Welche zusätzliche Annahme über die Verteilung der Daten ist hier notwendig? Stellen Sie die zu testenden Hypothesen auf. (4P)
 - (ii) Führen Sie den Test in R durch. Gehen Sie davon aus, dass die zusätzliche Annahme aus (c)(i) gegeben ist. (4P)