


Aufgabe 1 (16 Punkte)

Betrachten Sie die untenstehende Grafik. Sie zeigt den durchschnittlichen Ertrag (*“crop yield”*) für landwirtschaftliche Nutzflächen in Tonnen pro Hektar auf den Kontinenten der Erde im Jahr 2018.



Analysieren Sie die grafischen Mittel, die zur Visualisierung benutzt wurden:

(a) Geben Sie für alle in der Grafik gezeigten Merkmale jeweils

[5]

- das Skalenniveau
- die verwendeten Zuordnungen auf ästhetische Eigenschaften der gezeichneten Sechsecke an.

Lösung:

(x-y-Position: arbiträr bzw UE)

Kontinent:[0.5P.] Nominalskalenniveau [1P.] , Ästhetik: Farbe der Hexagons[1P.]

Ertrag:[0.5P.] Verhältnisskala [1P.] Ästhetik: Kantenlänge der Hexagons (?) [1P.]

(b) Inwiefern verletzt die hier verwendete Farbpalette die in der Vorlesung besprochenen Kriterien für Farbskalen in statistischen Grafiken? Was für eine Art von Farbskala sollte stattdessen verwendet werden?

[2]

Lösung:

problem: kaum unterscheidbare Blautöne und ein hervorstechender Rotton (weder divergierend noch sequentiell noch qualitativ). [1P.] besser: nominales Merkmal, also wähle wahrnehmungseinheitliche, gut unterscheidbare, qualitative [1P.] Farbskala.

- (c) Statistische Grafiken sollen die Datenlage möglichst unverfälscht darstellen. [2]
Inwiefern verfälscht die obige Darstellung die tatsächliche Datenlage?

Lösung:

Ertrag offensichtlich über Kantenlänge codiert (s. Afrika vs. Amerika)[1P.] , visueller Eindruck entsteht aber über (teils überlappende!!) Fläche. [1P.] verfälschter visueller Eindruck

- (d) Statistische Grafiken sollen die Datenlage möglichst kompakt darstellen, also: minimal viel [2]
verwendete Tinte für maximal viel vermittelte Information.
Inwiefern verfehlt die obige Darstellung dieses Ziel?

Lösung:

Darstellung der Verteilung eines Merkmals über Größe/Umfang von 5 eingefärbten Polygonen ist wasteful / ungeeignet. [1P.] (Darstellung über Größe der Polygone + Beschriftung würde reichen [1P.])

- (e) Statistische Grafiken sollen die Datenlage möglichst übersichtlich darstellen um den Kon- [2]
sument:innen der Grafik schnelles und präzises Ablesen relevanter quantitativer Informationen

zu ermöglichen. Inwiefern verfehlt die obige Darstellung dieses Ziel?

Lösung:

Wert des visualisierten Merkmals "Ertrag" schwierig bis unmöglich zwischen Kontinenten zu vergleichen [1P.] durch arbiträre Anordnung der Polygone, teilweise Überlappung, fehlende Reihung. [1P.]

- (f) Definieren Sie eine alternative grafische Darstellung für die in der obenstehenden Grafik [3] gezeigten Daten, welche diese unverfälscht, kompakt und übersichtlich visualisiert. Verwenden Sie für die Beschreibung die in der Vorlesung eingeführten Begrifflichkeiten der *grammar of graphics* oder die entsprechende {ggplot2}-Syntax.

Lösung:

Geometrie: Balken oder Punkt [1P.]

Mappings: Ertrag: x oder y Position (gemeinsame Achse!) [1P.] , Kontinent: position der zweiten Achse [1P.]

zb `geom_point(aes(x = continent, y = yield))`

Aufgabe 2 (16 Punkte)Seien X und Y Zufallsvariablen mit gemeinsamer Wahrscheinlichkeitsfunktion

$f_{X,Y}(x,y)$ X	Y		
	-1	0	2
0	0.3	0.2	0
1	0.1	0.15	0.05
2	0	0.05	0.15

- (a) Bestimmen Sie die Randverteilungen von
- X
- und
- Y
- .

[3]

Lösung:

$$f_X(0) = 0.5[0.5P.], f_X(1) = 0.3[0.5P.], f_X(2) = 0.2[0.5P.]$$
$$f_Y(-1) = 0.4[0.5P.], f_Y(0) = 0.4[0.5P.], f_Y(2) = 0.2[0.5P.];$$

- (b) Bestimmen Sie
- $E(X)$
- und
- $Var(X)$
- .

[3]

Lösung:

$$E(X) = \sum_{x=0}^2 x \cdot f_X(x) = 0 \cdot 0.5 + 1 \cdot 0.3 + 2 \cdot 0.2 = 0.7[1P.]$$
$$E(X^2) = \sum_{x=0}^2 x^2 \cdot f_X(x) = 0^2 \cdot 0.5 + 1^2 \cdot 0.3 + 2^2 \cdot 0.2 = 1.1[1P.]$$
$$Var(X) = E(X^2) - [E(X)]^2 = 1.1 - 0.7^2 = 0.61 [1P.]$$

- (c) Bestimmen Sie die Kovarianz und Korrelation zwischen
- X
- und
- Y
- und interpretieren Sie diese.

[7]

Lösung:

$$E(X \cdot Y) = \sum_x \sum_y x \cdot y \cdot f_{X,Y}(x, y) = 0 \cdot (-1) \cdot 0.3 + \dots + 2 \cdot 2 \cdot 0.15 = 0.6 \quad [1P.]$$

$$E(Y) = \sum_y y \cdot f_Y(y) = (-1) \cdot 0.4 + 0 \cdot 0.4 + 2 \cdot 0.2 = 0 \quad [1P.]$$

$$Cov(X, Y) = E(X \cdot Y) - E(X) \cdot E(Y) = 0.6 - 0.7 \cdot 0 = 0.6 \quad [1P.]$$

$$E(Y^2) = \sum_{y=-1}^2 y^2 \cdot f_Y(y) = (-1)^2 \cdot 0.4 + 0^2 \cdot 0.4 + 2^2 \cdot 0.2 = 1.2 \quad [1P.]$$

$$Var(Y) = E(Y^2) - [E(Y)]^2 = 1.2 - 0^2 = 1.2 \quad [1P.]$$

$$\rho(X, Y) = \frac{Cov(X, Y)}{\sqrt{Var(X)} \cdot \sqrt{Var(Y)}} = \frac{0.6}{\sqrt{0.61} \cdot \sqrt{1.2}} = 0.701 \quad [1P.]$$

Tendenziell nehmen die Werte von Y zu, wenn die X -Werte zunehmen und umgekehrt. [1P.]

(d) Bestimmen Sie die bedingte Verteilung von $Y|X = 0$.

[3]

Lösung:

$$f_{Y|X}(y|x) = \frac{f_{Y,X}(y,x)}{f_X(x)} \quad f_{Y|X=0}(-1|x=0) = \frac{3}{5} \quad [1P.]$$

$$f_{Y|X=0}(0|x=0) = \frac{2}{5} \quad [1P.]$$

$$f_{Y|X=0}(2|x=0) = 0 \quad [1P.]$$

Aufgabe 3 (17 Punkte)

Sei X betaverteilt mit $X \sim \text{Beta}(a, b)$ und Y gegeben X geometrisch verteilt mit $Y|X = x \sim \text{Geom}(x)$.

(a) Berechnen Sie $E(Y)$.

[8]

Hinweis: $\frac{\Gamma(c+1)}{\Gamma(c)} = c$.

Lösung:

Mit dem Satz vom iterierten Erwartungswert [1P.] gilt:

$$E(Y) = E_X(E_Y(Y|X)) = E_X\left(\frac{1}{X}\right) \text{ [2P.]}$$

$$\begin{aligned} E_X\left(\frac{1}{X}\right) &= \int_0^1 \frac{1}{x} \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1} (1-x)^{b-1} dx \text{ [1P.]} \\ &= \int_0^1 \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} x^{a-1-1} (1-x)^{b-1} dx \text{ [1P.]} \\ &= \frac{\Gamma(a-1)\Gamma(a+b)}{\Gamma(a)\Gamma(a-1+b)} \int_0^1 \frac{\Gamma(a-1+b)}{\Gamma(a-1)\Gamma(b)} x^{a-1-1} (1-x)^{b-1} dx \text{ [2P.]} \\ &= \frac{a+b-1}{a-1} \text{ [1P.]} \end{aligned}$$

(b) Berechnen Sie die Dichte von $X|Y$.

[8]

Lösung:

$$\begin{aligned} f_{X|Y}(x|y) &= \frac{f_{Y|X}(y|x)f_X(x)}{f_Y(y)} \text{ [1P.]} \\ &\propto f_{Y|X}(y|x)f_X(x) \text{ [1P.] [0.5P.]} \\ &= \frac{1}{c} x x^{a-1} (1-x)^{y-1} (1-x)^{b-1} \text{ [1P.]} \\ &= \frac{1}{c} \underbrace{x^a (1-x)^{b+y-2}}_{\text{Kern einer Beta Verteilung}} \text{ [1P.]} \end{aligned}$$

$$\Rightarrow X|Y = y \sim \text{Beta}(a+1, b+y-1) \text{ [1P.] [0.5P.] .}$$

(c) Berechnen Sie $E(X|Y)$.

[1]

Lösung:

Mit Teil b) folgt direkt

$$E(X|Y = y) = \frac{a+1}{a+b+y}$$

Aufgabe 4 (13 Punkte)

Ein fairer Würfel werde 6000-mal unabhängig geworfen.

Hinweis: $\Phi(3.46) \approx 0.9997$

(a) Bestimmen Sie mit Hilfe des zentralen Grenzwertsatzes eine Approximation für die Wahrscheinlichkeit, dass zwischen 900-mal und 1100-mal eine Sechs geworfen wird.

[8]

Lösung:

Zentraler Grenzwertsatz:

$$\frac{\sum_{i=1}^n X_i - nE(X_i)}{\sqrt{n} \cdot \sqrt{Var(X_i)}} \stackrel{a}{\sim} \mathcal{N}(0, 1)$$

$$X_i \sim \mathcal{B}(\pi = \frac{1}{6})$$

$$[0.5P.] E(X_i) = \pi = 1/6$$

$$[0.5P.] Var(X_i) = \pi \cdot (1 - \pi) = \frac{1}{6} \cdot \frac{5}{6} = \frac{5}{36}$$

$$[0.5P.] n = 6000$$

$$\frac{\sum_{i=1}^{6000} X_i - 1000}{\sqrt{6000} \cdot \sqrt{5/36}} \stackrel{a}{\sim} \mathcal{N}(0, 1)$$

$$[0.5P.] [1P.] \text{ Gesucht: } P\left(900 < \sum_{i=1}^{6000} X_i < 1100\right)$$

$$P\left(900 < \sum_{i=1}^{6000} X_i < 1100\right) = [1P.]$$

$$P\left(\sum_{i=1}^{6000} X_i < 1100\right) - P\left(\sum_{i=1}^{6000} X_i \leq 900\right) = [1P.]$$

$$P\left(\underbrace{\frac{\sum_{i=1}^{6000} X_i - 1000}{\sqrt{6000} \cdot \sqrt{5/36}}}_{\stackrel{a}{\sim} \mathcal{N}(0,1)} < \underbrace{\frac{1100 - 1000}{\sqrt{6000} \cdot \sqrt{5/36}}}_{\approx 3.46}\right) -$$

$$P\left(\underbrace{\frac{\sum_{i=1}^{6000} X_i - 1000}{\sqrt{6000} \cdot \sqrt{5/36}}}_{\stackrel{a}{\sim} \mathcal{N}(0,1)} \leq \underbrace{\frac{900 - 1000}{\sqrt{6000} \cdot \sqrt{5/36}}}_{\approx -3.46}\right) = [1P.]$$

$$\Phi(3.46) - \Phi(-3.46) = \Phi(3.46) - (1 - \Phi(3.46)) = [1P.]$$

$$2 \cdot \Phi(3.46) - 1 = 2 \cdot 0.9997 - 1 = 0.9994 [1P.]$$

- (b) Bestimmen Sie mit der Tschebyscheff-Ungleichung eine untere Schranke für die Wahrscheinlichkeit, dass zwischen 900-mal und 1100-mal eine Sechs geworfen wird. [5]

Lösung:

Tschebyscheff-Ungleichung:

 $Y = \sum_{i=1}^{6000} X_i \sim \mathcal{B}(n = 6000, \pi = \frac{1}{6})$ mit**[1P.]** $E(Y) = n \cdot \pi = 1000$,**[0.5P.]** $Var(Y) = n \cdot \pi \cdot (1 - \pi) = \frac{2500}{3}$.**[0.5P.]**

$$P(|Y - E(Y)| \geq c) \leq \frac{Var(Y)}{c^2} \Leftrightarrow$$

[0.5P.] $1 - P(|Y - E(Y)| < c) \leq \frac{Var(Y)}{c^2} \Leftrightarrow$

[0.5P.] $P(|Y - E(Y)| < c) \geq 1 - \frac{Var(Y)}{c^2} \Leftrightarrow$

[0.5P.] $P(|Y - 1000| < 100) = P(900 < Y < 1100) \geq 1 - \frac{\frac{2500}{3}}{100^2} = 0.9167$ **[0.5P.]** **[1P.]**

Aufgabe 5 (13 Punkte)

Prof. Dr. med. Kwarantina Bauterlach-Vligenört hat einen neuen diagnostischen Test für das Vorliegen einer akuten Infektion mit der schrecklichen Fnufnu-Krankheit entwickelt. Ihre klinische Erprobung des Tests an einer Stichprobe von Patient:innen, die entweder noch nie mit dem Fnufnu-Erreger infiziert waren (“Naiv”) oder eine solche Infektion bereits hinter sich haben (“Genesen”) oder zum Zeitpunkt der Studie an einer akuten Fnufnu-Infektion leiden (“Kranke”) ergibt folgende Ergebnisse:

Status	Naiv	Genesen	Krank	
Test positiv	1	3	35	39
Test negativ	20	25	3	48
	21	28	38	

Unter den Patient:innen, die Bauterlach-Vligenört im Klinikalltag versorgt, sind 30% Genesene, 65% Naive und 5% Fnufnu-Kranke.

Gehen Sie im Folgenden davon aus, dass die in der klinischen Erprobung ermittelten Eigenschaften des Tests (FPR, TNR, etc.) auch im Klinikalltag gelten.

- (a) Berechnen Sie auf Basis der Ergebnisse der klinischen Erprobung die Sensitivität und Spezifität des Tests zur Entdeckung einer akuten Infektion. [2]

Lösung:

Status $\in$ N, G, K; Test $\in$ P, N

TPR/Sensi. $P(P|K) = 35/38 = 0.921$ [1P.] und TNR/Spezi $P(N|\bar{K}) = (20 + 25)/(21 + 28) = 0.918$ [1P.] .

- (b) Berechnen Sie für die oben angegebene Prävalenz der Krankheit die Wahrscheinlichkeit, mit der ein Test im Klinikalltag ein positives Ergebnis zeigt. [3]

Lösung:

totale w.keit: $P(P) = \sum_{B \in (N, K, G)} P(P|B)P(B)$ [1P.]

$P(P|K) = 35/38, P(P|N) = 1/21, P(P|G) = 3/28$

$P(P) = 1/21 * 0.65 + 35/38 * 0.05 + 3/28 * 0.3 = 0.109$ [2P.]

- (c) Berechnen Sie die Wahrscheinlichkeit, mit der ein negatives Testergebnis im Klinikalltag eine tatsächlich nicht akut erkrankte Person anzeigt. [3]


Lösung:

Bayes: $P(G \cup N | nP) = \frac{P(nP|G \cup N)P(G \cup N)}{P(nP)}$ [1P.]

$P(nP|G \cup N)P(G \cup N) = (20 + 25)/(21 + 28) * (0.3 + 0.65) = .872$ [1P.]

$P(G \cup N | nP) = .872/(1 - P(P)) = .872/(1 - 0.109) = 0.979$ [1P.]

- (d) Die Grafik unten zeigt die ROC-Kurve eines alternativen, deutlich teureren diagnostischen Tests. Die ROC-Kurve ist an ausgewählten Punkten mit den entsprechenden Schwellenwerten des zu Grunde liegenden diagnostischen Scores beschriftet. [5]



- (i) Funktioniert der in den vorherigen Teilaufgaben analysierte Test von Bauterlach-Vlügenört etwa gleich gut, besser, oder schlechter als der hier dargestellte Test?
- (ii) Gehen Sie davon aus, dass eine Erkrankung mit der Fnufnu-Krankheit für Schwangere und ihre ungeborenen Kinder absolut lebensbedrohend ist, falls diese nicht sehr früh entdeckt und therapiert wird. Wie sollte der Schwellenwert des in der Grafik gezeigten diagnostischen Tests also gewählt werden, wenn dieser auf eine schwangere Patientin angewendet wird?

Begründen Sie Ihre Antworten kurz.

Lösung:

- i) Deutlich schlechter. Das hier gezeigte System erreicht für FPR 8% (also: FPR des Tests von B-V) eine TPR von deutlich über 95%, B-V nur 92. [2P.]
- ii) In dem hier beschriebenen Szenario ist die Entdeckung und Beseitigung möglichst aller Erkrankungen wichtiger als die Vermeidung von Fehlalarmen, also gilt es die Sensitivität/TPR zu maximieren. [1P.] Ein Schwellenwert > 55 [1P.] erscheint also angemessen, wobei aber eine Erhöhung auf mehr als ca. 65 keine deutliche Verbesserung der TPR mehr bietet, aber deutlich mehr Fehldiagnosen produziert..[1P.] (alles ab 40 bis 70 mit entsprechender begründung akzeptieren)

Aufgabe 6 (13 Punkte)

Sei $\Omega = \{1, 2, 3, 4, 5, 6\}$. Seien $U = \{1, 3, 5\}$, $V = \{1, 2, 3\}$, $\mu(A) := \sum_{\omega \in A} I_U(\omega)$ sowie $f : \Omega \rightarrow \mathbb{R}$ mit

$$f(\omega) = \omega^2.$$

(a) Geben Sie $\mathcal{F} = \sigma(\{U, V\})$ an.

[4]

Lösung:

$$\mathcal{F}_1 = \{\emptyset, \Omega, U, V, \bar{U}, \bar{V}, \{1, 3\}, \{2, 4, 5, 6\}, [1P.] \{4, 6\}, \{1, 2, 3, 5\}, [1P.] \{5\}, \{1, 2, 3, 4, 6\}, [1P.] \{2\}, \{1, 3, 4, 5, 6\}\}. [1P.]$$

(b) Zeigen Sie dass μ ein Maß zum Meßraum $(\Omega, \mathcal{F}_1)$ ist.

[4]

Lösung:

- i) $\mu(\emptyset) = 0$ [1P.]
- ii) $\mu(A) \geq 0$ [1P.]
- iii)

$$\mu\left(\bigcup A_i\right) = \sum_{\omega \in \bigcup A_i} I_U(\omega) [1P.] \quad (1)$$

$$= \sum_i \mu(A_i) \text{ da } A_i \text{ disjunkt } [1P.] \quad (2)$$

(c) Berechnen Sie $\int_V f d\mu$.

[5]

Lösung:

$$\int_V f d\mu = \int_{\{1,2,3\}} \omega^2 d\mu [1P.] \quad (3)$$

$$= \int_{\{1\}} \omega^2 d\mu + \int_{\{2\}} \omega^2 d\mu + \int_{\{3\}} \omega^2 d\mu [1P.] \quad (4)$$

$$= \int_{\{1\}} 1 d\mu + \int_{\{2\}} 4 d\mu + \int_{\{3\}} 9 d\mu [1P.] \quad (5)$$

$$= \mu(\{1\}) + 4\mu(\{2\}) + 9\mu(\{3\}) [1P.] = 1 + 9 = 10 [1P.] \quad (6)$$

Aufgabe 7 (13 Punkte)

Gegeben sei die stetige Zufallsvariable X mit Dichte

$$f_X(x) = c \cdot x \cdot I_{[1,3]}(x).$$

(a) Berechnen Sie die Konstante c .

[4]

Lösung:

Finde c so, dass $\int f(x)dx = 1$ [1P.]

$$\int f(x)dx = \int c \cdot x \cdot I_{[1,3]}(x) \quad (7)$$

$$= c \int_1^3 x dx \quad [1P.] \quad (8)$$


$$= c \left[\frac{1}{2}x^2 \right]_1^3 \quad [1P.] = c \cdot \frac{1}{2}(9 - 1) = 4c \quad [0.5P.] \quad (9)$$

$$\Rightarrow c = \frac{1}{4} \quad [0.5P.]$$

(b) Skizzieren Sie die Dichte. [1]

(c) Welche der folgenden Aussagen ist richtig? Begründen Sie kurz (keine explizite Berechnung notwendig). [3]

- Der Median von X ist 2.
- Die Schiefe von X ist größer 0.
- Der Erwartungswert von X ist kleiner als der Modus von X .

Lösung:

[1P.]

- Falsch: Der Median ist größer als 2. [1P.]
- Falsch: linksschief, Schiefe < 0 [1P.]

- Richtig: Modus ist 3, Erwartungswert irgendwo zwischen 2 und 3. [1P.]

- (d) Berechnen Sie mit Hilfe des Dichtetransformationssatzes die Dichte der Zufallsvariablen $Y = \frac{1}{1+X}$. [5]

Lösung:

$$f(x) = y = \frac{1}{1+x} \in [0.25, 0.5] \text{ [1P.]}$$

$$y = \frac{1}{1+x} \iff 1+x = \frac{1}{y} \iff x = \frac{1}{y} - 1 = \frac{1-y}{y} =: g(y) \text{ [1P.]}$$

$$g'(y) = -\frac{1}{y^2} \text{ [1P.]}$$

$$f_Y(y) = 2 \cdot \frac{1-y}{y} \cdot I_{[1,3]} \left(\frac{1}{y} - 1 \right) \cdot \frac{1}{y^2} \text{ [0.5P.]}$$

$$= 2 \cdot \frac{1-y}{y^3} \cdot I_{[0.25, 0.5]}(y) \text{ [1P.]}$$

Aufgabe 8 (12 Punkte)

Seien $X \sim N(0, 1)$ und $Y \sim \text{Poi}(2)$ zwei stochastisch unabhängige Zufallsvariablen.

- (a) Bestimmen Sie Erwartungswert und Kovarianzmatrix des Zufallsvektors $U = (Y - X, Y)^T$. [6]

Lösung:

$$E(Y - X) = E(Y) - E(X) = 2 - 0 = 2 \text{ [1P.]}$$

$$\text{Damit } E(U) = (2, 2) \text{ [1P.]}$$

$$V(Y - X) = V(Y) + V(X) = 3 \text{ wegen Unabhängigkeit [1P.]}$$

$$\text{Wegen Unabhängigkeit [2P.]}$$

$$\text{Cov}(Y - X, Y) = \text{Cov}(Y, Y) + \text{Cov}(X, Y) = V(Y) = 2$$

$$\text{Damit [1P.]}$$

$$V(U) = \begin{pmatrix} 3 & 2 \\ 2 & 2 \end{pmatrix}$$

- (b) Handelt es sich bei den folgenden Matrizen um gültige Kovarianzmatrizen? Begründen Sie kurz! [6]

$$\Sigma_1 = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 3 \end{pmatrix}, \Sigma_2 = \begin{pmatrix} 1 & 1 & -1 \\ 1 & -1 & 1 \\ -1 & 1 & 1 \end{pmatrix}, \Sigma_3 = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$$

$$\Sigma_4 = \begin{pmatrix} 1 & 1 & 0 & 0 \\ 1 & 2 & 1 & 0 \\ 0 & 1 & 3 & 1 \end{pmatrix}, \Sigma_5 = \begin{pmatrix} 1 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 1 \end{pmatrix}, \Sigma_6 = \begin{pmatrix} 2 & 0.5 & -2 \\ 1.5 & 0.5 & 0 \\ -2 & 0 & 7 \end{pmatrix}$$

Lösung:

- Σ_1 : Kovarianzmatrix, nur Varianzen[1P.]
- Σ_2 : Varianz negativ, keine Kovarianzmatrix[1P.]
- Σ_3 : Determinante negativ, keine Kovarianzmatrix[1P.]
- Σ_4 : Nicht quadratisch, keine Kovarianzmatrix [1P.]
- Σ_5 : Kovarianzmatrix, Determinante gleich 0 ist in Ordnung[1P.]
- Σ_6 : Nicht symmetrisch, keine Kovarianzmatrix [1P.]

Aufgabe 9 (21 Punkte)

Beantworten Sie die folgenden Fragen, jeweils mit kurzer Begründung oder Rechnung mit nachvollziehbarem Ansatz.

- (a) A und B spielen folgendes Spiel: Es wird mit 4 Würfeln gewürfelt. Tritt mindestens einmal die Zahl 6 auf, dann gewinnt A, sonst B. Ist das Spiel fair in dem Sinne, dass im Mittel beide gleich oft gewinnen werden? [2]

Lösung:

$$P(\text{"B gewinnt"}) = \left(\frac{5}{6}\right)^4 = 0.4822531 \neq 0.5 \implies \text{[1P.] Das Spiel ist nicht fair. [1P.]}$$

- (b) In einer Population leiden fünf Prozent der Menschen an erhöhtem Blutdruck. Von diesen fünf Prozent trinken 75% regelmäßig Alkohol. Außerdem ist bekannt, dass 50% der Menschen, die *keinen* erhöhten Blutdruck haben, regelmäßig Alkohol trinken. Wieviel Prozent der regelmäßigen Alkoholkonsument:innen leiden an erhöhtem Blutdruck? [3]

Lösung:

Ereignis B : Person leidet an hohem Blutdruck.

Ereignis A : Person trinkt regelmäßig Alkohol.

$$P(B) = 0.05; \quad P(A|B) = 0.75; \quad P(A|\bar{B}) = 0.5 \quad \text{[1P.]}$$

$$P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A|B) \cdot P(B) + P(A|\bar{B}) \cdot P(\bar{B})} = \frac{0.75 \cdot 0.05}{0.75 \cdot 0.05 + 0.5 \cdot 0.95} = 0.073$$

[1P.] [1P.]

- (c) Sei X eine stetige Zufallsvariable mit Verteilungsfunktion F_X und einem 0.25-Quantil von 3. [2]
Welche der folgenden Aussagen trifft/treffen zu?
- (i) $F_X(3) = 0.25$
 - (ii) $F_X(0.25) = 3$
 - (iii) $F_X^{-1}(3) = 0.25$

Lösung:

Nur i [1P.] , Angabe ist $F_X^{-1}(0.25) = 3$. [1P.]

- (d) Sei Y eine diskrete Zufallsvariable mit Träger $T_Y = \mathbb{N}$ und Verteilungsfunktion F_Y mit $F_Y(33/10) = 0.5$ und $F_Y(2) \neq F_Y(3) \neq F_Y(4)$. Geben Sie für die folgenden Aussagen an ob sie aus diesen Angaben folgen: [3]
- (i) Der Median von Y ist 3.
 - (ii) $P(Y < 3) \leq 0.5$
 - (iii) Der Erwartungswert von Y ist 3.

Lösung:

i und ii folgen, denn aus $T_Y = \mathbb{N}$ und $F_Y(3.3) = 0.5$ folgt $F_Y(3) = P(Y \leq 3) = 0.5$ [1P.] , und aus $F_Y(2) \neq F_Y(3) \neq F_Y(4)$ folgt $F_Y(2) < 0.5$, $F_Y(4) > 0.5$. [1P.] , der Erwartungswert ist unbekannt denn dieser hängt von der gesamten Verteilung ab [1P.] .

- (e) Welche Verteilung hat die Zufallsvariable $Z = 3U - 12$ falls $U \sim \mathcal{N}(\mu = 4, \sigma^2 = 5)$? [2]

Lösung:

$$E(Y) = 3 \cdot E(X) - 12 = 3 \cdot 4 - 12 = 0 \text{ [0.5P.]}$$

$$Var(Y) = 3^2 \cdot Var(X) = 9 \cdot 5 = 45 \text{ [0.5P.]}$$


$$\Rightarrow Y \sim \mathcal{N}(0, 45) \text{ [1P.]}$$

- (f) Nehmen Sie an, ein Pfandautomat akzeptiert jede ihm zugeführte Flasche mit Wahrscheinlichkeit $p < 1$. Sei F die Anzahl der Flaschen, die man dem Automaten zuführen muss um einen Pfandbon für m akzeptierte Flaschen zu bekommen. Mit welcher aus der Vorlesung bekannten parametrischen Verteilung können Sie F beschreiben, was sind die Parameterwerte und welche zusätzlichen Annahmen über den daten-generierenden Prozess müssen Sie dafür treffen? [3]

Lösung:

Angenommen (dass p konstant ist und) dass die einzelnen Versuche jeweils unabhängig voneinander sind [1P.] ist die Anzahl an Versuchen bis zum m -ten Erfolg negativ binomialverteilt [1P.] mit Parametern $F \sim NB(m, p)$ [1P.]

- (g) Folgender Mosaikplot stellt den beobachteten Zusammenhang der Merkmale Geschlecht (m/w) und Klausurerfolg (bestanden/nicht bestanden) für eine Statistiklausur dar. [3]



- (i) Für welches Geschlecht ist die Durchfallrate höher?
- (ii) Gibt es insgesamt mehr Männer, die bestehen oder mehr Frauen, die bestehen?
- (iii) Das in den oben dargestellten Daten zusätzlich erhobene Merkmal “Studienfach” mit möglichen Ausprägungen “Nebenfach” und “Hauptfach” ist empirisch unabhängig von “Geschlecht” und von “Klausurerfolg”. Die Hälfte der Prüfungsteilnehmer:innen sind Nebenfachstudierende, die anderen Hauptfachstudierende. Skizzieren Sie einen Mosaikplot für die gemeinsame Verteilung dieser drei Merkmale. (Nur schematische Skizze gefragt,

keine exakte Zeichnung!)

Lösung:

- i: männer, unteres linkes rechteck höher als unteres rechtes rechteck [1P.]
- ii: mehr männer – flächeinhalt oben links klar größer als oben rechts [1P.]
- iii: jede kachel des mosaikplots (senkrecht) in je 2 gleich große hälften für HF/NF teilen [1P.]

- (h) Es liegt eine große Anzahl n von unabhängig Poisson-verteilten Zufallsvariablen mit gleicher Rate λ vor. Wie ist die Summe dieser Zufallsvariablen exakt verteilt und welcher Verteilung folgt diese Summe approximativ? [3]

Lösung:

Die Summe von n Poisson-verteilten Zufallsvariablen mit Rate λ ist wieder Poisson-verteilt mit Rate $n\lambda$ (vgl. Skript zu Faltungen). [1P.] EW und Varianz dieser Verteilung sind beide $n\lambda$ [1P.] , über den Zentralen Grenzwertsatz lässt sich die Verteilung also durch eine Normalverteilung $\mathcal{N}(n\lambda, n\lambda)$ [1P.] approximieren.