


Aufgabe 1 (16 Punkte)

Betrachten Sie die untenstehende Grafik. Sie zeigt den durchschnittlichen Ertrag (*“crop yield”*) für landwirtschaftliche Nutzflächen in Tonnen pro Hektar auf den Kontinenten der Erde im Jahr 2018.



Analysieren Sie die grafischen Mittel, die zur Visualisierung benutzt wurden:

- (a) Geben Sie für alle in der Grafik gezeigten Merkmale jeweils [5]
- das Skalenniveau
 - die verwendeten Zuordnungen auf ästhetische Eigenschaften der gezeichneten Sechsecke an.
- (b) Inwiefern verletzt die hier verwendete Farbpalette die in der Vorlesung besprochenen Kriterien für Farbskalen in statistischen Grafiken? Was für eine Art von Farbskala sollte stattdessen verwendet werden? [2]

- (c) Statistische Grafiken sollen die Datenlage möglichst unverfälscht darstellen. [2]
Inwiefern verfälscht die obige Darstellung die tatsächliche Datenlage?
- (d) Statistische Grafiken sollen die Datenlage möglichst kompakt darstellen, also: minimal viel [2]
verwendete Tinte für maximal viel vermittelte Information.
Inwiefern verfehlt die obige Darstellung dieses Ziel?
- (e) Statistische Grafiken sollen die Datenlage möglichst übersichtlich darstellen um den Kon- [2]
sument:innen der Grafik schnelles und präzises Ablesen relevanter quantitativer Informationen
zu ermöglichen. Inwiefern verfehlt die obige Darstellung dieses Ziel?

- (f) Definieren Sie eine alternative grafische Darstellung für die in der obenstehenden Grafik [3]
gezeigten Daten, welche diese unverfälscht, kompakt und übersichtlich visualisiert. Verwenden
Sie für die Beschreibung die in der Vorlesung eingeführten Begrifflichkeiten der *grammar of
graphics* oder die entsprechende `{ggplot2}`-Syntax.

Aufgabe 2 (16 Punkte)

Seien X und Y Zufallsvariablen mit gemeinsamer Wahrscheinlichkeitsfunktion

$f_{X,Y}(x,y)$ X	Y		
	-1	0	2
0	0.3	0.2	0
1	0.1	0.15	0.05
2	0	0.05	0.15

- (a) Bestimmen Sie die Randverteilungen von X und Y .

[3]

- (b) Bestimmen Sie $E(X)$ und $Var(X)$.

[3]

- (c) Bestimmen Sie die Kovarianz und Korrelation zwischen X und Y und interpretieren Sie diese.

[7]

- (d) Bestimmen Sie die bedingte Verteilung von $Y|X = 0$. [3]

Aufgabe 3 (17 Punkte)

Sei X betaverteilt mit $X \sim \text{Beta}(a, b)$ und Y gegeben X geometrisch verteilt mit $Y|X = x \sim \text{Geom}(x)$.

- (a) Berechnen Sie $E(Y)$. [8]
Hinweis: $\frac{\Gamma(c+1)}{\Gamma(c)} = c$.
- (b) Berechnen Sie die Dichte von $X|Y$. [8]
- (c) Berechnen Sie $E(X|Y)$. [1]

Aufgabe 4 (13 Punkte)

Ein fairer Würfel werde 6000-mal unabhängig geworfen.

Hinweis: $\Phi(3.46) \approx 0.9997$

- (a) Bestimmen Sie mit Hilfe des zentralen Grenzwertsatzes eine Approximation für die Wahrscheinlichkeit, dass zwischen 900-mal und 1100-mal eine Sechs geworfen wird. [8]

- (b) Bestimmen Sie mit der Tschebyscheff-Ungleichung eine untere Schranke für die Wahrscheinlichkeit, dass zwischen 900-mal und 1100-mal eine Sechs geworfen wird. [5]

Aufgabe 5 (13 Punkte)

Prof. Dr. med. Kwarantina Bauterlach-Vligenört hat einen neuen diagnostischen Test für das Vorliegen einer akuten Infektion mit der schrecklichen Fnufnu-Krankheit entwickelt. Ihre klinische Erprobung des Tests an einer Stichprobe von Patient:innen, die entweder noch nie mit dem Fnufnu-Erreger infiziert waren (“Naiv”) oder eine solche Infektion bereits hinter sich haben (“Genesen”) oder zum Zeitpunkt der Studie an einer akuten Fnufnu-Infektion leiden (“Kranke”) ergibt folgende Ergebnisse:

Status	Naiv	Genesen	Krank	
Test positiv	1	3	35	39
Test negativ	20	25	3	48
	21	28	38	

Unter den Patient:innen, die Bauterlach-Vligenört im Klinikalltag versorgt, sind 30% Genesene, 65% Naive und 5% Fnufnu-Kranke.


Gehen Sie im Folgenden davon aus, dass die in der klinischen Erprobung ermittelten Eigenschaften des Tests (FPR, TNR, etc.) auch im Klinikalltag gelten.

- (a) Berechnen Sie auf Basis der Ergebnisse der klinischen Erprobung die Sensitivität und Spezifität des Tests zur Entdeckung einer akuten Infektion. [2]

- (b) Berechnen Sie für die oben angegebene Prävalenz der Krankheit die Wahrscheinlichkeit, mit der ein Test im Klinikalltag ein positives Ergebnis zeigt. [3]

- (c) Berechnen Sie die Wahrscheinlichkeit, mit der ein negatives Testergebnis im Klinikalltag eine tatsächlich nicht akut erkrankte Person anzeigt. [3]

- (d) Die Grafik unten zeigt die ROC-Kurve eines alternativen, deutlich teureren diagnostischen Tests. Die ROC-Kurve ist an ausgewählten Punkten mit den entsprechenden Schwellenwerten des zu Grunde liegenden diagnostischen Scores beschriftet. [5]



- (i) Funktioniert der in den vorherigen Teilaufgaben analysierte Test von Bauterlach-Vlügenört etwa gleich gut, besser, oder schlechter als der hier dargestellte Test?
- (ii) Gehen Sie davon aus, dass eine Erkrankung mit der Fnufnu-Krankheit für Schwangere und ihre ungeborenen Kinder absolut lebensbedrohend ist, falls diese nicht sehr früh entdeckt und therapiert wird. Wie sollte der Schwellenwert des in der Grafik gezeigten diagnostischen Tests also gewählt werden, wenn dieser auf eine schwangere Patientin angewendet wird?

Begründen Sie Ihre Antworten kurz.

Aufgabe 6 (13 Punkte)

Sei $\Omega = \{1, 2, 3, 4, 5, 6\}$. Seien $U = \{1, 3, 5\}$, $V = \{1, 2, 3\}$, $\mu(A) := \sum_{\omega \in A} I_U(\omega)$ sowie $f : \Omega \rightarrow \mathbb{R}$ mit $f(\omega) = \omega^2$.

- (a) Geben Sie $\mathcal{F} = \sigma(\{U, V\})$ an. [4]
- (b) Zeigen Sie dass μ ein Maß zum Meßraum $(\Omega, \mathcal{F}_1)$ ist. [4]
- (c) Berechnen Sie $\int_V f d\mu$. [5]

Aufgabe 7 (13 Punkte)

Gegeben sei die stetige Zufallsvariable X mit Dichte

$$f_X(x) = c \cdot x \cdot I_{[1,3]}(x).$$

- (a) Berechnen Sie die Konstante c . [4]
- (b) Skizzieren Sie die Dichte. [1]
- (c) Welche der folgenden Aussagen ist richtig? Begründen Sie kurz (keine explizite Berechnung notwendig). [3]
- Der Median von X ist 2.
 - Die Schiefe von X ist größer 0.
 - Der Erwartungswert von X ist kleiner als der Modus von X .
- (d) Berechnen Sie mit Hilfe des Dichtetransformationssatzes die Dichte der Zufallsvariablen $Y = \frac{1}{1+X}$. [5]

Aufgabe 8 (12 Punkte)

Seien $X \sim N(0, 1)$ und $Y \sim \text{Poi}(2)$ zwei stochastisch unabhängige Zufallsvariablen.

- (a) Bestimmen Sie Erwartungswert und Kovarianzmatrix des Zufallsvektors $U = (Y - X, Y)^T$. [6]
- (b) Handelt es sich bei den folgenden Matrizen um gültige Kovarianzmatrizen? Begründen Sie kurz! [6]

$$\Sigma_1 = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 3 \end{pmatrix}, \Sigma_2 = \begin{pmatrix} 1 & 1 & -1 \\ 1 & -1 & 1 \\ -1 & 1 & 1 \end{pmatrix}, \Sigma_3 = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$$

$$\Sigma_4 = \begin{pmatrix} 1 & 1 & 0 & 0 \\ 1 & 2 & 1 & 0 \\ 0 & 1 & 3 & 1 \end{pmatrix}, \Sigma_5 = \begin{pmatrix} 1 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 1 \end{pmatrix}, \Sigma_6 = \begin{pmatrix} 2 & 0.5 & -2 \\ 1.5 & 0.5 & 0 \\ -2 & 0 & 7 \end{pmatrix}$$

Aufgabe 9 (21 Punkte)


Beantworten Sie die folgenden Fragen, jeweils mit kurzer Begründung oder Rechnung mit nachvollziehbarem Ansatz.

- (a) A und B spielen folgendes Spiel: Es wird mit 4 Würfeln gewürfelt. Tritt mindestens einmal die Zahl 6 auf, dann gewinnt A, sonst B. Ist das Spiel fair in dem Sinne, dass im Mittel beide gleich oft gewinnen werden? [2]
- (b) In einer Population leiden fünf Prozent der Menschen an erhöhtem Blutdruck. Von diesen fünf Prozent trinken 75% regelmäßig Alkohol. Außerdem ist bekannt, dass 50% der Menschen, die *keinen* erhöhten Blutdruck haben, regelmäßig Alkohol trinken. Wieviel Prozent der regelmäßigen Alkoholkonsument:innen leiden an erhöhtem Blutdruck? [3]
- (c) Sei X eine stetige Zufallsvariable mit Verteilungsfunktion F_X und einem 0.25-Quantil von 3. Welche der folgenden Aussagen trifft/treffen zu? [2]
- (i) $F_X(3) = 0.25$
 - (ii) $F_X(0.25) = 3$
 - (iii) $F_X^{-1}(3) = 0.25$

- (d) Sei Y eine diskrete Zufallsvariable mit Träger $T_Y = \mathbb{N}$ und Verteilungsfunktion F_Y mit $F_Y(33/10) = 0.5$ und $F_Y(2) \neq F_Y(3) \neq F_Y(4)$. Geben Sie für die folgenden Aussagen an ob sie aus diesen Angaben folgen: [3]
- (i) Der Median von Y ist 3.
 - (ii) $P(Y < 3) \leq 0.5$
 - (iii) Der Erwartungswert von Y ist 3.
- (e) Welche Verteilung hat die Zufallsvariable $Z = 3U - 12$ falls $U \sim \mathcal{N}(\mu = 4, \sigma^2 = 5)$? [2]
- (f) Nehmen Sie an, ein Pfandautomat akzeptiert jede ihm zugeführte Flasche mit Wahrscheinlichkeit $p < 1$. Sei F die Anzahl der Flaschen, die man dem Automaten zuführen muss um einen Pfandbon für m akzeptierte Flaschen zu bekommen. Mit welcher aus der Vorlesung bekannten parametrischen Verteilung können Sie F beschreiben, was sind die Parameterwerte [3]

und welche zusätzlichen Annahmen über den daten-generierenden Prozess müssen Sie dafür treffen?

- (g) Folgender Mosaikplot stellt den beobachteten Zusammenhang der Merkmale Geschlecht (m/w) und Klausurerfolg (bestanden/nicht bestanden) für eine Statistiklausur dar. [3]



- (i) Für welches Geschlecht ist die Durchfallrate höher?
- (ii) Gibt es insgesamt mehr Männer, die bestehen oder mehr Frauen, die bestehen?
- (iii) Das in den oben dargestellten Daten zusätzlich erhobene Merkmal “Studienfach” mit möglichen Ausprägungen “Nebenfach” und “Hauptfach” ist empirisch unabhängig von “Geschlecht” und von “Klausurerfolg”. Die Hälfte der Prüfungsteilnehmer:innen sind Nebenfachstudierende, die anderen Hauptfachstudierende. Skizzieren Sie einen Mosaikplot für die gemeinsame Verteilung dieser drei Merkmale. (Nur schematische Skizze gefragt, keine exakte Zeichnung!)

- (h) Es liegt eine große Anzahl n von unabhängig Poisson-verteilten Zufallsvariablen mit gleicher Rate λ vor. Wie ist die Summe dieser Zufallsvariablen exakt verteilt und welcher Verteilung folgt diese Summe approximativ? [3]