

Klausur
Deskriptive Statistik und Wahrscheinlichkeitstheoretische Grundlagen
am 1. August 2022

Name: _____

Matrikelnummer: _____

Studiengang (Hauptfach):

- ☐ Bachelor Statistik und Data Science, Prüfungsordnung 2021
- ☐ Bachelor Statistik und Data Science, Prüfungsordnung 2010
- ☐ Andere: _____

Ich bestätige, dass ich die Hinweise auf der zweiten Seite zur Kenntnis genommen und die Klausurangabe auf Vollständigkeit überprüft habe.

Unterschrift: _____

Aufgabe	Punkte	Erreichte Punkte
1	19	
2	23	
3	15	
4	19	
5	17	
6	23	
7	12	
8	10	
9	12	
Gesamt	150	


Hinweise zur Klausur:

1. Überprüfen Sie zunächst, ob Ihre Klausurangabe vollständig ist. Die Klausurangabe sollte aus 17 Seiten (ohne Deckblatt) mit 9 Aufgaben bestehen.
2. Die Bearbeitungszeit beträgt 150 Minuten. In den ersten 30 Minuten und in den letzten 15 Minuten ist keine vorzeitige Abgabe vorgesehen.
3. Es können maximal 150 Punkte erreicht werden. Ein nachvollziehbarer Lösungsweg ist Voraussetzung zum Erlangen der vollen Punktzahl.
4. Es sind folgende Hilfsmittel zugelassen:
 - Ein DIN A4 Blatt mit handschriftlichen Notizen auf Vorder- und Rückseite.
 - Verteilungsübersicht ohne zusätzliche Notizen oder Ergänzungen. Unterstreichungen und farbige Markierungen sind erlaubt.
 - Nichtprogrammierbarer Taschenrechner
 - Bei Bedarf ein Wörterbuch
5. Verwenden Sie für Ihre Lösungen ausschließlich die Ihnen zur Verfügung gestellten karierten Kanzleibögen und kennzeichnen Sie jeden Kanzleibogen (einmal) mit Ihrem Namen und Ihrer Matrikelnummer.
6. Es darf nicht mit Rot- oder Bleistift geschrieben werden.
7. Legen Sie einen Lichtbildausweis und einen aktuell gültigen Studenausweis bereit.
8. Schalten Sie Telephone und andere elektrische Geräte aus.
9. Bei Unterschleif erfolgt eine Meldung an das Prüfungsamt. Sie sind verpflichtet, durch Ihr Verhalten jegliche Missverständnisse diesbezüglich auszuschließen.
10. Verlassen Sie den Prüfungsraum erst, nachdem Sie der Aufsicht die Klausur persönlich übergeben haben. Für den Eingang der kompletten Klausur bei der Aufsicht sind Sie selbst verantwortlich.
11. Bitte verlassen Sie nach der Klausur den Hörsaaltrakt zügig und leise, damit Sie die Teilnehmer anderer Klausuren nicht stören.

Viel Erfolg!

Aufgabe 1 (19 Punkte)

Betrachten Sie die folgende Grafik:



Data source: United Nations Population Division (2012 revision).

The interactive data visualization is available at [OurWorldinData.org](https://ourworldindata.org). There you find the raw data and more visualizations on this topic.

Licensed under CC-BY-SA by the author Max Roser.

Quelle: [Ourworldindata.org](https://ourworldindata.org)

Übersetzung der relevanten Grafikbeschriftungen:

- Titel: "Weltbevölkerung und Fruchtbarkeitsniveau über die Zeit"
- Untertitel: "Kumulative Anteile an Weltbevölkerung auf der x-Achse. Länder sind entlang der x-Achse absteigend nach ihrer Gesamtfruchtbarkeitsrate sortiert."
- Linke Seite: *Global average fertility* = Globale durchschnittliche Fruchtbarkeit; *Global replacement fertility* = Globale Fruchtbarkeitsrate für stabiles Bevölkerungsniveau
- Horizontale Achse: "Kumulativer Anteil an Weltbevölkerung"
- Vertikale Achse (rechts): "Anzahl an Kindern pro Frau (Gesamtfruchtbarkeitsrate)"

Analysieren Sie im folgenden die Datensituation, die der obigen Grafik zu Grunde liegt und die grafischen Mittel, die zur Visualisierung benutzt wurden.

(a) Welche Untersuchungseinheiten aus welcher Grundgesamtheit werden in der Grafik dargestellt? [2]

Lösung:

GG: alle Länder der Erde, UE: einzelne Länder [2P.]

(b) Was für eine Erhebungsart und Datenstruktur liegen hier vor? [2]

Lösung:

Vollerhebung (alle Länder der Erde) [1P.] als Panelstudie / Longitudinaldaten [1P.]

- (c) Welches Skalenniveau haben Gesamtfruchtbarkeitsrate und Bevölkerungsanteil jeweils? [2]

Lösung:

TFR : Absolutskala [1P.] (Intervall/Verhältnis [0.5P.])

Bevölkerung: Verhältnisskala [1P.] (Intervall [0.5P.])

- (d) Sind die auf der linken Seite angegeben Zeiträume die Ausprägungen eines ordinal-, nominal- oder intervallskalierten Merkmals? Begründen Sie Ihre Antwort kurz. [2]

Lösung:

Nicht nominal, mindestens ordinal weil klare Ordnung der Ausprägungen. [1P.]

Ordinal vs intervall: letzteres da Abstände zwischen Ausprägungen klar definiert und sinnvoll berechenbar [1P.]

(auch okee: ordinal weil "gruppiertes" Merkmal aus intervallskalierter Zeit [0.5P.])

- (e) Was für eine Art von Farbskala wurde in der Grafik verwendet? Welche Art von Farbskala wäre hier eventuell besser geeignet und warum? [2]

Lösung:

qualitative Farbskala [1P.]

sequentielle Farbskala besser geeignet da ordinales / metrisches Merkmal [1P.]

- (f) Welche "Geometrie" wird hier zur Darstellung benutzt? [2]
Geben Sie für alle in der Grafik gezeigten Merkmale die verwendeten ästhetischen Zuordnungen an.

Lösung:

Geometrie: Linie (bzw. Treppenfunktion) [0.5P.]

Zeitraum → Farbe [0.5P.]

Kum. Bevölkerungsanteil → x-Koordinate [0.5P.]

TFR → y-Koordinate [0.5P.]

- (g) Welche ästhetischen Eigenschaften welcher Geometrien würden Sie für welche Merkmale verwenden, um in einer wohlüberlegten statistischen Grafik auf Basis dieser Daten die zeitlichen Entwicklungen der Gesamtfruchtbarkeitsraten zwischen ausgewählten Ländern einfach vergleichbar zu machen? [4]
(Auch ggplot2-Befehle werden als Antwort akzeptiert.)

Lösung:

Z B:

`geom_line(aes(x = <Zeitraum>, y = <TFR>, color = <Land>))`

Geometrie: Linie

Land → Farbe

Zeitraum → x-Koordinate

TFR → y-Koordinate

(auch: facettierung nach land statt farbe für land)

- (h) Betrachten Sie die in der Grafik in rot eingezeichnete Linie. Stellen Sie sich vor, wir vertauschen die horizontalen und vertikalen Achsen der Grafik durch eine Rotation um 90° gegen den Uhrzeigersinn. Wäre die dadurch entstehende Funktion äquivalent zur empirischen Verteilungsfunktion der Gesamtfruchtbarkeitsrate im angegebenen Zeitraum? Begründen Sie Ihre Antwort. [3]


Lösung:

Nein. 1. x-Achse wäre falsch rum (von 8 nach 1) [1P.]

2. y-Achse wäre nicht Anteil an Untersuchungseinheiten (Anteil Länder mit $\text{TFR} \leq x$) sondern Anteil den diese Länder an Weltbevölkerung auf sich vereinen. [2P.]

Aufgabe 2 (23 Punkte)

Die folgenden Graphiken zeigen Streudiagramme zu den drei Datensätzen A, B und C, die jeweils $n = 20$ Beobachtungen zweier metrischer Merkmale enthalten.



- (a) Zeichnen Sie ein Histogramm der relativen Häufigkeiten des Merkmals X_A aus Datensatz A mit gleichbleibender Klassenbreite der Länge 5 und charakterisieren Sie die Verteilung. Wodurch werden im Histogramm die relativen Häufigkeiten dargestellt? [6]

Lösung:

Rechnung [0.5P.] [0.5P.] [0.5P.] [0.5P.] , Zeichnung [1P.] [1P.] . histogrammhöhen H_j sind $(2, 4, 5, 9)/20/5 = (0.02, 0.04, 0.05, 0.09)$
 verteilung: linksschief/rechtssteil [0.5P.] , unimodal [0.5P.] relative häufigkeit ist $f_j = H_j * b_j$ [1P.]

- (b) Nennen Sie jeweils einen allgemeinen Vor- und Nachteil der graphischen Darstellung eines metrischen Merkmals in einem Histogramm gegenüber der Darstellung in einem Boxplot. [2]

Lösung:

vorteile zb: multimodalität sichtbar, nähert dichte an für schmale klassenbreiten/große stichprobe
 nachteile zb: optischer eindruck stark beeinflusst von arbiträr wählbarer klassenbreite und position von klassengrenzen.

- (c) Geben Sie für die drei Streudiagramme jeweils an, ob der Korrelationskoeffizient nach Bravais-Pearson oder der Korrelationskoeffizient nach Spearman größer ist oder ob beide etwa den gleichen Wert haben. Geben Sie den genauen Wert für einen Korrelationskoeffizienten an, falls dieser direkt aus der Graphik abgelesen werden kann. [4]

Lösung:

- Datensatz A: $r_{x_A, y_A} = [0.5P.] r_{x_A, y_A}^{SP} = -1$ [0.5P.]

- Datensatz B: $r_{x_B, y_B} < [1P.] r_{x_B, y_B}^{SP} = 1$ [1P.]
- Datensatz C: $r_{x_C, y_C} = [0.5P.] r_{x_C, y_C}^{SP} = 0$ [0.5P.]

- (d) Welche Art von Zusammenhang misst der Korrelationskoeffizient nach Bravais-Pearson, welche Art von Zusammenhang der Korrelationskoeffizient nach Spearman? Für welche Skalenniveaus sind die beiden Maße jeweils geeignet? [4]

Lösung:

Pearson: lineare Zshg. [1P.] , metrische Merkmale (intervall/verhältnis/absolutskaliert) [1P.]

Spearman: monotone Zshg. [1P.] , mindestens ordinale Merkmale [1P.]

- (e) Für zwei Merkmale X und Y mit positivem Wertebereich sind der Korrelationskoeffizient nach Bravais-Pearson $r_{XY} = 0.5$ und der Korrelationskoeffizient nach Spearman $r_{XY}^{SP} = 0.6$ gegeben. Ändern sich die Werte der beiden Zusammenhangsmaße jeweils, wenn Y folgendermaßen zu Y_1 bzw. Y_2 transformiert wird? [4]

(i) $Y_1 = -Y$

(ii) $Y_2 = Y^2$

Geben Sie konkrete Werte für die resultierenden Korrelationskoeffizienten r_{XY_1} , $r_{XY_1}^{SP}$, r_{XY_2} und $r_{XY_2}^{SP}$ an, falls dies möglich ist.

Lösung:

(i) $Y_1 = -Y$:

- $r_{XY_1} = -r_{XY} = -0.5$ [1P.]
- $r_{XY_1}^{SP} = -r_{XY}^{SP} = -0.6$ [1P.]

(ii) $Y_2 = Y^2$:

- $r_{XY_2} \neq r_{XY}$ [1P.]
- $r_{XY_2}^{SP} = r_{XY}^{SP} = 0.6$ [1P.]

- (f) Ein weiteres Zusammenhangsmaß stellt Kendall's Tau dar. Was ist die Grundidee dieser Maßzahl? Erläutern Sie kurz das Vorgehen bei der Berechnung. [3]

Lösung:

Grundidee: Paarvergleiche aller Beobachtungen [1P.] Vorgehen:

- Bei der Berechnung wird die Differenz zwischen der Anzahl der konkordanten Paare (i, j) mit $x_i > x_j, y_i > y_j$ oder $x_i < x_j, y_i < y_j$ und der Anzahl der diskordanten Paare ermittelt. [1P.]
- Diese Differenz wird durch die Anzahl aller möglichen Beobachtungspaare $\frac{n(n-1)}{2}$ dividiert, so dass sich ein Wertebereich zwischen -1 und 1 ergibt. [1P.]

Aufgabe 3 (15 Punkte)

$$\text{Sei } F(x) = \begin{cases} 0 & x < 0 \\ \log(ax + b) & 0 \leq x \leq \exp(1) \\ 1 & x > \exp(1) \end{cases}$$

- (a) Für welche Werte von a und b ist $F(x)$ die Verteilungsfunktion einer stetigen Zufallsvariable? [6]

Lösung:

Hinreichend und notwendig: Monotonie und Stetigkeit

$$\begin{aligned} \lim_{x \searrow 0} F(x) &= 0 \text{ und} \\ \lim_{x \nearrow e} F(x) &= 1 \end{aligned}$$

[1P.]

Monotonie folgt aus der Logarithmusfunktion. [1P.]

Damit ist

$$F(0) = \log(b) = 0 \Rightarrow b = 1 \text{ [1P.]}$$

und

$$\begin{aligned} F(e) &= \log(ae + 1) = 1 \text{ [1P.]} \\ \Leftrightarrow ae + b &= e \text{ [1P.]} \\ \Leftrightarrow a &= \frac{e-1}{e} \text{ [1P.]} \end{aligned}$$

- (b) Wie lautet die zugehörige Dichte? [3]

Lösung:

$$\frac{\partial F(x)}{\partial x} \text{ [1P.]} = \frac{a}{ax+b} \text{ [1P.]} = \frac{e-1}{(e-1)x+e} \text{ [0.5P.]}$$

$f(x) = \frac{e-1}{(e-1)x+e} I(x \in [0, e])$ [0.5P.] (Indikatorfunktion oder Fallunterscheidung für Träger muss mit angegeben werden.)

- (c) Wie lautet die Quantilfunktion? Berechnen Sie das 95%-Quantil. [4]

Lösung:

Die Quantilfunktion ist die Umkehrfunktion von F :

$$\begin{aligned} p &= \log(ax + b) [0.5\text{P.}] \\ \exp(p) &= ax + b [0.5\text{P.}] \\ \frac{\exp(p) - b}{a} &= x [1\text{P.}] \\ \implies Q(p) = F^{-1}(p) &= \frac{\exp(p) - 1}{(e - 1)/e} \forall p \in [0, 1] [1\text{P.}] \end{aligned}$$

Für $p = 0.95$ gilt $x = 2.509$. [1P.]

- (d) (i) Wird durch $F(x)$ eindeutig eine Verteilung festgelegt? Begründen Sie. [2]
(ii) Wird durch $f(x)$ eindeutig eine Verteilung festgelegt? Begründen Sie.

Lösung:

- (i) Ja, wegen Korrespondenzsatz [1P.]
(ii) Nein, siehe Satz von Radon-Nikodym [1P.]

Aufgabe 4 (19 Punkte)

Die Firma “Loysent” will zur Qualitätskontrolle in der Lebensmittelproduktion ein System zur automatischen Entdeckung verunreinigter Produkte einsetzen. Pro Monat soll das System im Alltagsbetrieb 5 Millionen Einheiten überprüfen, von einer Million Einheiten sind erwartungsgemäß zehn verunreinigt. In einem Pilotversuch des Systems mit einer bewusst ausgewählten Stichprobe von Produkten löste es bei 13 von 15 tatsächlich verunreinigten Einheiten und bei 22 von 1100 nicht verunreinigten Einheiten einen Alarm aus.

- (a) Berechnen Sie auf Basis der Ergebnisse des Pilotversuchs die erwarteten monatlichen Häufigkeiten [6] von Fehlalarmen, zutreffenden Alarmen, übersehenen Verunreinigungen und vom System korrekt als beanstandungsfrei identifizierten Einheiten, falls das System in der Produktion zum Einsatz käme.

Lösung:

V: “Einheit verunreinigt”

A: “System löst Alarm aus”

Das System hatte im Pilotversuch TPR/Sensi. $P(A|V) = 13/15 = 0.867$ [0.5P.] und FPR $P(A|\bar{V}) = 22/1100 = 0.02$ [0.5P.]. Unter den 5 Mio Einheiten pro Monat sind $\frac{10}{1e6} \cdot 5e6 = 50$ [0.5P.] verunreinigt zu erwarten. Die erwarteten Häufigkeiten betragen $13/15 \cdot 50 = 43.33$ [1P.] korrekte Alarme (true positives), $2/15 \cdot 50 = 6.67$ [1P.] übersehene Verunreinigungen (false negatives), $22/1100 \cdot (5e6 - 50) = 99999$ [1P.] Fehlalarme (false positives) und $(1 - 22/1100) \cdot (5e6 - 50) = 4899951$ true negatives. [1P.]

	Verunreinigt V	$\bar{V}$	
Alarm A	43	99 999	100 042
$\bar{A}$	7	4 899 951	4 899 958
total	50	4 999 950	5 000 000

- (b) Halten Sie den Einsatz des Systems unter den gegebenen Umständen aus statistischer Sicht [3] für sinnvoll? Begründen Sie Ihre Antwort quantitativ mit geeigneten Kennzahlen.

Lösung:

$$\begin{aligned}
 P(V|A) &= \frac{P(V \cap A)}{P(A)} = \frac{P(V \cap A)}{P(A \cap V) + P(A \cap \bar{V})} \text{ [0.5P.]} \\
 &= \frac{P(A|V) \cdot P(V)}{P(A|V) \cdot P(V) + P(A|\bar{V}) \cdot P(\bar{V})} \text{ [0.5P.]} \\
 &= \frac{\frac{13}{15} \cdot \frac{10}{1e6}}{\frac{13}{15} \cdot \frac{10}{1e6} + \frac{22}{1100} \cdot (1 - \frac{10}{1e6})} \text{ [0.5P.]} \\
 &= 4.3 \cdot 10^{-5} \text{ [0.5P.]}
 \end{aligned}$$

(Oder direkt aus Kreuz-Tabelle oben: PPV = 43/100042)

Der PPV ($P(V|A)$) liegt nahe bei 0, d.h. dass ein positives Testergebnis nur sehr wenig Information liefert und die weit überwiegende Mehrzahl angezeigter Verunreinigungen


Fehlalarme sind. [0.5P.] Der Test ist zu ungenau um ihn sinnvoll für die automatische Überwachung der gesamten Produktion zu verwenden. [0.5P.]

- (c) Quantifizieren Sie die erwartete Stärke des Zusammenhangs zwischen der tatsächlichen Verunreinigung einer Einheit und der Reaktion des Systems auf diese Einheit im Alltagsbetrieb. Benutzen Sie dafür eine Maßzahl, deren Wertebereich $\mathbb{R}_0^+$ ist. Interpretieren Sie Ihr Ergebnis. [2]

Lösung:

Odds Ratio $\gamma(A, \bar{A}|V, \bar{V}) = (43 \cdot 4899951) / (7 \cdot 99999) = 301$ [1P.] , also sehr starker Zusammenhang [1P.] . (Kontingenzkoeffizienten wegen Missachtung des vorgegebenen Wertebereichs 1 Punkt Abzug.)

- (d) Die Grafik unten zeigt die ROC-Kurven zweier Systeme zur automatischen Entdeckung verunreinigter Produkte, die von den Firmen "Ponapticum" (blau, gestrichelt) und "Nopapcitom" (rot, durchgezogen) angeboten werden. Die ROC-Kurven sind an ausgewählten Punkten mit den entsprechenden Schwellenwerten des zu Grunde liegenden Scores beschriftet. [5]



- (i) Funktioniert das in den vorherigen Teilaufgaben analysierte System etwa gleich gut, deutlich besser oder deutlich schlechter als die zwei hier dargestellten Systeme?
- (ii) Gehen Sie davon aus, dass der Verkauf verunreinigter Produkte für "Loysent" existenzbedrohend ist und Einheiten, die vom System als verunreinigt eingestuft werden, einfach und kostengünstig automatisch gereinigt werden können. Welches der beiden in der Grafik gezeigten Systeme ist für diese Situation besser geeignet? Welcher (Bereich von) Schwellenwert(en) sollte für den praktischen Einsatz des präferierten Systems benutzt werden?

Begründen Sie Ihre Antworten kurz.

Lösung:

i) Deutlich schlechter. Beide hier gezeigten Systeme haben wesentlich höhere TPR und niedrigere FPR. [2P.]

ii) In dem hier beschriebenen Szenario ist die Entdeckung und Beseitigung möglichst aller Verunreinigungen wichtiger als die Vermeidung von Fehlalarmen, also gilt es die Sensitivität/TPR zu maximieren. [1P.] Im Fall hier hat das System von "Ponapticum" [1P.] für Schwellenwerte zwischen ca 19 und 23 [1P.] bessere TPR als "Nopapcitom" ohne dass die FPR sich massiv erhöht.

- (e) Das System prüft nacheinander jede einzelne produzierte Einheit. Im Zuge der Erprobung des Systems wurde auch festgehalten, wieviele vom System nicht beanstandete Einheiten jeweils zwischen zwei beanstandeten Einheiten überprüft wurden. [3]
- Mit welcher parametrischen Verteilungsfamilie können Sie die Verteilung dieser Messungen beschreiben?
- Welche Annahmen müssen Sie dafür zusätzlich treffen? Geben Sie an was die theoretischen Annahmen in der beschriebenen Situation konkret bedeuten (Stichpunkte).

Lösung:

Wartezeit in diskreter Zeit $\implies$ Geometrische Verteilung. [1P.] Annahmen: Geom. Verteilung basiert auf iid Bernoulli-Kette, also:

"Unabhängige Versuche" [0.5P.] $\iff$ Alarmw.keit hängt nicht davon ab wann der letzte Alarm war [0.5P.]

"identische Erfolgsw.keit" [0.5P.] $\iff$ Verunreinigungsquote bzw Alarm.wkeit ändert sich nicht über die Zeit [0.5P.]

Aufgabe 5 (17 Punkte)

Gegeben sei $\Omega = \{1, 2, 3, 4\}$. Sei $A = \{1\}$ und $B = \{1, 3\}$ sowie $\mu : \Omega \rightarrow \mathbb{R}$, $\mu(A) := \sum_{\omega \in A} \omega$ und

$f(\omega) = 1/\omega$.

(a) Geben Sie $\mathcal{F}_1 = \sigma(\{A, B\})$ an.

[3]

Lösung:

$\mathcal{F}_1 = \{\emptyset, \Omega, \{1\}, \{1, 3\}, \{2, 4\}, \{2, 3, 4\}, \{3\}, \{1, 2, 4\}\}$. [0.5P.] [0.5P.] [2P.]

(b) Zeigen Sie: Die Vereinigung von zwei σ -Algebren muss keine σ -Algebra sein. Definieren Sie dafür eine σ -Algebra $\mathcal{F}_2$ für Ω , so dass $\mathcal{F}_1 \cup \mathcal{F}_2$ keine σ -Algebra ist.

[4]

Lösung:

Zum Beispiel

$$\mathcal{F}_2 = \{\emptyset, \Omega, \{1, 2\}, \{3, 4\}\} \quad [2P.] \quad (1)$$

$$\mathcal{F}_1 \cup \mathcal{F}_2 = \{\emptyset, \Omega, \{1, 3\}, \{1\}, \{2, 4\}, \{1, 2, 4\}, \{3\}, \{2, 3, 4\}, \{1, 2\}, \{1, 3\}\} \quad [1P.] \quad (2)$$

$$\{1, 3\} \cup \{3, 4\} = \{1, 3, 4\} \notin \mathcal{F}_1 \cup \mathcal{F}_2 \quad [1P.] \quad (3)$$

(c) Zeigen Sie dass μ ein Maß zum Meßraum $(\Omega, \mathcal{F}_1)$ ist.

[4]

Lösung:

i) $\mu(\emptyset) = 0$ [1P.]

ii) $\mu(A) \geq 0$, da $\omega > 0 \forall \omega \in \Omega$ [1P.]

iii)

$$\mu\left(\bigcup A_i\right) = \sum_{\omega \in \bigcup A_i} \omega \quad [0.5P.] \quad (4)$$

$$= \sum_{\omega \in A_1} \dots \sum_{\omega \in A_k} \omega \text{ da } A_i \text{ disjunkt} \quad [1P.] \quad (5)$$

$$= \sum_i \mu(A_i) \quad [0.5P.] \quad (6)$$

(d) Berechnen Sie $\int_B f d\mu$.

[4]

Lösung:

$$\int_B f d\mu = \int_{\{1,3\}} \frac{1}{\omega} d\mu \text{ [1P.]} \quad (7)$$

$$= \int_{\{1\}} \frac{1}{\omega} d\mu + \int_{\{3\}} \frac{1}{\omega} d\mu \text{ [1P.]} \quad (8)$$

$$= \int_{\{1\}} \frac{1}{1} d\mu + \int_{\{3\}} \frac{1}{3} d\mu \text{ [1P.]} \quad (9)$$

$$= \mu(\{1\}) + \frac{1}{3}\mu(\{3\}) = 2 \text{ [1P.]} \quad (10)$$

(e) Ist f die Dichte einer Verteilung bezüglich des dominierenden Maßes μ ? Begründen Sie.

[2]

Lösung:

Nein, [1P.] da $\int_B f d\mu > 0$ bzw. $\int f d\mu = 4$ [1P.]

Aufgabe 6 (23 Punkte)

Sei

$$f(x) = \frac{3}{2} (x-1)^2 \cdot I_{[0,2]}(x)$$

die stetige Dichte der Zufallsvariable X .

- (a) Skizzieren Sie die Dichte. Wie ist der Modus der Verteilung? Geben Sie ohne Berechnung, aber mit Begründung Erwartungswert, Median und Schiefe der Verteilung an. [4]

Lösung:

U-Form [1P.] , Bimodal [0.5P.] mit Modus bei 0 und 2 [0.5P.] , Symmetrische Verteilung [0.5P.] $\Rightarrow E(X) = 1$ [0.5P.] , Schiefe = 0 [0.5P.] , Median=1 [0.5P.] .

- (b) Berechnen Sie die Varianz der Verteilung. [8]

Lösung:

$$\begin{aligned} \text{Var}(X) &= E(X^2) - E(X)^2 \text{ [1P.]} \\ E(X^2) &= \int x^2 f(x) dx \text{ [1P.]} \\ &= \int_0^2 x^2 \cdot \frac{3}{2} (x-1)^2 dx \text{ [1P.]} \\ &= \frac{3}{2} \int_0^2 x^2 (x^2 - 2x + 1) dx \text{ [0.5P.]} \\ &= \frac{3}{2} \int_0^2 (x^4 - 2x^3 + x^2) dx \text{ [0.5P.]} \\ &= \frac{3}{2} \left(\int_0^2 x^4 dx - \int_0^2 2x^3 dx + \int_0^2 x^2 dx \right) \text{ [1P.]} \\ &= \frac{3}{2} \left(\left[\frac{1}{5} x^5 \right]_0^2 - \left[\frac{2}{4} x^4 \right]_0^2 + \left[\frac{1}{3} x^3 \right]_0^2 \right) \text{ [0.5P.]} \\ &= \frac{3}{2} \left(\frac{32}{5} - \frac{16}{2} + \frac{8}{3} \right) = \text{ [0.5P.]} \\ &= \frac{3}{2} \frac{32}{30} = \frac{8}{5} \text{ [1P.]} \\ \text{Var}(X) &= E(X^2) - E(X)^2 = \frac{8}{5} - (1)^2 = \frac{3}{5} \text{ [1P.]} \end{aligned}$$

- (c) Berechnen Sie die Dichte von $Y = X^2$. [7]

Lösung:

g ist bijektiv auf $[0,2]$ [1P.]

$$\begin{aligned}g(x) &= x^2 \text{ [1P.]} \\h(y) &= y^{1/2} \text{ [1P.]} \\\frac{d}{dx}h(x) &= \frac{1}{2}y^{-1/2} \text{ [1P.]} \\f_Y(y) &= f_X(h(x))\left|\frac{1}{2}y^{-1/2}\right| \text{ [1P.]} \\&= \frac{3}{2}(\sqrt{y} - 1)^2 \frac{1}{2}y^{-1/2} \text{ [2P.]} \\&= \frac{3}{4}(y - 2y^{1/2} + 1)y^{-1/2} = \frac{3}{4}(y^{1/2} - 2 + y^{-1/2})\end{aligned}$$

- (d) Schätzen Sie den Erwartungswert von $Z = X^4$ ab. (Keine explizite Berechnung!)

[4]

Lösung:

Ungleichung von Jensen [1P.] :

$f(x) = x^4$ ist konkav auf $[0,2]$ [1P.] , daher $E(Z) = E(X^4) \geq E(X)^4 = 1^4 = 1$ [1P.] .

Oder $g(y) = y^2$ ist konkav auf $[0,2]$ [1P.] , daher $E(Z) = E(X^4) \geq E(X^2)^2 = \frac{8^2}{5^2}$ nach b) [1P.]

Aufgabe 7 (12 Punkte)

Prof. S. nimmt täglich ($n = 225$) den Bus zur Universität und ist immer pünktlich an der Bushaltestelle. Der Bus verspätet sich jedoch jeden Tag. Bezeichne X_i die zufällige Zeitdauer der Verspätung in Minuten am Tag i . Wir nehmen an, dass die X_i unabhängig und identisch exponentialverteilt sind mit $\mathbb{E}(X_i) = 1$. Betrachten wir die Zufallsgröße $X = \sum_{i=1}^n X_i$, also die aufsummierte Verspätung in einem Jahr.

- (a) Zeigen Sie, dass X approximativ normalverteilt ist. Wie lauten approximativer Erwartungswert und approximative Varianz? [8]

Lösung:

Da $\mathbb{E}(X_i) = \mu = 1 = \frac{1}{\lambda}$, ist $\lambda = 1$ [1P.] und damit $\text{Var}(X_i) = \frac{1}{\lambda^2} = 1 = \sigma^2 < \infty$ [1P.]. Da die X_i unabhängig und identisch verteilt sind [1P.], folgt mit dem Zentralen Grenzwertsatz [1P.] für $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

$$\begin{aligned} \frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}} &\stackrel{a}{\sim} \mathcal{N}(0, 1) \text{ [0.5P.]} \\ \Leftrightarrow \bar{X} - \mu &\stackrel{a}{\sim} \mathcal{N}\left(0, \frac{\sigma^2}{n}\right) \text{ [0.5P.]} \\ \Leftrightarrow \frac{1}{n} X &\stackrel{a}{\sim} \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right) \text{ [0.5P.]} \\ \Leftrightarrow X &\stackrel{a}{\sim} \mathcal{N}(n\mu, n\sigma^2) \text{ [0.5P.]} \end{aligned}$$

mit $\mu_X = n\mu = 225 \cdot 1 = 225$ [1P.] und $\sigma_X^2 = n\sigma^2 = 225 \cdot 1^2 = 225$ [1P.] .

- (b) Bestimmen Sie approximativ die Wahrscheinlichkeit dafür, dass Prof. S. über das Jahr gesehen mehr als 4 Stunden auf den Bus wartet. [4]

Hinweis: $\Phi(2) \approx 0.84$.

Lösung:

Von Interesse ist

$$\begin{aligned} \mathbb{P}(X > 4 \cdot 60) &\stackrel{[0.5P.]}{=} \mathbb{P}(X > 240) \stackrel{[1P.]}{=} 1 - \mathbb{P}(X \leq 240) \\ &\stackrel{[0.5P.]}{=} 1 - \mathbb{P}\left(\frac{X - \mu_X}{\sigma_X} \leq \frac{240 - 225}{15}\right) \\ &\stackrel{[1P.]}{\approx} 1 - \mathbb{P}\left(\frac{X - \mu_X}{\sigma_X} \leq 1\right) \stackrel{[0.5P.]}{\approx} 1 - \Phi(1) \approx 1 - 0.84 \stackrel{[0.5P.]}{=} 0.16 \end{aligned}$$

Aufgabe 8 (10 Punkte)

Sei $\mathbf{X} = (X_1, X_2)$ ein Zufallsvektor mit gemeinsamer Dichte

$$f(x_1, x_2) = \begin{cases} \lambda \exp(-\sqrt{\lambda}(x_1 + x_2)) & \text{für } x_1 > 0 \text{ und } x_2 > 0 \\ 0 & \text{sonst.} \end{cases}$$

- (a) Zeigen Sie, dass X_1 und X_2 stochastisch unabhängig sind.

[2]

Lösung:

Die gemeinsame Dichte lässt sich zerlegen in $f(x_1, x_2) = f_{X_1}(x_1)f_{X_2}(x_2)$ [1P.] mit $f(x_i) = \sqrt{\lambda} \exp(-\sqrt{\lambda}x_i)I_{(0,\infty)}(x_i)$ [1P.]

- (b) Leiten Sie die Randdichten (marginalen Dichten) von X und Y her. Handelt es sich um bekannte Verteilungen?

[2]

Lösung:

Siehe a) [1P.] . Exponentialverteilung mit $\sqrt{\lambda}$. [1P.]

- (c) Leiten Sie die Dichte von $Y = X_1 + X_2$ her.

[6]

Lösung:

Faltung:

$$\begin{aligned} \int f_y(y) &= \int f_{x_1}(y - x_2) \cdot f_{x_2}(x_2) dx_2 \text{ [1P.] } = \\ &= \int \lambda \exp(-\lambda(y - x_2)I_{(0,\infty)}(y - x_2)) \cdot \text{ [1P.] } \\ &\quad \cdot \lambda \exp(-\lambda x_2) \cdot I_{(0,+\infty)}(x_2) dx_2 \text{ [1P.] } \\ &= \int \lambda^2 \exp(-\lambda y + \lambda x_2 - \lambda x_2) \cdot I_{(0,y)}(x_2) dx_2 I_{(0,\infty)}(y) \text{ [1P.] } \\ &= \lambda^2 \exp(-\lambda y) I_{(0,\infty)}(y) \int I_{(0,y)}(x_2) dx_2 \text{ [1P.] } \\ &= \lambda^2 \exp(-\lambda y) I_{(0,\infty)}(y) \int_0^y dx_2 \text{ [0.5P.] } \\ &= \lambda^2 \exp(-\lambda y) y I_{(0,\infty)}(y) \text{ [0.5P.] } \end{aligned}$$

Aufgabe 9 (12 Punkte)

Sei $\mathbf{X}$ multivariat normalverteilt mit $\mu = (4, 2, 3)$ und Kovarianzmatrix

$$\Sigma = \begin{pmatrix} 2 & \frac{1}{2} & -2 \\ A & \frac{1}{2} & 0 \\ -2 & 0 & B \end{pmatrix}$$

- (a) Geben Sie A an und schätzen Sie B bestmöglichst ab.

[4]

Lösung:

$A = \frac{1}{2}$ wegen Symmetrie [1P.]

$\det(\Sigma) \geq 0$ [1P.] $\implies B - 2 - \frac{1}{4}B \geq 0$ [1P.] $\implies \frac{3}{4}B \geq 2$ [0.5P.] $\implies B \geq \frac{8}{3}$ [0.5P.]

Alternativ (ein Punkt weniger): $\rho_{13} = \frac{\text{Cov}(X_1, X_3)}{\sqrt{\text{Var}(X_1)\text{Var}(X_3)}} = \frac{-2}{\sqrt{2 \cdot B}} \geq -1$ [1P.] $\implies B \geq 2$ [1P.]

Alternativ $B \geq 0$ [1P.] oder $B \geq 0.5$ wegen Teilaufgabe B. [1P.] [0.5P.]

- (b) Welche Verteilung hat $Y = \sum_{i=1}^3 X_i$? Begründen Sie.

[4]

Lösung:

$Y \sim N$ [0.5P.] da lineare Transformation [0.5P.]

$E(Y) = \sum E(X_i) = 9$ [1P.]

$\text{Var}(Y) = \sum_i \text{Var}(X_i) + \sum_i \sum_j \text{Cov}(X_i, X_j) = B - \frac{1}{2}$ [2P.]

- (c) Geben Sie $\mathbb{E}(\exp(X_3) \cdot (X_2 - \frac{1}{2}))$ an. Begründen Sie.

[4]

Lösung:

X_2 und X_3 sind stoch. unabhängig, da $\text{Cov}(X_2, X_3) = 0$ [1P.]

Damit sind auch $(X_2 - \frac{1}{2})$ und $\exp(X_3)$ stochastisch unabhängig [1P.]

Da $E((X_2 - \frac{1}{2})) = 0$ [1P.] folgt $\mathbb{E}(\exp(X_3) \cdot (X_2 - \frac{1}{2})) = 0$ [1P.]