

Klausur
Deskriptive Statistik & Explorative Datenanalyse - Nachklausur
am 12.04.2024

Name: _____

Matrikelnummer: _____

Studiengang (Hauptfach):

☐ Bachelor Informatik

☐ Bachelor Mathematik

☐ Andere: _____

Ich bestätige, dass ich die Hinweise auf der zweiten Seite zur Kenntnis genommen und die Klausurangabe auf Vollständigkeit überprüft habe.

Unterschrift: _____

Aufgabe	Punkte	Erreichte Punkte
1	27	
2	20	
3	15	
4	15	
5	9	
6	11	
Gesamt	97	


Hinweise zur Klausur:

1. Überprüfen Sie zunächst, ob Ihre Klausurangabe vollständig ist. Die Klausurangabe sollte aus 18 Seiten (ohne diese Seite und das Deckblatt) mit 6 Aufgaben bestehen. Es können maximal 97 Punkte erreicht werden.
2. Die Bearbeitungszeit beträgt 90 Minuten. In den ersten 30 Minuten und in den letzten 15 Minuten ist keine vorzeitige Abgabe vorgesehen.
3. Es sind folgende Hilfsmittel zugelassen:
 - *open book*-Klausur: Vorlesungsunterlagen, Bücher, eigene Notizen, usw.
 - Nichtprogrammierbarer Taschenrechner
 - Bei Bedarf ein Wörterbuch
4. Ein nachvollziehbarer Lösungsweg und die korrekte Verwendung des entsprechenden Fachvokabulars ist Voraussetzung zum Erlangen der vollen Punktzahl. Bei Textantworten reichen nachvollziehbar formulierte Stichpunkte aus, vollständige Sätze sind nicht nötig.
5. Falls der Platz bei der jeweiligen Aufgabe nicht ausreicht benutzen Sie bitte die leeren Seiten am Ende der Angabe. Stellen Sie sicher dass alle Ihre Antworten klar und eindeutig der jeweiligen Teilaufgabe zugeordnet werden können. Falls nötig bekommen Sie weitere Zusatzblätter von der Klausuraufsicht. Kennzeichnen Sie diese unbedingt mit Ihrem Namen und Ihrer Matrikelnummer, da sie sonst nicht gewertet werden können.
6. Es darf nicht mit Rot- oder Bleistift geschrieben werden.
7. Legen Sie einen Lichtbildausweis und einen aktuell gültigen Studierendenausweis bereit.
8. Schalten Sie Telephone und andere elektronische Geräte wie Smartwatches o.ä. aus und legen Sie sie in Ihren Tasche oder Rucksack.
9. Bei Unterschleif erfolgt eine Meldung an das Prüfungsamt. Sie sind verpflichtet, durch Ihr Verhalten jegliche Missverständnisse diesbezüglich auszuschließen.
10. Verlassen Sie den Prüfungsraum erst, nachdem Sie der Aufsicht die Klausur persönlich übergeben haben. Für den Eingang der kompletten Klausur bei der Aufsicht sind Sie selbst verantwortlich.
11. Bitte verlassen Sie nach der Klausur den Hörsaaltrakt zügig und leise, damit Sie die Teilnehmenden anderer Klausuren nicht stören.

Viel Erfolg!

Aufgabe 1 (27 Punkte)

Betrachten Sie die untenstehende Grafik¹ und beantworten Sie die folgenden Fragen **in Stichpunkten unter Verwendung der in der Vorlesung eingeführten Fachbegriffe**.



(a) Auf welche Grundgesamtheit beziehen sich die hier visualisierten Daten?

[1]

(b) Geben Sie die Art der Datengewinnung und die Erhebungsform an, aus der diese Daten (vermutlich) stammen.

[2]

¹Übersetzung der englischen Beschriftung: Titel links oben: "Wo wurden US-Amerikaner geboren?"; Legende der Grafik oben rechts: "außerhalb der USA" in orange, "woanders in den USA" in hellblau, "im selben Bundesstaat" in dunkelblau, "keine Daten verfügbar" in hellgrau

- (c) **Betrachten Sie zunächst nur den mit "AK" (= "Alaska") betitelten Teil der Grafik oben rechts neben dem Titel.** Analysieren Sie diesen Teil der Grafik mit den Begriffen der in der Vorlesung besprochenen *grammar of graphics* – geben sie die in diesem Teil der Grafik verwendeten ästhetischen Zuordnungen der visualisierten Merkmale auf die verwendeten Geometrien an. [5]
- (d) **Betrachten Sie jetzt die gesamte Grafik für alle Bundesstaaten.** Analysieren Sie die nun die gesamte Grafik mit den Begriffen der in der Vorlesung besprochenen *grammar of graphics*: Welche *zusätzlichen* grafischen Mittel werden hier benutzt um welche *zusätzlichen* Merkmale zu visualisieren? [3]
- (e) Geben Sie für die visualisierten Merkmale und Statistiken jeweils das Skalenniveau an. Begründen Sie Ihre Antworten kurz in Stichpunkten. [5]

- (f) Was für eine Art von Farbskala wird hier verwendet? Begründen Sie Ihre Antwort. [2]
- (g) Geben Sie für die folgenden Aussagen an, ob diese zutreffen, nicht zutreffen, oder auf Basis der Informationen in der Grafik nicht entscheidbar sind. Begründen Sie Ihre Antworten kurz. [3]
1. *“In den Jahren 1850 und 2020 lebten in Kalifornien (CA, 4. Reihe von oben ganz links) jeweils etwa gleich viele Menschen, die außerhalb der USA geboren wurden.”*
 2. *“Der Anteil an Menschen in Florida (FL, ganz unten rechts), die nicht in Florida geboren wurden, war im Jahr 2020 etwa gleich groß wie im Jahr 1850.”*
- (h) Nehmen Sie an, dass Ihnen die der Grafik zugrundeliegenden Daten für das Jahr 2020 in absoluten Zahlen in Tabellenform vorliegen. Sie interessieren sich dafür, wie gleichmäßig oder ungleichmäßig sich Personen, die nicht in den USA geboren wurden (“born outside US”), im Jahr 2020 auf die verschiedenen Bundesstaaten der USA verteilen. Geben Sie eine aus [6]

der Vorlesung bekannte Maßzahl an, mit der Sie diese Frage beantworten können, geben Sie die Formel für diese Maßzahl an, und geben Sie in Stichpunkten an, was die Größen in der Formel in diesem konkreten Fall bedeuten und wie Sie diese in diesem konkreten Fall berechnen würden.

Aufgabe 2 (20 Punkte)

Baum des Jahres 2024 ist die Mehlsbeere. In einem Gutachten wird das Höhenwachstum dieser Bäume betrachtet.

Das Merkmal X beschreibt den Bodentyp ("Sandboden" $\simeq 1$ und "Schwarzerde" $\simeq 2$); das Merkmal Y beschreibt den Höhenwuchs (" $\leq 8m$ " $\simeq 0$ und "> 8m" $\simeq 1$).

Daraus ergibt sich folgende Kreuztabelle:

	$Y = 0$	$Y = 1$
$X = 1$	4	3
$X = 2$	2	3

- (a) Bestimmen Sie die Kontingenztafel der relativen Häufigkeiten sowie die Randverteilungen von X und Y . [4]

- (b) Berechnen Sie die Verteilung der Höhenklasse für Bäume, die auf Sandböden wachsen. [1]

- (c) Berechnen und interpretieren Sie das Odds-Ratio. [2]


- (d) Berechnen Sie den korrigierten Kontingenzkoeffizienten. [5]

Der Variable Y liegt eine exakte Höhenmessung zugrunde, die entsprechenden Auspägungen der Baumhöhe Z in Meter und des Bodentyps X werden im Folgenden angegeben:

i	1	2	3	4	5	6	7	8	9	10	11	12
X_i	1	1	1	1	1	1	1	2	2	2	2	2
Z_i	6.0	7.0	7.0	7.0	8.0	10.0	12.0	6.0	7.5	8.0	9.5	11.0

- (f) Zeichnen Sie einen einfachen Boxplot der Baumhöhe Z . Geben Sie auch Ihre Zwischenergebnisse an. [4]

- (g) Die folgende Grafik zeigt die ROC-Kurve für den Zusammenhang zwischen der Baumhöhe in Metern Z und dem Bodentyp X , wobei hier "Schwarzerde" ($X = 2$) als "positiver Fall" definiert ist. [4]



1. Bewerten Sie, wie erfolgreich der Bodentyp auf Basis der Baumhöhe vorhergesagt werden kann. Begründen Sie Ihre Antwort.
2. Erläutern Sie in Stichpunkten, mit Rückbezug auf die konkret vorliegenden Daten, warum diese ROC-Kurve ganz oben rechts ein diagonal verlaufendes Segment enthält.

Aufgabe 3 (15 Punkte)

Zur Auswahl stehen $N + 1$ Stapel $s_0, s_1, \dots, s_N$ von Roulettechips mit unterschiedlichen Anteilen von roten und grünen Chips.

Jeder Stapel enthält insgesamt N Chips und im Stapel s_j sind genau j rote und $N - j$ grüne Chips in zufälliger Reihenfolge.

Aus den $N + 1$ Stapeln von Chips wird zufällig einer ausgewählt und aus diesem Stapel werden zufällig ohne Zurücklegen zwei Chips gezogen.

Bezeichne $S_j; j \in 0, \dots, N$ das Ereignis, dass Stapel s_j ausgewählt wurde.

Sei $R_i; i = 1, 2$ das Ereignis, dass der i -te ausgewählte Chip rot ist.

Hinweise: $\sum_{j=0}^N j = N(N + 1)/2$ und $\sum_{j=0}^N j^2 = N(N + 1)(2N + 1)/6$

(a) Geben Sie $P(R_1|S_j)$ an. Was bedeutet diese Größe inhaltlich?

[1]

(b) Zeigen Sie, dass $P(R_1) = \frac{1}{2}$

[3]

(c) Bestimmen Sie $P(R_1 \cap R_2 | S_j)$. Vereinfachen Sie den Ausdruck so weit wie möglich. [4]

(d) Berechnen Sie die Wahrscheinlichkeit, dass der erste und der zweite Chip beide rot sind. [7]

Aufgabe 4 (15 Punkte)

Betrachten Sie die unabhängig und identisch $\mathcal{G}(\pi)$ -verteilten Zufallsvariablen $X_1, \dots, X_n$.

Hinweis: Für $Z \sim \mathcal{N}(0, 1)$ gilt: $F_Z(1.2772) = 0.8992$, $F_Z(1.7722) = 0.9618$, $F_Z(2.2771) = 0.9886$

- (a) Sei $E(X_i) = 28$ und $n = 20$. Mit welcher approximativen Wahrscheinlichkeit liegt der Mittelwert dieser Stichprobe unter 14? [8]

- (b) X_i soll beschreiben, wie oft Angler Fischer-Fritz an Tag i seine Angel auswerfen muss bis zum ersten Mal ein Fisch anbeißt. [7]

Nennen Sie alle Annahmen, die gelten müssen, damit

$$X_i \stackrel{i.i.d.}{\sim} \mathcal{G}(\pi); i = 1, \dots, n$$

gilt. Beschreiben Sie jeweils in Stichpunkten was in dieser konkreten Situation die inhaltliche Bedeutung der jeweiligen Annahme ist. Geben Sie außerdem jeweils an, wodurch die jeweilige Annahme in diesem Beispiel verletzt sein könnte.

Aufgabe 5 (9 Punkte)

Die Zufallsvariable X folgt einer Beta-Verteilung mit den Parametern a und b . Im folgenden betrachten wir die Zufallsvariablen

$$Y = (X + 2)^{-1}$$

und

$$Z = Y \cdot (X^2 + 3X + 2)$$

- (a) Berechnen Sie die Dichtefunktion der Verteilung von Y .

[5]

- (b) Bestimmen Sie den Erwartungswert und die Varianz von Z für $a = 2 = b$.

[4]

Aufgabe 6 (11 Punkte)

Beantworten Sie die folgenden Fragen, **jeweils mit kurzer Begründung in Stichpunkten unter Verwendung der relevanten Fachbegriffe oder durch Rechnung mit nachvollziehbarem Ansatz**.

- (a) Am Bahnhof Hintertupfing halten pro Stunde im Durchschnitt 3 Züge. Mit welcher parametrischen[3] Verteilung könnte man die Anzahl der Züge, die in einem gegebenen Zeitintervall dort halten, modellieren? Wie groß ist unter dieser Verteilungsannahme die Wahrscheinlichkeit, dass in einem gegebenen 20 Minuten Intervall mindestens ein Zug in Hintertupfing hält?
- (b) Für die Zufallsvariable X mit unimodaler Dichte $f_X(x)$ gilt: $E(X) = 55$, $F_X(40) = 0.5$, $\text{Var}(X) = 9^2$. [5]
1. Wie groß ist $P(X > 40)$?
 2. Sie ziehen eine umfangreiche Zufallsstichprobe mit unabhängigen Werten von X . Was ist wahrscheinlicher: Dass die Stichprobe mehr Ausreißer mit besonders großen Werten enthält oder dass sie mehr Ausreißer mit besonders kleinen Werten enthält?
 3. Geben Sie eine obere Schranke für die Wahrscheinlichkeit an, mit der Werte von X , die kleiner als 40 oder größer als 70 sind, auftreten.

- (c) Ein Diagnoseverfahren für eine Krankheit hat eine Sensitivität von 95% und eine Spezifität von 99%. Die Odds für eine Erkrankung sind in der Bevölkerung bei 1 : 999. Wie groß ist die Wahrscheinlichkeit, dass eine zufällig ausgewählte Person, bei der die Krankheit diagnostiziert wurde, tatsächlich krank ist? [3]

Zusatzblatt

Zusatzblatt

Zusatzblatt