

Hinweise:


- Abgabeschluss für bewertete Aufgaben ist immer Montag 12:00 der Folgewoche.
Nur Abgaben, die rechtzeitig und formgerecht (PDF in DIN A 4 Hochformat, Dateigröße < 20 MB) über die Moodle-Seite zur Veranstaltung erfolgen, werden akzeptiert und bewertet.
Bewertete Aufgaben enthalten im Titel **in rot** den Zusatz, wie viel Punkte sie maximal bringen.
- Gruppenarbeit ist nicht zulässig und wird als versuchter Unterschleif an das Prüfungsamt gemeldet.
- Nur nachvollziehbare, lesbare Lösungen können gewertet werden.
Geben Sie für alle Berechnungen auch ihren formalen Ansatz und wesentliche Zwischenergebnisse an, um die volle Punktzahl zu erreichen.
Wo Sie auf Sätze und Definitionen aus der Veranstaltung zurückgreifen, sollte klar erkennbar sein, was Sie verwendet haben.
- Fassen Sie sich bei Textantworten kurz – Stichpunkte genügen.
Formulieren Sie präzise mit korrekter Verwendung der in der Vorlesung eingeführten Fachbegriffe um die volle Punktzahl zu erreichen.
- Runden Sie Ihre Ergebnisse auf 2 Nachkommastellen und kürzen Sie Brüche vollständig.
- Wenn Sie bei einer Teilaufgabe Ergebnisse aus vorigen Teilaufgaben benötigen und diese nicht ermitteln konnten, geben Sie ggf. an, mit welchen alternativen Werten Sie stattdessen weiterarbeiten.
- Grafiken und Berechnungen können Sie gegebenenfalls auch mit R oder Python erzeugen bzw. durchführen.
Übertragen Sie in diesem Fall den vollständigen, lauffähigen (!) und kommentierten Code sowie den relevanten Output in Ihre abgegebene Lösung.
- In der Angabe bezeichnet $\log(x) = \log_e(x)$ immer den natürlichen Logarithmus zur Basis $e \approx 2.72$.

Eigenständigkeit:

Durch die Abgabe zur Benotung erklären Sie, dass Sie die eingereichte Lösung selbständig verfasst und keine anderen als die angegebenen Hilfsmittel benutzt haben. Die Stellen der Arbeit, die dem Wortlaut oder dem Sinn nach aus anderen Werken (dazu zählen auch Internetquellen oder von Künstlicher Intelligenz verfasste Texte und Berechnungen) übernommen wurden, haben Sie unter Angabe der Quelle kenntlich gemacht.

Aufgabe 1 Grundbegriffe: ATP Grand Slam (9 P)

Die untenstehende Grafik zeigt Karriereverläufe erfolgreicher Tennisprofis bis 2016. Als *Grand Slam*-Turniere werden die vier wichtigsten jährlichen Tennisturniere der ATP und WTA bezeichnet – die *Australian*, *French*, und *US Open* sowie *Wimbledon*.



Quelle: [Financial Times](#) (2016)

Beantworten Sie folgende Fragen zur Grafik, bei 2. und 3. **jeweils mit kurzen Begründungen**:

1. [1 P] Aus welcher *Grundgesamtheit* stammen die Daten der in dieser Grafik dargestellten *Untersuchungseinheiten*?
2. [6 P] Welche *Merkmale* dieser Untersuchungseinheiten werden in dieser Grafik dargestellt? Was ist (jeweils) das zugehörige *Skalenniveau* und der zugehörige *Merkmalsraum*?
3. [2 P] Charakterisieren sie die Erhebungsart, die den Informationen in der Grafik zu Grunde liegt, bezüglich *Umfang* und *Datenform*.

Aufgabe 2 Drei Säulen der Statistik: Deskription, Exploration und Induktion

In der Vorlesung haben Sie die drei Säulen der Statistik kennengelernt. Erläutern Sie mit eigenen Worten die Begriffe deskriptive, explorative und induktive Statistik. Stellen Sie die Zielsetzungen und Unterschiede dar.

Lösung

Deskription

- **Beschreibung** von betrachteten Merkmalen (z.B. Häufigkeiten von Ausprägungen)
- **Graphische Datenaufbereitung** (Diagramme, Verlaufskurven, Häufigkeitstabellen etc.), insbesondere relevant für die Präsentation umfangreichen Datenmaterials
- **Erster Eindruck** bzw. Ideen zur weiteren Analyse
- **Datenvalidierung**: Methoden der deskriptiven Statistik ermöglichen das Erkennen von Fehlern im Datensatz (z.B. durch falsche Übertragung vom Fragebogen).
- **Keine Rückschlüsse** auf die Grundgesamtheit über Erhebungsdaten möglich

Exploration

- **Suche nach Strukturen** in den Daten (ohne stochastische Methoden)
- Formulierung von Hypothesen für das den Daten zugrunde liegende stochastische Modell (wichtig für die Induktion)

Induktion

- **Ziehung von Schlüssen** von den Daten (Stichprobe) auf Grundgesamtheit
- Verwendung entsprechender **statistischer Methoden**
- Die Schlüsse basieren auf einem wahrscheinlichkeitstheoretischem **Modell**.
- Vorgehensweise: Fragestellung → Formulierung eines stochastischen Modells (nicht datenbasiert) → Punktschätzung, Konfidenzintervalle, Tests

Aufgabe 3 Grundbegriffe: Grundgesamtheit, Merkmale und Skalenniveau

Bestimmen Sie für die folgenden Sachverhalte die Grundgesamtheit, die statistischen Einheiten und Beobachtungen, die untersuchten Merkmale und die theoretisch möglichen Merkmalsausprägungen. Überlegen Sie sich weitere erfassbare Merkmale dieser Grundgesamtheiten, die für die jeweilige Fragestellung relevant sein könnten.

1. Die Besucherzahl der Münchner Residenzkonzertere im Jahr 2023 wird vom Veranstalter durch die Anzahl der verkauften Karten dokumentiert.
2. Es soll erhoben werden, welche Verkehrsmittel die Studierenden der LMU hauptsächlich nutzen, um zur Uni zu kommen.
3. Die räumliche Verteilung aller amtlich betriebener Stationen zur Messung von Luftschadstoffen in Bayern soll erhoben werden. Dazu werden die GPS-Koordinaten bei den zuständigen Behörden erfragt.

Lösung

Grundbegriffe & Theorie:

- **Merkmalsträger:**
 - Einzelobjekt einer statistischen Untersuchung (kleinste betrachtete Einheit)
 - genau definierter Gegenstand, Vorgang, Person o.ä.
 - Notation: $\omega_i, i = 1, \dots, n$
- **statistisches Merkmal:**
 - Eigenschaft eines Merkmalsträgers
 - Notation:
 - * X : Merkmal
 - * $a_1, \dots, a_k$: mögliche Merkmalsausprägungen
 - * $x_1, \dots, x_n$: beobachtete Ausprägungen bei den n betrachteten Merkmalsträgern
- **Grundgesamtheit:**
 - Menge aller relevanten Merkmalsträger
 - Notation: $\Omega = \{\omega_1, \dots, \omega_n\}$
 - Bemerkung: Ω kann auch (abzählbar) unendlich sein.
- **Merkmalsraum (Zustandsraum):**
 - Menge aller möglichen Merkmalsausprägungen
 - Notation: $\mathbb{S} = \{a_1, \dots, a_k\}$
 - Bemerkung: $\mathbb{S}$ kann auch überabzählbar unendlich sein (z.B. $\mathbb{S} = \mathbb{R}$).
- **Kodierung des Zustandsraumes:**
 - eindeutige Abbildung $C : \mathbb{S} \rightarrow \mathbb{R}$ (in der Regel $\mathbb{N}$)
 - rechentechnisch effizienter
- Damit lässt sich ein **Merkmal** als eindeutige Abbildung $X : \Omega \rightarrow \mathbb{R}, \omega_i \mapsto x_i$. beschreiben.
- Bemerkungen:
 1. später: Formalisierung von X als Zufallsvariable
 2. meist Beschränkung auf Teilgesamtheit (Teilpopulation) $T \subsetneq \Omega$, spätere Formalisierung von T als Stichprobe

Lösung:

1.
 - Ω : Residenzkonzerte in München im Jahr 2023
 - ω_i : Residenzkonzert i in München im Jahr 2023
 - X : Anzahl der verkauften Karten bei einem Residenzkonzert
 - $\mathbb{S} = \mathbb{N}_0$
 - Weitere erfassbare Merkmale z.B.: X_2 : Art des Konzertes, X_3 : Datum des Konzerts, ...
2.
 - Ω : Studierende der LMU
 - ω_i : Studierende:r i an der LMU
 - X : primäres Verkehrsmittel, das zur Fahrt zur Uni genutzt wird
 - $\mathbb{S} = \{\text{Öffentliche: Bus, Öffentliche: S-Bahn, Öffentliche: U-Bahn, Fahrrad, Auto, zu Fuß, Sonstige}\}$
 - Weitere erfassbare Merkmale z.B: X_2 : Studienfach, X_3 : Alter, X_4 : Geschlecht, ...
3.
 - Ω : Amtlich betriebene Stationen zur Messung von Luftschadstoffen in Bayern

- ω_i : Station i
- $Z = (X, Y)$; X : X-Koordinate; Y : Y-Koordinate
- $\mathbb{S} = \mathbb{S}_X \times \mathbb{S}_Y = [47, 51] \times [9, 14]$
- Weitere erfassbare Merkmale z.B.: Z_2 : Baujahr der Station, Z_3 : Ballungsraum ja/nein, Z_4 : Entfernung zur nächsten Industrieanlage, ...

Aufgabe 4 Merkmale: Skalenniveau und Diskret vs. Stetig

Geben Sie (mit kurzer Begründung) an, ob die folgenden Merkmale diskret oder stetig sind und welches Skalenniveau sie besitzen:

1. Geschlecht
2. Temperatur in Grad Celcius ($^{\circ}\text{C}$)
3. Temperatur in Grad Kelvin ($^{\circ}\text{K}$)
4. Familienstand
5. Alter
6. Religionszugehörigkeit
7. Produzierte Stückzahl pro Tag
8. Monatseinkommen
9. systolischer Blutdruck
10. Schulnote
11. erreichte Prozentzahl an Klausurpunkten,
12. Michelinster-Bewertung von Restaurants
13. Wohnfläche einer Mietwohnung
14. Kraftstoffverbrauch eines PKW auf 100 km

Lösung

Theorie: Wie lassen sich statistische Merkmale kategorisieren?

Klassifikationsmöglichkeiten für Merkmale

Unterscheidung nach ...		
... Quantifizierbarkeit der Ausprägungen	Qualitative Merkmale: • nur zuordenbar (einstufig)	Quantitative Merkmale: • mess- oder zählbar
... Anzahl der Ausprägungen*	Diskrete Merkmale: • Beispiele: Wohnort, Name • höchstens abzählbar unendlich viele mögliche Ausprägungen • Beispiele: Gehaltsklassen, Kaufverhalten	Stetige Merkmale: • Beispiele: Alter, Körpergröße • überabzählbar unendlich viele mögliche Ausprägungen • Beispiele: Geschwindigkeit, Gewicht

Unterscheidung nach ...		
... Direktheit der Informationsgewinnung	Beobachtbare Merkmale: • können direkt erhoben werden • Beispiel: Abiturnote	Latente Merkmale: • Operationalisierung über Indikatoren/Items notwendig • Beispiele: Bildungsgrad, Kreativität, Nutzen
... Skalenniveau	siehe unten	

Bemerkung:

- Es gibt Zwischenformen, sogenannte *quasi-stetige Merkmale*. Diese eigentlich diskreten Merkmale haben so viele mögliche Ausprägungen, dass sie wie stetige Merkmale behandelt werden können (z.B. Alter, Einkommen).
- Stetige Merkmale können durch Kategorisierung der Merkmalsausprägungen (Klassenbildung) in diskrete Merkmale transformiert werden.

Charakterisierung der Skalenniveaus

	Natürliche Reihenfolge	Interpretierbarkeit von Differenzen	Natürlicher Nullpunkt	Nat. Einheit
Nominalskala	nein	nein	nein	nein
Ordinalskala	ja	nein	nein	nein
Intervallskala	ja	ja	nein	nein
Verhältnisskala	ja	ja	ja	nein
Absolutskala	ja	ja	ja	ja

Lösung:

- Geschlecht (nominal, diskret),
- Temperatur in Celcius (intervallskaliert, stetig),
- Temperatur in Kelvin (verhältnisskaliert, stetig),
- Familienstand (nominal, diskret),
- Alter (verhältnisskaliert, quasi-stetig),
- Religionszugehörigkeit (nominal, diskret),
- Stückzahl in der Produktion (absolutskaliert, diskret),
- Monatseinkommen (verhältnisskaliert, quasi-stetig),
- Systolischer Blutdruck (verhältnisskaliert, stetig),
- Schulnote (ordinal, diskret),
- erreichte Prozentzahl an Klausurpunkten (absolut, diskret (quasi-stetig)),
- Michelinster-Bewertung von Restaurants (ordinal, diskret),
- Wohnfläche (verhältnisskaliert, stetig),
- Kraftstoffverbrauch eines PKW auf 100 km (verhältnisskaliert, stetig)

Aufgabe 5 Erhebungsarten: Methode, Datenform und Umfang

Erläutern Sie geeignete Erhebungsarten (Methode, Datenform, Umfang) für die folgenden Sachverhalte.

1. Testen der Wirkung eines neuen Düngemittels an Ackerpflanzen
2. Einschätzung der eigenen Fähigkeit zum sicheren Autofahren durch KFZ-halter:innen im Vergleich zu anderen Autofahrer:innen
3. Schätzung der durchschnittlichen Lebensdauer von Leuchtstoffröhren

Lösung

Theorie: Erhebungsarten:

Methode:

- **Beobachtung:**

- Datengewinnung durch Erfassen von Sachverhalten, die nicht gesteuert werden
- Systematisierung durch Beobachtungsprotokoll (zum Festhalten des Beobachteten) als Erhebungsinstrumentarium
- Verdeckte Beobachtung: Der Beobachter gibt sich nicht zu erkennen.
- Teilnehmende Beobachtung: Der Beobachter nimmt aktiv am Geschehen teil.

- **Befragung:**

- mündlich, schriftlich, telefonisch, Internet
- mit bzw. ohne Interviewer
- Grundlage: Fragebogen

- **Experiment:**

- Erzeugung der Daten durch Simulation der interessierenden Situation
- Eine interessierende Situation wird künstlich erzeugt, um eine direkte oder indirekte (über Befragung) Beobachtung zu ermöglichen.
- Anwendung vor allem in Naturwissenschaften, aber auch Sozialwissenschaften, Psychologie, Wirtschaftswissenschaften (Entscheidungssituationen)

Datenform:

- **Querschnittanalyse:** Querschnitt durch eine Population zu festem Zeitpunkt
- **Zeitreihe:** Beobachtung eines Objektes über einen längeren Zeitraum hinweg (mehrere Messzeitpunkte)
- **Panel bzw. Längsschnittanalyse:** Beobachtung einer (Teil-)Population (mehrere Objekte) über mehrere Messzeitpunkte

Umfang

- **Vollerhebung (Totalerhebung):**

- Untersuchung aller statistischen Einheiten der Grundgesamtheit
- Beispiel: Volkszählung
- Vorteil: Man erhält vollständige Informationen über die Grundgesamtheit, mögliche Unsicherheiten aufgrund fehlender Informationen sind somit ausgeschlossen.
- Nachteil: Antwortverweigerungen, Kosten, eventuell nicht durchführbar (z.B. bei zerstörender Materialprüfung oder bei hypothetischen Grundgesamtheiten)

- **Teilerhebung (Stichprobe):**

- Die Untersuchung beschränkt sich auf eine Teilgesamtheit, die für die Grundgesamtheit repräsentativ sein soll.
- Verschiedene Auswahlmöglichkeiten: Quotenauswahl (repräsentativer Querschnitt), Zufallsauswahl (rein oder geschichtet)
- Vorteil: geringere Kosten, generell weniger Aufwand als Vollerhebung
- Problem: Merkmalsausprägungen für Grundgesamtheit unbekannt, Stichprobenfehler durch Ungewissheit der Repräsentativität

Herkunft

- **Primärerhebung.** Die Erhebung wird speziell im Hinblick auf die aktuelle Fragestellung durchgeführt.
- **Sekundärerhebung.** Es wird auf Daten aus anderen Erhebungen zu ähnlichen Fragestellungen zurückgegriffen, z.B. auf bereits vorhandene Originaldaten aus dem statistischen Jahrbuch.
- **Tertiärerhebung:** Für die Untersuchung stehen nur bereits transformierte oder komprimierte Daten zur Verfügung, z.B. einzelne Lagemaße wie Mittelwerte.

Lösung:

1. Testen der Wirkung eines neuen Düngemittels an Ackerpflanzen: Experiment, Panel, Stichprobe
2. Einschätzung der eigenen Fahrtüchtigkeit durch Führerscheininhaber im Vergleich zu anderen Autofahrern: Befragung, Querschnittanalyse, Stichprobe
3. Schätzung der durchschnittlichen Lebensdauer von Leuchtstoffröhren: Beobachtung, Panel, Stichprobe

Aufgabe 6 Auswahlverfahren: Geschichtete und Klumpen-Stichproben

Betrachten Sie folgende Beispiele. Welches Auswahlverfahren würden Sie wählen? Begründen Sie Ihre Entscheidung.

1. Eine Untersuchung soll Aufschluss über den durchschnittlichen Quadratmeterpreis von Mietwohnungen in einer Stadt geben. Sie wissen, dass man die Stadt in drei Regionen einteilen kann, in denen die Quadratmeterpreise jeweils ähnlich sind: Region 1: Reiche Villengegend, Region 2: Mittlere Lage, Region 3: Plattenbausiedlung.
2. Zur Bestimmung des Zigarettenkonsums von Hauptschülern in der 8. Klasse soll eine Erhebung mit Hilfe von Fragebögen durchgeführt werden.

Lösung

Theorie: Bei Teilerhebungen wird noch weiter unterschieden in:

- **Nicht zufällige Auswahlverfahren:**
 - Willkürliche Auswahl
 - Bewusste Auswahl
 - Quotenauswahl
- **Zufällige Auswahlverfahren:**
 - Einfache Zufallsstichprobe:
 - * Alle Auswahlmöglichkeiten haben die gleiche Wahrscheinlichkeit.
 - Geschichtete Stichprobe:
 - * uneingeschränkte Zufallsauswahl aus den einzelnen Schichten
 - * Alle Schichten sind (mit im Vorhinein festgelegter Anzahl) in der Stichprobe vertreten.

- * Effizienzgewinn, falls die relevanten Merkmale innerhalb der Schichten homogen (Elemente innerhalb einer Schicht ähnlich) und zwischen den Schichten heterogen (Elemente aus verschiedenen Schichten unterschiedlich) sind
- Klumpenstichprobe
 - * Ziehen ohne Zurücklegen von (ganzen) Gruppe
 - * reduzierter Erhebungsaufwand
 - * Effizienzgewinn, falls jeder einzelne Klumpen ein gutes Abbild der Grundgesamtheit ist (Klumpen sind in sich heterogen, untereinander jedoch homogen.)

Lösung:

1. Eine Möglichkeit ist die Ziehung einer einfachen Zufallsstichprobe von beispielsweise 300 Wohnungen. Da aber bekannt ist, dass die Mietpreise stark von der Region abhängig sind, erscheint es sinnvoll, die Ziehung geschichtet nach den Regionen durchzuführen. Wenn man nun aus allen drei Regionen einzeln eine Stichprobe zieht, kann man nicht nur Aufschluss über die Mietpreise in den einzelnen Regionen gewinnen, sondern auch das Gesamtmittel des Quadratmetermietpreises effizienter schätzen, d.h. mit geringerer Varianz.
2. Bei der Ziehung einer Stichprobe ist es sehr aufwendig, einzelne Schüler direkt auszuwählen. Voraussetzung hierfür wäre, dass eine Liste von Schülern der 8. Klasse vorliegt, aus welcher dann zufällig Schüler gezogen und anschließend befragt werden könnten. Eine derartige Liste ist jedoch selten vorhanden oder wird aus Datenschutzgründen nicht zur Verfügung gestellt. Daher liegt es nahe, jeweils ganze Klassen zu befragen. Dazu ist nur eine Zufallsauswahl von Schulklassen zu treffen. Bei diesem Auswahlverfahren handelt es sich um eine Klumpenstichprobe.