

Klausur
Deskriptive Statistik und Wahrscheinlichkeitstheoretische Grundlagen
am 11. September 2025

Name: _____

Matrikelnummer: _____

Studiengang (Hauptfach):

- ☐ Bachelor Statistik und Data Science, Prüfungsordnung 2021
- ☐ Wechsel auf Bachelor Statistik und Data Science geplant
- ☐ Andere: _____

Ich bestätige, dass ich die Hinweise auf der zweiten Seite zur Kenntnis genommen und die Klausurangabe auf Vollständigkeit überprüft habe.

Unterschrift: _____

Aufgabe	Punkte	Erreichte Punkte
1	22	
2	22	
3	14	
4	14	
5	16	
6	17	
7	15	
Gesamt	120	


Hinweise zur Klausur:

1. Überprüfen Sie zunächst, ob Ihre Klausurangabe vollständig ist. Die Klausurangabe sollte aus 19 Seiten (ohne diese Seite und das Deckblatt) mit 7 Aufgaben bestehen.
2. Die Bearbeitungszeit beträgt 150 Minuten. In den ersten 30 Minuten und in den letzten 15 Minuten ist keine vorzeitige Abgabe vorgesehen.
3. Es können maximal 120 Punkte erreicht werden.
Ein nachvollziehbarer Lösungsweg und die korrekte Verwendung des entsprechenden Fachvokabulars ist Voraussetzung zum Erlangen der vollen Punktzahl.
4. Es sind folgende Hilfsmittel zugelassen:
 - Ein DIN A4 Blatt mit handschriftlichen Notizen auf Vorder- und Rückseite.
 - Verteilungsübersicht ohne zusätzliche Notizen oder Ergänzungen. Unterstreichungen und farbige Markierungen sind erlaubt.
 - Nichtprogrammierbarer Taschenrechner
 - Bei Bedarf ein Wörterbuch
5. Nur die in den vorgesehenen Bereichen des Prüfungsbogens eingetragenen Ergebnisse werden bepunktet; falls der Platz in einem der Bereiche nicht ausreicht, muss im betreffenden Bereich ein Verweis zur Lösung zu finden sein.
6. Runden Sie Ergebnisse auf drei Nachkommastellen.
7. Es darf nicht mit Rot- oder Bleistift geschrieben werden.
8. Legen Sie einen Lichtbildausweis und einen aktuell gültigen Studenausweis bereit.
9. Schalten Sie Telephone und andere elektrische Geräte aus.
10. Bei Unterschleif erfolgt eine Meldung an das Prüfungsamt. Sie sind verpflichtet, durch Ihr Verhalten jegliche Missverständnisse diesbezüglich auszuschließen.
11. Verlassen Sie den Prüfungsraum erst, nachdem Sie der Aufsicht die Klausur persönlich übergeben haben. Für den Eingang der kompletten Klausur bei der Aufsicht sind Sie selbst verantwortlich.
12. Bitte verlassen Sie nach der Klausur den Hörsaaltrakt zügig und leise, damit Sie die Teilnehmenden anderer Klausuren nicht stören.

Viel Erfolg!

Aufgabe 1 (22 Punkte)

Die folgende Abbildung zeigt die geschätzten Normalverteilungs-Dichtefunktionen der Mathematik-Scores eines standardisierten Tests für US-Schüler:innen von Kindergarten (K) bis Klasse 12 (Testzeitpunkt: Frühjahr)¹.



Beantworten Sie dazu die folgenden Teilaufgaben:

- (a) Geben Sie an, aus welcher Grundgesamtheit die in der Grafik gezeigten Untersuchungseinheiten vermutlich stammen. [1]

--

- (b) Analysieren Sie die Grafik mit den in der Vorlesung eingeführten Begriffen der *Grammar of Graphics*. Geben Sie dazu die verwendete(n) Geometrie(n) sowie die hier verwendeten ästhetische Zuordnungen (Mappings) aller gezeigten Merkmale oder Statistiken an. [4]

--

¹Northwest Evaluation Association (NWEA) – Growth Study 2020.


- (c) Geben Sie die Skalenniveaus der in der Grafik gezeigten Merkmale der Untersuchungseinheiten so genau wie möglich an. Begründen Sie Ihre Antworten in Stichpunkten. [4]

- (d) Welche Art von Farbskala wurde hier verwendet? Ist sie für diese Datensituation angemessen? [3]
Wie könnte sie verbessert werden?
Begründen Sie Ihre Antworten in Stichpunkten. Benutzen Sie die relevanten Fachbegriffe.


- (e) Interpretieren Sie die Grafik: Was können Sie allgemein über die Entwicklung der bedingten Mittelwerte und Varianzen der Test-Scores über die verschiedenen Klassenstufen aussagen? [2]

- (f) Bewerten Sie folgenden Aussagen – sind sie wahr, falsch, oder auf Basis der Grafik nicht entscheidbar? Begründen Sie Ihre Antworten in Stichpunkten. [4]

1. “Die meisten getesteten Schüler:innen sind im Kindergartenalter (Grade: K).”
2. “Etwa 3% der getesteten Schüler:innen in der ersten Klasse (Grade: 1) erreichen einen Score von ca. 180.”
3. “Etwa die Hälfte der getesteten Schüler:innen in der dritten Klasse erreichen Scores von über 200.”



- (g) Nehmen Sie nun an, der zugrundeliegende Originaldatensatz mit den Merkmalen **id** (Identifikationsnummer der Schülerin/des Schülers), **score** (erzieltes Testergebnis) und **grade** (Klassenstufe der Person zum Testzeitpunkt) enthält ein zusätzliches Merkmal **private**, das angibt, ob die Person einer öffentlichen Schule oder einer Privatschule angehört (Ausprägungen: "privat" / "öffentlich"). Der Datensatz enthält ca. 27 000 Testergebnisse. [4]
- Sie wollen zeigen, ob bzw. wie sich die Verteilung der Testergebnisse zwischen privaten und öffentlichen Schulen in den verschiedenen Klassenstufen unterscheidet.
- Beschreiben Sie eine dafür gut geeignete grafische Darstellung mit den Begriffen der *Grammar of Graphics* oder in **ggplot2**-Pseudocode. Benutzen Sie keine (Kern-)Dichteschätzungen.



Aufgabe 2 (22 Punkte)


Eine kombinierte Impf- und Diagnostikstudie untersucht den Zusammenhang zwischen **Impfung** (I) gegen und **Erkrankung** (E) an der schrecklichen *Fnu-fnu-Krankheit* sowie die prognostische Genauigkeit eines Biomarker-Scores S zur Diagnose der Erkrankung an derselben.

- (a) Die Studie lieferte folgende Ergebnisse: Von 5000 Geimpften erkrankten 25 Personen, während 60 von 5000 Ungeimpften erkrankten. [6]
- (i) Berechnen und interpretieren Sie die Differenz der relativen Häufigkeiten der Erkrankung zwischen den Ungeimpften und Geimpften.
 - (ii) Berechnen und interpretieren Sie die Odds Ratio $\gamma(E, \bar{E}|\bar{I}, I)$ für die gegebenen Daten.
 - (iii) Erläutern Sie kurz in Stichpunkten, warum sich die numerischen Werte dieser beiden Maßzahlen für die Wirksamkeit der Impfung so deutlich unterscheiden.

- (b) Die Studienleitung vermutet, dass das Alter der Patient:innen die Wirksamkeit der Behandlung beeinflusst, die entsprechende dreidimensionale Kontingenztafel ergibt: [8]

Alter < 50	Erkrankt	Gesund	Alter ≥ 50	Erkrankt	Gesund
Geimpft	10	2490	Geimpft	15	2485
Placebo	20	2480	Placebo	40	2460

- (i) Betrachten Sie jetzt nur die Gruppe der *Erkrankten*. Welcher der vier folgenden Mosaik-Plots zeigt den Zusammenhang zwischen *Alter* und *Behandlung* in dieser Gruppe? Bestimmen Sie die relevante 2×2 -Kontingenztafel und begründen Sie dann Ihre Antwort durch Ausschlussverfahren.



- (ii) Bestimmen Sie die Odds Ratios für jede Altersgruppe.
(iii) Interpretieren Sie Ihre Ergebnisse aus (ii). (Wie) Beeinflusst also das Alter die Wirkung der Behandlung?

Grid area for calculations and interpretation.

- (c) In einer Stichprobe mit drei Erkrankten (E_i) und vier Gesunden (G_i) wurden die folgenden diagnostischen Score-Werte S erhoben: [8]

$$\begin{aligned} S(E_i) : & \quad 95, 90, 69 \\ S(G_i) : & \quad 65, 71, 72, 74 \end{aligned}$$

- (i) Berechnen Sie die Sensitivität und Spezifität des diagnostischen Tests für den Schwellenwert $c = 70$.
- (ii) Bestimmen Sie das ROC-AUC des Scores S für diese Daten.
Hinweis: Keine Berechnung der ROC-Kurve nötig! Wie oft liegen die Scores einer/s Erkrankten über dem Score einer/s Gesunden?
- (iii) Interpretieren Sie Ihr AUC-Ergebnis. Wenn Sie bei (ii) auf kein Ergebnis gekommen sind, gehen Sie von einem AUC Wert von 0.743 aus. Stichpunkte genügen.
- (iv) Gehen Sie davon aus, dass das ROC-AUC für den Score S aus (iii) in der Population der Ungeimpften ermittelt wurde. Bei Geimpften hat der Score S von Erkrankten und Gesunden jeweils die gleichen Mittelwerte wie bei ungeimpften Erkrankten bzw. Gesunden, aber doppelt so große Standardabweichungen.
Wie verändert sich dadurch das ROC-AUC für die Geimpften gegenüber dem bei den Ungeimpften: steigt es, fällt es, bleibt es gleich, oder kann man das auf Basis der hier gelieferten Informationen nicht vorhersagen?
Begründen Sie Ihre Antwort in Stichpunkten. Keine Rechnung nötig oder gefragt.

Aufgabe 3 (14 Punkte)

Gegeben sei $\Omega = \{-3, -2, \dots, 2, 3\}$. Sei $A = \{-3\}$, $B = \{-2, -1\}$, $\mu(A) := \sum_{\omega \in A} a\omega^2$ sowie $f : \Omega \mapsto \mathbb{R}$ mit

$$f(\omega) = |\omega + 1|.$$

- (a) Geben Sie die von A und B erzeugte σ -Algebra $\mathcal{F} = \sigma(\{A, B\})$ an.

[3]

- (b) Geben Sie das Bild $f(\mathcal{F})$ an. Ist $f(\mathcal{F})$ eine σ -Algebra über $\Omega' = \{0, 1, \dots, 4\}$?


[4]

- (c) Bestimmen sie a so, dass μ ein Wahrscheinlichkeitsmaß ist.

[3]

(d) Berechnen Sie $\int_B f d\mu$.

[4]



Aufgabe 4 (14 Punkte)

Die gemeinsame Dichte von X und Y sei

$$f_{X,Y}(x,y) = I_{(0,1)}(x)I_{(0,1)}(y).$$

- (a) Begründen Sie, dass X und Y stochastisch unabhängig sind.


[1]

- (b) Geben Sie die marginalen Verteilungen von X und Y an.

[2]


- (c) Sei $U = X + Y$. Berechnen Sie die Dichte von U . Skizzieren Sie diese Dichte.

[8]



(d) Sei $Z = X \cdot Y$. Geben Sie mit Begründung $\mathbb{E}(Z)$ an.

[3]



Aufgabe 5 (16 Punkte)

Beantworten Sie die folgenden Fragen:


- (a) Monaco-Franze kennt jede 10 000ste Person in München. Auf einem Spaziergang begegnet er insgesamt 150 Personen. Sei X_4 die Anzahl der ihm bekannten Personen, die er auf seinem Spaziergang trifft. Geben Sie an, welcher bekannten parametrischen Verteilung mit welchen Parameterwerten die Zufallsvariable X_4 folgt. Geben Sie auch an, welche Annahmen Sie dafür treffen müssen. [3]

- (b) Ein Glücksrad sei in $K \geq 2$ gleich große Sektoren, nummeriert mit $1, \dots, K$ unterteilt. Das Glücksrad wird n -mal gedreht, der Gewinn $G = \min(G_1, G_2, \dots, G_n)$ ist die kleinste Sektornummer, in denen das Glücksrad bei den n Versuchen stehen blieb. $G_i; i = 1, \dots, n$ sind stochastisch unabhängig und alle K Sektoren werden in jedem Versuch mit der gleichen Wahrscheinlichkeit erreicht. [6]

- (i) Zeigen Sie, dass

$$F_G(x) = 1 - \frac{(K - x)^n}{K^n}.$$

- (ii) Der Anbieter des Glücksspiels will erreichen, dass die Spielenden mit einer Wahrscheinlichkeit von unter 10% einen Gewinn von mehr als $K/2$ erzielen. Wie viele Versuche n sollte er also den Spielenden anbieten? Antwort mit Ansatz & Rechnung.



- (c) Aktienfonds A hat eine erwartete Rendite von 5% pro Jahr, mit einer Standardabweichung der jährlichen Renditen von 1.5%. [7]

(i) Was können Sie über die Wahrscheinlichkeit aussagen, dass die Rendite für Fonds A in einem gegebenen Jahr zwischen 3% und 7% liegt?

Antwort mit Ansatz & Rechnung.


(ii) Aktienfonds B hat die selbe erwartete jährliche Rendite und die selbe Standardabweichung der jährlichen Renditen wie Aktienfonds A. Der Quartilskoeffizient der Renditen für Aktienfonds B ist -0.8 . Der Quartilskoeffizient der Renditen für Aktienfonds A ist 0.1 .

Welcher Aktienfonds ist das attraktivere Investment? Begründen Sie Ihre Antwort.

(iii) Eine Investition in den hochspekulativen Aktienfonds C lieferte in den letzten Jahren folgende Ergebnisse:

Jahr	2020	2021	2022	2023	2024
Rendite [%]	-22	+6	+15	+8	+32

Berechnen Sie die durchschnittliche jährliche Rendite in Prozent über den Zeitraum 2020-2024.



Aufgabe 6 (17 Punkte)

Beantworten Sie folgende Fragen.

- (a) Gegeben sei die Funktion

[7]


$$F(x) = \begin{cases} 0 & x < 0 \\ 2 - 2^{-\alpha x} & x \geq 0 \end{cases}$$

mit $\alpha > 0$. Überprüfen Sie ob F eine Verteilungsfunktion ist. Gehen Sie dabei auf **alle drei Bedingungen** einer Verteilungsfunktion ein.

- (b) Ein Basketballspieler übt Würfe auf den Korb. Sei X die Zufallsvariable der erfolgreichen Würfe bei n Versuchen. Die Wahrscheinlichkeit P für einen erfolgreichen Wurf ist uns unbekannt, wir nehmen *a priori* $P \sim \text{Beta}(a, b)$ an. Berechnen Sie den Erwartungswert von X bei n Würfen auf den Korb. [4]

- (c) Sei $X \in \mathbb{R}^n$ eine Zufallsvariable mit Dichte f_X . Seien $\Sigma \in \mathbb{R}^{n \times n}$ eine invertierbare $n \times n$ -Matrix. [6]
Beweisen Sie unter Verwendung des Transformationssatzes, dass

$$f_{\Sigma X}(y) = \frac{f_X(\Sigma^{-1}X)}{|\det(\Sigma)|}.$$




Aufgabe 7 (15 Punkte)

Beantworten Sie folgende Fragen.


- (a) Ein Unternehmen misst täglich die Anzahl der Kunden, die zwischen 12 und 13 Uhr das Geschäft betreten. Die Tageswerte werden als unabhängige Zufallsvariablen $X_1, X_2, \dots, X_n$ modelliert, mit Erwartungswert $\mu = 25$ und Standardabweichung $\sigma = 10$. [4]
- (i) Nach 100 Tagen berechnet man den Durchschnitt $\bar{X}_{100} = \frac{1}{100} \sum_{i=1}^{100} X_i$. Erklären Sie, warum man die Verteilung von $\bar{X}_{100}$ näherungsweise als normalverteilt annehmen kann.
- (ii) Wie sind der Erwartungswert und die Standardabweichung von $\bar{X}_{100}$?
- (iii) Schätzen Sie näherungsweise die Wahrscheinlichkeit, dass $\bar{X}_{100}$ zwischen 25 und 27 liegt.

<i>Ausgewählte Quantile der Standardnormalverteilung</i>									
α (Quantil)	0.800	0.841	0.900	0.933	0.950	0.975	0.978	0.990	0.995
z_α	0.842	1.000	1.282	1.500	1.645	1.960	2.000	2.326	2.576

- (b) Seien X_n, X diskrete Zufallsvariablen mit Werten in $\{0, 1\}$. Zeigen Sie: X_n konvergiert in Verteilung gegen X genau dann, wenn $\mathbb{P}(X_n = 0) \rightarrow \mathbb{P}(X = 0)$ für $n \rightarrow \infty$. [5]




- (c) Seien $X, Y \in \mathbb{R}$ Zufallsvariablen mit beschränktem zweitem Moment. [3]
Begründen Sie warum die Kovarianz von X, Y endlich ist, d.h. $|\text{Cov}(X, Y)| < \infty$.




- (d) Handelt es sich im Folgenden jeweils um Kovarianzmatrizen? Begründen Sie jeweils kurz. [3]


$$A = \begin{pmatrix} 2 & 0.5 & 0.1 \\ 0.5 & 1 & 0 \\ 0.2 & 0 & 3 \end{pmatrix}, \quad B = \begin{pmatrix} 1 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 1 \end{pmatrix}, \quad C = \begin{pmatrix} 1 & 0.5 & -0.5 \\ 0.5 & -1 & 0.5 \\ -0.5 & 0.5 & 1 \end{pmatrix}$$



Zusatzblatt



Zusatzblatt



Zusatzblatt

