


Aufgabe 1 (16 Punkte)


Der Mobilfunkanbieter „Vertel Mobil“ möchte SIM-Aktivierungen automatisch auf Betrug prüfen lassen. Pro Monat werden zwei Millionen Aktivierungen vorgenommen; erfahrungsgemäß sind von einer Million Aktivierungen 20 betrügerisch. In einer bewusst zusammengesetzten Erprobungstichprobe schlug das System bei 18 von 20 tatsächlich betrügerischen und bei 99 von 1980 unauffälligen Aktivierungen an.

Gehen Sie im Folgenden davon aus, dass die in der Erprobungstichprobe ermittelten Eigenschaften des Systems auch im laufenden Betrieb gelten.


- (a) Berechnen Sie die erwarteten monatlichen Häufigkeiten der richtig positiven, falsch positiven, falsch negativen und richtig negativen Entscheidungen. Stellen Sie Ihre Ergebnisse in einer vollständig beschrifteten 2×2 -Kontingenztafel dar. [6]




- (b) Halten Sie eine Treffermeldung unter den gegebenen Umständen für einen verlässlichen Hinweis auf einen tatsächlichen Betrugsfall? Begründen Sie Ihre Antwort quantitativ mit einer geeigneten bedingten Wahrscheinlichkeit. [3]




- (c) Quantifizieren Sie die Stärke des Zusammenhangs zwischen dem tatsächlichen Status einer Aktivierung und der Reaktion des Systems mit einer Maßzahl, deren Wertebereich $\mathbb{R}_0^+$ ist. Interpretieren Sie Ihr Ergebnis. [2]



- (d) Die folgende Grafik zeigt ROC-Kurven zweier alternativer Systeme. Das System „Trustcheck“ ist schwarz, „Netzwächter“ grau dargestellt. Die Zahlen markieren ausgewählte Schwellenwerte. [5]



- (i) Funktioniert das zuvor analysierte System deutlich besser, etwa gleich gut oder deutlich schlechter als die beiden dargestellten Systeme? Bestimmen Sie dazu seinen Punkt (FPR, TPR) und vergleichen Sie ihn mit den ROC-Kurven.
- (ii) Ein übersehener Betrugsfall verursacht einen hohen Schaden; eine Falschmeldung führt nur zu einer kurzen manuellen Nachprüfung. Welches System und welcher ungefähre Schwellenwertbereich sind für diese Situation geeignet? Begründen Sie kurz.



Aufgabe 2 (13 Punkte)

Ein Schnelltest zur Prüfung von Bodenproben auf einen Schadstoff wurde in einem Umweltlabor an drei bewusst ausgewählten Probengruppen erprobt. Die Ergebnisse der Erprobung sind:

Status	Unbelastet	Saniert	Aktuell belastet	Σ
Test positiv	2	5	54	61
Test negativ	98	95	6	199
Σ	100	100	60	260


Im Routinebetrieb des Labors sind 70% der eingehenden Bodenproben unbelastet, 28% stammen von sanierten Flächen und 2% sind aktuell belastet. Gehen Sie davon aus, dass die gruppenspezifischen Testraten aus der Erprobung auch im Routinebetrieb gelten.

- (a) Berechnen Sie Sensitivität und Spezifität des Tests zur Entdeckung einer aktuellen Belastung. [2]

- (b) Berechnen Sie die Wahrscheinlichkeit, mit der der Test im Routinebetrieb ein positives Ergebnis zeigt. Benennen Sie den verwendeten Wahrscheinlichkeitssatz. [3]

- (c) Berechnen Sie die Wahrscheinlichkeit, mit der ein negatives Testergebnis im Routinebetrieb tatsächlich eine nicht aktuell belastete Probe anzeigt. [3]

- (d) Eine ROC-Kurve eines teureren Alternativtests verläuft vollständig oberhalb des Punkts des hier untersuchten Tests. Erläutern Sie, was diese Aussage bedeutet. Wie sollte der Schwellenwert des Alternativtests gewählt werden, wenn eine übersehene Belastung deutlich schwerer wiegt als eine unnötige Nachuntersuchung im Labor? [5]



Aufgabe 3 (10 Punkte)

Eine Studie untersucht den Zusammenhang zwischen der Teilnahme an einem freiwilligen Vorbereitungskurs („Teilnahme“ / „keine Teilnahme“) und dem Bestehen einer Prüfung („bestanden“ / „nicht bestanden“) bei 600 Studierenden. Zusätzlich wurde erhoben, ob bereits einschlägige Vorerfahrung vorlag. Die folgenden Kontingenztafeln sind unvollständig.

Gesamt	Bestanden	Nicht bestanden	Σ
Teilnahme	240	60	_____
Keine Teilnahme	210	_____	300
Σ	_____	150	600

Keine Vorerfahrung	Bestanden	Nicht bestanden	Σ
Teilnahme	60	_____	100
Keine Teilnahme	120	80	_____
Σ	_____	120	300

Vorerfahrung	Bestanden	Nicht bestanden	Σ
Teilnahme	180	20	_____
Keine Teilnahme	90	10	_____
Σ	270	_____	300

- (a) Vervollständigen Sie alle drei Kontingenztafeln. [3]
- (b) Berechnen und interpretieren Sie die marginale Odds Ratio für den Prüfungserfolg bei Teilnahme gegenüber keiner Teilnahme. [2]
- (c) Berechnen Sie die entsprechenden Odds Ratios getrennt für Studierende mit und ohne Vorerfahrung. Interpretieren Sie die Ergebnisse. [3]
- (d) Wie lässt sich der Unterschied zwischen marginaler und bedingter Betrachtung fachlich bezeichnen? Erklären Sie kurz, wodurch er in diesen Daten entsteht. [2]



Aufgabe 4 (14 Punkte)

Eine Urne enthält zu Beginn 3 weiße und 2 schwarze Kugeln. Es wird eine Kugel zufällig gezogen und ihre Farbe notiert. Anschließend wird sie zusammen mit zwei weiteren Kugeln derselben Farbe in die Urne zurückgelegt. Danach wird erneut eine Kugel zufällig gezogen.

Bezeichne W_i , $i \in \{1, 2\}$, das Ereignis, dass die i -te gezogene Kugel weiß ist.


- (a) Bestimmen Sie $P(W_1)$ und $P(W_2 | W_1)$. [2]

- (b) Berechnen Sie $P(W_2)$. Benennen Sie den verwendeten Wahrscheinlichkeitssatz. [3]

- (c) Die zweite gezogene Kugel ist weiß. Berechnen Sie die Wahrscheinlichkeit, dass auch die erste Kugel weiß war. [3]

- (d) Sind W_1 und W_2 stochastisch unabhängig? Begründen Sie rechnerisch. [2]

- (e) Die Urne enthalte nun zu Beginn w weiße und s schwarze Kugeln, und die gezogene Kugel werde jeweils zusammen mit c weiteren Kugeln derselben Farbe zurückgelegt. Zeigen Sie, dass $P(W_2) = \frac{w}{w+s}$ gilt, der Wert also nicht von c abhängt. [4]



Aufgabe 5 (14 Punkte)


Ein seltenes Stoffwechselleiden tritt in einer Population mit Odds von 1 : 1999 auf. Ein diagnostischer Test besitzt eine Sensitivität von 96% und eine Spezifität von 98,5%. Gehen Sie davon aus, dass diese Testeigenschaften in der Population gelten.

- (a) Bestimmen Sie aus den Odds die Prävalenz der Erkrankung. [1]
- (b) Berechnen Sie die Wahrscheinlichkeit, dass eine zufällig ausgewählte Person mit positivem Testergebnis tatsächlich erkrankt ist. [3]

- (c) Berechnen Sie die Wahrscheinlichkeit, dass eine Person mit negativem Testergebnis tatsächlich nicht erkrankt ist. Wie heißt diese Wahrscheinlichkeit in der Vorlesung? [3]

- (d) In einer anderen Teilpopulation sind 4% der Personen erkrankt. Wird der positiv prädikative Wert dort größer, kleiner oder gleich sein? Begründen Sie zunächst ohne Rechnung und berechnen Sie ihn anschließend. [3]

- (e) Wie viele richtig positive und falsch positive Ergebnisse sind bei der Untersuchung von 100 000 Personen aus der ursprünglichen Population im Mittel zu erwarten? Erläutern Sie anhand dieser Zahlen, warum der Anteil aller korrekt klassifizierten Personen allein nicht zur Beurteilung des Tests ausreicht. [4]



Aufgabe 6 (16 Punkte)

In einer Verkehrsbefragung wurden 400 Personen nach ihrer Wohnlage und nach dem von ihnen hauptsächlich genutzten Verkehrsmittel gefragt. Es ergaben sich die folgenden beobachteten Häufigkeiten:

Wohnlage	Rad	ÖPNV	Auto	Σ
Innenstadt	70	110	20	200
Stadttrand	25	65	30	120
Umland	5	25	50	80
Σ	100	200	100	400

- (a) Stellen Sie die Unabhängigkeitstabelle der erwarteten Häufigkeiten auf. Tragen Sie Ihre Werte in die folgende Vorlage ein. [4]

Wohnlage	Rad	ÖPNV	Auto	Σ
Innenstadt	_____	_____	_____	_____
Stadttrand	_____	_____	_____	_____
Umland	_____	_____	_____	_____
Σ	_____	_____	_____	_____

- (b) Berechnen Sie den χ^2 -Koeffizienten. [4]

- (c) Berechnen Sie den korrigierten Kontingenzkoeffizienten und interpretieren Sie ihn. Erläutern Sie, warum die Normierung gegenüber dem χ^2 -Koeffizienten notwendig ist. [4]

- (d) Eine zweite Erhebung mit 4000 Personen ergibt in jeder Zelle genau das Zehnfache der oben beobachteten Häufigkeiten. Wie ändern sich der χ^2 -Koeffizient und der korrigierte Kontingenzkoeffizient? Begründen Sie ohne vollständige Rechnung. [2]

- (e) Nennen Sie einen Aspekt des Zusammenhangs, den der korrigierte Kontingenzkoeffizient im Unterschied zur Odds Ratio nicht erfasst. [2]

Aufgabe 7 (17 Punkte)

In einer Stichprobe mit vier Erkrankten (E_i) und fünf Gesunden (G_i) wurden folgende diagnostische Score-Werte S erhoben. Hohe Werte sprechen für eine Erkrankung.

$$S(E_i) : 88, 74, 74, 61, \quad S(G_i) : 55, 61, 70, 79, 83.$$

Eine Person wird als positiv eingestuft, wenn $S \geq c$ gilt.

- (a) Berechnen Sie Sensitivität und Spezifität für den Schwellenwert $c = 70$.

[3]


- (b) Bestimmen Sie alle Punkte der ROC-Kurve. Verwenden Sie $c = \infty$ sowie jeden vorkommenden Score-Wert als Schwellenwert und tragen Sie die Falsch-Positiv-Rate $FPR = 1 - \text{Spezifität}$ und die Richtig-Positiv-Rate $TPR = \text{Sensitivität}$ in die folgende Tabelle ein.

[5]


Schwellenwert c	FPR	TPR
_____	_____	_____
_____	_____	_____
_____	_____	_____
_____	_____	_____
_____	_____	_____
_____	_____	_____
_____	_____	_____
_____	_____	_____

- (c) Bestimmen Sie die AUC, also die Fläche unter der ROC-Kurve, für diese Daten.


[4]



- (d) Interpretieren Sie Ihr AUC-Ergebnis in einem vollständigen Satz. [2]



- (e) Der Score wird durch $S' = 2S + 10$ ersetzt. Wie ändern sich die ROC-Kurve und die AUC, und wie muss ein Schwellenwert umgerechnet werden? Begründen Sie. [3]



Aufgabe 8 (13 Punkte)

Ein Versandunternehmen betreibt drei Verteilzentren A , B und C . Von allen versendeten Paketen stammen 70% aus A , 20% aus B und 10% aus C . Die Wahrscheinlichkeit für einen Transportschaden beträgt bedingt auf das Zentrum 1% in A , 2% in B und 5% in C .

Sei D das Ereignis „Paket ist beschädigt“.

- (a) Geben Sie $P(A)$, $P(B)$ und $P(C)$ sowie $P(D | A)$, $P(D | B)$ und $P(D | C)$ an. [3]

- (b) Berechnen Sie $P(D)$. [3]

- (c) Ein zufällig ausgewähltes Paket ist beschädigt. Berechnen Sie die Wahrscheinlichkeit, dass es aus Zentrum C stammt. [3]

- (d) Sind die Ereignisse „Paket stammt aus C “ und „Paket ist beschädigt“ stochastisch unabhängig? Begründen Sie rechnerisch. [2]


- (e) Eine Person behauptet: „Die meisten beschädigten Pakete kommen aus C , weil dort die Schadensrate am höchsten ist.“ Beurteilen Sie die Aussage anhand Ihrer Ergebnisse. [2]

Aufgabe 9 (17 Punkte)


Zwei diagnostische Scores A und B sollen zur Diagnose einer Krankheit eingesetzt werden. Die Krankheit hat in der betrachteten Population eine Prävalenz von 0,5%. Für drei mögliche Schwellenwerte sind folgende Punkte (FPR, TPR) bekannt, wobei $\text{FPR} = 1 - \text{Spezifität}$ und $\text{TPR} = \text{Sensitivität}$ gilt:

System	Schwellenwert c	FPR	TPR
A	70	0,01	0,80
A	55	0,04	0,94
A	40	0,12	0,99
B	70	0,02	0,88
B	55	0,06	0,97
B	40	0,15	0,99

- (a) Tragen Sie die sechs Punkte in das folgende ROC-Koordinatensystem ein, verbinden Sie die Punkte jedes Systems sinnvoll und beschriften Sie die Schwellenwerte. [4]




- (b) Welches System ist bei $\text{FPR} = 0,04$ vorzuziehen? Ist eines der beiden Systeme über den gesamten dargestellten Bereich eindeutig besser? Vergleichen Sie dazu die TPR-Werte bei jeweils gleicher FPR. [3]




Eine falsch negative Entscheidung verursacht im Mittel Kosten von 5000 Euro, eine falsch positive Entscheidung Kosten von 20 Euro. Es werden 100 000 Personen untersucht.

- (c) Berechnen Sie für jeden der sechs Punkte die erwartete Anzahl falsch negativer und falsch positiver Entscheidungen. [4]
- (d) Bestimmen Sie für jeden Punkt die erwarteten Gesamtkosten. Welches System und welcher Schwellenwert sollten unter diesem Kriterium gewählt werden? [4]
- (e) Warum kann sich die optimale Wahl ändern, wenn das Programm in einer Population mit höherer Prävalenz eingesetzt wird? [2]



Aufgabe 10 (12 Punkte)

Der folgende Mosaikplot stellt den beobachteten Zusammenhang der Merkmale Vertragsart („Jahresabo“ / „Monatsabo“) und Kündigung im ersten Jahr („gekündigt“ / „nicht gekündigt“) bei 400 Kundinnen und Kunden dar. Die Breite eines Rechtecks entspricht der relativen Häufigkeit der Vertragsart; seine Höhe innerhalb einer Spalte der bedingten relativen Häufigkeit des Kündigungsverhaltens.



- (a) Wie viele Kundinnen und Kunden hatten ungefähr ein Jahresabo beziehungsweise ein Monatsabo? [2]
- (b) Für welche Vertragsart ist die Kündigungsrate höher? Gibt es insgesamt mehr Kündigungen bei Jahres- oder bei Monatsabos? Begründen Sie jeweils anhand der Kantenlängen und der zugehörigen absoluten Häufigkeiten. [3]

- (c) Sind Vertragsart und Kündigung im ersten Jahr empirisch unabhängig? Begründen Sie anhand der bedingten relativen Häufigkeiten. [2]

Zusätzlich wurde das Merkmal Altersgruppe („unter 30“ / „30 und älter“) erhoben. Es ist empirisch unabhängig von der Vertragsart und vom Kündigungsverhalten; beide Altersgruppen sind gleich häufig vertreten.

- (d) Skizzieren Sie schematisch eine mit diesen Angaben vereinbare gemeinsame Verteilung aller drei Merkmale als Mosaikplot. Eine exakte Zeichnung ist nicht erforderlich; die beiden angegebenen empirischen Unabhängigkeiten müssen jedoch erkennbar sein. [3]

- (e) Erläutern Sie, woran man in Ihrer Skizze erkennt, dass die Altersgruppe empirisch unabhängig [2]
von der Vertragsart und vom Kündigungsverhalten ist.

