

GOP Bootcamp 2026

Woche 1 – Theorie

Einführung

Ablauf, Organisation, Lernziel und ein realistischer Blick auf die GOP

Datenerhebung & Messungenen

Datensatz, Erhebung, Skalenniveaus und sauberes Lesen von Tabellen

Kennwerte von Merkmalen

Lage, Streuung, Form, Transformationen und Konzentration

Häufigkeiten & ecdf

Von der Urliste zur Häufigkeitstabelle und zur Treppenfunktion

Zusammenhangsmaße & Kausalität

Diskrete und metrische Merkmale, Korrelation, Confounding und Simpson

Statistische Grafiken

Grammar of Graphics, Verteilungen, Streudiagramme und Farbskalen

EINFÜHRUNG

Einführung

- Wie das GOP-Bootcamp aufgebaut ist und wie ihr die Zeit nutzt
- Was die Prüfung von euch verlangt – und welches Ziel realistisch ist
- Warum Rechnen, Nachfragen und Üben wichtiger sind als passives Zuhören

Warum ihr hier seid – und warum wir

Die schlechte Nachricht

Die GOP ist die Prüfung, an der in eurem Studiengang die meisten scheitern. Sie prüft **zwei** Vorlesungen in **150 Minuten** ab – Deskriptive Statistik *und* Wahrscheinlichkeitstheorie.

Die gute Nachricht

Sie ist **bestehbar**. Man braucht **50 % der Punkte**. Und die Klausuren wiederholen sich in ihren Aufgabentypen stärker, als man denkt.

Was wir hier machen

5 Wochen, 15 Termine, jeweils **2 h Theorie** am Vormittag und **2 h Übung** am Nachmittag. Wir gehen den kompletten Stoff durch – mit Fokus auf **Intuition** und **typische Aufgabentypen**.

Unser Ziel ist nicht die 1,0.

Unser Ziel ist, dass **jede und jeder von euch** am **16. September die 50 % schafft**.

Was das von euch verlangt: Anwesenheit reicht nicht. Ihr müsst rechnen – hier, nachmittags, und abends. Wer 15 Vormittage lang zuhört und sonst nichts tut, besteht nicht.

Zu den Zahlen hinter dieser Aussage kommen wir gleich.

Wer euch durch die fünf Wochen bringt

THEORIE & ÜBUNG

Eugen

Woche 1 komplett, Woche 3, Konvergenz- & Grenzwertsätze

THEORIE & ÜBUNG

Timo

Woche 2 – Wahrscheinlichkeitsrechnung, Verteilungen, Momente

THEORIE & ÜBUNG

Maxim

Woche 4 – Maßtheorie, Zufallsvektoren, Lebesgue-Integral

ÜBUNG & UNTERSTÜTZUNG

Rubin

Übungsleitung Woche 1, Unterstützung Woche 4

UNTERSTÜTZUNG

Vici & Simon

Nachmittags in den Übungen ansprechbar (Woche 2–3)

GOP PROBE II & FINALE

Carlota

Probeklausur II, Q&A und Mut machen am letzten Tag

Nachmittags sind immer zwei von uns da. Eine Person leitet die Übung, eine geht herum. Nutzt das – individuelle Fragen sind nachmittags *deutlich* besser aufgehoben als vormittags.

Der Plan: 5 Wochen, 15 Termine

KW	TERMIN	ORT	THEMA	THEORIE 10–12	ÜBUNG 13–15	UNTERSTÜTZUNG 13–15
1	Mo 10.08.	Luisenstr. 37 (C) C006	Einführung, Datenerhebung & Messungen, Kennwerte von Merkmalen	Eugen	Rubin	Eugen
	Mi 12.08.	Luisenstr. 37 (C) C006	Statistische Grafiken, Vertiefung Kennwerte	Eugen	Rubin	Eugen
	Fr 14.08.	Theresienstr. 37/39/41 B004	Zusammenhangsmaße diskret & metrisch	Eugen	Rubin	Eugen
2	Mo 17.08.	Luisenstr. 37 (C) C006	Wahrscheinlichkeitsrechnung, Satz von Bayes, Zufallsvariablen	Timo	Timo	Vici
	Mi 19.08.	Luisenstr. 37 (C) C006	Verteilungsfunktion (auch mehrdim.), Dichte, wichtige Verteilungen	Timo	Timo	Simon
	Fr 21.08.	Theresienstr. 37/39/41 B004	Momente: Erwartungswert, Varianz, Schiefe, Kurtosis	Timo	Timo	Vici
3	Mo 24.08.	Luisenstr. 37 (C) C006	Dichtetransformationssatz, Faltungen	Eugen	Eugen	Simon
	Mi 26.08.	Luisenstr. 37 (C) C006	GOP Probe I	Eugen	Eugen	Simon
	Fr 28.08.	Theresienstr. 37/39/41 B004	Q&A / Puffer	Eugen	Eugen	Vici
4	Mo 31.08.	Luisenstr. 37 (C) C006	Maßtheorie	Maxim	Maxim	Rubin
	Mi 02.09.	Luisenstr. 37 (C) C006	Zufallsvariablen & Zufallsvektoren	Maxim	Maxim	Rubin
	Fr 04.09.	Theresienstr. 37/39/41 B004	Lebesgue-Integral	Maxim	Maxim	Rubin
5	Mo 07.09.	Luisenstr. 37 (C) C006	Dichte, Momente allgemein, Ungleichungen, erzeugende Funktionen	Maxim	Maxim	Rubin
	Mi 09.09.	Luisenstr. 37 (C) C006	Konvergenz- und Grenzwertsätze	Eugen	Eugen	Carlota
	Fr 11.09.	Theresienstr. 37/39/41 B004	GOP Probe II	Carlota	Carlota	Rubin
	Mo 14.09.	Luisenstr. 37 (C) C006	Mut machen, Q&A	–	Eugen	Carlota
	Mi 16.09.	–	GOP-Klausur (150 min)	–	–	–

Tagesablauf & Pausen


ZEIT	WAS
10:00 – 12:00	Theorie – Konzepte, Formeln, Intuition
12:00 – 13:00	Mittagspause – Mensa Arcisstraße
13:00 – 15:00	Übung – Aufgaben rechnen, Besprechung, offene Fragen

Fragen jederzeit. Unterbrecht uns. Wenn ihr etwas nicht versteht, versteht es garantiert die Hälfte des Raums auch nicht.

Mittagessen – Mensa Arcisstraße

Arcisstraße 17, ca. 8 Minuten zu Fuß von der Luisenstraße.

Geöffnet 11:00–14:00 Uhr.



Wer lieber draußen sitzt: der Alte Botanische Garten liegt auf halbem Weg.

Disclaimer – lest das bitte wirklich

1. Wir kennen eure GOP nicht. Wir haben keine Kenntnis über die konkreten Inhalte oder Aufgaben eurer Klausur. Wir arbeiten mit den Vorlesungsfolien und den Altklausuren – nicht mit Insiderwissen.

2. Kein einheitlicher Stil. Fünf Tutor:innen, fünf Handschriften, fünf Notationen. Wir versuchen, uns an die Vorlesung zu halten – garantieren können wir es nicht.

3. Keine Garantie für Richtigkeit oder Vollständigkeit. Wir machen das neben Studium und Job. Findet ihr einen Fehler: sagt Bescheid, wir korrigieren ihn.

4. Kein Ersatz für eigenständiges Lernen. Dieses Bootcamp ist ein Gerüst. Das Rechnen nimmt euch niemand ab. Und insbesondere: Wir zielen auf **bestehen**. Wer nicht nur bestehen, sondern **gut bestehen** will, braucht deutlich mehr Aufwand und deutlich mehr Detailtiefe, als dieses Bootcamp abdeckt.

Wir sind Studierende wie ihr, die diese Prüfung schon hinter sich haben.

Kein Lehrstuhl, keine offizielle Veranstaltung, keine Absprache mit dem Prüfungsamt. Was wir mitbringen, ist Erfahrung – und ziemlich viel Zeit, die wir in diese fünf Wochen stecken.

Im Zweifel gilt immer: Vorlesungsfolien > Altklausur > unsere Unterlagen.

Vorwissen, das wir voraussetzen

Analysis

- **Ableiten** – inkl. Ketten- und Produktregel, inkl. **partieller** Ableitungen
- **Integrieren** – inkl. partieller Integration und Integration durch Substitution
- **Mehrdimensionale Integrale** – Satz von Fubini, Reihenfolge der Integration, Integrationsgrenzen bestimmen
- Grenzwerte, Reihen (geometrische Reihe!), $\exp$, $\log$ und ihre Rechenregeln

Lineare Algebra

- **Definitheit von Matrizen** (positiv/negativ semidefinit)
- **Determinanten und Eigenwerte**
- Matrix-Vektor-Rechnung, Transponieren, Inverse von 2×2

Warum das wichtig ist

Ein großer Teil der GOP-Punkte in Statistik 2 geht nicht bei der Stochastik verloren, sondern beim **Rechnen**: Ein Integral, das man nicht löst. Eine Substitution, die man nicht sieht. Grenzen, die man falsch setzt.

Wenn ihr bei einem dieser Punkte unsicher seid: Das ist Hausaufgabe für *diese* Woche, nicht für September. Wir wiederholen es nicht.

MAHNENDE WORTE

Jetzt der unangenehme Teil.

Wir zeigen euch gleich drei Dinge: die Bestehensquoten der letzten Jahre, eure eigene LinAlg-Klausur – und eine sehr einfache Rechnung zu der Zeit, die euch bis zum 16. September bleibt.

Das ist nicht zum Angstmachen. Das ist, damit ihr *heute* anfangt und nicht am 1. September.



Die GOP in Zahlen

~80 %

Durchfallquote **letztes Jahr**

~90 %

Durchfallquote im **Zweitversuch**

50 %

der Punkte genügen zum **Bestehen**

Warum ist die Quote so hoch?

Die Rahmenbedingungen

- Zwei Vorlesungen, **eine** Klausur, 150 Minuten
- Statistik 2 baut auf Maßtheorie auf – ungewohnt abstrakt im ersten Jahr
- Sehr viel Stoff, sehr wenig Wiederholung während des Semesters
- Sprachlich anspruchsvoll gestellte Aufgaben

Cheatsheet zu spät oder schlecht

Das Cheatsheet ist kein Nachschlagewerk, sondern ein **Lernprodukt**. Wer es am Vorabend unterschreibt, hat ein Blatt Papier – aber nichts gelernt. Wer es zwei Wochen vorher baut und beim Üben ständig überarbeitet, merkt genau, wo die Lücken sind.
Und: In der Klausur kostet Suchen Zeit. Ein überladenes Blatt ist schlimmer als ein dünnes, das ihr kennt.

Falscher Umgang mit KI

Ein Sprachmodell löst euch jede Übungsaufgabe in 20 Sekunden – und ihr habt beim Lesen der Lösung das Gefühl, sie verstanden zu haben. In der Klausur sitzt ihr dann vor einem leeren Blatt.

Sinnvoll: selbst rechnen, dann die eigene Lösung prüfen lassen; sich einen Beweisschritt erklären lassen, den ihr nicht knackt; euch Aufgaben *stellen* lassen.

Nicht sinnvoll: die Lösung lesen und weiterblättern. Und: Modelle rechnen bei Maßtheorie und Dichtetransformationen häufig falsch – nur merkt ihr das nur, wenn ihr es selbst könnt.



Don't fool yourself

Eine Lösung **nachvollziehen** zu können ist etwas komplett anderes, als sie **selbst zu finden**. Folien lesen, Videos schauen, Musterlösungen durchgehen – das fühlt sich nach Lernen an und ist fast keins.

Der einzige ehrliche Test: **leeres Blatt, Aufgabe, Stoppuhr**. Wenn ihr das nicht regelmäßig macht, wisst ihr am 16. September zum ersten Mal, was ihr wirklich könnt. Das ist zu spät.

Quelle der Quoten: Erfahrungswerte aus den Vorjahren und Angaben der Fachschaft – keine offizielle Prüfungsstatistik.

Eure Lineare Algebra Klausur dieses Jahr



LINEARE ALGEBRA

9 ECTS Stoff

zeitlich eine der **nettesten** Klausuren

gut kommunizierte, **erwartbare Struktur**

dieses Jahr eine der **einfachsten** Klausuren

nette Bestehensgrenze

keine **Sprachbarriere**

GOP

18 ECTS Stoff

zeitlich eine der **schwierigsten** Klausuren

viele Unbekannte, jedes Jahr neue **Wildcards**

dieses Jahr vermutlich eher eine **schwere**

vermutlich **50 %** Bestehensgrenze

bewusst sprachlich **schwierig** gestellt

Der Punkt: Wer regelmäßig im Tutorium war, hat deutlich wahrscheinlicher bestanden.

Kausalität? Vorsicht – das ist eine *Assoziation*. Wer ins Tutorium geht, lernt vermutlich auch sonst mehr. Wir kommen am Freitag ausführlich auf Korrelation vs. Kausalität zurück. Nutzt trotzdem beides.

Wie viel Zeit ihr wirklich habt



Heute (Tag 1)	Mo 10.08.2026
GOP-Klausur	Mi 16.09.2026
Verbleibende Tage	37
abzüglich 5 Tage „Leben“ (krank, Geburtstag, Kater, Familie ...)	– 5
Effektive Lerntage	32

Tage für „Leben“ 5 Statistik 1 : Statistik 2 50 : 50

Statistik 1 · 16 Tage
Theorie 8 Tage · Übung 8 Tage

Statistik 2 · 16 Tage
Theorie 8 Tage · Übung 8 Tage

Dem gegenüber steht

Statistik 1: 12 Kapitel à 4 h	48 h
Statistik 1: 12 Übungen à 2 h	24 h
Statistik 2: 12 Kapitel à 4 h	48 h
Statistik 2: 12 Übungen à 2 h	24 h
GOP-Tutorium: 5 Wochen à 12 h	60 h
Gesamt	204 h

204 h auf 32 effektive Tage

6,4 h

pro Tag – **jeden** Tag, auch am Wochenende

Warum das trotzdem zu schaffen ist

1. Ihr braucht nur die Hälfte

Keine Eleganz, keine Vollständigkeit. Punkte gibt es auch für angefangene Rechnungen, richtige Ansätze und korrekte Definitionen.

2. Die Aufgabentypen wiederholen sich

Schaut euch die Altklausuren SoSe 22 bis SoSe 25 an: Skalenniveaus zuordnen, Kennwerte berechnen, Boxplot lesen, Bayes anwenden, Dichte transformieren. Immer wieder.

3. Ihr seid nicht allein

15 Termine, viel Übungsmaterial und Altklausuren, fünf Leute, die euch nachmittags über die Schulter schauen.

UNSER DEAL

**Wir bereiten 15 Vormittage und
15 Nachmittage vor.**

Ihr kommt hin und rechnet mit.

Fangen wir an.

Datenerhebung & Messungen

- Grundbegriffe: Untersuchungseinheit, Grundgesamtheit, Merkmal
- Zeilen- und Spaltenbetrachtung eines Datensatzes
- Was *ist* eigentlich eine Messung?
- Erhebungsarten: Vollerhebung vs. Stichprobe; Querschnitt, Zeitreihe, Längsschnitt
- **Skalenniveaus** und ihre zulässigen Transformationen
- Merkmalstypen: diskret, stetig, quasi-stetig, gruppiert

Grundlage: Kapitel 2 der Statistik-1-Folien (S. 50–77)

Wir machen das an echten Daten: Mietspiegel München

Zeilen 12 ▾

Sortieren nach

Urliste (unsortiert) ▾

Andere Wohnungen zeigen

#	NM [€]	NMQM	WFL [M²]	ROOMS	BJ	BEZ	LAGE	KÜCHE
1	741,39	10,90	68	2	1.918	2	gut	nein
2	715,82	11,01	65	2	1.995	2	gut	nein
3	528,25	8,38	63	3	1.918	2	gut	nein
4	553,99	8,52	65	3	1.983	16	normal	nein
5	698,21	6,98	100	4	1.995	16	gut	ja
6	935,65	11,55	81	4	1.980	16	normal	nein
7	204,85	3,72	55	2	1.924	6	normal	nein
8	426,93	5,40	79	3	1.924	6	normal	nein
9	446,33	8,58	52	1	1.957	6	normal	nein
10	381,45	4,95	77	3	1.948	6	normal	nein
11	337,26	9,64	35	1	1.957	6	normal	nein
12	756,73	11,13	68	2	1.985	6	gut	nein

Datenquelle: Mietspiegel der Stadt München 2003, Open-Data-Server der LMU (`data.ub.uni-muenchen.de`).
Hier ein Auszug mit **964** Wohnungen – derselbe Datensatz, mit dem auch eure Vorlesung arbeitet.

Warum ausgerechnet Mieten?

Weil ihr alle in München wohnt (oder es versucht). Und weil in diesem einen Datensatz **alle fünf Skalenniveaus** vorkommen.

Die Variablen

nm	Nettomiete in €
nmqm	Nettomiete pro m²
wfl	Wohnfläche in m²
rooms	Zimmerzahl
bj	Baujahr
bez	Stadtbezirk (1–25)
lage	Wohnlage: normal / gut / best
kueche	gehobene Küche (ja/nein)

Grundbegriffe – am Datensatz erklärt

Statistische Einheit / Untersuchungseinheit (UE)

Objekt, an dem die interessierenden Größen erfasst werden.
„Merkmalsträger“.

→ hier: **eine Wohnung**, also eine Zeile der Tabelle

Grundgesamtheit / Population (GG)

Menge aller für die Fragestellung relevanten statistischen Einheiten.

→ hier: **alle Mietwohnungen in München** (2003)

Teilgesamtheit / Stichprobe

Teilmenge der GG – speziell die UE, für die Daten vorliegen.

→ hier: die **964 befragten Wohnungen**

Beobachtung

Gesamtheit der beobachteten Ausprägungen aller gemessenen Merkmale **einer** UE zu **einem** Messzeitpunkt.

→ hier: eine komplette **Zeile**

Merkmal / (Ko-)Variable

Messbare Eigenschaft der Untersuchungseinheiten.

→ hier: **Nettomiete, Wohnfläche, Zimmerzahl, Bezirk ...** – also eine **Spalte**

Merkmalsausprägung

Konkreter Wert eines Merkmals für eine bestimmte UE.

→ hier: **741,39 €** – also eine **Zelle**

Merkmalsraum (Zustandsraum)

Menge *aller möglichen* Ausprägungen eines Merkmals.

→ Zimmerzahl: $\{1, 2, 3, \dots\}$ · Nettomiete: $[0, \infty)$

! beobachtete Ausprägungen $\subseteq$ Merkmalsraum

Merkhilfe: Zeilen- und Spaltenbetrachtung

Das Folgende gilt nur für **tabulare Daten im Tidy-Format**.¹ Sobald die Daten anders strukturiert sind, muss man sich jeden Begriff einzeln erarbeiten.

Zeilenbetrachtung

UE	Wen oder was beschreibt eine Zeile?
Grundgesamtheit	Wer oder was <i>könnte</i> alles in diesem Datensatz auftauchen?
Stichprobe	Wer oder was taucht tatsächlich in dem Datensatz auf?
Beobachtung	Eine Zeile

Spaltenbetrachtung

Merkmal	Der Spaltenname
Merkmalsausprägung	Eine Zelle
Merkmalsraum	Was <i>könnte</i> alles in dieser Spalte stehen?

Ein blaues ? heißt: Das könnt ihr **nicht am Datensatz ablesen**. Das müsst ihr euch aus dem **Kontext** erschließen – aus der Fragestellung, der Erhebungsbeschreibung oder dem Aufgabentext.

Gegenbeispiel: nicht-tabulare Daten

Ein Ordner mit **10.000 Röntgenbildern**. Was ist hier die UE – ein Bild? ein:e Patient:in (mit mehreren Aufnahmen)? Was ist ein Merkmal – jeder einzelne Pixel? Und was ist der Merkmalsraum: alle Graustufen? alle möglichen Bilder?

Ebenso bei **Texten, Audio, Netzwerkdaten** oder **Zeitstempeln von Sensoren**. Die Begriffe gelten dort weiterhin – nur muss man erst **entscheiden**, wie man die Daten in Zeilen und Spalten übersetzt. Diese Entscheidung ist bereits Teil der Analyse.

¹ Tidy-Format – drei Prüffragen an die Tabelle:

1. Steht in jeder Spalte **ausschließlich das, was die Spaltenüberschrift ankündigt** – und in jeder Zelle genau ein einzelner Wert davon?

Verletzt: Spalte Größe/Gewicht mit Eintrag 180/75. Oder eine Spalte Wert, in der mal eine Miete und mal eine Fläche steht.

2. Ist jede Spaltenüberschrift der **Name** einer Eigenschaft – und nicht selbst schon ein **Wert**?

Verletzt: Spalten 2019, 2020, 2021 mit Umsätzen. „2020“ ist kein Eigenschaftsname, sondern ein Wert der Eigenschaft *Jahr*.

3. Beschreiben **alle Zeilen Objekte derselben Art**, und jede Zeile genau eines davon?

Verletzt: eine Tabelle, in der zwischen den Wohnungen Zwischensummen-Zeilen für ganze Gebäude stehen.

Nach Wickham (2014): „each variable is a column, each observation is a row“. Er räumt dort selbst ein, dass sich „Variable“ und „Beobachtung“ allgemein nur schwer sauber definieren lassen – deshalb hier die praktisch prüfbare Fassung, die ohne diese Begriffe auskommt.

Was ist eine Messung?

Messen

Zuordnung von Zahlen oder Symbolen zu Ausprägungen von Merkmalen an Untersuchungseinheiten.

Klingt banal, ist es nicht: Ob eine Größe überhaupt messbar ist – und wie eindeutig – entscheidet darüber, was man später mit den Zahlen rechnen darf. Genau darauf laufen die Skalenniveaus hinaus.

Beispiele für die Frage „Wie messe ich das?“ aus verschiedenen Disziplinen

- **Physikalisch:** Länge, Blutdruck, Temperatur, Wohnfläche
- **Psychometrisch:** Gewaltbereitschaft, Schwere einer Depression
- **Wirtschaftswissenschaftlich:** Inflation, Bruttosozialprodukt, Arbeitslosenquote

Zwei Typen von Messungen

1. Direkte Messung („representational“)

Es gibt ein **reales Relativ**: eine Struktur, die man **ohne Zahlen** prüfen kann. Bei Länge etwa „länger als“ (Stäbe nebeneinanderhalten) und Aneinanderlegen. Die Messung bildet diese Struktur nur ab.

Länge, Gewicht, Anzahl, Wohnfläche, Blutzuckerkonzentration

2. Indirekte / operationale Messung („pragmatic“)

Es gibt keine solche Struktur – das Relativ wird erst durch die **Operationalisierung** definiert. Der Wert *ist* die Vorschrift.

Intelligenz, Schweregrad einer Krankheit, Arbeitslosenquote, „Wohnlage“

Der Unterschied ist nicht „mit oder ohne Konvention“. Auch das Urmeter ist eine Konvention – aber es legt nur die **Einheit** fest, nicht, was Länge *ist*. Der Test: Liefern zwei Verfahren verschiedene Werte, ist bei Länge eines davon **nachweisbar falsch**. Bei „Depressionsschwere“ messen sie vielleicht einfach Verschiedenes – und kein Experiment entscheidet das.

In der Praxis ist das ein Übergang, keine saubere Zweiteilung.

Erhebungsarten

Umfang

Vollerhebung

Alle statistischen Einheiten der GG werden untersucht.

→ Volkszählung, Wahlergebnis, Notenspiegel eines Jahrgangs

Stichprobe (Teilerhebung)

Ein Teil der UE wird untersucht. Ist die Auswahl **zufällig**, spricht man von einer **Zufallsstichprobe**.

→ unser Mietspiegel: 964 von hunderttausenden Wohnungen

Induktive Statistik ist in der Regel nur auf Basis geeigneter Zufallsstichproben zulässig. Wer nur die Wohnungen befragt, die freiwillig antworten, bekommt keine Zufallsstichprobe – sondern einen Selektionseffekt.

Datenform – auch das ist Zeilen- und Spaltenbetrachtung

QUERSCHNITT

Eine Beobachtung pro UE.

Ein oder mehrere Merkmale werden an mehreren UE **einmal** erhoben.

Zeilenbetrachtung: jede UE kommt genau einmal vor.

→ unser Mietspiegel

ZEITREIHE

Mehrere Beobachtungen **einer** UE.

Ein Merkmal wird für dieselbe UE wiederholt erhoben, meist in regelmäßigen Abständen.

Zeilenbetrachtung: alle Zeilen gehören zur selben UE, unterschieden nur durch die Zeit.

→ Mietpreisindex München 1990–2026

LÄNGSSCHNITT / PANEL

Mehrere Beobachtungen **mehrerer** UE.

Dieselben Merkmale werden mehrmals zu verschiedenen Zeitpunkten an mehreren UE erhoben.

Zeilenbetrachtung: UE-Kennung **und** Zeitpunkt zusammen identifizieren eine Zeile.

→ Corona-Inzidenz *aller* Landkreise
Bundesliga-Tabelle über alle Spieltage, Mikrozensus

Methoden operationaler Messung

Beobachtung (verdeckt oder teilnehmend, systematisch mit Protokoll) · **Befragung** (mündlich mit/ohne Interviewer, schriftlich, online) · **Experiment** (kontrollierte Situation)

Experiment

Gemeinsamkeit aller Experimente: **experimenteller Eingriff ins Geschehen**. Bei der **randomisierten klinischen Studie** erfolgt die Zuordnung der Behandlungen durch ein Losverfahren – deshalb erlaubt sie kausale Aussagen. A/B-Testing im Web ist dasselbe Prinzip.

Skalenniveaus – die Übersicht

Die **Menge der zulässigen Transformationen** bestimmt das Skalenniveau. Höheres Niveau = mehr sinnvolle Rechenoperationen, aber **weniger** erlaubte Transformationen.

NIVEAU	BEISPIELE (UNSER DATENSATZ)	ERLAUBTE TRANSFORMATIONEN	= / ≠	< / >	DIFFERENZ	QUOTIENT	SINNVOLLE LAGEMASSE ¹
Nominal qualitativ	Stadtbezirk, Küche ja/nein, Farbe, Religion	alle bijektiven Abbildungen f : $a = b \Leftrightarrow f(a) = f(b)$	✓	×	×	×	Modus
Ordinal qualitativ	Wohnlage (normal < gut < best), Schulbildung, Noten	alle streng monoton steigenden f : $a < b \Leftrightarrow f(a) < f(b)$	✓	✓	×	×	+ Median, Quantile
Intervall metrisch	Baujahr, Temperatur in °C, IQ	lineare Transformationen $f(x) = ax + b, a > 0$	✓	✓	✓	×	+ arithm. Mittel
Verhältnis metrisch	Nettomiete, Wohnfläche, Preise, Längen, Gewichte	Reskalierung $f(x) = ax, a > 0$	✓	✓	✓	✓	+ geom. / harm. Mittel
Absolut metrisch	Zimmerzahl, Häufigkeit, Anzahl	nur die Identität (Einheit liegt natürlich fest)	✓	✓	✓	✓	alle

¹ Die Lagemaße selbst behandeln wir erst in Teil 2. Hier geht es nur darum, dass das Skalenniveau darüber entscheidet, welche davon überhaupt zulässig sind.

Verhältnisskala = Intervallskala, bei der der kleinstmögliche Wert 0 ist.
Deshalb ist „das Jahr 1990 ist 1,005-mal so groß wie das Jahr 1980“ Unsinn – die Jahreszählung könnte genauso gut bei einem anderen Nullpunkt beginnen. Dagegen ist „80 m² ist doppelt so groß wie 40 m²“ korrekt, denn 0 m² ist wirklich die kleinstmögliche Fläche.

Sonderfall dichotome Merkmale (0/1-codiert): formal nominalskaliert – aber ihr Mittelwert ist sinnvoll interpretierbar, nämlich als **relative Häufigkeit**. In unseren Daten: $\bar{x}_{\text{Kueche}} = 0,066$, also 6,6 % der Wohnungen haben eine gehobene Küche.

Auch *Statistiken* haben ein Skalenniveau

Die Regel

Das Skalenniveau einer berechneten Größe ergibt sich daraus, **wie sie sich verhält, wenn man das zugrunde liegende Merkmal zulässig transformiert**. Man muss es also nicht raten – man rechnet es nach.

Beispiel: x ist das **Baujahr**, also intervallskaliert. Zulässig ist $y = ax + b$ mit $a > 0$.

Mittelwert

$$\bar{y} = a \bar{x} + b$$

→ verhält sich wie x selbst

→ **intervallskaliert**

Varianz

$$s_y^2 = a^2 s_x^2$$

→ das b fällt heraus, es bleibt eine reine Streckung

→ **verhältnisskaliert**

Die Varianz eines **intervallskalierten** Merkmals ist also selbst **verhältnisskaliert** – das Skalenniveau einer Statistik kann **höher** sein als das der Daten. „Die Varianz der Baujahre hat sich verdoppelt“ ist eine sinnvolle Aussage, „das mittlere Baujahr hat sich verdoppelt“ dagegen nicht.

Übersicht

STATISTIK	SKALENNIVEAU
absolute Häufigkeit h_j	absolut
relative Häufigkeit / Anteil f_j	verhältnis (0 = „keiner“)
Modus, Median, Quantile	erben das Niveau des Merkmals
Mittelwert	erbt das Niveau des Merkmals
Varianz, Standardabweichung, IQR	verhältnis
Variationskoeffizient v , Gini G , Korrelation r	einheitenlos, invariant
Rangplatz	ordinal

Der Klassiker: Das Merkmal „Küche gehoben (ja/nein)“ ist **nominal**. Sein Mittelwert ist ein **Anteil** und damit **verhältnisskaliert** – 6,6 % sind wirklich doppelt so viel wie 3,3 %.

Klausurhinweis: In den Altklausuren steht die Frage fast immer als „Geben Sie für alle in der Grafik gezeigten **Merkmale und Statistiken** das Skalenniveau an“ (so wörtlich SoSe 24, Aufgabe 1(f)). Das Wort *Statistiken* wird gerne überlesen – dort liegen Punkte.

Wenn die fünf Niveaus nicht reichen

Indexbildung

Zusammenfassung mehrerer Merkmale (Items) zu einem aggregierten Merkmal – einem **Score** oder **Index**. Meist als (gewichtete) Summe.

Beispiel Wahl-O-Mat: „Übereinstimmung mit der SPD“ $= w_1 \cdot Q_1 + w_2 \cdot Q_2 + \dots$

Die Indexbildung ist meist **theoriegeleitet** bzw. folgt fachspezifischen Überlegungen – sie ist eine inhaltliche Entscheidung, keine statistische.

Likert-Skalen

Häufigstes Verfahren der Psychometrie: mehrere **Ratingskalen** fragen Zustimmung oder Ablehnung zu Aussagen zum selben Thema ab.

„stimme gar nicht zu“ – „stimme nicht zu“ – „neutral“ – „stimme zu“ – „stimme voll zu“

Der Skalenwert ist der Summen- oder Durchschnittsscore der Einzelratings.

Das Problem

Die Einzelitems einer Likert-Skala sind **ordinal**. Trotzdem wird gemittelt – und das setzt eigentlich Intervallskalenniveau voraus.

Offene Fragen bei jeder Indexbildung:

- Wie werden die Items **gewichtet**?
- Welches **Skalenniveau** hat der Index am Ende?

Die ehrliche Antwort: irgendwo zwischen ordinal und intervall. In der Praxis behandelt man Likert-Scores meist als metrisch – und weiß, dass man dabei etwas unterschlägt.

Wenn schon die *Ordnung* nicht funktioniert

Nicht transitiv. Eine Ordinalskala setzt voraus, dass aus $a > b$ und $b > c$ auch $a > c$ folgt. Hackordnungen in der Natur verletzen das regelmäßig: Henne A pickt B, B pickt C – und C pickt A. Dasselbe Muster bei Schere-Stein-Papier oder beim **Condorcet-Paradoxon** in Wahlen. Dann existiert schlicht **keine** Ordinalskala, egal welche Zahlen man vergibt.

Bindungen (Ties). Drei Personen schreiben dieselbe Klausurleistung und sind alle Fünftbeste – die nächste ist dann Achtbeste. Die Zahlen 5, 5, 5, 8 sind keine reinen Ränge mehr, es entstehen Lücken. Es gibt mehrere Konventionen: 1 2 2 4 (competition), 1 2 2 3 (dense) oder 1 2,5 2,5 4 (Mittelränge).

Merkt euch die **Mittelränge** – genau die braucht man am Freitag für den Spearman-Rangkorrelationskoeffizienten.

Und noch ein Grenzfall: die log-Skala

Der Logarithmus ist **keine zulässige Transformation** einer Verhältnisskala. „Unzulässig“ heißt hier aber **nicht verboten**, sondern: man **verlässt die Skala** und muss ab dann die Regeln der neuen benutzen.

Aus $x \mapsto ax$ wird für $y = \log x$ nämlich $y \mapsto y + \log a$ – es bleiben **nur noch Verschiebungen**. Folge: Differenzen sind interpretierbar (als Faktoren), absolute Werte und Quotienten nicht.

Bakterienkonzentration $10^{-3} \rightarrow 10^{-4} \rightarrow 10^{-5}$: auf der log-Skala jeweils dieselbe Differenz -1 , also Faktor $\frac{1}{10}$ – und zwar **unabhängig von der Einheit**. Genau deshalb sind log-Skalen so nützlich.

Übung: Ordnet die Merkmale zu

MERKMAL	NOMINAL	ORDINAL	INTERVALL	VERHÄLTNIS	ABSOLUT	SONSTIGES
Stadtbezirk (1–25)	☐	☐	☐	☐	☐	☐
Wohnlage (normal/gut/best)	☐	☐	☐	☐	☐	☐
Baujahr	☐	☐	☐	☐	☐	☐
Nettomiete in €	☐	☐	☐	☐	☐	☐
Zimmerzahl	☐	☐	☐	☐	☐	☐
Küche gehoben (ja/nein)	☐	☐	☐	☐	☐	☐
Temperatur in °C	☐	☐	☐	☐	☐	☐
Rang in der Klausur (1., 2., 3.)	☐	☐	☐	☐	☐	☐
Punkte in der Klausur	☐	☐	☐	☐	☐	☐
Matrikelnummer	☐	☐	☐	☐	☐	☐
Uhrzeit	☐	☐	☐	☐	☐	☐
Inflationsindex (Basisjahr = 100)	☐	☐	☐	☐	☐	☐

Auflösen

Zurücksetzen

Vorgehen in der Klausur

1. Kann ich die Werte **sinnvoll der Größe nach ordnen**? Nein → nominal.
2. Sind **Abstände sinnvoll interpretierbar**? Nein → ordinal.
3. Ist der kleinstmögliche Wert **0**? Nein → intervall.
4. Ist die **Einheit frei wählbar**? Nein → absolut. Ja → verhältnis.

Typische Fehler: Postleitzahl und Trikotnummer sind Zahlen, aber **nominal**. Schulnoten sind **ordinal** (der Abstand 1→2 ist nicht derselbe wie 4→5) – auch wenn alle Welt Notendurchschnitte bildet. Temperatur in Kelvin ist **verhältnisskaliert**, in °C nur **intervallskaliert**.

Merkmaltypen: diskret, stetig – und die Grauzone

Diskretes Merkmal

Nur endlich oder abzählbar unendlich viele Werte möglich.

→ Zimmerzahl, Stadtbezirk, Wohnlage, Kinderanzahl

Stetiges Merkmal

Alle Werte in einem Kontinuum möglich.

→ Zeitdauer, Körpergröße, Gewicht

Quasi-stetiges Merkmal

Diskret, aber mit sehr kleinen Einheiten – „praktisch“ stetig.

→ **Nettomiete in Cent**, Wohnfläche in ganzen m²

Gruppierte Daten / Häufigkeitsdaten

Wertebereich eines (quasi-)stetigen Merkmals wird in Klassen eingeteilt.

→ Mieten in 100-€-Klassen, Alter in Altersklassen

Warum das praktisch relevant ist

Der Merkmaltyp entscheidet über die **Wahl der Grafik**¹ und der **Kennwerte**:

diskret, wenige Ausprägungen	Säulendiagramm, Modus
(quasi-)stetig	Histogramm, Boxplot, Mittelwert
gruppiert	Histogramm mit Flächentreue

¹ Die genannten Grafiktypen kommen erst am Mittwoch im Kapitel *Statistische Grafiken* dran. Hier reicht: der Merkmaltyp legt fest, was überhaupt in Frage kommt.

Realität: Jede reale Messung ist quasi-stetig – wegen der begrenzten Auflösung des Messinstruments und der Gleitkommadarstellung im Rechner. „Stetig“ ist ein Modell, keine Beobachtung.

Bemerkung: Gruppierung dient auch dem **Datenschutz** – „Einkommen zwischen 40.000 und 50.000 €“ ist weniger identifizierend als der exakte Betrag.

Kennwerte von Merkmalen

- **Lagemaße:** Modus, Median, Quantile, die vier Mittelwerte
- **Streuungsmaße:** Spannweite, IQR, Varianz, MAD, Variationskoeffizient
- **Verteilungseigenschaften:** Modalität, Schiefe, Wölbung
- **Konzentration:** Lorenzkurve und Gini-Koeffizient

Grundlage: Kapitel 7 der Statistik-1-Folien (S. 318–398)

Zwei Fragen an jedes Merkmal

LAGEMASSZAHLEN

Wo?

- Wo liegt die „Mitte“ der beobachteten Werte?
- Welche Merkmalsausprägung ist „typisch“?
- Wo liegen die meisten Daten?

Modus · Median · Quantile · arithmetisches / gewichtetes / geometrisches /
harmonisches / getrimmtes Mittel

STREUUNGSMASSZAHLEN

Wie unsicher?

- Wie groß ist die Schwankung der Werte?
- Über welchen Bereich erstrecken sich die Ausprägungen?
- Wodurch kommen die Unterschiede zustande?

Spannweite · Quartilsabstand · Varianz & Standardabweichung · MAD &
MedAD · Variationskoeffizient

Modus, Median und Quantile

Modus x_{mod}

Der häufigste Wert.

- oft **nicht eindeutig**
- nur bei gruppierten Daten oder wenigen Ausprägungen sinnvoll
- überträgt sich direkt bei **allen eindeutigen** Transformationen
- geeignet für **jedes** Skalenniveau – auch nominal
- meist nur bei **diskreten** Merkmalen sinnvoll – bei stetigen Merkmalen kommt praktisch jeder Wert nur einmal vor

Im Datensatz: Modus der Zimmerzahl = 3 (369 von 964 Wohnungen).

Median $\bar{x}$

Mind. 50 % der Daten sind $\leq \bar{x}$ und mind. 50 % sind $\geq \bar{x}$.

$$\bar{x} = \begin{cases} x_{(k)} & k = \frac{n+1}{2} \in \mathbb{N} \\ \frac{1}{2}(x_{(k)} + x_{(k+1)}) & k = \frac{n}{2} \in \mathbb{N} \end{cases}$$

mit $x_{(1)} \leq \dots \leq x_{(n)}$ den **geordneten** Werten.

- ab **ordinalem** Skalenniveau
- **robust** gegen extreme Werte
- überträgt sich bei **monotonen** Transformationen

Anschaulich: Der Median ist der Wert, bei dem die Summe der **absoluten** Abstände zu allen Beobachtungen am kleinsten wird.

p -Quantil $\bar{x}_p$


Mind. Anteil p der Daten $\leq \bar{x}_p$, mind. Anteil $1 - p \geq \bar{x}_p$.

$$\bar{x}_p = \begin{cases} x_{(k)} & np \notin \mathbb{N}, k = [np] \\ \in [x_{(k)}; x_{(k+1)}] & k = np \in \mathbb{N} \end{cases}$$

- p -Quantil $\equiv$ (100 p)-Perzentil
- Median = 0,5-Quantil
- $\bar{x}_{0.25}, \bar{x}_{0.75}$: unteres / oberes **Quartil**

Achtung: Es gibt viele alternative Quantildefinitionen – in R allein neun Typen.
Beispiel $x = (1, 2, 3, 4)$, $p = 0,25$, also $np = 1$:
• Vorlesung / R-Typ 2: $\frac{1}{2}(x_{(1)} + x_{(2)}) = 1,5$
• R-Typ 1 (untere Treppenfunktion): $x_{(1)} = 1$
• R-Typ 7 (R-Standard, lineare Interpolation): 1,75
Bei großem n und mittleren p fällt der Unterschied kaum ins Gewicht – **in der Klausur gilt die Definition der Vorlesung.**

Quantile an echten Daten

Merkmal p $0,50$ Stichprobengröße n


Rechenweg: $n = 964$, $p = 0,50 \Rightarrow n \cdot p = 482,00$ ist **ganzzahlig** $\Rightarrow \tilde{x}_p = \frac{1}{2} \cdot (x_{(482)} + x_{(483)}) = \frac{1}{2} \cdot (8,33 + 8,33) = 8,33 \text{ €/m}^2$

n	964	Minimum	1,80
$\tilde{x}_{0,25}$	6,74	Median $\tilde{x}$	8,33
$\tilde{x}_{0,75}$	9,97	Maximum	18,26
IQR d_Q	3,23	Mittelwert $\bar{x}$	8,27

Rechenrezept für die Klausur

1. Werte **sortieren** $\rightarrow x_{(1)}, \dots, x_{(n)}$
2. np ausrechnen
3. Ist np **keine** ganze Zahl: aufrunden, das ist der Index k , Ergebnis $x_{(k)}$
4. Ist np **ganzzahlig**: Mittelwert aus $x_{(np)}$ und $x_{(np+1)}$

Stellt n auf **9** oder **20** – dann seht ihr die beiden Fälle der Definition nebeneinander: Bei $n = 20$ und $p = 0,25$ ist $np = 5$ ganzzahlig, also wird gemittelt. Bei $n = 9$ und $p = 0,25$ ist $np = 2,25$, also $x_{(3)}$.

Die vier Mittelwerte – und wann man welchen nimmt

Arithmetisches Mittel $\bar{x}$

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{n} \sum_{j=1}^k h_j a_j = \sum_{j=1}^k f_j a_j$$

Ab **Intervallskala**. „Schwerpunkt“ der Daten. **Nicht robust**.

Analog zum Median: $\bar{x}$ macht die Summe der **quadratierten** Abstände zu allen Beobachtungen minimal.

Gewichtetes Mittel $\bar{x}_w$

$$\bar{x}_w = \frac{1}{\sum_{i=1}^n w_i} \sum_{i=1}^n w_i x_i, \quad w_i \geq 0$$

Verallgemeinerung: mit $w_i = 1$ erhält man $\bar{x}$.

Wofür man das braucht: Umfragen, die nicht repräsentativ sind – sind Junge unterrepräsentiert, bekommen sie ein höheres Gewicht (*Post-Stratifikation*). Ebenso: Notendurchschnitt nach ECTS, Verbraucherpreisindex nach Warenkorbanteilen, Meta-Analysen nach Studiengröße.

Getrimmtes Mittel $\bar{x}_\alpha$

$$\bar{x}_\alpha = \frac{1}{n - 2r} \sum_{i=r+1}^{n-r} x_{(i)}, \quad r = \lfloor n\alpha \rfloor$$

Unten und oben je Anteil α abschneiden → **robuster**.

Variante **winsorisiertes Mittel**: die extremen Werte werden nicht gelöscht, sondern durch die entsprechenden Quantile **ersetzt**.

Wofür man das braucht: Wertungen im Sport (Eiskunstlauf, Turmspringen: höchste und niedrigste Note fallen raus). Reaktionszeiten in der Psychologie, wo einzelne Messungen durch Unaufmerksamkeit völlig aus dem Rahmen fallen. Sensordaten mit gelegentlichen Fehlmessungen.

Geometrisches Mittel $\bar{x}_G$

$$\bar{x}_G = \sqrt[n]{\prod_{i=1}^n x_i} = \exp\left(\frac{1}{n} \sum_{i=1}^n \log x_i\right)$$

Ab **Verhältnisskala**, nur für $x_i > 0$.

Merksatz: Immer dann, wenn die Werte **multiplikative Faktoren** sind.

Beispiele: Renditen und Verzinsung · Bevölkerungs- oder Fallzahlwachstum (der *R*-Wert einer Epidemie wird geometrisch gemittelt) · **Odds Ratios** in der Biostatistik · der **Human Development Index** ist das geometrische Mittel dreier Teilindizes · Verdünnungsreihen und Antikörpertiter in der Labormedizin.

Harmonisches Mittel $\bar{x}_H$

$$\bar{x}_H = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}} = \left(\frac{1}{n} \sum_{i=1}^n x_i^{-1} \right)^{-1}$$

Ab **Verhältnisskala**, nur für $x_i > 0$.

Merksatz: Immer dann, wenn die Werte **Quotienten unterschiedlicher Skalen** sind.

Beispiele: Geschwindigkeiten (km/h) · Kurs-Gewinn-Verhältnisse · der **F1-Score** im Machine Learning ist das harmonische Mittel aus Precision und Recall · durchschnittliche Bearbeitungsrate, wenn mehrere Personen unterschiedlich schnell dieselbe Menge Arbeit erledigen.

Es gilt immer $\bar{x}_H \leq \bar{x}_G \leq \bar{x}$ (bei positiven Werten, Gleichheit nur wenn alle x_i gleich sind).

Warum das nicht egal ist

Geometrisches Mittel: Renditen

Anfangskapital 100 €. Q1: +20 % · Q2: +50 % · Q3: -40 %

Faktoren	1,2	1,5	0,6
Kapital nach jedem Quartal	120	180	108
arithm. Mittel der Faktoren	1,10 → ergäbe 133,1 ×		
geom. Mittel der Faktoren	1,026 → ergibt 108,0 ✓		

$\bar{x}_G = \exp\left(\frac{1}{3}(\log 1,2 + \log 1,5 + \log 0,6)\right) = 1,026$, und $100 \cdot 1,026^3 = 108$. Nur das geometrische Mittel ist die „effektive Verzinsung pro Periode“.

Harmonisches Mittel: Geschwindigkeiten

Ihr fahrt die ersten 100 km mit 30 km/h, die zweiten 100 km mit 100 km/h.
Durchschnittsgeschwindigkeit?

Gesamtstrecke	200 km
Gesamtzeit	3,33 h + 1 h = 4,33 h
Wahre Durchschnittsgeschwindigkeit	46,2 km/h
arithm. Mittel	$\frac{30 + 100}{2} = 65$ ×
harm. Mittel	$\frac{2}{\frac{1}{30} + \frac{1}{100}} = 46,2$ ✓

Fünf Wege, Streuung zu messen

Spannweite (Range)

$$sp = x_{\max} - x_{\min}$$

Extrem sensibel gegen Ausreißer. Hauptanwendung: **Datenqualitätskontrolle** – Plausibilität, Eingabefehler, Fehlmessungen.

Quartilsabstand (IQR)

$$d_Q = x_{0.75} - x_{0.25}$$

Bereich der **mittleren Hälfte** der Daten. Länge der Box im Boxplot. **Robust**. Bereits ab ordinaler Skala verwendbar.

Stichprobenvarianz & Stichprobenstandardabweichung

$$s_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2, \quad s_x = \sqrt{s_x^2}$$

$$\mathfrak{s}_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

„Mittlere Abweichung vom Mittelwert“. Ab **Intervallskala**, **nicht robust**. $n-1$ bei Stichproben, n bei Vollerhebungen.¹

¹ Die übliche Begründung „ein Freiheitsgrad geht für $\bar{x}$ drauf“ ist nur die halbe Wahrheit. Der eigentliche Grund ist ein **Bias-Variance-Trade-off** beim Schätzen – das kommt in der Inferenzstatistik.

Mittlere absolute Abweichung

$$MAD_x = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}| \leq \mathfrak{s}_x$$

$$MedAD_x = \text{Median}(|x_i - x_{\text{med}}|)$$

Einfacher zu interpretieren als s_x , weniger ausreißerempfindlich (vor allem MedAD) – aber theoretisch weniger schön, daher seltener verwendet.

Variationskoeffizient

$$v = \frac{\mathfrak{s}_x}{\bar{x}}, \quad \bar{x} > 0$$

Einheitenlos und skalenunabhängig. Maß für die *relative* Schwankung. Nur für Merkmale mit positiven Ausprägungen sinnvoll.

Wozu? Um Streuungen von Merkmalen mit verschiedenen Einheiten zu vergleichen – streut die Nettomiete (in €) stärker als die Wohnfläche (in m²)?

In unseren Daten: Nettomiete $v = \frac{246,84}{575,13} = 0,43$ vs. Miete pro m² $v = \frac{2,43}{8,27} = 0,29$.

Die Miete pro Quadratmeter ist also relativ homogener – erwartbar, denn die absolute Miete hängt stark von der Wohnungsgröße ab.

Transformationsregeln, Verschiebungssatz, Streuungszerlegung

Lineare Transformation

Sei $y_i = a + b x_i$. Dann gilt:

$$\bar{y} = a + b \bar{x}$$

$$s_y^2 = b^2 s_x^2, \quad \tilde{s}_y = |b| \tilde{s}_x$$

Ganz allgemein gilt $g(\bar{x}) \neq \bar{g(x)}$ – nur bei **linearen** g darf man vertauschen. (Das ist genau die Jensen-Ungleichung, die euch in Statistik 2 wiederbegegnet.)

Beispiel: Die mittlere Miete pro m² ist **nicht** die mittlere Miete geteilt durch die mittlere Fläche.
 $575, 13/70, 97 = 8, 10$, aber $\text{nmqm} = 8, 27$.

Verschiebungssatz

Für jedes $c \in \mathbb{R}$ gilt:

$$\frac{1}{n} \sum_{i=1}^n (x_i - c)^2 = s_x^2 + (\bar{x} - c)^2$$

Mit $c = 0$ folgt die bekannte Rechenformel:

$$\begin{aligned} s_x^2 &= \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 \\ &= \overline{x^2} - \bar{x}^2 \end{aligned}$$

In der Klausur: Diese Form spart per Hand oft viel Zeit – ihr braucht nur $\sum x_i$ und $\sum x_i^2$.

Achtung: Diese Kurzform gilt nur für die Variante mit $\frac{1}{n}$. Für die Stichprobenvarianz mit $\frac{1}{n-1}$ lautet sie $s_x^2 = \frac{1}{n-1} \left(\sum_i x_i^2 - n \bar{x}^2 \right)$.


Streuungszerlegung

Daten in r Schichten aufgeteilt, Schichtmittel $\bar{x}_j$, Schichtvarianzen $s_{x_j}^2$, Umfänge n_j :

$$s_x^2 = \underbrace{\frac{1}{n} \sum_{j=1}^r n_j s_{x_j}^2}_{\text{innerhalb}} + \underbrace{\frac{1}{n} \sum_{j=1}^r n_j (\bar{x}_j - \bar{x})^2}_{\text{zwischen}}$$

Später seht ihr dieses Konzept immer wieder unter dem Namen **ANOVA** – *ANalysis Of VAriance*.

Streuungszerlegung am Beispiel: Miete nach Zimmerzahl



Der rote Punkt ist das jeweilige Schichtmittel $\bar{x}_j$, die gestrichelte Linie das Gesamtmittel $\bar{x}$.

ZIMMER	N_j	$\bar{x}_j$	$\bar{s}^2_j$
1	107	9,95	5,39
2	315	8,59	5,88
3	369	7,82	5,17
4	143	7,62	5,02
5	21	7,83	5,21
6	9	7,22	6,84
Gesamtvarianz $\bar{s}^2$			5,922
innerhalb der Schichten			5,421
zwischen den Schichten			0,501
Anteil zwischen			8,5 %

Ablesen: Die Schichtmittel liegen nah beieinander (7,2 bis 9,9 €/m²), **innerhalb** jeder Zimmerklasse streut die Miete dagegen fast genauso stark wie insgesamt.

Nur rund **8,5 %** der Gesamtvarianz entfallen auf Unterschiede **zwischen** den Zimmerklassen. Die Zimmerzahl erklärt die Quadratmetermiete also kaum – wer wissen will, warum eine Wohnung teuer ist, muss woanders suchen (Lage, Baujahr, Ausstattung).

In der Klausur kommt es rückwärts

Gegeben sind nur die **Schichtkennwerte**, gesucht ist die **Gesamtvarianz**. Dann zuerst $\bar{x}$ als gewichtetes Mittel der Schichtmittel bestimmen:


GRUPPE	n_j	$\bar{x}_j$	$\bar{s}^2_{x_j}$
unter 35	30	3,56	4,00
ab 35	20	2,06	2,25

$\bar{x} = \frac{30 \cdot 3,56 + 20 \cdot 2,06}{50} = 2,96$ · innerhalb $= \frac{30 \cdot 4,00 + 20 \cdot 2,25}{50} = 3,30$

zwischen $= \frac{30 \cdot 0,60^2 + 20 \cdot 0,90^2}{50} = 0,54 \Rightarrow \bar{s}^2_x = 3,30 + 0,54 = 3,84$

So gestellt in der Nebenfach-Klausur WiSe 25/26, Aufgabe 2(e).

Symmetrie, Schiefe und die Lageregeln



FORM	BEDEUTUNG	LAGEREGEL
linkssteil (rechtsschief)	fällt nach links steil ab, nach rechts langsam – langer Ausläufer rechts Tritt häufig auf, wenn das Merkmal nach unten beschränkt ist und kleine Werte üblich sind: Einkommen, Mieten, Wartezeiten.	$\bar{x} > \bar{x} > x_{\text{mod}}$
symmetrisch	rechte und linke Hälfte annähernd spiegelbildlich	$\bar{x} \approx \bar{x} \approx x_{\text{mod}}$
rechtssteil (linksschief)	fällt nach rechts steil ab, nach links langsam – langer Ausläufer links Tritt häufig auf, wenn das Merkmal nach oben beschränkt ist und große Werte üblich sind: Punkte in einer leichten Klausur, Lebensalter bei Tod, Erntereife in Prozent.	$\bar{x} < \bar{x} < x_{\text{mod}}$

Merkhilfe gegen die Namensverwirrung: Der Name sagt, wo die Verteilung **steil** ist. Der „Schief“-Name sagt, wo der **Ausläufer** ist. Linkssteil = rechtsschief. Und: Lageregeln sind **Daumenregeln**, keine Sätze.

Quantilkoeffizient der Schiefe

$$g_p = \frac{(\bar{x}_{1-p} - \bar{x}_{\text{med}}) - (\bar{x}_{\text{med}} - \bar{x}_p)}{\bar{x}_{1-p} - \bar{x}_p}, \quad 0 < p < 0,5$$

$g_{0,25}$ heißt **Quantilkoeffizient**. Werte: $g_p = 0$ symmetrisch, $g_p > 0$ linkssteil, $g_p < 0$ rechtssteil. **Robust**.

Momentenkoeffizient der Schiefe

$$g_m = \frac{m_3}{s_x^3} = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s_x} \right)^3$$

Das **dritte standardisierte Moment**. Gleiche Vorzeichen-Interpretation, aber **nicht robust** – dritte Potenz.

Unser Datensatz: Nettomiete $g_m = 1,11$ (deutlich linkssteil – typisch für Geld). Miete pro m² $g_m = 0,06$ (praktisch symmetrisch). Einkommens- und Preisverteilungen sind fast **immer** linkssteil: nach unten begrenzt durch 0, nach oben offen.

Wölbung (Kurtosis) – wie häufig sind Extremwerte?


Die Leitfrage: **Wie häufig treten Werte auf, die weit von der Mitte entfernt liegen** – verglichen mit dem „Berg“ in der Mitte?

$$k = \frac{m_4}{s_x^4} = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s_x} \right)^4$$

$$k^* = k - 3 \quad (\text{Exzess-Kurtosis})$$

$k^* \approx 0$	mesokurtisch	normalgipflig, wie die Normalverteilung
$k^* > 0$	leptokurtisch	steilgipflig – schmaler Gipfel, schwere Ränder , viele extreme Werte
$k^* < 0$	platykurtisch	flachgipflig – breiter Gipfel, dünne Ränder , wenige extreme Werte

Die 3 kommt nicht aus dem Nichts: Für die Normalverteilung ist $k = 3$. Deshalb zieht man 3 ab – damit die Normalverteilung als Referenz bei 0 liegt.



Anmerkung: die gängige Fehldeutung


Die Namen „steilgipflig“ und „flachgipflig“ legen nahe, die Kurtosis beschreibe die **Form des Gipfels**. Das tut sie nicht. Wegen der vierten Potenz trägt bei der Normalverteilung der Bereich $|z| < 1$ – immerhin 68 % der Daten – nur rund 4 % zu k bei, während $|z| > 2$ mit 4,6 % der Daten gut 55 % ausmacht.

Man kann Verteilungen konstruieren, die einen extrem spitzen Gipfel haben und trotzdem $k^* < 0$ sind. Lest „leptokurtisch“ also als „**mehr Extremwerte**“, nicht als „spitzer“.

Ausführlich: Westfall (2014), *Kurtosis as Peakedness, 1905–2014. R.I.P.*, The American Statistician 68(3).

Spielt damit: Wie robust sind die Maße?

Zieht die Punkte mit der Maus. Beobachtet, welche Kennwerte mitwandern – und welche stehen bleiben.



Mittelwert $\bar{x}$	20,00	Median $\tilde{x}$	20,00
Modus (grob)	20,0	Spannweite	20,0
IQR d_Q	8,00	Std.abw. s_x	5,22
MAD	4,27	MedAD	4,00
Var.-koeff. v	0,261	Schiefe g_m	0,000
Quartilskoeff. $g_{0,25}$	0,000	Exzess-Kurtosis k^*	-0,589

Worauf ihr achten sollt

- Zieht **einen einzigen Punkt** nach ganz rechts: $\bar{x}$ und s_x explodieren, $\tilde{x}$, IQR und MedAD bleiben fast unverändert.
- Bei **linkssteiler** Verteilung gilt die Lageregel $\bar{x} > \tilde{x} > x_{\text{mod}}$.
- Der **Momentenkoeffizient der Schiefe** g_m reagiert viel stärker auf einen Ausreißer als der **Quartilskoeffizient** $g_{0,25}$ – dritte Potenz!
- Ein einziger extremer Wert treibt die **Exzess-Kurtosis** nach oben.

Theorie ↔ Empirie: dieselbe Idee, zwei Sprachen

Das ist die wichtigste Tabelle des heutigen Tages – sie ist die Brücke zwischen Statistik 1 und Statistik 2.

KONZEPT	THEORIE (ZUFALLSVARIABLE X)	EMPIRIE (BEOBACHTETES MERKMAL)
Merkmal	Zufallsvariable $X, Y, \dots$	Merkmal, Spalte im Datensatz
Verteilung	Wahrscheinlichkeitsfunktion / Dichte $f_X(a)$	relative Häufigkeit f_j
Verteilungsfkt.	$F_X(x) = P(X \leq x)$	empirische VF $\widehat{F}(x) = \text{Anteil UE mit } x_i \leq x$
Lage	$E(X) = \int x f(x) dx$	$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \sum_{j=1}^k a_j f_j$
Streuung	$\text{Var}(X) = \int (x - E(X))^2 f(x) dx$	$s_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$
Median	$x_{\text{med}}: F_X(x_{\text{med}}) = 0,5$	$\widetilde{x} = x_{(\lfloor n/2 \rfloor)}$
Modus	$x_{\text{mod}} = \arg \max_x f_X(x)$	$\mathfrak{x}_{\text{mod}}: h(\mathfrak{x}_{\text{mod}}) \geq h(a_j) \quad \forall j$
Schiefe	$E \left[\left(\frac{X - E(X)}{\sigma(X)} \right)^3 \right]$	$g_m = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s_x} \right)^3$
Wölbung	$E \left[\left(\frac{X - E(X)}{\sigma(X)} \right)^4 \right]$	$k = \frac{1}{n} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s_x} \right)^4$

Die Struktur ist identisch: Integral ↔ Summe, Dichte ↔ relative Häufigkeit. Wer das einmal verstanden hat, muss in Statistik 2 nur noch die Notation lernen, nicht das Konzept. In der Schätztheorie fragt man dann: Wie gut schätzt die rechte Spalte die linke?

Lorenzkurve & Gini-Koeffizient

Grundidee: Grafisch darstellen, dass „die ärmsten x % der Individuen einen Anteil von y % der gesamten Merkmalssumme besitzen“.

Konstruktion

Merkmal darf nur **positive** Werte annehmen. Sei $x_{(1)} \leq \dots \leq x_{(n)}$ die geordnete Stichprobe. Setze $u_0 = v_0 = 0$ und

$$u_j = \frac{j}{n}, \quad v_j = \frac{\sum_{i=1}^j x_{(i)}}{\sum_{i=1}^n x_{(i)}}, \quad j = 1, \dots, n$$

Die Punkte (u_j, v_j) werden eingetragen und mit Linien verbunden.

Eigenschaften der Kurve

- $(u_0, v_0) = (0, 0)$ und $(u_n, v_n) = (1, 1)$ – **immer**
- verläuft immer **unterhalb** (im Grenzfall auf) der Winkelhalbierenden
- streng monoton steigend und **konvex**: jedes Segment ist mindestens so steil wie das vorherige

Gini-Koeffizient

$G = 2F$, wobei F die Fläche zwischen Diagonale und Lorenzkurve ist. Rechenformeln:

$$G = \frac{2 \sum_{i=1}^n i x_{(i)} - (n+1) \sum_{i=1}^n x_{(i)}}{n \sum_{i=1}^n x_{(i)}}$$

$$G = 1 - \frac{1}{n} \sum_{i=1}^n (v_{i-1} + v_i) = \frac{n-1}{n} - \frac{2}{n} \sum_{i=1}^{n-1} v_i$$

Wertebereich $0 \leq G \leq \frac{n-1}{n}$. Deshalb der **normierte** Gini-Koeffizient:

$$G^+ = \frac{n}{n-1} G = \frac{n}{n-1} \left(\frac{n-1}{n} - \frac{2}{n} \sum_{i=1}^{n-1} v_i \right) \\ = 1 - \frac{2}{n-1} \sum_{i=1}^{n-1} v_i \in [0, 1]$$

$G^+ = 0$: keine Konzentration (Gleichverteilung). $G^+ = 1$: volle Konzentration (Monopol).

Wichtige Einschränkung: Sehr **unterschiedliche** Lorenzkurven können denselben Gini-Wert liefern. Der Gini ist unempfindlich gegen **relatives** Wachstum (alle Werte mal 2 $\rightarrow G$ unverändert), aber empfindlich gegen Ausreißer am oberen Ende.

Lorenzkurve aus gruppierten Daten

In der Klausur liegt fast nie eine Urliste vor, sondern eine **Häufigkeitstabelle**. Dann gilt: **Klassenmitten** als repräsentative Werte, **Häufigkeiten** als Gewichte.

Bestellwerte eines Online-Shops, $n = 100$ Bestellungen:

KLASSE [€]	h_j	MITTE m_j	$h_j m_j$	u_j	v_j
[0, 50)	40	25	1000	0,40	0,103
[50, 100)	30	75	2250	0,70	0,333
[100, 200)	20	150	3000	0,90	0,641
[200, 500)	10	350	3500	1,00	1,000
Σ	100	–	9750	–	–

$$u_j = \frac{\text{kumulierte Anzahl}}{n}, \quad v_j = \frac{\text{kumulierte Merkmalssumme}}{\sum_j h_j m_j}$$

$$\text{Beispiel: } v_2 = \frac{1000 + 2250}{9750} = 0,333$$

Den Punkt lesen können

(0,70; 0,333) heißt:

Die **70 % kleinsten Bestellungen** machen zusammen nur **33,3 %** des gesamten Bestellwerts aus. Umgekehrt: die obersten 30 % bringen zwei Drittel des Umsatzes.

Gini aus der Tabelle

Mit ungleich breiten Schritten auf der u -Achse gilt die Trapezformel:

$$G = 1 - \sum_j (u_j - u_{j-1})(v_j + v_{j-1})$$

Hier: $G = 0,469$, also $G^+ = \frac{100}{99} \cdot 0,469 = 0,474$ – mittlere Konzentration.

Zwei Fallen: (1) Die einfache Formel $G = 1 - \frac{1}{n} \sum (v_{j-1} + v_j)$ gilt nur bei **gleich großen** Schritten auf der u -Achse – bei gruppierten Daten sind die Schritte unterschiedlich breit. (2) Die Klassenmitte ist eine **Annahme**: Sie unterstellt, dass die Werte innerhalb der Klasse gleichmäßig liegen. Bei der letzten, sehr breiten Klasse [200, 500) ist das oft falsch.

So gestellt in der Nebenfach-Klausur WiSe 25/26, Aufgabe 4, und ähnlich in WiSe 24/25 Nachklausur, Aufgabe 2(f).

Lorenzkurve zum Anfassen

5 Bauern, je 20 ha


4 haben nichts, 1 hat alles

Nettomieten (n=964)

50 % ohne Anteil

untere 75 % teilen 25 %

Bestellwerte (gruppiert)



Datensatz5 Bauern, je 20 ha

n5

Gini G0,0000

normiert G+0,0000

Fläche F = G/20,0000

J	X (j)	U j	V j
0	—	0,000	0,000
1	20,0	0,200	0,200
2	20,0	0,400	0,400
3	20,0	0,600	0,600
4	20,0	0,800	0,800
5	20,0	1,000	1,000

Vergleicht die letzten beiden Datensätze: **identischer Gini-Wert, völlig verschiedene Kurven**. Genau davor warnt die Vorlesung. Ein Gini-Wert allein sagt euch nicht, *wie* die Konzentration zustande kommt.

Zum Vergleich: Der Gini der individuellen **Nettovermögen** in Deutschland liegt bei ca. **0,77–0,80**. Der Gini unserer Nettomieten bei nur 0,23 – Mieten sind eben viel gleichmäßiger verteilt als Vermögen.

Häufigkeitsverteilungen & empirische Verteilungsfunktion

- Von der **Urliste** zur **Häufigkeitstabelle** – und was dabei verloren geht
- **Kennwerte aus einer Häufigkeitstabelle** berechnen
- Die **ecdf** $F_n(x)$ – Aufbau, Eigenschaften
- Aus einer ecdf **ablesen**: Anteile, Quantile, Median, Modus, Schiefe

Grundlage: Kapitel 5 der Statistik-1-Folien (S. 209–225)

Von der Urliste zur Häufigkeitstabelle

Notation – das braucht ihr wörtlich

X	Merkmal – der Spaltenname
$x_1, \dots, x_n$	Urliste / Rohdaten – die Einträge der Spalte
$a_1, \dots, a_k$	Menge der Merkmalsausprägungen – die unique Einträge der Spalte (der Größe nach sortiert, wenn sinnvoll)
$h_j = h(a_j)$	absolute Häufigkeit – wie häufig taucht a_j in der Spalte auf?
$f_j = h_j/n$	relative Häufigkeit – ein Anteil, immer in $[0, 1]$
$h_1, \dots, h_k$	absolute Häufigkeitsverteilung , analog $f_1, \dots, f_k$ relativ

Immer gilt $\sum_j h_j = n$ und $\sum_j f_j = 1$. Das ist die schnellste Kontrolle, ob ihr euch verzählt habt.

Zwei Indizes, zwei Bedeutungen – nicht verwechseln: i läuft über die **Untersuchungseinheiten** ($1 \dots n$, also über die Zeilen), j läuft über die **Ausprägungen** ($1 \dots k$). Es gilt immer $k \leq n$.

Am Datensatz: die Spalte rooms

i	NM	WFL	ROOMS	BJ
1	741,39	68	2	1918
2	715,82	65	2	1995
3	528,25	63	3	1918
4	553,99	65	3	1983
5	698,21	100	4	1995

Die ersten fünf Wohnungen des Mietspiegels. Wir betrachten nur die grüne Spalte, also $n = 5$.

Dieselben fünf Zahlen in der Notation

X	rooms – die Zimmerzahl
n	5 Untersuchungseinheiten (Zeilen)
$x_1, \dots, x_5$	2, 2, 3, 3, 4 – die Spalte von oben nach unten
a_1, a_2, a_3	2, 3, 4 – unique und sortiert, also $k = 3$
h_1, h_2, h_3	2, 2, 1 – die 2 kommt zweimal vor, die 3 zweimal, die 4 einmal
f_1, f_2, f_3	0,4; 0,4; 0,2

Kontrolle: $2 + 2 + 1 = 5 = n$ ✓ und $0,4 + 0,4 + 0,2 = 1$ ✓

Beachtet: x_3 und a_3 sind **zwei völlig verschiedene Dinge**. $x_3 = 3$ ist die dritte Wohnung, $a_3 = 4$ ist die dritte Ausprägung.

Kennwerte aus einer Häufigkeitstabelle

Beispiel: Wir haben $n = 50$ Studierende gefragt: „Wie viele Absagen habt ihr kassiert, bis es mit der Wohnung geklappt hat?“

a_j ABSAGEN	0	1	2	3	4	5	6	8	16
h_j Anzahl	8	17	9	7	4	2	1	1	1
f_j	0,16	0,34	0,18	0,14	0,08	0,04	0,02	0,02	0,02
kumuliert $F_n(a_j)$	0,16	0,50	0,68	0,82	0,90	0,94	0,96	0,98	1,00

Mittelwert

$$\bar{x} = \frac{1}{n} \sum_{j=1}^k a_j h_j = \sum_{j=1}^k a_j f_j$$

$$\bar{x} = \frac{0 \cdot 8 + 1 \cdot 17 + 2 \cdot 9 + \dots + 16 \cdot 1}{50} = \frac{112}{50} = 2,24$$

Median

$n \cdot p = 50 \cdot 0,5 = 25$ ist **ganzzahlig** $\Rightarrow \bar{x} = \frac{1}{2}(x_{(25)} + x_{(26)})$.
 Kumuliert: bis $a = 0$ sind es 8 Werte, bis $a = 1$ genau 25. Also
 $x_{(25)} = 1, x_{(26)} = 2$.
 $\Rightarrow \bar{x} = \frac{1}{2}(1 + 2) = 1,5$

Rechenrezept

1. Zeile $f_j = h_j/n$ ergänzen, Zeile **kumuliert** ergänzen (wenn nicht bereits gegeben). Beides kostet 30 Sekunden und rettet jede Teilaufgabe.
2. **Modus**: größtes h_j suchen $\Rightarrow x_{\text{mod}} = 1$ (17 Nennungen).
3. **Mittelwert**: $\sum a_j h_j$ und durch n teilen. Nicht die a_j mitteln!
4. **Median / Quantile**: in der kumulierten Zeile die erste Stelle $\geq p$ suchen, dann die Ganzzahl-Regel aus Tag 1 anwenden.
5. **Varianz**: $s_x^2 = \sum_j (a_j - \bar{x})^2 f_j$ – dieselbe Gewichtung.


Häufig gesehener Fehler

$$\bar{x} = \frac{0 + 1 + 2 + 3 + 4 + 5 + 6 + 8 + 16}{9} = 4,78 - \text{das ist der Mittelwert der}$$

Ausprägungen, nicht der **Daten**. Die 17 Leute mit einer Absage zählen siebzehnmal, nicht einmal. Wer das verwechselt, verliert die ganze Teilaufgabe.

Und direkt weiterdenken: $x_{\text{mod}} = 1 < \bar{x} = 1,5 < \bar{x} = 2,24$ – nach der Lageregel von Tag 1 also **linkssteil / rechtsschief**. Die eine Person mit 16 Absagen zieht den Mittelwert nach rechts, den Median nicht. Wer nach der *typischen* Zahl an Absagen gefragt wird, nennt deshalb den **Median**.

Die empirische Verteilungsfunktion $F_n(x)$



$F_n(8) = 0,980 \Rightarrow 98,0\%$ der Beobachtungen sind **höchstens** 8.

Anteil **größer** als 8: $1 - F_n(x) = 1 - 0,980 = 0,020$

Anteil **mindestens** 8: $1 - F_n(x^-) = 1 - 0,960 = 0,040$

Der Unterschied zwischen den beiden letzten Zeilen ist genau die Sprunghöhe $f_j = 0,020$.

$n = 50 \cdot k = 9$ verschiedene Ausprägungen · Modus = 1 (größter Sprung) · Median = $1,50 \cdot \bar{x} = 2,24$

Definition

$$F_n(x) = \frac{\#\{i: x_i \leq x\}}{n} = \sum_{j: a_j \leq x} f_j$$

In Worten: **der Anteil der Beobachtungen, die höchstens x sind**. Mehr steht da nicht.

Sprechweise: Wir sagen ab jetzt durchgehend **ecdf** – *empirical cumulative distribution function*. In der Vorlesung heißt dasselbe Objekt „empirische Verteilungsfunktion“, Symbol F_n .

Vier Eigenschaften der ecdf

- monoton **wachsende Treppenfunktion** mit Sprüngen an den Ausprägungen $a_1, \dots, a_k$
- **Sprunghöhe an a_j ist genau f_j** – daraus liest man die Häufigkeitstabelle zurück
- **rechtsseitig stetig** (der volle Punkt liegt rechts, der Wert $F_n(a_j)$ ist schon *inklusive* a_j)
- $F_n(x) = 0$ für $x < a_1$, $F_n(x) = 1$ für $x \geq a_k$

Theorie ↔ Empirie

Zufallsvariable X	$\cong$	Merkmal X
Träger T_X	$\cong$	Merkmalsraum $\supseteq \{a_1, \dots, a_k\}$
W.kteitsfunktion $f_X(x)$	$\leftrightarrow$	rel. Häufigkeiten f_j
Verteilungsfkt. $F_X(x)$	$\leftrightarrow$	ecdf $F_n(x)$

Dieselbe Idee in zwei Sprachen – genau wie bei den Kennwerten gestern. Ab Woche 2 arbeitet ihr nur noch mit der linken Spalte.

Die fünf Fragen, die man an eine ecdf stellt

FRAGE	SO GEHT'S	AM BEISPIEL „ABSAGEN“ (n = 50)
„Anteil mit höchstens x?“	Direkt $F_n(x)$ ablesen – senkrecht hoch bis zur Stufe, waagrecht nach links.	$F_n(2) = 0,68 \Rightarrow 68\%$ der Befragten hatten höchstens 2 Absagen.
„Anteil mit mindestens x?“	$1 - F_n(x^-)$, also eins minus dem Wert direkt vor dem Sprung . Der Wert x selbst gehört dazu!	Anteil ≥ 2 : $1 - F_n(1) = 1 - 0,50 = 0,50$ – und nicht $1 - F_n(2) = 0,32$.
„Welcher Wert gehört zu p?“ (Quantil, Median)	Auf der y-Achse bei p waagrecht nach rechts bis zur Kurve, dann herunter. Trifft man eine waagrechte Stufe genau , gilt die Ganzzahl-Regel aus Tag 1: Mitte zwischen den beiden Nachbarwerten.	$p = 0,68$: $50 \cdot 0,68 = 34$ ganzzahlig, die Stufe wird exakt getroffen $\Rightarrow \bar{x}_{0,68} = \frac{1}{2}(2 + 3) = 2,5$ $p = 0,50$ (Median): $F_n(1) = 0,50$ exakt $\Rightarrow \bar{x} = \frac{1}{2}(1 + 2) = 1,5$
„Modus?“	Der höchste Sprung . Nicht die höchste Stelle der Kurve – die ist immer ganz rechts.	Größter Sprung: $0,50 - 0,16 = 0,34$ bei $a = 1 \Rightarrow x_{\text{mod}} = 1$
„Schiefe?“	Modus und Median aus der Grafik, $\bar{x}$ ist meist gegeben $\Rightarrow$ Lageregel von Tag 1 anwenden.	$1 < 1,5 < 2,24 \Rightarrow$ linkssteil / rechtsschief , langer Ausläufer nach rechts.

Der Rückweg

Aus einer ecdf und n lässt sich die **komplette Häufigkeitstabelle** rekonstruieren: Sprungstellen $= a_j$, Sprunghöhen $= f_j$, mal n ergibt h_j . Bei **gruppierten** Daten muss die Kurve in jeder Klasse genau um f_j steigen – damit prüft ihr, ob eine gezeigte ecdf zu einer gegebenen Tabelle passen kann.

Woran man die Form erkennt

-  **steil $\rightarrow$ flach**: rechtsschief (linkssteil), langer Ausläufer rechts
-  **flach $\rightarrow$ steil**: linksschief (rechtssteil), Ausläufer links
-  **flach $\rightarrow$ steil $\rightarrow$ flach**: eingipflig und **symmetrisch**, Masse in der Mitte, wenige Extremwerte auf beiden Seiten
-  **steil $\rightarrow$ flach $\rightarrow$ steil**: **zweigipflig** – die flache Stelle ist die Lücke zwischen den Gipfeln
-  **gleichmäßige Steigung**: annähernd gleichverteilt

Typische Fehler

- „mindestens“ als $1 - F_n(x)$ statt $1 - F_n(x^-)$ rechnen
- Modus als die Stelle mit dem größten F_n -Wert lesen
- eine ecdf für ein **nominales** Merkmal zeichnen – geht nicht, es gibt keine Ordnung
- Bei der Quantilsfrage die Ganzzahl-Regel vergessen

Zusammenhangsmaße

Ab hier schauen wir immer auf **zwei** Merkmale gleichzeitig. Welches Maß erlaubt ist, entscheidet allein das **Skalenniveau der beiden** – das ist der rote Faden durch den ganzen Teil.

nominal – nominal	Kontingenztafel, bedingte Häufigkeiten, χ^2 , K , K^*
binär – binär	Odds und Odds Ratio
metrisch – metrisch	Kovarianz S_{xy} , Bravais-Pearson r_{xy}
(mindestens) ordinal	Spearman r_{xy}^{SP} , Kendall τ_{xy}
binär – metrisch	Sensitivität, Spezifität, ROC-Kurve, AUC

Grundlage: Kapitel 4 (S. 132–188) und Kapitel 11 (S. 528–599) der Statistik-1-Folien. In der Kopfzeile jeder Folie steht, für welche Kombination das gerade behandelte Maß gedacht ist.

Die Kontingenztafel

$(k \times m)$ -Tafel der absoluten Häufigkeiten

	b_1	...	b_m	Σ
a_1	h_{11}	...	h_{1m}	$h_{1.}$
$\vdots$	$\vdots$		$\vdots$	$\vdots$
a_k	h_{k1}	...	h_{km}	$h_{k.}$
Σ	$h_{.1}$	...	$h_{.m}$	n

$h_{i.} = \sum_j h_{ij}$ (Zeilensumme, **Randhäufigkeit von X**) · $h_{.j} = \sum_i h_{ij}$

(Spaltensumme, Randhäufigkeit von Y)

Der **Punkt steht für „aufsummiert“**: In $h_{.2}$ ist der erste Index weggesummt, der zweite fest – also die Spaltensumme der 2. Spalte.

Relativ: $f_{ij} = h_{ij}/n$, $f_{i.} = h_{i.}/n$, $f_{.j} = h_{.j}/n$, $\sum_{i,j} f_{ij} = 1$.

Die eine Frage, die alles entscheidet: Teile ich durch n , durch die **Zeilensumme** oder durch die **Spaltensumme**? $f_{ij} \rightarrow$ durch n . $f(Y | X) \rightarrow$ durch die Zeilensumme. $f(X | Y) \rightarrow$ durch die Spaltensumme. Der Strich zeigt auf das, wodurch geteilt wird.

Unser Beispiel für die nächsten Folien

Wir haben $n = 200$ Studierende nach ihrer **Wohnform** (X) und ihrer **Zufriedenheit mit der Wohnsituation** (Y) gefragt.

$X \setminus Y$	UNZUFRIEDEN	ZUFRIEDEN	SEHR ZUFRIEDEN	$h_{i.}$
WG	20	30	30	80
eigene Wohnung	10	20	30	60
bei den Eltern	15	9	6	30
Wohnheim	15	11	4	30
$h_{.j}$	60	70	70	200

Drei Größen, drei verschiedene Nenner

$h_{.2}$	Spaltensumme zu „zufrieden“	$= 30 + 20 + 9 + 11 = 70$
f_{31}	Zelle Zeile 3, Spalte 1, durch n	$= 15/200 = 0,075$
$f(X = 2 Y = 1)$	bedingt auf Spalte 1 $\rightarrow$ durch $h_{.1}$	$= 10/60 = 0,167$

χ^2 , Kontingenzkoeffizient K und K^*

Die Idee in einem Satz

X und Y heißen **empirisch unabhängig**, wenn die Verteilung von Y in jeder Schicht $X = a_i$ dieselbe ist. Daraus folgen die Häufigkeiten $\bar{h}_{ij}$, die man bei **gleichen Randverteilungen** unter Unabhängigkeit erwarten würde – und χ^2 misst, wie weit die beobachteten h_{ij} davon abweichen.

$$\bar{h}_{ij} = \frac{h_{i.} \cdot h_{.j}}{n} \quad (\text{„Zeile mal Spalte durch } n\text{“})$$

$$\chi^2 = \sum_{i=1}^k \sum_{j=1}^m \frac{(h_{ij} - \bar{h}_{ij})^2}{\bar{h}_{ij}}$$

Nur für 2×2 -Tafeln $\begin{pmatrix} a & b \\ c & d \end{pmatrix}$ gibt es die Abkürzung

$$\chi^2 = \frac{n(ad - bc)^2}{(a+b)(a+c)(b+d)(c+d)}$$

Normierung

$$K = \sqrt{\frac{\chi^2}{n + \chi^2}} \in \left[0, \sqrt{\frac{M-1}{M}}\right], \quad M = \min(k, m)$$

$$K^* = \frac{K}{\sqrt{(M-1)/M}} \in [0, 1]$$

Erst K^* ist über verschiedene Tafelgrößen hinweg vergleichbar. Nur damit darf man „schwach / mittel / stark“ sagen.

In der Praxis wird trotzdem χ^2 berichtet

K und K^* sind reine **deskriptive** Normierungen – sie helfen beim Vergleichen, mehr nicht. In der Anwendung meldet man fast immer den rohen χ^2 -Wert, weil er sich **induktiv** weiterverwenden lässt: unter der Unabhängigkeitshypothese ist χ^2 näherungsweise χ^2 -verteilt (mit $(k-1)(m-1)$ Freiheitsgraden), und daraus wird ein **p-Wert**. Die Aussage „so eine Abweichung tritt rein zufällig nur in 0,3 % der Fälle auf“ ist deutlich informativer als „ $K^* = 0,39$ “. Das kommt in Statistik 3.

Durchgerechnet: Wohnform x Zufriedenheit

ZEILE	$\bar{h}_{1.}$	$\bar{h}_{.2}$	$\bar{h}_{.3}$
WG (80)	24,0	28,0	28,0
eigene Wohnung (60)	18,0	21,0	21,0
bei den Eltern (30)	9,0	10,5	10,5
Wohnheim (30)	9,0	10,5	10,5

z. B. $\bar{h}_{11} = \frac{80 \cdot 60}{200} = 24$ gegenüber beobachtet $h_{11} = 20$. Der größte Ausreißer ist $\bar{h}_{31} = 9$ gegen beobachtet 15.

Summiert man alle zwölf Beiträge $(h_{ij} - \bar{h}_{ij})^2 / \bar{h}_{ij}$, ergibt sich mit $n = 200$ und $M = \min(4, 3) = 3$:

$$\chi^2 = 22,60 \cdot K = \sqrt{\frac{22,60}{200 + 22,60}} = 0,319 \cdot K^* = \frac{0,319}{\sqrt{2/3}} = 0,390$$

⇒ ein moderater Zusammenhang zwischen Wohnform und Zufriedenheit. Auf der nächsten Folie könnt ihr euch mit „Beitrag zu χ^2 “ ansehen, welche Zellen den Wert treiben.

Drei Eigenschaften, drei Fallen


- $\chi^2 = 0 \Leftrightarrow$ empirisch unabhängig. χ^2 misst nur die **Stärke**, nie die Richtung – ein Vorzeichen gibt es nicht.
- χ^2 wächst **proportional mit n** : verzehnfacht man alle Zellen, verzehnfacht sich χ^2 . Rohe χ^2 -Werte aus verschieden großen Stichproben zu vergleichen ist deshalb sinnlos.
- Alle diese Maße benutzen nur das **Nominalskalenniveau**. Eine Ordnung in X oder Y wird komplett ignoriert – dafür braucht ihr Kendall oder Spearman.

Bedingte Häufigkeiten – und wie Unabhängigkeit aussieht

Datensatz Wohnform × Zufriedenheit (n = 200) Anzeigeh_{ij}f_{ij}f(Y | X)f(X | Y)h̄_{ij}Beitrag zu χ²

WOHNFORM X \ ZUFRIEDENHEIT Y	UNZUFRIEDEN	ZUFRIEDEN	SEHR ZUFRIEDEN	H _{i.}
WG	20	30	30	80
eigene Wohnung	10	20	30	60
bei den Eltern	15	9	6	30
Wohnheim	15	11	4	30
Σ	60	70	70	200

h_{ij} – gemeinsame absolute Häufigkeiten. Grün: mehr als unter Unabhängigkeit erwartet, rot: weniger. Am Rand die Randhäufigkeiten h_{i.} und h_{.j}.
n = 200 · Tafel 4×3 · χ² = 22,60 · K = 0,3187 · K* = 0,3903 (M = min(4,3) = 3)



Bedingte relative Häufigkeit

$$f_{Y|X}(b_j | a_i) = \frac{h_{ij}}{h_{i.}} = \frac{f_{ij}}{f_{i.}}$$

Merksatz: bedingte Verteilungen entstehen durch Division der h_{ij} durch die entsprechende **Zeilen-** bzw. **Spaltensumme**. Jede bedingte Verteilung summiert sich wieder zu 1.

Empirische Unabhängigkeit – so sieht sie aus

X und Y sind genau dann empirisch unabhängig, wenn die bedingte Verteilung von Y in **jeder** Schicht $X = a_i$ dieselbe ist:

$$f_{Y|X}(b_j | a_1) = \dots = f_{Y|X}(b_j | a_k) \quad \forall j$$

Im Widget: **alle Zeilen unter $f(Y | X)$ identisch** und alle Balken im Stapeldiagramm gleich aufgeteilt. Dann ist $\tilde{h}_{ij} = h_{ij}$ und damit $\chi^2 = 0$.

Prüfungstipp: beide Zahlen nebeneinander

Rechnet die $\tilde{h}_{ij}$ nicht in einer zweiten Tabelle aus, sondern schreibt sie **direkt neben die beobachteten Werte in dieselbe Zelle:**

$$102 \quad (125, 93)$$


Dann steht jedes Paar $(h_{ij}, \tilde{h}_{ij})$ direkt beieinander, ihr könnt Zelle für Zelle durchgehen, ohne zwischen zwei Tabellen hin- und herzuspringen – und seht sofort, wo die großen Abweichungen sitzen. Spart Zeit und verhindert Verrutscher in den Indizes.

Odds und Odds Ratio – das Kreuzproduktverhältnis

Beispiel Nierensteine – zwei Behandlungen ☐ auf Drittvariable bedingen

ALLE	ERFOLG	MISSERFOLG	Σ	ODDS
Behandlung A	273	77	350	3,545
Behandlung B	289	61	350	4,738
Σ	562	138	700	$\gamma = 0,748$

Odds Zeile 1: $273 : 77 = 3,545$ · **Odds Zeile 2:** $289 : 61 = 4,738$
 $\gamma = (h_{11} \cdot h_{22}) / (h_{21} \cdot h_{12}) = (273 \cdot 61) / (289 \cdot 77) = 0,748$ · $\chi^2 = 2,31$ · $K^* = 0,081$
Aggregiert $\gamma \approx 0,75 < 1$ – Behandlung B sieht besser aus (83 % vs. 78 % Erfolg). Bedingt auf die **Steingröße** ist A in **beiden** Gruppen besser ($\gamma = 2,08$ und $1,23$). Grund: A wurde überwiegend bei den schwierigen großen Steinen eingesetzt. Lehrbuch-Simpson.



Odds (Chance)

Verhältnis der Häufigkeiten von $Y = 1$ und $Y = 2$ **innerhalb** einer Zeile:

$$\gamma(1, 2 | X = a_i) = \frac{h_{i1}}{h_{i2}}$$

„20 zu 30“ = 0,667 – also 2 : 3. Eine Chance ist **kein Anteil**: sie läuft von 0 bis ∞ , nicht bis 1.

Odds Ratio

$$\gamma = \frac{h_{11}/h_{12}}{h_{21}/h_{22}} = \frac{h_{11}h_{22}}{h_{21}h_{12}}$$

Die Interpretation wörtlich: γ gibt an, um welchen **Faktor** die Chance auf $Y = 1$ statt $Y = 2$ in der Subpopulation $X = a_1$ größer ist als in der Subpopulation $X = a_2$.

- $\gamma = 1$: Odds in beiden Gruppen gleich – kein Zusammenhang
- $\gamma = 2,5$: „Die Chance, $Y = 1$ statt $Y = 2$ zu beobachten, ist in Gruppe 1 **2,5-mal so groß** wie in Gruppe 2.“
- $\gamma = 0,4$: dieselbe Chance ist in Gruppe 1 nur **40 % so groß** – gleichbedeutend mit: in Gruppe 2 ist sie $1/0,4 = 2,5$ -mal so groß.


Nicht sagen: „doppelt so wahrscheinlich“. Ein Odds Ratio ist ein Verhältnis von **Chancen**, nicht von Anteilen – bei häufigen Ereignissen weichen die beiden stark voneinander ab.

Warum das Maß so beliebt ist

- **Symmetrisch:** $\gamma(Y | X) = \gamma(X | Y)$. Deshalb darf man in einer **Fall-Kontroll-Studie** das Risiko interpretieren, obwohl man nach der Krankheit ausgewählt hat.
- Vertauschen von Zeilen **oder** Spalten $\Rightarrow 1/\gamma$. Beides vertauschen $\Rightarrow \gamma$ unverändert.
- Bei $k \times m$ -Tafeln: **zwei Zeilen und zwei Spalten herausgreifen**, gerne gegen eine Referenzkategorie.
- Es misst **Richtung und Stärke** – das kann χ^2 nicht.

Kovarianz – vier Quadranten, ein Vorzeichen

Datensatz Mietspiegel: Wohnfläche → Nettomiete ↕



$n = 964$
 $\bar{x} = 70,97$
 $\bar{y} = 575,13$
 $S_x = 24,71$
 $S_y = 246,97$
 $S_{xy} = 4.282,55$
 $r_{xy} = 0,702$
 $r_{xy}^{SP} = 0,689$

Größere Wohnungen kosten mehr – klar positiv, aber mit viel Streuung.

Kovarianz

$$S_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

- Summand i ist **positiv**, wenn x_i und y_i auf **derselben** Seite ihres Mittelwerts liegen (grüne Quadranten oben rechts und unten links), sonst negativ (rote Quadranten).
- $S_{xx} = S_x^2$ – die Kovarianz eines Merkmals mit sich selbst **ist** die Varianz.
- Der Wert hängt von den **Einheiten** ab: in Cent statt Euro ist S_{xy} hundertmal so groß. Deshalb ist er als Maßzahl unbrauchbar – nur das **Vorzeichen** ist direkt interpretierbar.

Die Normierung: Bravais-Pearson

$$r_{xy} = \frac{S_{xy}}{S_x S_y} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

Man teilt jede Abweichung durch ihre eigene Streuung – das ist genau die z-Standardisierung von Tag 1, angewendet auf beide Merkmale. Ergebnis: **dimensionslos**, immer in $[-1, 1]$.

Schaut euch die ersten beiden Datensätze an: Wohnfläche und Nettomiete korrelieren mit $r = 0,70$ stark positiv – größere Wohnung, höhere Miete. Wohnfläche und Miete **pro m²** korrelieren mit $r = -0,20$ **negativ**: große Wohnungen sind pro Quadratmeter billiger. Dasselbe Merkmal, entgegengesetztes Vorzeichen – je nachdem, wie man Y definiert.

Was r_{xy} kann – und was es nicht sieht

Eigenschaften

- $r_{xy} \in [-1, 1]$, **symmetrisch**: $r_{xy} = r_{yx}$
- $r_{xy} > 0$: „je größer X , desto größer im **Durchschnitt** Y “
- $|r_{xy}| = 1 \iff$ alle Punkte liegen **exakt** auf einer Geraden (Steigung $\neq 0, \infty$) – unabhängig davon, wie **steil** die Gerade ist
- Bei linearen Transformationen $\tilde{X} = a_X X + b_X$, $\tilde{Y} = a_Y Y + b_Y$: **Betrag bleibt gleich**. Vorzeichen kippt genau dann, wenn a_X und a_Y verschiedene Vorzeichen haben.
- $r_{xy} = 0$ heißt „**kein linearer Zusammenhang**“ – nicht gleichbedeutend mit „unabhängig“

Drei Blindstellen

Nichtlinearität	Ein exakter quadratischer Zusammenhang $y = x^2$ auf symmetrischem Bereich liefert $r_{xy} = 0$. Perfekt deterministisch, Korrelation null.
Ausreißer	Ein einziger Punkt kann r von 0,9 auf 0,1 drücken. r ist nicht robust – genau wie $\bar{x}$ und s_x .
Struktur	Vier völlig verschiedene Punktwolken können dasselbe n , $\bar{x}$, $\bar{y}$, S_x , S_y und dasselbe $r_{xy} = -0,06$ haben. Immer erst das Streudiagramm ansehen.

Kovarianzmatrix S – Mietspiegel München

	NETTOMIETE	MIETE/M ²	WOHNFL.	BAUJAHR	ZIMMER
Nettomiete	60995,0	303,7	4282,6	492,1	131,1
Miete/m ²	303,7	5,9	-12,0	16,8	-0,6
Wohnfläche	4282,6	-12,0	610,5	-100,2	20,6
Baujahr	492,1	16,8	-100,2	615,5	-2,8
Zimmer	131,1	-0,6	20,6	-2,8	1,0

Auf der Hauptdiagonalen stehen die **Varianzen** S_j^2 (grün) – denn $S_{jj} = S_j^2$. Die Matrix ist **symmetrisch**, weil $S_{xy} = S_{yx}$.

Die Zahlen sind untereinander unvergleichbar: 60995 für (Nettomiete, Nettomiete) und 1,0 für (Zimmer, Zimmer) sagen nichts über „mehr Streuung“ aus – die Einheiten sind €² und Zimmer². Genau deshalb normiert man.


Korrelationsmatrix R – dieselben Daten

	NETTOMIETE	MIETE/M ²	WOHNFL.	BAUJAHR	ZIMMER
Nettomiete	1	0,51	0,70	0,08	0,54
Miete/m ²	0,51	1	-0,20	0,28	-0,19
Wohnfläche	0,70	-0,20	1	-0,03	0,83
Baujahr	0,08	0,28	-0,03	1	-0,05
Zimmer	0,54	-0,19	0,83	-0,05	1

Zellenweise $r_{jl} = S_{jl}/(S_j S_l)$, also **R** ist die zeilen- und spaltenweise normierte **S**. Auf der Diagonalen steht deshalb immer 1. Die grafische Entsprechung ist die **Scatterplot-Matrix**.

Spearman – Pearson auf den Rängen

Datensatz Lernstunden → Punkte (gekrümmt, ein Ausreißer) ↕ ☐ im Rang-Raum zeichnen



I	A	B	C	D	E	F	G	H	Σ
Lernstunden	2,0	4,0	5,0	7,0	9,0	11,0	14,0	30,0	
rg(x)	1,0	2,0	3,0	4,0	5,0	6,0	7,0	8,0	
Punkte	35,0	48,0	42,0	55,0	66,0	60,0	71,0	74,0	
rg(y)	1,0	3,0	2,0	4,0	6,0	5,0	7,0	8,0	
d _i	0,0	-1,0	1,0	0,0	-1,0	1,0	0,0	0,0	
d _i ²	0,00	1,00	1,00	0,00	1,00	1,00	0,00	0,00	4

Σ d_i² = 4,0
r_{xy} = 0,8091 – Pearson auf den Werten
r^{SP}_{xy} = 0,9524 – Pearson auf den Rängen
Kurzformel: 1 - 6·4,0 / (8·(8²-1)) = 0,9524 ✓ identisch

Definition
Voraussetzung: X, Y mindestens **ordinal**. Idee: Bravais-Pearson, aber auf den **Rängen** statt auf den Werten.

$$r_{xy}^{SP} = \frac{\sum (rg(x_i) - \bar{rg}_X)(rg(y_i) - \bar{rg}_Y)}{\sqrt{\sum (rg(x_i) - \bar{rg}_X)^2 \sum (rg(y_i) - \bar{rg}_Y)^2}}$$

Immer gilt $\bar{rg}_X = \bar{rg}_Y = \frac{n+1}{2}$ – das muss man nie ausrechnen.

Die Klausurformel – nur ohne Bindungen!

$$r_{xy}^{SP} = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}, \quad d_i = rg(x_i) - rg(y_i)$$


- 1. x-Werte sortieren, Ränge 1...n vergeben – dasselbe für y
 - 2. **Bindungen: Durchschnittsränge.** Zwei gleiche Werte auf Platz 3 und 4 bekommen beide 3,5.
 - 3. Spalte d_i, Spalte d_i², aufsummieren, einsetzen
- Achtung:** Sobald Bindungen auftreten, ist diese Kurzformel nur noch eine Näherung – dann die lange Formel nehmen.

Interpretation und Invarianz

- r^{SP} > 0: gleichsinniger **monotoner** Zusammenhang, < 0: gegensinnig, ≈ 0: kein monotoner Zusammenhang
- r^{SP} = ±1 schon bei **jedem** streng monotonen Zusammenhang – die Punkte müssen nicht auf einer Geraden liegen
- Invariant unter **streng monotonen** Transformationen (Logarithmus, Wurzel, dritte Potenz ...). Das Vorzeichen kippt nur, wenn genau eine der beiden Transformationen fallend ist.
- Deutlich **robuster** gegen Ausreißer als Pearson: ein extremer Wert bekommt nur den Rang n, nicht sein volles Gewicht.

Kendall's τ – alle Paare durchzählen

Datensatz Lernstunden → Punkte ↕ Paare zeigen **alle** nur konkordant nur diskordant



Nach x sortiert. Eine **grüne** Verbindung steigt (konkordant), eine **rote** fällt (diskordant).

$n = 8 \Rightarrow n(n-1)/2 = 28$ Paare

$N_C = 26$ konkordant · $N_D = 2$ diskordant

$\tau = (26 - 2) / 28 = 0,8571$

Goodman & Kruskal $\gamma = 0,8571$

zum Vergleich: $r^{SP} = 0,9524$ · $r = 0,8091$

Konkordant und diskordant

Man vergleicht **Paare von Beobachtungen** (x_i, y_i) und (x_j, y_j) :

konkordant $x_i < x_j$ **und** $y_i < y_j$ (oder beide $>$) – die Rangfolgen stimmen überein

diskordant $x_i < x_j$ **aber** $y_i > y_j$ – die Rangfolgen sind vertauscht

Insgesamt gibt es $\binom{n}{2} = \frac{n(n-1)}{2}$ Paare.

$$\tau_{xy} = \frac{N_C - N_D}{n(n-1)/2}$$

⚠ Diese Definition heißt in der Literatur **Kendall's τ_a** und setzt **Bindungsfreiheit** voraus:

Gebundene Paare sind weder konkordant noch diskordant, zählen im Nenner $\binom{n}{2}$ aber mit – dann kann $|\tau_a|$ den Wert 1 nicht mehr erreichen. Dagegen gibt es τ_b (Nenner um Bindungen korrigiert) und τ_c . In der Vorlesung ist immer τ_a gemeint.

Zählschema für die Klausur

1. Beobachtungen **nach x aufsteigend sortieren** – dann gilt für jedes Paar automatisch $x_i < x_j$.
2. Nur noch die y-Spalte durchgehen: pro Zeile zählen, wie viele y-Werte **darunter größer** sind ($\rightarrow N_C$) und wie viele **kleiner** ($\rightarrow N_D$).

τ oder r^{SP} ?

- **Spearman** schaut, **wie stark** sich die Ränge unterscheiden (Rangdifferenzen d_i).
- **Kendall** schaut nur, **ob** sich die Rangfolge umdreht.
- Deshalb ist $|\tau|$ meist **kleiner** – Konstruktion, kein schwächerer Zusammenhang. Beide führen fast immer zur selben Schlussfolgerung.

Ein Score, zwei Gruppen, ein Schwellenwert

Das Setting

$Y \in \{0, 1\}$ ist die **dichotome Zielgröße**, X ein mindestens ordinaler **Score**. Aus X soll eine Vorhersage $\hat{y}$ für Y werden – über einen **Schwellenwert** c :

$$\hat{y}_i = 1 \iff x_i \geq c$$

$Y = 1$ ist per Konvention der „positive“ Fall – das heißt nicht „der erfreuliche“, sondern der, den man entdecken will.

Wo das überall vorkommt

KONTEXT	SCORE X	ZIELGRÖSSE Y
Kreditvergabe	Bonitätsscore	Kreditausfall ja/nein
Spamfilter	Spam-Wahrscheinlichkeit einer Mail	Mail ist wirklich Spam ja/nein
Personalauswahl	Punktzahl im Auswahltest	im Job erfolgreich ja/nein
Marketing	bisheriger Umsatz mit der Kundin	Vertragsverlängerung ja/nein
Qualitätskontrolle	Messwert am Bauteil	Bauteil defekt ja/nein
Medizin	Biomarker, diagnostischer Score	krank / gesund

Wir bleiben in den Beispielen bei „krank / gesund“, weil die Begriffe daher kommen. Die Rechnung ist in allen Zeilen dieselbe.

Die Vierfeldertafel – die Spalten sind die Wahrheit

	$y_i = 0$ GESUND	$y_i = 1$ KRANK
Vorhersage $\hat{y}_i = 0$	wahr negativ TN	falsch negativ FN
Vorhersage $\hat{y}_i = 1$	falsch positiv FP	wahr positiv TP


Lesehilfe für die Namen: Das zweite Wort ist immer die **Vorhersage** (positiv = „wir sagen krank“), das erste sagt, ob sie **stimmt**. „Falsch negativ“ heißt also: wir haben „gesund“ gesagt, und das war falsch.

Das Dilemma

c groß	wenige positive Vorhersagen → wenig falsch positiv, aber auch wenig wahr positiv . Wir übersehen Kranke.
c klein	viele positive Vorhersagen → wir finden fast alle Kranken, produzieren aber viele Fehlarmede .

Man kann nicht beides gleichzeitig optimieren. Welchen Fehler man lieber macht, ist eine **inhaltliche** Entscheidung: Beim Screening auf eine behandelbare Krankheit will man kaum falsch negative, bei einem teuren oder riskanten Folgeeingriff kaum falsch positive.

Der Schwellenwert c und die Vierfeldertafel



	Y = 0 GESUND	Y = 1 KRANK	Σ
Vorhersage $\hat{Y} = 0$	31 TN	8 FN	39
Vorhersage $\hat{Y} = 1$	9 FP	17 TP	26
Σ	40	25	65

Schwellenwert $c = 59,1 \Rightarrow 26$ positive Vorhersagen, davon 17 richtig.
Übersehen werden 8 Kranke (FN), fälschlich alarmiert werden 9 Gesunde (FP).

Was ihr hier sehen sollt

- Jeder Punkt ist eine Untersuchungseinheit. **Gefüllt** = wir sagen „krank“ voraus, weil $x_i \geq c$.
- Die obere Reihe sind die **echt Kranken**, die untere die **echt Gesunden**. Beides erfährt man in der Realität nur nachträglich.
- **Schiebt c ganz nach links:** alles wird positiv vorhergesagt – kein FN mehr, dafür maximal viele FP.
- **Schiebt c ganz nach rechts:** umgekehrt. Die vier Zellen wandern, die Zeilensummen der Tafel ändern sich, die **Spaltensummen bleiben fest**.

Die Spaltensummen sind Daten, die Zeilensummen sind Entscheidung

Wie viele Kranke und Gesunde es gibt, steht fest, bevor wir irgendetwas rechnen – das sind die **Spaltensummen**. Wie viele wir als krank *klassifizieren*, hängt allein an unserer Wahl von c – das sind die **Zeilensummen**.

Deshalb rechnet man alle Gütemaße des **Tests** spaltenweise. Wer zeilenweise rechnet, misst nicht mehr den Test, sondern die Zusammensetzung der Population mit. Auf der nächsten Folie wird genau das der Knackpunkt.

Stellt einmal „kein Zusammenhang“ ein. Dann liegen beide Punktwolken exakt übereinander:

Egal wo c steht, der Anteil der Gefüllten ist in beiden Reihen gleich groß. Der Score trennt nichts – und keine Wahl von c kann das reparieren.

Die vier Raten – und in welche Richtung bedingt wird

Spaltenweise: Eigenschaften des Tests

Sensitivität <i>TPR(c)</i>	$= f(\widehat{Y} = 1 \mid Y = 1) = \frac{TP}{TP + FN} = \frac{h_{22}}{h_{2.}}$ „Welcher Anteil der Kranken wurde entdeckt?“
Spezifität <i>TNR(c)</i>	$= f(\widehat{Y} = 0 \mid Y = 0) = \frac{TN}{TN + FP} = \frac{h_{11}}{h_{1.}}$ „Welcher Anteil der Gesunden wurde korrekt erkannt?“

Zeilenweise: Eigenschaften des Befunds

ppV	$= f(Y = 1 \mid \widehat{Y} = 1) = \frac{TP}{TP + FP} = \frac{h_{22}}{h_{2.}}$ „Mein Befund ist positiv – wie groß ist die Chance, dass ich wirklich krank bin?“
npV	$= f(Y = 0 \mid \widehat{Y} = 0) = \frac{TN}{TN + FN} = \frac{h_{11}}{h_{1.}}$

Indizes wie in Teil 2: Zeile *i* = Vorhersage ($\widehat{Y} = 0$ bzw. $\widehat{Y} = 1$), Spalte *j* = Wahrheit ($Y = 0$ bzw. $Y = 1$). Also $h_{22} = TP$, $h_{11} = TN$, $h_{2.} =$ alle positiven Befunde, $h_{1.} =$ alle Kranken.

Die Merkhilfe, die alles rettet

Sensitivität und Spezifität werden **spaltenweise** gerechnet (bedingt auf die **Wahrheit** *Y*), ppV und npV **zeilenweise** (bedingt auf die **Vorhersage** $\widehat{Y}$).

⚠ **Aber Vorsicht:** Diese Merkregel gilt nur für **diese** Anordnung – Vorhersage in den Zeilen, Wahrheit in den Spalten. Ein billiger, aber wirksamer Trick ist, die Tafel **transponiert** vorzulegen – oder gar keine Tafel zu geben, sondern nur einen Fließtext, aus dem ihr sie selbst bauen müsst. Dann rettet euch nur, dass ihr die Definitionen **über die Bedingung** lest: Sensitivität bedingt auf *Y*, ppV bedingt auf $\widehat{Y}$ – egal, wo das in der Tabelle steht. **Erst beschriften, dann rechnen.**

Bayes theoretisch – und empirisch

Sensitivität und ppV bedingen in **entgegengesetzte Richtungen**. Der Satz von Bayes (Woche 2, Montag) rechnet die eine in die andere um:

$$P(Y = 1 \mid \widehat{Y} = 1) = \frac{P(\widehat{Y} = 1 \mid Y = 1)P(Y = 1)}{P(\widehat{Y} = 1)}$$

Dieselbe Aussage mit unserer **Häufigkeitsnotation** – *f* statt *P*, sonst identisch:

$$f(Y = 1 \mid \widehat{Y} = 1) = \frac{f(\widehat{Y} = 1 \mid Y = 1)f(Y = 1)}{f(\widehat{Y} = 1)}$$

Die Randhäufigkeiten sind dabei genau unsere **Randhäufigkeiten aus Teil 2**: die Prävalenz $f(Y = 1) = f_{2.} = h_{2.}/n$, der Anteil positiver Befunde $f(\widehat{Y} = 1) = f_{2.} = h_{2.}/n$. Damit lautet Bayes in der **Notation der Vierfeldertafel**:

$$\frac{h_{22}}{h_{2.}} = \frac{\overset{\text{Sens.}}{\widehat{h_{22}}} \cdot \overset{\text{Präv.}}{\widehat{f_{2.}}}}{\underset{\text{ppV}}{f_{2.}}} \underset{\text{pos. Befunde}}{f_{2.}}$$

Rechts kürzen sich $h_{2.}$ und *n* weg – übrig bleibt die linke Seite. **Wenn die ganze Tafel vorliegt, ist Bayes also nichts als Kürzen.** Gebraucht wird der Satz erst, wenn man die Tafel *nicht* hat, sondern nur Sensitivität, Spezifität und Prävalenz. Den Nenner baut man dann über die totale Wahrscheinlichkeit:

$$f_{2.} = f(\widehat{Y} = 1) = TPR \cdot f_{2.} + FPR \cdot f_{1.}$$

Die Klausurfrage „Wie groß ist $P(\text{krank} \mid \text{Test positiv})$?“ ist deshalb **eine deskriptive Aufgabe, die sich als Bayes-Aufgabe verkleidet**.

Reales Beispiel: Corona-Schnelltest 2021


Gepoolte Werte einer Meta-Analyse von 2021 über alle Antigen-Schnelltests: **Sensitivität 76,3 %**, **Spezifität 99,1 %** – also *FPR* = 0,9 %. Wie viele positive Schnelltests waren wirklich Infektionen?

PRÄVALENZ	PPV	NPV
0,01 % (ruhiger Sommer 2021)	0,8 %	100,0 %
0,4 % (Winterwelle 2021)	25,4 %	99,9 %
2 % (Ausbruch in einer Einrichtung)	63,4 %	99,5 %

Die mittlere Zeile in absoluten Zahlen: Von 100 000 Getesteten sind 400 infiziert. Der Test findet davon 305 (TP) und übersieht 95 (FN). Von den 99 600 Gesunden schlagen 896 fälschlich an (FP). Es gibt also **1201 positive Befunde, von denen nur 305 stimmen** – jeder vierte.

Deshalb galt die Regel: **positiver Schnelltest → PCR zur Bestätigung**, negativer Schnelltest → ziemlich verlässlich. Und deshalb wurde bei niedriger Inzidenz nicht anlasslos massengetestet.

ROC-Kurve und AUC



	Y = 0 GESUND	Y = 1 KRANK	Σ
$\hat{Y} = 0$	31 TN	8 FN	39
$\hat{Y} = 1$	9 FP	17 TP	26
Σ	40	25	65

Sensitivität = $17/25 = 0,680$ (spaltenweise, bedingt auf Y) · Spezifität = $31/40 = 0,775$
ppV = $0,654$ · npV = $0,795$ (zeilenweise, bedingt auf die Vorhersage $\hat{Y}$) · AUC = $0,806$

Die ROC-Kurve

verbindet für **alle** möglichen Schwellenwerte c die Punkte $(FPR(c), TPR(c))$ – also **(1 – Spezifität, Sensitivität)**.

- c kleiner als alle Werte → alles positiv vorhergesagt → Punkt (1, 1), rechts oben
- c größer als alle Werte → alles negativ → Punkt (0, 0), links unten
- Die Kurve ist eine **Treppe** und startet immer in (0, 0), endet in (1, 1)
- Je weiter sie sich in die **linke obere Ecke** wölbt, desto besser trennt X die beiden Y-Gruppen

AUC – Area Under the Curve

$AUC = 1$ perfekte Trennung: es gibt ein c , das **alle** richtig klassifiziert

$AUC = 0,5$ Diagonale – der Score ist so gut wie Münzwurf

$AUC < 0,5$ der Score zeigt **in die falsche Richtung** – einfach umdrehen, dann $1 - AUC$

Schöne Interpretation: AUC ist der Anteil aller Paare (ein Kranker, ein Gesunder), bei denen der Kranke den höheren Score hat. Das ist genau ein **Paarvergleichsmaß** wie Kendalls τ – es gilt sogar $AUC = \frac{1 + D_{SY}}{2}$ mit Somers' D .

Kritik: Die AUC basiert nur auf Sensitivität und Spezifität – sie ist **unabhängig von der Prävalenz** und sagt deshalb nichts darüber, wie nützlich der Test in der Praxis ist (siehe ppV).

Und sie mittelt über **alle** Schwellenwerte, auch über völlig unbrauchbare. Zwei Kurven mit gleicher AUC können im relevanten Bereich sehr verschieden sein.

Welches Zusammenhangsmaß wann?

MASS	BRAUCHT MINDESTENS	WERTEBEREICH	MISST	BLIND GEGENÜBER / BEMERKUNG
Odds Ratio γ	zwei nominale Merkmale, ausgewertet auf einer 2x2-Tafel	$(0, \infty)$, 1 = kein Zush.	Stärke und Richtung	symmetrisch – deshalb in Fall-Kontroll-Studien interpretierbar
χ^2	zwei nominale Merkmale, $k \times m$	$[0, n(\min(k, m) - 1)]$	nur Stärke	wächst mit n – roh nicht vergleichbar, dafür induktiv nutzbar (p-Wert)
K, K^*	wie χ^2	$K^* \in [0, 1]$	nur Stärke, normiert	ignoriert jede Ordnung in X, Y
Bravais-Pearson r_{xy}	beide metrisch	$[-1, 1]$	Stärke + Richtung des linearen Zusammenhangs	nichtlineare Zusammenhänge, Ausreißer, Struktur
Spearman r_{xy}^{SP}	beide ordinal – metrische Merkmale sind damit ausdrücklich eingeschlossen	$[-1, 1]$	Stärke + Richtung des monotonen Zusammenhangs	nicht-monotone Zusammenhänge; robuster als r_{xy} , nutzt Rangabstände
Kendall τ_{xy}	beide ordinal (metrisch eingeschlossen)	$[-1, 1]$	wie Spearman, über Paarvergleiche	Spearman benutzt, wie stark sich die Ränge unterscheiden, Kendall nur, ob sie sich unterscheiden. Deshalb ist $ \tau $ meist kleiner – das ist Konstruktion, kein schwächerer Zusammenhang. Die Vorlesungsversion τ_a ist für Bindungen nicht gedacht .
ROC-Kurve / AUC	Y binär , X mindestens ordinal	$AUC \in [0, 1]$, 0,5 = Zufall	Trennschärfe von X über alle Schwellenwerte hinweg	AUC = Anteil der Paare (krank, gesund) mit höherem Score beim Kranken – also wieder ein Paarvergleichsmaß , es gilt $AUC = \frac{1 + D_{xy}}{2}$. Ignoriert die Prävalenz.

Was wir *nicht* behandelt haben

nominal ($k > 2$) x metrisch	das Korrelationsverhältnis η^2 – der Anteil der Varianz, der zwischen den Gruppen liegt. Das ist exakt die Streuungserlegung von Tag 1 .
binär x metrisch	punktbiseriale Korrelation – einfach r_{xy} mit 0/1-Codierung, ein Spezialfall von Pearson
binär x binär	φ -Koeffizient $= \sqrt{\chi^2/n}$ mit Vorzeichen von $ad - bc$; daneben das relative Risiko als Alternative zum Odds Ratio
nominal x nominal	Cramér's V und Goodman & Kruskals λ als Alternativen zu K^*
ordinale Struktur in $k \times m$-Tafeln	χ^2 „weiß“ nicht, dass die Kategorien geordnet sind. Maße, die es wissen: τ_b (Kendall mit Bindungskorrektur), Goodman & Kruskals γ $= \frac{N_C - N_D}{N_C + N_D}$ (Ignoriert gebundene Paare) und Somers' D (normiert nur auf Paare mit ungleichen y , zugeschnitten auf binäres Y – und mit $AUC = \frac{1 + D_{xy}}{2}$ direkt mit der ROC-Kurve verwandt)
beliebige Abhängigkeit	Distanzkorrelation – das einzige Maß, für das $dr_{xy} = 0$ genau dann gilt, wenn X und Y unabhängig sind
drei und mehr Merkmale	partielle Korrelation – der Zusammenhang von X und Y , nachdem der Einfluss von Z herausgerechnet wurde. Genau das Thema von Teil 3.

Zwei Sätze zum Auswendiglernen

„ $r_{xy} = 0$ bedeutet **nicht** Unabhängigkeit, sondern nur, dass kein **linearer** Zusammenhang besteht.“
„Umgekehrt gilt aber: unabhängig $\Rightarrow$ unkorreliert.“
Der Klassiker: $|r_{xy}|$ **vs.** $|r_{xy}^{SP}|$
 $|r^{SP}| > |r_{xy}|$ spricht für einen **monotonen, aber gekrümmten** Zusammenhang oder für **Ausreißer**. $|r_{xy}| > |r^{SP}|$ ist selten und deutet auf einen sehr sauberen linearen Kern mit Rangbindungen hin. Beides auf Folie 12 nachvollziehbar.

Korrelation & Kausalität


- **Fork, Pipe, Collider** – drei kausale Strukturen, eine Korrelation
- **Confounding** und Scheinkorrelationen über Drittvariablen
- **Simpson's Paradox** – wenn Bedingen das Vorzeichen dreht
- **Ökologischer Fehlschluss** und **Collider-Bias** durch Stichprobenauswahl

Grundlage: Kapitel 12 der Statistik-1-Folien (S. 600–636)

Drei Rollen für eine Drittvariable Z

Wir interessieren uns immer für denselben Effekt: $X \rightarrow Y$. Z ist eine dritte Variable, die wir gemessen haben oder auch nicht. Je nachdem, **wo Z im Kausaldiagramm sitzt**, hat sie eine völlig andere Wirkung auf das, was wir beobachten.

Z ist Confounder – Fork




Z verursacht **beide**. X und Y sind korreliert, obwohl zwischen ihnen kein Pfeil läuft – eine **Scheinkorrelation**.

Beispiel: X = Eiscremeabsatz, Y = Zahl der Badeunfälle, Z = Sonnentage im Monat. An heißen Tagen wird mehr Eis verkauft *und* es gehen mehr Leute schwimmen. Eis verursacht keine Badeunfälle.

Bedingt man auf Z (nur Monate mit gleich vielen Sonnentagen vergleichen), **verschwindet** die Assoziation. Genau das ist die Diagnose – und die Korrektur.

Z ist Mediator – Pipe




Die Wirkung von X auf Y läuft (auch) **durch Z hindurch**. Auch hier sind X und Y korreliert – diesmal aber völlig zu Recht.

Beispiel: X = Besuch des Tutoriums, Z = Zahl der selbst gerechneten Übungsaufgaben, Y = Klausurpunkte. Das Tutorium wirkt **unter anderem**, weil man danach mehr rechnet.

Bedingt man auf Z (nur Leute mit gleich vielen gerechneten Aufgaben vergleichen), verschwindet die Assoziation oder wird deutlich schwächer – sie kann sogar das Vorzeichen wechseln (Simpson's Paradox, nächste Folie).

Das ist kein Fehler, sondern eine Frage der Fragestellung: Ohne Bedingen misst man den **totalen Effekt** von X auf Y, mit Bedingen den **direkten Effekt**, der *nicht* über Z läuft. Beides ist legitim – man muss nur wissen (und dazuschreiben), welchen der beiden man berichtet.

Z ist Collider – gemeinsame Wirkung



X und Y verursachen **beide** Z. **Ohne** Bedingen sind X und Y unabhängig.

Beispiel: X = Talent, Y = Fleiß, Z = Zulassung zum Studium. Zugelassen wird, wer *talentiert oder fleißig oder beides* ist.


Bedingt man auf Z (nur Studierende ansehen), **entsteht** eine negative Korrelation, die es in der Gesamtbevölkerung nicht gibt. Die gefährlichste der drei Strukturen – weil man oft gar nicht merkt, dass man bedingt hat.

Die Kernaussage in einem Satz: Alle drei Strukturen erzeugen **dieselbe** beobachtbare Assoziation zwischen X und Y. Aus einer Korrelation allein lässt sich also weder erschließen, welche Struktur dahintersteht, noch in welche Richtung die Kausalität läuft.

Merkregel zum Bedingen: Bei **Confounder** und **Mediator** *schwächt* Bedingen die Assoziation oder lässt sie verschwinden, beim **Collider** *erzeugt* es eine. Beim Confounder ist Bedingen nötig, beim Mediator eine Frage der Fragestellung (total vs. direkt), beim Collider ein Fehler. „Kausalität“ ist hier immer stochastisch gemeint: Rauchen verursacht Lungenkrebs, auch wenn nicht jeder Raucher erkrankt.

Confounding und Simpson's Paradox

☐ nach Vorwissen (Note in der 11. Klasse) einfärben



Über alle Schüler:innen hinweg $r = -0,70$ – wer mehr Nachhilfe nimmt, schneidet *schlechter* ab. Naive Schlussfolgerung: „Nachhilfe schadet.“
Jetzt die Checkbox anhängen.

Simpson's Paradox

Kein echtes Paradox, sondern ein häufiges Phänomen: Durch Bedingen auf eine Drittvariable Z kann eine Assoziation zwischen X und Y

- **entstehen** (Titanic), **verschwinden** (Berkeley) oder **ihr Vorzeichen ändern** (Nachhilfe links).

Synonym: **omitted variable bias**.

Titanic – Assoziation entsteht

ERWACHSENE	GESTORBEN	GERETTET	RATE
3. Klasse	476	151	0,24
Crew	673	212	0,24
Bedingt auf $Z = \text{Geschlecht}$:			
Männer 3. Kl. / Crew	387 / 670	75 / 192	0,16 / 0,22
Frauen 3. Kl. / Crew	89 / 3	76 / 20	0,46 / 0,87

Aggregiert: **gleiche** Überlebensrate. Getrennt nach Geschlecht: die 3. Klasse ist in **beiden** Gruppen deutlich schlechter dran – weil der Frauenanteil in beiden Gruppen sehr verschieden ist.

Berkeley 1973 – Assoziation verschwindet

Aggregiert: Aufnahmequote Männer 45 %, Frauen 30 %, $\gamma = 1,83$ – sieht nach Benachteiligung aus. Nach **Fach** aufgeteilt liegen die Odds Ratios zwischen 0,35 und 1,22, mehrheitlich **unter 1**. Frauen bewarben sich häufiger auf Fächer mit niedriger Aufnahmequote – hier ist $Z = \text{Fach}$ ein **Mediator**, kein Confounder.

Zurück zu Folie 11: Im Odds-Ratio-Widget könnt ihr Nierensteine, Berkeley und Titanic mit einem Klick auf- und zuklappen. Das Vorgehen ist immer dasselbe: Odds Ratio je Schicht, aggregiertes Odds Ratio, vergleichen, interpretieren.

Zwei weitere Arten, sich zu täuschen

1. Ökologischer Fehlschluss – falsche Aggregationsebene

Ein Zusammenhang, der zwischen **Gruppen** gilt, muss innerhalb der Gruppen nicht gelten – und schon gar nicht für einzelne Personen.

Das Standardbeispiel (Robinson 1950): 48 US-Bundesstaaten, Volkszählung 1930, zwei Merkmale – **Anteil im Ausland Geborener** und **Anteil Lesekundiger**.

auf Ebene der
Bundesstaaten ($n = 48$)

$r = +0,53$

auf Ebene der **Personen** ($n \approx 97$ Mio.)

$r = -0,11$

Auf Staatenebene sieht es aus, als gäbe es dort mehr Lesekundige, wo viele Zugewanderte leben. Auf Personenebene waren Zugewanderte im Schnitt *seltener* lesekundig – **das Vorzeichen dreht sich um**.

Der Grund: Zugewanderte ließen sich bevorzugt in wirtschaftlich starken Staaten mit guten Schulen nieder – also dort, wo die *einheimische* Bevölkerung ohnehin besonders lesekundig war.

Faustregel: Sobald eine **Zeile** eurer Datentabelle eine **Gruppe** beschreibt – ein Land, eine Schule, einen Stadtteil – und nicht eine Person, gilt jedes Ergebnis **nur für Gruppen**. Das ist wieder die Zeilenbetrachtung von Tag 1: *Was ist eine Untersuchungseinheit?*

Die Checkliste zu jeder Zusammenhangsaussage

1. Gibt es etwas Drittes, das X und Y gleichzeitig beeinflusst?

→ **Confounder**. Der Zusammenhang verschwindet, sobald man nur Einheiten mit gleichem Z vergleicht.

2. Wirkt X auf Y über einen Zwischenschritt?
→ **Mediator**. Der Zusammenhang ist echt.

Bedingen liefert den direkten statt den totalen Effekt.

3. Musste man etwas erfüllen, um überhaupt in den Daten zu landen?

nur Zugelassene, nur Überlebende, nur Antwortende → **Collider**. Der Zusammenhang entsteht erst durch die Auswahl.

4. Beschreibt eine Zeile eine Gruppe statt eine Person?

→ **ökologischer Fehlschluss**. Das Ergebnis gilt dann nur für Gruppen.


5. Wie viele Zusammenhänge wurden geprüft?

Wer lange genug sucht, findet immer einen → schlichter **Zufall**.

2. Collider-Bias – verzerrte Stichprobenauswahl

Auch *selection bias*: Ob eine Untersuchungseinheit überhaupt in die Daten kommt, hängt von etwas ab, das **von X und Y gemeinsam verursacht** wird.

☐ nur die zugelassene Teilpopulation zeigen



Gesamtbevölkerung ($n = 200$): $r = 0,064$ – Talent und Fleiß sind hier **unabhängig** erzeugt.

Nur die Zugelassenen ($n = 79$): $r = -0,424$ – deutlich **negativ**.

Zugelassen wird, wer **Talent + Fleiß > 207** erreicht. Die fehlende Ecke unten links (wenig von beidem) erzeugt die Scheinkorrelation – es gibt in der Stichprobe niemanden, der in beidem schwach ist.

Statistische Grafiken

- **Grammar of Graphics** – woraus eine Grafik besteht, plus die ggplot2-Übersetzung
- **Ein Merkmal:** Säulendiagramm, Boxplot, Histogramm, Kerndichteschätzer
- **Zwei Merkmale:** gestapeltes Säulendiagramm, Mosaikplot, Streudiagramm
- **Mehr als zwei:** Farbskalen, Facetten, Scatterplot-Matrix

Grundlage: Kapitel 6 der Statistik-1-Folien (S. 227–300)

Grammar of Graphics – die Zerlegung jeder Grafik

Grafik = Daten + geometrische Elemente + ästhetische Zuordnung

+ Datentransformationen + Skalen + Koordinatensystem + Facettierung + Theme

Geometrische Elemente	Punkte, Linien, Rechtecke, Boxplots, Dichtefunktionen ...
Ästhetische Zuordnung	Position, Farbe, Größe, Form
Datentransformationen	Häufigkeiten h_j , Mittelwerte, Anteile, Dichteschätzung ...
Skalen	Achsenabschnitte, Farbskalen, Legenden, Beschriftungen
Koordinatensysteme	kartesisch, logarithmisch, Polarkoordinaten, Kartenprojektion
Facettierung	small multiples / Lattice-Plots
Theme	Font, Gitterlinien, Hintergrund, Textlayout – trägt nie Information

Wahrnehmungshierarchie

Wie genau Menschen Größenunterschiede ablesen können – von **am genauesten** nach **am ungenauesten**:

1. **Position**
2. Abstände / Längen
3. Steigung
4. Winkel
5. Flächen
6. Volumen
7. Farbe (Ton, Helligkeit, Sättigung)

Deshalb ist das Kreisdiagramm schlecht: Es kodiert über **Winkel** und **Flächen** – Plätze 4 und 5. Ein Säulendiagramm kodiert über **Position** und **Länge** – Plätze 1 und 2. Und 3D-Torten sind eine Beleidigung.

Goldene Regeln

- **Kommunikationsabsicht klarmachen** – was soll die Grafik zeigen?
- **Lesbarkeit maximieren**
- Korrekte Interpretierbarkeit vor Ästhetik

Die Grammatik in Code: ggplot2

KONZEPT (VORLESUNG)	GGPLOT2-BAUSTEIN	KONKRET AM MIETSPIEGEL
Daten	<code>ggplot(data = ...)</code>	<code>ggplot(miete)</code>
Ästhetische Zuordnung	<code>aes(x=, y=, colour=, fill=, size=, shape=, alpha=)</code>	<code>aes(x = wfl, y = nm, colour = lage)</code> Merkmal → Position / Farbe
Geometrische Elemente	<code>geom_*()</code>	<code>geom_point()</code> · <code>geom_bar()</code> / <code>geom_col()</code> · <code>geom_histogram()</code> · <code>geom_boxplot()</code> · <code>geom_density()</code> · <code>geom_step()</code> für die ecdf
Datentransformation	<code>stat_*()</code> bzw. das <code>stat=</code> -Argument in <code>geom_*()</code>	<code>geom_bar()</code> zählt selbst aus (<code>stat_count</code>), <code>geom_col()</code> nimmt die Werte wie sie sind (<code>stat = "identity"</code>). <code>geom_histogram()</code> klassiert (<code>stat_bin</code>), <code>geom_density()</code> schätzt (<code>stat_density</code>).
Skalen	<code>scale_<aes>_<typ>()</code> , <code>labs()</code>	<code>scale_y_log10()</code> · <code>scale_fill_viridis_c()</code> · <code>labs(x = "Wohnfläche [m²]")</code>
Koordinatensystem	<code>coord_*()</code>	<code>coord_cartesian()</code> · <code>coord_flip()</code> macht aus einer Säule einen Balken · <code>coord_polar()</code> macht aus einem gestapelten Balken eine Torte
Facettierung	<code>facet_wrap()</code> , <code>facet_grid()</code>	<code>facet_wrap(~ rooms)</code> – ein Panel pro Zimmerzahl („small multiples“)
Theme	<code>theme_*()</code> , <code>theme()</code>	<code>theme_minimal()</code> · <code>theme(legend.position = "bottom")</code>

Ein Aufruf, zerlegt

```
ggplot(miete,
  aes(x = wfl, y = nm,
    colour = lage)) +
  geom_point(alpha = .4) +
  facet_wrap(~ rooms) +
  scale_y_log10() +
  labs(x = "Wohnfläche [m²]",
    y = "Nettomiete [€]") +
  theme_minimal()
```

Ästhetiken: Wohnfläche→x, Nettomiete→y, Wohnlage→Farbe.

Geometrie: Punkte.


Facettierung: nach Zimmerzahl.

Skala: y logarithmisch. **Datentransformation:** keine.

Die schönste Erkenntnis der Grammatik: Ein Kreisdiagramm *ist* ein einzelner gestapelter Balken in `coord_polar()`. Gleiche Daten, gleiche Geometrie, gleiche Datentransformation – nur ein anderes Koordinatensystem. Und genau dieser Wechsel verschiebt die Kodierung von **Länge** (Platz 2) auf **Winkel** (Platz 4).

Auf den nächsten Folien steht zu jeder Grafik eine **Grammar-Box**: Geometrie, Ästhetiken, Datentransformation, Koordinatensystem – und der zugehörige ggplot2-Aufruf. Genau in dieser Reihenfolge beantwortet man auch die Zerlegungsaufgabe.

Säulen- und Balkendiagramm



Definitionen

- **Säulendiagramm:** über jeder Ausprägung $a_1, \dots, a_k$ ein **Rechteck**, dessen Höhe die Häufigkeit h_j (oder f_j) ist. Merkmalsachse waagrecht.
- **Balkendiagramm:** dasselbe mit **vertikaler** Merkmalsachse – die Rechtecke liegen also.

Anwendbar auf **nominale** und **ordinale** Merkmale sowie auf metrische mit **wenigen** Ausprägungen. Bei nominalen Merkmalen ist die Anordnung beliebig – dann nach Häufigkeit sortieren, nicht alphabetisch.

Säule oder Balken?

Im Zweifel die **Säule**: Menschen vergleichen Höhen nebeneinander stehender Objekte besser als Längen übereinander liegender, und die Leserichtung der Beschriftung stimmt.

Der Balken lohnt sich, sobald die Kategorienamen auf der x-Achse zu lang werden – Stadtbezirke, Parteienamen, Studiengänge. Gekippte oder abgeschnittene Achsenbeschriftungen sind schlimmer als eine gedrehte Grafik. Probiert es oben mit „Stadtbezirk“.


Grammar of Graphics

Geometrie	<code>geom_col()</code> (Werte gegeben) bzw. <code>geom_bar()</code> (zählt selbst aus)
Ästhetiken	<code>x = Zimmerzahl</code> , <code>y = (relative) Häufigkeit</code>
Datentransf.	<code>stat_count</code> bei <code>geom_bar()</code> , <code>stat_identity</code> bei <code>geom_col()</code>
Koordinaten	kartesisch – das Balkendiagramm ist dasselbe mit <code>coord_flip()</code>

Klassische Manipulation: die y-Achse nicht bei 0 beginnen lassen. Da Säulen über **Länge** kodieren, wird der Unterschied dann optisch verzerrt. Beim **Punktdiagramm** ist ein abgeschnittener Bereich dagegen zulässig – dort kodiert nur die **Position**.

Gestapeltes Säulendiagramm und Mosaikplot

Datensatz Wohnform × Zufriedenheit (n = 200) ↕

Darstellung **Mosaikplot** gestapelt, absolut gestapelt, relativFläche = gemeinsame Häufigkeit f_{ij}
■ unzufrieden ■ zufrieden ■ sehr zufrieden


Mosaikplot. Die **Breite** jeder Säule ist der Randanteil $f_{i.}$, die **Höhe** der Abschnitte darin die bedingte Häufigkeit $f(Y|X)$. Damit ist die **Fläche jeder Kachel proportional zur gemeinsamen Häufigkeit f_{ij}** — flächentreu.

$n = 200 \cdot \text{Tafel } 4 \times 3 \cdot \chi^2 = 22,60 \cdot K^* = 0,390$

Gestapeltes Säulendiagramm

Eine Säule pro Ausprägung von X , aufgeteilt nach Y . **Absolut** zeigt die Gruppengrößen, **relativ** (jede Säule auf 1 normiert) die **bedingten Verteilungen $f(Y|X)$** – und nur die darf man vergleichen.


Mosaikplot

Flächentreue Darstellung der gemeinsamen Verteilung: **Breite** einer Säule = $f_{i.}$, **Höhe** der Abschnitte darin = $f(Y|X)$, also **Fläche** = f_{ij} . Damit ist er der relative Stapel *plus* die Gruppengrößen – und auch für drei und mehr Merkmale einsetzbar.

Grammar of Graphics

Geometrie	Rechtecke – <code>geom_bar(position = "fill")</code> bzw. <code>geom_mosaic()</code> (Paket <code>ggmosaic</code>)
Ästhetiken	<code>x</code> = Wohnform, <code>fill</code> = Zufriedenheit; beim Mosaikplot zusätzlich Breite = $f_{i.}$.
Datentransf.	Auszählen und auf Zeilensummen normieren (<code>position = "fill"</code>)
Skalen	<code>scale_fill_*()</code> – bei ordinalem Y sequenziell, siehe Folie 34

Boxplot – die 5-Punkte-Zusammenfassung

Merkmal Miete pro m² Typ einfach modifiziert ☐ nach Zimmerzahl gruppieren ☐ Rohdaten einblenden


Alle Wohnungen (n = 964): Minimum 1,80 · $\tilde{x}_{0,25} = 6,74$ · Median = 8,33 · $\tilde{x}_{0,75} = 9,97$ · Maximum 18,26
 $d_Q = 3,23 \Rightarrow$ Zäune bei $z_u = 1,89$ und $z_o = 14,82 \Rightarrow$ **9 Ausreißer** im modifizierten Boxplot.

Aufbau

- Box von $\tilde{x}_{0,25}$ bis $\tilde{x}_{0,75}$, Länge d_Q ; Strich darin: **Median**
- Einfacher** Boxplot: Whisker bis $x_{\min}$ und $x_{\max}$
- Modifizierter** Boxplot: Zäune bei $\tilde{x}_{0,25} \mp 1,5 d_Q$ bzw. $\tilde{x}_{0,75} \pm 1,5 d_Q$; Whisker nur bis zum extremsten Wert *innerhalb* der Zäune, alles außerhalb als Punkt

Dafür: kompakt, ideal zum Vergleichen von Gruppen, zentraler Bereich und Ausreißer direkt ablesbar, Schiefe sichtbar.

Dagegen: viel Farbe für wenig Daten, Ausreißer wirken zu prominent, die Höhe trägt keine Information – und **Multimodalität bleibt unsichtbar**.


Grammar of Graphics

Geometrie	Rechteck + Band + Whisker (+ Punkte) – <code>geom_boxplot()</code>
Ästhetiken	Box von $\tilde{x}_{0,25}$ bis $\tilde{x}_{0,75}$, Band = $\tilde{x}_{\text{med}}$, $x = \text{Gruppe}$
Datentransf.	<code>stat_boxplot</code>
Koordinaten	<code>coord_flip()</code> legt die Boxen waagrecht

Was ggplot2 anders macht

- Voreingestellt ist mit `coef = 1.5` der **modifizierte** Boxplot. Den **einfachen** bekommt man mit `geom_boxplot(coef = Inf)` – Whisker bis Minimum und Maximum, keine Ausreißerpunkte.
- Die Box-Ränder sind Quantile nach `quantile(type = 7)`, also mit **linearer Interpolation**. Die Vorlesungsdefinition ($n \cdot p$ ganzzahlig $\rightarrow$ Mittel der Nachbarn) liefert leicht andere Werte, Basis-R- `boxplot()` wiederum Tukeys *hinges* aus `fivenum()`.
- `varwidth = TRUE` kodiert die Gruppengröße über die Breite.

Histogramm – und warum Flächentreue zählt



Klassenbreite $b = 50$ € · 35 gleich breite Klassen · $n = 964$.

Vorgehen

1. In Klassen aufteilen (falls noch nicht gruppiert)
2. h_j und $f_j = h_j/n$ bestimmen
3. Höhen y_j so wählen, dass gilt:

$$b_j \cdot y_j = f_j \iff y_j = \frac{f_j}{b_j}$$

Die **Fläche** trägt die relative Häufigkeit – nicht die Höhe. Nur bei **gleichen** Klassenbreiten sind beide proportional.

Grammar of Graphics

Geometrie	achsenparallele Rechtecke – <code>geom_histogram()</code>
Ästhetiken	x-Ecken = Klassengrenzen, Fläche = f_j
Datentransf.	<code>stat_bin</code> – klassieren und auszählen
Skalen	y als <code>after_stat(density)</code> statt <code>count</code>


⚠ ggplot2 rechnet hier anders als die Vorlesung

- `geom_histogram()` trägt standardmäßig die **Anzahl** auf (`after_stat(count)`) – also **höhentreu**, nicht flächentreu. Das Vorlesungs-Histogramm bekommt man erst mit `geom_histogram(aes(y = after_stat(density)))`; dort ist `density = count / (width · n)`, also genau f_j/b_j .
- Die Klassen sind per Voreinstellung **gleich breit**, ihre Anzahl ist schlicht `bins = 30` – ggplot warnt selbst, dass man das besser setzt (`binwidth =` oder `breaks =`).
- Bei **ungleichen** Klassen über `breaks =` bleibt `count` falsch; `after_stat(density)` teilt dagegen durch die jeweilige Klassenbreite. Klassen sind rechts geschlossen $(a, b]$ – wie in der Vorlesung.

Kerndichteschätzer – das glatte Histogramm

Merkmal Miete pro m² Bandbreite h 0,545 €/m² Kern Gauß ☐ Histogramm dahinter

☐ einzelne Kerne zeigen



Kern: **Gauß** · Bandbreite $h = 0,545 \text{ €/m}^2$ (das 1,0-fache der Silverman-Faustregel 0,545)

Guter Bereich — die Form ist erkennbar, ohne dass jede Beobachtung einen eigenen Gipfel bekommt.

Die Idee

Statt Beobachtungen in Klassen zu werfen, legt man über **jede einzelne Beobachtung** eine kleine Funktion – den **Kern** K – und summiert alle auf:

$$\hat{f}(x) = \frac{1}{n h} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right)$$

„Einzelne Kerne zeigen“ anhaben: die blauen Hügel sind die Summanden, die grüne Kurve ihre Summe. Es gilt $\int \hat{f}(x) dx = 1$ – eine **Dichte**, keine Häufigkeit.

Die Bandbreite h ist die eigentliche Entscheidung

- h **größer** $\Rightarrow$ **glatter**. Verdoppelt man h , verschmelzen Nebengipfel, die Kurve wird flacher und breiter. Zu groß: nur noch ein Berg.
- h **kleiner** $\Rightarrow$ **zackiger**. Im Extremfall ein Gipfel pro Beobachtung – Rauschen, keine Struktur.
- Der **Kern** spielt kaum eine Rolle. Nur der Rechteckkern erzeugt sichtbare Treppen, weil er unstetig ist.


Grammar of Graphics

Geometrie	Kurve / Fläche – <code>geom_density()</code>
Ästhetiken	<code>x</code> = Wert, <code>y</code> = geschätzte Dichte; <code>colour</code> für Gruppen
Datentransf.	<code>stat_density</code> mit <code>bw =</code> und <code>kernel =</code>

Vorteil gegenüber dem Histogramm: kein willkürlicher Klassenanfang, keine Sprungstellen, und mehrere Verteilungen lassen sich in **einer** Grafik übereinanderlegen. **Nachteil:** an harten Rändern (z. B. „Miete ≥ 0 “) schmiert der Schätzer über die Grenze hinaus und behauptet Dichte, wo es keine Daten geben kann.

Streudiagramm – und die dritte Ästhetik

x Wohnfläche y Nettomiete 3. Ästhetik keine ☒ Transparenz gegen Überplotten



$n = 964$ Punkte · $r_{xy} = 0,702$ · $r^{SP} = 0,689$

Mit Transparenz erkennt man, wo die Punkte dicht liegen — ohne sie sieht eine überplottete Wolke überall gleich schwarz aus.

Streudiagramm

Ein Punkt pro Untersuchungseinheit, x und y tragen die beiden Werte. Man liest ab: **Richtung, Stärke, Form** des Zusammenhangs, Gruppen und Ausreißer. Die Grafik, die man **immer** ansehen sollte, bevor man r_{xy} interpretiert.

Die dritte Variable dazunehmen

Farbe	nominal → qualitative Palette, metrisch → stetige Skala (Folie 34)
Größe	nur für positive Merkmale, immer über die Fläche skalieren – sonst wird der Unterschied quadriert
Form	höchstens 4–5 Kategorien
Facetten	oft die beste Wahl: <code>facet_wrap(~ Z)</code> , alle Panels mit gleichen Achsen

Grammar of Graphics

Geometrie	Punkte – <code>geom_point()</code>
Ästhetiken	x, y, optional colour / size / shape, alpha
Datentransf.	keine – jede Zeile wird direkt gezeichnet

Überplotten (overplotting) ist das Hauptproblem bei großen n : Punkte liegen übereinander, und die dichten Bereiche sehen genauso aus wie die dünnen.

Gegenmittel: **Transparenz** (`alpha`), **Hexbins** (`geom_hex()`), 2D-Kerndichte (`geom_density_2d()`) oder schlicht eine Zufallsstichprobe der Punkte.

Farbskalen – Farbe ist eine Ästhetik, keine Dekoration

Drei Typen – und das Skalenniveau entscheidet

qualitativ nominal		gut unterscheidbare Farbtöne ohne Reihenfolge. Höchstens etwa 7 Kategorien , sonst kann man sie nicht mehr auseinanderhalten – dann Kategorien zusammenfassen.
sequenziell ordinal, metrisch		ein Farbton, von hell nach dunkel. Die Helligkeit trägt die Ordnung – deshalb funktioniert die Skala auch in Graustufen und für Farbfehlsichtige.
divergierend metrisch mit Mittelpunkt		zwei Farbtöne, in der Mitte neutral. Für Größen mit einem inhaltlichen Nullpunkt : Residuen, Differenzen, Korrelationen, Abweichungen vom Erwartungswert.

Die Zuordnung folgt dem Skalenniveau – genau wie bei allem anderen an Tag 1. Eine sequenzielle Skala auf ein nominales Merkmal zu legen erfindet eine Rangfolge, die es nicht gibt. Eine qualitative Palette auf ein metrisches Merkmal zu legen zerstört die vorhandene.

Der Regenbogen ist kaputt

Die klassische Regenbogenskala (blau–grün–gelb–rot) hat zwei harte Fehler:



- **Die Helligkeit ist nicht monoton.** Gelb ist viel heller als seine Nachbarn – man sieht dort eine Kante, wo in den Daten keine ist, und umgekehrt.
- **Gleiche Farbabstände bedeuten nicht gleiche Wertabstände.** Der grüne Bereich ist optisch breit und wertmäßig schmal.
- In Graustufen gedruckt und für Rot-Grün-Blinde (rund **8 % der Männer**) ist sie unbrauchbar.

Besser: wahrnehmungslineare Skalen wie **viridis** – in ggplot2 `scale_colour_viridis_c()` bzw. `_d()`, für Kategorien und Karten die ColorBrewer-Paletten `scale_fill_brewer()`.



viridis: durchgehend zunehmende Helligkeit, funktioniert in Graustufen und bei Farbfehlsichtigkeit.

Drei Regeln für die Praxis

1. **Farbe zuletzt.** Sie ist Platz 7 der Wahrnehmungshierarchie – alles, was über Position oder Länge geht, ist genauer. Farbe ist gut zum **Gruppieren**, schlecht zum **Ablesen von Werten**.
2. **Nie Farbe als einzigen Träger** einer Information. Zusätzlich Form, Beschriftung oder Facetten verwenden, dann bleibt die Grafik auch schwarzweiß lesbar.
3. **Divergierende Skala nur mit echtem Mittelpunkt** – und den Mittelwert der Skala dann auch wirklich auf 0 (bzw. den inhaltlichen Bezugswert) legen.

Wenn es mehr als zwei Merkmale sind



unten links: Streudiagramme · oben rechts: r (Schriftgröße = $|r|$, grün positiv, rot negativ)

Scatterplot-Matrix

Alle paarweisen Streudiagramme in einem Raster – das **grafische Gegenstück zur Korrelationsmatrix** von Folie 13. Unten links die Punktwolken, oben rechts die r_{xy} , auf der Diagonalen die Merkmalsnamen (oft auch deren Histogramm).

Man sieht sofort, welche Paare überhaupt zusammenhängen – und **ob der Zusammenhang linear ist**. Genau das verrät eine Korrelationsmatrix allein nicht.

In R: `GGally::ggpairs()` oder `pairs()`. Praktikabel bis etwa **6 Merkmale**.

Die weiteren Werkzeuge

Facettierung <code>facet_wrap()</code>	ein Panel je Ausprägung eines dritten Merkmals, alle mit gleichen Achsen
2D-Kerndichte / Hexbin <code>geom_density_2d()</code> , <code>geom_hex()</code>	gegen Überplotten: Höhenlinien bzw. sechseckige Zellen statt Punkten
Parallele Koordinaten	eine Achse pro Merkmal, jede Beobachtung ein Linienzug
Heatmap	farbige Kacheln, z. B. die Korrelationsmatrix selbst – mit divergierender Skala

Was man *nicht* tut: 3D. Perspektivische 3D-Streudiagramme und 3D-Säulen verzerren Längen und verdecken Punkte. Fast immer sind **Facetten** die bessere Lösung – dieselbe Regel wie beim Kreisdiagramm.

Die Entscheidungshilfe: welche Grafik wann?

GRAFIKTYP	MERKMALE	GEOMETRIE	ÄSTHETISCHE ZUORDNUNG	ZEIGT VOR ALLEM
Säulen- / Balkendiagramm	ein diskretes Merkmal (nominal, ordinal, metrisch mit wenigen Ausprägungen)	Rechtecke	x-Position = Ausprägung, y-Position = Häufigkeit	Häufigkeitsverteilung eines diskreten Merkmals
Gestapeltes Säulendiagramm	zwei diskrete Merkmale	gestapelte Rechtecke	x = Gruppe, Füllfarbe = 2. Merkmal, Länge = (bedingte) Häufigkeit	bedingte Verteilungen $f(Y X)$ im Vergleich
Mosaikplot	zwei oder mehr diskrete Merkmale	geschachtelte Rechtecke	Höhe = $f_{i.}$, Breite = $f(Y X)$, Fläche = f_{ij} ; Farbe = Residuum	gemeinsame Verteilung, Abweichung von Unabhängigkeit
Boxplot	ein Merkmal, mind. ordinal; sinnvoll ab metrisch	Rechteck + Band + Whisker (+ Punkte)	Ausdehnung = $\bar{x}_{0.25}$ bis $\bar{x}_{0.75}$, Band = Median	Lage, Streuung, Ausreißer – ideal zum Vergleichen von Gruppen
Histogramm	ein metrisches Merkmal, mind. Intervallskala	achsenparallele Rechtecke	x-Position der Ecken = Klassengrenzen, Fläche = f_j	Form der Verteilung, Modalität, Schiefe
Kerndichteschätzer	ein metrisches, (quasi-)stetiges Merkmal	Kurve / gefüllte Fläche	x = Merkmalswert, y = geschätzte Dichte	Form und Modalität ohne Klassengrenzen; mehrere Gruppen übereinander
ecdf	ein Merkmal, mind. ordinal	Treppenfunktion	x = Merkmalswert, y = kumulierte relative Häufigkeit	Anteile und Quantile exakt ablesbar
Streudiagramm	zwei metrische Merkmale	Punkte	x- und y-Position = die beiden Merkmalswerte	Richtung, Stärke und Form des Zusammenhangs, Ausreißer
Streudiagramm mit 3. Ästhetik	zwei metrische + ein drittes Merkmal	Punkte	zusätzlich Farbe (nominal → qualitativ, metrisch → sequenziell), Größe oder Form	ob der Zusammenhang in allen Gruppen gleich ist – das Simpson-Werkzeug
Lorenzkurve	ein metrisches Merkmal, nur positive Werte	Polygonzug	x = kumul. Anteil UE, y = kumul. Anteil Merkmalssumme	Konzentration
Kreisdiagramm	ein diskretes Merkmal	Kreissectoren	Winkel und Fläche = relative Häufigkeit	wenig – Winkel und Flächen sind Plätze 4 und 5 der Wahrnehmungshierarchie

Damit ist die **gesamte Deskriptive Statistik** (Empirie) durch. Ab jetzt seht ihr keine Daten mehr. Ab Montag: Wahrscheinlichkeitsrechnung.

Wie viel davon steckt in der GOP?

38 %

In fünf ausgewerteten **Hauptfach-GOPs**¹ entfielen insgesamt **235 von 626 Punkten** auf den Stoff dieser Woche.

Die Spannweite

28–49 % der jeweiligen Gesamtpunktzahl, je nach Klausur.

¹ Grundlage: fünf ausgewertete Hauptfach-GOPs. Nebenfach-Klausuren sind nicht enthalten.

Noch **33 Tage** bis zur GOP.