

Deskriptive Statistik – Tutorium

Übungsblatt 1: Datenerhebung & Messung

Klausurvorbereitung, Statistik I – LMU München

Aufgabe 1 Grundbegriffe: München-Marathon

Der Veranstalter des München-Marathons dokumentiert nach dem Zieleinlauf für *jede Person*, die das Ziel erreicht hat, die folgenden Angaben:

Erfasste Angabe	Beispieleintrag
Startnummer	4711
Nettozielzeit (hh:mm:ss)	03:41:12
Platzierung in der Gesamtwertung	1274
Altersklasse (U20, 20–29, 30–39, ..., 70+)	30–39
Geschlecht (w / m / d)	w
Nationalität	ITA
Anzahl bisher gelaufener Marathons	7
Vereinstrikot getragen (ja / nein)	nein

1. Geben Sie die *Untersuchungseinheiten* und die *Grundgesamtheit* an, auf die sich diese Daten beziehen. Grenzen Sie dabei sauber ab, wer *nicht* zur Grundgesamtheit gehört.
2. Bestimmen Sie für die Merkmale *Nettozielzeit*, *Platzierung*, *Altersklasse*, *Nationalität* und *Anzahl bisher gelaufener Marathons* jeweils
 - (a) das Skalenniveau,
 - (b) den Merkmalsraum,
 - (c) ob das Merkmal diskret, stetig oder quasi-stetig ist.
3. Charakterisieren Sie die Erhebung bezüglich *Umfang*, *Datenform* und *Methode der Messung*. Begründen Sie jeweils kurz.
4. Sowohl *Platzierung* als auch *Nettozielzeit* werden als Zahl erfasst, besitzen aber unterschiedliche Skalenniveaus. Begründen Sie den Unterschied über die jeweils *zulässigen Transformationen* und geben Sie an, welche Information beim Übergang von der Zielzeit zur Platzierung verloren geht.
5. Ein Mitarbeiter codiert die Altersklassen als 1, 2, ..., 7 und berechnet daraus ein arithmetisches Mittel von 3,8. Warum ist diese Kennzahl problematisch? Welches Lagemaß wäre hier stattdessen angemessen?
6. Der Veranstalter titelt in einer Pressemitteilung: „Deutschlands Freizeitläufer:innen werden immer schneller.“ Auf welche Grundgesamtheit beziehen sich die Daten *tatsächlich*? Nennen Sie zwei Gründe, warum der Schluss auf alle Freizeitläufer:innen nicht zulässig ist.

Aufgabe 2 Grundbegriffe: Randomisierte Schlafstudie

Ein Forschungsteam untersucht, ob eine sechswöchige app-gestützte Intervention die Schlafqualität verbessert. 240 Personen mit selbstberichteten Ein- und Durchschlafproblemen werden *per Losverfahren* auf zwei Gruppen aufgeteilt: „App“ und „Kontrolle“. Zu drei Zeitpunkten (Beginn, nach 6 Wochen, nach 6 Monaten) werden bei allen Teilnehmenden erhoben:

- der *PSQI*, ein Summenscore aus 19 Fragebogen-Items mit je vier Antwortstufen („nie“ / „selten“ / „manchmal“ / „häufig“),
 - die mittlere nächtliche Schlafdauer in Minuten, gemessen über einen Fitness-Tracker,
 - die Gruppenzugehörigkeit sowie Alter und Geschlecht.
1. Benennen Sie Untersuchungseinheiten, Grundgesamtheit und Teilgesamtheit. Um welchen *Erhebungsumfang* handelt es sich?
 2. Um welche *Datenform* handelt es sich? Grenzen Sie diese explizit gegen eine *Zeitreihe* und gegen *Querschnittsdaten* ab. Wie viele *Beobachtungen* im Sinne der Vorlesung liefert eine einzelne Untersuchungseinheit?
 3. Welche *Methoden operationaler Messung* kommen hier zum Einsatz? Was genau macht diese Studie zu einem *Experiment*?
 4. Bei welchem der beiden Zielmerkmale (PSQI, Schlafdauer) handelt es sich um eine *direkte*, bei welchem um eine *indirekte (operationale)* Messung? Erläutern Sie den Begriff *Operationalisierung* anhand dieses Beispiels.
 5. Der PSQI entsteht als *Index* durch Summenbildung über 19 ordinale Items. Nennen Sie zwei Probleme der Indexbildung, die in der Vorlesung besprochen wurden, und diskutieren Sie: Welches Skalenniveau darf man dem Summenscore streng genommen zusprechen?
 6. Geben Sie für die Merkmale *Gruppenzugehörigkeit*, *Schlafdauer in Minuten* und *Erhebungszeitpunkt* jeweils Skalenniveau und Merkmalsraum an.
 7. Warum werden die Teilnehmenden *zufällig* auf die Gruppen aufgeteilt und nicht z. B. nach eigenem Wunsch? (Stichpunkte)

Aufgabe 3 Skalenniveaus: Aufnahmebogen einer Arztpraxis

Im Folgenden sehen Sie (in gekürzter Form) den Aufnahmebogen, den Patient:innen in einer hausärztlichen Praxis vor der Behandlung ausfüllen bzw. der von den Medizinischen Fachangestellten ergänzt wird.

Tragen Sie rechts neben dem Pfeil jeweils das Skalenniveau des erfassten Merkmals ein.

Angabe im Aufnahmebogen	Eintrag	Skalenniveau
Geschlecht (w / m / d)	m	→ _____
Geburtsdatum (TT.MM.JJJJ)	04.09.1978	→ _____
Alter (in vollendeten Jahren)	47	→ _____
Körpergröße (in cm)	181	→ _____
Körpergewicht (in kg)	88,4	→ _____
Körpertemperatur (in °C)	37,2	→ _____
Systolischer Blutdruck (in mmHg)	138	→ _____
Blutgruppe (A / B / AB / 0)	AB	→ _____
Postleitzahl des Wohnorts	80539	→ _____
Versichertenstatus (gesetzlich / privat)	gesetzlich	→ _____
Pflegegrad (1 / 2 / 3 / 4 / 5)	2	→ _____
Aktuelle Schmerzstärke, NRS (0 = kein Schmerz ... 10 = stärkster Schmerz)	6	→ _____
Anzahl der Arztbesuche in den letzten 12 Monaten	3	→ _____
Zufriedenheit mit der Wartezeit (sehr zufrieden / zufrieden / neutral / unzufrieden / sehr unzufrieden)	neutral	→ _____
Heutige Wartezeit (in Minuten)	23	→ _____

Beantworten Sie anschließend die folgenden Fragen:

1. Welche der oben erfassten Merkmale sind *diskret*, welche *stetig* und welche *quasi-stetig*? Begründen Sie Ihre Einordnung an zwei Beispielen.
2. Die *Postleitzahl* wird als Zahl erfasst. Warum ist die Berechnung eines arithmetischen Mittels der Postleitzahlen dennoch sinnlos? Argumentieren Sie über die für dieses Merkmal zulässigen Transformationen.
3. Für welche der 15 Merkmale ist die Angabe eines *arithmetischen Mittels* inhaltlich sinnvoll interpretierbar, für welche nur der *Modus*? Nennen Sie je drei Beispiele.
4. Aus *Körpergröße* und *Körpergewicht* bildet die Praxis-Software automatisch den Body-Mass-Index $BMI = \frac{\text{Gewicht in kg}}{(\text{Größe in m})^2}$.
 - (a) Um was für eine Art von Merkmalsbildung handelt es sich hier?
 - (b) Welches Skalenniveau besitzt der BMI-Wert selbst?
 - (c) Die Software gibt zusätzlich die Kategorie „Untergewicht / Normalgewicht / Übergewicht / Adipositas“ aus. Um welche Art von Transformation handelt es sich, und welches Skalenniveau hat das Ergebnis?
5. Die Praxis möchte „Behandlungszufriedenheit“ messen, indem sie die numerischen Codes der Items *Schmerzstärke* und *Zufriedenheit mit der Wartezeit* addiert. Nehmen Sie kurz Stellung: Ist das zulässig? Welche zwei Probleme der Indexbildung treten auf?

6. Die Körpertemperatur wird in $^{\circ}\text{C}$ gemessen. Ein Patient sagt: „ $38,0^{\circ}\text{C}$ sind doppelt so warm wie $19,0^{\circ}\text{C}$.“ Widerlegen Sie diese Aussage rechnerisch, indem Sie beide Werte in Grad Fahrenheit ($^{\circ}\text{F} = 1,8 \cdot ^{\circ}\text{C} + 32$) umrechnen und die Quotienten vergleichen. In welcher Einheit wäre eine solche Verhältnisaussage zulässig und warum?

Aufgabe 4 Datenform: Zeitreihe, Querschnitt oder Längsschnitt?

Der (fiktive) Jahresumsatz der beiden rechtlich eigenständigen Unternehmensgruppen *Aldi Nord* und *Aldi Süd* in Deutschland liegt für die Geschäftsjahre $t = 1, \dots, 5$ in der folgenden Form vor. Alle Angaben in Mrd. Euro.

Datensatz A			
t	Umsatz Aldi Nord	Umsatz Aldi Süd	
1	5,8	6,4	
2	6,1	6,9	
3	6,0	7,2	
4	6,4	7,6	
5	6,7	8,1	

Dieselben Zahlen lassen sich auch so aufschreiben:

Datensatz B (nur Aldi Nord)

t	Umsatz
1	5,8
2	6,1
3	6,0
4	6,4
5	6,7

Datensatz C (nur Aldi Süd)

t	Umsatz
1	6,4
2	6,9
3	7,2
4	7,6
5	8,1

- Geben Sie die Definitionen von *Querschnittsdaten*, *Zeitreihe* und *Längsschnittdaten* wieder. Machen Sie dabei jeweils explizit, wie viele *Untersuchungseinheiten* und wie viele *Beobachtungen pro Untersuchungseinheit* vorliegen.
- Ordnen Sie die Datensätze B und C jeweils einer dieser drei Datenformen zu. Was ist hier die Untersuchungseinheit, was das erhobene Merkmal?
- Datensatz A lässt sich *sowohl* als Sammlung von *zwei Zeitreihen als auch* als *Längsschnittdatensatz* auffassen.
 - Erläutern Sie beide Sichtweisen und geben Sie jeweils an, was dann die Untersuchungseinheit ist und wie groß n ist.
 - Woran genau entscheidet sich, welche der beiden Sichtweisen vorliegt?
- Betrachten Sie nur die Zeile $t = 3$ aus Datensatz A. Um welche Datenform handelt es sich dann, und wie groß ist der Stichprobenumfang?

Aufgabe 5 Skalentransformationen und zulässige Operationen

1. Geben Sie für jede der folgenden Transformationen f das *höchste* Skalenniveau an, auf dem f noch strukturerhaltend (also zulässig) ist.

Transformation	Niveau
(a) $f(x) = 3x$	...
(b) $f(x) = 1,8x + 32$	...
(c) $f(x) = \log_{10}(x)$	...
(d) $f(x) = -x$	...
(e) $f(x) = x^2$	...
(f) $\{1, 2, 3, 4, 5\} \rightarrow \{A, B, C, D, E\}$	...
(g) $\{1, 2\} \rightarrow$ „niedrig“, $\{3, 4, 5\} \rightarrow$ „hoch“	...

2. Erklären Sie in eigenen Worten den in der Vorlesung formulierten Zusammenhang:

„Höhere Skalenniveaus erlauben mehr sinnvolle *Operationen*, aber weniger zulässige *Transformationen*.“

Illustrieren Sie dies am Vergleich von Nominal- und Verhältnisskala.

3. Bakterienkonzentrationen werden häufig auf der $\log_{10}$ -Skala berichtet. Betrachten Sie die Messwerte 0,002, 0,0002 und 0,00002.
- (a) Berechnen Sie die zugehörigen $\log_{10}$ -Werte.
 - (b) Wie sind Differenzen auf der log-Skala inhaltlich zu interpretieren?
 - (c) Die Vorlesung bezeichnet diese Skalenwahl als „inhaltlich sinnvoll, theoretisch nicht zulässig“. Erklären Sie, worin der theoretische Konflikt besteht.
4. Ein dichotomes Merkmal (z. B. „raucht: ja/nein“) wird als 0/1 codiert. Es ist nominalskaliert – trotzdem ist sein arithmetisches Mittel sinnvoll interpretierbar. Erklären Sie, warum, und geben Sie an, was das Mittel dann konkret misst.

Aufgabe 6 Erhebungsarten und Auswahlverfahren

Bestimmen Sie für jedes der folgenden Vorhaben

- den geeigneten *Erhebungsumfang* (Vollerhebung / Stichprobe),
- die zu erwartende *Datenform*,
- die *Methode* der Messung (Beobachtung / Befragung / Experiment)

Begründen Sie Ihre Wahl jeweils in ein bis zwei Sätzen.

1. Für den Münchner Mietspiegel soll die durchschnittliche Nettoquadratmetermiete geschätzt werden. Bekannt ist, dass sich die Mieten zwischen Baualtersklassen und zwischen den Stadtbezirken systematisch unterscheiden.

2. Das Landesamt für Wald- und Forstwirtschaft möchte die Verbreitung eines Schädlings in Bayern erfassen. Die Begutachtung erfordert die Anreise eines Teams zu einzelnen, weit verstreuten Waldstücken.
3. Das Institut für Statistik (350 eingeschriebene Studierende) möchte die Zufriedenheit mit dem Lehrangebot des vergangenen Semesters erfassen.