

Deskriptive Statistik – Tutorium

Übungsblatt 2: Kennwerte & Verteilungseigenschaften

Klausurvorbereitung, Statistik I – LMU München

Aufgabe 1 Lage- & Streuungsmaße: Wartezeiten

In einer Notaufnahme wurde an 12 zufällig ausgewählten Tagen die Wartezeit (in Minuten) bis zur Ersteinschätzung dokumentiert, getrennt nach Vormittags- und Nachmittagsschicht:

Vormittagsschicht ($n_1 = 6$)	9, 12, 15, 15, 15, 18
Nachmittagsschicht ($n_2 = 6$)	11, 20, 21, 24, 27, 29

Betrachten Sie in den Teilaufgaben 1–6 zunächst *alle* $n = 12$ Werte *gemeinsam*.

1. Bestimmen Sie die geordnete Urliste $x_{(1)}, \dots, x_{(12)}$ sowie arithmetisches Mittel $\bar{x}$, Modus x_{mod} , Median $\tilde{x}_{\text{med}}$ und die beiden übrigen Quartile $\tilde{x}_{0,25}$, $\tilde{x}_{0,75}$.

→ Lösung →

- $x^{\text{geordnete-Urliste}} = (9, 11, \dots, 29)$
- $\bar{x} = 18$
- $x_{\text{mod}} = 15$
- $\tilde{x}_{\text{med}} = [15, 18]$. Intervallmitte 16.5 auch möglich.
- $\tilde{x}_{0,25} = [12, 15]$ Intervallmitte 13.5 auch möglich.
- $\tilde{x}_{0,75} = [21, 24]$ Intervallmitte 22.5 auch möglich.

2. Berechnen Sie Spannweite sp , Quartilsabstand d_Q , die Stichprobenvarianz s_x^2 sowie die deskriptive Varianz $\tilde{s}_x^2$ und die zugehörigen Standardabweichungen. Welche der beiden Varianten ist hier angemessen? Begründen Sie kurz.

→ Lösung →

- $sp = 20$
- $d_Q = 22.5 - 13.5 = 9$
- $s_x^2 = 40.36$
- $\tilde{s}_x^2 = 37$
- $s_x = \sqrt{40.36} = 6.35$
- $\tilde{s}_x = \sqrt{37} = 6.08$

Stichprobenvarianz angemessen, weil *wahrer Mittelwert* unbekannt

3. Berechnen Sie den Variationskoeffizienten v unter Verwendung der *deskriptiven* Standardabweichung und die mittlere absolute Abweichung MAD_x . Überprüfen Sie an Ihren Ergebnissen die in der Vorlesung angegebene Beziehung $\text{MAD}_x \leq \tilde{s}_x$.

→ Lösung →

- $v = \tilde{s}_x / \bar{x} = \frac{6.08}{18} = 0.34$
- $MAD = 5.17$
- $5.17 < 6.08$

4. Bestimmen Sie den Quartilkoeffizienten der Schiefe $g_{0,25}$ und charakterisieren Sie die Verteilung.

→ Lösung →

$$g_{0,25} = \frac{6-3}{9} = 1/3$$

Linkssteil / Rechtsschief

5. Die Klinikleitung erwägt, die Wartezeiten künftig in Stunden statt in Minuten zu berichten, also $y_i = x_i/60$. Geben Sie *ohne erneute Berechnung aus den Rohdaten* $\bar{y}$, $\tilde{s}_y^2$, $\tilde{s}_y$ und den Variationskoeffizienten v_y an. Welche Transformationsregeln verwenden Sie? Warum ändert sich v nicht?

→ Lösung →

- $\bar{y} = 18/60$
- $\tilde{s}_y^2 = 37/3600$
- $\tilde{s}_y = 6.08/60$
- $v_y = \frac{\tilde{s}_x/60}{\bar{x}/60} = v_x$
- v ist skalierungsinvariant
- $\mathbb{E}(aX) = a\mathbb{E}(X)$
- $\mathbb{V}(aX) = a^2\mathbb{V}(X)$

6. **Streuungszerlegung.** Fassen Sie nun Vormittag und Nachmittag als zwei Schichten auf.

(a) Berechnen Sie die Schichtmittelwerte $\bar{x}_1, \bar{x}_2$ und die Schichtvarianzen $\tilde{s}_{x1}^2, \tilde{s}_{x2}^2$.

→ Lösung →

- $\bar{x}_1 = 14, \bar{x}_2 = 22$
- $\tilde{s}_{x1}^2 = 8, \tilde{s}_{x2}^2 = 34$

(b) Berechnen Sie die Streuung *innerhalb* und *zwischen* den Schichten und weisen Sie nach, dass sich beide Anteile zur Gesamtvarianz $\tilde{s}_x^2$ aus Teilaufgabe 2 addieren.

→ Lösung →

- $\tilde{s}_{innerhalb,x}^2 = 1/2 * 8 + 1/2 * 34 = 21$
- $\tilde{s}_{zwischen,x}^2 = 1/2 * (14 - 18)^2 + 1/2 * (22 - 18)^2 = 16$
- Summe ist dann 37

(c) Welcher Anteil der Gesamtstreuung wird durch die Schichtzugehörigkeit „erklärt“? Interpretieren Sie das Ergebnis inhaltlich.

→ Lösung →

$$\tilde{s}_{zwischen,x}^2 / \tilde{s}_x^2 = 16/37 = 43\%$$

Die Schichtzugehörigkeit macht fast die Hälfte, also einen großen Anteil, der Gesamtstreuung aus.

7. Ein Tippfehler wird entdeckt: Der Wert 29 muss durch 92 ersetzt werden. Geben Sie an, wie sich $\bar{x}$, $\tilde{x}_{med}$, s_x und d_Q jeweils verändern (Richtung und ungefähre Größenordnung genügen, keine vollständige Neuberechnung nötig). Welche Kennwerte bezeichnet man deshalb als *robust*?

→ Lösung →

- $\bar{x}$ -> erhöht sich stark
 - $\tilde{x}_{\text{med}}$ -> bleibt gleich
 - s_x -> erhöht sich
 - d_Q -> bleibt gleich, da beide Quantile *nicht* vom Maximalwert beeinflusst werden
 - Robust sind daher quantilsbasierte Kennzahlen
8. Ein 13. Beobachtung wird nachgereicht, der eine Wartezeit von 16 Minuten aufweist. Wie verändert sich $\tilde{x}_{0,25}$ und welche Regel zur Berechnung von $\tilde{x}_\alpha$ greift jetzt?
- Lösung →

In der Vorlesung wurde das α -Quantil definiert als:

$$\tilde{x}_\alpha = \begin{cases} x_{\lceil n\alpha \rceil} & \text{falls } n\alpha \text{ keine ganze Zahl} \\ [x_{n\alpha}, x_{n\alpha+1}] & \text{falls } n\alpha \text{ ganze Zahl} \end{cases}$$

Dadurch, dass $n\alpha$ nun nicht ganzzahlig wird ($n\alpha = 3.25$ für $\alpha = 0.25$). Daher muss das 4. Element der Liste verwendet werden. Dieses ist dann **15**.

Aufgabe 2 Harmonisches Mittel I: Durchschnittsgeschwindigkeiten

1. Eine Spedition fährt eine Route in drei Abschnitten von je 12 km Länge: der erste Abschnitt mit 60 km/h, der zweite mit 40 km/h, der dritte mit 30 km/h.
- (a) Berechnen Sie das arithmetische Mittel $\bar{x}$ und das harmonische Mittel $\bar{x}_H$ der drei Geschwindigkeiten.
- Lösung →

- $\bar{x} = 1/3 * 60 + 1/3 * 40 + 1/3 * 30 = 43.33 \text{ km/h}$
- $\bar{x}_H = \frac{12+12+12}{\frac{12}{60} + \frac{12}{40} + \frac{12}{30}} = 40$

- (b) Begründen Sie allgemein, warum bei *gleich langen Streckenabschnitten* das harmonische Mittel der korrekte Mittelwert ist.

→ Lösung →

Korrekt ist $\bar{x}_H$. Es soll über die *Zeit* gewichtet werden - nicht über die *Strecke*. Die *Zeit* ergibt sich hier als Verhältnis von $\frac{\text{Strecke}}{\text{Geschwindigkeit}}$. Daher passt es ins Schema des harmonischen Mittels.

Hinweis: Oft ist es intuitiver und schneller, das harmonische Mittel zu ignorieren und zuerst die Größe auszurechnen, **über die gewichtet werden soll**. In diesem Fall also die 3 Zeiten ausrechnen: $w_1^{\text{Zeit}} = 12/60 = 0.2$, $w_2^{\text{Zeit}} = 12/40 = 0.3$, $w_3^{\text{Zeit}} = 12/30 = 0.4$. Und dann mit Ihnen das gewichtete Mittel ausrechnen. $\bar{x} = \frac{1}{0.2+0.3+0.4} * (0.2 * 60 + 0.3 * 40 + 0.4 * 30) = 40$

2. Nun sind die Abschnitte *unterschiedlich lang*: 20 km mit 80 km/h und anschließend 10 km mit 20 km/h.

- (a) Berechnen Sie die tatsächliche Durchschnittsgeschwindigkeit.

→ Lösung →

Gewichte ausrechnen: $w_1^{Zeit} = 20/80 = 0.25, w_2^{Zeit} = 10/20 = 0.5$. Dann gewichtetes Mittel: $\bar{x} = \frac{1}{0.25+0.5}(0.25 * 80 + 0.5 * 20) = 40$

- (b) Stellen Sie die Formel für das *gewichtete* harmonische Mittel

$$\bar{x}_{H,w} = \frac{\sum_{i=1}^n w_i}{\sum_{i=1}^n \frac{w_i}{x_i}}$$

auf und geben Sie an, welche Größen hier die Gewichte w_i bilden. Rechnen Sie nach.

→ Lösung →

Die w_i in der Formel des $\bar{x}_H$ sind die direkt *angegebenen falschen* Gewichte. Die *wahren* Gewichte ergeben sich durch w_i/x_i . Weil man dann die x_i mit den *wahren* Gewichten gewichtet, rechnet man immer $w_i^{wahr} * x_i = \frac{w_i}{x_i} x_i = w_i$. Daher ergeben sich die w_i im Zähler

- (c) Wie groß ist das (ungewichtete) arithmetische Mittel? Um wie viel Prozent würde man die Durchschnittsgeschwindigkeit damit überschätzen?

→ Lösung →

$$\bar{x} = \frac{1}{2}80 + \frac{1}{2}20 = 50$$

Daher Überschätzung um 25%.

3. Ein LKW fährt nun *eine Stunde lang* mit 80 km/h und anschließend *eine Stunde lang* mit 20 km/h. Welcher Mittelwert ist jetzt der richtige und warum? Rechnen Sie nach. Formulieren Sie abschließend eine allgemeine Merkregel: Wann mittelt man Quotienten arithmetisch, wann harmonisch?

→ Lösung →

Hier wurden die *wahren* Gewichte bereits angegeben, daher einfach das gewichtete Mittel. Allgemeine Regel.

- *wahre* Gewichte angegeben -> gewichtetes Mittel
- *falsche* Gewichte angegeben, aber $w_i^{wahr} = \frac{w_i^{falsch}}{x_i}$ -> harmonisches Mittel mit $w_i = w_i^{falsch}$ in der Formel.

$\bar{x} = 50 \text{ km/h}$ Was die *wahren* Gewichte sind ergibt sich im Sachzusammenhang.

Aufgabe 3 Harmonisches & geometrisches Mittel II

1. **Cost-Average-Effekt.** Eine Anlegerin investiert vier Monate lang jeweils 1200 Euro in einen Fondsanteil. Die Anteilspreise betragen (in Euro):

Monat	1	2	3	4
Preis je Anteil	20	24	30	40

- (a) Berechnen Sie die Anzahl der in jedem Monat erworbenen Anteile sowie den insgesamt gezahlten Durchschnittspreis pro Anteil.

→ Lösung →

Stückzahl = (60, 50, 40, 30)

$$\bar{x}^{Preis} = \frac{1}{60+50+40+30} * (60 * 20 + \dots + 30 * 40) = 26.7$$

- (b) Zeigen Sie, dass dieser Durchschnittspreis genau dem *harmonischen Mittel* der vier Preise entspricht. Warum ist das so?

→ Lösung →

Hier ist es so, dass die *wahren* Gewichte die *Stückzahl* ist und nicht das Volumen / die Investitionshöhe. Es gilt $\text{Stückzahl} = \frac{\text{Investitionshöhe}}{\text{Preis}}$. Weil Investitionshöhe, das angegebene *falsche* Gewicht ist und der Preis das x_i , das uns interessiert, ist es genau das richtige Schema für das harmonische Mittel.

- (c) Berechnen Sie zusätzlich das arithmetische und das geometrische Mittel der vier Preise und ordnen Sie alle drei Mittelwerte der Größe nach. Welche allgemeine Ungleichung zwischen $\bar{x}_H$, $\bar{x}_G$ und $\bar{x}$ wird hier bestätigt?

→ Lösung →

$$\bar{x} = \frac{1}{4 \cdot 1200} (1200 \cdot 20 + \dots + 1200 \cdot 40) = 1/4 \cdot 20 + \dots + 1/4 \cdot 40 = 28.5$$

$$\bar{x}_{Geo} = \sqrt[4]{20 \cdot 24 \cdot 30 \cdot 40} = 27.5$$

Die arithmetisch-geometrische Ungleichung: $\bar{x}_{Geo} \leq \bar{x}$ (Gleichheit bei $\forall_{i,j \in I^2} x_i = x_j$).

$$x_H \leq x_{Geo}$$

- (d) Angenommen, die Anlegerin kauft stattdessen jeden Monat 50 *Anteile* (statt für einen festen Eurobetrag). Welcher Mittelwert der Preise ist dann der korrekte Durchschnittspreis pro Anteil? Begründen Sie.

→ Lösung →

Dann sind die *wahren* Gewichte angegeben und das gewichtete Mittel oder arithmetische Mittel (bei gleich hohen Gewichten) kann verwendet werden. $\bar{x} = 28.5$

2. **Wachstumsraten.** Der Umsatz eines Unternehmens verändert sich in drei aufeinander folgenden Jahren um +25%, +60% und -20%.

- (a) Bestimmen Sie die drei Wachstumsfaktoren und den Gesamtfaktor über die drei Jahre.

→ Lösung →

Es gilt $\text{Wachstumsfaktor} = 1 + \text{Wachstumsrate}$, Faktoren sind damit 1.25, 1.6, 0.8, der Gesamtfaktor ist das Produkt, also $1.25 \cdot 1.6 \cdot 0.8 = 1.6$

- (b) Berechnen Sie die durchschnittliche jährliche Wachstumsrate über das *geometrische Mittel*.

Nutzen Sie dabei die Darstellung $\bar{x}_G = \exp\left(\frac{1}{n} \sum_{i=1}^n \log(x_i)\right)$.

→ Lösung →

$$\bar{x}_{Geo} = e^{\frac{1}{3}(\ln 1.25 + \ln 1.6 + \ln 0.8)} = 1.17$$

Die durchschnittliche *Rate* ist damit 17%.

- (c) Berechnen Sie das arithmetische Mittel der Faktoren. Zeigen Sie durch Potenzieren mit 3, dass dieser Wert den Endstand des Umsatzes *falsch* vorhersagt, das geometrische Mittel dagegen korrekt.

→ Lösung →

$\bar{x} = 1/3 \cdot 1.25 + \dots = 1.22$. Gesamtfaktor sollte nach dieser Rechnung dann $1.22^3 = 1.82$ sein. $\neq 1.6$

- (d) Für welche Art von Merkmalen ist das geometrische Mittel der richtige Mittelwert?

→ Lösung →

Für Wachstum / prozentuale Zuwächse

Aufgabe 4 Konzentrationsmaße: Lorenzkurve und Gini

Auf einem regionalen Markt für Ladeinfrastruktur sind fünf Anbieter tätig. Ihre Jahresumsätze (in Mio. Euro) betragen:

1, 1, 2, 4, 12.

1. Erstellen Sie eine vollständige Wertetabelle mit j , $x_{(j)}$, u_j und v_j und zeichnen Sie die Lorenzkurve (inklusive Winkelhalbierender und beschrifteter Achsen).
 → Lösung →

j	$x_{(j)}$	$\sum_{i=1}^j x_{(i)}$	$u_j = \frac{j}{n}$	$v_j = \frac{\sum_{i=1}^j x_{(i)}}{\sum_{i=1}^n x_i}$
0	–	0	0,0	0,00
1	1	1	0,2	0,05
2	1	2	0,4	0,10
3	2	4	0,6	0,20
4	4	8	0,8	0,40
5	12	20	1,0	1,00

Tabelle 1: Wertetabelle zur Lorenzkurve ($n = 5$, $\sum x_i = 20$).

2. Lesen Sie aus Ihrer Tabelle ab bzw. formulieren Sie in Worten: Welchen Anteil am Gesamtumsatz vereinen die *kleinsten* 60% der Anbieter auf sich? Welchen Anteil hat der *größte* Anbieter?

→ Lösung →

Für die kleinsten 60% einfach $v_3 = 0.2$. Für den größten Anbieter dann $v_5 - v_4 = 0.6$

3. Berechnen Sie den Gini-Koeffizienten G auf *beiden* in der Vorlesung angegebenen Wegen:

$$G = \frac{2 \sum_{i=1}^n i \cdot x_{(i)} - (n+1) \sum_{i=1}^n x_{(i)}}{n \sum_{i=1}^n x_{(i)}} \quad \text{und} \quad G = 1 - \frac{1}{n} \sum_{i=1}^n (v_{i-1} + v_i).$$

Geben Sie außerdem den theoretischen Wertebereich von G für $n = 5$ an sowie den normierten Gini-Koeffizienten G^+ .

→ Lösung →

- $G = 1/2$
- $G \in [0, 0.8]$
- $G^+ = \frac{5}{4} * 0.5 = 0.625$

4. **Fusion.** Die beiden kleinsten Anbieter fusionieren. Es gibt nun $n = 4$ Anbieter mit Umsätzen 2, 2, 4, 12. Der Marktanteil des größten Anbieters bleibt unverändert und er hat einen Konkurrenten weniger, trotzdem sinkt der Gini-Koeffizient. Erklären Sie diesen scheinbaren Widerspruch. Gehen Sie dabei auf zwei Punkte ein: Was misst der Gini - und was passiert mit seinem Wertebereich, wenn n kleiner wird.

→ Lösung →

Betrachten wir nur den größten Anbieter, der 60% kontrolliert. **Davor** hatte das Trapez (Rechteck und darüber Dreieck), dass der größte Anbieter bei der Lorenzkurve beiträgt, eine Breite von $\frac{1}{5}$. Jetzt hat es eine größere Breite von $\frac{1}{4}$, wodurch sein Flächenbeitrag deutlich steigt. Dadurch fällt die Fläche zwischen Winkelhalbierender und Lorenzkurve. Der allgemeine Grund ist, dass der Gini-Index, die Verteilung *innerhalb einer erfassten Gruppe* erfasst. Bei Fusion oder dem Verlassen des Marktes, kann es sein, dass diese *erfasste Gruppe* kleiner wird, was den Gini-Index *künstlich* senken kann. Außerdem kommt noch hinzu, dass $Wertebereich_G = [0, \frac{n-1}{n}]$ mit größerem n schrumpft.

5. Berechnen und Interpretieren Sie G^+ nach der Fusion

→ Lösung →

$$G^+ = \frac{4}{3} * G = \frac{4}{3} * 0.4 = 0.53. \text{ Konzentration ist im Mittelfeld.}$$

6. **Skaleninvarianz.** Alle fünf ursprünglichen Umsätze verdoppeln sich. Wie ändern sich G , G^+ ? Begründen Sie ohne Neuberechnung.

→ *Lösung* →

Gini basiert auf *Anteilen*, wenn sich alle Werte vervielfachen bleiben die Anteile unverändert.

7. Zwei Märkte haben denselben Wert $G^+ = 0,5$, aber deutlich unterschiedliche Lorenzkurven. Skizzieren Sie zwei solche Situationen (verbal oder grafisch) und erklären Sie, warum die alleinige Angabe des Gini-Koeffizienten irreführend sein kann.

→ *Lösung* →

Gini ist nur ein Maß, das den gesamten Markt betrifft. 2 Situationen mit gleichem Gini wären

- Es gibt 2 *Schichten*. Innerhalb der Schichten sind alle gleich, aber es bestehen sehr große Unterschiede zwischen den Schichten. Die Lorenzkurve besteht in diesem Fall aus 2 Geraden: Im ersten Abschnitt mit niedriger Steigung, im zweiten Abschnitt mit hoher Steigung.
- Normalfall mit streng monoton wachsender Lorenzkurve ähnlich der Form x^2 oder e^x