

Deskriptive Statistik – Tutorium

Übungsblatt 3: Zusammenhangsmaße & statistische Grafiken

Klausurvorbereitung, Statistik I – LMU München

Aufgabe 1 Diskrete Merkmale: Verkehrsmittelwahl

In einer Befragung von $n = 200$ Studierenden wurden das hauptsächlich genutzte Verkehrsmittel zur Universität (X) und der Wohnort (Y) erhoben:

	$b_1 = \text{Stadt}$	$b_2 = \text{Umland}$	Σ
$a_1 = \text{Fahrrad}$	60	10	
$a_2 = \text{ÖPNV}$	50	40	
$a_3 = \text{Auto}$	10	30	
Σ			200

1. Vervollständigen Sie die Randhäufigkeiten $h_{i\bullet}$ und $h_{\bullet j}$ und stellen Sie die Kontingenztafel der *relativen* Häufigkeiten f_{ij} auf.
2. Berechnen Sie folgende Größen und formulieren Sie zu jeder einen Interpretationssatz: h_{32} , $f_{1\bullet}$, $f_{Y|X}(b_2 | a_1)$, $f_{X|Y}(a_3 | b_2)$.
3. Geben Sie die vollständige bedingte Häufigkeitsverteilung von Y gegeben $X = a_i$ für alle drei Verkehrsmittel an. Sind X und Y *empirisch unabhängig*? Begründen Sie Ihre Antwort mit der Definition der empirischen Unabhängigkeit über bedingte relative Häufigkeiten.
4. Stellen Sie die Unabhängigkeitstabelle der unter empirischer Unabhängigkeit erwarteten Häufigkeiten $\tilde{h}_{ij}$ auf.
5. Berechnen Sie den χ^2 -Koeffizienten, den Kontingenzkoeffizienten K sowie den korrigierten Kontingenzkoeffizienten K^* . Geben Sie außerdem den theoretischen Maximalwert von χ^2 für diese Tafel an und interpretieren Sie K^* .
6. Warum ist der Wert von χ^2 allein kaum interpretierbar? Nennen Sie zwei Gründe. Was würde mit χ^2 und mit K^* geschehen, wenn alle Zellhäufigkeiten verzehnfacht würden?
7. Betrachten Sie nur die Teiltabelle aus den Zeilen *Fahrrad* und *Auto*.
 - (a) Berechnen Sie die bedingten Odds für „Stadt statt Umland“ in beiden Subpopulationen.
 - (b) Berechnen Sie das Odds Ratio γ und interpretieren Sie den Wert präzise.
 - (c) Welche Information liefert das Odds Ratio, die K^* *nicht* liefert?
8. Sie möchten die bedingten Verteilungen $Y | X = a_i$ grafisch darstellen.
 - (a) Welche Grafik wählen Sie? Skizzieren Sie sie.
 - (b) Beschreiben Sie Ihre Grafik mit den Begriffen der *grammar of graphics*: Welche Geometrie, welche ästhetischen Zuordnungen für welche Merkmale?

- (c) Welchen Nachteil hat eine auf 100% normierte Darstellung gegenüber einer Darstellung der absoluten Häufigkeiten – und umgekehrt?

Aufgabe 2 Metrische & ordinale Merkmale: Korrelation

Für $n = 8$ Studierende wurden die Anzahl der bearbeiteten Übungsblätter (X) und die in der Klausur erreichte Punktzahl (Y , von maximal 20) erhoben:

i	1	2	3	4	5	6	7	8
x_i	1	2	3	4	5	6	7	8
y_i	3	5	4	8	7	11	9	13

1. Zeichnen Sie ein Streudiagramm der Daten und beschreiben Sie den erkennbaren Zusammenhang qualitativ (Richtung, Stärke, Form).
2. Berechnen Sie $\bar{x}$, $\bar{y}$, $\sum_i (x_i - \bar{x})^2$, $\sum_i (y_i - \bar{y})^2$ und $\sum_i (x_i - \bar{x})(y_i - \bar{y})$. Legen Sie dazu eine übersichtliche Arbeitstabelle an.
3. Berechnen Sie die Kovarianz S_{xy} und den Bravais-Pearson-Korrelationskoeffizienten r_{xy} . Interpretieren Sie beide Werte. Warum ist r_{xy} besser geeignet als S_{xy} ?
4. Berechnen Sie den Rangkorrelationskoeffizienten nach Spearman r_{xy}^{SP} über die Kurzformel

$$r_{xy}^{SP} = 1 - \frac{6 \sum_{i=1}^n d_i^2}{(n^2 - 1)n}, \quad d_i = rg(x_i) - rg(y_i).$$

Unter welcher Voraussetzung darf diese Kurzformel verwendet werden? Ist sie hier erfüllt?

5. Berechnen Sie Kendalls τ_{xy} , indem Sie die Anzahl konkordanter und diskordanter Paare bestimmen. Wie viele Paare sind insgesamt zu betrachten?
6. Vergleichen Sie r_{xy} , r_{xy}^{SP} und τ_{xy} .
 - (a) Welche Art von Zusammenhang misst jedes der drei Maße?
 - (b) Welches Skalenniveau setzt jedes Maß mindestens voraus?
 - (c) Welche in der Vorlesung genannte Regelmäßigkeit über das Verhältnis von τ_{xy} und r_{xy}^{SP} bestätigt sich hier?
7. Die Merkmale werden transformiert zu $\tilde{x}_i = 2x_i + 1$ und $\tilde{y}_i = 20 - y_i$ („verlorene Punkte“ statt erreichter Punkte). Geben Sie $r_{\tilde{x}\tilde{y}}$ und $r_{\tilde{x}\tilde{y}}^{SP}$ *ohne Neuberechnung* an und begründen Sie mit der jeweiligen Transformationsregel.
8. Es kommt eine neunte Person hinzu mit $x_9 = 1$ und $y_9 = 20$. Diskutieren Sie *ohne vollständige Neuberechnung*: Welches der drei Zusammenhangsmaße reagiert am stärksten, welches am schwächsten auf diese Beobachtung? Begründen Sie.
9. Betrachten Sie den folgenden zweiten Datensatz:

x_i	-3	-2	-1	0	1	2	3
y_i	9	4	1	0	1	4	9

- Zeigen Sie durch Rechnung, dass $r_{xy} = 0$ gilt.
- Zwischen X und Y besteht ein exakter funktionaler Zusammenhang. Welcher?
- Was folgt daraus für die Aussage „ $r_{xy} = 0$ bedeutet Unabhängigkeit“? Formulieren Sie die korrekte Aussage.
- Welches der in der Vorlesung besprochenen Maße wäre geeignet, auch solche nichtlinearen Zusammenhänge zu entdecken?

Aufgabe 3 Sensitivität, Spezifität, ROC und AUC

Für 10 Patient:innen liegen ein Biomarker-Score X (je höher, desto stärker der Krankheitsverdacht) und der tatsächliche Krankheitsstatus Y vor ($Y = 1$: krank, $Y = 0$: gesund):

i	1	2	3	4	5	6	7	8	9	10
x_i	1	2	3	4	5	6	7	8	9	10
y_i	0	0	1	0	0	1	0	1	1	1

Diagnostiziert wird nach der Regel $\hat{y}_i = 1 \iff x_i \geq c$ für einen Schwellenwert c .

- Stellen Sie für den Schwellenwert $c = 6$ die 2×2 -Tafel der Vorhersagen gegen den wahren Status auf. Benennen Sie alle vier Zellen mit den Begriffen der Vorlesung (wahr positiv, falsch positiv, wahr negativ, falsch negativ).
- Berechnen Sie für $c = 6$ Sensitivität (TPR), Spezifität (TNR) und Falsch-Positiv-Rate (FPR). Formulieren Sie zu jeder Kennzahl den zugehörigen Fragesatz („Welcher Anteil der ... wurde ...“).
- Bestimmen Sie die Wertepaare $(FPR(c), TPR(c))$ für *alle* relevanten Schwellenwerte $c \in \{1, 2, \dots, 10\}$ sowie für $c < x_{(1)}$ und $c > x_{(n)}$. Legen Sie dazu eine Tabelle an und zeichnen Sie die ROC-Kurve.
- Warum verläuft die ROC-Kurve immer von $(0,0)$ nach $(1,1)$? Was bedeuten diese beiden Endpunkte inhaltlich?
- Die Klinik fordert eine Sensitivität von mindestens 0,8. Welchen Schwellenwert c würden Sie wählen, um dabei die Falsch-Positiv-Rate zu minimieren? Begründen Sie anhand Ihrer Tabelle.
- Berechnen Sie die AUC. Interpretieren Sie den Wert in einem Satz.
- Welchen AUC-Wert erwarten Sie, wenn X und Y unabhängig sind? Wie sähe die ROC-Kurve in diesem Fall aus?
- Basistraten.** Der Test wird nun in einem Screening eingesetzt. Nehmen Sie Sensitivität = 0,8 und Spezifität = 0,8 an; die Prävalenz der Krankheit in der gescreenten Bevölkerung betrage 1%.
 - Erstellen Sie eine erwartete Häufigkeitstabelle für 100 000 getestete Personen.
 - Berechnen Sie den positiv prädiktiven Wert ppV und den negativ prädiktiven Wert npV .

- (c) Erläutern Sie in Stichpunkten, warum der *ppV* so niedrig ausfällt, obwohl Sensitivität und Spezifität hoch erscheinen, und was das für den Praxiseinsatz eines Screening-Tests bedeutet.

Aufgabe 4 Kerndichteschätzer: Fehlersuche im Pseudocode

In der Vorlesung wurde der Kerndichteschätzer eingeführt als

$$\hat{f}_h(x) = \frac{1}{n h} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right),$$

wobei K eine Kernfunktion und $h > 0$ die Bandbreite bezeichnet. Im Folgenden wird stets der *Gauß-Kern* verwendet, also die Dichte der Standardnormalverteilung

$$\varphi(z) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}z^2\right).$$


Eine Studierende möchte den Schätzer selbst implementieren und schreibt dazu den folgenden Pseudocode. Der Code **enthält zwei inhaltliche Fehler**.

```
1 KDE <- new Object()
2
3 KDE.Data <- (x_1, x_2, ..., x_n)      # Datensatz (Urliste)
4 KDE.h    <- 2                        # Bandbreite
5 KDE.n    <- length(KDE.Data)         # Stichprobenumfang
6
7 KDE.Kernel <- function(z) {
8   return dnorm(z / KDE.h)            # dnorm(.) = Dichte der N(0,1)
9 }
10
11 KDE.density <- function(x) {
12   Summe <- 0
13   for (i in 1 : KDE.n) {
14     mu      <- KDE.Data[i]
15     Entfernung <- x - mu
16     Summe    <- Summe + KDE.Kernel(x)
17   }
18   return Summe / KDE.n
19 }
```

Identifizieren Sie die beiden Fehler. Geben Sie jeweils die Zeilennummer an und beschreiben Sie in einem Satz, was dort falsch gemacht wird.

Aufgabe 5 Grammer of graphics

Teil A: Kritik einer Infografik.



1. Beschreiben Sie die Grafik mit den Begriffen des *Grammar of Graphics* frameworks.
2. Beschreiben Sie einen Kritikpunkt an der Grafik

Teil B: Histogramm und Flächentreue.

Für $n = 100$ Mietwohnungen wurde die Wohnfläche (in m^2) in ungleich breite Klassen eingeteilt:

Klasse	(0, 10]	(10, 20]	(20, 40]	(40, 80]
absolute Häufigkeit n_j	20	40	30	10

3. Berechnen Sie die relativen Häufigkeiten f_j , die Klassenbreiten b_j und die korrekten Histogramm-Höhen y_j nach dem *Prinzip der Flächentreue* ($b_j \cdot y_j = f_j$). Skizzieren Sie das Histogramm.
4. Welchen falschen Eindruck erzeugt ein Histogramm, in dem stattdessen die absoluten Häufigkeiten als Höhen abgetragen werden? Welche Klasse würde dann über-, welche unterschätzt?
5. Nennen Sie zwei weitere in der Vorlesung genannte Nachteile bzw. Fallstricke von Histogrammen und geben Sie an, welches alternative Verfahren zur Darstellung der Verteilung eines metrischen Merkmals diese Probleme abmildert.

Teil C: Grafikwahl.

Geben Sie für jede der folgenden Fragestellungen an, welche Grafik Sie wählen würden und warum (Auswahl u. a.: Säulen-/Balkendiagramm, Stapeldiagramm, Mosaikplot, Histogramm, Kerndichteschätzer, gruppierter Boxplot, Streudiagramm, Streudiagramm mit Facettierung, Dotplot):

6. Wie unterscheidet sich die Verteilung der Nettoquadratmetermiete zwischen sechs Baualterklassen?
7. Besteht ein Zusammenhang zwischen Wohnfläche und Nettomiete, und unterscheidet sich dieser zwischen normaler und bester Wohnlage?
8. Ist die Verteilung der Zinssätze eingipflig oder mehrgipflig?
9. Wie verteilen sich die Antworten auf eine fünfstufige Zufriedenheitsskala über vier Altersgruppen hinweg?

Aufgabe 6 Kausalität: Confounding & Simpson's Paradox

Eine Universität vergleicht zwei Kursformate in der Mathematik-Grundvorlesung (Präsenz vs. Online) hinsichtlich der Bestehensquote. Zusätzlich ist bekannt, ob die Studierenden vorher den freiwilligen Mathe-Vorkurs besucht haben.

Teilgruppe	Format	Teilnehmende	bestanden	Bestehensquote
ohne Vorkurs	Präsenz	400	200	
	Online	100	45	
mit Vorkurs	Präsenz	100	95	
	Online	400	360	

1. Berechnen Sie alle vier bedingten Bestehensquoten (also die bedingten relativen Häufigkeiten $f(\text{bestanden} \mid \text{Format}, \text{Vorkurs})$) und tragen Sie sie in die Tabelle ein. Welches Format ist *innerhalb jeder* der beiden Teilgruppen besser?
2. Stellen Sie die aggregierte 2×2 -Tafel auf (Format $\times$ bestanden, über beide Teilgruppen hinweg) und berechnen Sie die beiden marginalen Bestehensquoten. Welches Format ist nun besser?
3. Berechnen Sie das Odds Ratio „bestehen statt durchfallen, Präsenz gegen Online“
 - (a) innerhalb der Gruppe *ohne* Vorkurs,
 - (b) innerhalb der Gruppe *mit* Vorkurs,
 - (c) auf Basis der aggregierten Tafel.

Interpretieren Sie alle drei Werte und beschreiben Sie, was mit der *Richtung* des Zusammenhangs beim Aggregieren passiert.

4. Wie heißt das hier beobachtete Phänomen? Erklären Sie in Stichpunkten, wodurch es *rechnerisch* zustande kommt (Hinweis: Achten Sie auf die Verteilung der Teilnehmendenzahlen über die Teilgruppen).
5. Zeichnen Sie die kausale Struktur mit den drei Variablen *Format*, *Bestehen* und *Vorkurs* als Pfeildiagramm. Welche Rolle spielt der Vorkurs? Wie heißt diese kausale Struktur in der Vorlesung?
6. Auf welcher Ebene – aggregiert oder nach Vorkurs getrennt – würden Sie die Ergebnisse berichten, wenn Sie eine Empfehlung für das Kursformat aussprechen sollen? Begründen Sie.

7. Wie müsste eine Studie angelegt sein, damit ein *kausaler* Schluss „Präsenzlehre erhöht die Bestehenswahrscheinlichkeit“ zulässig wäre? Beziehen Sie sich auf die in der Vorlesung besprochenen Erhebungsarten.