

Deskriptive Statistik – Tutorium

Übungsblatt 3: Zusammenhangsmaße & statistische Grafiken

Klausurvorbereitung, Statistik I – LMU München

Aufgabe 1 Diskrete Merkmale: Verkehrsmittelwahl

In einer Befragung von $n = 200$ Studierenden wurden das hauptsächlich genutzte Verkehrsmittel zur Universität (X) und der Wohnort (Y) erhoben:

	$b_1 = \text{Stadt}$	$b_2 = \text{Umland}$	Σ
$a_1 = \text{Fahrrad}$	60(0.3)	10(0.05)	70(0.35)
$a_2 = \text{ÖPNV}$	50(0.25)	40(0.2)	90(0.45)
$a_3 = \text{Auto}$	10(0.05)	30(0.15)	40(0.2)
Σ	120(0.6)	80(0.4)	200(1)

1. Vervollständigen Sie die Randhäufigkeiten $h_{i\bullet}$ und $h_{\bullet j}$ und stellen Sie die Kontingenztafel der *relativen* Häufigkeiten f_{ij} auf.
2. Berechnen Sie folgende Größen und formulieren Sie zu jeder einen Interpretationssatz: h_{32} , $f_{1\bullet}$, $f_{Y|X}(b_2 | a_1)$, $f_{X|Y}(a_3 | b_2)$.
→ Lösung →

- $h_{32} = 30$ -> Absolute Häufigkeit Auto+Umland
- $f_{1\bullet} = 0.35$ -> Relative Häufigkeit Fahrrad
- $f_{Y|X}(b_2 | a_1) = \frac{1}{7}$ -> Relative Häufigkeit von Umland gegeben Fahrrad
- $f_{X|Y}(a_3 | b_2) = \frac{0.15}{0.4} = 0.375$ -> Relative Häufigkeit von Auto gegeben Umland

3. Geben Sie die vollständige bedingte Häufigkeitsverteilung von Y gegeben $X = a_i$ für alle drei Verkehrsmittel an. Sind X und Y *empirisch unabhängig*? Begründen Sie Ihre Antwort mit der Definition der empirischen Unabhängigkeit über bedingte relative Häufigkeiten.
→ Lösung →

- $p_{Y|X} = a_1 = (\frac{6}{7}, \frac{1}{7})$
- $p_{Y|X} = a_2 = (\frac{5}{9}, \frac{4}{9})$
- $p_{Y|X} = a_3 = (\frac{1}{4}, \frac{3}{4})$

-> abhängig, weil die Verteilung von Y sich in den Schichten von $X = a_i$ unterscheidet

4. Stellen Sie die Unabhängigkeitstabelle der unter empirischer Unabhängigkeit erwarteten Häufigkeiten $\tilde{h}_{ij}$ auf.

→ Lösung →

	$b_1 = \text{Stadt}$	$b_2 = \text{Umland}$	Σ
$a_1 = \text{Fahrrad}$	42	28	70(0.35)
$a_2 = \text{ÖPNV}$	54	36	90(0.45)
$a_3 = \text{Auto}$	24	16	40(0.2)
Σ	120(0.6)	80(0.4)	200(1)

5. Berechnen Sie den χ^2 -Koeffizienten, den Kontingenzkoeffizienten K sowie den korrigierten Kontingenzkoeffizienten K^* . Geben Sie außerdem den theoretischen Maximalwert von χ^2 für diese Tafel an und interpretieren Sie K^* .

→ Lösung →

Zunächst wird die Tabelle angegeben, wobei die Zellen $(x_i, y_j) = \frac{(n_{ij} - \hat{n}_{ij})^2}{\hat{n}_{ij}}$

	$b_1 = \text{Stadt}$	$b_2 = \text{Umland}$	Σ
$a_1 = \text{Fahrrad}$	54/7	81/7	
$a_2 = \text{ÖPNV}$	8/27	4/9	
$a_3 = \text{Auto}$	49/6	49/4	
Σ			

- $\chi^2 = 40.4$
 - $K = \sqrt{\frac{40.4}{40.4+200}} = 0.41$
 - $K^* = \sqrt{2} * 0.41 = 0.58$ -> Erkennbarer deutlicher Zusammenhang zwischen den Merkmalen
 - $\chi^2_{\max} = n * (\min\{k, l\} - 1) = 200 * 1 = 200$
6. Warum ist der Wert von χ^2 allein kaum interpretierbar? Nennen Sie zwei Gründe. Was würde mit χ^2 und mit K^* geschehen, wenn alle Zellhäufigkeiten verzehnfacht würden?

→ Lösung →

- Der Wertebereich von χ^2 hängt sehr stark von n ab.
 - Und auch von der Tafelgröße $\min(k, l)$
 - $\chi^2 = \sum_{ij} \frac{(n_{ij} - \hat{n}_{ij})^2}{\hat{n}_{ij}}$
 - Wenn sich n ver-10-fach, ver-10-fachen sich n_{ij} und $\hat{n}_{ij}$. Damit ver-10-fachen sich alle Summanden und χ^2 ver-10-facht sich ebenso.
 - K^* ist auf $[0, 1]$ normiert und würde keine Reaktion zeigen.
7. Betrachten Sie nur die Teiltafel aus den Zeilen *Fahrrad* und *Auto*.

- (a) Berechnen Sie die bedingten Odds für „Stadt statt Umland“ in beiden Subpopulationen.

→ Lösung →

- $\xi_{\text{Fahrrad}} = \frac{0.3}{0.05} = 6$
- $\xi_{\text{Auto}} = \frac{0.05}{0.15} = \frac{1}{3}$

- (b) Berechnen Sie das Odds Ratio γ und interpretieren Sie den Wert präzise.

→ Lösung →

$\gamma = 18$. Die bedingten Odds für *Stadt statt Umland* sind in der Schicht *Fahrrad* 18 mal so hoch als in der Schicht *Auto*.

- (c) Welche Information liefert das Odds Ratio, die K^* nicht liefert?

→ Lösung →

Kennzahlen, die auf χ^2 basieren, können nur bestimmen, ob ein Zusammenhang vorliegt. Odds können zusätzlich einen Richtungszusammenhang identifizieren.

8. Sie möchten die bedingten Verteilungen $Y | X = a_i$ grafisch darstellen.

- (a) Welche Grafik wählen Sie? Skizzieren Sie sie.

→ Lösung →

...

`geom_bar(aes(x = Wohnort, color = Verkehrsmittel), position = dodge)`

- (b) Beschreiben Sie Ihre Grafik mit den Begriffen der *grammar of graphics*: Welche Geometrie, welche ästhetischen Zuordnungen für welche Merkmale?

→ Lösung →

- Geometrie -> Balken / Rechtecke
- Ästhetik -> Höhe der Balken (y-Achse) für die bedingten relativen Häufigkeiten von Y. Die Position an der x-Achse gibt die beiden möglichen Merkmalsausprägungen von Y an. Dem Merkmal X wird die Ästhetik Farbe zugeordnet.

- (c) Welchen Nachteil hat eine auf 100% normierte Darstellung gegenüber einer Darstellung der absoluten Häufigkeiten – und umgekehrt?

→ Lösung →

- Normierte Darstellung gibt Auskunft über bedingte relative Häufigkeiten, absoluten Häufigkeiten sind nicht einsehbar.
- Darstellung der absoluten Häufigkeiten dann umgekehrt

Aufgabe 2 Metrische & ordinale Merkmale: Korrelation

Für $n = 8$ Studierende wurden die Anzahl der bearbeiteten Übungsblätter (X) und die in der Klausur erreichte Punktzahl (Y , von maximal 20) erhoben:

i	1	2	3	4	5	6	7	8
x_i	1	2	3	4	5	6	7	8
y_i	3	5	4	8	7	11	9	13

1. Zeichnen Sie ein Streudiagramm der Daten und beschreiben Sie den erkennbaren Zusammenhang qualitativ (Richtung, Stärke, Form).

→ Lösung →

Positiv, Stark, Linear

2. Berechnen Sie $\bar{x}$, $\bar{y}$, $\sum_i (x_i - \bar{x})^2$, $\sum_i (y_i - \bar{y})^2$ und $\sum_i (x_i - \bar{x})(y_i - \bar{y})$. Legen Sie dazu eine übersichtliche Arbeitstabelle an.

→ Lösung →

- $\bar{x} = 4.5$
- $\bar{y} = 7.5$

- $\sum_i (x_i - \bar{x})^2 = 42$
- $\sum_i (y_i - \bar{y})^2 = 84$
- $\sum_i (x_i - \bar{x})(y_i - \bar{y}) = 55$

3. Berechnen Sie die Kovarianz S_{xy} und den Bravais-Pearson-Korrelationskoeffizienten r_{xy} . Interpretieren Sie beide Werte. Warum ist r_{xy} besser geeignet als S_{xy} ?
 → Lösung →

- $S_{xy} = \frac{1}{8} 55 = 6.9$
- $r_{xy} = \frac{55}{\sqrt{42 \cdot 84}} = 0.93$
- S_{xy} -> Der Durchschnitt des Produktes der beiden Abweichungen von den Mittelwerten ist 6.9
- r_{xy} -> hoher gleichgerichteter Zusammenhang
- S_{xy} ist schlechter geeignet, weil es einheitenabhängig und unbeschränkt ist

4. Berechnen Sie den Rangkorrelationskoeffizienten nach Spearman r_{xy}^{SP} über die Kurzformel

$$r_{xy}^{SP} = 1 - \frac{6 \sum_{i=1}^n d_i^2}{(n^2 - 1)n}, \quad d_i = rg(x_i) - rg(y_i).$$

Unter welcher Voraussetzung darf diese Kurzformel verwendet werden? Ist sie hier erfüllt?
 → Lösung →

- $r_{SP} = 0.93$
- Verwendung wenn keine Rang-Bindungen vorliegen -> erfüllt

5. Berechnen Sie Kendalls τ_{xy} , indem Sie die Anzahl konkordanter und diskordanter Paare bestimmen. Wie viele Paare sind insgesamt zu betrachten?

→ Lösung →

Für $n = 8$ gibt es insgesamt $(8 \text{ über } 2) = 28$ Paare. $\tau_{xy} = 0.79$

6. Vergleichen Sie r_{xy} , r_{xy}^{SP} und τ_{xy} .

(a) Welche Art von Zusammenhang misst jedes der drei Maße?

→ Lösung →

Einen *Richtungszusammenhang*. r_{xy} misst einen linearen Zusammenhang, während τ_{xy} und r_{SP} einen monotonen Zusammenhang messen.

(b) Welches Skalenniveau setzt jedes Maß mindestens voraus?

→ Lösung →

- r_{xy} verlangt Intervallskala
- r_{SP} und τ_{xy} verlangen nur Ordinalskala

(c) Welche in der Vorlesung genannte Regelmäßigkeit über das Verhältnis von τ_{xy} und r_{xy}^{SP} bestätigt sich hier?

→ Lösung →

Kendall's kleiner.

7. Die Merkmale werden transformiert zu $\tilde{x}_i = 2x_i + 1$ und $\tilde{y}_i = 20 - y_i$ („verlorene Punkte“ statt erreichter Punkte). Geben Sie $r_{\tilde{x}\tilde{y}}$ und $r_{\tilde{x}\tilde{y}}^{SP}$ ohne Neuberechnung an und begründen Sie mit der jeweiligen Transformationsregel.

→ Lösung →

- Für lineare Transformationen $f(x) = ax + b$ mit $a > 0$ bleiben die Kennzahlen gleich. Weil hier bei $f(y)$ $a < 0$ gilt, drehen sie sich um.
 - $r_{xy} = -0.93; r_{SP} = -0.93$
8. Es kommt eine neunte Person hinzu mit $x_9 = 1$ und $y_9 = 20$. Diskutieren Sie *ohne vollständige Neuberechnung*: Welches der drei Zusammenhangsmaße reagiert am stärksten, welches am schwächsten auf diese Beobachtung? Begründen Sie.
- Lösung →
- Die neue Beobachtung ist ein ziemlicher Ausreißer, es geht daher um die *Ausreißersensitivität*.

- r_{xy} reagiert am stärksten, weil es die neue Beobachtung voll numerisch miteinbezieht
 - τ_{xy} reagiert am schwächsten, weil es auf *Richtungs-Paaren* besteht. Diese Paare beziehen aber nur Vorzeichen mit ein.
9. Betrachten Sie den folgenden zweiten Datensatz:

x_i	-3	-2	-1	0	1	2	3
y_i	9	4	1	0	1	4	9

- (a) Zeigen Sie durch Rechnung, dass $r_{xy} = 0$ gilt.
- Lösung →
- (b) Zwischen X und Y besteht ein exakter funktionaler Zusammenhang. Welcher?
- Lösung →
- Quadratisch
- (c) Was folgt daraus für die Aussage „ $r_{xy} = 0$ bedeutet Unabhängigkeit“? Formulieren Sie die korrekte Aussage.
- Lösung →
- nicht Linear abhängig
- (d) Welches der in der Vorlesung besprochenen Maße wäre geeignet, auch solche nichtlinearen Zusammenhänge zu entdecken?
- Lösung →
- Distanzkorrelation

Aufgabe 3 Sensitivität, Spezifität, ROC und AUC

Für 10 Patient:innen liegen ein Biomarker-Score X (je höher, desto stärker der Krankheitsverdacht) und der tatsächliche Krankheitsstatus Y vor ($Y = 1$: krank, $Y = 0$: gesund):

i	1	2	3	4	5	6	7	8	9	10
x_i	1	2	3	4	5	6	7	8	9	10
y_i	0	0	1	0	0	1	0	1	1	1

Diagnostiziert wird nach der Regel $\hat{y}_i = 1 \iff x_i \geq c$ für einen Schwellenwert c .

1. Stellen Sie für den Schwellenwert $c = 6$ die 2×2 -Tafel der Vorhersagen gegen den wahren Status auf. Benennen Sie alle vier Zellen mit den Begriffen der Vorlesung (wahr positiv, falsch positiv, wahr negativ, falsch negativ).

→ Lösung →

	Wahr: $y = 1$ (krank)	Wahr: $y = 0$ (gesund)
Vorhersage: $\hat{y} = 1$ (krank)	4 (wahr positiv)	1 (falsch positiv)
Vorhersage: $\hat{y} = 0$ (gesund)	1 (falsch negativ)	4 (wahr negativ)

2. Berechnen Sie für $c = 6$ Sensitivität (TPR), Spezifität (TNR) und Falsch-Positiv-Rate (FPR). Formulieren Sie zu jeder Kennzahl den zugehörigen Fragesatz („Welcher Anteil der ... wurde ...“).

→ Lösung →

- $TPR = 0.8$ -> 80% der Kranken als krank erkannt
 - $TNR = 0.8$ -> 80% der Gesunden auch als gesund erkannt
 - $FPR = 0.2$ -> Für 20% der Gesunden wurde krank vorhergesagt
3. Bestimmen Sie die Wertepaare $(FPR(c), TPR(c))$ für alle relevanten Schwellenwerte $c \in \{1, 2, \dots, 10\}$ sowie für $c < x_{(1)}$ und $c > x_{(n)}$. Legen Sie dazu eine Tabelle an und zeichnen Sie die ROC-Kurve.

→ Lösung →

Schwellenwert c	TP	FP	TPR ($TP/5$)	FPR ($FP/5$)	Punkt (FPR, TPR)
$c > 10$	0	0	0.0	0.0	(0.0, 0.0)
$c = 10$	1	0	0.2	0.0	(0.0, 0.2)
$c = 9$	2	0	0.4	0.0	(0.0, 0.4)
$c = 8$	3	0	0.6	0.0	(0.0, 0.6)
$c = 7$	3	1	0.6	0.2	(0.2, 0.6)
$c = 6$	4	1	0.8	0.2	(0.2, 0.8)
$c = 5$	4	2	0.8	0.4	(0.4, 0.8)
$c = 4$	4	3	0.8	0.6	(0.6, 0.8)
$c = 3$	5	3	1.0	0.6	(0.6, 1.0)
$c = 2$	5	4	1.0	0.8	(0.8, 1.0)
$c = 1$	5	5	1.0	1.0	(1.0, 1.0)
$c < 1$	5	5	1.0	1.0	(1.0, 1.0)

4. Warum verläuft die ROC-Kurve immer von (0,0) nach (1,1)? Was bedeuten diese beiden Endpunkte inhaltlich?

→ Lösung →

Wenn man $c > x_{max}$ wählt, werden alle als negativ vorhergesagt. Damit ist die TPR und die FPR automatisch 0. Wenn man $c < x_{min}$ wählt, werden alle als positiv vorhergesagt, damit sind TPR und FPR automatisch 1.

5. Die Klinik fordert eine Sensitivität von mindestens 0,8. Welchen Schwellenwert c würden Sie wählen, um dabei die Falsch-Positiv-Rate zu minimieren? Begründen Sie anhand Ihrer Tabelle.

→ Lösung →

$c = 6$

6. Berechnen Sie die AUC. Interpretieren Sie den Wert in einem Satz.

→ Lösung →

AUC = 0.84. Wenn zufällig eine kranke und eine gesunde Person gewählt werden, ist die Wahrscheinlichkeit, dass die kranke Person einen höheren Score hat gleich 84%.

7. Welchen AUC-Wert erwarten Sie, wenn X und Y unabhängig sind? Wie sähe die ROC-Kurve in diesem Fall aus?

→ Lösung →

AUC = 0.5, ROC Kurve ist Winkelhalbierende

8. **Basisraten.** Der Test wird nun in einem Screening eingesetzt. Nehmen Sie Sensitivität = 0,8 und Spezifität = 0,8 an; die Prävalenz der Krankheit in der gescreenten Bevölkerung betrage 1%.

(a) Erstellen Sie eine erwartete Häufigkeitstabelle für 100 000 getestete Personen.

→ Lösung →

	Wahr: $y = 1$ (krank)	Wahr: $y = 0$ (gesund)	Summe
Test positiv ($\hat{y} = 1$)	800	19 800	20 600
Test negativ ($\hat{y} = 0$)	200	79 200	79 400
Summe	1 000	99 000	100 000

(b) Berechnen Sie den positiv prädiktiven Wert ppV und den negativ prädiktiven Wert npV .

→ Lösung →

Für ppV und npV müssen die horizontalen Schichten betrachtet werden.

- $ppV = 0.04$
- $npV = 0.997$

(c) Erläutern Sie in Stichpunkten, warum der ppV so niedrig ausfällt, obwohl Sensitivität und Spezifität hoch erscheinen, und was das für den Praxiseinsatz eines Screening-Tests bedeutet.

→ Lösung →

Weil die Prävalenz so niedrig ist. Für den Praxiseinsatz bedeutet es, dass erhöhte Vorsicht bei der Modellauswahl geboten ist. Nur hohe TPR / TNR bedeuten nicht automatisch, dass es sich um ein performantes Modell handelt.

Aufgabe 4 Kerndichteschätzer: Fehlersuche im Pseudocode

In der Vorlesung wurde der Kerndichteschätzer eingeführt als

$$\hat{f}_h(x) = \frac{1}{n h} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right),$$

wobei K eine Kernfunktion und $h > 0$ die Bandbreite bezeichnet. Im Folgenden wird stets der *Gauß-Kern* verwendet, also die Dichte der Standardnormalverteilung

$$\varphi(z) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}z^2\right).$$

Eine Studierende möchte den Schätzer selbst implementieren und schreibt dazu den folgenden Pseudocode. Der Code **enthält zwei inhaltliche Fehler**.

```

1 KDE <- new Object()
2
3 KDE.Data <- (x_1, x_2, ..., x_n)      # Datensatz (Urliste)
4 KDE.h    <- 2                        # Bandbreite
5 KDE.n    <- length(KDE.Data)         # Stichprobenumfang
6
7 KDE.Kernel <- function(z) {
8   return dnorm(z / KDE.h)            # dnorm(.) = Dichte der N(0,1)
9 }
10
11 KDE.density <- function(x) {
12   Summe <- 0
13   for (i in 1 : KDE.n) {
14     mu      <- KDE.Data[i]
15     Entfernung <- x - mu
16     Summe    <- Summe + KDE.Kernel(x)
17   }
18   return Summe / KDE.n
19 }

```


Identifizieren Sie die beiden Fehler. Geben Sie jeweils die Zeilennummer an und beschreiben Sie in einem Satz, was dort falsch gemacht wird.

→ Lösung →

- 16: bei KDE.Kernel(.) muss Entfernung = $x - \mu$ eingesetzt werden
- 18: Es muss zusätzlich durch KDE.h geteilt werden (siehe Formel)

Aufgabe 5 Grammar of graphics

Teil A: Kritik einer Infografik.



1. Beschreiben Sie die Grafik mit den Begriffen des *Grammar of Graphics* frameworks.

→ Lösung →

- Geometrie -> Balken / Rechtecke
- Ästhetiken -> Merkmal *Prog. Language* durch Position auf x-Achse und Symbol. Die *Regular Usage Rate* wird durch die Höhe der Balken (y-Achse) dargestellt.

2. Beschreiben Sie einen Kritikpunkt an der Grafik

→ Lösung →

- Die Breite der Rechtecke ist für R, SQL, und Python höher als für die anderen Sprachen. Das führt zu einer Verzerrung der Wahrnehmung der tatsächlichen *Regular Usage Rate* - *Proportionen*

Teil B: Histogramm und Flächentreue.

Für $n = 100$ Mietwohnungen wurde die Wohnfläche (in m^2) in ungleich breite Klassen eingeteilt:

Klasse	(0, 10]	(10, 20]	(20, 40]	(40, 80]
absolute Häufigkeit n_j	20	40	30	10

3. Berechnen Sie die relativen Häufigkeiten f_j , die Klassenbreiten b_j und die korrekten Histogramm-Höhen y_j nach dem *Prinzip der Flächentreue* ($b_j \cdot y_j = f_j$). Skizzieren Sie das Histogramm.

→ Lösung →

j	Klasse	Breite b_j	Rel. Häufigkeit f_j	Höhe y_j
1	(0, 10]	10	0,2	0,0200
2	(10, 20]	10	0,4	0,0400
3	(20, 40]	20	0,3	0,0150
4	(40, 80]	40	0,1	0,0025

4. Welchen falschen Eindruck erzeugt ein Histogramm, in dem stattdessen die absoluten Häufigkeiten als Höhen abgetragen werden? Welche Klasse würde dann über-, welche unterschätzt?

→ Lösung →

Breite Klassen haben möglicherweise nur aufgrund ihrer *Breite* hohe absolute Häufigkeiten. Wenn die Klassenbreite bei der Darstellung nicht miteinbezogen wird, führt das zu einer Überschätzung von *breiten Klassen*.

5. Nennen Sie zwei weitere in der Vorlesung genannte Nachteile bzw. Fallstricke von Histogrammen und geben Sie an, welches alternative Verfahren zur Darstellung der Verteilung eines metrischen Merkmals diese Probleme abmildert.

→ Lösung →

- (a) Wenn sich Werte genau an der Klassengrenze befinden tragen sie trotzdem voll zu ihrer Klasse bei, und überhaupt nicht zu der Nachbarklasse
- (b) Die Klasseneinteilungen müssen gewählt werden
- (c) Kerndichteschätzung (KDE) als Alternative

Teil C: Grafikwahl.

Geben Sie für jede der folgenden Fragestellungen an, welche Grafik Sie wählen würden und warum (Auswahl u. a.: Säulen-/Balkendiagramm, Stapeldiagramm, Mosaikplot, Histogramm, Kerndichteschätzer, gruppierter Boxplot, Streudiagramm, Streudiagramm mit Facettierung, Dotplot):

6. Wie unterscheidet sich die Verteilung der Nettoquadratmetermiete zwischen sechs Baualterklassen?

→ Lösung →

gruppierter Boxplot

7. Besteht ein Zusammenhang zwischen Wohnfläche und Nettomiete, und unterscheidet sich dieser zwischen normaler und bester Wohnlage?

→ Lösung →

Streu mit Facettierung

8. Ist die Verteilung der Zinssätze eingipflig oder mehrgipflig?

→ Lösung →

Kerndichteschätzer

9. Wie verteilen sich die Antworten auf eine fünfstufige Zufriedenheitsskala über vier Altersgruppen hinweg?

→ Lösung →

Balkendiagramm der Zufriedenheitsstufen, gruppiert nach Alter.

`geom_bar( aes(x = Zufriedenheit, color = Alter), position = dodge )`

Aufgabe 6 Kausalität: Confounding & Simpson's Paradox

Eine Universität vergleicht zwei Kursformate in der Mathematik-Grundvorlesung (Präsenz vs. Online) hinsichtlich der Bestehensquote. Zusätzlich ist bekannt, ob die Studierenden vorher den freiwilligen Mathe-Vorkurs besucht haben.

Teilgruppe	Format	Teilnehmende	bestanden	Bestehensquote
ohne Vorkurs	Präsenz	400	200	0.5
	Online	100	45	0.45
mit Vorkurs	Präsenz	100	95	0.95
	Online	400	360	0.9

1. Berechnen Sie alle vier bedingten Bestehensquoten (also die bedingten relativen Häufigkeiten $f(\text{bestanden} \mid \text{Format}, \text{Vorkurs})$) und tragen Sie sie in die Tabelle ein. Welches Format ist *innerhalb jeder* der beiden Teilgruppen besser?

→ Lösung →

Bei fixer Teilgruppe ist Präsenz immer mit einer höheren Bestehensquote assoziiert.

2. Stellen Sie die aggregierte 2×2 -Tafel auf (Format $\times$ bestanden, über beide Teilgruppen hinweg) und berechnen Sie die beiden marginalen Bestehensquoten. Welches Format ist nun besser?

→ Lösung →

Format	bestanden	nicht bestanden	Summe (Teilnehmende)	Marginale Quote
Präsenz	295	205	500	0,59
Online	405	95	500	0,81
Summe	700	300	1000	0,70

Nun Online besser

3. Berechnen Sie das Odds Ratio „bestehen statt durchfallen, Präsenz gegen Online“

- (a) innerhalb der Gruppe *ohne* Vorkurs,

→ Lösung →

$$\text{OR} = 1,22$$

- (b) innerhalb der Gruppe *mit* Vorkurs,

→ Lösung →

$$\text{OR} = 2,11$$

- (c) auf Basis der aggregierten Tafel.

→ Lösung →

$$\text{OR} = 0,34$$

Interpretieren Sie alle drei Werte und beschreiben Sie, was mit der *Richtung* des Zusammenhangs beim Aggregieren passiert.

→ Lösung →

Bei festhalten ist das $OR > 1$, die bedingten Odds für *Bestanden vs. durchgefallen* sind in der Schicht *Präsenz* also höher als in der Schicht *Online*. Nach dem Aggregieren dreht sich dieser Zusammenhang um.

4. Wie heißt das hier beobachtete Phänomen? Erklären Sie in Stichpunkten, wodurch es *rechnerisch* zustande kommt (Hinweis: Achten Sie auf die Verteilung der Teilnehmendenzahlen über die Teilgruppen).

→ *Lösung* →

Simpson-Paradoxon. Bei fixer Teilgruppe ist Präsenz mit einer höheren Bestehensquote assoziiert. Allerdings ist die Teilgruppe *ohne Vorkurs* mit einer niedrigeren Bestehensquote assoziiert und das Format *Präsenz* ist genau in dieser Teilgruppe deutlich überrepräsentierter.

5. Zeichnen Sie die kausale Struktur mit den drei Variablen *Format*, *Bestehen* und *Vorkurs* als Pfeildiagramm. Welche Rolle spielt der Vorkurs? Wie heißt diese kausale Struktur in der Vorlesung?

→ *Lösung* →

Format -> Bestehen

Vorkurs -> Format, Bestehen

Vorkurs ist ein Confounder

6. Auf welcher Ebene – aggregiert oder nach Vorkurs getrennt – würden Sie die Ergebnisse berichten, wenn Sie eine Empfehlung für das Kursformat aussprechen sollen? Begründen Sie.

→ *Lösung* →

Confounder sollte ins Modell aufgenommen werden, um die wahre kausale Struktur zu entdecken. Daher immer bedingt auf die Teilgruppe angeben.

7. Wie müsste eine Studie angelegt sein, damit ein *kausaler* Schluss „Präsenzlehre erhöht die Bestehenswahrscheinlichkeit“ zulässig wäre? Beziehen Sie sich auf die in der Vorlesung besprochenen Erhebungsarten.

→ *Lösung* →

Randomisiertes Experiment