

GOP Bootcamp 2026

Woche 3 · Mehrdimensionale Verteilungen, Transformationen & Faltungen

Tag 1

Gemeinsame, marginale und bedingte
Verteilungen · Abhängigkeit ·
Kovarianzmatrizen

Tag 2

Dichtetransformationen · Faltungen

Tag 3

GOP-nahe Aufgabenblöcke analysieren,
rechnen und besprechen

Die Farbe eines Kastens sagt, was darin steht

Definition

Satz, Definition, Formel.
Die Grundlage, auf die sich
alles andere beruft.

z. B. die Faltungsformel

Beispiel

Einordnung, Herleitung,
durchgerechnete Aufgabe.
Hier steht, *warum* etwas
gilt.

z. B. jeder Kasten
„Durchgerechnet“

Rezept

Was zu tun ist: Rechenweg,
Klausurstrategie, Kontrolle.

z. B. „Vier Schritte für jede
Aufgabe“

Achtung

Typischer Fehler oder
Einschränkung. Genau hier
gehen Punkte verloren.

z. B. $f_Y(x)$ statt $f_Y(z-x)$

Neutral

Nur ein Rahmen, ohne
Wertung: Tabellen, Zahlen,
interaktive Grafiken.

z. B. die Widgets an Tag 2

In den Grafiken bedeutet Farbe etwas anderes

Dort steht sie nicht für die Art des Kastens, sondern für die Rolle einer Größe –
und zwar in allen Widgets gleich:

■ X ■ Y ■ Ergebnis Z ■ die Stelle, die gerade eingestellt ist

Vertiefung erkennt man am Chip

Steht oben auf einer Folie **ZUSATZ**, ist sie Vertiefung: laut Altklausur-Analyse
nicht klausurkritisch. Verstehen lohnt sich, üben muss man es nicht.

Faustregel beim Lesen: Definiert der Kasten etwas → **grün**. Erklärt oder illustriert er → **blau**. Sagt er, was zu tun ist → **amber**.
Warnt er → **rot**. Nichts davon → **grau**.

Sonst wird Farbe nirgends dekorativ eingesetzt: Ist etwas farbig, hat das eine Bedeutung.

Mehrdimensionale Verteilungen, Bedingungen & Abhängigkeit

- Eine gemeinsame Verteilung aus Tabelle oder Dichte lesen: Ränder, Bedingungen, Unabhängigkeit
- Mit zwei Zufallsvariablen rechnen: $E[g(X, Y)]$, $E(XY)$, $\text{Var}(X + Y)$ und die Regeln für Kovarianzen
- Bedingt rechnen und die beiden Zerlegungssätze anwenden: iterierter Erwartungswert und totale Varianz
- Kovarianzmatrizen auf Gültigkeit prüfen und die Brücke zur empirischen Statistik aus Woche 1 schlagen

Grundlage: Statistik 1, Kapitel 9, Folien 457–475 und 483–499; Statistik 2, Kapitel 11–13.

Mehrdimensionale Verteilungen beschreiben mehrere Größen gleichzeitig

Zufallsvektor

$$\mathbf{X} = (X_1, \dots, X_d)^\top$$

Beispiel

Bei derselben Person messen wir Lernstunden X_1 und GOP-Punkte X_2 . Erst das Paar (X_1, X_2) zeigt, welche Werte gemeinsam auftreten.

Gemeinsame Verteilungsfunktion

$$F_{\mathbf{X}}(x_1, \dots, x_d) = P(X_1 \leq x_1, \dots, X_d \leq x_d)$$

Für $d = 2$ schreibt man üblicherweise $F_{X,Y}(x,y)$.

Marginale Verteilung · Randverteilung

Die Verteilung einer einzelnen Komponente oder eines Teilvektors. Alle übrigen Komponenten werden aus der gemeinsamen Verteilung herausgerechnet.

$$F_{X_j}(x_j), \quad p_{X_j}(x_j) \text{ oder } f_{X_j}(x_j)$$

Für $d > 2$ ist beispielsweise auch $F_{X_i, X_j}(x_i, x_j)$ eine marginale Verteilungsfunktion.

Conditionale Verteilung · bedingte Verteilung

Die Verteilung einiger Komponenten, nachdem die übrigen festgehalten wurden.

$$\begin{aligned} F_{X_1 | X_2}(x_1 | x_2) &= P(X_1 \leq x_1 | X_2 = x_2) \\ F_{X_1, \dots, X_k | X_{k+1}, \dots, X_d}(x_1, \dots, x_k | x_{k+1}, \dots, x_d) \\ &= P(X_1 \leq x_1, \dots, X_k \leq x_k | X_{k+1} = x_{k+1}, \dots, X_d = x_d) \end{aligned}$$

Wichtiger Unterschied

Die Randverteilungen allein bestimmen die gemeinsame Verteilung nicht. Dieselben Ränder können mit positiver, keiner oder negativer Abhängigkeit kombiniert werden.

Eine gemeinsame Tabelle enthält Ränder und Bedingungen

WERTE	X=0	X=1	X=2	P_Y(Y)
Y=0	0,100	0,130	0,020	0,25
Y=1	0,070	0,200	0,130	0,40
Y=2	0,080	0,070	0,200	0,35
p_X(x)	0,25	0,40	0,35	1,00

p(x,y)



Abhängigkeit positiv ↕

Ansicht gemeinsam ↕

Drei Fragen an dieselbe Tabelle


Gemeinsam: Welche Wahrscheinlichkeit hat ein Wertepaar?

Marginal: Was bleibt nach dem Summieren über die andere Variable?

Bedingt: Wie verteilt sich eine ausgewählte Zeile nach erneuter Normierung?

Beobachtung: Beim Wechsel der Abhängigkeit bleiben die Summenränder gleich – nur die Masse innerhalb der Tabelle wandert.

Eine gemeinsame Dichte enthält Ränder und Bedingungen



Abhängigkeit positiv

Ansicht gemeinsam

$$P(\mathbf{X} \in A) = \int_A f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}$$

Die Punktwolke zeigt simulierte Paare. Beim Wechsel der Abhängigkeit bleiben beide grünen Randdichten Exp(1).

Dichtehöhe ist keine Wahrscheinlichkeit. Erst die Integration über eine Fläche liefert Wahrscheinlichkeit.

Information über Y darf X nicht verändern

Diskrete Zufallsvariablen

$$X \perp Y \iff P(X = x, Y = y) = P(X = x)P(Y = y)$$

für alle möglichen x, y

Stetige Zufallsvariablen

$$X \perp Y \iff f_{X,Y}(x, y) = f_X(x)f_Y(y)$$

für fast alle x, y

Äquivalent über Bedingungen

$$P(X = x \mid Y = y) = P(X = x) \quad (\text{diskret})$$

$$f_{X|Y}(x \mid y) = f_X(x) \quad (\text{stetig})$$

Diskret prüfen: Tabelle

1. Ränder berechnen.
2. Für jede Zelle $p_{X,Y}(x_i, y_j) = p_X(x_i)p_Y(y_j)$ prüfen.

Ein einziges Gegenbeispiel genügt. Besonders schnell geht es über eine **Nullzelle**: Sind $p_X(x) > 0$ und $p_Y(y) > 0$, aber $p_{X,Y}(x, y) = 0$, ist Unabhängigkeit sofort widerlegt.

Stetig prüfen: zuerst der Träger

Die Faktorisierung muss für **alle** (x, y) gelten – also muss der Träger ein Rechteck sein:

$$T_{X,Y} = T_X \times T_Y$$

Hängt eine Grenze von der anderen Variablen ab, ist Unabhängigkeit ausgeschlossen. Beispiel: $f_{X,Y}(x, y) = 8xy \mathbb{I}_{\{0 < x < y < 1\}}(x, y)$ sieht faktorisiert aus, der Träger ist aber ein Dreieck: Weiß man $X = 0,9$, muss $Y > 0,9$ sein – **also abhängig**.

Die Randdichten sind hier $f_X(x) = 4x(1 - x^2)$ und $f_Y(y) = 4y^3$; ihr Produkt ist nicht $8xy$.

Gemeinsam normalverteilt

$$\rho_{X,Y} = 0 \iff X \perp Y$$

Nur in diesem Spezialfall. Allgemein folgt aus $\rho = 0$ keine Unabhängigkeit.

Ein Satz für jede Funktion von X und Y

Transformationssatz in zwei Dimensionen

$$E[g(X, Y)] = \sum_x \sum_y g(x, y) p_{X,Y}(x, y)$$

$$E[g(X, Y)] = \iint g(x, y) f_{X,Y}(x, y) dx dy$$

Man braucht die Verteilung von $g(X, Y)$ **nicht**. Es genügt, die Funktionswerte mit der gemeinsamen Verteilung zu gewichten. Für $g(x, y) = x$ entsteht daraus wieder $E(X)$, für $g(x, y) = xy$ der Ausdruck $E(XY)$.

Linearität – gilt immer

$$E(aX + bY + c) = aE(X) + bE(Y) + c$$

Ohne jede Voraussetzung: keine Unabhängigkeit, keine Unkorreliertheit. Das unterscheidet den Erwartungswert von der Varianz.

Das Produkt – nur bei Unabhängigkeit

$$X \perp Y \implies E(XY) = E(X)E(Y)$$

Die Umkehrung gilt nicht: Aus $E(XY) = E(X)E(Y)$ folgt nur Unkorreliertheit.

Durchgerechnet · diese Tabelle begleitet den ganzen Block

$p_{X,Y}(x, y)$	Y=0	Y=1	p_X
X=0	0,4	0,1	0,5
X=1	0,2	0,3	0,5
p_Y	0,6	0,4	1

Ränder ablesen: $X \sim \text{Bernoulli}(0,5)$, $Y \sim \text{Bernoulli}(0,4)$.

Die drei Erwartungswerte

$$E(X) = 0,5, \quad E(Y) = 0,4$$

$$E(XY) = \sum_x \sum_y xy p_{X,Y}(x, y) = 1 \cdot 1 \cdot 0,3 = 0,3$$

Nur das Paar (1, 1) hat einen Beitrag ungleich null – bei 0/1-Variablen ist $E(XY) = P(X = 1, Y = 1)$.

Und schon sieht man die Abhängigkeit

$E(X)E(Y) = 0,5 \cdot 0,4 = 0,2$, aber $E(XY) = 0,3$. Die Produktregel gilt hier also **nicht** – X und Y sind abhängig. Die Differenz $0,3 - 0,2 = 0,1$ ist genau die Kovarianz.

Varianzen addieren sich nur, wenn die Kovarianz null ist

Kovarianz

$$\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))] = E(XY) - E(X)E(Y)$$

Die rechte Form ist der Verschiebungssatz und in der Klausur fast immer der schnellere Weg.

Varianz einer Summe und einer Differenz

$$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y)$$

$$\text{Var}(X - Y) = \text{Var}(X) + \text{Var}(Y) - 2 \text{Cov}(X, Y)$$

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{Cov}(X, Y)$$

Auch bei der Differenz werden die Varianzen **addiert** – nur das Vorzeichen vor der Kovarianz dreht sich.

Rechenregeln für die Kovarianz

Symmetrie	$\text{Cov}(X, Y) = \text{Cov}(Y, X)$
mit sich selbst	$\text{Cov}(X, X) = \text{Var}(X)$
Verschiebung	$\text{Cov}(X + a, Y + b) = \text{Cov}(X, Y)$
Skalierung	$\text{Cov}(aX, bY) = ab \text{Cov}(X, Y)$
Bilinearität	$\text{Cov}(X + Y, Z) = \text{Cov}(X, Z) + \text{Cov}(Y, Z)$
Konstante	$\text{Cov}(X, c) = 0$

Verschieben ändert nichts, Skalieren zieht als Faktor heraus – deshalb ist die Korrelation unter affinen Transformationen invariant, bis auf das Vorzeichen von ac .

Der häufigste Fehler im ganzen Kapitel

$\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y)$ ist **kein** Naturgesetz, sondern braucht $\text{Cov}(X, Y) = 0$. Unabhängigkeit reicht dafür, ist aber nicht nötig – Unkorreliertheit genügt. Und $\text{Var}(X - Y)$ ist niemals $\text{Var}(X) - \text{Var}(Y)$.

Durchgerechnet · dieselbe Tabelle wie eben

$$\text{Var}(X) = 0,5 - 0,25 = 0,25, \quad \text{Var}(Y) = 0,4 - 0,16 = 0,24$$

$$\text{Cov}(X, Y) = 0,3 - 0,2 = 0,1, \quad \text{Corr}(X, Y) \approx 0,41$$

$$\text{Var}(X + Y) = 0,25 + 0,24 + 2 \cdot 0,1 = 0,69$$

Bei 0/1-Variablen ist $E(X^2) = E(X)$ – das spart jeweils einen Rechenschritt.

Gegenprobe über die Verteilung von $Z = X + Y$

z	0	1	2
$p_Z(z)$	0,4	0,3	0,3

$$E(Z) = 0,9, \quad E(Z^2) = 1,5, \quad \text{Var}(Z) = 1,5 - 0,81 = 0,69 \checkmark$$

Beide Wege führen zum selben Wert – aber die Regel spart die komplette Herleitung der Verteilung von Z . Genau dafür lernt man sie.

Bedingt rechnen: erst normieren, dann wie gewohnt

Bedingter Erwartungswert

$$E_{Y|X=x}(Y) = \sum_y y p_{Y|X}(y|x)$$

$$E_{Y|X=x}(Y) = \int_{-\infty}^{\infty} y f_{Y|X}(y|x) dy$$

Zwei Schritte, immer dieselben: erst die bedingte Verteilung bilden (also die Zeile neu auf Summe bzw. Fläche eins normieren), dann ganz normal den Erwartungswert berechnen.

Bedingte Varianz

$$\text{Var}_{Y|X=x}(Y) = E_{Y|X=x}(Y^2) - (E_{Y|X=x}(Y))^2$$

Der Verschiebungssatz gilt auch bedingt – es ist dieselbe Rechnung, nur in der bedingten statt in der gemeinsamen Verteilung.

Der Index sagt, worüber gemittelt wird

$E_{Y|X=x}$ mittelt über die **bedingte** Verteilung von Y bei festem x , E_X über die **Randverteilung** von X , $E_{X,Y}$ über die **gemeinsame** Verteilung. In Vorlesung und Klausur steht meist nur E ; dann muss man aus dem Argument erschließen, welche Verteilung gemeint ist. Hier schreiben wir den Index aus – ohne ihn sind die beiden Sätze auf der nächsten Folie kaum eindeutig lesbar.

Durchgerechnet · dieselbe Tabelle

Bedingen auf $X = 0$ heißt: Zeile $X = 0$ durch ihre Summe 0,5 teilen.

$$p_{Y|X}(0|0) = \frac{0,4}{0,5} = 0,8, \quad p_{Y|X}(1|0) = 0,2$$

Also $Y|X=0 \sim \text{Bernoulli}(0,2)$ und genauso $Y|X=1 \sim \text{Bernoulli}(0,6)$:

x	$E_{Y X=x}(Y)$	$\text{Var}_{Y X=x}(Y)$
0	0,2	$0,2 \cdot 0,8 = 0,16$
1	0,6	$0,6 \cdot 0,4 = 0,24$

Das Wissen über X verschiebt die Erwartung an Y von 0,2 auf 0,6. Genau das ist Abhängigkeit – bei Unabhängigkeit stünde beide Male $E_Y(Y) = 0,4$.

Zahl oder Zufallsvariable?

$E_{Y|X=x}(Y)$ ist für festes x eine **Zahl**. Lässt man x laufen, entsteht die Funktion $g(x) = E_{Y|X=x}(Y)$ und daraus die **Zufallsvariable** $E_{Y|X}(Y) = g(X)$ – sie hängt über X vom Zufall ab. Auf dieser Unterscheidung beruht die ganze nächste Folie.

Zwei Spezialfälle

$$X \perp Y \implies E_{Y|X=x}(Y) = E_Y(Y)$$

$$\text{bivariat normal: } E_{X_1|X_2=x_2}(X_1) = \mu_1 + \rho \frac{\sigma_1}{\sigma_2}(x_2 - \mu_2)$$

Der zweite Fall ist die Gerade auf der Folie zur bivariaten Normalverteilung: die bedingte Mitte hängt linear von x_2 ab, die bedingte Varianz gar nicht.

Iterierter Erwartungswert und totale Varianz

Satz vom iterierten Erwartungswert (Turmregel)

$$E_Y(Y) = E_X[E_{Y|X}(Y)]$$

$$\text{diskret: } E_Y(Y) = \sum_x E_{Y|X=x}(Y) p_X(x)$$

Innen wird über Y gemittelt, bei festgehaltenem x . **Außen** wird über X gemittelt, also über alle möglichen Bedingungen. Zusammen ergibt das den Erwartungswert von Y in seiner Randverteilung.

Satz der totalen Varianz (Varianzzerlegung)

$$\text{Var}_Y(Y) = E_X[\text{Var}_{Y|X}(Y)] + \text{Var}_X[E_{Y|X}(Y)]$$

Erster Summand: die **mittlere Streuung innerhalb** der durch X definierten Gruppen – der von X nicht erklärte Rest.

Zweiter Summand: die **Streuung der Gruppenmittel** – der durch X erklärte Anteil.

Wozu man das braucht

Beide Sätze zerlegen eine Größe der gemeinsamen Verteilung in eine innere und eine äußere Rechnung. Allgemein gilt

$$E_{X,Y}[g(X, Y)] = E_X[E_{Y|X}(g(X, Y))].$$

Immer wenn eine Aufgabe zweistufig formuliert ist – „zuerst wird X gezogen, dann hängt Y davon ab“ –, ist die bedingte Verteilung bekannt und die gemeinsame nicht. Dann rechnet man von innen nach außen, statt die gemeinsame Verteilung erst herzuleiten.

Durchgerechnet · Turmregel

$$E_X[E_{Y|X}(Y)] = 0,2 \cdot 0,5 + 0,6 \cdot 0,5 = 0,4 = E_Y(Y) \checkmark$$

Durchgerechnet · totale Varianz

$$E_X[\text{Var}_{Y|X}(Y)] = 0,16 \cdot 0,5 + 0,24 \cdot 0,5 = 0,20$$

$$\text{Var}_X[E_{Y|X}(Y)] = 0,5(0,2 - 0,4)^2 + 0,5(0,6 - 0,4)^2 = 0,04$$

$$0,20 + 0,04 = 0,24 = \text{Var}_Y(Y) \checkmark$$

Von der Gesamtstreuung 0,24 entfallen 0,04 auf den Zusammenhang mit X – ein Sechstel.

Zwei typische Fehler

Varianzen dürfen **nicht** einfach gemittelt werden: $\text{Var}_Y(Y) \neq E_X[\text{Var}_{Y|X}(Y)]$. Ohne den zweiten Summanden kommt man immer zu klein heraus.

Bei Unabhängigkeit ist $E_{Y|X}(Y) = E_Y(Y)$ konstant, der zweite Summand also null. Dafür reicht aber schon, dass die bedingte Mitte nicht von x abhängt – Unabhängigkeit ist nicht nötig.

Brücke zu Woche 1

Das ist dieselbe Idee wie die **Streuungszerlegung** der deskriptiven Statistik: Gesamtstreuung = Streuung innerhalb der Gruppen + Streuung zwischen den Gruppen. Dort sind die Gruppen die Ausprägungen eines Merkmals, hier die Werte von X .

Vor jeder Rechnung: Ist das überhaupt eine Kovarianzmatrix?

Die beiden Maßzahlen

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$$

$$\rho_{X,Y} = \text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}}$$

Die Kovarianz hängt von den Einheiten ab, ρ nicht: $\rho \in [-1, 1]$. Und $|\rho| = 1$ gilt genau dann, wenn Y fast sicher eine affine Funktion von X ist.

Kovarianzmatrix

$$\Sigma = \text{Cov}(\mathbf{X}) = E[(\mathbf{X} - E(\mathbf{X}))(\mathbf{X} - E(\mathbf{X}))^T]$$

$$\Sigma_{ij} = \text{Cov}(X_i, X_j), \quad \Sigma_{ii} = \text{Var}(X_i)$$

$$\Sigma = \begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) \\ \text{Cov}(X_1, X_2) & \text{Var}(X_2) \end{pmatrix}$$

Auf der Diagonale stehen **Varianzen**, nicht Standardabweichungen.

Lineare Transformation

$$E(\mathbf{A}\mathbf{X} + \mathbf{b}) = \mathbf{A}E(\mathbf{X}) + \mathbf{b}$$

$$\text{Cov}(\mathbf{A}\mathbf{X} + \mathbf{b}) = \mathbf{A}\Sigma\mathbf{A}^T$$

Der Verschiebungsvektor $\mathbf{b}$ fällt heraus – das ist die Matrixversion von $\text{Cov}(X + a, Y + b) = \text{Cov}(X, Y)$.

Prüfschema in drei Schritten

- 1. Quadratisch und symmetrisch?** $\Sigma_{ij} = \Sigma_{ji}$. Ein einziger schiefer Eintrag reicht zum Ausschluss.
- 2. Diagonale nichtnegativ?** Dort stehen Varianzen, also $\Sigma_{ii} \geq 0$.
- 3. Positiv semidefinit?** Im 2×2 -Fall genügt $\det \Sigma \geq 0$. Allgemein: alle Eigenwerte ≥ 0 bzw. alle führenden Hauptminoren ≥ 0 .

In dieser Reihenfolge abarbeiten – Schritt 1 und 2 sind Sekunden und erledigen die meisten Aufgaben schon.

Die schnelle Widerlegung

Für jedes Paar muss gelten:

$$|\text{Cov}(X_i, X_j)| \leq \sqrt{\text{Var}(X_i) \text{Var}(X_j)}$$

Das ist die Cauchy-Schwarz-Ungleichung und im 2×2 -Fall äquivalent zu $\det \Sigma \geq 0$. Gleichwertig: $|\rho_{ij}| \leq 1$. Mit dieser einen Ungleichung lässt sich fast jede Klausuraufgabe dieses Typs entscheiden.

Durchgerechnet

Für welche $a \in \mathbb{R}$ ist

$$\Sigma(a) = \begin{pmatrix} 4 & a \\ a & 9 \end{pmatrix}$$

eine Kovarianzmatrix?

1. symmetrisch für jedes a ✓
2. $4 \geq 0$ und $9 \geq 0$ ✓
3. Determinante:

$$\det \Sigma(a) = 36 - a^2 \geq 0 \iff |a| \leq 6$$

Dasselbe über die Schranke: $|a| \leq \sqrt{4 \cdot 9} = 6$. Für $|a| = 6$ ist $\rho = \pm 1$, X_2 also eine affine Funktion von X_1 .

Zwei Gegenbeispiele

$$\begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix} \quad \det = -3 < 0$$

Symmetrisch und mit positiver Diagonale – trotzdem keine Kovarianzmatrix. Schritt 3 ist nicht optional.

$$\begin{pmatrix} 1 & 0,5 \\ 0,4 & 1 \end{pmatrix} \quad \text{nicht symmetrisch}$$

Hier reicht schon Schritt 1.

Dieselbe Idee – einmal aus Daten, einmal aus dem Modell

	WOCHE 1 · EMPIRISCH, AUS DATEN $x_1, \dots, x_n$	WOCHE 3 · THEORETISCH, AUS DEM MODELL
Lage	$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$	$E(X) = \sum_x x p(x)$ bzw. $\int x f(x) dx$
Streuung	$S_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$	$\text{Var}(X) = E[(X - E(X))^2]$
Zusammenhang	$S_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$	$\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))]$
normiert	$r_{xy} = \frac{S_{xy}}{S_x S_y} \in [-1, 1]$	$\rho_{X,Y} = \frac{\text{Cov}(X,Y)}{\sigma_X \sigma_Y} \in [-1, 1]$
als Matrix	empirische Kovarianzmatrix S	$\Sigma = \text{Cov}(\mathbf{X})$

Was gleich bleibt

Beide messen ausschließlich **lineare** Zusammenhänge, beide reagieren empfindlich auf Ausreißer, beide sind normiert auf $[-1, 1]$ – und aus beiden folgt **keine Kausalität**. Auch die Rechenregeln sind dieselben: Verschieben ändert nichts, Skalieren zieht als Faktor heraus.

Was verschieden ist

$\bar{x}$, S_{xy} und r_{xy} sind **Kennzahlen einer Stichprobe** – andere Daten, andere Werte. $E(X)$, $\text{Cov}(X, Y)$ und ρ sind **feste Größen eines Modells**. r_{xy} schätzt ρ , ist aber nicht ρ .

Woran man es in der Klausur erkennt

Steht in der Aufgabe eine **Datentabelle** oder ein Streudiagramm, ist r_{xy} gemeint. Steht dort eine **Verteilung** – Tabelle mit Wahrscheinlichkeiten, Dichte, Kovarianzmatrix –, ist ρ gemeint. Spearman und Kendall aus Woche 1 haben hier kein Gegenstück: Das sind Rangmaße, ρ ist ein Momentenmaß.

Eigenwerte, Korrelations- und Precision-Matrix

Struktur Heatmaps für Korrelations- und Precision-Matrix, dazu die Streuungsellipsen der drei Paare.


R = Korrelationsmatrix

	X1	X2	X3
X1	1,00	0,60	0,30
X2	0,60	1,00	0,50
X3	0,30	0,50	1,00
	X1	X2	X3

Ω = R⁻¹


	X1	X2	X3
X1	1,56	-0,94	0
X2	-0,94	1,90	-0,67
X3	0	-0,67	1,33
	X1	X2	X3

(X1,X2)




ρ = 0,60

(X1,X3)



ρ = 0,30

(X2,X3)



ρ = 0,50

Ω₁₃ = 0: X₁ und X₃ sind gegeben X₂ unabhängig.

Korrelationsmatrix

$$\mathbf{R} = \mathbf{D}_{\Sigma}^{-1/2} \Sigma \mathbf{D}_{\Sigma}^{-1/2}$$

mit $\mathbf{D}_{\Sigma}^{-1/2} = \text{diag}(\Sigma_{11}^{-1/2}, \dots, \Sigma_{dd}^{-1/2})$. Dann ist $R_{ij} = \rho_{ij}$ und $R_{ii} = 1$ – die einheitenfreie Version von Σ .

Orthogonale Diagonalisierung

$$\Sigma = \mathbf{Q} \Lambda \mathbf{Q}^T, \quad \mathbf{Q}^T \mathbf{Q} = \mathbf{I}$$

Die Eigenvektoren q_i geben die Hauptstreuungsrichtungen an, die Eigenwerte λ_i die Varianz in diese Richtung. Die Halbachsen der Dichteellipse sind proportional zu $\sqrt{\lambda_i}$. Alle $\lambda_i \geq 0$ ist genau Schritt 3 des Prüfschemas.

Precision-Matrix und Blöcke

$$\Omega = \Sigma^{-1}, \quad \Omega_{ij} = 0 \iff X_i \perp X_j \mid \mathbf{X}_{-(i,j)}$$


$$\text{Cov}(\mathbf{X}_1 \mid \mathbf{X}_2 = \mathbf{a}) = \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$$

Beides nur für $\mathbf{X} \sim \mathcal{N}_n(E(\mathbf{X}), \Sigma)$.

Einordnung: Diese Folie ist Vertiefung. In den fünf ausgewerteten GOPs wurde nie ein Eigenwert einer Kovarianzmatrix berechnet – geprüft wurde die Gültigkeit einer Matrix, $\text{Cov}(\mathbf{A}\mathbf{X} + \mathbf{b}) = \mathbf{A}\Sigma\mathbf{A}^T$ und die bedingte Verteilung im bivariaten Normalfall. Genau das steht auf den beiden Nachbarfolien.

Quelle: Wikipedia, „Multivariate normal distribution“, Abschnitt „Conditional distributions“.

Hier verbindet ρ Konturen, Bedingungen und Unabhängigkeit



Ansicht gemeinsam ρ 0,50

$\text{Var}(X_1)$ 1,00

Bivariate Normalverteilung

$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim \mathcal{N}_2 \left(\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} v_1 & \rho\sqrt{v_1} \\ \rho\sqrt{v_1} & 1 \end{pmatrix} \right)$$

Aktuell: $\Sigma = [[1,00, 0,50], [0,50, 1,00]]$

$$X_1 | X_2 = x_2 \sim \mathcal{N}(\rho\sqrt{v_1} x_2, v_1(1 - \rho^2))$$

Die bedingte Mitte folgt $x_1 = \rho\sqrt{v_1} x_2$, die bedingte Varianz ist $v_1(1 - \rho^2)$. X_2 bleibt standardnormal; X_1 hat Varianz v_1 .

$\rho = 0 \iff X_1 \perp X_2$ (gemeinsam normal)

Dichtetransformationen & Faltungen

- Von der CDF-Transformation zum Jacobi-Faktor
- Bijektiv und stückweise bijektiv sicher unterscheiden – besonders, wenn der Träger einen Ast abschneidet
- Faltung als gewichteten Mittelwert, Diagonalschnitt und Klausurrezept verstehen
- Minimum und Maximum unabhängiger Zufallsvariablen über die Verteilungsfunktion bestimmen

Grundlage: Statistik 1, Folien 442–456 und 476–482; Statistik 2, Folien 473–497 und 574–576.

Wahrscheinlichkeit bleibt – ihr Ort verändert sich

$$Y = g(X)$$

$$P(Y \in A) = P(X \in g^{-1}(A))$$

Das ist Integration durch Substitution

$$\int_A f_Y(y) dy = \int_A f_X(g^{-1}(y)) |(g^{-1})'(y)| dy = \int_{g^{-1}(A)} f_X(x) dx$$

Warum daraus die Integralform folgt: Ist $F' = f$, dann macht die Kettenregel den Integranden zu einer Ableitung. Der Hauptsatz liefert direkt

$$\int_a^b f(g(x))g'(x) dx = \int_a^b (F \circ g)'(x) dx = F(g(b)) - F(g(a)) = \int_{g(a)}^{g(b)} f(u) du$$


Anwendung in der Wahrscheinlichkeit: Setze $x = g^{-1}(y)$. Dann wird

$$dx = |(g^{-1})'(y)| dy.$$

Dieselbe Wahrscheinlichkeit wird nur in anderen Koordinaten integriert. Mehrdimensional gilt entsprechend $d\mathbf{x} = |\det J_{g^{-1}}(\mathbf{y})| d\mathbf{y}$.

Nicht unnötig transformieren: Ist nur $E[g(X)]$ oder $\text{Var}(g(X))$ gefragt, ist die Dichte von $Y = g(X)$ meistens Overkill. Nutze direkt $E[g(X)] = \int g(x)f_X(x) dx$ und $\text{Var}(g(X)) = E[g(X)^2] - E[g(X)]^2$.

So verändern Transformationen Verteilungsfunktion und Dichte

Verteilung von X Transformation

Verteilungsfunktion

Dichte

x

$$F_Y(g(x)) = F_X(x) = 0,739$$

Wachsend: Aus $g(X) \leq g(x)$ wird $X \leq x$; dieselbe Wahrscheinlichkeit erscheint an einer neuen Stelle.

Darstellung nach Statistik I, PDF-Seite 467 / Folie 446.

Die inverse Ableitung korrigiert Strecken und Stauchen

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|$$

Ein x -Intervall wird durch g gestreckt (gestaucht): Dieselbe Masse verteilt sich über mehr (weniger) y -Länge, also sinkt (steigt) die Dichte.

Der Betrag ist unverzichtbar: Eine fallende Transformation spiegelt die Achse, aber eine Dichte kann nicht negativ werden.


Rezept für bijektives g

1. Inverse bestimmen: $y = g(x)$ nach $x = g^{-1}(y)$ umformen.
2. $(g^{-1})'(y)$ bestimmen.
3. In die Formel einsetzen und vereinfachen.
4. Träger anpassen: $T_Y = g(T_X)$.

Typische Beispiele

$Y = aX + b$	$f_Y(y) = \frac{1}{ a } f_X\left(\frac{y-b}{a}\right)$
$Y = e^X$	$f_Y(y) = \frac{1}{y} f_X(\log y), y > 0$
$Y = \log X$	$f_Y(y) = e^y f_X(e^y), X > 0$
$Y = 1/X$	$f_Y(y) = \frac{1}{y^2} f_X(1/y), X > 0$
$Y = X^2$	$f_Y(y) = \frac{f_X(\sqrt{y})}{2\sqrt{y}}, X > 0$

Bei $Y = X^2$ liefern zwei Urbilder Masse zum selben y



y 1,20

$$g^{-1}(y) = \{-\sqrt{y}, +\sqrt{y}\}$$

$$f_Y(y) = \frac{f_X(\sqrt{y}) + f_X(-\sqrt{y})}{2\sqrt{y}}$$

Zerlege den Träger in G_- und G_+ , auf denen x^2 jeweils bijektiv ist. Berechne beide Beiträge und addiere sie.

Diese Formel ist ein Spezialfall

Sie setzt voraus, dass **beide** Wurzeln im Träger von X liegen – hier gilt $T_X = \mathbb{R}$. Ist der Träger nicht symmetrisch, fällt für manche y ein Ast weg und der Vorfaktor ändert sich. Genau das steht zwei Folien weiter.

Jedes reguläre Urbild trägt einen Dichteanteil bei

Über alle Urbilder

$$f_Y(y) = \sum_{x \in g^{-1}(\{y\})} \frac{f_X(x)}{|g'(x)|}$$

Gültig für endlich viele reguläre Urbilder mit $g'(x) \neq 0$.

Über bijektive Teilbereiche

$$T_X = \bigcup_{i=1}^k T_{X,i}, \quad g_i := g|_{T_{X,i}}$$

Auf jedem $T_{X,i}$ ist g_i bijektiv. Der Beitrag des i -ten Astes ist

$$f_{Y,i}(y) = f_X(g_i^{-1}(y)) |(g_i^{-1})'(y)|, \quad y \in g_i(T_{X,i}).$$

$$f_Y(y) = \sum_{i: y \in g_i(T_{X,i})} f_{Y,i}(y).$$

Warum beide Formeln gleich sind


Auf jedem Teilbereich ist g_i bijektiv. Für $x_i = g_i^{-1}(y)$ gilt nach dem Satz über die Ableitung der Umkehrfunktion

$$(g_i^{-1})'(y) = \frac{1}{g'(g_i^{-1}(y))} = \frac{1}{g'(x_i)}.$$

Praktischer Weg

1. Träger in bijektive Bereiche zerlegen.
2. Pro Bereich die bekannte bijektive Formel anwenden.
3. Nur gültige Urbilder im jeweiligen Träger behalten.
4. Alle Astbeiträge addieren.

Wenn der Träger endet, fällt ein Ast weg



Zwei Kontrollen, die immer gehen

$$\int_0^1 \frac{dy}{3\sqrt{y}} = \frac{2}{3}, \quad \int_1^4 \frac{dy}{6\sqrt{y}} = \frac{1}{3}$$

$$P(Y \leq 1) = P(-1 \leq X \leq 1) = \frac{2}{3} \checkmark$$

Fläche eins – und das Ergebnis stimmt mit der direkten Rechnung über X überein. Immer gegenrechnen, das deckt vergessene Äste sofort auf.

Aufgabe

$$X \sim U(-2, 1), \quad f_X(x) = \frac{1}{3} \mathbb{I}_{(-2, 1)}(x), \quad Y = X^2$$

Der Träger ist $T_Y = g(T_X) = (0, 4)$: Er reicht bis 4, weil $(-2)^2 = 4$ der größte erreichbare Wert ist – und eben nicht nur bis 1.

Urbilder je nach y

$0 < y < 1$	$-\sqrt{y}$ und $+\sqrt{y}$ liegen beide in $(-2, 1)$	zwei Äste
$1 < y < 4$	nur $-\sqrt{y}$ liegt in $(-2, 1)$, denn $+\sqrt{y} > 1$	ein Ast

Allgemeine Formel anwenden

$$f_Y(y) = \sum_{x \in g^{-1}(\{y\}) \cap T_X} \frac{f_X(x)}{|g'(x)|}$$


$$|g'(x)| = 2|x| = 2\sqrt{y}$$

$$f_Y(y) = \begin{cases} 2 \cdot \frac{1/3}{2\sqrt{y}} = \frac{1}{3\sqrt{y}} & 0 < y < 1 \\ 1 \cdot \frac{1/3}{2\sqrt{y}} = \frac{1}{6\sqrt{y}} & 1 < y < 4 \\ 0 & \text{sonst} \end{cases}$$

Der Vorfaktor ist die **Anzahl der gültigen Urbilder**. Bei $y = 1$ springt f_Y deshalb von $1/3$ auf $1/6$.

Die Jacobi-Determinante misst den Flächenfaktor


x-Raum: ursprüngliches Flächenelement



Fläche = 1 · Dichte = 1

y-Raum: transformiertes Flächenelement

$$A = \begin{bmatrix} 1,30 & 0,45 \\ 0 & 0,80 \end{bmatrix}$$



Fläche = $|\det A| = 1,04$
Dichte = $1/|\det A| = 0,96$

x-Skalierung 1,30

y-Skalierung 0,80

Scherung 0,45

Die **25 Punkte** tragen vor und nach der Transformation dieselbe Masse. Die Fläche wird mit **1,040** multipliziert; deshalb wird die Dichte durch **1,040** geteilt.

$$f_Y(\mathbf{y}) = f_X(g^{-1}(\mathbf{y})) |\det J_{g^{-1}}(\mathbf{y})|$$

Die Ableitung aus 1D wird in 2D zur Jacobi-Matrix. Ihre Determinante fasst die Streckung in allen Richtungen zum lokalen Flächenfaktor zusammen:
 $d\mathbf{y} \approx |\det J_g(\mathbf{x})| d\mathbf{x}$. Weil die Wahrscheinlichkeit gleich bleibt, wird die Dichte invers korrigiert.

In d Dimensionen misst die Determinante das Volumen

Bijektiv

$$f_Y(\mathbf{y}) = f_X(g^{-1}(\mathbf{y})) |\det J_{g^{-1}}(\mathbf{y})|$$

Genau die Struktur aus 1D: Aus der Ableitung wird die Jacobi-Matrix, aus dem Betrag der Determinante.

Mehrere Äste

$$T_X = \bigcup_m T_{X,m}, \quad g_m = g|_{T_{X,m}}$$

$$f_Y(\mathbf{y}) = \sum_m f_X(g_m^{-1}(\mathbf{y})) |\det J_{g_m^{-1}}(\mathbf{y})| \mathbb{1}_{g_m(T_{X,m})}(\mathbf{y})$$

$$\text{äquivalent: } f_Y(\mathbf{y}) = \sum_{\mathbf{x} \in g^{-1}(\{\mathbf{y}\})} \frac{f_X(\mathbf{x})}{|\det J_g(\mathbf{x})|}$$

Beide Formen sind gleich, weil $J_{g_m^{-1}}(\mathbf{y}) = J_g(\mathbf{x}_m)^{-1}$.

Rezept & der Trick bei sinkender Dimension

1. Inverse g^{-1} und neuen Träger bestimmen.
2. Jacobi-Matrix $J_{g^{-1}}$ aufstellen.
3. Betrag der Determinante einsetzen.

Der Satz verlangt $g: \mathbb{R}^d \rightarrow \mathbb{R}^d$. Für $Z = X_1 + X_2$ ergänzt man deshalb eine Hilfsvariable, transformiert $(Z, W) = (X_1 + X_2, X_2)$ bijektiv und marginalisiert danach über w . **Genau daraus entsteht gleich die Faltung.**

Typische mehrdimensionale Transformationen

TRANSFORMATION	TRANSFORMIERTE DICHTEN
$(U, V) = (X + Y, Y)$	$f_{U,V}(u, v) = f_{X,Y}(u - v, v)$
$(U, V) = (X/Y, Y), Y > 0$	$f_{U,V}(u, v) = f_{X,Y}(uv, v) v $
$(R, \Phi) = (\sqrt{X^2 + Y^2}, \text{atan2}(Y, X))$	$f_{R,\Phi}(r, \varphi) = f_{X,Y}(r \cos \varphi, r \sin \varphi) r$
$\mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{b}$	$f_Y(\mathbf{y}) = \frac{f_X(\mathbf{A}^{-1}(\mathbf{y} - \mathbf{b}))}{ \det \mathbf{A} }$

Jeweils nur auf dem transformierten Träger $T_Y = g(T_X)$.

Ehrliche Einordnung für die Klausur

In den fünf ausgewerteten GOPs kam eine echte mehrdimensionale Dichtetransformation **genau einmal** vor – SoSe 2025, Aufgabe 6(c), und dort als Beweis. Die Leave-One-Out-Analyse führt sie als *nicht vorhersehbar*. Verstehe das Prinzip und die erste Tabellenzeile, investiere die Übungszeit aber in Stufe 1 bis 4 und in Faltungen.

Was man wirklich mitnehmen sollte

Die Zeile $(U, V) = (X + Y, Y)$ mit $|\det J| = 1$ ist der einzige mehrdimensionale Fall, der regelmäßig gebraucht wird – als Herleitung der Faltungsformel.

TAG 2 · ZWEITER TEIL

Faltung: Wie addieren sich Zufallsvariablen?

Für jedes mögliche z sammeln wir alle Paare (x, y) , die $x + y = z$ erfüllen.

Didaktische Grundlage: 3Blue1Brown, „Convolutions | Why X+Y in probability is a beautiful mess“, plus Statistik-2-Folien 486–494.




Für ein festes z addieren wir die Gewichte aller passenden Paare

Feste Summe z  **7** X Y · beide Würfel sind zu hohen Augenzahlen hin gezinkt ☐ Randterme mit Gewicht 0 zeigen

1 · Spiegeln und schieben: Eine Spalte ist ein Wert x des blauen Würfels, darunter steht der dazu passende Wert $y = z - x$. Das blaue Band bleibt fest, das orange läuft rückwärts und rutscht bei $z \mapsto z + 1$ eine Position nach rechts. Grün: die Spalten, in denen **beide** Würfel einen gültigen Wert haben.

						0,04	0,06	0,10	0,15	0,25	0,40						
						0,30	0,25	0,18	0,12	0,09	0,06						
-5	-4	-3	-2	-1	0	1	2	3	4	5	6	7	8	9	10	11	12

Faltung ist ein gleitendes gewichtetes Mittel



z

Verteilungen

Die grüne Fläche ist **0,500** und wird unten an der Stelle $z = 1,33$ als Höhe eingetragen.

Fall $2 \cdot 1 \leq z \leq 2$: $f_Z(z) = 1/2$ — das Plateau, weil der kürzere Träger ganz in den längeren passt
 f_Y ist hier symmetrisch — das Spiegeln sieht man nicht, nur das Schieben. Wähle eine Exp-Verteilung, um beides zu sehen.

1. f_Y spiegeln: $f_Y(-x)$.
2. Um z verschieben: $f_Y(z-x)$.
3. Punktweise mit $f_X(x)$ multiplizieren.
4. Die Fläche unter dem Produkt wird als Höhe $f_Z(z)$ eingetragen – an derselben Stelle z , also genau auf der roten Linie.

Quelle: [3Blue1Brown, Convolutions](#); Statistik 2, Folie 492 beschreibt dieselbe Gewichtungsmittel-Interpretation.

Unabhängigkeit macht aus der gemeinsamen Dichte ein Produkt

$$f_{X+Y}(z) = (f_X * f_Y)(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z-x) dx$$

Jedes x wird danach gewichtet, wie plausibel der dazu passende Wert $y = z - x$ ist. Die Summe aller gewichteten Beiträge ergibt die Dichtehöhe bei z .

Symmetrie

$$f_X * f_Y = f_Y * f_X$$

CDF-Alternative

$$F_{X+Y}(z) = E[F_X(z-Y)] = \int_{-\infty}^{\infty} F_X(z-y) f_Y(y) dy$$

Die CDF-Form kann angenehmer sein, wenn F_X einfach ist oder die Dichte an Grenzen stückweise springt.

Die Integrationsgrenzen kommen aus den Trägern

$$x \in T_X \cap (z - T_Y)$$

$$\text{Dabei ist } z - T_Y = \{z - y : y \in T_Y\} = -T_Y + z.$$

$$T_X = [x_{\min}, x_{\max}], T_Y = [y_{\min}, y_{\max}] \implies [L(z), U(z)] = [x_{\min}, x_{\max}] \cap [z - y_{\max}, z - y_{\min}]$$

$$L(z) = \max(x_{\min}, z - y_{\max}), \quad U(z) = \min(x_{\max}, z - y_{\min})$$

BEDINGUNG	INTERVALL $[L(z), U(z)]$
$z \leq x_{\min} + y_{\max}, z \leq x_{\max} + y_{\min}$	$[x_{\min}, z - y_{\min}]$
$x_{\max} + y_{\min} \leq z \leq x_{\min} + y_{\max}$	$[x_{\min}, x_{\max}]$
$x_{\min} + y_{\max} \leq z \leq x_{\max} + y_{\min}$	$[z - y_{\max}, z - y_{\min}]$
$z \geq x_{\min} + y_{\max}, z \geq x_{\max} + y_{\min}$	$[z - y_{\max}, x_{\max}]$

Damit gibt es höchstens vier Grenzformen. Für feste endliche $x_{\min}, x_{\max}, y_{\min}, y_{\max}$ schließen sich die beiden mittleren Formen bis auf einen Randpunkt gegenseitig aus. Ist $L(z) > U(z)$, ist der Schnitt leer.

Unendliche Endpunkte reduzieren die Fälle


Eine unendliche Grenze entfernt jeweils einen Kandidaten aus Maximum oder Minimum:

$x_{\min} = -\infty$	$L(z) = z - y_{\max}$
$y_{\max} = +\infty$	$L(z) = x_{\min}$
$x_{\max} = +\infty$	$U(z) = z - y_{\min}$
$y_{\min} = -\infty$	$U(z) = x_{\max}$

In der Rechnung immer zuerst $A(z) = T_X \cap (z - T_Y)$ bilden. Die Fallunterscheidung entsteht nur dadurch, welcher Kandidat in $\max$ bzw. $\min$ aktiv ist.

Die Grenzen sind der Schnitt $A(z) = T_X \cap (z - T_Y)$

Typ: stetig T_X : 0 bis 2 T_Y : 0 bis 1
 Summe z : - 1,5 + oder Pfeiltasten für Einzelschritte (0,25)
 Typische Fälle: U(0,2) + U(0,1) U(0,2) + Exp(1) Exp + Exp N(0,1) + U(0,1) diskret: zwei Vierseiter



$$T_X = [0; 2] \cdot z - T_Y = [0,5; 1,5]$$

$$A(z) = [0,5; 1,5]$$

$$L(z) = \max(0, 0,5) = 0,5$$


$$U(z) = \min(2, 1,5) = 1,5$$

Fall 3 der Tabelle (beide Grenzen von $z - T_Y$ — der Schnitt ist ganz $z - T_Y$).

$$f_Z(z) = \int_{A(z)} f_X(x) f_Y(z - x) dx$$

Der Kandidat, der in $\max$ bzw. $\min$ gewinnt, ist farbig: **blau** heißt, die Grenze kommt aus T_X , **orange** heißt, sie kommt aus $z - T_Y$. Diese Kombination **ist** die Fallnummer der Tabelle von der vorigen Folie.

$U(0, 2) + U(0, 1)$: drei Fälle, ein Trapez



Drei Kontrollen

$$\frac{1}{4} + \frac{1}{2} + \frac{1}{4} = 1, \quad E(Z) = 1 + \frac{1}{2} = \frac{3}{2}$$

$$\text{Var}(Z) = \frac{4}{12} + \frac{1}{12} = \frac{5}{12}$$

Die Varianzen addieren sich, weil $X \perp Y$, und $P(1 \leq Z \leq 2) = \frac{1}{2}$ liest man direkt am Plateau ab.

Ansatz

$$f_X(x) = \frac{1}{2} \mathbb{I}_{[0,2]}(x), \quad f_Y(y) = \mathbb{I}_{[0,1]}(y)$$

$$f_Z(z) = \int_{A(z)} f_X(x) f_Y(z-x) dx = \frac{1}{2} |A(z)|$$

Träger $T_Z = [0, 3]$. Weil beide Dichten auf ihrem Träger **konstant** sind, ist das Integral nur die halbe Länge des Schnitts – die Aufgabe reduziert sich auf reine Geometrie.

Der Schnitt $A(z) = [0, 2] \cap [z-1, z]$

z	$A(z)$	LÄNGE	$f_Z(z)$
$0 \leq z < 1$	$[0, z]$	z	$z/2$
$1 \leq z \leq 2$	$[z-1, z]$	1	$1/2$
$2 < z \leq 3$	$[z-1, 2]$	$3-z$	$(3-z)/2$

Außerhalb von $[0, 3]$ ist der Schnitt leer und damit $f_Z(z) = 0$. Die Knickpunkte $z = x_{\min} + y_{\max} = 1$ und $z = x_{\max} + y_{\min} = 2$ sind genau die beiden mittleren Zeilen der Grenzen-Tabelle.

Wenn beide Träger gleich lang sind

Bei $U(0, 1) + U(0, 1)$ schrumpft das Plateau auf einen Punkt: Es entsteht ein **Dreieck** über $[0, 2]$ – nie eine Gleichverteilung.

Vier Schritte für jede Aufgabe $Z = X + Y$

1. **Unabhängigkeit prüfen.** Nur dann darf die gemeinsame Dichte bzw. Masse als Produkt geschrieben werden.
2. **Integrand aufschreiben:** $f_X(x)f_Y(z-x)$ bzw. $p_X(x)p_Y(z-x)$.
3. **Zulässige Werte schneiden:** $x \in T_X \cap (z - T_Y)$.
4. **Nach z -Fällen aufteilen** und integrieren bzw. summieren. Je nach Trägern können dafür bis zu vier Fallunterscheidungen nötig sein.

Durchgerechnetes Beispiel: $X \sim \text{Exp}(1)$, $Y \sim \text{Exp}(2)$, $X \perp Y$

Träger und Schnitt

$$\begin{aligned} T_X &= T_Y = [0, \infty) \\ A(z) &= [0, \infty) \cap (-\infty, z] \\ A(z) &= [0, z] \text{ für } z \geq 0, \quad A(z) = \emptyset \text{ für } z < 0 \end{aligned}$$

Einsetzen und integrieren

$$\begin{aligned} f_Z(z) &= \int_0^z e^{-x} 2e^{-2(z-x)} dx \\ f_Z(z) &= 2e^{-2z} \int_0^z e^x dx = 2(e^{-z} - e^{-2z}), \quad z \geq 0 \\ f_Z(z) &= 0 \quad \text{für } z < 0 \end{aligned}$$

Typischer Fehler: $f_Y(x)$ statt $f_Y(z-x)$. Frage immer: Wenn $X = x$ ist, welchen Wert muss Y annehmen, damit die Summe z ergibt?

Erst transformieren, dann falten

$$U = g(X), \quad V = h(Y), \quad Z = U + V$$

Differenz

$$X - Y = X + (-Y)$$

Transformiere Y zu $-Y$.

Linearkombination

$$aX + bY = (aX) + (bY)$$

Transformiere beide Summanden samt ihrer Träger.

Allgemeine Funktionen

$$g(X) + h(Y) = U + V$$

Bestimme zuerst f_U, T_U und f_V, T_V .

Achtung: Erst Dichte und Träger transformieren, dann die transformierten Größen falten.

Unabhängige Normalverteilungen bleiben unter Summen normal

$$X \sim \mathcal{N}(\mu_X, \sigma_X^2), \quad Y \sim \mathcal{N}(\mu_Y, \sigma_Y^2)$$

$$X \perp Y \implies X + Y \sim \mathcal{N}(\mu_X + \mu_Y, \sigma_X^2 + \sigma_Y^2)$$

Die Mittelwerte und – wegen der Unabhängigkeit – die Varianzen addieren sich. Nicht die Standardabweichungen.

Die Aussage ist einfach, der direkte Beweis nicht

Das Faltungsintegral zweier Normaldichten ist technisch aufwendig. In einigen Wochen liefern charakteristische bzw. momenterzeugende Funktionen einen deutlich eleganteren Beweis.

Iterierte Faltung

$$S_n = X_1 + \dots + X_n, \quad f_{S_n} = f_{X_1} * \dots * f_{X_n}$$

Auch eine Summe vieler unabhängiger Variablen entsteht durch wiederholte Faltung. Für $n \rightarrow \infty$ führt die zentrierte und skalierte Summe zum zentralen Grenzwertsatz.

Welche Familien bleiben beim Addieren erhalten?

Für unabhängige Summanden:

FALTUNGSREGEL	VORAUSSETZUNG
$\mathcal{N}(\mu_1, \sigma_1^2) + \mathcal{N}(\mu_2, \sigma_2^2) = \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$	keine weitere
$\mathcal{N}_d(\mu_1, \Sigma_1) + \mathcal{N}_d(\mu_2, \Sigma_2) = \mathcal{N}_d(\mu_1 + \mu_2, \Sigma_1 + \Sigma_2)$	gleiche Dimension
$\text{Ga}(a_1, b) + \text{Ga}(a_2, b) = \text{Ga}(a_1 + a_2, b)$	gleiche Rate b
$\text{Bin}(n, \pi) + \text{Bin}(m, \pi) = \text{Bin}(n + m, \pi)$	gleiches π
$\text{Poi}(\lambda_1) + \text{Poi}(\lambda_2) = \text{Poi}(\lambda_1 + \lambda_2)$	keine weitere
$M(n, \mathbf{p}) + M(m, \mathbf{p}) = M(n + m, \mathbf{p})$	gleiches $\mathbf{p}$
$\text{NegBin}(r_1, p) + \text{NegBin}(r_2, p) = \text{NegBin}(r_1 + r_2, p)$	gleiches p

Wechsel in eine andere Familie der Übersicht

$$\begin{aligned} \text{Exp}(\lambda) + \text{Exp}(\lambda) &= \text{Ga}(2, \lambda) \\ \sum_{i=1}^n X_i &\sim \text{Ga}(n, \lambda), \quad X_i \sim \text{Exp}(\lambda) \\ \sum_{i=1}^r Y_i &\sim \text{NegBin}(r, p), \quad Y_i \sim \text{Geom}(p) \end{aligned}$$

Im Allgemeinen nicht abgeschlossen

Stetige und diskrete Gleichverteilung, Beta- und inverse Gamma-Verteilung. Die Summe zweier Standard-Cauchy-Variablen ist zwar wieder Cauchy-verteilt, hat aber Skalenparameter 2 und ist daher nicht mehr die auf dem Blatt angegebene Standard-Cauchy-Verteilung.

Parametrisierung wie in **Statistik 2 Stoff/Verteilungen.pdf**: $\text{Ga}(a, b)$ verwendet Form a und Rate b .

Minimum und Maximum gehen über die Verteilungsfunktion

Das Ereignis übersetzen – der ganze Trick

$$\max_i X_i \leq z \iff X_1 \leq z, \dots, X_n \leq z$$

$$\min_i X_i > z \iff X_1 > z, \dots, X_n > z$$

Beide Ereignisse betreffen **alle** Variablen gleichzeitig. Genau deshalb faktorisiert die Wahrscheinlichkeit bei Unabhängigkeit – und man braucht keine Faltung. Beim Minimum geht man über das Gegenereignis.

Verteilungsfunktionen (unabhängig)

$$F_{\max}(z) = \prod_{i=1}^n F_i(z)$$

$$F_{\min}(z) = 1 - \prod_{i=1}^n (1 - F_i(z))$$

Bei identischer Verteilung wird daraus $F(z)^n$ beziehungsweise $1 - (1 - F(z))^n$.

Dichten durch Ableiten (i.i.d.)

$$f_{\max}(z) = n F(z)^{n-1} f(z)$$

$$f_{\min}(z) = n (1 - F(z))^{n-1} f(z)$$

Kettenregel, nichts weiter. Ableiten immer erst ganz am Schluss.

Rezept

1. Ereignis in „alle X_i ...“ übersetzen – beim Minimum über $P(\min > z)$.
2. Unabhängigkeit nutzen und das Produkt bilden.
3. Träger nicht vergessen: außerhalb ist F gleich 0 bzw. 1.
4. Erst jetzt ableiten, falls eine Dichte gefragt ist.

Vier Zeilen statt eines Faltungsintegrals.

Zwei Fehler, die Punkte kosten

Man kann $f_{\min}$ **nicht** direkt aus den Dichten zusammensetzen – der Weg führt zwingend über F . Und ohne Unabhängigkeit darf das Produkt gar nicht gebildet werden.

Durchgerechnet · Exponentialverteilung

$X_1, \dots, X_n$ unabhängig $\text{Exp}(\lambda)$, also $F(z) = 1 - e^{-\lambda z}$ für $z \geq 0$:

$$F_{\min}(z) = 1 - (e^{-\lambda z})^n = 1 - e^{-n\lambda z}$$

Das ist wieder eine Exponentialverteilung:

$$\min_i X_i \sim \text{Exp}(n\lambda), \quad E(\min_i X_i) = \frac{1}{n\lambda}$$

Anschaulich: Je mehr unabhängige Wartezeiten parallel laufen, desto früher ist die erste fertig. Das Maximum ist dagegen **nicht** exponentialverteilt – dort bleibt $F_{\max}(z) = (1 - e^{-\lambda z})^n$ stehen.

Einordnung

Summe, Minimum und Maximum sind die drei Standardwege, aus mehreren Zufallsvariablen eine neue zu machen. Die Summe braucht eine Faltung, Minimum und Maximum nur eine Zeile Mengenlehre. Genau dieser Aufgabentyp steckt in **SoSe 2025, Aufgabe 5(b)**.

Keine neue Theorie – wir trainieren wiederkehrende GOP-Blöcke

- Erste zwei Aufgaben jedes Blocks gemeinsam strukturieren
- Danach selbstständig rechnen, Lösungen vergleichen und Fragen klären
- Aufgabensprache in einen verlässlichen Arbeitsablauf übersetzen

Drei Aufgabenfamilien, ein Werkzeugkasten

Grafikaufgaben

Datensituation · Grammar of Graphics ·
Skalen · Ablesen · Kritik · Alternative
Darstellung

10 Aufgaben · 16–26 Punkte typisch in
Altklausuren

Wahrscheinlichkeit, Kontingenz & Diagnostik

Basisraten · Bayes · Vierfeldertafel · Odds
Ratio · Sensitivität/Spezifität · ROC

10 Aufgaben · stark wiederkehrende
Rechenschritte

Dichte, VF & Transformation

Normierung · CDF/Dichte ·
Momente/Quantile · Transformation ·
Faltung

10 Aufgaben · Woche-2/3-Kernstoff

Aufgabe 1 und 2 variieren dasselbe Basisratenproblem

Klausur Deskriptive Statistik und Wahrscheinlichkeitstheoretische Grundlagen

GOP-Training

Aufgabe 1 (16 Punkte)

Die Firma „Nordkem“ möchte in der Lebensmittelproduktion ein automatisches System zur Erkennung verunreinigter Packungen einsetzen. Pro Monat werden zwei Millionen Packungen hergestellt; erfahrungsgemäß sind von einer Million Packungen 20 verunreinigt. In einer bewusst zusammengestellten Validierungstestprobe liess das System bei 18 von 20 tatsächlich verunreinigten und bei 99 von 1980 nicht verunreinigten Packungen einen Alarm aus. Gehen Sie im Folgenden davon aus, dass die in der Validierungstestprobe ermittelten Eigenschaften des Systems auch im Produktionsalltag gelten.

(a) Berechnen Sie die erwarteten monatlichen Häufigkeiten von zutreffenden Alarmen, Fehlar-
men, überschrittenen Verunreinigungen und korrekt als unbedenklich erkannten Packungen.
Stellen Sie Ihre Ergebnisse in einer vollständig beschrifteten Vierfeldertafel dar. [6]

(b) Halten Sie einen Alarm unter den gegebenen Umständen für einen verlässlichen Hinweis auf
eine tatsächliche Verunreinigung? Begründen Sie Ihre Antwort quantitativ mit einer geeigneten
bedingten Wahrscheinlichkeit. [3]

(c) Quantifizieren Sie die Stärke des Zusammenhangs zwischen dem tatsächlichen Zustand einer
Packung und der Reaktion des Systems mit einer Maßzahl, deren Wertebereich $\mathbb{R}_0^1$ ist. Inter-
pretieren Sie Ihr Ergebnis. [2]

(d) Die folgende Grafik zeigt ROC-Kurven zweier alternativer Systeme. Das System „Safescur“ ist
schwarz, „Klarsicht“ grau dargestellt. Die Zahlen markieren ausgewählte Schwellenwerte. [5]

Seite 1 von 19

Klausur Deskriptive Statistik und Wahrscheinlichkeitstheoretische Grundlagen

GOP-Training

Aufgabe 2 (13 Punkte)

Ein diagnostischer Test auf eine akute Infektion wurde an drei bewusst ausgewählten Personengruppen erprobt. Die Ergebnisse der klinischen Erprobung sind:

Status	Nie infiziert	Genesen	Akut erkrankt	Σ
Test positiv	2	5	54	61
Test negativ	98	95	6	199
Σ	100	100	60	260

Im Klinikalltag sind 70% der Patient:innen nie infiziert, 28% genesen und 2% akut erkrankt. Gehen Sie davon aus, dass die gruppenspezifischen Testraten aus der Erprobung auch im Klinikalltag gelten.

(a) Berechnen Sie Sensitivität und Spezifität des Tests zur Erkennung einer akuten Infektion. [2]
Fassen Sie dabei „nie infiziert“ und „genesen“ als „nicht akut erkrankt“ zusammen.

(b) Berechnen Sie mit dem Satz der totalen Wahrscheinlichkeit die Wahrscheinlichkeit, mit der der
Test im Klinikalltag ein positives Ergebnis zeigt. Berücksichtigen Sie alle drei Statusgruppen. [3]

(c) Berechnen Sie die Wahrscheinlichkeit, mit der ein negatives Testergebnis im Klinikalltag tat-
sächlich eine nicht akut erkrankte Person anzeigt. [3]

(d) Eine ROC-Kurve eines teureren Alternativtests verläuft vollständig oberhalb des Punktes des
hier untersuchten Tests. Erläutern Sie, was diese Aussage bedeutet. Wie sollte der Schwellen-
wert des Alternativtests gewählt werden, wenn eine übersehene akute Infektion deutlich schwe-
rer wiegt als eine unnötige Folgeuntersuchung? [5]

Seite 3 von 19

Aufgabe 1 · Produktion

Validierungsraten auf Population übertragen,
Vierfeldertafel, ppV, Odds Ratio und ROC-
Entscheidung.

Aufgabe 2 · Diagnostik

Drei Statusgruppen, Sensitivität/Spezifität, totale
Wahrscheinlichkeit, npV und ROC-Abwägung.

Gemeinsamer Kern

Bedingte Testraten + echte Basisraten →
erwartete Häufigkeiten → gesuchte Richtung der
Bedingung.

Aufgabe 1 und 2 prüfen die komplette univariate Kette

Klausur Deskriptive Statistik und Wahrscheinlichkeitstheoretische Grundlagen GOP-Training 2026

Aufgabe 1 (18 Punkte)
Gegeben sei die stetige Zufallsvariable X mit Dichte

$$f_X(x) = c(1+x) \mathbb{I}_{[0,2]}(x).$$

(a) Berechnen Sie die Konstante c . [4]

(b) Skizzieren Sie die Dichte. [2]

(c) Berechnen Sie den Erwartungswert von X . [3]

Seite 1

Klausur Deskriptive Statistik und Wahrscheinlichkeitstheoretische Grundlagen GOP-Training 2026

Aufgabe 2 (15 Punkte)
Sei

$$F(x) = \begin{cases} 0, & x < 1, \\ \ln(ax+b), & 1 \leq x \leq \exp(1), \\ 1, & x > \exp(1). \end{cases}$$

(a) Für welche Werte von a und b ist F die Verteilungsfunktion einer stetigen Zufallsvariablen? Begründen Sie. [6]

(b) Wie lautet die zugehörige Dichte f ? [3]

Seite 3

Aufgabe 1 · Dichte gegeben

Normierung, Skizze, Erwartungswert, Median und $(Y=e^X)$ mit neuem Träger.

Aufgabe 2 · CDF gegeben

Parameterbedingungen, Ableitung zur Dichte, Quantilfunktion und Eindeutigkeit.

Gemeinsamer Kern

Träger → gültige Verteilung → zwischen (F) und (f) wechseln → Kennwert/Transformation.

WOCHE 3 ABGESCHLOSSEN

Damit sind **mehrdimensionale Verteilungen, Dichtetransformationen und Faltungen** durch.
Am Praxistag wird daraus ein verlässlicher Einstieg in wiederkehrende GOP-Aufgaben.

Wie viel Stoff ist damit abgedeckt?

68,8 %

In fünf analysierten **Hauptfach-GOPs** waren **431 von 626 Punkten** mit dem Stoff aus Woche 1–3 lösbar.

Wiederkehrende Aufgabenblöcke

≈ 50 %

der GOP sind im Mittel allein durch bisherigen Stoff über gezielt trainierbare, wiederkehrende Aufgabenblöcke erreichbar.

Jetzt zählt vor allem: **selbst rechnen, Lösungswege vergleichen und typische Einstiege automatisieren.**

Noch **19 Tage** bis zur GOP.