

GOP Bootcamp 2026

Woche 5 · Dichten, Momente, Konvergenz & Grenzwertsätze

Tag 1

Dichten relativ zu einem Maß · Erwartungswert und Momente · charakteristische Funktionen und Fourier-Idee

Tag 2

Endliche Schranken · Konvergenz und Konsistenz · GGZ und ZGWS als Brücke zur Inferenzstatistik

Die Farbe eines Kastens trägt seine Bedeutung

Definition

Satz, Begriff oder Formel, auf die wir uns später beziehen.

z. B. $P(A) = \int_A f \, d\mu$

Beispiel

Einordnung, Intuition oder eine vollständig durchgerechnete Anwendung.

z. B. Normalapproximation

Rezept

Ein verlässlicher Rechenweg für typische Klausuraufgaben.

z. B. sechs Schritte beim ZGWS

Achtung

Voraussetzung, typischer Fehler oder Plausibilitätskontrolle.

z. B. Stetigkeitskorrektur

Neutral

Tabellen, Zahlen und interaktive Grafiken ohne Wertung.

z. B. die Konvergenzpfade

Zusatz markiert Randthemen. Sie helfen beim Einordnen, sind aber der erste Kürzungspunkt, wenn die Zeit knapp wird.

Dichten, Momente & charakteristische Funktionen

- Dichten immer relativ zu einem dominierenden Maß lesen
- Verstehen, wie sich Wahrscheinlichkeitsmaße durch Dichten und Gewichte konstruieren lassen
- Momente und ihre Existenz sicher unterscheiden und berechnen
- Mit charakteristischen Funktionen Momente, Summen und Verteilungen untersuchen

Grundlage: Statistik 2, Kapitel 7, 8 und 10, besonders Folien 273–300, 316–370, 405–411 und 418–422.

Eine Dichte ist die Ableitung von P bezüglich eines dominierenden Maßes

Absolute Stetigkeit

$$P \ll \mu \iff \mu(A) = 0 \Rightarrow P(A) = 0 \quad \forall A \in \mathcal{F}$$

Für uns bedeutet das später: **Ist ein Ereignis eine Nullmenge bezüglich μ , dann hat es Wahrscheinlichkeit 0.** Man sagt auch: μ dominiert P .

Satz von Radon–Nikodým

Ist μ σ -endlich, dann gilt:

$$P \ll \mu \iff \exists f \geq 0: P(A) = \int_A f d\mu \quad \forall A \in \mathcal{F}$$

$$f = \frac{dP}{d\mu}$$

Die Funktion f heißt **Radon–Nikodým-Dichte** von P bezüglich μ .

Rolle des dominierenden Maßes

μ legt fest, welche Mengen Volumen besitzen. Wo μ nichts sieht, darf P keine Masse ablegen. Die Ableitung $f = dP/d\mu$ gibt die Wahrscheinlichkeitsmasse pro Einheit dieses Volumens an.

Eindeutigkeit fast überall

$$f = g \quad \mu\text{-fast überall} \implies \int_A f d\mu = \int_A g d\mu$$

Dichten dürfen sich auf μ -Nullmengen unterscheiden. Zum Beispiel erzeugen $\mathbb{I}_{[0,1]}$ und $\mathbb{I}_{(0,1)}$ bezüglich λ dasselbe Wahrscheinlichkeitsmaß.

Verbindung zum Maßeindeutigkeitssatz

$$F(x) = P((-\infty, x]) = \int_{(-\infty, x]} f d\mu$$

Stimmen zwei Wahrscheinlichkeitsmaße auf allen Intervallen $(-\infty, x]$ überein, stimmen sie auf der gesamten Borelschen σ -Algebra überein. Das Maß ist eindeutig, seine Dichte nur fast überall.


Normierungskonstanten bekannter Verteilungen

Schreibt man eine Dichte als $f = c \cdot k$, dann sorgt $c = (\int k \, d\mu)^{-1}$ für Gesamtmasse 1. Die Verteilungstabelle enthält diese Konstanten bereits.

STETIG: VERTEILUNG	KERN k	KONSTANTE c	DISKRET: VERTEILUNG	KERN $k(y)$	KONSTANTE c
$U(a, b)$	$\mathbb{I}_{[a, b]}(x)$	$(b - a)^{-1}$	Diskret uniform	$\mathbb{I}_{\{y_1, \dots, y_k\}}(y)$	$1/k$
$N(\mu, \sigma^2)$	$e^{-(x - \mu)^2 / (2\sigma^2)}$	$(2\pi\sigma^2)^{-1/2}$	Bin (n, p)	$\binom{n}{y} p^y (1 - p)^{n - y}$	1
$N_d(\mu, \Sigma)$	$e^{-(x - \mu)^T \Sigma^{-1} (x - \mu) / 2}$	$(2\pi)^{-d/2} \det(\Sigma)^{-1/2}$	Poi (λ)	$\lambda^y / y!$	$e^{-\lambda}$
Cauchy	$(1 + x^2)^{-1}$	π^{-1}	Multinomial	$\binom{n}{y_1, \dots, y_k} \prod_j p_j^{y_j}$	1
Beta (a, b)	$x^{a-1} (1 - x)^{b-1} \mathbb{I}_{[0, 1]}(x)$	$\Gamma(a + b) / (\Gamma(a) \Gamma(b))$	Geom (p)	$(1 - p)^{y-1} \mathbb{I}_{\mathbb{N}}(y)$	p
Ga (a, b)	$x^{a-1} e^{-bx} \mathbb{I}_{(0, \infty)}(x)$	$b^a / \Gamma(a)$	NegBin (r, p)	$\binom{y-1}{r-1} (1 - p)^{y-r}$	p^r
IG (a, b)	$x^{-a-1} e^{-b/x} \mathbb{I}_{(0, \infty)}(x)$	$b^a / \Gamma(a)$			
Exp (λ)	$e^{-\lambda x} \mathbb{I}_{\{x \geq 0\}}$	λ			

Quelle und Parametrisierung: Statistik 2 Stoff · Verteilungen.pdf.

Dieselbe Formel beschreibt diskrete, stetige und gemischte Verteilungen



Verteilung Binomial(4; 0,4) ▾

Ansicht RN-Dichte ▾

Grenze b 1,00**Binomial:** $\mu = \sum_{k=0}^4 \delta_k$ $f = dP/d\mu, \quad f(k) = C(4,k) \cdot 0,4^k \cdot 0,6^{4-k}$

$\int_A f \, d\mu = \sum_{k \in A \cap \{0, \dots, 4\}} f(k)$. Das Zählmaß zählt die Stützstellen, f gewichtet sie mit ihren Wahrscheinlichkeiten.

Summe markierter Punktmassen: $P(X \leq 1,00)$
= 0,4752.

In allen drei Fällen gilt dieselbe Struktur:
 $f = dP/d\mu$ und $P(A) = \int_A f \, d\mu$. Das Widget ändert nur μ , f und die passende Darstellung des Integrals.

Momente beschreiben Lage, zentrierte Momente die Form

Erwartungswert unter P

$$E_P(X) := \int_{\mathbb{R}} X dP$$

Der Erwartungswert ist das Integral der messbaren Funktion X bezüglich des Wahrscheinlichkeitsmaßes P .

Vom Erwartungswert zu Momenten

Setzt man statt X höhere Potenzen oder zentrierte Potenzen ein, erhält man Lage-, Streuungs- und Forminformationen über dieselbe Verteilung.

k -tes Moment

$$m_k = E(X^k)$$

Für $k = 1$: Erwartungswert.

Absolutes Moment

$$m_{(k)} = E(|X|^k)$$

Entscheidet über Existenz und Integrabilität.

Zentriertes Moment

$$m_k^0 = E[(X - EX)^k]$$

Für $k = 2$: Varianz.

Standardisiert

$$E\left[\left(\frac{X - E(X)}{\sigma}\right)^k\right]$$

Macht Formmaße einheitenfrei.

Existenzleiter aus Hölder

Für $0 < j < k$ liefert Hölder beziehungsweise die daraus folgende Lyapunov-Ungleichung

$$(E|X|^j)^{1/j} \leq (E|X|^k)^{1/k}$$

Ein endliches höheres absolutes Moment sichert daher alle niedrigeren. Endliche Varianz sichert einen endlichen Erwartungswert.

Reihenfolge beim Rechnen

Erst prüfen, ob das benötigte Moment existiert. Dann Summe oder Integral aufstellen. Erst danach vereinfachen.

Beim Cauchy-Modell liegt das Zentrum bei 0, aber der Erwartungswert existiert nicht

Existenzkriterium

$$E(X) \text{ existiert endlich} \iff E(|X|) < \infty$$

Positive und negative Teile müssen beide endliche Integrale besitzen.

Cauchy-Dichte

$$f(x) = \frac{1}{\pi(1+x^2)}$$

Die Dichte ist symmetrisch um 0, aber ihre Tails fallen zu langsam ab.

Die entscheidende Rechnung

$$E(|X|) = 2 \int_0^{\infty} \frac{x}{\pi(1+x^2)} dx = \infty$$

Das formale Wegkürzen von linker und rechter Seite wäre $\infty - \infty$. Dieser Ausdruck ist nicht definiert.

Warum der Name „Erwartungswert“ täuscht

Im Alltag meint „erwartet“ oft den plausibelsten oder typischsten Ausgang. Mathematisch bezeichnet $E(X)$ ein wahrscheinlichkeitsgewichtetes Integral und damit den theoretischen langfristigen Durchschnitt, sofern das Integral existiert. Er muss weder der wahrscheinlichste noch überhaupt ein möglicher Einzelwert sein. Beim fairen Würfel gilt zum Beispiel $E(X) = 3,5$.

Was wir bei Cauchy tatsächlich erwarten würden

Wegen der Symmetrie wirkt 0 als natürliche Prognose. Tatsächlich sind Median und Modus gleich 0. Seltene extreme Beobachtungen verhindern aber, dass sich der Stichprobenmittelwert stabilisiert. Deshalb existiert der mathematische Erwartungswert nicht.

Zur Terminologie: UC Berkeley SticiGui, „The Long Run and the Expected Value“; Penn State STAT 414, Lesson 8.

Die nächsten Momente beantworten verschiedene Fragen

Varianz aus den ersten zwei Momenten

$$\text{Var}(X) = E[(X - E(X))^2] = E(X^2) - E(X)^2$$

Das zweite zentrierte Moment misst Streuung.

Schiefe aus den ersten drei Momenten

$$\gamma_1 = \frac{E[(X - E(X))^3]}{\sigma^3}$$

$$E[(X - E(X))^3] = E(X^3) - 3E(X)E(X^2) + 2E(X)^3$$

Kurtosis aus den ersten vier Momenten

$$K = \frac{E[(X - E(X))^4]}{\sigma^4}$$

$$E[(X - E(X))^4] = E(X^4) - 4E(X)E(X^3) + 6E(X)^2E(X^2) - 3E(X)^4$$

Zusammenhang


Die Binomialentwicklung übersetzt zentrale Momente in gewöhnliche Momente. Durch Division durch σ^k werden Schiefe und Kurtosis einheitenfrei. Für die Normalverteilung gilt $K = 3$, der Exzess ist $(K-3)$.

Die Zerlegungen setzen die jeweiligen Momente voraus. Hohe Potenzen gewichten Tails und Ausreißer besonders stark.


Die charakteristische Funktion ist die Fourier-Transformation der Verteilung

Verteilung Frequenz t Ausgewählter Wert x

1 · Verteilung und ausgewählter Wert



2 · Phasen, Bahn von ϕ_X und Tangente ϕ'_X



Funktion und erste Ableitung

$$\begin{aligned}\varphi_X(t) &= E(e^{itX}), & \varphi'_X(t) &= E(iXe^{itX}) \\ \varphi'_X(0) &= iE(X) \implies E(X) &= \operatorname{Im}(\varphi'_X(0))\end{aligned}$$

Die violette Tangente zeigt die Richtung von $\varphi'_X(t)$. Bei $t = 0$ ist sie vertikal, ihre imaginäre Komponente liefert den Erwartungswert.

Schwerpunkt und momentane Änderung

Für $x = 1,50$ gilt $e^{itx} = 0,071 + 0,997i$. Die blauen Phasen mitteln sich zum grünen Punkt.

$$\phi_X(1,00) = 0,408 + 0,635i$$

$$\phi'_X(1,00) = -0,865 + 0,051i$$

Am Ursprung gilt $\phi'_X(0) = 1,00i$. Deshalb ist $E(X) = \operatorname{Im}(\phi'_X(0)) = 1,00$. Der violette Pfeil zeigt die Tangentenrichtung, seine Länge ist zur Lesbarkeit skaliert.

Bei Bernoulli entsteht die Funktion direkt aus zwei möglichen Werten

Allgemeines Rechenrezept

$$\varphi_X(t) = \sum_x e^{itx} P(X = x) \quad \text{diskret}$$

$$\varphi_X(t) = \int_{\mathbb{R}} e^{itx} f_X(x) dx \quad \text{stetig}$$

Man setzt die Funktion $x \mapsto e^{itx}$ in die Erwartungswertformel ein. Bei stetigen Verteilungen berechnet man damit eine Fourier-Transformation.

Herleitung für $X \sim \text{Bern}(p)$

$$\begin{aligned} \varphi_X(t) &= e^{it \cdot 0} P(X = 0) + e^{it \cdot 1} P(X = 1) \\ &= (1 - p) + pe^{it} \end{aligned}$$

Das Beispiel fällt damit nicht vom Himmel. Es ist die Definition, ausgewertet an den beiden Stützstellen 0 und 1.

Taylor-Idee

$$e^{itX} = 1 + itX - \frac{t^2 X^2}{2} + \frac{(itX)^3}{3!} + \dots$$

$$\varphi_X(t) = 1 + itE(X) - \frac{t^2}{2}E(X^2) + \dots$$

Erste und zweite Ableitung

$$\varphi'_X(t) = E(iXe^{itX}) \quad \Rightarrow \quad \varphi'_X(0) = iE(X)$$

$$\varphi_X^{(2)}(t) = E((iX)^2 e^{itX}) \quad \Rightarrow \quad \varphi_X^{(2)}(0) = -E(X^2)$$

Allgemeines Moment

$$E(X^k) = i^{-k} \varphi_X^{(k)}(0)$$

Die Ableitungsformel setzt die Existenz des entsprechenden Moments voraus. Die charakteristische Funktion selbst existiert auch ohne Momente.

Bekannte Funktionsformen identifizieren bekannte Verteilungen

VERTEILUNG	CHARAKTERISTISCHE FUNKTION $\varphi_X(t)$	BEMERKUNG
Bern (p)	$(1 - p) + pe^{it}$	Direkt über zwei Stützstellen
Bin (n, p)	$(1 - p + pe^{it})^n$	Summe von n unabhängigen Bernoulli-Variablen
Poi (λ)	$\exp\{\lambda(e^{it} - 1)\}$	Potenzreihe der Exponentialfunktion
$N(\mu, \sigma^2)$	$\exp\{i\mu t - \frac{1}{2}\sigma^2 t^2\}$	Phase kodiert Lage, Betrag kodiert Streuung
Exp (b) mit Rate b	$\frac{b}{b - it}$	Existiert für jedes reelle t
$U(a, b)$	$(e^{itb} - e^{ita})/(it(b - a))$	Bei $t = 0$ stetig durch $\varphi_X(0) = 1$ ergänzen
Standard-Cauchy	$e^{- t }$	Charakteristische Funktion existiert trotz fehlender Momente

Erkennen: Stimmt eine berechnete charakteristische Funktion mit einer bekannten Zeile überein, dann stimmt wegen der Eindeutigkeit auch die Verteilung überein.

Immer prüfen: $\varphi_X(0) = 1$, $|\varphi_X(t)| \leq 1$ und $\varphi_X(-t) = \overline{\varphi_X(t)}$.

Fourier-Transformationen ersetzen schwierige Faltungen durch Produkte

Eindeutigkeit

Jede charakteristische Funktion bestimmt genau eine Wahrscheinlichkeitsverteilung. Die transformierte Funktion verliert also keine Information.

Unabhängige Summen

$$X \perp Y \implies \varphi_{X+Y}(t) = \varphi_X(t) \varphi_Y(t)$$

Im ursprünglichen Raum müsste man die Verteilungen falten.

Momente

$$E(X^k) = i^{-k} \varphi_X^{(k)}(0)$$

Ableitungen bei 0 liefern vorhandene Momente.

Grenzverteilungen

Punktweise Konvergenz charakteristischer Funktionen führt unter der Stetigkeitsbedingung bei 0 zur Konvergenz in Verteilung. Diese Idee steckt in vielen ZGWS-Beweisen.

Leichte Frage mit Transformation

Welche Verteilung hat die Summe zweier unabhängiger normalverteilter Variablen?

Mit charakteristischen Funktionen genügt das Produkt zweier bekannter Formeln. Ohne Transformation müsste man das Faltungsintegral quadratisch ergänzen und auswerten.

Fourier-Inversion für eine Dichte

Ist φ_X integrierbar, erhält man die Dichte durch die inverse Fourier-Transformation:

$$f_X(x) = \frac{1}{2\pi} \int_{\mathbb{R}} e^{-itx} \varphi_X(t) dt.$$

Die charakteristische Funktion enthält damit weiterhin die vollständige Information über die Verteilung.

Vergleich zur MGF

Falls M_X in einer Umgebung von 0 existiert, gilt formal $M_X(t) = \varphi_X(-it)$. Die MGF kann wegen exponentiell gewichteter Tails divergieren. Die charakteristische Funktion existiert immer und ist deshalb allgemeiner.

Die Summe unabhängiger Normalverteilungen ist wieder normalverteilt

Ausgangslage

$$X \sim N(\mu_X, \sigma_X^2), \quad Y \sim N(\mu_Y, \sigma_Y^2), \quad X \perp Y$$

Gesucht ist die Verteilung von $S = X + Y$.

Produkt bilden

$$\begin{aligned} \varphi_S(t) &= E(e^{it(X+Y)}) = \varphi_X(t)\varphi_Y(t) \\ &= e^{i\mu_X t - \sigma_X^2 t^2/2} e^{i\mu_Y t - \sigma_Y^2 t^2/2} = e^{i(\mu_X + \mu_Y)t - (\sigma_X^2 + \sigma_Y^2)t^2/2} \end{aligned}$$

Bekannte charakteristische Funktionen

$$\varphi_X(t) = e^{i\mu_X t - \sigma_X^2 t^2/2}$$

$$\varphi_Y(t) = e^{i\mu_Y t - \sigma_Y^2 t^2/2}$$

Bekannte Form erkennen

Die letzte Zeile ist die charakteristische Funktion einer Normalverteilung mit Erwartungswert $\mu_X + \mu_Y$ und Varianz $\sigma_X^2 + \sigma_Y^2$.

$$S = X + Y \sim N(\mu_X + \mu_Y, \sigma_X^2 + \sigma_Y^2)$$

Wo Unabhängigkeit eingeht

$$E(e^{itX}e^{itY}) = E(e^{itX})E(e^{itY})$$

Letzter Beweisschritt

Erst der Eindeutigkeitssatz für charakteristische Funktionen erlaubt den Schluss von gleicher charakteristischer Funktion auf gleiche Verteilung. Ohne Unabhängigkeit darf man das Produkt nicht bilden.

Momenterzeugende Funktionen verwenden reelle Exponentialgewichte

Definition

$$M_X(t) = E(e^{tX})$$

Die MGF ist für uns nur dann regulär nutzbar, wenn sie für alle t in einer offenen Umgebung von 0 endlich ist.

Verbindung zur charakteristischen Funktion

$$M_X(t) = \varphi_X(-it)$$

Das gilt dort, wo die MGF existiert. Der entscheidende Unterschied: e^{tX} kann in einem Tail explosionsartig wachsen, während $|e^{itX}| = 1$ immer beschränkt bleibt.

Taylor-Idee: Momente stecken in den Koeffizienten

$$e^{tX} = \sum_{k=0}^{\infty} \frac{t^k X^k}{k!} \implies M_X(t) = \sum_{k=0}^{\infty} \frac{t^k E(X^k)}{k!}$$

$$M_X^{(k)}(0) = E(X^k)$$

Der Austausch von Erwartungswert, Reihe und Ableitung benötigt passende Integrierbarkeit — genau deshalb ist die Existenzannahme wichtig.

Wofür ist die MGF nützlich?

$$X \perp Y \implies M_{X+Y}(t) = M_X(t)M_Y(t)$$

Ableitungen liefern Momente; Produkte identifizieren Summenverteilungen. Zusammen mit Markov erhält man für $t > 0$ außerdem exponentielle Tail-Schranken:

$$P(X \geq a) \leq e^{-ta} M_X(t)$$

Typische Formen

$X \sim \text{Bern}(p)$	$M_X(t) = 1 - p + pe^t$
$X \sim \text{Bin}(n, p)$	$M_X(t) = (1 - p + pe^t)^n$
$X \sim N(\mu, \sigma^2)$	$M_X(t) = e^{\mu t + \sigma^2 t^2 / 2}$

Warum nur Zusatz?

Bei einer Lognormalverteilung sind zwar alle gewöhnlichen Momente endlich, aber $M_X(t) = \infty$ für jedes $t > 0$. Die charakteristische Funktion existiert dagegen für jede Verteilung und ist deshalb das allgemeinere Werkzeug.

Merksatz

MGF: bequem, wenn sie existiert. **Charakteristische Funktion:** immer verfügbar.

Vom Zufallsmodell zur Inferenzstatistik

- Statistiken als zufällige Funktionen einer Stichprobe verstehen
- Mit Ungleichungen Garantien für endliche Stichproben erhalten
- Konsistenz mit Konvergenz und dem GGZ begründen
- Mit dem ZGWS Schwankungen, Standardfehler und spätere Inferenz vorbereiten

Heute endet Wahrscheinlichkeitstheorie dort, wo Inferenzstatistik beginnt: bei der Frage, was eine zufällige Stichprobe verlässlich über eine unbekannte Population verrät.

2

Asymptotik verbindet empirische Verfahren mit Wahrscheinlichkeitstheorie

Woche 1 · Empirie

Beobachtete Daten $x_1, \dots, x_n$ werden zu einer Kennzahl t_n .



Wochen 2–4 · Theorie

Das Modell $X_1, \dots, X_n \sim P_\theta$ macht Stichproben zufällig.



Woche 5 · Asymptotik

Wir untersuchen T_n , wenn n wächst: Ziel und Schwankung.



Nächstes Semester · Inferenz

Schätzer, Tests und Konfidenzintervalle machen Aussagen über θ .

Statistik als Zufallsvariable

$$X_1, \dots, X_n \sim P_\theta \mapsto T_n = T_n(X_1, \dots, X_n)$$

Vor der Datenerhebung ist auch das Ergebnis des Verfahrens zufällig.

Beispiele für T_n

Mittelwert: $\bar{X}_n$

ECDF: $F_n(x) = n^{-1} \sum_i \mathbb{I}\{X_i \leq x\}$

MLE: $\hat{\theta}_n = \arg \max_{\theta} L_n(\theta)$

Median: $X_{(\lfloor n/2 \rfloor)}$

Test: $\varphi_n \in \{0, 1\}$

1 · Zieltreue

Für endliches n : Hat T_n Bias, also $E(T_n) - \theta$? Für wachsendes n : Gilt Konsistenz $T_n \xrightarrow{P} \theta$?

2 · Unsicherheit

Wie groß ist $\text{Var}(T_n)$? Welche Grenzverteilung besitzt der normierte Fehler? Daraus entstehen später Standardfehler, Tests und Konfidenzintervalle.

Werkzeuge des zweiten Tages

Markov und Tschebyscheff liefern Garantien ohne genaue Verteilungsform. Das **GGZ** beantwortet die Zieltreue durch Konsistenz. Der **ZGWS** beschreibt die verbleibende Unsicherheit.

Asymptotische Aussagen gelten für $n \rightarrow \infty$. Bei kleinen Stichproben können endliche Schranken oder Simulationen die bessere Orientierung geben.

Der Erwartungswert begrenzt, wie oft eine nichtnegative Größe groß sein kann

Markov

$$Y \geq 0, a > 0 \implies P(Y \geq a) \leq \frac{E(Y)}{a}$$

Warum die Schranke stimmen muss

$$\begin{aligned} E(Y) &= \int_0^{\infty} y f(y) d\mu(y) \geq \int_{[a, \infty)} y f(y) d\mu(y) \\ &\geq a \int_{[a, \infty)} f(y) d\mu(y) = a P(Y \geq a) \end{aligned}$$

Im Ereignis $Y \geq a$ trägt jeder Fall mindestens a zum Erwartungswert bei.

Wartezeit-Beispiel

Eine nichtnegative Wartezeit hat $E(Y) = 12$ Minuten.

$$P(Y \geq 30) \leq \frac{12}{30} = 0,40$$

Ohne Kenntnis der Verteilung ist 40 % eine garantierte obere Schranke.

Abweichungen mit Markov abschätzen

Bei endlicher Varianz gilt $E|Y - E(Y)| \leq \sigma$. Daher:


$$\begin{aligned} P(|Y - E(Y)| \geq \varepsilon) &\leq \frac{E|Y - E(Y)|}{\varepsilon} \leq \frac{\sigma}{\varepsilon} \\ P(|Y - E(Y)| \geq \varepsilon) &\leq \frac{\text{Var}(Y)}{\varepsilon^2} \end{aligned}$$

Die zweite Zeile wendet Markov auf $(Y - E(Y))^2$ an. Genau daraus entsteht die Tschebyscheff-Ungleichung.

Voraussetzung vor der Rechnung

Markov verlangt $Y \geq 0$. Für eine vorzeichenbehaftete Variable betrachtet man etwa $|X|$ oder $(X - E(X))^2$.

Eine Schranke braucht wenig Wissen und zahlt dafür mit Grobheit



Modell Uniform(0; 1) ↕


Schwelle a 2,00**Uniform(0; 1) bei $a = 2,00$** $E(Y) = 0,50$ Exakt: $P(Y \geq a) = 0,00 \%$ Markov: $P(Y \geq a) \leq 25,00 \%$

Die Markov-Schranke verwendet nur $E(Y)$, nicht die Form der Verteilung.

Survivalfunktion

Die blaue Kurve ist $S_Y(a) = P(Y \geq a)$. Man kann die gesuchte Wahrscheinlichkeit an der gewählten Schwelle direkt ablesen. Die gelbe Kurve zeigt die Markov-Obergrenze $E(Y)/a$, bei 100 % abgeschnitten. Weil sich die Erwartungswerte unterscheiden, ändert sich nun auch die Schranke.

Eine verteilungsfreie Schranke macht bereits Konsistenz sichtbar

Modell Abstand $k\sigma$ 1,96 σ

$$P(|X - E(X)| \geq k) \leq \frac{\sigma^2}{k^2}$$

$$P(|X - E(X)| \geq k\sigma) \leq \frac{1}{k^2}$$

Die zweite Zeile misst den Abstand in Standardabweichungen und folgt aus der ersten durch Einsetzen von $k\sigma$.

Normalverteilung: außerhalb 1,96 σ

Exakt: **5,00 %**Tschebyscheff höchstens: **26,03 %**

Die rote Fläche nutzt die konkrete Verteilung. Die Schranke 26,03 % gilt auch dann, wenn nur Erwartungswert und Varianz bekannt sind.


Brücke zum Gesetz der großen Zahlen

Für iid-Variablen gilt $\text{Var}(\bar{X}_n) = \sigma^2/n$. Deshalb folgt direkt

$$P(|\bar{X}_n - E(X_1)| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

Die Ungleichung beweist damit die Konsistenz des Stichprobenmittels.

Jensen überträgt die Definition von Konvexität auf Zufallsvariablen



Anwendung quadratischer Verlust

Streuung d 6

Von der Definition zu Jensen

$$g(tx_1 + (1-t)x_2) \leq tg(x_1) + (1-t)g(x_2)$$

Interpretiere t und $1-t$ als Wahrscheinlichkeiten. Dann ist links $g(E(X))$ und rechts $E(g(X))$. Für konkaves g dreht sich das Zeichen um.

Konvex: quadratischer Verlust

$$g(E[X]) \leq E[g(X)]$$

$$g(E[X]) = 100,000, \quad E[g(X)] = 136,000$$

Die vertikale Differenz 36,00 entspricht hier $\text{Var}(X) = d^2$.

Im Widget gilt

$P(X = 10 - d) = P(X = 10 + d) = 1/2$. Die gestrichelte Sekante enthält $E(g(X))$, die Kurve enthält $g(E(X))$. Jensen vergleicht genau diese beiden Punkte.

Normen messen Größe, Hölder kontrolliert Produkte, Minkowski Summen

WERKZEUG	AUSSAGE	STATISTISCHE INTUITION	TYPISCHE ANWENDUNG
L^p -Norm	$\ X\ _p = (E X ^p)^{1/p},$ $p \geq 1$	Eine Skala für die typische Größe von X . Größere p gewichten seltene große Abweichungen stärker.	$p = 1$: erwartete absolute Größe. $p = 2$: quadratische Größe $\sqrt{E(X^2)}$, <i>RMS</i> . Prüft, welche Momente endlich sind.
Hölder	$\ XY\ _1 \leq \ X\ _p \ Y\ _{q'},$ $p, q > 1, 1/p + 1/q = 1$	Ein großes Produkt verlangt, dass mindestens ein Faktor groß ist. Passende Einzelmomente kontrollieren daher $E XY $.	Zeigt die Existenz von Produkterwartungswerten, etwa bei gewichteten Beobachtungen oder Kovarianzen.
Cauchy–Schwarz	$ E(XY) \leq \ X\ _2 \ Y\ _2$	Der erwartete Gleichlauf kann nicht größer sein als die getrennten quadratischen Größen. Gleichheit verlangt, dass X und Y fast sicher proportional sind.	Nach Zentrierung: $ \text{Cov}(X, Y) \leq \sigma_X \sigma_Y$, also $ \text{Corr}(X, Y) \leq 1$.
Minkowski	$\ X + Y\ _p \leq \ X\ _p + \ Y\ _p,$ $p \geq 1$	Dreiecksungleichung für Zufallsfehler: Zwei Fehlerquellen können zusammen höchstens so groß sein wie ihre getrennten Größen addiert.	Begrenzt den L^p -Fehler einer Summe. Für $p = 2$ erhält man eine Schranke für den quadratischen Gesamtfehler.

Gemeinsames Bild: Zufallsvariablen verhalten sich in L^p wie Vektoren. Cauchy–Schwarz kontrolliert ihren Winkel beziehungsweise linearen Zusammenhang, Minkowski die Länge ihrer Summe.

Eine Statistik ist für jedes n zufällig, ihre Qualität soll mit n wachsen

Leitbeispiel

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

Aus Daten zu einer Zielgröße

Für jede Stichprobengröße entsteht ein neuer zufälliger Schätzer. Konvergenz beschreibt, ob und in welchem Sinn $\bar{X}_n$ an die Zielgröße $E(X_1)$ heranrückt.

Viele Schätzer sehen ähnlich aus

Relative Häufigkeiten, empirische Verteilungsfunktionen und Monte-Carlo-Integrale sind Mittelwerte geeigneter Funktionen $g(X_i)$. Viele kompliziertere Schätzer lassen sich zumindest näherungsweise auf solche Mittelwerte zurückführen.

Zwei getrennte Fragen

GGZ: Trifft der Schätzer langfristig die Zielgröße?

ZGWS: Welche Form und Breite hat die verbleibende Zufallsschwankung?

Ein einzelner beobachteter Wert kann nicht „konvergieren“. Konsistenz ist eine Eigenschaft der ganzen Schätzerfolge (T_n) .

Ein festes Ergebnis ω bestimmt einen ganzen Pfad

Definition eines Pfades

Alle Zufallsvariablen $Y_1, Y_2, \dots$ leben auf demselben Wahrscheinlichkeitsraum Ω . Nach dem Fixieren von ω bleibt eine gewöhnliche Zahlenfolge:

$$\omega \mapsto (Y_1(\omega), Y_2(\omega), Y_3(\omega), \dots)$$

Beispiel: fortlaufende Münzwürfe

Das Ergebnis $\omega = (1, 0, 1, 1, 0, \dots)$ enthält bereits die ganze unendliche Wurffolge.

n	1	2	3	4	5
$X_n(\omega)$	1	0	1	1	0
$\bar{X}_n(\omega)$	1,00	0,50	0,67	0,75	0,60

Beim Übergang von n zu $n + 1$ ziehen wir nicht alle Daten neu. Derselbe Pfad wird um eine weitere Beobachtung verlängert.

Beispiel: eine MCMC-Kette

$$\omega = (X_0, \xi_1, u_1, \xi_2, u_2, \dots)$$

Startwert, Vorschläge und Akzeptanzzahlen legen eine komplette Kette fest. Ein Traceplot zeigt genau einen solchen Pfad von links nach rechts.

Schritt t	0	1	2	3	4
Zustand X_t	0	1	1	0	1
Laufendes Mittel	0,00	0,50	0,67	0,50	0,60

Warum der Begriff gebraucht wird

Fast sichere Konvergenz fixiert ω und fragt, ob fast jede so entstehende Zahlenfolge konvergiert. Verschiedene Ergebnisse ω erzeugen verschiedene Pfade.

Stochastische Konvergenz erweitert die gewöhnliche Folgenkonvergenz

Aus Analysis: Konvergenz einer Zahlenfolge

$$x_n \longrightarrow x \iff \forall \varepsilon > 0 \exists N_\varepsilon \in \mathbb{N} \forall n \geq N_\varepsilon: |x_n - x| < \varepsilon$$

Leserichtung: Wähle eine beliebig kleine Toleranz ε . Dann gibt es einen von ε abhängigen Startindex N_ε , sodass *alle* $n \geq N_\varepsilon$ im ε -Schlauch um x bleiben.

Fast sicher

$$P\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1$$

Für fast jedes ω konvergiert die Zahlenfolge $X_n(\omega)$ im obigen Analysis-Sinn. Der Startindex $N_{\omega, \varepsilon}$ darf vom Pfad und von ε abhängen.

In Wahrscheinlichkeit

$$P(|X_n - X| > \varepsilon) \rightarrow 0 \quad \forall \varepsilon > 0$$

Der Anteil der Ergebnisse außerhalb des ε -Schlauchs geht gegen 0.

In Verteilung

$$F_{X_n}(x) \rightarrow F_X(x)$$

Die Verteilungsfunktionen konvergieren an allen Stetigkeitsstellen von F_X .

Im r -ten Moment, L^r

$$E(|X_n - X|^r) \rightarrow 0 \quad (r > 0)$$

Der mit $|\cdot|^r$ gewichtete mittlere Fehler verschwindet.

Das Grid trennt Pfadverhalten und Wahrscheinlichkeitsanteile

Beispiel Stichprobenmittel ↕ Spalte n 120 Toleranz ε 0,10

	1	2	5	10	20	40	80	120 ▼	160	200
Pfad A	1,00	0,50	0,40	0,40	0,50	0,53	0,55	0,53	0,58	0,54
Pfad B	0,00	0,00	0,00	0,30	0,50	0,43	0,49	0,52	0,47	0,46
Pfad C	0,00	0,50	0,20	0,30	0,40	0,50	0,55	0,61	0,58	0,58
Pfad D	0,00	0,50	0,60	0,50	0,60	0,70	0,66	0,63	0,60	0,58
Pfad E	1,00	0,50	0,40	0,30	0,40	0,35	0,39	0,40	0,43	0,44
Pfad F	1,00	0,50	0,60	0,40	0,55	0,55	0,50	0,53	0,50	0,51
Pfad G	0,00	0,50	0,60	0,50	0,70	0,58	0,51	0,49	0,49	0,50
Pfad H	1,00	1,00	0,80	0,60	0,65	0,55	0,45	0,46	0,45	0,45
Rot-Anteil $P(B_n)$	100 %	50 %	38 %	34 %	26 %	15 %	5,7 %	2,2 %	0,9 %	0,4 %

Spaltenfrage bei $n = 120$

2 von 8 gezeigten Pfaden sind rot. Über alle möglichen Ergebnisse beträgt der rote Anteil 2,2 %. Konvergenz in Wahrscheinlichkeit verlangt, dass dieser Anteil gegen 0 geht.

Zeilenfrage: Stichprobenmittel

Jeder Pfad verwendet dieselbe wachsende Stichprobe. Das starke GGZ sagt, dass fast jeder Mittelwertpfad die roten Bereiche irgendwann dauerhaft verlässt.

Beide Konvergenzarten gelten

Das Stichprobenmittel konvergiert fast sicher und damit auch in Wahrscheinlichkeit. Für klassische Inferenz interessiert meist die Spaltenaussage bei einem festen Stichprobenumfang.

Die relevante Konvergenz hängt von der beobachteten Richtung ab

1 · Fast sicher ist wichtig: MCMC

Wir führen meist eine konkrete Kette aus und beobachten einen Pfad. Für Schätzungen aus dieser Kette brauchen wir den ergodischen Grenzwert

$$\widehat{S}_t = \frac{1}{t} \sum_{s=1}^t g(X_s) \xrightarrow[t]{a.s.} E_{\pi}[g]$$

Konvergenz der Randverteilung $X_t \rightarrow \pi$ beantwortet dagegen die Burn-in-Frage.

2 · Fast sicher gilt, Wahrscheinlichkeit genügt

Für iid-Daten liefert das starke GGZ sogar

$$\bar{X}_n \xrightarrow{a.s.} \mu$$

In klassischer Inferenz betrachten wir aber einen festen Stichprobenumfang und mögliche Stichproben dieser Größe. Konsistenz in Wahrscheinlichkeit, Raten und Grenzverteilungen beantworten diese Spaltenfrage. Die stärkere Pfadaussage liefert keinen Standardfehler für das beobachtete n .

3 · Wahrscheinlichkeit gilt, fast sicher nicht


Jede Woche läuft eine unabhängige Studie unter einer wahren Nullhypothese. Sei Y_n der Fehlalarmindikator und $\alpha_n = 1/n$.

$$P(Y_n = 1) = \frac{1}{n} \rightarrow 0 \quad \Rightarrow \quad Y_n \xrightarrow{P} 0$$

Weil $\sum_n 1/n = \infty$, treten nach Borel–Cantelli II mit Wahrscheinlichkeit 1 unendlich viele Fehlalarme auf. Daher keine fast sichere Konvergenz.

Brücke zur fast sicheren Konvergenz: Aus $\sum_n P(|Y_n - Y| > \varepsilon) < \infty$ folgt nach Borel–Cantelli I, dass rote Felder in fast jeder Zeile irgendwann dauerhaft verschwinden. Bei Testniveaus $\alpha_n = 1/n^2$ wäre diese Summe endlich.

Stärkere Aussagen liefern schwächere, die Pfeile laufen selten zurück



Moment impliziert Wahrscheinlichkeit

$$P(|X_n - X| > \varepsilon) \leq \frac{E|X_n - X|^r}{\varepsilon^r}$$

Markov übersetzt einen kleinen mittleren Fehler in einen kleinen roten Anteil.

Keine automatische Umkehrung

Konvergenz in Wahrscheinlichkeit muss weder fast sicher noch im r -ten Moment gelten. Fast sichere und Momentenkonvergenz implizieren sich ebenfalls nicht gegenseitig.

Spezialfall: konstanter Grenzwert

Die Verteilung des konstanten Grenzwerts c ist die Dirac-Verteilung δ_c . Anschaulich schreiben wir

$$T_n \xrightarrow{D} \delta_c \iff T_n \xrightarrow{P} c$$

Präzise bedeutet die linke Seite $\mathcal{L}(T_n) \Rightarrow \delta_c$: Die Verteilungen konvergieren gegen die gesamte Masse im Punkt c .

Gleiche Histogramme bedeuten nicht, dass zwei Variablen nahe beieinander liegen

Zwei unabhängige faire Würfel

Sei Y ein Würfelwurf und Y_n für jedes n ein unabhängiger neuer Würfelwurf.

$$Y_n \xrightarrow{D} Y$$

Die Verteilungen sind sogar für jedes n exakt gleich.

Aber nicht nahe

$$P(|Y_n - Y| > 0,5) = P(Y_n \neq Y) = \frac{5}{6}$$

Dieser Wert schrumpft nicht. Also keine Konvergenz in Wahrscheinlichkeit.

Was fehlt?

Konvergenz in Wahrscheinlichkeit braucht die gemeinsame Verteilung des Paares (Y_n, Y) . Verteilungskonvergenz betrachtet nur die einzelnen Randverteilungen.

Typischer Fehlschluss

Aus „die CDFs werden gleich“ folgt nicht „ $Y_n - Y$ wird klein“.

Diese Gegenidee stammt aus der Zeilen-vs.-Spalten-Intuition der ergänzenden Konvergenznotizen und bleibt vollständig innerhalb der Kursdefinitionen.

Stichprobenmittel stabilisieren sich beim theoretischen Erwartungswert

Hauptaussage

$$\begin{aligned} X_i \text{ iid, } E|X_1| < \infty \\ \bar{X}_n &\xrightarrow{a.s.} E(X_1) \\ \bar{X}_n &\xrightarrow{P} E(X_1) \end{aligned}$$

In Worten

Viele unabhängige Beobachtungen mitteln Zufallsschwankungen heraus. Der Mittelwert trifft langfristig den Erwartungswert der Grundverteilung, wenn dieser existiert.

Das GGZ liefert weder eine Geschwindigkeit noch eine Normalapproximation. Dafür wird anschließend der ZGWS benötigt.

Der einfache Beweisweg im Kurs

Unter der stärkeren Annahme $\text{Var}(X_1) = \sigma^2 < \infty$ gilt

$$\begin{aligned} \text{Var}(\bar{X}_n) &= \frac{\sigma^2}{n} \\ P(|\bar{X}_n - \mu| \geq \varepsilon) &\leq \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0 \end{aligned}$$


Tschebyscheff beweist direkt Konvergenz in Wahrscheinlichkeit.

Randnotiz zur Vorlesung

Die Vorlesung unterscheidet schwaches und starkes GGZ. Das schwache Gesetz lässt sich mit Tschebyscheff sehr einfach beweisen, verlangt in dieser Version aber unnötig viel: Die Varianz muss existieren. Das starke Gesetz kommt bei iid-Folgen bereits mit $E|X_1| < \infty$ aus.

Für viele statistische Anwendungen genügt trotzdem Konvergenz in Wahrscheinlichkeit, weil wir bei einem festen n über mögliche Stichproben und nicht über einen beobachteten unendlichen Pfad sprechen.

Die relative Häufigkeit ist ein konsistenter Schätzer für p



Neu sampeln

Mit $\sqrt{n}$ skalieren**n = 500**

$$X_i \sim \text{Bern}(0, 35), \quad \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \longrightarrow 0,35$$

Auf der Originalskala markiert der transparente Bereich $0,35 \pm \varepsilon$ mit $\varepsilon = 0,05$. Beim Umschalten wird derselbe Schlauch mit $\sqrt{n}$ skaliert.

18 Pfade bei n = 500


18 von 18 liegen im ε -Schlauch.

Endwerte: **0,316 bis 0,398**

Neu sampeln erzeugt andere Ergebnisse ω aus demselben Modell.

Das GGZ sagt keine monotone Annäherung voraus. Die Skalierung zeigt zusätzlich die Restschwankung $\sqrt{n}(\bar{X}_n - p)$, die nicht gegen 0 zusammengedrückt wird.

Fast jeder Spieler verliert, obwohl der Erwartungswert wächst

Skala ↕Betrachtete Runde

Spielregel

$$Y_n = \prod_{t=1}^n M_t, \quad M_t = \begin{cases} 1,5 & \text{mit } 1/2 \\ 0,6 & \text{mit } 1/2 \end{cases}$$

Runde 100

Über Startkapital: **6 von 30 Pfaden**Typischer Wert: **0,01**Erwartungswert: **132**Exakt $P(Y_n \geq 1)$: **13,56 %**

Auf der Log-Skala werden die negative typische Drift und die seltenen Gewinner gleichzeitig sichtbar.

Das GGZ auf der richtigen Skala

$$\frac{1}{n} \log Y_n \xrightarrow{a.s.} E(\log M) = \frac{1}{2} \log(0,9) < 0$$

Darum gilt $Y_n \xrightarrow{a.s.} 0$ und folglich auch $Y_n \xrightarrow{P} 0$.
Gleichzeitig ist $E(Y_n) = 1,05^n \rightarrow \infty$, also gibt es keine L^1 -Konvergenz gegen 0.

Bei iid-Cauchy-Daten gibt es kein Zielzentrum für den Mittelwert

Voraussetzung scheitert

$$E(|X_1|) = \infty$$


Damit ist weder der inhaltliche Zielwert $E(X_1)$ definiert noch das GGZ anwendbar.

Noch stärker

Für standard-Cauchy X_i ist auch jeder Mittelwert wieder standard-Cauchy verteilt:


$$\bar{X}_n \sim \text{Cauchy}(0, 1)$$

Die Verteilung wird überhaupt nicht schmaler.



Vor jedem GGZ: Existiert $E|X_1|$? Symmetrie allein reicht nicht.

Der ZGWS macht den verbleibenden Schätzfehler berechenbar

Ausgangsverteilung Stichprobengröße n

Zentraler Grenzwertsatz

Sind $X_1, X_2, \dots$ iid mit $E(X_1) = \mu$ und $0 < \text{Var}(X_1) = \sigma^2 < \infty$, dann

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{D} N(0, 1).$$

Intuition: Das GGZ zieht $\bar{X}_n$ zum Erwartungswert. Der ZGWS vergrößert den verbleibenden Fehler mit $\sqrt{n}$ und zeigt seine asymptotische Glockenform. Daraus entstehen Standardfehler, Konfidenzintervalle und Tests.

Für endliches n liefert der Satz eine Approximation. Eine multivariate Version gilt auch für Zufallsvektoren und führt zu mehrdimensionalen Normalverteilungen.

Das Zentrum wächst bei Summen mit n , die Streuung nur mit $\sqrt{n}$

Summe $S_n = \sum X_i$

$$E(S_n) = n\mu$$

$$\text{Var}(S_n) = n\sigma^2$$

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{D} N(0, 1)$$

Approximation: $S_n \approx N(n\mu, n\sigma^2)$.

Mittelwert $\bar{X}_n = S_n/n$

$$E(\bar{X}_n) = \mu$$

$$\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}$$

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{D} N(0, 1)$$

Approximation: $\bar{X}_n \approx N(\mu, \sigma^2/n)$.

Zwei häufige Fehler: Bei der Summe durch $\sigma^2\sqrt{n}$ teilen statt durch $\sigma\sqrt{n}$. Beim Mittelwert σ verwenden statt des **Standardfehlers** $\sigma/\sqrt{n}$ — der inferenzstatistisch relevanten Streuung des Schätzers.

Sechs Entscheidungen führen vom Text zur Normalwahrscheinlichkeit

- 1 Grundvariable festlegen.** Was bedeutet ein X_i ? Wertebereich, μ , σ^2 .
- 2 Voraussetzungen prüfen.** iid, endliche Varianz, n ausreichend für die Form.
- 3 Zielgröße wählen.** Summe S_n oder Mittelwert $\bar{X}_n$. Ereignis exakt formulieren.
- 4 Zusatz: Stetigkeitskorrektur.** Bei einer ganzzahligen Summe können Grenzen um 0,5 korrigiert werden. Für die GOP wird dieser Schritt nicht verlangt.
- 5 Standardisieren.** Jede Grenze mit $z = \frac{\text{Zielgröße} - E(\text{Zielgröße})}{\text{Standardabweichung}(\text{Zielgröße})}$.
- 6 Mit Φ auswerten.** Links: $\Phi(z)$. Rechts: $1 - \Phi(z)$. Intervall: $\Phi(z_o) - \Phi(z_u)$. Falls nur positive Tabellenwerte vorliegen, hilft die Symmetrie $\Phi(z) = 1 - \Phi(-z)$.

Plausibilitätskontrolle

Liegt eine obere Grenze über dem Zentrum, muss ihr z -Wert positiv sein. Eine symmetrische $k\sigma$ -Umgebung hat zwei gleich große Tails.

Approximation sichtbar markieren

Schreibe $\approx$, nicht $=$. Bei starker Schiefe oder seltenen Bernoulli-Erfolgen kann ein viel größeres n nötig sein.

Blick ins nächste Semester

Heute berechnen wir Wahrscheinlichkeiten bei bekanntem μ . In der Inferenz wird die Richtung umgedreht: Aus dem beobachteten $\bar{X}_n$ und seinem Standardfehler wird ein plausibler Bereich für das unbekannte μ .

Gegebene Φ -Werte machen die letzte Zeile zur reinen Übersetzung

Aufgabe

100 unabhängige Bestellungen besitzen Warenwerte mit $\mu = 24\text{€}$ und $\sigma = 12\text{€}$. Approximiere $P(S_{100} \leq 2600\text{€})$.

1–3 · Modell und Ziel

X_i : Wert einer Bestellung. iid und endliche Varianz seien gegeben. Zielgröße ist die Summe.

$$E(S_{100}) = 2400, \quad \text{SD}(S_{100}) = 12\sqrt{100} = 120$$

4–5 · Stetig und standardisieren

Keine Stetigkeitskorrektur.

$$z = \frac{2600 - 2400}{120} = 1,67$$

6 · Gegebener Tabellenwert

Gegeben sei $\Phi(1,67) = 0,9525$.

$$P(S_{100} \leq 2600) \approx \Phi(1,67) = 0,9525$$

Etwa 95,25 % der Tage bleiben unter 2600€ Gesamtwert.

Die Einzelwerte müssen nicht normalverteilt sein. Der ZGWS begründet die approximative Normalverteilung der Summe.

Beim Mittelwert wird mit dem Standardfehler standardisiert

Aufgabe

64 unabhängige Abfüllmengen besitzen den Erwartungswert $\mu = 500$ ml und die Standardabweichung $\sigma = 8$ ml. Approximiere $P(\bar{X}_{64} \leq 501,5)$.

1–3 · Modell und Ziel

X_i : Abfüllmenge einer Flasche. iid und endliche Varianz seien gegeben. Zielgröße ist der Mittelwert.

$$E(\bar{X}_{64}) = 500, \quad \text{SD}(\bar{X}_{64}) = \frac{8}{\sqrt{64}} = 1$$

4–5 · Stetig und standardisieren

Keine Stetigkeitskorrektur.

$$z = \frac{501,5 - 500}{1} = 1,5$$

6 · Gegebener Tabellenwert

Gegeben sei $\Phi(1,5) = 0,9332$.

$$P(\bar{X}_{64} \leq 501,5) \approx \Phi(1,5) = 0,9332$$

Etwa 93,32 % der Stichprobenmittel liegen höchstens bei 501,5 ml.

Die Einzelstreuung beträgt 8 ml. Für den Mittelwert zählt der Standardfehler $8/\sqrt{64} = 1$ ml.

Der Standardfehler macht die 1σ -, 2σ - und 3σ -Regel direkt nutzbar

Abfüllmenge mit $\mu = 500$ ml und $\sigma = 12$ ml, $n = 36$. Dann gilt approximativ $\bar{X}_{36} \sim N(500, 2^2)$, denn $\sigma/\sqrt{n} = 2$ ml.

Innerhalb von 1 Standardfehler

$$498 \leq \bar{X} \leq 502$$

68,27 %

$$\Phi(1) - \Phi(-1)$$

Innerhalb von 2 Standardfehlern

$$496 \leq \bar{X} \leq 504$$

95,45 %

$$\Phi(2) - \Phi(-2)$$

Innerhalb von 3 Standardfehlern

$$494 \leq \bar{X} \leq 506$$

99,73 %

$$\Phi(3) - \Phi(-3)$$

Hier bedeutet „ σ “ in der 68-95-99,7-Regel die Standardabweichung der approximierenden Größe. Beim Mittelwert ist das $\sigma/\sqrt{n}$, nicht die Einzelstreuung σ .

Zeile liefert die erste Dezimalstelle, Spalte die zweite

z	0,00	0,01	0,02	0,03	0,04	0,05
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115

Beispiel

$z = 1,23$: Zeile 1,2, Spalte 0,03. Daher $\Phi(1,23) = 0,8907$.

Drei Übersetzungen

$$P(Z \leq 1,23) = \Phi(1,23) = 0,8907$$

$$P(Z > 1,23) = 1 - 0,8907 = 0,1093$$

$$P(Z \leq -1,23) = 1 - \Phi(1,23) = 0,1093$$

Intervall

$$P(a \leq Z \leq b) = \Phi(b) - \Phi(a)$$

Prüfe zuerst, welche Tabelle vorliegt. Im Bootcamp verwenden wir die kumulative Tabelle $\Phi(z) = P(Z \leq z)$, nicht die Fläche zwischen 0 und z .

Eine diskrete Zähleinheit entspricht einem Intervall der Breite 1

Summenskala

Für $Y \sim \text{Bin}(200, 0,4)$ gilt $E(Y) = 80$ und $SD(Y) = \sqrt{48} = 6,93$.

$$\begin{aligned} 70 \leq Y \leq 90 &\leadsto 69,5 \leq Y^* \leq 90,5 \\ z_u = -1,52, &\quad z_o = 1,52 \end{aligned}$$

Warum $\pm 0,5$?

Der Balken der ganzen Zahl 70 belegt auf der kontinuierlichen Achse das Intervall von 69,5 bis 70,5. Die Korrektur gibt den Balken ihre volle Breite zurück.

Mittelwert- oder Anteilsskala

Für $\bar{X} = Y/200$ wird die halbe Zähleinheit durch n geteilt.


$$Y \leq 90 \leadsto \bar{X}^* \leq \frac{90,5}{200} = 0,4525$$

$$SD(\bar{X}) = \sqrt{\frac{0,4 \cdot 0,6}{200}} = 0,03464$$

Nur Zusatz

Die Stetigkeitskorrektur wird in der GOP nicht verlangt. Ohne Korrektur bleibt der ZGWS-Rechenweg derselbe. Falls sie verwendet wird: zuerst die Grenze auf der Zählkala korrigieren, danach standardisieren.

Die empirische Verteilungsfunktion nähert sich der Grundverteilung überall zugleich



Stichprobengröße 50

Neu sampeln

Satz von Glivenko–Cantelli

Für iid $X_1, X_2, \dots$ mit Verteilungsfunktion F und

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}\{X_i \leq x\}$$

gilt

$$\sup_{x \in \mathbb{R}} |F_n(x) - F(x)| \xrightarrow{a.s.} 0.$$

Intuition

Für jeden Schwellenwert x ist $F_n(x)$ eine relative Häufigkeit. Der Satz sagt mehr als punktweise Konvergenz: Der größte vertikale Abstand über *alle* Schwellen verschwindet.

Brücke zu Woche 1: Die empirische Verteilungsfunktion beschreibt die beobachtete Stichprobe. Glivenko–Cantelli rechtfertigt, warum sie mit wachsendem n die unbekannte Verteilungsfunktion als Ganzes schätzt.

Der Aufgabentext verrät, welches Grenzwertwerkzeug passt

„Langfristig nahe am Erwartungswert“

Stichprobenmittel oder relative Häufigkeit, iid und Moment prüfen. Dann GGZ.

„Approximiere eine Wahrscheinlichkeit“

Summe oder Mittelwert, iid und endliche Varianz. Dann ZGWS, standardisieren und mit Φ auswerten.

„Schätze die gesamte Verteilungsfunktion“

Empirische Verteilungsfunktion aus einer iid-Stichprobe. Dann liefert Glivenko–Cantelli gleichmäßige Konsistenz.

„Garantierte Schranke, Verteilung unbekannt“

Nichtnegative Variable: Markov. Abstand vom Erwartungswert und Varianz bekannt: Tschebyscheff.

Vier Kontrollen vor dem Ergebnis

- Voraussetzungen genannt?
- Summe und Mittelwert nicht verwechselt?
- Approximation mit $\approx$ markiert?
- Ergebnis zwischen 0 und 1 und Richtung plausibel?

Minimaler Lösungsstart: Modell und Zielgröße, passende Voraussetzung, Satz, Standardisierung, Interpretation.

Der Stoff ist abgeschlossen — jetzt wird daraus Klausurroutine

Noch bis zur GOP

7 Tage

Genug Zeit für gezieltes Wiederholen,
nicht für planloses Neulernen.

Stofflich abgedeckt

100 %

Statistik 1 und 2 sind im Bootcamp
vollständig einmal eingeordnet worden.

Was noch verbleibt

Aufgaben im Stil der GOP
Altklausuren unter Zeitdruck
Cheat-Sheet verdichten und testen

Ab jetzt zählt: selbst rechnen, Fehlerbilder erkennen und sichere Einstiege automatisieren.

Und nächstes Semester wird aus diesen Zufallsmodellen Inferenz: Schätzen, Konfidenzintervalle und Testen.

Aufgabe 1 und 2 trainieren denselben maßtheoretischen Ablauf

Klausur Deskriptive Statistik und Wahrscheinlichkeitstheoretische Grundlagen
GOP-Training 2026

Aufgabe 1 (15 Punkte)
 Sei $\Omega = \{a, b, c, d, e, f, g\}$. Es seien

$$A = \{a, b, c, d\}, \quad B = \{c, d, e\}, \quad \mathcal{F} = \sigma(\{A, B\}).$$

Jedem Ergebnis werde das Gewicht

$$(w_a, w_b, w_c, w_d, w_e, w_f, w_g) = (1, 1, 2, 2, 3, 0, 0)$$

zugeordnet. Für $C \in \mathcal{F}$ sei $\mu(C) = \sum_{\omega \in C} w_\omega$.

(a) Geben Sie $\mathcal{F}$ vollständig an. [4]

(b) Zeigen Sie, dass μ ein Maß auf $(\Omega, \mathcal{F})$ ist. [9]

Seite 1

Klausur Deskriptive Statistik und Wahrscheinlichkeitstheoretische Grundlagen
GOP-Training 2026

Aufgabe 2 (14 Punkte)
 Eine Schachtel enthält die fünf Lose

$$\Omega_1 = \{R_1, R_2, B_1, B_2, G_1\}.$$

Der Buchstabe bezeichnet die Farbe des Loses. Die Abbildung $f: \Omega_1 \rightarrow \Omega_2$ mit $\Omega_2 = \{R, B, G\}$ ordnet jedem Los seine Farbe zu. Auf Ω_1 sei das Wahrscheinlichkeitsmaß P durch

$$P(\{R_1\}) = P(\{R_2\}) = \frac{1}{8}, \quad P(\{B_1\}) = \frac{1}{4}, \quad P(\{B_2\}) = \frac{1}{8}, \quad P(\{G_1\}) = \frac{3}{8}$$

gegeben.

(a) Geben Sie die Abbildung f vollständig an. [2]

(b) Bestimmen Sie $\mathcal{G} = \sigma(\{f(R, B)\})$ über Ω_2 . [2]

(c) Bestimmen Sie das Mengensystem

$$f^{-1}(\mathcal{G}) := \{f^{-1}(D) : D \in \mathcal{G}\}.$$

Zeigen Sie kurz, dass diese eine σ -Algebra über Ω_1 ist. [9]

Seite 3

Aufgabe 1 · Gewichtsmaß · 15 Punkte

Erzeugte σ -Algebra $\sigma(\{A, B\})$ vollständig angeben, Maßeigenschaft nachweisen, Nullmengen bestimmen, ein Maßintegral berechnen und zuletzt eine Dichte normieren.

Aufgabe 2 · Bild und Urbild · 14 Punkte

Erzeugte σ -Algebra im Bildraum, das Urbildsystem $f^{-1}(\mathcal{G})$ samt Nachweis, Messbarkeit begründen und das Bildmaß P_f angeben.

Gemeinsamer Kern

Erzeuger notieren $\rightarrow$ disjunkte Atome bilden $\rightarrow$ alle Vereinigungen zählen $\rightarrow$ erst danach Maß, Integral oder Dichte rechnen.

Aufgabe 1 und 2 führen von der gemeinsamen Dichte zum Grenzwertsatz

Zufallsvektoren und Grenzwertwerkzeug GOP-Training 2026

Aufgabe 1 (33 Punkte)
 In einem Fertigungsprozess durchläuft ein Werkstück eine Zwischenkontrolle und eine Endkontrolle. Die Bearbeitungsdauer sei auf das Intervall $(0, 1)$ normiert. Es bezeichne X den Zeitpunkt der Zwischenkontrolle und Y den Zeitpunkt der Endkontrolle. Der Zufallsvektor (X, Y) besitzt die Dichte

$$f_{X,Y}(x, y) = \begin{cases} c(x+y), & 0 < x < y < 1, \\ 0, & \text{sonst.} \end{cases}$$

(a) Bestimmen Sie c . [3]

(b) Bestimmen Sie die Randdichten f_X und f_Y . Welche bekannte parametrische Verteilung besitzt Y , und mit welchen Parametern? [6]

(c) Bestimmen Sie $f_{X|Y=y}$ und $E(X | Y = y)$ für $0 < y < 1$. [5]

Seite 1

Zufallsvektoren und Grenzwertwerkzeug GOP-Training 2026

Aufgabe 2 (23 Punkte)
 Ein Kurierdienst benötigt für eine Sendung eine Rüstzeit X und anschließend eine Fahrzeit Y , jeweils in Stunden. Es gelte

$$X \sim U(0, 1), \quad Y \sim \text{Exp}(1),$$

und X und Y seien stochastisch unabhängig. Die gesamte Lieferzeit ist $S = X + Y$. [2]

(a) Geben Sie die Erwartungswerte und Varianzen von X und Y an. [2]

(b) Bestimmen Sie die Dichte von S vollständig. Begründen Sie insbesondere die von s abhängigen Integrationsgrenzen. [8]

(c) Geben Sie $E(S)$ und $\text{Var}(S)$ an, ohne die in (b) gefundene Dichte zu integrieren. Begründen Sie die verwendeten Rechenregeln. [3]

Seite 4

Aufgabe 1 · Fertigungsprozess · 33 Punkte

Normierungskonstante, beide Randdichten, bedingte Dichte mit $E(X | Y = y)$, Momente und Kovarianz – zum Schluss eine Indikatorsumme über den zentralen Grenzwertsatz.

Aufgabe 2 · Lieferzeit · 23 Punkte

Faltung von $U(0, 1)$ und $\text{Exp}(1)$ mit begründeten Grenzen, Momente ohne Integration und ein Stichprobenumfang einmal per Tschebyscheff, einmal per Grenzwertsatz.

Gemeinsamer Kern

Träger klären → Rand- oder Faltungsdichte → Momentregeln statt Integralen → Grenzwertwerkzeug aus dem Aufgabentext ableiten.

Gezielt trainierbare Standardblöcke tragen 82,4 % der GOP-Punkte

HEBEL	PUNKTE IN 5 GOPS	IM BOOTCAMP	SCHWIERIGKEIT
Grafikaufgabe	101	Woche 1	Interpretation und Zeit
Wahrscheinlichkeit, Kontingenz & Diagnostik	83	Woche 1–2	Lange Texte und Rechenfehler
Dichte, VF & Transformation	127	Woche 2–3	Unsauber/Unvollständig
Maßtheorie	62	Woche 4	Angst und Stress
Zufallsvektoren & Konvergenz	143	Woche 3 & 5	Schwierigkeit und Mustererkennung

Die Punkte sind disjunkt gezählt: Eine Teilaufgabe erscheint nie in zwei Hebeln.

Vier eng umrissene Blöcke

373 / 626 = 59,6 %

Sehr stabile äußere Form: große Grafik, Diagnostik/Kontingenz, univariate Dichteaufgabe und Maßtheorie.

Fünfter, breiterer Hebel

+ 143 P = +22,8 Prozentpunkte

Gemeinsame und bedingte Verteilungen, Kovarianzmatrizen, hierarchische Modelle sowie GGZ/ZGWS.

Trainierbares Standardportfolio

516 / 626 = 82,4 %

Aufgabentyp und Lösungsbaukasten sind planbar – Erkennen und saubere Ausführung bleiben Klausurleistung.

Rund 88 % sind vorhersehbar – aber neue Varianten bleiben

Leave-One-Out-Ergebnis

550 / 626 = 87,9 %

Jede GOP wird einmal zurückgehalten. Ein Punkt zählt nur, wenn sein konkreter Lösungsbaustein in mindestens einer der anderen vier GOPs vorkam.

Vorhersehbarer Anteil je Test-GOP

SOSE 22	WISE 22/23	SOSE 23	SOSE 24	SOSE 25
86,7 %	97,8 %	90,4 %	81,5 %	81,7 %

Was steckt in den übrigen 12,1 %?

76 Punkte aus neuen Spezialvarianten, Transferaufgaben und Beweisen – meist keine komplett neue Themenwelt.

Einordnung: Das misst Strukturstabilität, keine Zeitprognose und keine Punktegarantie.

Plausible GOP-Wildcards

- Operationalisierung & Studiendesigns
- Robuste Kennwerte & Konzentration
- Gamma-, χ^2 -, Cauchy- & hypergeometrische Verteilung
- Bedingte Varianz & bedingte Unabhängigkeit
- Kausale Graphen & Selektionsfehler
- Alternative Zusammenhangsmaße
- **Hazardrate und Survivorfunktion**
- **Charakteristische Funktionen**
- **Weitere Konvergenzarten und Slutsky**
- **Markov-Ketten und Copulas**

Rot = zusätzliche Restlücke

Diese Themen kamen in keiner der fünf GOPs vor und werden auch im Bootcamp nicht behandelt.

Strategie

Zuerst die wiederkehrenden 88 % automatisieren. Wildcards danach als kompakte Transferreserve absichern.

Wie fielen die bisherigen Klausurergebnisse aus?

GOP SoSe 2025 Ansicht Empirische Verteilungsfunktion

Das 50%-Quantil ist der Median der erzielten Punkte – nicht 50 % der Maximalpunktzahl.

Ausgewertete Klausuren

n = 272


50%-Quantil

40,8 % · 49 P.

Bestehensgrenze

50,0 % · 60 P.

Bestanden

18,8 % · 51/272

50 % der Maximalpunkte und Bestehensgrenze fallen zusammen.

Quelle: s25_Stat2_WTG Bewertungen.ods